



실력완성!!

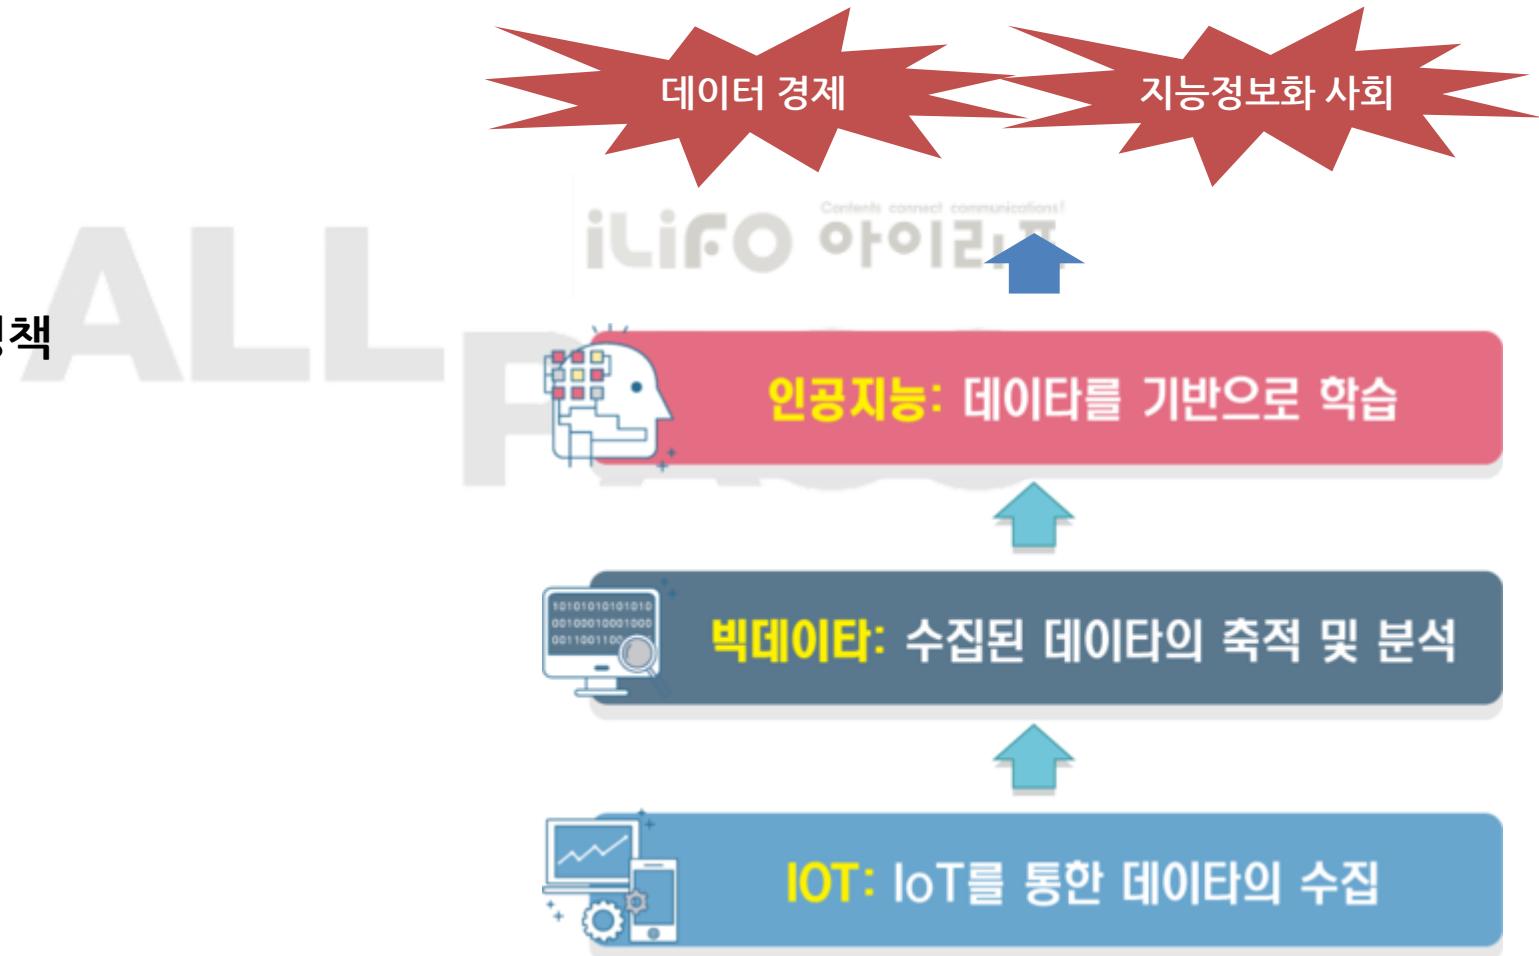
데이터 / 인공지능

(V2.1)

김미경 정보관리기술사, 김은진 정보관리기술사
(mayching1106@naver.com)

목차

- 통계
- 데이터마이닝
- 인공지능
- 인공신경망
- 인공지능 주요 정책
- 인공지능 보안





통계

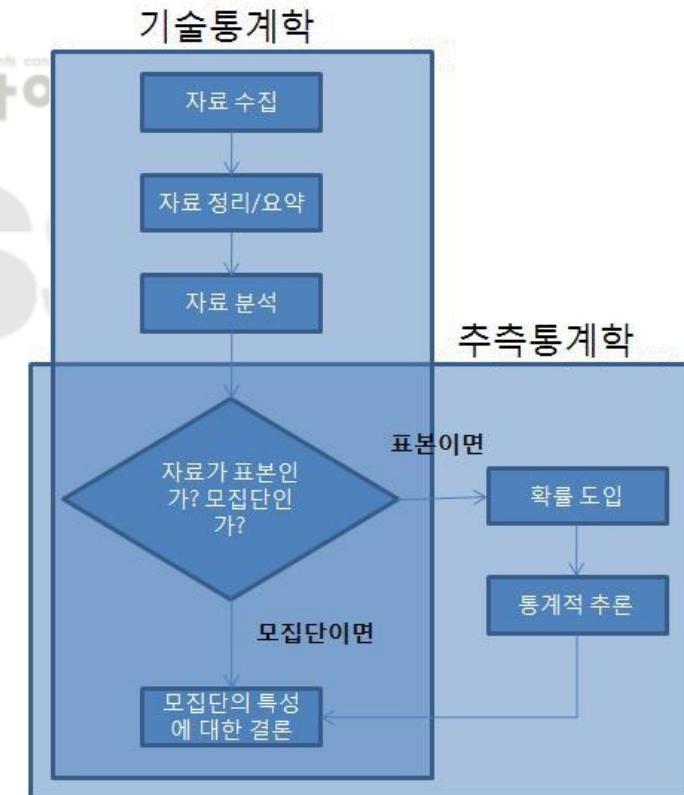
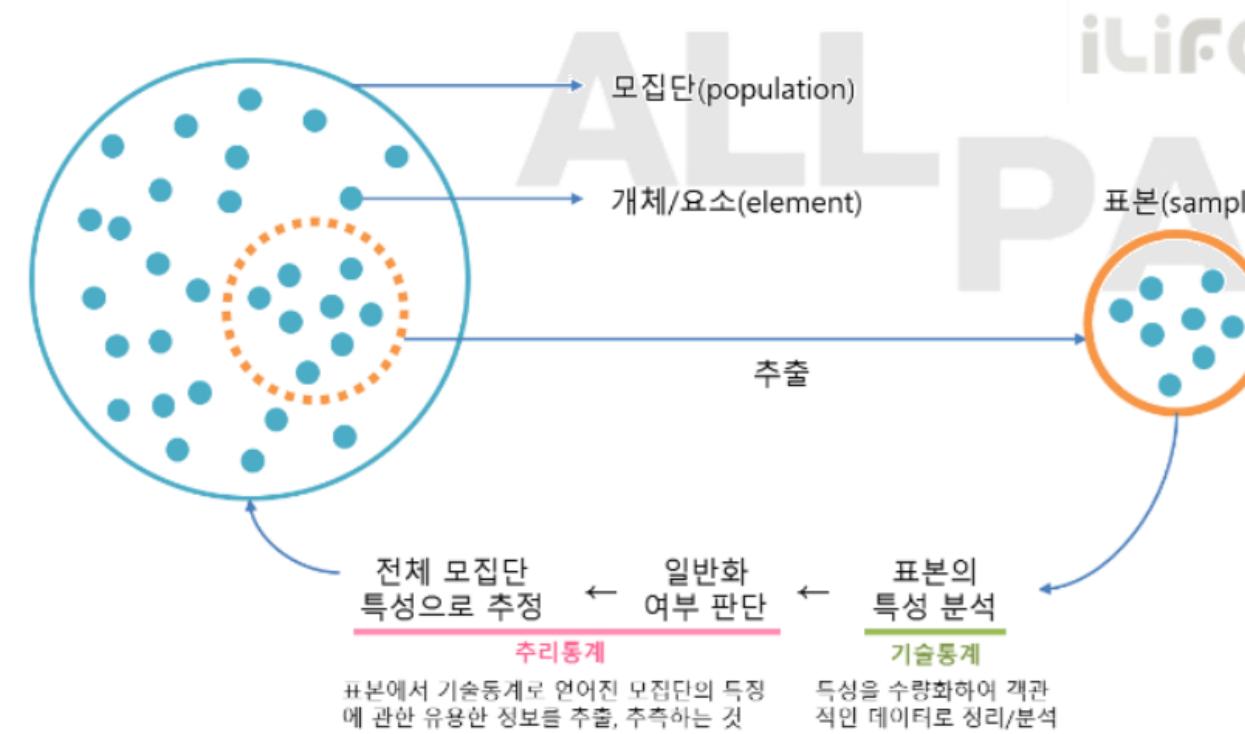
기술통계, 추론통계 (추리통계)

1. 기술통계(descriptive statistics) : 수집된 **자료의 특성**을 나타내도록 **표, 그림, 평균 등의 값을 구하는 통계 기법**

- 기술통계는 추론통계의 기초작업을 수행하기 위한 과정
- 주요내용> 평균값 (mean), 중위수 (median), 최빈수 (mode), 최대값, 최소값, 범위 (range), 분산 (variance), 표준편차 (standard deviation) 등

2. 추론통계(inferential statistics) or 추리통계 : 전체 모집단을 분석하지 않고, **표본을 추출**하여 모집단의 특성을 **추정하고, 신뢰성을 검정하는 통계 기법**

- 주요내용> 표본, 확률, 가설검정…



통계 기본 - 평균, 분산, 표준편차

- 평균(mean) : 데이터의 총합을 표본의 크기로 나눈 값
- 중앙값(median) : n개의 관찰값을 이등분해 주는 값
- 최빈값(mode) : 데이터 중에서 발생빈도가 가장 높은 값
- 분산(variance) : 관찰값과 평균의 차이(잔차)의 제곱의 평균
- 표준편차(standard deviation) : 분산의 제곱근, 평균으로부터 관찰값까지의 평균거리

산술평균

$$\bar{x} = \frac{1}{n} \cdot \sum_{i=1}^n x_i$$

기하평균

$$\bar{x} = \sqrt[n]{\prod_{i=1}^n x_i}$$

곱의 n제곱근
예) 34, 27, 45, 55, 22, 34의 기하 평균은 $(34 \times 27 \times 45 \times 55 \times 22 \times 34)^{1/6}$
→ ex. 성장을 평균을 구할 때 많이 사용

분산

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (X_i - \mu)^2$$

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

조화평균


$$\bar{x} = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$$


(역수의 산술평균)의 역수
→ ex. 평균 속력을 구할 때 사용
→ ex. F1 Score (분류모델성과평가지표)

$$(F1-score) = 2 \times \frac{1}{\frac{1}{Precision} + \frac{1}{Recall}}$$

표준편차

모 표준편차

$$\sigma = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^2}{N}}$$

표본 표준편차

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}$$

중앙값

n이 홀수인 경우 :

$$M_e = X \left(\frac{n+1}{2} \right)$$

n이 짝수인 경우 :

$$M_e = \frac{X \left(\frac{n}{2} \right) + X \left(\frac{n+1}{2} \right)}{2}$$

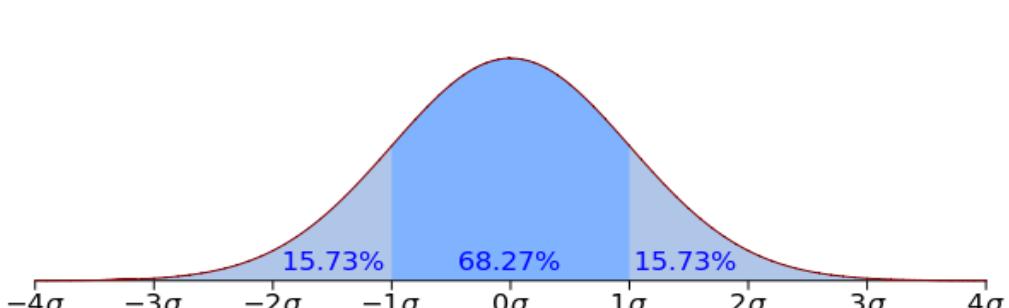
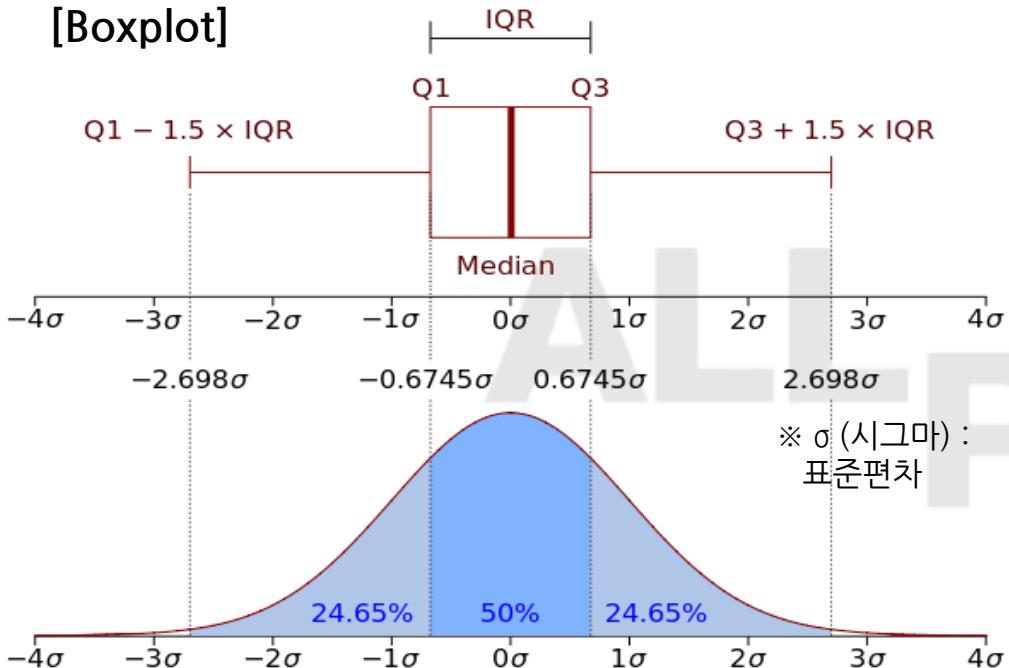
※ N: 모집단개수, μ : 모평균, n: 표본개수, \bar{x} : 표본평균

통계 기본 - 사분위수 범위

1. 사분위수 범위(IQR, Inter Quartile Range)의 개요

- 정의 : 데이터의 분포에서 75percentile(3Q, 3사분위)과 25Percentile(1Q, 1사분위) 간의 거리(Q3-Q1)
- 활용 : 자료의 퍼짐과 이상치를 가시적 확인, Boxplot에 표현 가능

[Boxplot]



사분위수	설명
제 1 사분위수 (Q1)	데이터의 25%가 이 값보다 작거나 같음.
제 2 사분위수 (Q2)	중위수 데이터의 50%가 이 값보다 작거나 같음.
제 3 사분위수 (Q3)	데이터의 75%가 이 값보다 작거나 같음.
사분위수 범위 (IQR=Q3-Q1)	제1사분위수와 제3사분위수 간의 거리(Q3-Q1) 이므로, 데이터의 중간 50%에 대한 범위

통계 기본 - 왜도, 첨도

1. 왜도(Skewness): 데이터의 분포가 평균을 중심으로 얼마나 대칭형인지를 나타내는 측도
2. 첨도(kurtosis): 정규분포 대비 데이터 분포도가 얼마나 뾰족하지를 나타내는 측도

왜도(Skewness)

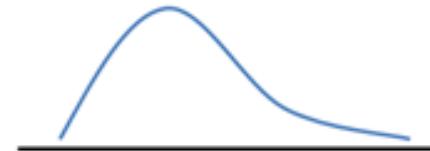


Negative Skew ($S < 0$)

왼쪽으로 긴 꼬리

오른쪽으로 치우친 분포

예) 시험성적 분포



Positive Skew ($S > 0$)

오른쪽으로 긴 꼬리

왼쪽으로 치우친 분포

예) 소득자료

첨도(kurtosis)



Negative Kurtosis ($K < 0$)

정규분포보다 납작한 분포



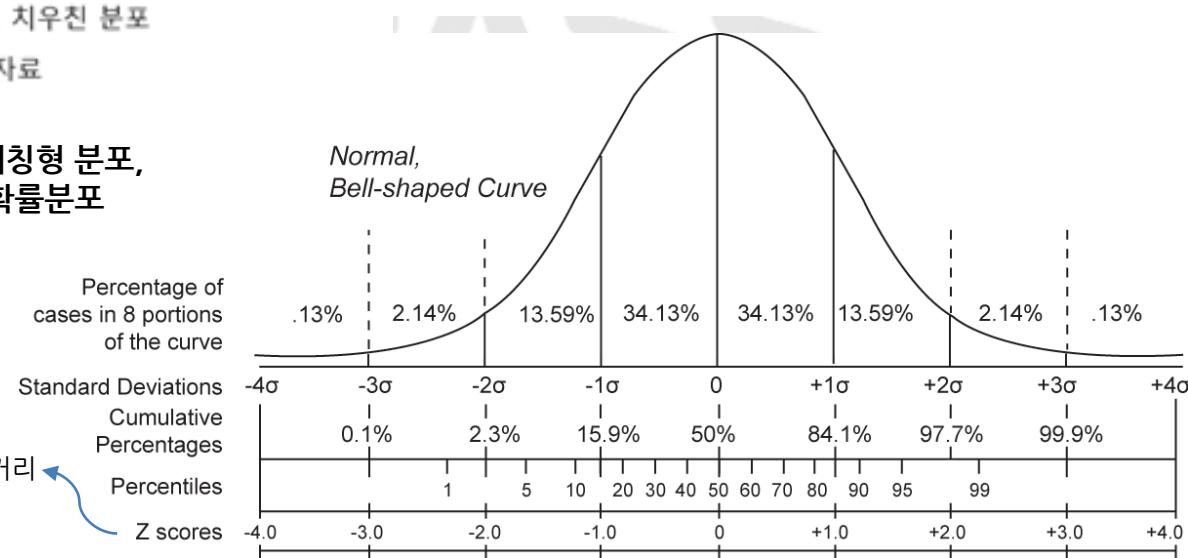
Positive Kurtosis ($K > 0$)

정규분포보다 뾰족한 분포

3. 정규분포 : 일반적으로 발견되는 좌우 대칭형 분포, 모수가 평균 μ 이고, 표준편차가 σ 인 연속확률분포

Z score (표준점수) : 평균으로부터 떨어진 표준편차 거리

$$z \text{ score} = \frac{x - \mu}{\sigma}$$

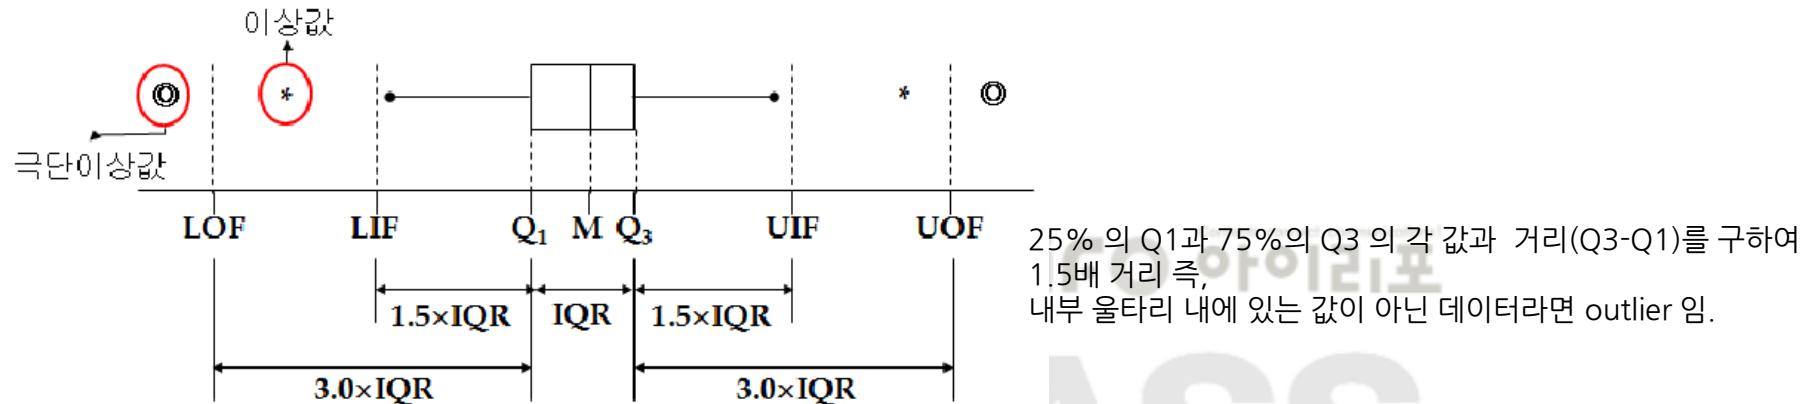




통계 기본 - percentile 기반 이상치 제거

1. percentile 기반 이상치 제거

- 크기가 있는 값들로 이뤄진 자료를 순서대로 나열했을 때 백분율로 나타낸 특정 위치의 값을 이르는 척도



하 내부울타리(lower inner fence : LIF) : $LIF = Q_1 - 1.5 \times \text{IQR}$

상 내부울타리(upper inner fence : UIF) : $UIF = Q_3 + 1.5 \times \text{IQR}$

하 외부울타리(lower outer fence : LOF) : $LOF = Q_1 - 3.0 \times \text{IQR}$

상 외부울타리(upper outer fence : UOF) : $UOF = Q_3 + 3.0 \times \text{IQR}$



통계 기본 - 결측치(Missing Value) 처리

Deletion

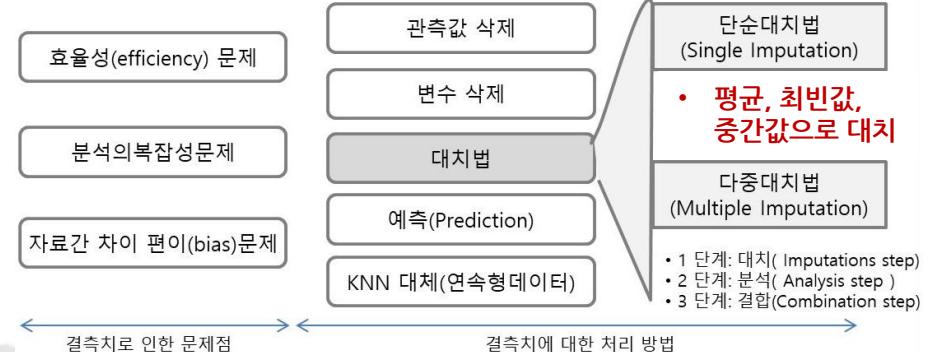
Imputation

1. 분석에 필요한 데이터셋에서 일부 데이터 값이 측정되지 않은 데이터, 결측치의 개요

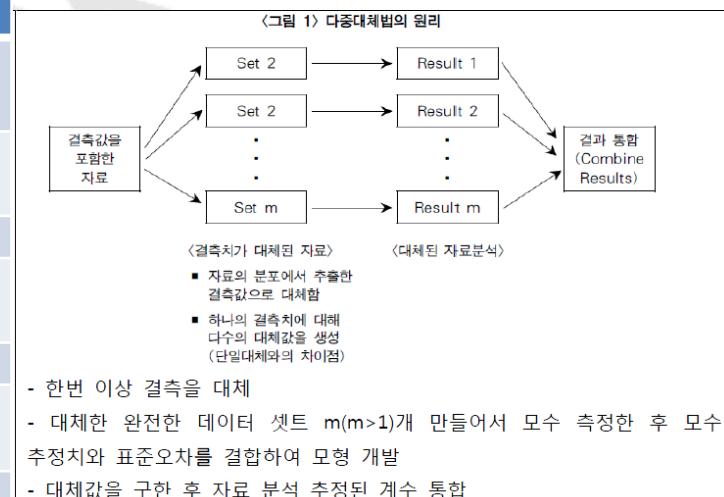
- 실험이나 조사시 설문문항 이해의 부족, 부정적 태도, 무관심, 부주의 등 이유로 관측되어야 할 값을 얻지 못한 데이터로 **전처리 단계에서 적절한 값으로 처리가 필요한 데이터**

2. 통계처리 결측치 처리 방안

- 결측치 처리는 결측 비율에 따라 다른 방법을 적용함.
- 결측치가 50% 이상인 경우
- 결측치가 30 ~ 50% 인 경우
- 결측치가 10 ~ 30% 인 경우
- 결측치가 10% 미만인 경우



구분	처리방안	설명
Single Imputation (단일대체법)	List wise deletion (완전제거법)	<ul style="list-style-type: none"> 하나의 변수라도 결측치 존재시 분석 대상에서 제외 모든 변수 값 존재시만 분석 대상에 포함
	평균대체방법	<ul style="list-style-type: none"> 관측 자료의 평균값으로 대체 편향된 추정치 발생시킬 수 있음
	연역적 대체방법	<ul style="list-style-type: none"> <u>논리적 제약조건</u>: 다른 기록에 의거하여 결측값을 논리적 유추값으로 이용하는 방법
	일치대응대체법	<ul style="list-style-type: none"> 결측된 정보를 다른 조사자료로부터 얻을 수 있는 경우 동일한 조사단위에 해당하는 다른 외부자료의 값으로 대체하는 방법
	핫덱대체(Hot-deck)	<ul style="list-style-type: none"> 동일한 특성 응답값 중에서 랜덤 추출하여 대체
	회귀대체방법	<ul style="list-style-type: none"> 회귀분석: 결측치가 포함되어 있는 변수를 종속변수, 다른 변수들을 독립변수로 분석 회귀분석을 실시한 결과 얻은 추정치를 결측치의 대체값 사용
Multiple Imputation (다중대체법)	<ul style="list-style-type: none"> 한번 이상 결측을 대체 대체한 완전한 데이터 셋트 $m(m>1)$개 만들어서 모수 측정한 후 모수 추정치와 표준오차를 결합하여 모형 개발 대체값을 구한 후 자료 분석 추정된 계수 통합 	



통계 기본 - 표본, 중심극한의 정리

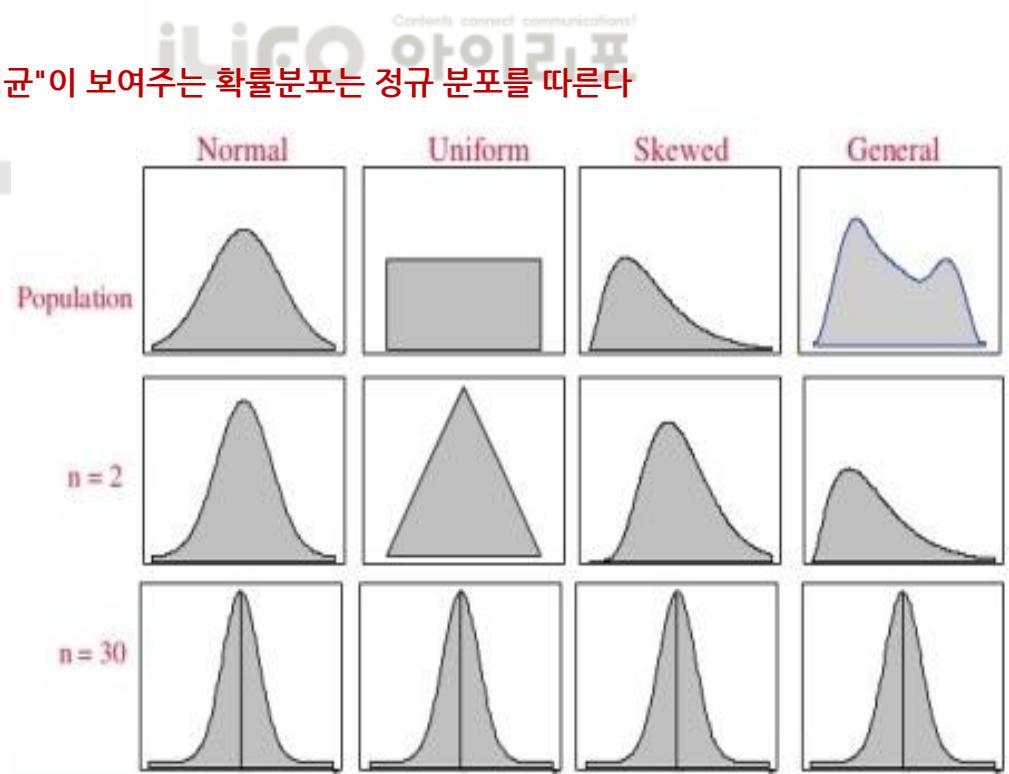
1. Population (모집단), Sample (표본)

- Population (모집단): parameter (모수), 평균(μ 뮤, m), 표준편차(σ 시그마), 분산(σ^2)
- Sample (표본): statistics (통계량), 평균(\bar{X}), 표준편차(s), 분산(s^2)

※ 표본평균은 고정값이 아니라, 표본의 크기에 따라 변화하는 확률변수임.

※ 확률변수 : 무작위 실험을 했을 때 특정확률로 발생하는 각각 결과를 수치적 값으로 표현하는 변수

2. 중심극한의 정리 : 표본 크기가 충분히 크면, "표본들의 평균"이 보여주는 확률분포는 정규 분포를 따른다



통계 기본 - 변수, 척도

1. Variable (변수)

- **Independent Variable (독립변수)**
= Explanatory Variable (설명변수)
= Input Variable (입력변수)
= Predictor Variable (예측변수)
= Feature (특징)

- **Dependent Variable (종속변수)**
= Response Variable (반응변수)
= Target Variable (표적변수)
= Outcome Variable (출력변수)
= Predicted Variable (피예측변수)
= Measured Variable (측정변수)

2. Scale (척도) = 변수종류 = 데이터종류

• Categorical(범주형)

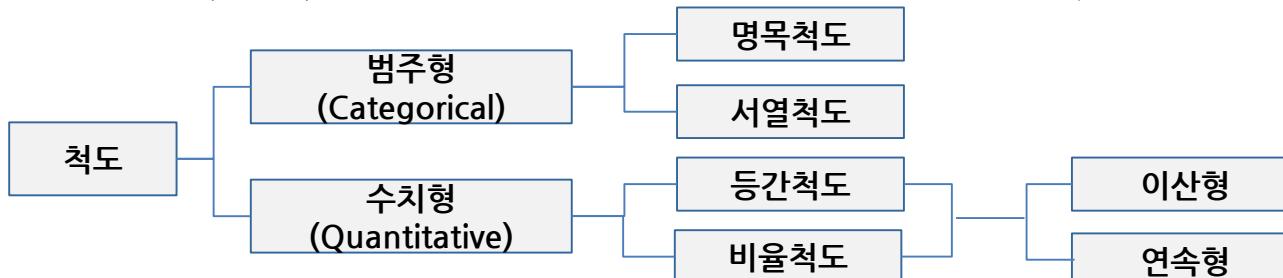
- Nominal Scale (명목척도) : 크기나 순서에 대한 의미가 없고 이름만 의미를 부여할 수 있는 자료 ex>남자, 여자 / 서울, 부산, 대구
- Ordinal Scale (순서척도, 서열척도) : 어떤 기준에 따라 순서에 의미를 부여할 수 있는 자료 ex> 상/중/하, 대/중/소

• Quantitative(수치형)

- Interval Scale (등간척도) : 데이터의 연속된 측정 구간 사이의 간격이 동일한 자료 ex> 시각, IQ, 물가지수, 온도, 사회지표
- Ratio Scale (비율척도) : 순서사이의 간격이 동일하고, 절대값(0)과 값간의 비율이 있는 자료 ex> 시간, 길이, 무게, 거리, 점수, 비율

※ 등간(interval)이나 비율(ratio)자료는 이산형(discrete)이나 연속형(continuous) 둘 중의 하나의 속성을 갖음

- Discrete(이산형) : 측정값이 정수로 딱딱 떨어지는 경우 ex> 자녀수, 불량수
- Continuous (연속형) : 연속된 무수히 많은 값 중 하나를 가질 수 있는 경우 ex> 길이 12.3cm, 무게 72.7kg



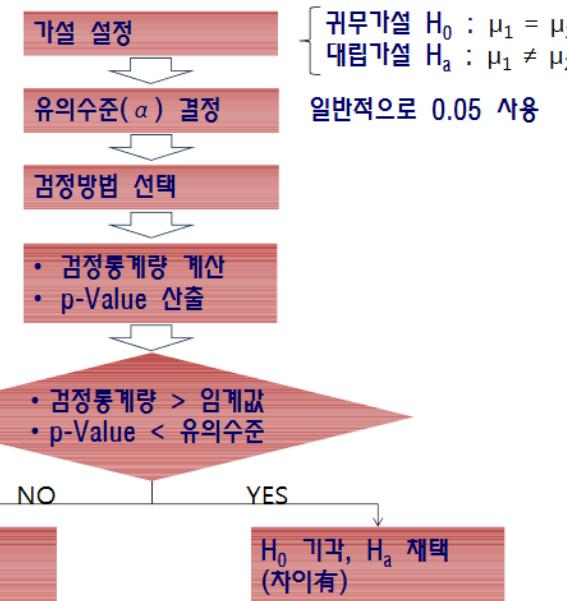
예>
 $y=f(x)$ → 종속변수 y , 독립변수 x
 $z=f(x, y)$ → 독립변수 x, y , 종속변수 z
교습법이 학업성적에 미치는 영향
→ 독립변수 교습법, 종속변수 학업성적



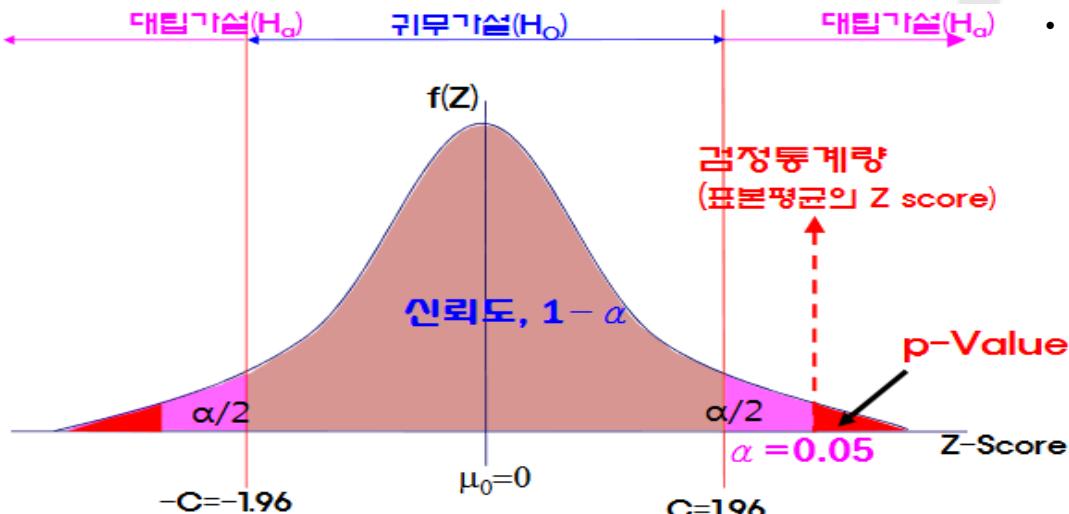
통계 기본 - 추정과 가설검정

- 추정 : 모집단에서 추출된 표본을 기반으로 모수를 추론
- 가설검정 : 모집단에 대한 어떤 가설을 설정한 뒤에 표본관찰을 통해 그 가설의 채택여부를 결정하는 분석 방법

가설종류	의미
귀무가설 = 영가설 (H_0 , null hypothesis)	<ul style="list-style-type: none"> - 가설 검정(假說檢定)에서, 표본에 의하여 그 적부(適否)가 검정되어야 할 가설 (기본적인 가설) - 통계학에서 처음부터 버릴 것을 예상하는 가설 - 차이가 없거나 의미 있는 차이가 없는 경우의 가설이며 이것이 맞거나 맞지 않다는 통계학적 증거를 통해 증명하려는 가설
대립가설 (H_1 , alternative hypothesis)	<ul style="list-style-type: none"> - 비교하고 싶은 가설 - 연구자가 연구를 통해 입증되기를 기대하는 예상이나 주장하는 내용 - 일반적으로 연구에서 검증하는 가설을 귀무가설이라 하고, 귀무가설과 반대되는 가설을 대립가설



- P-Value : 관측된 검정통계량의 값보다 더 대립가설을 지지하는 검정통계량이 나올 확률 (유의수준, 유의확률)
 → H_0 가 참이라고 가정하고, 실제로 관측된 값보다 더 극단적인 값이 나올 확률



- 구간추정: 모수가 특정한 구간에 있을 것
 - 신뢰구간 99.9%, 99%, 95%
 - 유의수준 0.1%, 1%, 5%

4. 1종 오류, 2종 오류

실제상황 검정결과	귀무가설의 상황	대립가설의 상황
귀무가설을 기각 안 함	옳은 결정	제2종 오류 (H_0 이 옳지 않은데 채택함)
귀무가설을 기각함	제1종 오류 (H_0 이 옳은데 기각함)	옳은 결정



통계적 가설 검정(testing hypothesis)

귀무가설 대립가설 유의수준 검정통계량 p value

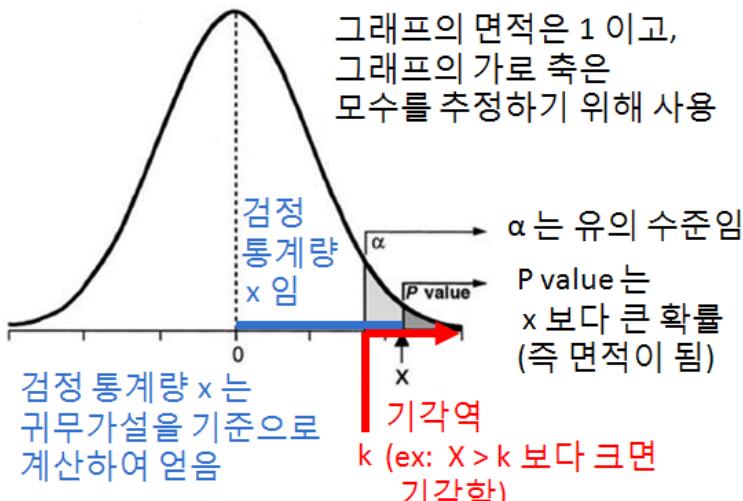
1. 가설의 옳고 그름을 통계적으로 판정하는, 가설 검정(testing hypothesis)의 개요

- 통계 추론 분야에서 가설 검정은 표본에 담긴 정보를 이용하여 **가설의 옳고 그름을 통계적으로 판정하는 학문 분야**.
- 모집단 실제의 값이 얼마가 된다는 주장과 관련해, **표본의 정보를 사용해서 가설의 합당성 여부를 판정하는 과정**
- 수집된 /표본 결과가 확률적 오차를 수반하므로 **오류의 허용확률을 미리 정해 놓고 그 기준에 따라 가설의 채택이나 기각을 결정**

2. 통계적 가설 검정의 특징(1종 오류, 2종 오류)

- 가설검정은 **전체 데이터가 아닌 샘플 데이터로 해석**하기 때문에 **오류 발생은 필연**,
- 즉, 가설검정의 판정결과가 틀릴 수도 있다는 것을 전제하고 설계된 분석기법**이므로, **1종 오류와 2종 오류라는 개념을 필요**하고, 이 중 **1종 오류의 확률을 유의수준**이라고 함.
- 1종 오류**: 귀무가설이 옳지만, Data 해석으로 귀무가설 기각하는 오류
- 2종 오류**: 귀무가설을 기각해야하나, Data 해석상 기각하지 못하는 오류

3. 통계적 가설 검정의 개념도 및 구성요소



- 가설 검정은 귀무가설이 옳다는 것을 증명 하는 것이 아니라 옳지 않다는 것을 증명하는 것임**

구분	설명	예
가설	• 하나의 특정 주장을 모수를 이용해 나타낸 형태	귀무가설 대립가설
귀무가설, H_0	• null hypothesis • 주로 기각하고 싶은 주장을 모수로 표현한 가설 • 대립가설이 참이라는 확실한 근거가 없는 경우에 받아들이는 가설 • 즉, 대립가설이 참이 아닌 가설	점수 평균 = 50
대립가설, H_1	• alternative hypothesis • 주로 검증하고자 하는 주장을 모수로 표현한 가설 • 표본으로부터 확실한 근거에 의하여 입증하고자 하는 가설을 대립 가설이라고 함 • 즉, 분석자가 주장하는 가설, 모집단의 특성에 대한 새로운 사실이나 주장하는 가설	점수 평균 > 50
유의 수준 (level of significance)	• 검정 통계량이 기각역에 속할 확률 • 검정시, 1종 오류가 발생할 확률에 대한 허용하는 최대값 • 귀무가설 H_0 가 참일 때 대립가설 H_1 을 채택하는 오류를 범할 확률의 최대 허용 한계	$\alpha = 0.05$
검정 통계량 (test statistic)	• 귀무가설의 채택 여부를 결정하는 자료의 함수 • 표본평균, 분산, 개수 및 귀무 가설로 계산한 값	$Z=2$
채택역 (acceptance region)	• 귀무가설을 채택하는 검증 통계값의 범위. C0로 표시	
기각역 (위험역; critical region)	• 귀무가설을 기각하는 검증 통계값의 범위. C1으로 표시	
유의 수준에 따라 계산된 모수의 범위		$Z_{(0.05)} = 1.645$

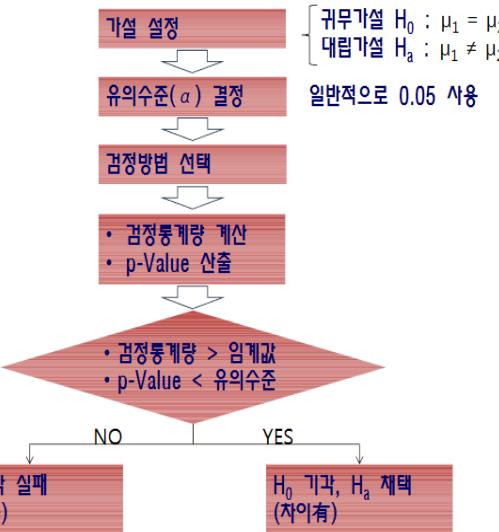
통계적 가설 검정(testing hypothesis)

3. 통계적 가설검정의 수행절차

수행 절차	핵심 개념	수행 활동
가설 설계	가설, 유의수준 설정	귀무가설 H_0 , 대립가설 H_1 , 유의수준(유의수준 0.1%, 1%, 5%) 설정
검정통계량 설정	표본 평균과 분산, 분포	결론 판정 시, 적용할 분포나 통계량 설정
기각역 설정	유의 수준을 기준	설정된 분포를 활용하여 기각역을 설정
검정통계량 계산	표본, 귀무 가설로 계산	표본과 귀무 가설을 기반으로 검정통계량 계산
통계적인 의사결정	귀무 가설 기각 여부 • 귀무 가설이 기각되면, 대립 가설을 결론으로 인정함	귀무 가설이 기각되면, 대립 가설로 결론 • 귀무 가설이 기각되면, 대안으로 대립 가설을 결론으로 인정함

4. 통계적 가설 검정 방법의 종류

방법	설명
신뢰구간 이용 (Confidence Interval)	자료를 수집하기 이전에 유의 수준과 기각역을 설정하여 귀무가설의 기각 여부를 결정
p-value 이용	- 유의 수준을 사전에 결정하지 않고 검정 통계량이 표본으로 계산한 통계값보다 더 극단적일 확률을 구할 수 있음 - 귀무가설이 참이라는 전제하에서 이와 같이 구한 확률을 p-value라고 함 - 확률을 통하여 검정할 수 있으므로 방법이 간단하고, 통계 솔루션에서 일반적으로 p-value에 의한 통계적 검정 방법을 사용함



p-value

1. p-value의 개요

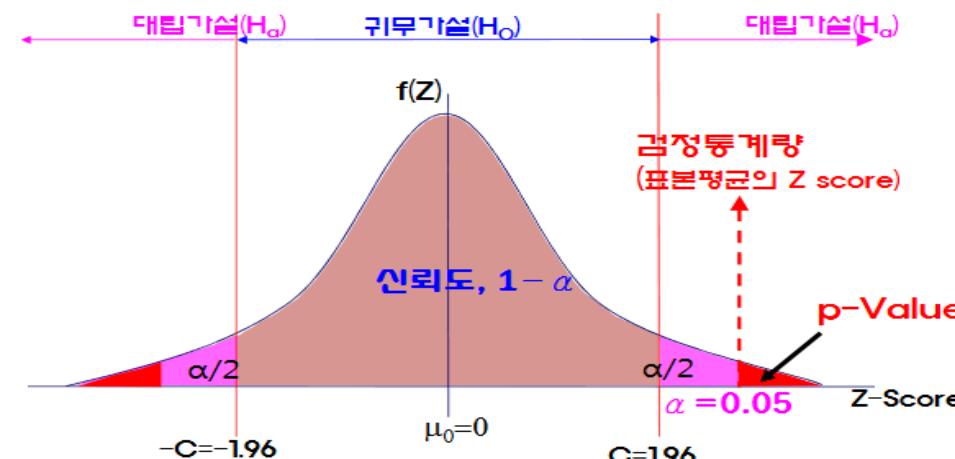
- 귀무가설로 정의한 모수에 대해 해당되는 사건이 발생할 확률
- 관측된 검정통계량의 값보다 더 대립가설을 지지하는 검정통계량이 나올 확률 (유의수준, 유의확률)
→ H_0 가 참이라고 가정하고, 실제로 관측된 값보다 더 극단적인 값이 나올 확률
- 가설검정해석: p-value가 α 보다 작으면 귀무가설 기각, 대안이 되는 대립가설을 인정

2. p-value의 개념도

면적 = $P(z < -y \text{ 혹은 } z > y | \theta = \theta_0)$

- 양측 검증의 경우, p-value는 귀무가설 하에서 무작위로 생성된 표본으로 계산된 “검정 통계값” z 가 관찰된 표본에서 계산한 검정 통계값 y 보다 극단적일 확률
- p 는 대립가설 하에서 표본이 생성되었을 확률. 따라서, $1-p$ 값은 실제 자료가 추정한 모수값을 가지는 분포부터 생성되었을 확률.
- 단측 검증의 경우 추정한 모수값보다 더 큰 모수를 가지는 분포에서 생성되었을 확률이나 더 작은 모수값을 가지는 분포에서 생성되었을 확률, 한가지 만을 고려

- p-value가 작을수록 검정 통계량이 표본 통계값이나 혹은 보다 극단적인 값을 취할 확률이 낮아지므로 표본이 귀무가설을 기각할 가능성이 더 큼
- p-value가 클 수록 귀무가설을 기각할 가능성이 작음
- p-value가 유의수준 α 보다 작거나 같다면 귀무가설은 유의수준 α 에서 기각할 수 있음.
- 유의수준 α 가 작아질수록 임계값은 더욱 극단적이 되므로 귀무가설을 기각하기 어려워짐



p-value

3. p-value를 활용한 가설검증 사례

4) R을 활용한 독립표본 t-검정

- 예제 : A, B 두 지역의 겨울 낮 최고기온에 차이가 있는지를 알아보기 위해 약 10일 동안 두 지역의 낮 최고기온을 측정한 데이터로 독립표본 t-검정을 수행해보자. (표본이 정규성을 만족한다는 가정 하에 양측검정 수행, 유의수준 = 0.05)] 유의수준결정

- 귀무가설(H_0) : A, B 두 지역에 따른 겨울 낮 최고기온은 차이가 없다. ($\mu_1 = \mu_2$)
- 대립가설(H_1) : A, B 두 지역에 따른 겨울 낮 최고기온은 차이가 있다. ($\mu_1 \neq \mu_2$)] 가설설정
- 데이터 입력 : A, B 지역에 대한 10일 동안의 겨울 낮 최고기온 데이터와 지역구분 데이터를 이용해 weather라는 데이터프레임을 생성

R 코드

```
> group<-factor(rep(c("A","B"),each=10)) # 집단구분을 위한 변수
> A<-c(-1, 0, 3, 4, 1, 3, 3, 1, 1, 3) # A 지역의 온도
> B<-c(6, 6, 8, 8, 11, 11, 10, 8, 8, 9) # B 지역의 온도
> weather<-data.frame(group=group, temp=c(A,B)) # 데이터프레임 생성
```

검정방법 선택

- 독립표본 t-검정을 하기 전에 앞서, 등분산 검정을 수행해야 하며 이를 위한 R의 다양한 함수 중 var.test 함수를 이용해보자.

R 코드

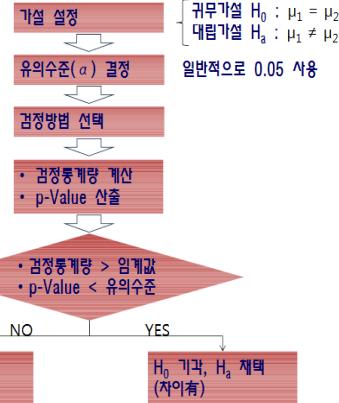
```
> var.test(temp~group, data=weather, alternative="two.sided") // 등분산검정
```

F test to compare two variances

```
data: temp by group
F = 0.82807, num df = 9, denom df = 9, p-value = 0.7833
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
0.2056809 3.3338057
sample estimates:
ratio of variances
0.8280702
```

P-value 유의수준 확인 & H_0 기각

- 독립표본 t-검정 수행 결과, 검정통계량(t값)은 -8.806, df(자유도)는 18, 유의확률(p-value)은 6.085e-08이다. p-value가 0에 가까운 매우 작은 숫자로 유의수준 0.05보다 작기 때문에 귀무 가설을 기각한다. 따라서 'A, B 두 지역의 겨울 낮 최고기온에는 통계적으로 유의한 차이가 존재한다.'라는 결론을 내릴 수 있다.



- 등분산 검정의 결과 유의확률(p-value)이 0.7833으로 유의수준 0.05보다 크기 때문에 귀무 가설을 기각하지 않는다. 따라서 A, B 두 집단의 데이터는 등분산 가정을 만족한다고 볼 수 있다.
- 두 모집단이 등분산성을 만족한다는 가정 하에 t.test함수를 이용해 독립표본 t-검정을 수행해보자. 문법은 아래와 같다.

```
t.test(x, y, alternative, var.equal=FALSE)
t.test(formula, data, alternative, var.equal=FALSE)
```

R 코드

```
> t.test(temp~group, data=weather, alternative="two.sided", var.equal=TRUE)
```

Two Sample t-test

```
data: temp by group
t = -8.806, df = 18, p-value = 6.085e-08
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
-8.298481 -5.101519
sample estimates:
mean in group A mean in group B
1.8 8.5
```

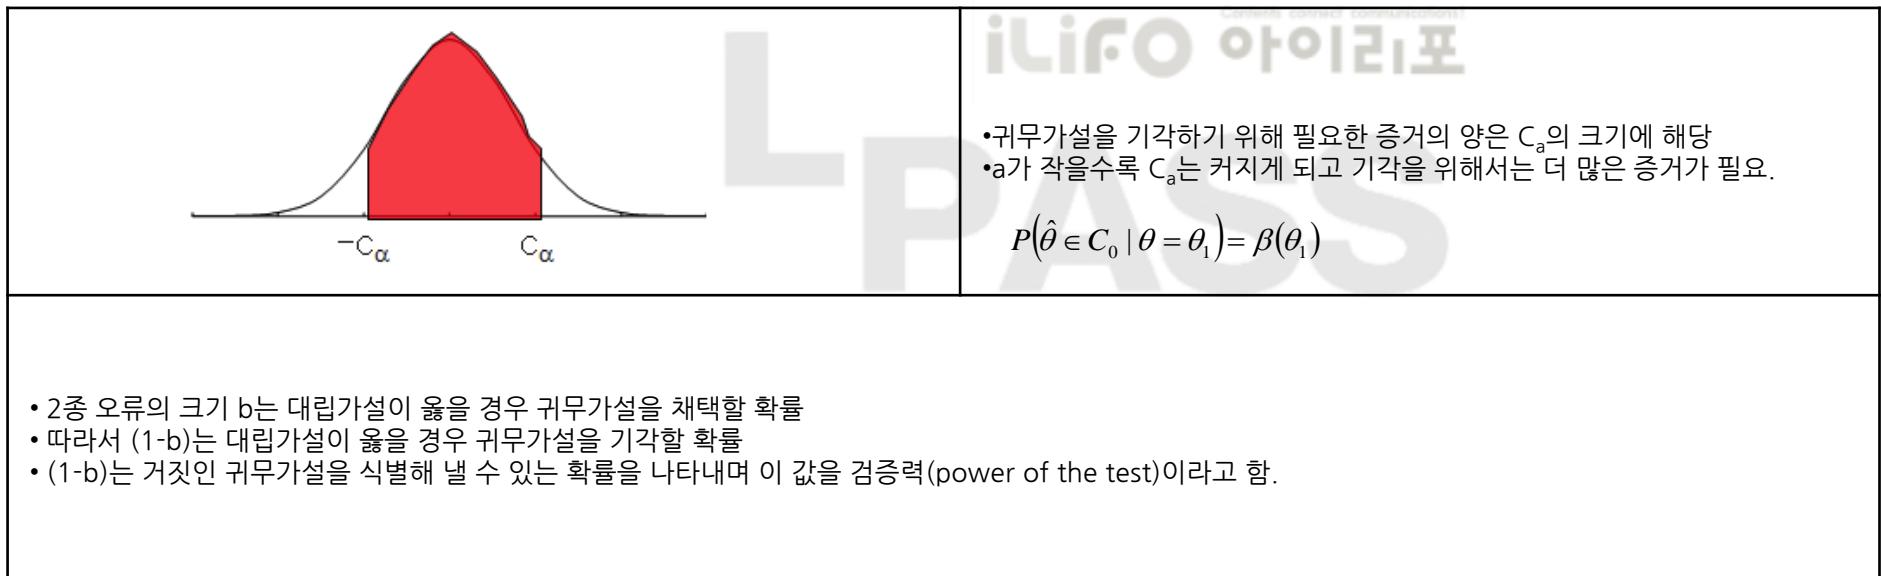
검정통계량 계산, P-value산출

1종 오류(Type 1 Error)와 2종 오류(Type 2 Error)

1. 1종 오류와 2종 오류의 개념도

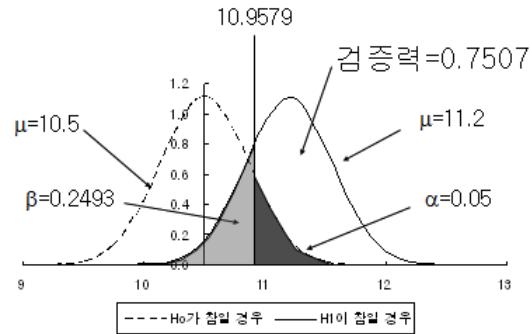
검정 결과	실제상황	귀무가설의 상황 (H_0)	대립가설의 상황(H_1)
귀무가설을 기각 안함		옳은 결정	제 2종 오류 (H_0 이 옳지 않은데 채택함)
귀무가설을 기각 함		제 1종 오류 (H_0 이 옳은데 기각함)	옳은 결정

2. 1종 오류의 개념도



1종 오류(Type 1 Error)와 2종 오류(Type 2 Error)

3. 2종 오류



- 1종 오류와는 다르게, 2종 오류가 발생할 수 있는 경우의 수는 무한한
- 어떤 특정한 값 $q=q_1$ 에서의 2종 오류는 다음과 같이 표시
-

$$P(\hat{\theta} \in C_0 \mid \theta = \theta_1) = \beta(\theta_1)$$

iLIFO 아이리포
Contents connect communications!

- 2종 오류의 크기 β 는 대립가설이 옳을 경우 귀무가설을 채택할 확률
- 따라서 $(1-\beta)$ 는 대립가설이 옳을 경우 귀무가설을 기각할 확률
- $(1-\beta)$ 는 거짓인 귀무가설을 식별해 낼 수 있는 확률을 나타내며 이 값을 검증력(power of the test)이라고 함.

2종오류(β)와 검증력 (power of the test)	<ul style="list-style-type: none">- Z 검증의 경우 $(1-\beta)$는 α, σ, n의 함수이며 이 세 가지 요인들은 검증력에 절대적인 영향을 미치게 됨- 검증력은 통계적 검정에 있어서 매우 중요한 고려사항	
	유의수준 (α)	유의수준 α 가 클수록 β 값은 작아지고 검증력은 높아지게 됨. 유의수준 α 는 보통 0.05 정도로 결정하는 것이 보통이므로 이러한 관계를 이용하여 검증력을 높일 수는 없음.
	표준편차 (σ)	현실적으로 표본의 표준편차 자체를 줄이는 것은 거의 불가능
	표본 수 (n)	대개의 경우 표본 수를 늘리는 것이 유일하게 검증력을 향상시키는 방법 “끝”

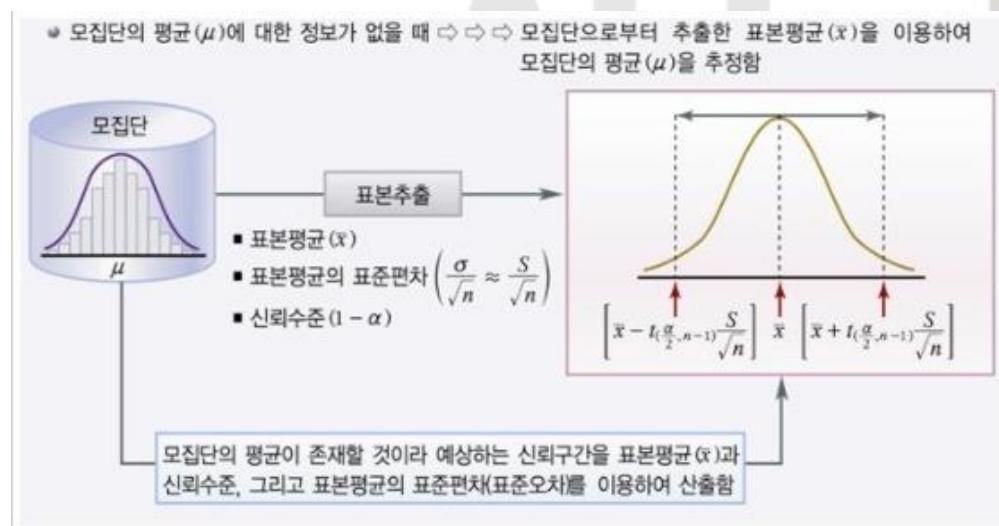
Estimation Theory

1. 모집단에서 표본을 추출하여 모수를 추정하는 Estimation Theory의 개요

- 무작위(random) 요소를 갖고 있는 표본의 경험적 데이터를 근거로 모수추정을 다루는 통계학의 한 분야로 표본조사 결과를 가지고 모집단의 특성을 알아보는 분석 방법
- 모수 추정 : 표본으로부터 도출한 측정 데이터를 분석하면 표본의 속성을 나타내는 수치인 '통계량(statistics)'을 구할 수 있고, 이 통계량을 이용해 알려지지 않은 모집단의 속성을 나타내는 통계량인 '모수(parameter)'를 추론

2. 추정이론의 과정

- 점추정의 경우 선택된 추정량이 모수와 정확하게 일치되는 경우가 없어서 한계가 존재



종류	내용
점추정	하나의 수치로 모집단의 모수를 측정하는 방법
구간추정	특정 구간으로 모수를 측정하는 방법



시계열 분석(Time-Series Analysis)

정상성

모델 4가지

1. 시간의 흐름에 따른 데이터의 변화 추이 또는 패턴을 찾아 미래를 예측할 수 있는 분석 기법, 시계열 분석의 개요

- 일/월, 계절, 연도 등 **시간의 흐름에 따라 순차적으로 관측되는 자료들을 분석**하여 **미래에 대한 예측**을 하는 기법
- 시계열 자료들 간의 계열 상관을 이용하여 동태적인 관계를 분석하는 기법.
- 자료간의 인과관계나 시차분포형태에 대한 사전적인 제약이 최소화된 모형을 추정해서 데이터의 의미를 도출하는 방법
- 목적 : 시계열 자료가 가지고 있는 **시간에 따른 자기 종속구조를 파악**하여 종속구조를 효과적으로 기술하는 모형을 개발하여 미래의 값을 예측

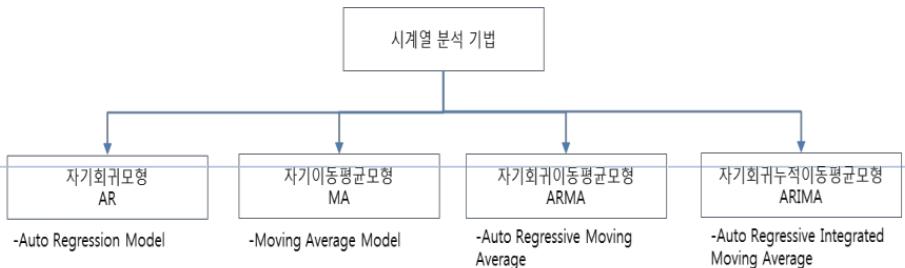
특징(구성요인)	설명	비고
추세성 (Trend)	일정기간 같은 방향으로 직선이나 곡선을 따라 상승하거나 하강하는 경향	<ul style="list-style-type: none"> 환경적 추세 획률적 추세
계절성 (Seasonality)	계절에 따른 기온변화, 수요와 공급의 변화 등 자연 및 경제현상의 변화에 기인	<ul style="list-style-type: none"> 추세요인의 제거는 계절차분이용
변동성 (Volatility)	시계열의 분산이 시간 추이에 따라 변하는 성질로 금융이나 주식시장에서 자산 가치에 영향을 주는 외적 사건의 출현에서 주어지는 시계열의 패턴	<ul style="list-style-type: none"> 경제 또는 금융현상과 관련된 위험 설명하는 수단
비선형성 (Nonlinearity)	시간에 따라 변화는 값들 사이에 존재하는 종속관계나 인과관계가 자신의 값들 사이의 비선형관계로 설명되는 경우	<ul style="list-style-type: none"> -

2. 시계열 분석의 이해를 위한 원리 (개념)

원리	설명
정상성 (Stationary)	<ul style="list-style-type: none"> 시점에 상관없이 시계열의 특성이 일정하다는 성질 정상성의 3대 조건 (정상성 조건을 하나라도 만족하지 못하는 경우의 시계열자료를 비정상 시계열이라고 함) <ul style="list-style-type: none"> 가) 평균이 일정하다 나) 분산이 시점에 의존하지 않는다 다) 공분산은 단지 시차에만 의존하고 시점 자체에는 의존하지 않는다. 비정상성 시계열 : 시계열 분석하는데 다루기 어려운 시계열자료 정상성 시계열 : 비정상 시계열을 핸들링해 다루기 쉬운 시계열 자료 변환한 자료
변동요인	<ul style="list-style-type: none"> 추세변동요인 : 인구변화, 기술변화, 생산성 증대 등 장기적인 변동으로 통상 10년 이상의 변동 주기를 가지는 변동 요인 순환변동요인 : 경기순환 등에 따라 반복되는 변동으로 2년~5년 주기로 변화하는 변동 요인 계절변동요인 : 계절의 변화 및 각종 관습에 의해 생성되는 1년 주기로 반복되는 변동 요인 불규칙변동요인 : 추세, 순환, 계절 변동요인이 아닌 돌발적이거나 원인 불명의 요인에 의거하여 발생하는 변동 요인
안정시계열과 불안정시계열	<ul style="list-style-type: none"> 안정시계열(stationary) <ul style="list-style-type: none"> 시계열의 움직임이 구간이 달라지더라도 매 구간별 특성이 동일한 시계열 시계열의 평균과 분산에 시간에 따른 규칙적인 변화가 없고 주기적 변화도 없는 시계열 불안정시계열(nonstationary) <ul style="list-style-type: none"> 시계열의 평균 및 분산이 시간에 따라 변화하는 시계열 추세변동요인과 계절변동요인이 뚜렷한 경제시계열은 대체로 불안정시계열임
차분, 지수평활화, 변수변환	<ul style="list-style-type: none"> 차분 : 현재 시점 자료에서 과거 인접 시점의 자료를 차감하는 기법 (시계열의 차분으로 시계열이 전기에 비해 얼마나 증감했는지 파악) 평활화 : 주기가 짧은 변동 요인 즉 교란요인을 제거하여 시계열의 기초적 흐름 파악 (중심화이동평균, 후방이동평균, 가중이동평균, 이중이동평균 등) 변수변환 : 로그(log)등 수학적 함수를 이용하여 큰 변동값은 작게, 작은 변동 값은 크게 만들어 주어 선형적 분석이 가능하게 하는 기법



시계열 분석 유형 (모델, 기법)



1. 자기 상관모형(Auto coRrelativeness)

- 자기상관성 : 어떠한 확률변수(Random variable)에 대해서 **이전의 값이 이후의 값에 영향을 미치는 상황**
- 자기 상관모형(AR) : 자기상관성을 시계열 모형으로 구성한 모형으로, 규칙성을 만드는 패턴을 두가지 형태로 나누어 이전의 결과와 이후의 결과 사이에 발생하는 결과로 예측하는 모형

구분	설명	세부 내용
자기상관성		<ul style="list-style-type: none"> 평균이 0이라는 특성이 있으며, 이전에 양수가 오면 이후에는 음수가 나오는(반대도 가능) 일정한 패턴을 예상하게 함 이전의 결과의 영향을 받기도 하지만 드물게 Delay가 발생하기도 함
자기상관모형	AR(1)모형 AR(P)모형	<ul style="list-style-type: none"> 바로 직전 데이터가 다음 데이터에 영향을 준다고 가정한 모형 더 이전의 시점(P시점)을 AR모형에 적용되는 모형

2. 이동평균모형(Moving Average)

- 같은 시점의 백색잡음과 바로 전 시점의 백색잡음의 결합으로 이루어진 모형
- 이전에 생긴 불규칙한 사건이 이후의 결과에 편향성을 초래하는 현상을 분석하는 모형**

구분	설명	세부 내용
개념도		<ul style="list-style-type: none"> 시간이 지날수록 어떠한 확률변수의 평균값이 지속적으로 증가하거나 감소하는 모형 증권가에서 기술분석 시 가장 많이 사용(ex. 최근 50일평균값보다 최근 15일 이동 평균값이 커지면 주가 상승)
이동 평균모형	MA(1)모형 MA(P)모형	<ul style="list-style-type: none"> 바로 직전 데이터가 다음 데이터에 영향을 준다고 가정한 모형 더 이전의 시점(P시점)을 AR모형에 적용되는 모형

시계열 분석 유형

3. 자기회귀 이동평균 모형(Auto Regressive Moving Average, ARMA)

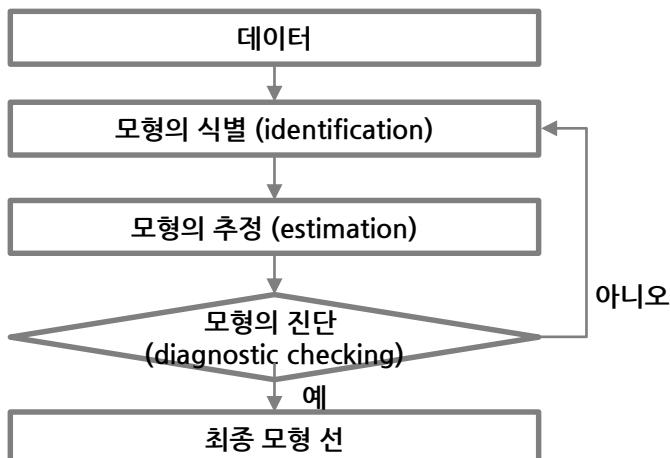
- 자기회귀모형과 이동평균모형이 혼합된 모형임
- 시계열의 시차(p, q)에 따라 ARMA(p, q)로 표시함

4. 자기회귀 누적이동평균 모형(Auto Regressive Integrated Moving Average, ARIMA)

- 자기회기(AR), 적분(Integration), 이동평균(MR) 세가지 필터를 동시에 사용하여 시계열을 특정짓는 몇 개의 요인을 추출하고, 더 이상의 정보가 추출되지 않을 때까지 반복하는 모형
- AR, MA 모형을 동시에 포함하여 시계열모형의 모수를 줄여서 보다 효율적인 시계열 분석을 수행하는 모델 기법

단계	절차	세부 설명
1단계	시계열 확인	<ul style="list-style-type: none">• 시계열 자료를 시각화 해서 안정적인 시계열인지 확인한다
2단계	시계열 변환	<ul style="list-style-type: none">• 시계열 자료를 안정적 시계열로 변환한다<ul style="list-style-type: none">- 차분과 로그함수로 안정적 시계열(Trend, Seasonal, Random값)로 변환
3단계	파라미터 최적화	<ul style="list-style-type: none">• ACF/PACF차트나 auto.arima 함수를 사용하여 최적화된 파라미터를 찾는다.<ul style="list-style-type: none">- ARIMA(p, d, q) - d : 차분 차수 / p : AR 모형 차수 / q : MA 모형 차수
4단계	ARIMA 모형 만들기	<ul style="list-style-type: none">• ARIMA 모형 선택을 선택한다.
5단계	미래 예측	<ul style="list-style-type: none">• ARIMA 모형에 보정된 데이터를 통해 미래값을 예측한다.

- 시계열을 차분해서 ARMA 모형이 되는 모형
- 과거의 관측값과 오차를 사용해서 현재의 시계열 값을 설명하는 ARMA 모델을 일반화한 모델
- ARIMA modeling 과정



[참고] 비정상시계열의 정상화

구분	설명
분산이 일정하지 않은 경우	<ul style="list-style-type: none">• 분산안정화변환 (로그변환, 제곱근변환, Box-Cox 변환을 시도)
추세를 가지는 경우	<ul style="list-style-type: none">• 결정적 추세 -> 분해법 또는 추세항 모형에 포함• 확률적 추세 (Dickey-Fuller의 단위근 검정) -> 차분
계절성을 가지는 경우	<ul style="list-style-type: none">• 결정적 계절추세 -> 계절 추세항 모형에 포함• 확률적 계절추세 (계절형 단위근 검정) -> 계절차분

[시계열분석] 정상성(Stationarity, 定常)

1. 시계열의 확률적인 성질들이 시간의 흐름에 따라 변하지 않는 성질, 시계열분석의 정상성(Stationarity)의 개념

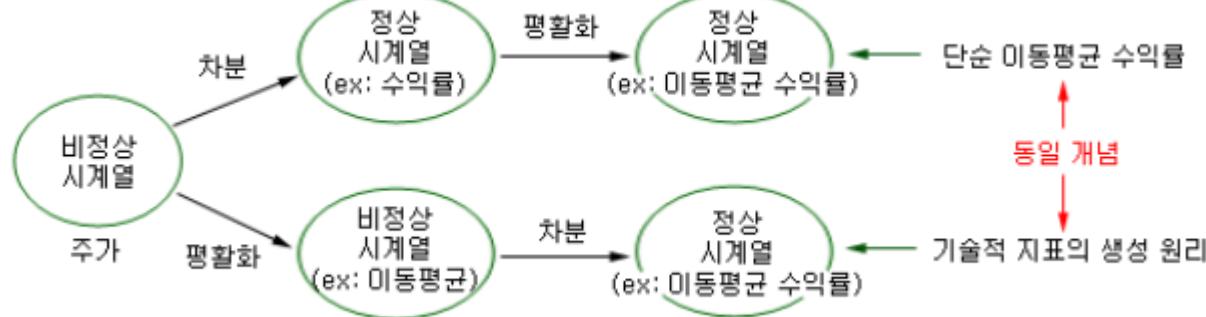
- 평균과 분산이 일정한 시계열 자료를 Stationary time series(시계열 자료의 안정성)로 어떤 시점에서 모든 분포성질이 동일한 상태
- 데이터가 정상성을 가진다는 것은 평균과 분산이 안정되어 있어서 분석하기 쉽다는 의미

2. 정상성을 만족하기 위한 특징

- 평균이 일정하다. 즉 모든 시점에 대해 일정한 평균을 가짐.
- 분산도 시점에 의존하지 않음.
- 공분산은 단지 시차에만 의존하고 실제 어느 시점에 의존하지 않음.

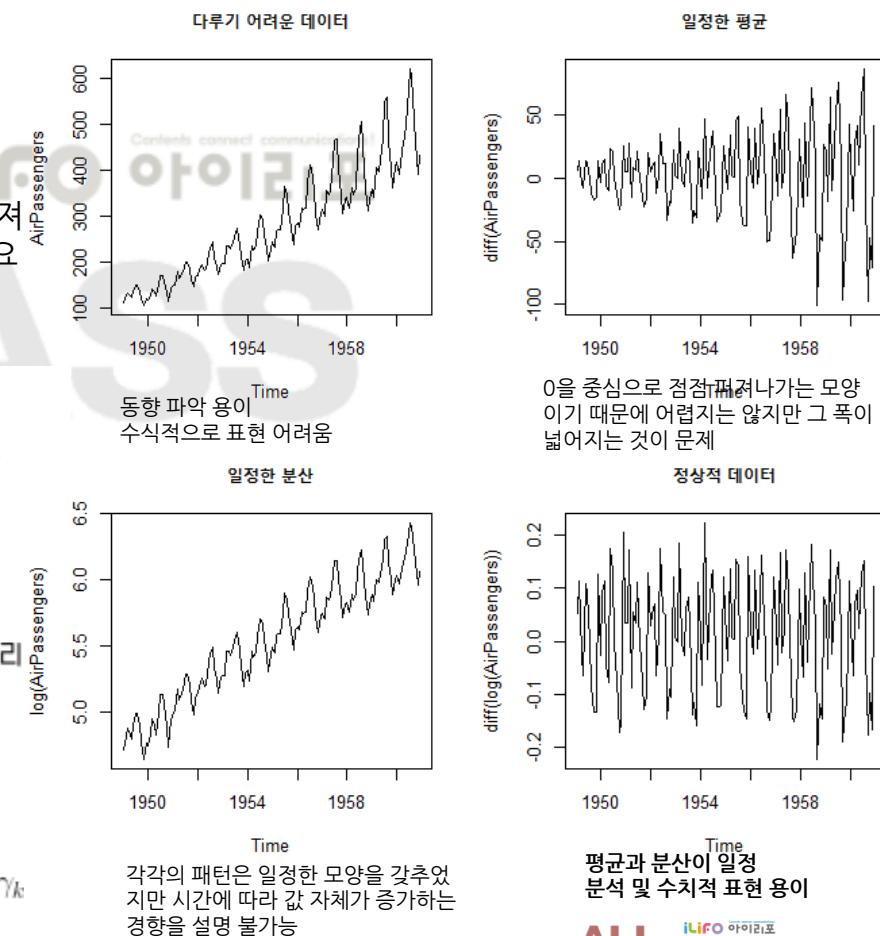
3. 비정상 시계열을 정상 시계열로 바꾸는 방법

- 평균과 분산들이 계속 변하는 복잡한 형태일 경우 추정대상 모수가 많아야져 비정상시계열로 판단되므로 비정상시계열을 정상시계열로 바꾸어 진행필요
- 정상성 없으면 분석이 어렵기 때문에 정상성을 갖도록 만드는 전처리수행
 - 평균이 일정하지 않으면 차분을 취함
 - 분산이 일정하지 않으면 변환을 취함



4. 시계열에서의 정상성 3가지 조건

- 평균이 시간에 따라 불변 $\mu_t = \mu$ for all t
- 분산이 시간에 따라 불변 $\sigma_t^2 = \sigma^2$ for all t
- 자기공분산이 시차에 의해서만 영향을 받음 $\gamma(t, t+k) = \gamma(t-k, t) = \gamma_k$



데이터 마이닝

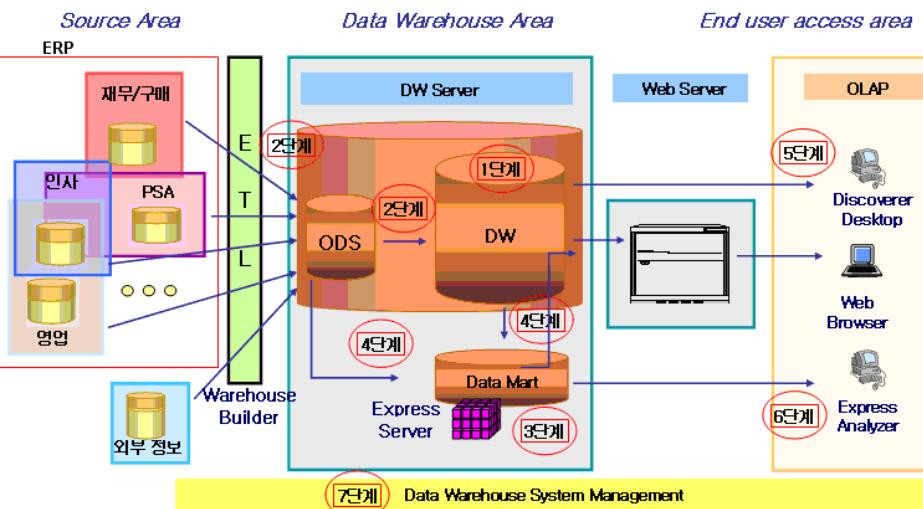


DW(Data Warehouse)

1. 효율적인 비즈니스 의사결정을 위한 통합 데이터베이스 DW의 개요

- 기업 의사결정 과정을 지원하기 위한 **주제 중심적(subject oriented), 통합적(integrated), 시간가변적(time-variant)인 비 휘발성(non-volatile) 자료의 집합**
- 대량의 Data와 각종 외부 Data들로부터 의미 있는 정보를 찾아 내어 기업 활동에 활용하고, 전사에 걸친 이질의 분산 Database를 통합하여 효율적인 의사결정 지원정보를 제공하기 위한 통합 데이터베이스

2. DW 구조와 구성요소



구 分	특징 및 설명
ETL/ETT	<ul style="list-style-type: none">- Extract, Transform and Load- 데이터의 추출(Extraction), 가공(Transformation), 전송(Transportation)- 데이터를 소스 시스템에서 추출하여 Data Warehouse에 Load시켜 정제 작업까지의 전 과정
ODS (Operational Data Store)	<ul style="list-style-type: none">- Operational Data Store- 운영계 시스템에서 데이터를 추출하여 ODS에 저장- ODS는 다차원 모델링이 아니라 ER모델링으로 되어 있음에 따라 사용자로부터 직접적 액세스가 없음
OLAP (On-Line Analytical Processing)	<ul style="list-style-type: none">- 최종 사용자가 다차원 정보에 직접 접근하여 대화식으로 정보를 분석하고 의사결정에 활용하는 과정- 복잡한 실세계를 다차원을 통하여 분석하고자 하는 새로운 데이터 질의 방법
Data Mart	<ul style="list-style-type: none">- 소수의 사용자들이 제한된 주제를 가지고 소규모의 데이터를 추출하여 구축한 시스템- 일반적으로 각 부서별 다양한 분석과 예측을 목적으로 만들어짐
Meta data	<ul style="list-style-type: none">- 운영데이터, ODS, DW, Data Mart에서 유지되는 데이터의 식별 및 일관성 관리상세자료- 기업의 전사적 데이터구조의 LifeCycle 관리자료



DW 모델링

1. 목적에 맞는 고성능 DW 구축을 위한, DW모델링의 개요

- 대용량의 데이터를 다양한 관점에서 빠른 성능으로 분석할 수 있도록 구성하는 데이터 분석 관점의 모델링 기법
- DW 자체에 대한 데이터모델을 일반적인 ERD 형태의 표현할 수도 있고 Star Schema와 Snow Flake Schema로 표현할 수도 있음

2. DW 모델링 용어

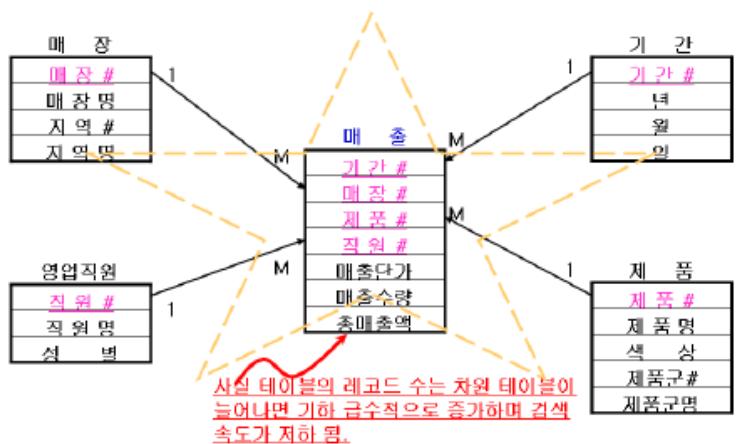
구분	설명
Fact	<ul style="list-style-type: none">- 중심테이블(major 테이블)로서 관련성이 높은 <u>Measure</u>들의 집합- Measure는 사업의 Performance와 주요 사업성공 요인들을 관찰할 수 있는 수단으로 사업분석에 필요로 하는 Data(금액, 건수, 시간 등)- 두 가지의 Type의 Measures Raw(Base) fact / Derived(Calculated) metric
Dimension	<ul style="list-style-type: none">- 부속 테이블(minor 테이블)- 각 Fact를 분석하는 하나의 관점 Dimension은 복수의 속성을 가지고 있으며 이것은 Drill-up과 Drill-down 등 데이터분석의 요약수준에 대한 Navigation를 가능하게 하는 경로를 지님
속성 (Attribute)	<ul style="list-style-type: none">- 각 차원 테이블이 가지고 있는 속성 임.- 사실을 검색하고, 여과하고 분류할 때 사용 됨.
속성 계층 (Hierarchies)	<ul style="list-style-type: none">- 차원 내 정의된 속성들 간에 존재하는 계층 관계- 아래로 가기(Drill-down) 및 위로 가기(Roll-up) 등 기능 이용



DW 모델링

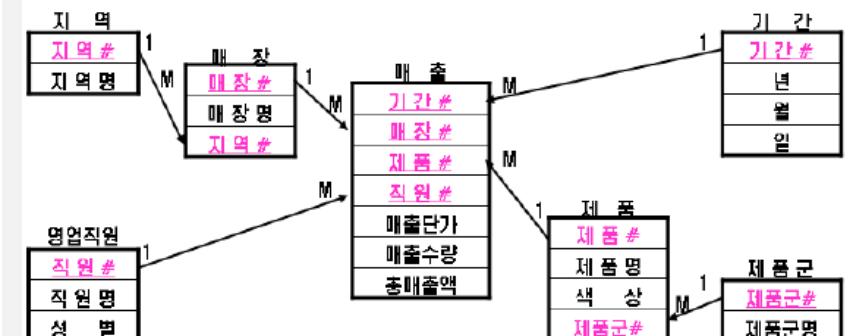
스타스키마

- FACT 테이블과 Dimension 테이블로 데이터를 분리하여 설계
- 장점 : 이해 쉬움, 계층 구조 정의 용이, 조인 수 줄어듦
→빠름
- 단점 : 단일차원→속성의 중복 저장
관점 변경 시(Dimension 추가) Fact 테이블 재생성 또는 비슷한 Fact 테이블 생성 필요



스노우 플레이크

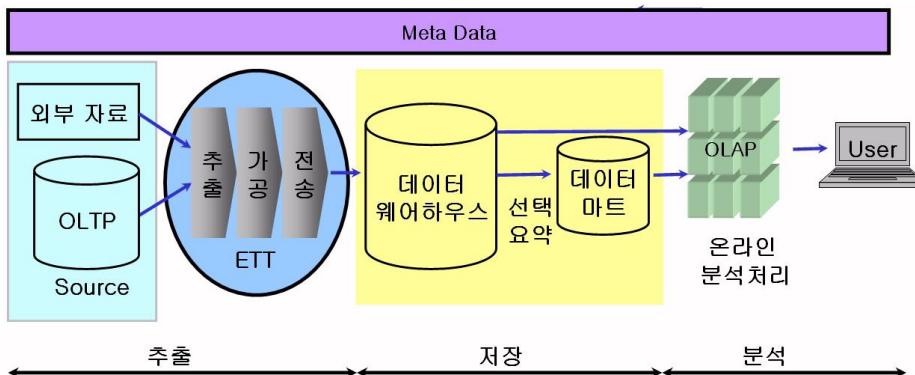
- 스타 스키마에서 나아가, dimension 테이블을 정규화한 구조
- 장점 : 중복 데이터 제거 저장 공간 줄임
- 단점 : 조인 증가 검색 속도 저하



ETT (Extraction, Transformation, Transportation)

1. DW의 지속적 사용성 보장, ETT 의 개요

- 데이터를 소스 시스템에서 추출하여 정제/변환 후 DW에 적재 작업까지의 전 과정



구 분	내 용
Off-Line방식	메일 또는 배달, 소스 시스템에서 데이터를 SAM 파일로 만들어서 Data Warehouse로 방식
On-Line방식	소스 시스템 DB와 D/W Db를 직접 연결하여 직접 로딩 방식
Semi-Online방식	처리계 시스템 내에 사용자 로그를 만들어 Data Warehouse 서버가 이 로그 파일을 주기적으로 읽어 가져오는 방식

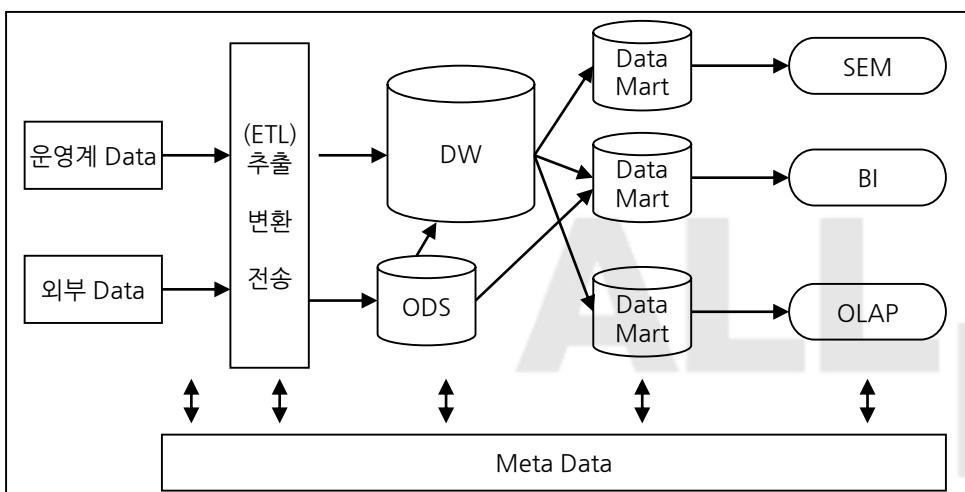
구분	의미
데이터의 추출 (Extraction)	<ul style="list-style-type: none"> 원본 파일과 트랜잭션 데이터베이스로부터 DW에 저장될 데이터를 추출하는 과정임. 초기 추출은 DW에 처음 데이터를 입력할 때 사용됨.
데이터의 가공 (Transformation)	<ul style="list-style-type: none"> 질적으로 문제가 있는 데이터를 데이터 정제(Cleansing) 기법을 통해 수정한 후에 사용·필드 수준의 가공과 레코드 수준의 가공이 존재 필드 수준의 가공은 원본 필드의 형태를 DW의 형태에 맞게 변형하는 것을 의미 레코드 수준의 가공은 선택(Selection), 결합(Join), 집단화(Aggregation) 기능을 이용하여 레코드 집합을 조작
데이터의 전송 (Transportation)	<ul style="list-style-type: none"> 선택된 데이터를 DW에 전송하여 저장하고, 필요한 색인을 만드는 것 전체 간신 방법과 부분 간신 방법 DW의 색인을 만들기 위해 비트맵 색인(Bitmapped Index) 방식을 사용

처리단계	설명
데이터 확인	<ul style="list-style-type: none"> 소스 데이터에서 어떤 데이터를 추출할지 확인 유사한 여러 필드가 있는 경우에는 그 중 가장 신뢰할 만 하거나 기준으로 삼을 필드를 정함
데이터 추출	실제로 소스 데이터에서 필요한 데이터를 추출함
데이터 정제	<ul style="list-style-type: none"> 데이터 품질을 높이기 위한 작업 겹치는 필드를 조정하고, 오류의 가능성이 있는 데이터를 기준 데이터나 비즈니스 규칙에 의거하여 정리
데이터 변환	<ul style="list-style-type: none"> 추출되고 정리된 데이터를 타겟 데이터 형식에 맞게 변환 비즈니스적인 의미를 부여하기 위한 메타데이터 정의/정리 작업 등의 표준화 작업 선결 수행
데이터 통합(전송)	다양한 소스 데이터들을 단일한 데이터로 의미를 가질 수 있도록 통합하여 DW로 통합 적재(전송)

ODS(Operational Data Store)

1. DW에서 추출문제 해결을 위한 중간 단계 데이터 저장소, ODS의 개요

- 적시성(거의 실시간성:near real-time)과 확장성 보장 및 운영계에 영향을 주지 않고 데이터를 추출/변환하여 DW로 적재하기 위하여, 운영계와 DW 중간에 추가한 데이터 저장소. (변경가능한 데이터)

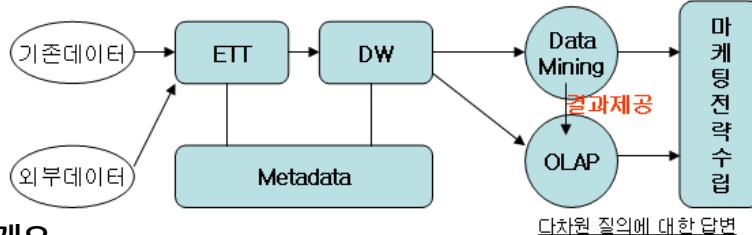


[ODS의 분류] - 간접 속도와 그 자료의 소스에 따라 5가지 Class로 분류

분류	내용
Class1	<ul style="list-style-type: none"> 운영 환경에서 실행된 트랜잭션이 1~2초 간에 즉시 ODS로 이동됨
Class2	<ul style="list-style-type: none"> 운영 환경에서 일어난 모든 활동이 저장되었다가 4시간 정도마다 ODS로 보내어짐
Class3	<ul style="list-style-type: none"> 운영 환경에서 실행된 트랜잭션과 ODS로의 반영 사이에는 하룻밤의 시간 차가 있음
Class4	<ul style="list-style-type: none"> DSS 분석가들이 DW 환경에서 수행한 분석 사항 DW로부터 데이터를 가져와 분석적 프로세스의 결과에 잘 맞을 때 까지 데이터를 요약해 ODS에 넣음
Class5	<ul style="list-style-type: none"> 운영 환경으로 부터 오는 통합 데이터와 분석적 환경에서 오는 집합적 데이터의 조합

구분	ODS	DW
데이터의 성격	<ul style="list-style-type: none"> 현재, 최신 정보 데이터 (current, near current) 운영 데이터베이스 transactional data update Homogeneous data 	<ul style="list-style-type: none"> 히스토리 데이터 정보 데이터 베이스 Query용 information Heterogeneous data
데이터 간접	<ul style="list-style-type: none"> 현재 데이터베이스의 상태 반영 (volatile) 간접 스케줄이 없음(동시 or 자주) 	<ul style="list-style-type: none"> 데이터 축적 보관(nonvolatile snapshots) 스케줄에 따라 저장(주간, 월간)
용도	<ul style="list-style-type: none"> 운영 요원의 최근 가치에 근거한 즉시적인 의사결정에 사용 	<ul style="list-style-type: none"> 장기적 분석, 트렌드 분석 등 DSS 분석가와 관리자에 의해 전략적 의사결정에 사용
상세성의 정도	<ul style="list-style-type: none"> Detailed data (dynamic summary data) 	<ul style="list-style-type: none"> Detailed data, summary data
크기	<ul style="list-style-type: none"> 일반적으로 DW 보다 작음 	<ul style="list-style-type: none"> 대형
간접단위	<ul style="list-style-type: none"> update-record-oriented 	<ul style="list-style-type: none"> Load-and-access tech
데이터 모델	<ul style="list-style-type: none"> Application-specific (특정 비즈니스 프로세스) Normalized design(중복이 없다) 	<ul style="list-style-type: none"> Application-neutral → crossfunctional Access-optimized(generally dimensional)design

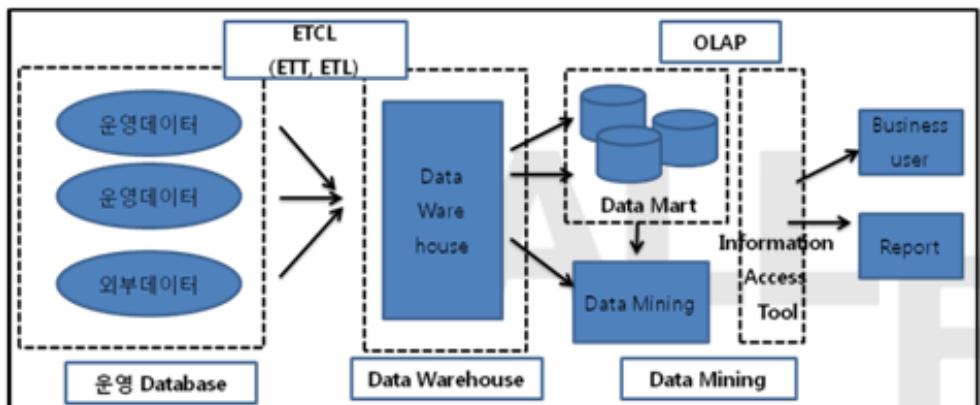
OLAP



1. 온라인 다차원 대용량 데이터 분석을 위한 OLAP (Online Analytical Processing)의 개요

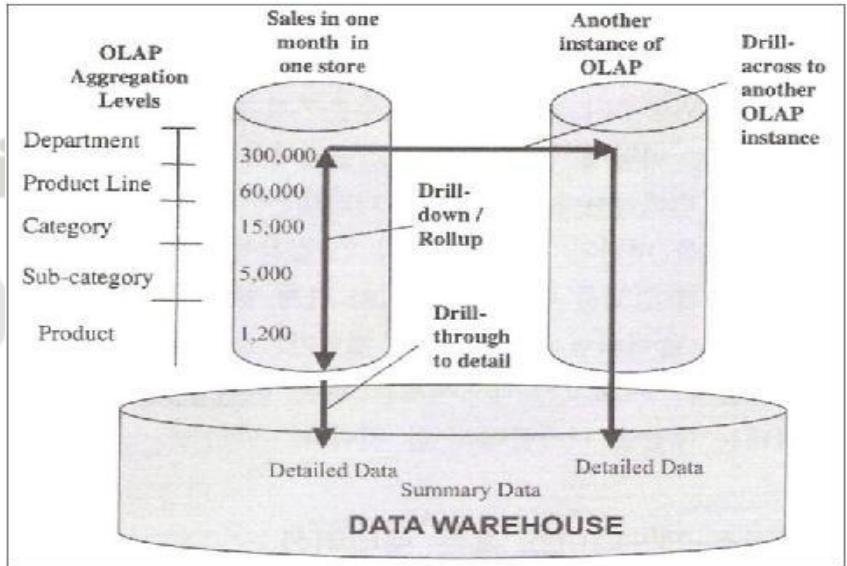
- 최종 사용자가 다차원 정보에 직접 접근하여 대화식으로 정보를 분석하고 의사 결정에 활용하는 과정 및 도구
- 특징 : 다차원, 직접 접근, 대화식 분석, 의사 결정

2. OLAP 구성도 및 주요 기술용어



기술용어	설명
Cell	<ul style="list-style-type: none"> 하나의 데이터 값이 저장됨 다차원 배열 내에서 각 차원의 특정 멤버들에 의해 정의되며, 각 차원들이 상호 교차하는 지점임
다차원배열 (Multi Dimensional Array)	<ul style="list-style-type: none"> 데이터의 차원에 의해 정렬된 데이터 셀의 집합 이차원 배열은 스프레드시트와 유사하게 보임 삼차원 배열은 정육면체(cube)로 나타내고 이때 각 평면 및 평면에 평행한 평면들은 차원을 표현
Dimension	<ul style="list-style-type: none"> 사용자가 분석하려는 항목에 대한 관점 예) 매출액을 지역별, 상품별, 기간별 분석한다면 지역, 상품, 기간이 차원이 됨
Dimension hierarchy	여러 차원이 중첩되어 계층을 구성하는 계층구조
Measure /Variable	<ul style="list-style-type: none"> 분석하고자 하는 항목 예) 매출액, 판매수량, 비용

3. OLAP의 개념도



OLAP operations:

Roll Up = Aggregatin to a higer level. For example from month to year)

Drill Down = recalculation with more details

Slice = Selecting a subset by using a fixed dimension value.

Drill Across = Join of fact data across conformed dimensions

Drill Through = Accessing related data from a OLTP system.

Aggregating

Pivoting = See next slide!

OLAP

4. OLAP의 유형

유형	설명		
<u>ROLAP</u> <u>(Relational OLAP)</u>	<ul style="list-style-type: none"> -관계형 데이터베이스와 SQL과 같은 관계형 질의어를 사용하여 다차원 데이터를 저장하고 분석하는 형태임. -전형적 3 Tier 구조 		
	장점	<ul style="list-style-type: none"> -대용량으로서 전사적으로 구축하는데 적합하며 확장성이 뛰어남. -요약정보가 추출된 원시데이터를 검색해 볼 수 있음 	<p>관계형 데이터베이스</p> <p>데이터 웨어하우스</p> <p>ROLAP 서버</p> <p>ROLAP 엔진</p> <p>ROLAP 클라이언트</p> <p>SQL</p> <p>결과</p> <p>질의 및 결과</p>
	단점	<ul style="list-style-type: none"> -정규화를 통해 저장되어 응답시간이 느림(Star Schema) -기존의 SQL 사용한계(다차원데이터분석의 충분한 기능 없음) 	
<u>MOLAP</u> <u>(Multi dimensional OLAP)</u>	<ul style="list-style-type: none"> -다차원데이터를 저장하기 위한 특수한 구조의 다차원DB사용 -Transaction DB에서 추출된 데이터를 데이터셀에 보관하고, 속도 개선을 위해 주기억장치의 큐브 캐시(Cube Cache)속에 데이터 큐브를 보관함 		
	장점	<ul style="list-style-type: none"> -ROLAP 대비 사용이 쉽고, 검색속도가 빠름, 중소형 DW에 적합 차원 미리 정의, 데이터 큐브를 먼저 생성 후 데이터를 적재 	<p>관계형 데이터베이스</p> <p>데이터 웨어하우스</p> <p>다차원 데이터베이스</p> <p>MOLAP 서버</p> <p>MOLAP 클라이언트</p> <p>SQL</p> <p>질의 및 결과</p>
	단점	<ul style="list-style-type: none"> -새 데이터 차원 ->새 데이터 큐브 생성필요 : 확장성 미흡 -추출된 원시 데이터 추적 불가 	
<u>HOLAP</u> <u>(Hybrid OLAP)</u>	<ul style="list-style-type: none"> -ROLAP과 MOLAP을 결합한 형태 -DB저장은 ROLAP사용, 다차원 프로세싱은 MOLAP사용 		
	장점	<ul style="list-style-type: none"> - ROLAP의 대용량데이터 저장능력, MOLAP의 정밀한 다차원 프로세싱 분석능력 	
	단점	<ul style="list-style-type: none"> -정밀하지만 구현이 어렵다 	
<u>DOLAP</u> <u>(Desktop OLAP)</u>	<ul style="list-style-type: none"> -서버 없이 직접 Data Warehouse와 연결되어 최종 사용자의 분석 및 질의 요구 처리 -Desktop OLAP으로서 DW 추출 후 사용자 PC에 저장하는 형태 -다차원 데이터의 저장 및 프로세싱이 모두 Client에서 발생 		
	장점	<ul style="list-style-type: none"> -싸고 빠르다 -설치와 관리가 용이하다 	<p>관계형 데이터베이스</p> <p>데이터 웨어하우스</p> <p>DOLAP Tool</p> <p>질의 및 결과</p>
	단점	<ul style="list-style-type: none"> -대용량의 데이터를 처리하는 데에 한계 -데이터 정합성을 유지하기 힘들다 	
<u>Web OLAP</u>	<ul style="list-style-type: none"> - 사용자가 웹을 통해 OLAP사용 - OLAP 데이터는 Broadcasting 		
	장점	C/S OLAP에 비하여 가격 저렴	
	단점	인터페이스 방식 및 보안문제	

OLAP

5. ROLAP, MOLAP, HOLAP 비교

구분	ROLAP	MOLAP	HOLAP
기본구조	관계형 DB	다차원 DB	다차원DB+관계형 DB
핵심기술	다차원 모델링	다차원 큐브 생성	RDB, MDB의 연계
처리용량	대용량 처리 가능	대용량 처리 불가능	대용량 처리 가능
고급분석	불가능	가능	가능
상세조회	가능	불가능	가능
장점	-보편화 환경 -다양한 지원 도구	-다차원 분석 빠른 수행 -복잡한 분석 지원	- ROLAP과 MOLAP의 장점 취득
단점	-복잡한 분석 어려움 -수행 속도 낮음	-대용량 처리 어려움 -Data 로딩 시 오래걸림	- MOLAP과 RDB간 추가 변환이 필요

6. OLTP(online transaction Processing)와 OLAP 비교

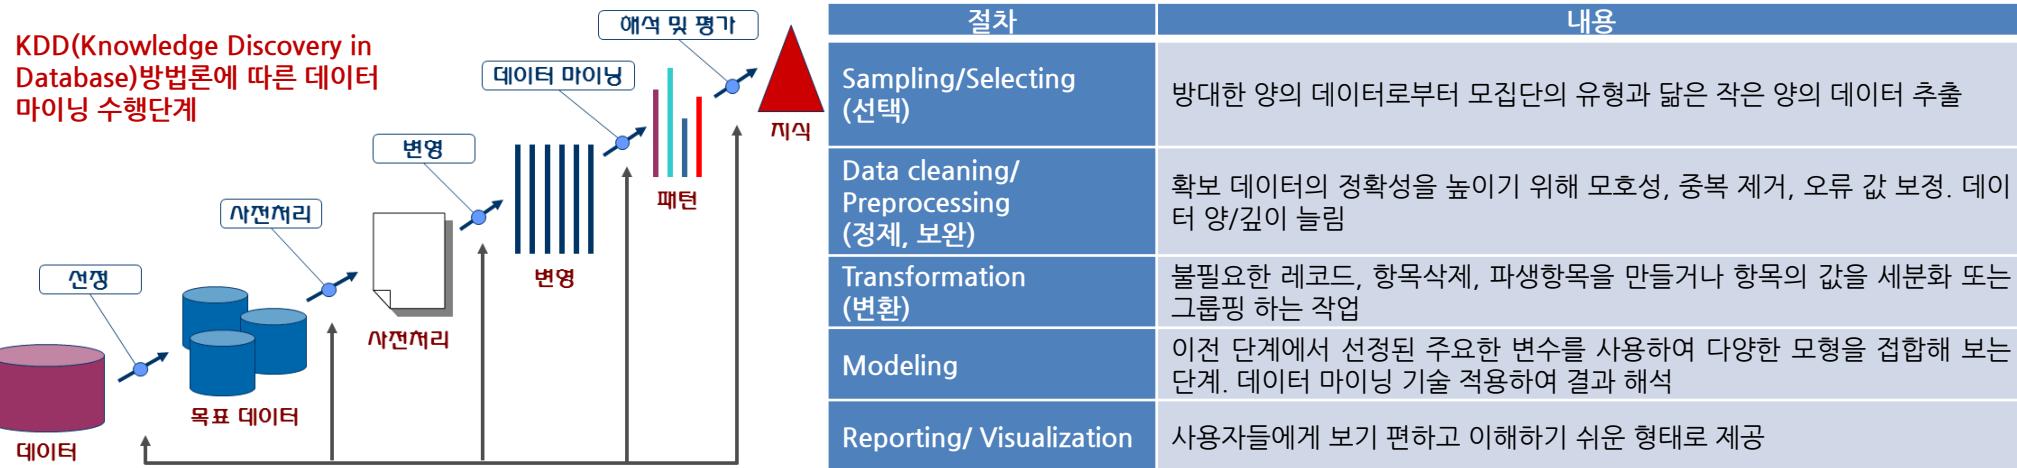
구분	OLTP	OLAP
업무성격	거래 처리(What)	의사결정에 활용하는 측면 (Why)
주제	워크플로우 기반(업무 프로세스 중심)	사용자의 분석 수행 기반 (주제 중심)
데이터 변경	잦음	거의 없음
데이터 구조	2차원, 정규화	다차원, 계층화
Granularity	상세 데이터, 중복성 배제	요약정보, 중복성 수용
데이터 처리	소량의 데이터 처리 활용 패턴 단순 고른 시간대 분포 시스템 자원 사용량 예측 용이	대량의 데이터 처리 활용 패턴 다양 시간대 불규칙 분포 시스템 자원 사용량 예측 어려움
관련 도구	사용자 중심 응용 프로그램 Customizing 용이 정형화된 보고서/변경 어려움 단순한 화면 조작	전용 도구(Off-the-Shelf, Out-of-Box) Customizing 제한적 동적인 비정형 보고서/변경 용이 EUC(End User Computing) 활성화 필요
SDLC 측면	구축 후 데이터 축적 중심 전통적 개발주기 방법론 유지보수 단순	구축 후 데이터 축적 및 스키마 변경 반복 확장 개발주기 방법론 유지보수 전략 필요

데이터 마이닝

1. 효율적, 과학적 의사결정을 위한 정보 추출 및 분석기법, 데이터 마이닝의 개요

- 대용량의 **데이터 간 관계, 패턴, 추세**를 발견하고, 이를 **의미 있는 정보로 변환**하여 기업의 의사결정에 활용하는 기술

2. 일반적인 데이터 마이닝의 수행단계 개념도 및 상세수행절차



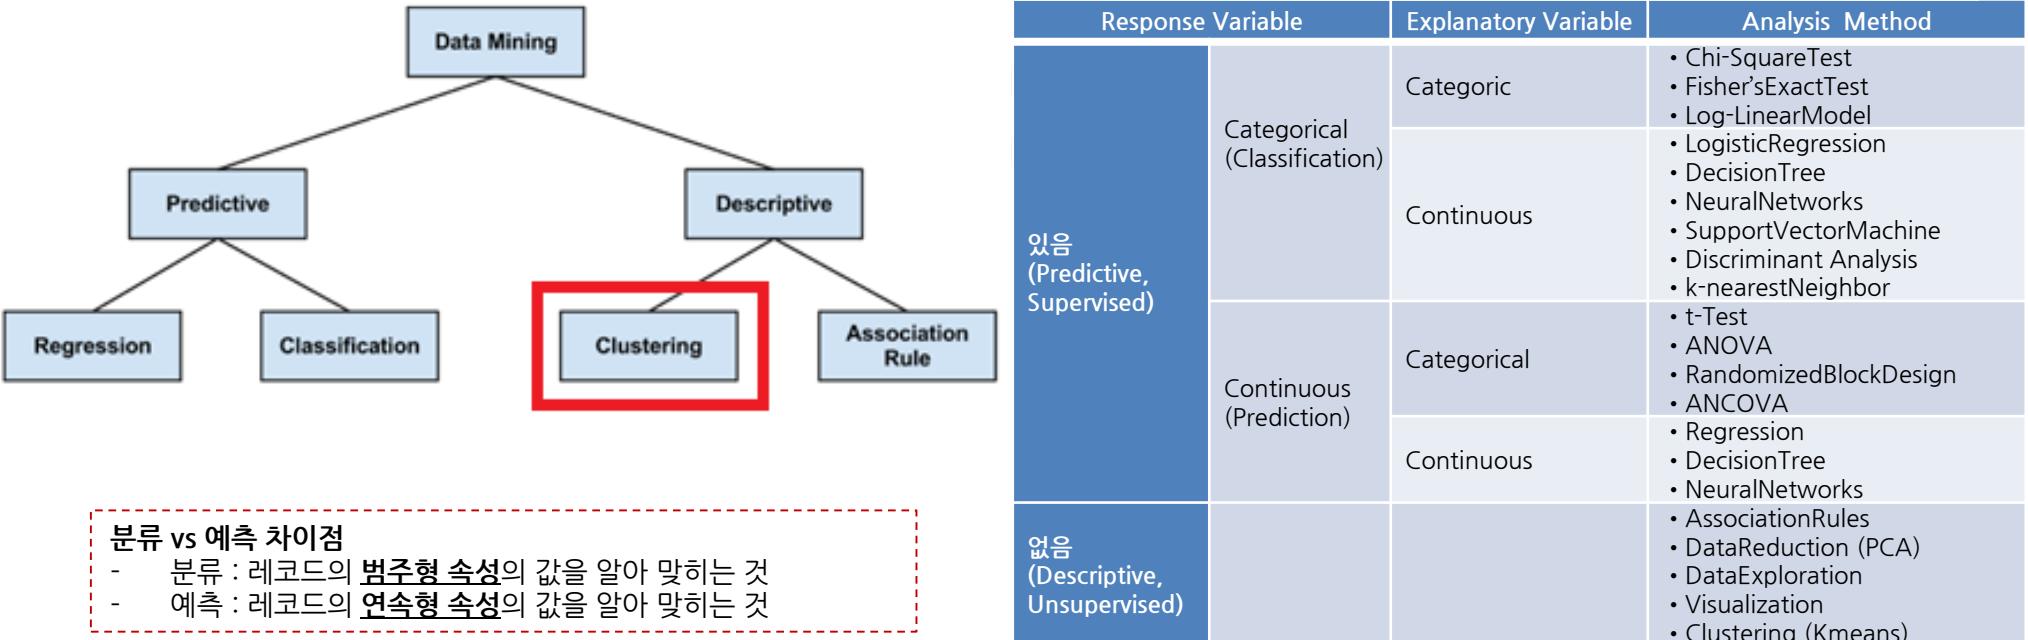
3. 데이터 마이닝 적용기법

기법	설명 (원리와 특징)
연관성 탐색 (Association)	<ul style="list-style-type: none"> 여러 개의 트랜잭션들 중에서 동시에 발생하는 트랜잭션의 연관 관계를 발견하는 것임 예) 넥타이 구매고객의 50% 이상이 셔츠를 구매
연속성 규칙 (Sequence)	<ul style="list-style-type: none"> 개인별 트랜잭션 이력 데이터를 시계열적으로 분석하여 트랜잭션의 향후 발생 가능성을 예측하는 것임 예) A품목을 구매한 회원이 B품목을 구매할 확률은 75%
분류 규칙 (Classification)	<ul style="list-style-type: none"> 과거 수집된 레코드를 분석하여 이들 사이에 존재하는 패턴 즉, 분류별 특성을 속성의 조합으로 나타내는 나무형태의 분류 모형(분류 규칙, Classification) 예) 우수 고객 분류 모형
데이터 군집화 (Clustering)	<ul style="list-style-type: none"> 유사한 특징을 갖는 데이터를 그룹화 시킴 예) 은행 고객의 군집화- 다른 서비스 제공 / 고객의 지역/연령/성별에 따른 차별화 홍보전략
특성발견 (Characterization)	<ul style="list-style-type: none"> 인간두뇌 세포를 모방한 개념으로 반복적인 학습과정을 통하여 모형을 만들어가는 기법. 데이터 집합의 일반적인 특성을 분석하는 것으로 데이터의 요약과정을 통하여 특성규칙을 발견하는 것 (특성화, Characterization) 예) 우수고객분석, 연체자 예측

데이터 마이닝

4. 데이터 마이닝 모델의 유형

유형	설명
예측형 (Predictive)	<ul style="list-style-type: none"> 데이터는 입력값 x와 결과값 y로 구성, 모델은 $f : x \rightarrow y$로 모델링 입력값을 기반으로 결과 값, 또는 목표(target)를 예측하는 모델 회귀(regression): 목표가 연속형인 경우 분류(classification): 목표가 이산형/범주형인 경우
서술형 (Descriptive)	<ul style="list-style-type: none"> 결과값이 알려져 있지 않은 입력 데이터에 대해, 데이터에 숨어 있는 패턴을 찾아내는 방법 군집(clustering): 거리(비유사도)를 기반으로 관련성이 높은 항목을 서로 그룹화하는 방법 연관 규칙(association rule): 입력 데이터의 각 속성간의 관련성을 찾는 방법



[데이터 마이닝 방법론] KDD

5 단계

1. KDD (Knowledge Discovery in Database) 방법론

- 기술과 데이터베이스를 중심으로 한 **insight 발굴**을 위한 절차와 단계를 정리한 방법론
- 데이터베이스에서 Data를 통해 Insight를 얻기 위한 표준화된 처리 절차와 방법
- 때문에 DBMS를 운영하는 조직에서는 쉽고 유용하게 사용될 수 있음
- 그래서 BI(Business Intelligence)라는 용어로 불림
 - BI는 개념적인 측면의 용어, KDD는 방법론의 이름
- 비즈니스 목적 요구를 반영하기에 적합하지 않음



[데이터 마이닝 방법론] SEMMA

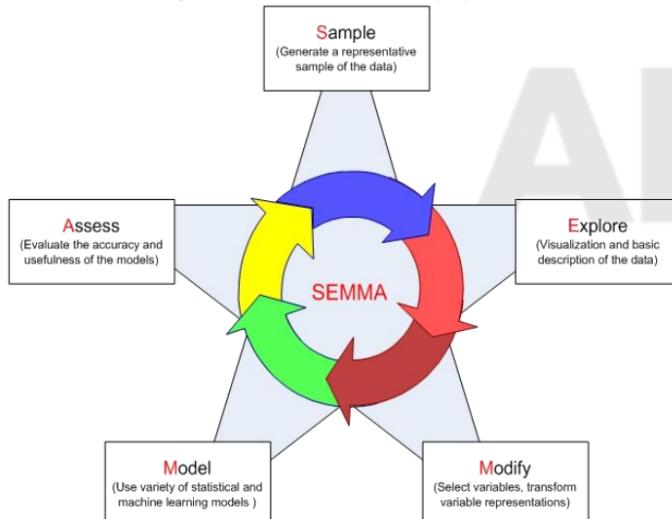
Sample

5 단계

1. 통계중심의 방법론, SEMMA (Sampling Exploration Modification Modeling Assessment) 방법론

- SAS 기업에서 개발한 데이터 마이닝 표준 가이드로써 Sample, Explore, Modify, Model, Assess 의 단계로 구성되어 있으며 각 5 단계 프로세스를 순차적으로 실행하는 데이터 분석 방법론
- 기술적 관점 중심, 비즈니스 관점 미약

2. SEMMA 5 단계 프로세스 세부 설명

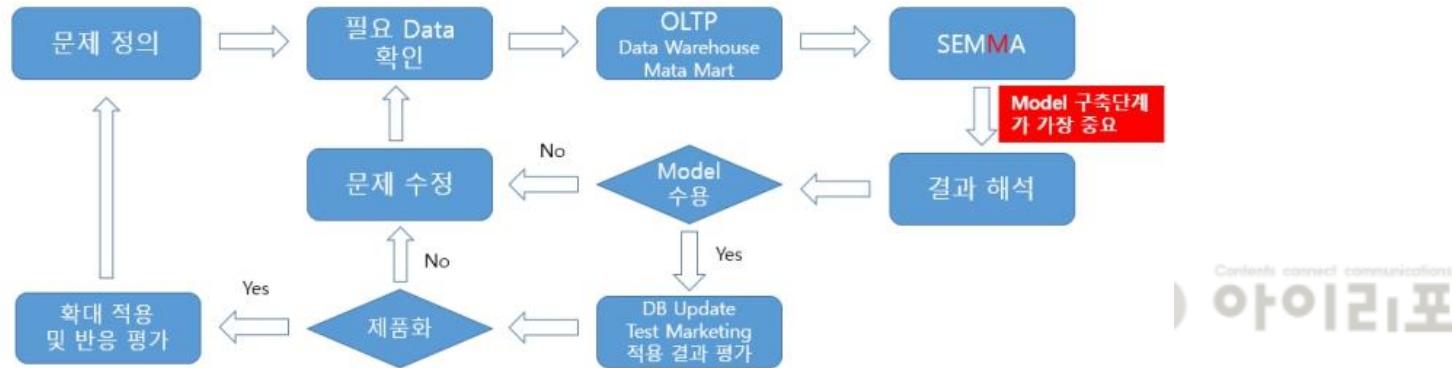


단계	SAS Enterprise Miner Tool	설명
Sample	- Input Data Source	- Mining에 필요한 데이터 입력 변수의 역할(설명/반응 변수)지정
	- Sample	- 분석 데이터 생성(통계적 추출, 조건 추출) - 비용절감 및 모델 평가를 위한 데이터 준비
Explore	- Filter Outlier - Transform Variables - Bar Chart - DataMining Database (DMDB) Variable Selection	- 분석 데이터 탐색하여 기초통계, 그래픽적 탐색, 요인별 분할표 - Clustering, 변수 유의성 및 상관 분석 - 데이터 조감을 통한 데이터 오류 검색 및 제거 통해 모델의 효율 증대 -> 데이터 현황을 통해 비즈니스 이해, 아이디어를 위해 이상현상, 변화 등을 탐색
Modify		- 분석 데이터 수정/변환(수량화, 표준화, 각종 변환, 그룹화) - 데이터가 지닌 정보의 표현 극대화해 최적의 모델을 구축할 수 있도록 다양한 형태로 변수를 생성 및 변형
Modeling	- Regression - Data Splits - Neural Network	- 모델 구축(Neural Network, Decision Tree, Logistic Regression, 전통적 통계) - 데이터의 숨겨진 패턴 발견하고 하나의 비즈니스 문제 해결을 위해 Generalized Linear 모델, Multilayer Perceptron(MLP) 등의 알고리즘 적용 가능
Assess	- Assessment	- 모델 평가 및 검증(텍스트 교본, Feedback) - 모델의 검증 서로 다른 모델을 동시에 비교하고 추가 분석 수행 여부 결정



[데이터 마이닝 방법론] SEMMA

3. 데이터 마이닝 절차에서의 SEMMA



Contents connect communications!
아이리포

절차	설명
문제 정의	<ul style="list-style-type: none"> 문제를 가장 먼저 해결하고 어떤 결과를 얻을 것인지 목표를 설정하는 단계
필요한 Data 확인	<ul style="list-style-type: none"> 마이닝 대상 될 데이터베이스를 선택하고 가져온 원천 데이터 확인 단계
OLTP	<ul style="list-style-type: none"> 데이터웨어하우스에 경제 및 통합된 데이터를 트랜잭션 단위로 SAS Enterprise Miner로 전달하는 단계 Data Mart은 DW의 하위단위로써 데이터 저장소로 쉬운 접근성과 사용성을 제공
SEMMA	<ul style="list-style-type: none"> 분석 데이터 생성/추출, 데이터 탐색, 데이터 변수 수정/변환, 모델 구축한 후 모델 평가 및 검증하는 프로세스로써 모델 평가 단계가 가장 중요함
결과 해석	<ul style="list-style-type: none"> SEMMA 분석 결과가 적용 업무에 부합되는지 판단하기 위한 단계 Model 수용하면 DB Update Test Marketing 단계로 이동 Model 수용이 안되면 문제 수정 단계로 넘어가 필요한 Data를 확인함
DB Update Test Marketing 적용 결과 평가	<ul style="list-style-type: none"> DB 업데이트 및 테스트 마케팅을 적용한 결과 보고서를 평가하는 단계 - 제품화 결과에 따라 확대 적용 및 반응 결과 보고서 평가 제품화 결과가 좋지 않으면 문제 수정 단계로 이동해서 지속적 반복 수행
제품화	<ul style="list-style-type: none"> 제품화 단계로 제품 판매 또는 서비스 제공
확대 적용 및 반응 평가	<ul style="list-style-type: none"> 소비자의 제품 판매 또는 서비스 제공 확대 적용 및 판매 반응 평가하는 단계 - 문제 정의 단계로 이동해서 다음 문제의 원인과 해결 방안을 모색하고 목적을 설정하는 절차를 반복 수행함



[데이터 마이닝 방법론] CRISP-DM

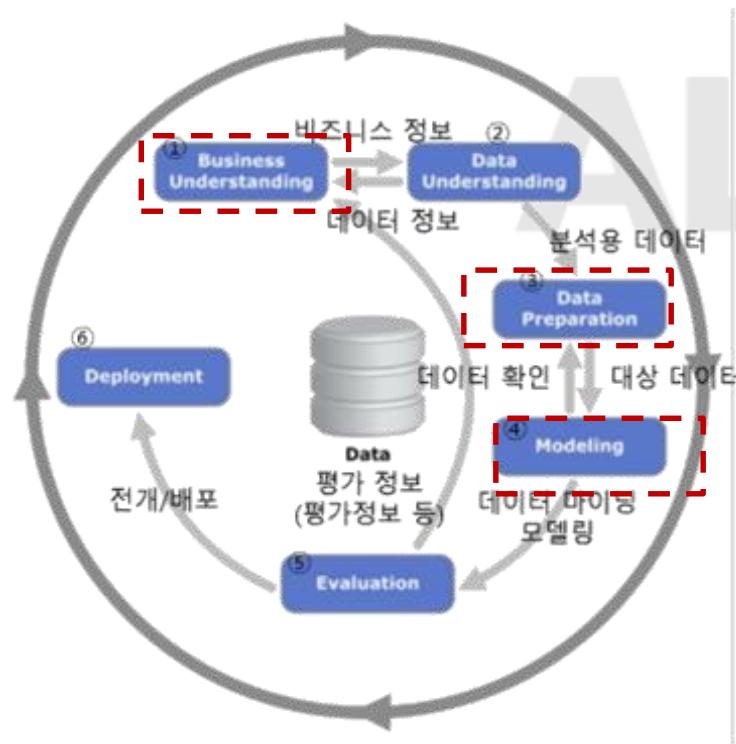
비즈니스의 이해

6 단계

1. 계층적 프로세스 모델, CRISP-DM (Cross Industry Standard Process for Data Mining) 방법론

- 비즈니스 이해, 데이터분석을 이용하여 수행하는, 비즈니스 현장에서 가장 많이 쓰이는 방법론
- 유럽연합에서 시작된 프로젝트에 SPSS, NCR 등이 참여한 첫 버전인 CRISP-DM은 계층적 프로세스 모델로써 4개 레벨과 6단계로 수행되는 데이터 마이닝 방법론
- 6 단계 : 비즈니스 이해 - 데이터 이해 - 데이터 준비 - 모델링 - 평가 - 전개(지속개선)

2. CRISP-DM 개념도 및 6단계 프로세스



단계	General Task	Task 설명	Output/산출물
① Business Understanding	Determine Business Objectives	비즈니스 관점 고객 이해	Success Criteria
	Assess Situation	영향평가 및 상황조사	Costs and Benefits
	Determine Data Mining Goals	기술관점 목표수립	Goals and Criteria
	Produce Project Plan	프로젝트 세부계획 수립	Initial Assessment
② Data Understanding	Collect Initial Data	초기데이터 수집/확보	Initial Data Report
	Describe Data	수집데이터 특성확인	Describe Report
	Explore Data	목표 부합데이터 추출	Explore Report
	Verify Data Quality	데이터 품질 검사/검증	Quality Report
③ Data Preparation	Select Data	분석대상 데이터 선별	Rationale
	Clean Data	데이터 정제, 품질확보	Cleaning Report
	Construct Data	분석데이터 구조화	Attributes/Records
	Integrate Data	모델링 위한 데이터 통합	Merged Data
	Format Data	모델 적합 위한 형식 보완	Reformatted Data
④ Modeling	Select Modeling Techniques	데이터 모델링 기법 선택	Tech. & Assumptions
	Generate Test Design	품질검증/유효성 검사	Test Design
	Build Model	유효 모델링 생성	Parameter Settings
	Assess Model	모델 순위 지정	Model Assessment
⑤ Evaluation	Evaluate Results	측정/모델링 결과 평가	Approved Models
	Review Process	중요항목 도출/확인	Review Report
	Determine Next Steps	다음 단계 결정	List of Actions
	Plan Deployment	전개 전략 수립	Plan Report
⑥ Deployment	Plan Monitoring and Maintenance	지속/유지 전략수립	Detail Plan
	Produce Final Report	최종보고서 작성	Final Report
	Review Project	최종보고서 검토	Final Documentation

- 데이터 분석과 비즈니스 이해를 바탕으로 6 단계로 수행되는 데이터 마이닝 방법론

[데이터 마이닝 방법론] 비교

1. SEMMA vs CRISP-DM 분석 방법론 비교

비교항목	SEMMA	CRISP-DM
개요	SAS 등에서 추진된 5 개 프로세스 기반 데이터마이닝 분석 방법론	SPSS 등에서 추진된 4 레벨, 6 단계 프로세스 기반 데이터마이닝 분석 방법론
프로세스	Sample -> Explore -> Modify -> Modeling -> Assess	Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, Deployment
주요특징	개발자 관점에서 데이터 마이닝 집중으로 인해 비즈니스 관점이 미흡	비즈니스 문제 인식과 상황을 고려한 데이터 마이닝 결과 해석에 집중함
업계동향	SAS 데이터 통계 패키지에 활용	IBM SPSS 중점 추진
활용Tool	SAS Enterprise Miner	SPSS Modeler
적용분야	SAS Enterprise Miner 에 사용	주로 빅데이터 분석에 활용

2. 데이터 분석 프로세스 과정 SEMMA vs CRISP-DM 비교

프로세스	SEMMA	CRISP-DM
비즈니스 이해	없음	- Business Understanding (고객 요구사항과 비즈니스 목표 이해)
필요 데이터 정의	- Sample,(분석 데이터 생성 및 준비) - Explore(분석 데이터를 탐색해 기초 통계 변수 유의성 및 상관분석 등)	- Data Understanding (초기 데이터 수집 및 이해, 데이터 품질 정의)
파생 데이터 설계 및 데이터 작업 요건 전달	- Modify (분석 데이터 수정/변환)	- Data Preparation (모델링 대상 데이터 준비)
분석 모델 설계 및 테스팅	- Model (모델 구축, 데이터의 숨겨진 패턴 발견)	- Modeling (모델링 기법을 선택 및 최적 값 가진 파라미터 변수 설정)
분석결과 평가	- Assessment (모델 평가 및 검증)	- Evaluation (평가를 통한 비즈니스 목표 달성을 위한 모델 선정)
분석결과에 대한 비즈니스 Action Plan	없음	- Deployment (프로세스를 통한 획득한 지식을 실행 계획을 수립하고 고객에게 제시)

3. 데이터 마이닝 방법론 비교

비교항목	CRISP-DM	SEMMA	KDD
개요	SPSS 등에서 추진된 6 개프로세스기반 데이터마이닝 방법론	SAS 등에서 추진된 5 개프로세스기반 데이터마이닝 방법론	데이터 Insight 발굴을 위한, 5 개프로세스기반 데이터마이닝 방법론
프로세스	Business Understanding, Data Understanding 등 6 개프로세스	Sample, Explore, Modify, Model, Assess 5 개프로세스	Select, Pre-processing, Transformation, Data Mining, Interpretation Evaluation 5 개프로세스
주요특징	비즈니스문제인식 및 비즈니스 상황에 따른 데이터마이닝 결과해석	기술적관점 마이닝 집중으로 비즈니스관점분석 미약	기술과 데이터베이스를 중심으로한 지식발견을 위한 절차와 전 단계 정리
동향	IBM SPSS 중점추진	SAS 통계패키지 활용	연구활용 (Fayyad, Han 등)
활용패키지	SPSS Modeler	SAS Enterprise Miner	OracleData Mining
명칭	Cross Industry Standard Process for Data Mining	Sample, Explore, Modify, Model and Assess	Knowledge Discovery in Database

연관규칙(Association)

지지도 | 신뢰도 | 향상도

1. 두 제품 또는 사건 사이의 연관성의 발견, 연관규칙(Association Rule)의 개요

- 특정 사건(상품 구매)들이 동시에 발생하는 빈도로 상호간의 연관성을 표현하는 규칙
- 대용량 데이터베이스 내의 단위 트랜잭션에서 빈번하게 발생하는 사건의 유형을 발견 (장바구니 분석)



후보 데이터군 → 최소한의 지지도
DB검색

$$S = P(X \cap Y) = \frac{\text{품목 } X \text{와 품목 } Y \text{를 포함하는 거래 수}}{\text{전체 거래 수}(N)}$$

↑ 친화성 ↴

의미가 있는
후보 데이터군을
추출
Apriori 방법

2. 연관규칙 탐색 원칙

- 최소지지도(minimum support) : 분석자가 정하는 최소한의 지지도
- 최소신뢰도(minimum confidence) : 분석자가 정하는 최소한의 신뢰도
- 연관규칙의 탐색은 최소지지도와 최소신뢰도를 넘는 모든 가능한 연관규칙을 찾음

- 대용량 데이터군 검색: 트랜잭션을 대상으로 최소지지도 이상을 만족하는 빈발항목 집합을 발견하는 과정
- 연관규칙 발견: 발견된 다량 항목 집합 내에 포함된 항목들 중에서 최소신뢰도 이상을 만족하는 항목들 간의 연관규칙을 생성하는 단계

항목	설명
단계1	• 빈발 항목집합의 생성(Frequent Item Set Generation), 최소지지도(minimum support)를 만족하는 모든 빈발항목을 찾는다
단계2	• 연관규칙의 생성 (Rule Generation), 단계 1에서 찾은 빈발항목집합에서 • 최소신뢰도 (minimum confidence) 가 높은 모든 연관 규칙을 찾는다

3. 연관 정도를 정량화 하기 위한 세 가지 기준(척도)

구분	설명	공식												
지지도 (Support)	• 전체 거래 중 항목 X와 항목 Y를 동시에 포함하는 거래의 정도를 나타내며 전체 구매도에 대한 경향 파악	$C = P(Y X) = \frac{P(X \cap Y)}{P(X)}$ = 품목 X와 품목 Y를 포함하는 거래 수 품목 X를 포함한 거래 수												
신뢰도 (Confidence)	• 항목 X를 포함하는 거래 중에서 항목 Y가 포함될 확률이 어느 정도인가를 나타내며 연관성의 정도를 파악	$L = \frac{P(Y X)}{P(Y)} = \frac{P(X \cap Y)}{P(X)P(Y)}$												
향상도 (Lift /Improvement)	• 항목 X를 구매한 경우 그 거래가 항목 Y를 포함하는 경우와 항목 Y가 임의로 구매되는 경우의 비	<table border="1"> <tr> <th>Lift</th> <th>의 미</th> <th>예</th> </tr> <tr> <td>1</td> <td>두 품목이 서로 독립적인 관계</td> <td>과자와 후추</td> </tr> <tr> <td>>1</td> <td>두 품목이 서로 양의 상관 관계</td> <td>빵과 버터</td> </tr> <tr> <td><1</td> <td>두 품목이 서로 음의 상관 관계</td> <td>지사제, 변비약</td> </tr> </table>	Lift	의 미	예	1	두 품목이 서로 독립적인 관계	과자와 후추	>1	두 품목이 서로 양의 상관 관계	빵과 버터	<1	두 품목이 서로 음의 상관 관계	지사제, 변비약
Lift	의 미	예												
1	두 품목이 서로 독립적인 관계	과자와 후추												
>1	두 품목이 서로 양의 상관 관계	빵과 버터												
<1	두 품목이 서로 음의 상관 관계	지사제, 변비약												

연관규칙(Association)

4. 연관규칙의 장단점

구분	설명	설명
장점	탐색적 기법	• 조건 반응(if-then)으로 표현되는 연관성분석의 결과 이해가 쉬움
	강력한 비목적성 분석기법	• 분석방향이나 목적이 특별히 없는 경우 목적변수가 없으므로 유용함
	사용 편리한 분석데이터의 형태	• 거래내용에 대한 데이터를 변환 없이 그 자체로 이용할 수 있는 간단한 자료구조를 갖는 분석방법
	계산의 용이성	• 분석을 위한 계산이 비교적 간단
단점	많은 계산과정	• 품목수가 증가하면 분석에 필요한 계산은 기하급수적으로 늘어남
	적절품목 결정 필요	• 너무 세분화된 품목을 가지고 연관성 규칙을 찾으면 의미 없는 분석이 될 수도 있음
	품목 간 비율차이 발생	• 거래량이 적은 품목은 포함된 거래수가 적으며, 규칙발견 시 제외되기가 쉬움

5. 사례

판매 품목	거래 수
TV 구매	4,000
DVD 구매	2,000
TV와 DVD 동시 구매	1,000
전체 거래 수	10,000

TV에 대한 DVD의 지표분석 (TV를 사면 DVD도 같이 산다.)

$$\text{지지도(Support)} : \text{전체 거래 중 TV와 DVD를 구매한 사람 비율} \\ = \text{TV \& DVD} / \text{전체거래 수} = 1,000 / 10,000 = 10\%$$

$$\text{신뢰도(Confidence)} : \text{TV를 산 사람들 중에 DVD를 산 사람들의 비율} \\ = \text{TV \& DVD} / \text{TV} = 1,000 / 4,000 = 25\%$$

$$\text{리프트(Lift)} : \text{TV를 사면 DVD도 같이 사는 경우의 비율} \\ = \text{지지도} / (\text{TV구매확률} * \text{DVD구매확률}) \\ = 0.1 / (0.4 * 0.2) = 1.25 > 1 \therefore \text{연관성 있음.}$$

우유 ⇒ 주스의 지지도와 신뢰도가 각각 얼마인가

$$\text{지지도} = (\text{우유} + \text{주스 거래수}) / \text{전체거래수} = 2 / 4 = 50\%$$

$$\text{신뢰도} = (\text{우유} + \text{주스 거래수}) / \text{우유가 포함된 거래수} = 2 / 3 = 67\%$$

$$\text{리프트} = \text{지지도} / (\text{우유구매확률} * \text{주스구매확률}) = 0.5 / (0.75 * 0.5) = 1.33$$

트랜잭션-id	구매한 상품
101	우유, 빵, 주스
792	우유, 주스
1130	우유, 계란
1735	빵, 과자, 커피



[연관규칙] Apriori

빈발항목집합 선형적 규칙 최소지지도 최소신뢰도

1. 데이터 마이닝 기술에서 연관규칙을 찾아주는 알고리즘, Apriori 의 개요

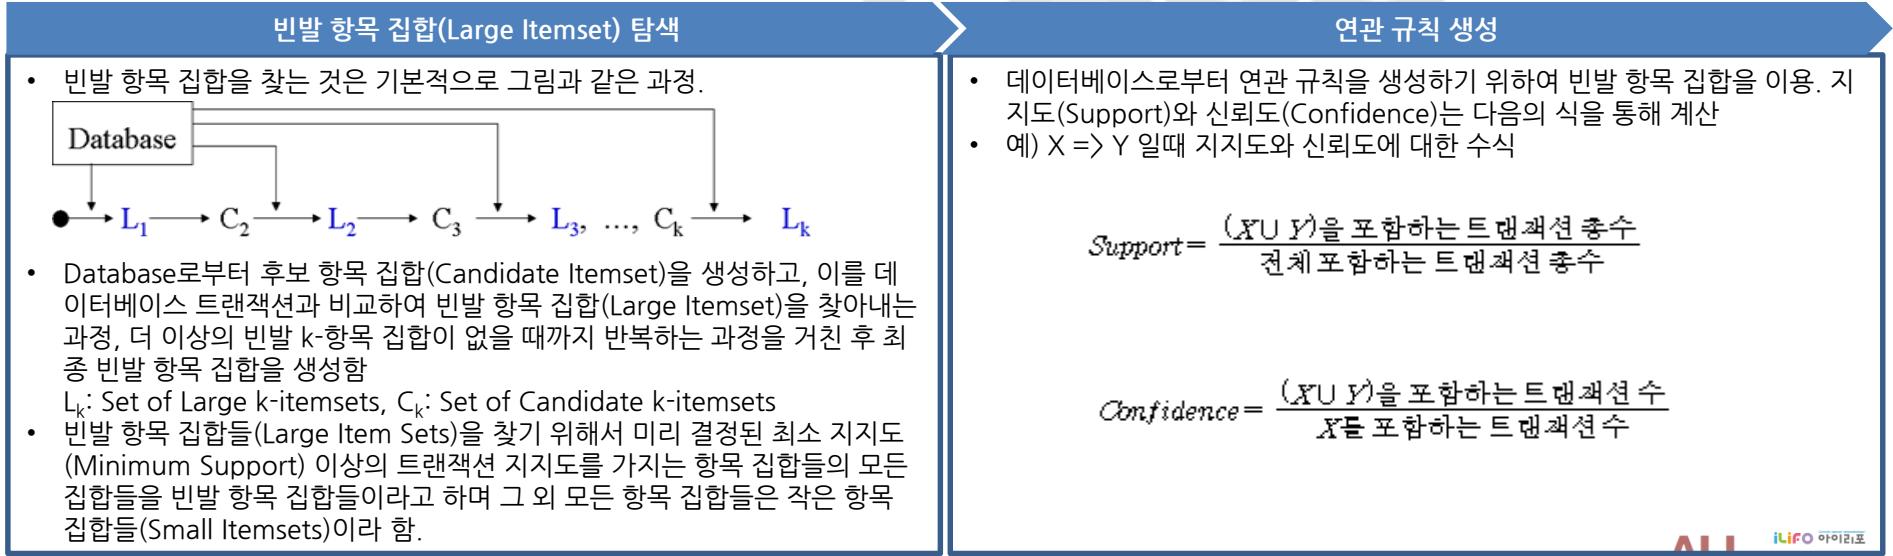
- 데이터들에 대한 발생 빈도를 기반으로 각 데이터간의 연관관계를 밝히기 위한 수학적 접근 알고리즘
- 데이터베이스에서 후보 항목집합(Candidate Item set)을 생성하고, 이를 데이터베이스 트랜잭션과 비교하여 후보 항목 집합들의 발생 빈도를 계산하고, 사용자가 정의한 최소지지도를 기준으로 빈발 항목집합(Frequent Item set)을 결정하는 알고리즘
- 어 프라이오리(a priori) : 시스템 기술등을 종합적으로 검토하고 선형성(경험에 선행하는 선천적인 인식)을 높이는 인식
- (원리) 어떤 항목집합이 빈발하다면, 그 항목집합의 모든 부분집합도 빈발함

2. Apriori 의 선형적 규칙

특징	설명
규칙 1	한 항목집합이 빈발 하다면, 이 항목집합의 모든 부분집합은 빈발항목 집합 예) 모든 항목집합 {a, b, c, d}, 빈발항목집합 {b, c, d}라면, 이 집합의 부분집합 {b, c}, {b, d}, {c, d}, {b}, {c}, {d}는 빈발항목 집합
규칙 2	한 항목집합이 비 빈발 하다면, 이 항목집합을 포함하는 모든 집합은 비 빈발항목 집합 예) 모든 항목집합 {a, b, c, d}, 비 빈발항목집합 {a, b}라면, 이 집합을 포함하는 {a, b, c}, {a, b, d}, {a, b, c, d}는 비 빈발항목 집합

- Apriori 알고리즘을 적용해 빈발집단을 결정하여 3 가지 척도를 계산해 연관분석을 수행함

3. Apriori 알고리즘의 연관규칙 탐색 과정

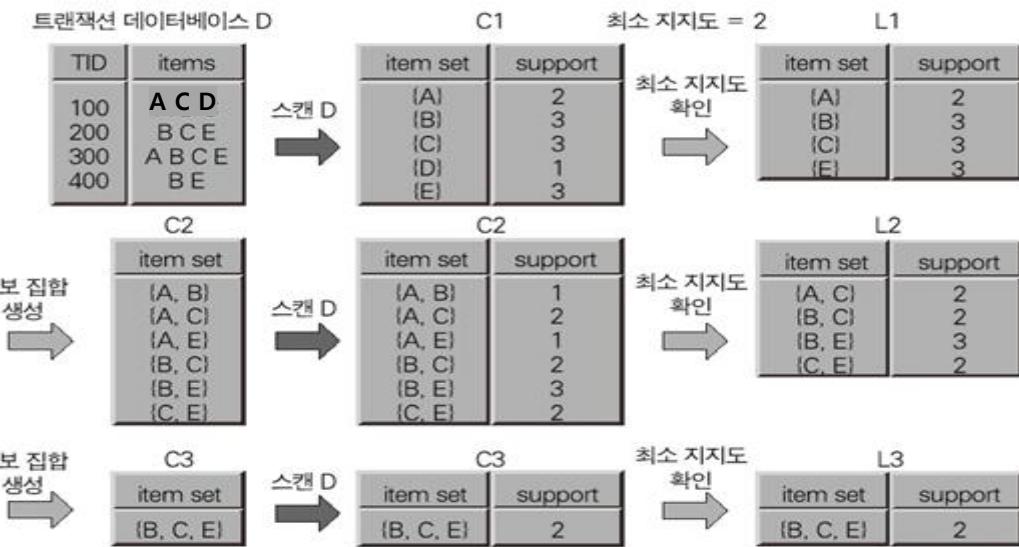


[연관규칙] Apriori

3. Apriori 알고리즘 예시

- 최소 지지도 = 50% 이고 최소 신뢰도 80% 이상인 연관 규칙 찾기
- Join Step: $C_k = L_{k-1} \bowtie L_{k-1}$ (\bowtie = natural join)
- Prune Step: C_k 의 모든 $(k-1)$ -subset이 L_{k-1} 에 속하는 C_k 만 보존

[빈발 항목 탐색 과정]



※ 원래 지지도는 “구매건수/전체구매건수”로 계산할 수 있지만, 계산의 편의를 위해, 단순히 아이템의 개수로 계산하시오

[빈발 항목 집합]

규칙	지지도(X Y)	지지도 (X)	신뢰도
{A} → {C}	2	2	100
{B} → {C}	2	3	66.7
{B} → {E}	3	3	100
{C} → {E}	2	3	66.7
{B} → {C E}	2	3	66.7
{C} → {B E}	2	3	66.7
{E} → {B C}	2	3	66.7
{C} → {A}	2	3	66.7
{C} → {B}	2	3	66.7
{E} → {B}	3	3	100
{E} → {C}	2	3	66.7
{C E} → {B}	2	2	100
{B E} → {C}	2	3	66.7
{B C} → {E}	2	2	100

4. Apriori의 효율을 증대하는 기법

- Apriori 알고리즘은 구현하기 쉽고, 이해하기 쉬우며 어느정도 만족할 만한 결과를 주기 때문에 자주 쓰이고 있으나, 후보 집합 생성시에 아이템의 개수가 많아지면 계산 복잡도가 엄청나게 증가하게 되는 문제 발생
- 해시 기반 기법(항목집합의 개수를 해싱하기): 해시 기반 기법은 후보 k-항목 집합 $C_k (k > 1)$ 의 크기를 줄이는데 사용
- 트랜잭션 감소(다음 단계에서 스캔될 트랜잭션의 수를 줄임): 빈발 k-항목집합을 포함하지 않는 트랜잭션은 당연히 빈발($k+1$)-항목집합을 포함하지 않으므로 해당 트랜잭션을 제거함
- 분할(후보 항목집합을 탐색하기 위한 데이터 분할): 분할기법은 빈발 항목집합을 발견하기 위하여 단지 두 번의 데이터베이스 스캔을 요구할 때 사용
- 샘플링(주어진 데이터의 일부분으로 마이닝): 주어진 데이터 D에서 임의의 샘플 S를 취한 후에 D대신에 S에서 빈발 항목 집합을 탐색

[연관규칙] Apriori

5. Apriori 알고리즘 풀이사례

트랜잭션 데이터베이스 D

TID	items
100	A C D
200	B C E
300	A B C E
400	B E

C1 최소 지지도 = 2

item set	support
{A}	2
{B}	3
{C}	3
{D}	1
{E}	3

최소 지지도 확인

item set	support
{A}	2
{B}	3
{C}	3
{E}	3

후보 집합 생성

C2 스캔 D

item set	support
{A, B}	
{A, C}	
{A, E}	
{B, C}	
{B, E}	
{C, E}	

스캔 D

item set	support
{A, B}	1
{A, C}	2
{A, E}	1
{B, C}	2
{B, E}	3
{C, E}	2

최소 지지도 확인

item set	support
{A, C}	2
{B, C}	2
{B, E}	3
{C, E}	2

후보 집합 생성

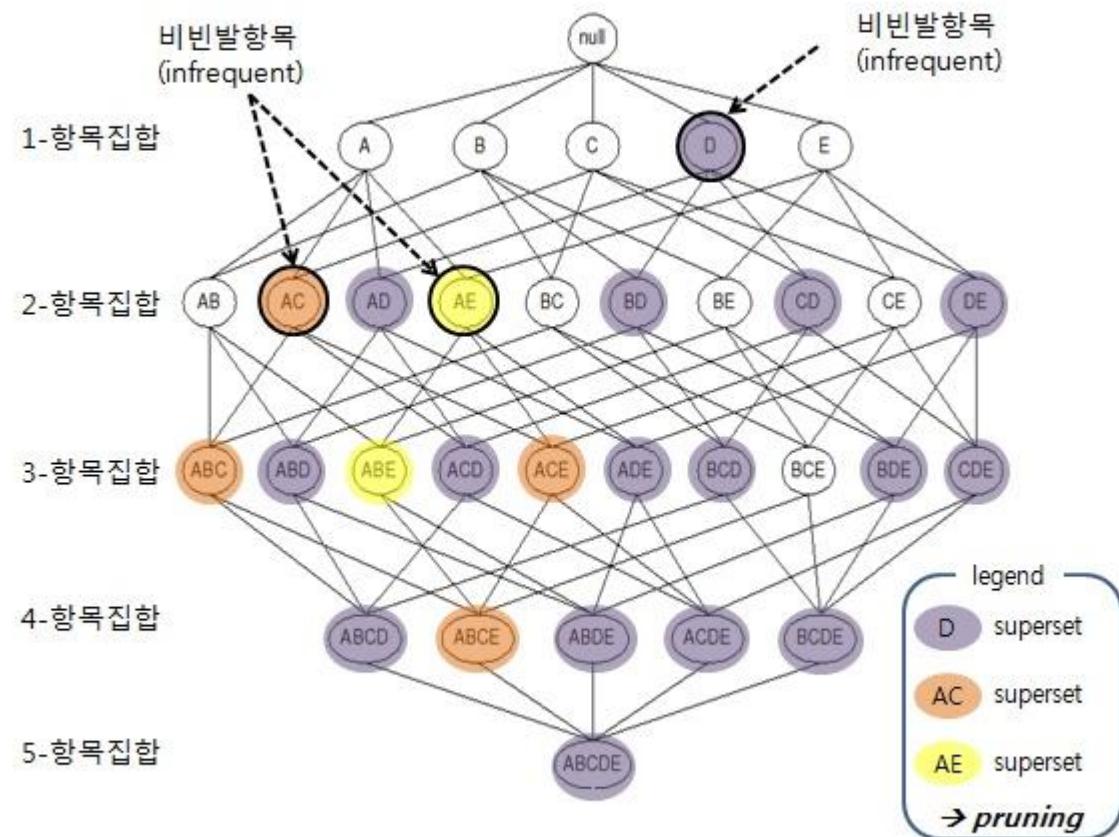
C3 스캔 D

item set	support
{B, C, E}	2

최소 지지도 확인

item set	support
{B, C, E}	2

{D}, {A, C}, {A, E}가 infrequent item set 일 경우 superset pruning 예시



[R 분석과 프로그래밍] <http://rfriend.tistory.com>

연속규칙

1. 연관 규칙에 시간의 개념을 첨가한, 연속규칙의 개요

- **연관 규칙에 시간의 개념을 첨가하여** 시간의 흐름에 따른 항목들의 상호 연관성을 탐색
- 동시에 구매될 가능성이 큰 상품군을 찾아내는 연관성 측정에서 시간이라는 시계열 자료의 개념이 포함되어 순차적인 구매 가능성이 큰 상품군을 찾아내는 것

2. 순차패턴 마이닝의 알고리즘 단계

구분	단계	내용
1단계	Sort Phase - 거래의 정렬단계	<ul style="list-style-type: none">• 거래 데이터베이스 원본을 시퀀스 데이터베이스로 변환• 거래 데이터베이스는 고객의 ID를 주 키로 하고, 거래 시간을 보조키로 하여 정렬되어야 함
2단계	Large itemset Phase - 빈도가 높은 항목 집합 발견 단계	<ul style="list-style-type: none">• 빈도가 많은 항목집합(Large itemset : itemset) L의 집합을 발견• 동시에 빈도가 높은 1-시퀀스의 모든 집합을 발(최소지지도를 만족하는 빈도가 높은 항목집합을 찾는 단계)• 여기서, 지지도는 항목집합을 포함하는 고객의 수를 의미한다. 한 고객이 다른 거래에서 같은 항목을 사더라도 지지도는 한 번만 계산된다. 구해진 빈도가 높은 항목을 연속된 정수로 변환한다
3단계	Transformation phase - 거래 데이터베이스 변환 단계	<ul style="list-style-type: none">• 주어진 빈도가 높은 시퀀스들의 집합이 고객의 시퀀스에 포함되어 있는지를 반복적으로 결정할 필요가 있다. 이러한 검정을 빠르게 하기 위해서 우리는 고객 각각의 시퀀스를 또 다른 표현으로 변환시킨다. 각각의 거래에서 빈도가 높은 항목집합을 포함하고 있는 거래만을 존속시킨다. 또한 고객의 시퀀스가 어떤 빈도가 높은 항목집합도 포함하고 있지 않다면 이를 제거시키지만 고객의 총 수를 계산에서는 포함시킨다. 이 과정을 통하여 각 거래의 항목들이 거래에 속하는 빈도가 높은 항목으로 대체되는 것이다. 이러한 변환을 통하여 고객의 시퀀스는 이제 빈도가 높은 항목집합의 리스트만으로 표현되게 된다.
4단계	Sequence phase - 빈도가 높은 시퀀스 발견단계	<ul style="list-style-type: none">• 원하는 시퀀스를 발견하기 위해서 빈도가 높은 항목의 집합을 사용한다. 알고리즘의 각 단계는 빈도가 높은 시퀀스를 초기 입력 값의 집합으로 놓고 시작한다. 그러한 초기 입력 값 집합을 새로운 잠재적 빈도가 높은 시퀀스를 생성하기 위해 사용하며, 이러한 잠재 시퀀스를 “후보 시퀀스(candidate sequence)” 라 부른다. 주어진 데이터베이스를 이용하여 후보 시퀀스에 대한 지지도를 구한다. 사용자가 기술한 최소지지도를 만족하는 후보 시퀀스만이 실제빈도가 높은 시퀀스가 된다. 이러한 빈도가 높은 시퀀스가 다음 단계의 초기 입력 값이 된다. 첫 번째 단계에서 최소 지지도를 가지는 모든 1-시퀀스는 빈도가 높은 항목 집합에서 얻어지며 초기 입력값 집합을 형성한다.
5단계	Maximal phase - 최대 시퀀스 발견 단계	<ul style="list-style-type: none">• 빈도가 높은 시퀀스들의 집합 중에서 최대 시퀀스를 발견• 여기서 구해진 최대 시퀀스(maximal sequence)가 순차 패턴 마이닝의 최종 결과가 됨

분류(classification)

1. 데이터마이닝 분류 기법의 개요

- 다수의 속성(attribute) 또는 변수를 갖는 객체(object)를 **사전에 정해진 그룹 또는 범주(class, category)** 중의 하나로 **분류**하는 분석 기법

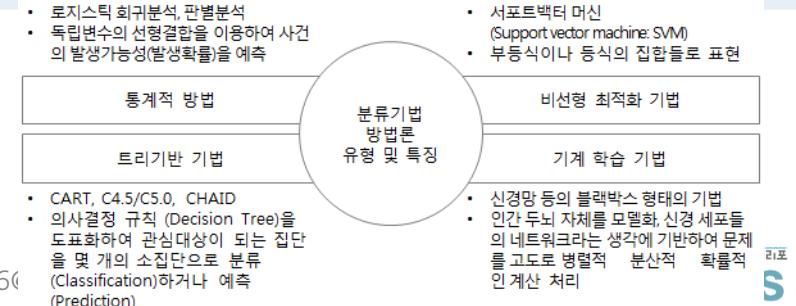
2. 데이터마이닝 분류 기법의 개념도



- 소속집단을 알고 있는 데이터를 이용하여 모형을 만들고, 소속집단을 모르는 데이터의 집단을 결정하는 기법

3. 유사한 데이터 집단을 결정하는 분류분석 모형

분류	모형	특징
통계기반	베이즈(Bayes) 분류모형	<ul style="list-style-type: none"> 각 집단으로 분류되는 사전확률(prior probability)과 집단별가능도확률(likelihood probability)을 알 때, 소속집단을 모르는 데이터에 대하여 베이즈정리(Bayes theorem)를 이용한 사후확률(posterior probability)를 구하여 그 확률이 높은 집단으로 분류하는 방법
	로지스틱(Logistic)회귀 모형	<ul style="list-style-type: none"> 선형회귀모델에서 종속변수 Y가 범주형인 경우로 확장한 것 (예: 성공/실패 등…) 분류함수를 의사결정규칙으로 표현할 때 타원(분기점), 직선(가지), 사각형(잎사귀)을 이용하여 나무형태로 그려서 분석하는 도구
수학/ 컴퓨터 기반	의사결정나무(Decision Tree) 분류모형	<ul style="list-style-type: none"> “if ~ then..” 규칙들의 집합을 사용하여 항목들을 분류하는 방법. 둘 이상의 클래스를 포함하는 데이터 집합에서 한 번에 한 클래스씩 규칙들을 얻음
	규칙기반(Rule Based) 분류모형	<ul style="list-style-type: none"> 새로운 데이터(설명변수값)에 대해 이와 가장 유사한(거리가 가까운) k-개의 과거 자료(설명변수값)의 결과(반응변수: 집단)를 이용하여 다수결로 분류함. 과거자료를 이용하여 미리 분류모형을 수립하는 이 아니라, 과거 데이터를 저장만 해두고 필요시 비교를 수행하는 방식
비선형 최적화 기법	SVM (Support Vector Machine) 모형	<ul style="list-style-type: none"> 수학함수를 이용하여 데이터 공간을 나누는 방식. 선형함수를 이용하여 나누는 선형SVM과 비선형함수를 이용하여 나누는 비선형SVM이 있음
기계학습 기법	양상분 모형	<ul style="list-style-type: none"> 여러 개의 분류모형에 대한 결과를 종합하여 한 데이터를 분류하는 모형. 결과의 종합은 다수결이나 기타 방법을 사용
	신경망(Neural Network) 모형	<ul style="list-style-type: none"> 사람의 두뇌와 유사하게 여러 개의 노드를 네트워크로 연결하여 데이터를 분류하는 의사결정을 함. 일반화된 비선형함수를 분류함수로 이용



클러스터 (군집분석(cluster analysis))

1. 각각의 군집 데이터의 대표 값으로 전체 데이터 특성을 파악하는 클러스터 탐지의 개요

- 전체 데이터를 몇 개의 집단으로 그룹화하여 각 집단의 성격을 파악함으로써 데이터 전체의 구조에 대한 이해를 돋고자 하는 분석법
- 각 개체간의 유사도(similarity) 혹은 비유사도(dissimilarity)를 기반으로 서로 유사한 개체를 동일한 그룹에 할당하여 분석하는 기법
- 클러스터 : 비슷한 특성을 가진 데이터들의 집단 (비계획된 기계학습 (unsupervised machine learning))
- 소속집단을 모르고 있는 데이터를 이용하여 유사한 데이터들의 집단을 결정하는 기법

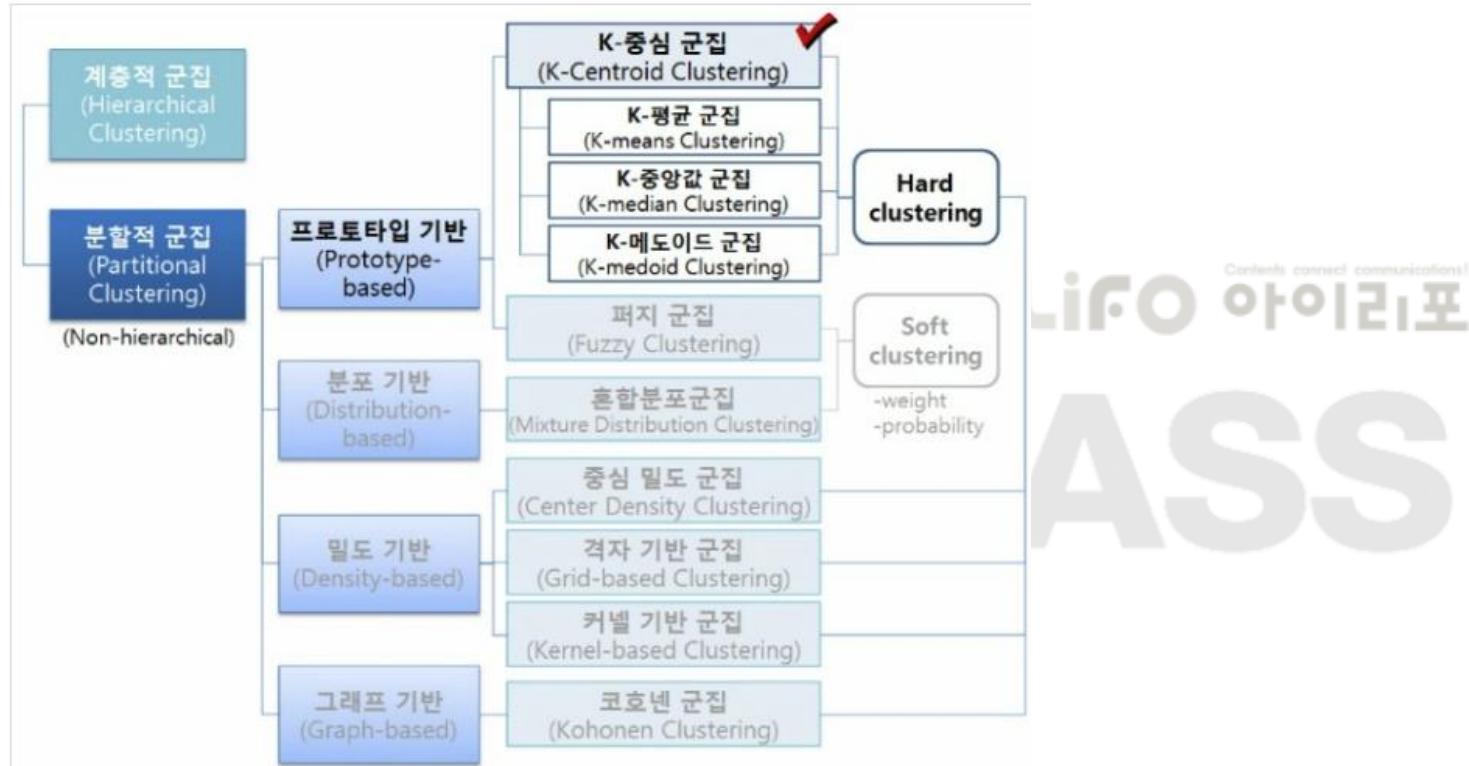
특징	설명
탐색적인 기법	주어진 자료에 대한 사전정보 없이 의미 있는 자료구조를 찾아 낼 수 있음
다양한 형태의 데이터에 적용가능	거리만 잘 정의되면 모든 종류의 자료에 적용 할 수 있음
분석자에 의존	자료의 사전 정보 없이 자료를 파악하는 방법으로, 분석자의 주관에 결과가 달라짐
분석방법 용이	분석방법의 적용이 쉬움
가중치 및 거리	가중치와 거리의 정의가 어려움
결과 해석	결과의 해석이 어려움
초기 군집수 K 결정	초기 군집수 K의 결정이 어려움

2. 분산 데이터의 유사도 기반 그룹핑, 군집 알고리즘의 분류

분류	알고리즘	사례
Partitioning Methods	<ul style="list-style-type: none">사전에 결정된 군집들의 수를 사용하는 것레코드들을 군집에 할당계산량이 많지 않아서 대량의 DB에서 유용	K-means K-medoids PAM CRARA CRARANS
Hierarchical Methods	<ul style="list-style-type: none">병합 또는 분할 방법 사용병합: n개의 군집들을 가지고 시작해서 최종적으로 하나의 군집이 남을 때까지 순차적으로 유사군집 병합분할: 병합과 반대. 모든 레코드들을 포함하고 있는 하나의 군집에서 출발군집들을 자연적인 계층으로 정리하고자 할 때 유용	CURE CHAMELON BIRCH
Model Based Methods	<ul style="list-style-type: none">어떤 정보가 hidden 되어있는 경우 가장 그럴듯한 모델 추정시 사용하는 효과적 반복 알고리즘Maximum Likelihood Estimate 방법을 사용관측된 데이터에 알맞은 모델의 변수(parameter) 추정	EM (Expectation Maximization)

클러스터 (군집분석(cluster analysis))

[분할적 군집 (Partitional Clustering, Non-hierarchical Clustering)]



클러스터 (군집분석(cluster analysis))

3. 다차원 공간의 거리관점 유사도 측정방식

거리계산법	공식 및 설명																
유클라디안거리	<p>p차원의 공간 위에 있는 두 점 x와 y 사이의 유클리드 거리 $d(x,y)$</p> <p>$p=2$인 경우, 즉 2차원에서 유클리드 거리는 $d(x,y)=\sqrt{(x_1-y_1)^2 + (x_2-y_2)^2}$</p> <p>$A$와 B 간의 유클리드 거리제곱 = $\sum_{j=1}^p (X_{jA} - X_{jB})^2$</p> <p>$A$와 B 간의 유클리드 거리 = $\sqrt{\sum_{j=1}^p (X_{jA} - X_{jB})^2}$</p>																
민코프스키(Minkowski)거리	<p>민코프스키 거리는 유클리드 거리를 일반화한 것</p> <p>P는 양의 정수로 디폴트 값은 2</p> $d(x,y)=(\sum_{i=1}^p x_i - y_i ^m)^{1/m}$																
맨해튼 거리	<p>두 관찰치 사이의 거리로 각 변수 값 차이의 절대값의 합</p> $d_1(\mathbf{p}, \mathbf{q}) = \ \mathbf{p} - \mathbf{q}\ _1 = \sum_{i=1}^n p_i - q_i $ <p>만약 $\mathbf{p} = (p_1, p_2, \dots, p_n)$과 $\mathbf{q} = (q_1, q_2, \dots, q_n)$은 공간 벡터가 된다.</p>																
표준화 거리	$d(x, y) = \left(\sum_{i=1}^p (x_i - y_i)^2 / s_i^2 \right)^{1/2}$																
범주형 자료의 거리	<p>불일치 항목수</p> $d(A, B) = 2, d(A, C) = 1, d(B, C) = 3$ <table border="1"> <tr> <td>개체</td> <td>성별</td> <td>학력</td> <td>출신지역</td> </tr> <tr> <td>A</td> <td>남자</td> <td>고졸</td> <td>경기</td> </tr> <tr> <td>B</td> <td>여자</td> <td>고졸</td> <td>전남</td> </tr> <tr> <td>C</td> <td>남자</td> <td>대졸</td> <td>경기</td> </tr> </table>	개체	성별	학력	출신지역	A	남자	고졸	경기	B	여자	고졸	전남	C	남자	대졸	경기
개체	성별	학력	출신지역														
A	남자	고졸	경기														
B	여자	고졸	전남														
C	남자	대졸	경기														

클러스터 (군집분석(cluster analysis))

4. 군집분석의 고려사항

구분	설명
표준화	<ul style="list-style-type: none">군집분석은 자료 사이의 거리를 이용하여 수행되기 때문에 자료의 단위가 결과에 큰 영향을 미침표준화 : 각 변수의 관측값에서 평균을 빼고 표준편차로 나누는 것표준화 된 자료는 모든 변수가 평균이 0이고 표준편차가 1
가중치	<ul style="list-style-type: none">각 변수의 중요도가 다를 경우 가중치를 이용하여 각 변수의 중요도를 조절가중치는 대부분의 경우 단위변환(표준화)를 수행한 후 부여가중치에 대한 군집의 영향을 평가하기 위하여 여러 가지의 가중치에 대하여 군집분석의 결과를 비교

5. 군집분석의 장단점

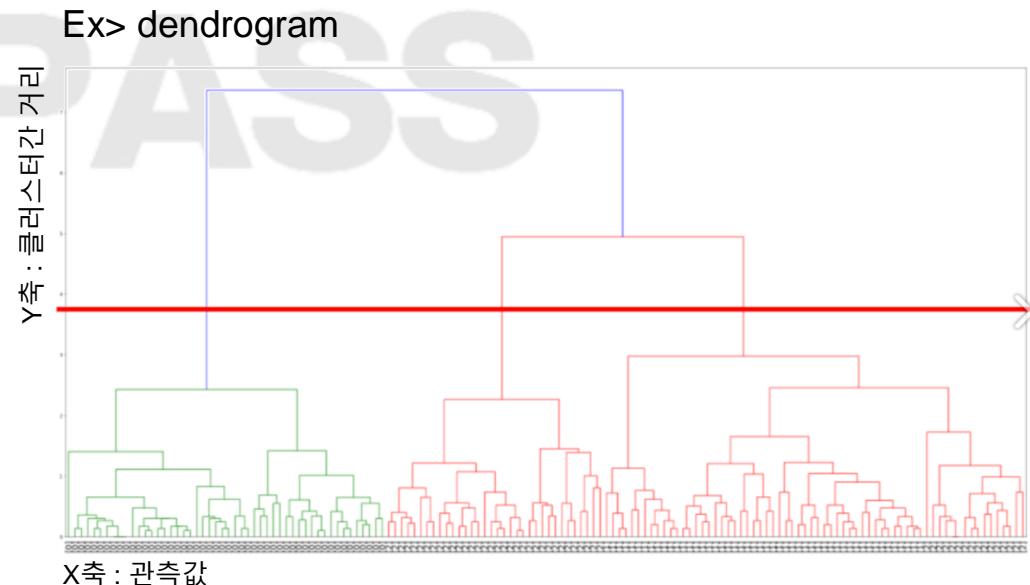
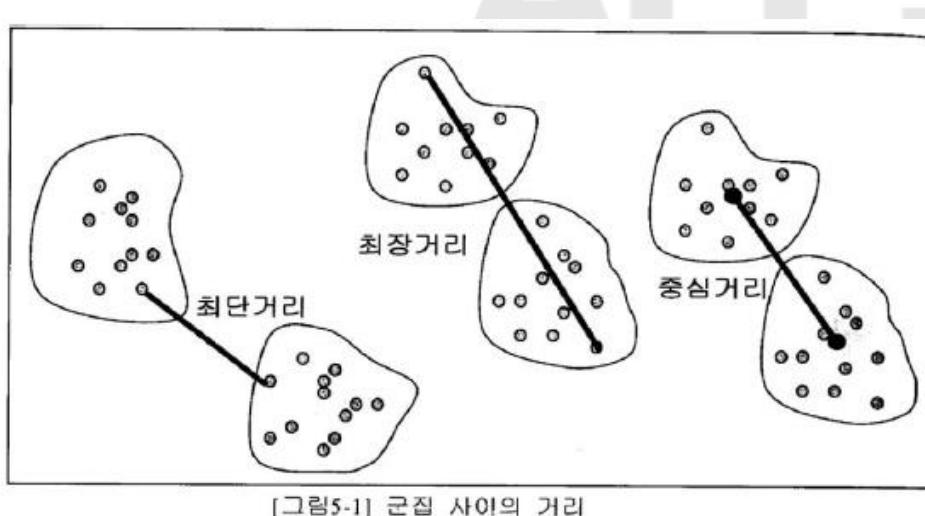
구분	세부사항	설명
장점	탐색적인 기법	군집분석은 그 자체가 대용량 데이터에 대한 탐색적인 기법으로서, 주어진 데이터의 내부구조에 대한 사전적인 정보 없이 의미 있는 자료구조를 찾아낼 수 있는 방법
	다양한 형태의 데이터에 적용 가능	분석을 위해서는 기본적으로 관찰치 간의 거리를 데이터형태에 맞게만 정의하면, 거의 모든 형태의 데이터에 대하여 적용이 가능한 방법
	분석방법의 적용 용이성	대부분의 군집방법이 분석대상 데이터에 대해 사전정보를 거의 요구하지 않음 적용 유리 즉, 모형화를 위한 분석과 같이 사전에 특정 변수에 대한 역할 정의가 필요하지 않고 다만 관찰치들 사이의 거리만이 분석에 필요한 입력자료로 사용.
단점	가중치와 거리 정의	군집분석의 결과는 관찰치 사이의 비 유사성인 거리 또는 유사성을 어떻게 정의하느냐에 따라 크게 좌우, 따라서 관찰치들 사이의 거리를 정의하고 각 변수에 대한 가중치를 결정하는 것은 매우 어려운 문제다.
	초기 군집수의 결정	k -평균 군집분석에서는 사전에 정의된 군집 수를 기준으로 동일한 수의 군집을 찾게 되므로 만일 군집수 k 가 원 데이터구조에 적합하지 않으면 좋은 결과를 얻을 수 없다.
	결과해석의 어려움	탐색적인 분석방법으로의 장점을 가지고 있는 반면에 사전에 주어진 목적이 없으므로 결과를 해석하는데 있어서 어려움 존재

계층적 군집분석(Hierarchical Cluster Method)

1. 계층적 군집 분석의 개요

- **가까운 관측 값들끼리 묶는 병합**(agglomeration)과 먼 관측 값을 나누어가는 분할(division)에 의해 전체 군집들간 구조적 관계를 분석하는 기법
- 병합방법 : 최단거리, 최장거리, 평균거리 방법 등

계층적 군집분석	구분	설명
	병합계층 군집화	-Agglomerative Hierarchical Method -단일 개체로부터 시작하여 서로 유사한 개체들끼리 병합하는 방법
	분할계층 군집화	-Divisive Hierarchical Method -단일 그룹에서 시작하여, 두 개의 하위 그룹으로 분할하는 방법



비계층적 군집분석

1. 비계층적 군집분석의 개요

- 관측 값들을 몇 개의 군집으로 나누기 위하여 주어진 판정기준을 최적화
- 대표적인 비계층적 군집분석 방법이 K-Means, K-medoids, DBSCAN

	사용되는 유사도 측정 방식	하이퍼 파라미터	장점	단점 (한계점)
k 평균	좌표 기반 거리 구하기 (유clidean, 마할라노비스, 맨하탄)	<ul style="list-style-type: none">군집 개수종료 조건	<ul style="list-style-type: none">알고리즘이 쉽고 직관적임분산 시스템을 이용한 대용량 데이터 처리 가능각 유형의 특징 파악 용이	<ul style="list-style-type: none">아웃라이어에 민감유형별 데이터의 분산이 비슷하고 구형으로 분포되어 있지 않으면 결과가 좋지 못함
DBSCAN	좌표 기반 거리 구하기 (유clidean, 마할라노비스, 맨하탄)	<ul style="list-style-type: none">군집의 최소 개체 수 (minPts)밀도 측정 최소 범위 (epsilon)	<ul style="list-style-type: none">아웃라이어 제외 가능다양한 분포의 데이터에 대해서 군집 분석 가능	<ul style="list-style-type: none">군집 간의 밀도 차이가 불분명하면 결과가 좋지 못함각 유형의 특징 파악하기 어려움
GMM	좌표 기반 거리 구하기 (유clidean, 마할라노비스, 맨하탄)	<ul style="list-style-type: none">군집 개수종료 조건	<ul style="list-style-type: none">확률 분포의 차이를 고려하여 군집을 묶는 방식이기 때문에 k 평균 알고리즘에 비해 좀 더 통계적으로 엄밀한 결과를 얻을 수 있음	<ul style="list-style-type: none">계산량이 많기 때문에 대량의 데이터에 사용하기 어려움유형들의 분포가 정규 분포와 차이가 크다면 결과가 좋지 못함
계층 클러스터링	모든 유사도 측정 방식 사용 가능	<ul style="list-style-type: none">군집 개수군집 간의 거리 측정 방법	<ul style="list-style-type: none">개체간의 거리는 구할 수는 있지만 군집의 평균을 구할 수 없는 데이터에 대해서도 적용 가능	<ul style="list-style-type: none">계산량이 많기 때문에 대량의 데이터에 사용하기 어려움

[회귀] 회귀분석 (Regression Analysis)

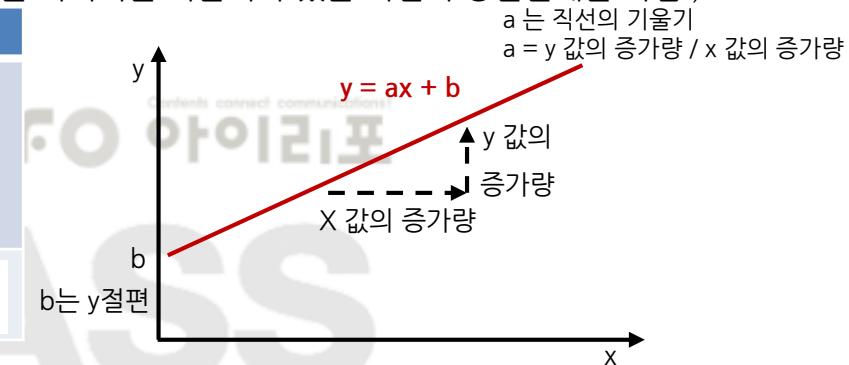
1. 회귀 분석의 개요

- 하나 또는 그 이상의 **변수들이 또 다른 변수에 미치는 영향에 대해 추론**할 수 있는 통계 기법
- 원인이 되는 값과 결과가 되는 값의 상관관계를 통계적 기법에 의해 조사하는 대표적인 분류 기법

2. 회귀분석의 유형

- 독립변수의 수에 따른 유형 ($y = \text{절편} + \beta x$ 는 기울기로, 독립변수 1개를 가지는 회귀식은 기울기가 있는 직선의 상관관계를 가짐.)

독립변수 수	유형	회귀식(사례)
독립변수 1개	단순회귀분석 Simple Regression Analysis	$y = \alpha + \beta x + \epsilon$ 종속변수 ↑ ↓ 독립변수 모회귀계수
독립변수 2개 이상	다중회귀분석 Multiple Regression Analysis	$Y_i = \alpha + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + \epsilon_i$



- 종속변수의 수에 따른 유형

종속변수 개수	유형	독립변수 개수
종속변수 1개	일변량 회귀분석	단순 회귀분석 ($y = ax + b$)
종속변수 2개 이상	다변량 회귀분석	다중 회귀분석 ($y = a_1X_1 + a_2X_2 + \dots + a_nX_n$)

- 종속변수의 형태에 따른 유형

연속형	범주형(이산형)
종속변수 Y가 확률값을 갖는 연속형 변수 회귀분석(Regression Analysis) 직교회귀분석(Orthogonal Regression Analyses)	종속변수 Y가 범주형(이산형) 변수 로지스틱 회귀분석 Logistic Regression Analysis

- 직교회귀분석은 종속변수 Y값과 방정식간의 직각거리를 최소화하는 분석기법
- 로지스틱 회귀분석은 종속변수가 2개 이상인 다항 로지스틱 회귀분석과 분화로지스틱 회귀분석으로 분류됨.

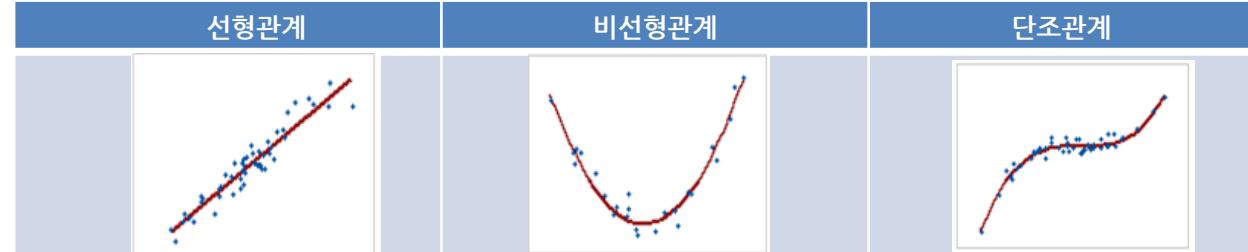
[회귀] 회귀분석 (Regression Analysis)

3. 변수와 관계의 이해

[변수의 이해]

독립변수	종속변수
설명변수	반응변수
예측변수	목표변수
방정식에서 X 값	방정식에서 Y값
Input	output

[관계의 이해]



- 이제 어떤 이름으로 나오더라도 독립변수와 종속변수를 구분할 수 있음

4. 회귀분석의 종류

종류	모형	
단순회귀분석	$Y = ax + b$	설명변수가 1개, 반응변수와의 관계가 직선
다중회귀분석	$Y = ax_1 + bx_2 + cx_3 \dots + e$	설명변수가 k개, 반응변수와의 관계가 선형(1차함수)
다항회귀분석	$Y = ax_1 + bx_2^2 + cx_3^2 \dots + e$	설명변수가 k개, 반응변수와의 관계가 1차 함수 이상
비선형회귀	$Y = g(ax_1 + bx_2 + cx_3 \dots) + e$	계량형 반응 변수와 하나 이상의 설명 변수 사이의 비선형 관계를 설명

5. 회귀분석에서 설명변수 선정 방법

유형	방법	설명
모든 가능한 조합의 회귀분석 (all possible regression)	AIC(Akaike Information Criterion)	-정보량 규준(information criterion)을 손실 가중치의 계산 법 -모형과 데이터의 확률 분포 사이의 Kullback-Leibler 수준을 가장 크게 가져감
	BIC(Bayesian Information Criterion)	-정보량 규준(information criterion)을 손실 가중치의 계산 법 -exponential family라는 가정하에 주어진 데이터에서 모형의 likelihood를 측정
단계적 변수 선택 (stepwise variable selection)	전진선택법(forward selection)	중요하다고 생각되는 설명변수부터 선택
	후진제거법(backward elimination)	제곱합을 기준으로 가장 적은 영향을 주는 변수부터 제거 선택
	단계별방법(stepwise method)	전진선택법에 의해 변수 추가하면 새롭게 추가된 변수에 기인해 기존 변수가 그 중요도가 약화되면 해당 변수 제거

정규화 선형회귀(Regularized Linear Regression)

1. 회귀식의 과적합을 막기 위한 정규화 선형회귀

- 정규화 선형회귀(Regularized Linear Regression) : 선형회귀 계수(weight)에 대한 제약 조건을 추가함으로써 모형이 과도하게 최적화되는 현상, 즉 과최적화를 막는 회귀분석 기법
- 선형회귀 계수(weight)에 대한 제약 조건을 추가함으로써 모형이 과도하게 최적화되는 현상, 즉 과최적화를 막는 회귀분석 기법

2. 정규화 선형회귀의 유형

유형	설명	Python 함수명
Ridge	가중치들의 제곱합(squared sum of weights)을 최소화하는 것을 추가적인 제약 조건으로 하는 정규화 선형회귀 기법	Ridge()
LASSO	Lasso(Least Absolute Shrinkage and Selection Operator) 가중치의 절대값의 합을 최소화하는 것을 추가제약 조건으로 하는 정규화 선형회귀 기법	LASSO()
Elastic Net	가중치의 절대값의 합과 제곱합을 동시에 최소화하는 것을 추가 제약 조건으로 하는 정규화 선형회귀 기법	ElasticNet()

3. 세부 정규화 유형

- 회귀식 : $Y = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p + \epsilon$
- 잔차제곱합(residual sum of squares, RSS) : $RSS = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \dots - \beta_p x_{ip})^2$
- λ : hyper parameter 분석자가 지정함

유형	최적화 목적함수식	설명
Ridge	$W = RSS + \lambda \sum_{j=1}^p \beta_j^2$	<ul style="list-style-type: none">(모든 계수의 제곱합) X (지정된 상수 λ)를 식이 추가RSS와 동시에 추가식(상수 λ, 계수 β)를 최소화가 목표임, 그래서 Shrinkage Penalty로 불림계수 β의 제곱에 비례하는 Penalty추가 → L2 규제
LASSO	$W = RSS + \lambda \sum_{j=1}^p \beta_j $	<ul style="list-style-type: none">(모든 계수의 절대값합) X (지정된 상수 λ)를 식이 추가적당한 λ만으로 일부 계수를 0으로 가게 만들 수 있음, 중요하지 않은 변수삭제 효과가 있어서, Sparse Model로 불림계수 β의 절대값에 비례하는 Penalty추가 → L1 규제
Elastic Net	$W = RSS + \lambda_1 \sum_{j=1}^p \beta_j^2 + \lambda_2 \sum_{j=1}^p \beta_j $	<ul style="list-style-type: none">Ridge 와 Lasso를 결합한 규제(모든 계수의 제곱합) X (지정된 상수 λ) + (모든 계수의 절대값합) X (지정된 상수 λ)를 식이 추가

정규화 선형회귀(Regularized Linear Regression)

4. Ridge, Lasso의 기하학적 해석

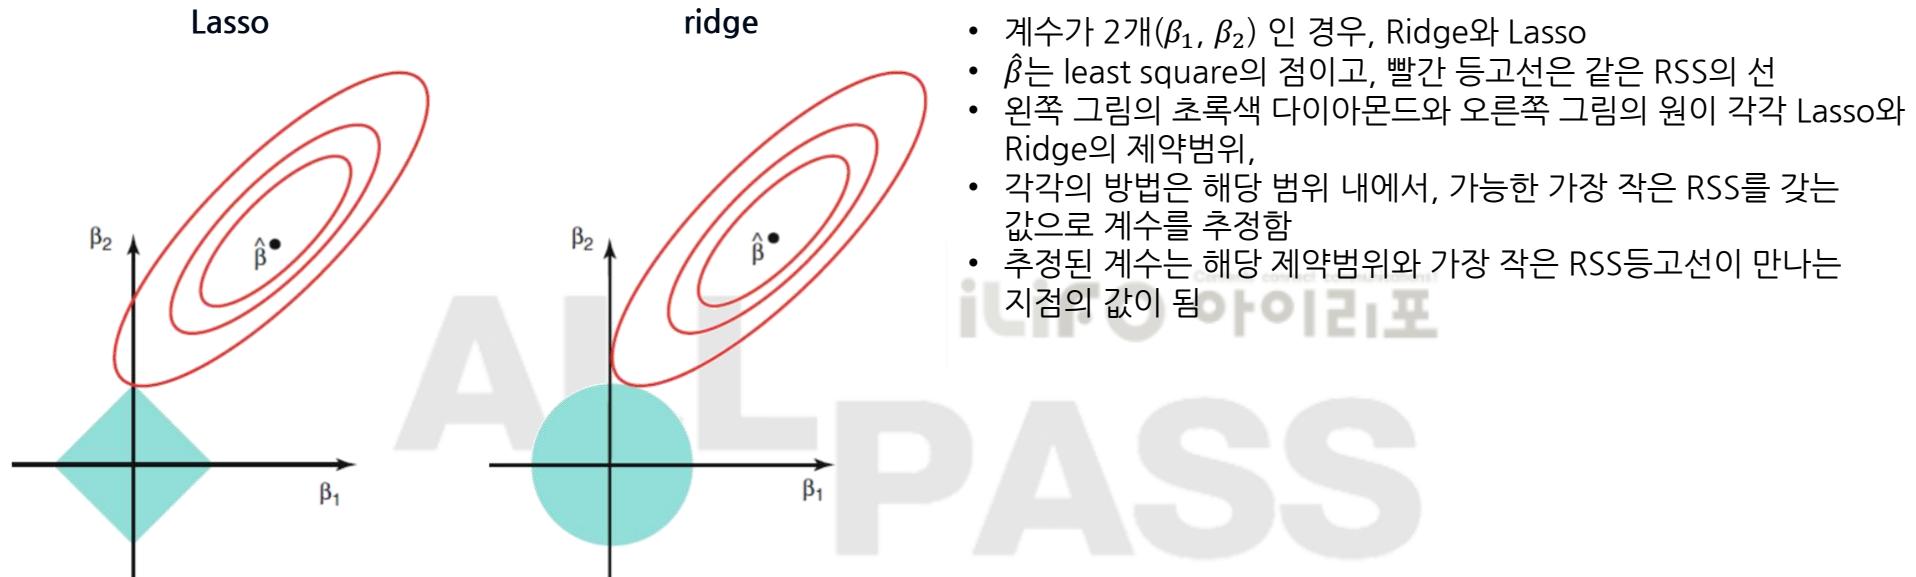


FIGURE 6.7. Contours of the error and constraint functions for the lasso (left) and ridge regression (right). The solid blue areas are the constraint regions, $|\beta_1| + |\beta_2| \leq s$ and $\beta_1^2 + \beta_2^2 \leq s$, while the red ellipses are the contours of the RSS.

선형회귀분석

선형성 | 독립성 | 정규성 | 등분산성

1. 선형회귀의 개요

- 종속변수 y 와 한 개 이상의 독립 변수 x 와의 선형 상관 관계를 모델링하는 기법.
- 독립변수 개수에 따라 단순/다중 선형 회귀 분석 구분

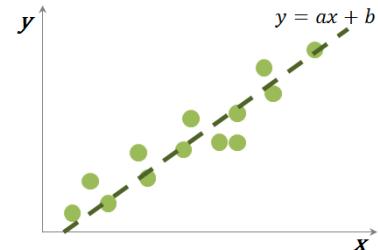
2. 선형회귀분석의 사용 및 선호이유

- 해석이 용이 : 모수는 기울기, 설명변수 한단위 증가할 때 종속변수의 단위 변화량이 나타남
- 로그변환 통한 선형 변환 가능 : 양쪽 변수에 로그를 취하여 선형함수로 만들 수 있음

3. 선형회귀모형 추론

- 하나 또는 그 이상의 독립변수(X)의 종속변수(Y)에 대한 상관관계를 나타내는 선형회귀모형을 추론하기 위해 반드시 만족해야 하는 **선형성, 독립성, 등분산성, 정규성** 등의 기본 성질

4. 선형회귀모형의 추론에 대한 4가지 가정



필요성	설명
설명변수 전처리	최적의 모델 생성 위해 변수 선택, 로그, 루트, 이상치 제거 등 수행
유의한 모델 생성	4가지 가정을 모두 만족하는 유의한 선형회귀모형 생성
예측력 향상	가정의 검증 및 위배시 해결 통하여 선형회귀모형의 예측력 향상

구분	가정	설명	위배 시 해결법
모형에 대한 가정	선형성	<ul style="list-style-type: none">예측하고자 하는 종속변수 y와 독립변수 x간에 선형성을 만족한다고 가정종속변수와 독립변수 간의 선형성을 만족함독립성	<ul style="list-style-type: none">잔차의 분포가 고르게 분포하지 못하고 오류값이 선형성을 나타냄이차항 추가
	독립성	<ul style="list-style-type: none">독립변수 x 간에 상관관계가 없음을 가정다중회귀분석에서 독립변수 X간의 상관관계가 없이 독립성을 만족함	<ul style="list-style-type: none">일정한 패턴을 보일 경우 강한 상관관계를 띠고 있어 독립성 위배다중공선성을 일으키는 변수 제거 필요 (R의 Step 함수 이용)
오차에 대한 가정	잔차의 등분산성	<ul style="list-style-type: none">잔차는 정규분포를 따른다고 가정잔차(Residual)의 분산이 같아 특정한 패턴이 없이 고르게 분포함	<ul style="list-style-type: none">y가 커짐에 따라 잔차가 커지며 등분산성 만족하지 않음이차항 추가하거나 로그나 루트를 취해 분산을 일정하게 해주어야 함
	잔차의 정규성	<ul style="list-style-type: none">잔차가 특정한 패턴 없이 고르게 분포한다고 가정잔차의 분포가 평균이 0인 정규성을 만족함	<ul style="list-style-type: none">잔차가 정규 분포를 따르지 못할 경우 정규성을 만족하지 못함로그나 루트를 취함이상치를 제거

[회귀] 로지스틱 회귀(Logistic Regression)

범주형 승산비 로짓 로그

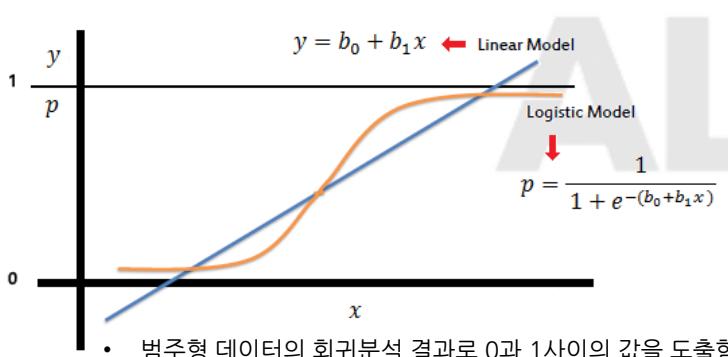
1. 범주형 종속변수의 회귀식, 로지스틱 회귀분석의 개요

- 분석 대상들이 여러 집단으로 나누어진 경우, 독립 변수의 선형 결합을 이용하여 **개별 관측치가 어느 집단에 속하는지 확률을 계산**하는 분류 기법

2. 로지스틱 회귀분석의 특징

- 승산비 (odds rate) : $(p/(1-p))$
- Logit & Log : **0과 1 사이 값을 취하기 위해 log를 이용하여 변환 (로짓 변환)**, 최종적으로 로지스틱 함수를 얻어 분석에 이용

3. 로지스틱 회귀분석의 그래프 및 주요 개념



개념	설명	관련식
승산비	Odds rate (OR) 어떤 사건이 일어날 확률과 일어나지 않을 확률의 비	$\text{odds} = \frac{p(y=1 x)}{1 - p(y=1 x)}$
Log	log 는 $(-\infty, \infty)$ 의 값 가능하여 회귀 모형 성립이 가능	$\text{Log (odds)} = \text{Log}(p/1-p)$
Logit	Log 연산을 통한 Logit 획득 (0~1)	$\text{logit}(p) = \log \frac{p}{1-p}$

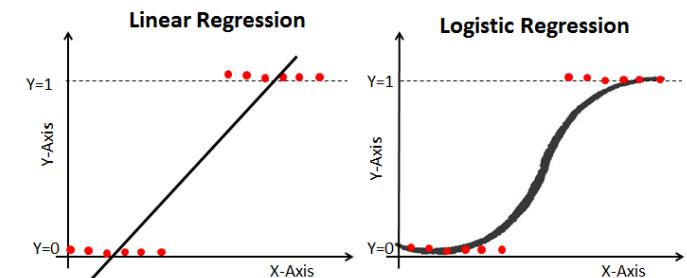
3. 로지스틱 회귀변수에 사용하는 범주형 변수 및 로지스틱 회귀분석 유형

- 범주형 변수

변수유형	범주 수	예
명목형	2개(이분형)	질병 유무(1:유, 0:무), 생존 여부 등
	3개이상	건강 보험 종류(1:지역 의료 보험, 2:직장, 3:의료급여 1종...) 등
순서형	3개이상	소득 수준 (1:하, 2:중 하, 3:중 상, 4:상) 등

- 로지스틱 회귀분석 유형

독립변수	단순 로지스틱 회귀변수	다중 로지스틱 회귀변수
연속형	독립변수 값의 1단위별 변화에 따른 종속변수의 오즈비 변화량	다른 독립변수를 통제한 상태 하에서 독립 변수 값의 1단위별 변화에 따른 종속변수의 오즈비 변화량
범주형	기준 범주에 대비한 다른 범주와의 오즈비 차이	다른 독립변수를 통제한 상태 하에서 기준 범주에 대비한 다른 범주와의 오즈비 차이



[회귀] 로지스틱 회귀분석의 로짓변환

log 와 odds 이므로 줄여서 로짓이라 부름

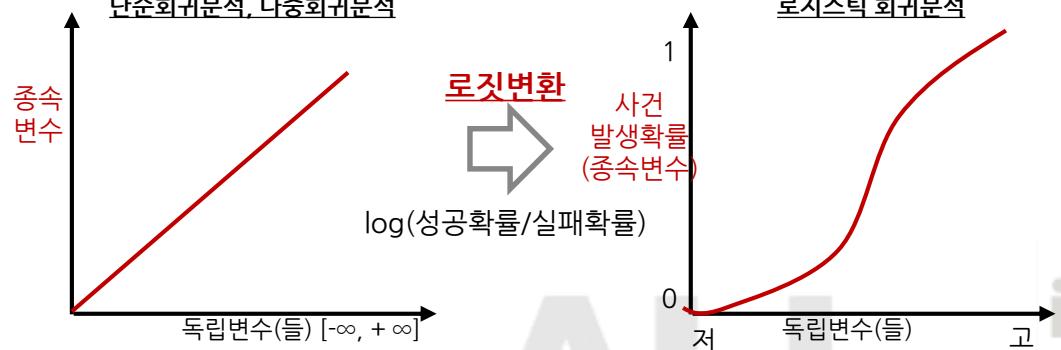
승산비(odds)

자연로그

확률표현

1. 상하한 경계 제한을 없애는 로짓 변환(logit transformation)

단순회귀분석, 다중회귀분석



- 종속변수가 이산형 비연속 자료인 경우 활용
- 독립변수의 계수들에 대한 종속변수의 범위를 [0, 1]사이의 확률 값으로 변환하기 위해 자연로그를 취하는 과정
- 자연로그(Log)와 승산비(Odds)의 변환으로 오즈에 로그를 취한 변환 과정
- 계수들에 대해 비선형인 odds ratio(성공확률/실패확률)를 선형으로 변환하기 위해 자연로그를 취하는 과정
- 입력값의 범위가 $[-\infty, +\infty]$ 일 때, 출력값의 범위가 [0, 1]로 조정됨
- 승산비(Odds) = (성공확률 / 실패확률)

2. 로짓변환의 의의

의의	설명	활용
종속변수 상한, 하한 제한	독립변수(입력)에 따른 종속변수(출력)이 $[-\infty, +\infty]$ 로 나타나는 범위를 확률 값 [0, 1]로 변환	종속변수의 [0, 1]의 확률 표현
선형함수 표현	독립변수에 대한 로짓 변환으로 선형적 표현	[0, 1]의 선형 그래프 표현
종속변수의 분류	판정기준치(cut off)에 따른 분류화	클러스터링, 데이터마이닝

3. 로짓변환의 원리

$$y = \log(\text{odds}) \text{ 표현이 가능하므로 } y = a + bx \quad \log(\text{odds}) = a + bx \text{ 표현 가능, 즉, 종속변수의 확률적 표현 가능}$$

구분	설명	목표
확률의 선형 모형 표시	• $y = a + bx$ 의 선형모델 (a, b 는 계수, x 는 독립변수)	y 는 종속변수로서 확률을 의미하도록 표현
범위의 문제	• 독립변수 x 의 범위는 $[-\infty, +\infty]$, 따라서 종속변수 y 의 범위도 $[-\infty, +\infty]$	확률 표현으로 y 의 범위는 [0, 1]로 표현
오즈(odds) 적용	• 오즈(odds, 승산비) = 성공확률 / 실패확률 • 예) 성공확률 2/10, 실패확률 8/10 일 경우 오즈는 $(2/10) / (8/10) = 1/4$	일반적으로 성공확률/전체확률의 표현에서 오즈는 성공확률/실패 확률로 전체 시행 수를 제거
범위 변경	• 확률의 범위는 [0, 1] • 확률의 비율인 오즈의 범위는 $[0, \infty]$	- 확률의 범위는 [0, 1] - 확률의 비율인 오즈의 범위는 $[0, \infty]$
로그 적용	• $-\infty <= \log(\text{odds}) <= \infty$ • $a + bx$ 의 종속변수의 범위 $[-\infty, +\infty]$ 와 동일	- $y = \log(\text{odds})$ 로 표현

[회귀] 로지스틱 회귀분석의 로짓변환

4. 로짓변환 절차

절차	수식표현	설명
승산비 (odds) 이용	$\frac{P}{1 - P}$	<ul style="list-style-type: none">사건이 발생할 확률인 p 와 발생하지 않은 확률인 $1 - p$ 의 비율Odds는 성공(1)확률이 실패(0) 확률에 비해 몇 배 더 높은가를 나타냄
로짓변환 (자연 로그 이용)	$\log\left(\frac{P}{1-P}\right)$	<ul style="list-style-type: none">승산비에 자연로그를 취함Odds에 로그를 취한 값으로 입력값의 범위가 $[-\infty, +\infty]$ 일 때 출력값의 범위를 $[0, 1]$로 조정

5. 로짓변환의 활용

분야	활용	설명
데이터 마이닝	분류기법	<ul style="list-style-type: none">종속변수가 범주형인 경우 사용(불량/양호, 합격/불합격 등)
머신러닝	활성화 함수	<ul style="list-style-type: none">입력데이터에 대한 출력 데이터의 활성여부의 함수를 적용

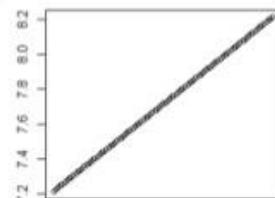
상관분석

1. 상관분석의 개요

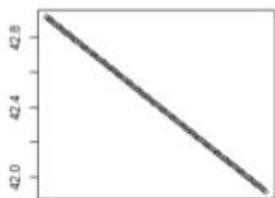
두 변수간에 어떤 선형적 관계를 갖고 있는지를 분석하는 방법

- 피어슨 상관계수(Pearson correlation coefficient)
 - 공분산을 이용하여 두 변수의 상관관계를 -1과 1의 값을 갖도록 하는 상관계수
 - 비선형 상관관계는 나타내지 못함

$$\rho = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2} \sqrt{\sum_i (y_i - \bar{y})^2}}$$



강한 양의 상관관계

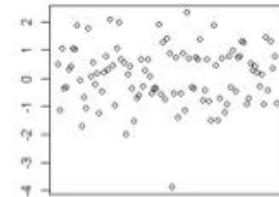


강한 음의 상관관계

- 스피어만 상관계수(Spearman's rank correlation coefficient)
 - 두 변수를 모두 **순위**로 변환시킨 후, 두 순위 사이의 관계를 피어슨 상관계수로 정의하는 상관계수

r_i 는 $\{x_1, x_2, x_3 \dots\}$ 에서의 x순위
 s_i 는 $\{y_1, y_2, y_3 \dots\}$ 에서의 y순위

$$r_s = \frac{\sum_{i=1}^n (R_i - \bar{R})(S_i - \bar{S})}{\sqrt{\sum_{i=1}^n (R_i - \bar{R})^2 \sum_{i=1}^n (S_i - \bar{S})^2}}$$



상관관계 없음



곡선 상관관계

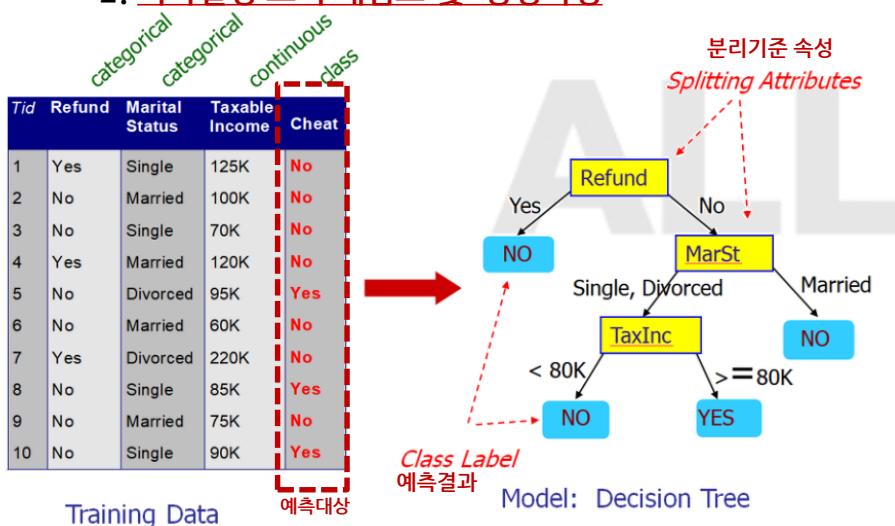
[분류] 의사결정 트리 (Decision Tree)

성장 가지치기 타당성 평가 해석 및 예측 분할속성

1. 의사결정트리의 개요

- 관찰된 데이터로부터 분할기준 속성을 판별하고, 분할기준 속성에 따라 트리 형태로 모델링할 **분류, 예측 모델**
- 가지 분할 시의 정지 규칙을 정하고, 가지 분할을 위한 변수 선택 (엔트로피, 지니, 분류 오류율 등을 이용 - 예시는 분류 오류율 이용)
- 특징: 분류정확도 낮지만 분류과정의 이해 및 설명용이 / 예측보다는 데이터 분류가 주목적
- 구성: Root , Internal , Leaf Node

2. 의사결정 트리 개념도 및 형성과정

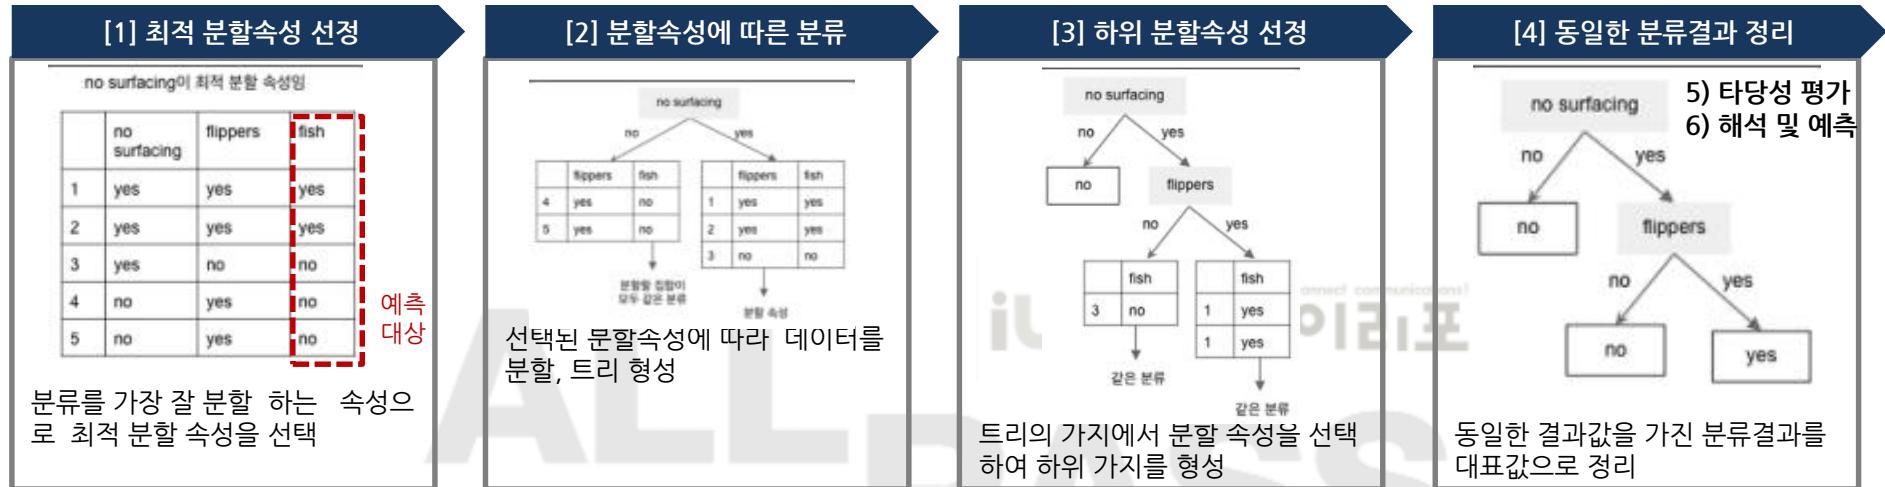


형성단계	설명
의사결정나무 형성	<ul style="list-style-type: none"> 분석목적과 자료구조에 따라 적절한 분리 CHAID (Kas 1980), CART (Breiman et al, 1984), C45(Quinlan, 1993). 분석의 목적과 자료구조에 따라 적절한 분리기준(split criterion)과 정지규칙(stopping rule)을 지정하여 의사결정나무를 얻음 분석의 목적과 자료구조에 따라서 적절한 분리기준(split criterion)과 정지규칙(stopping rule)을 지정하여 의사결정 나무를 획득
가지치기	<ul style="list-style-type: none"> 분류오류나 위험이 높은 부적절한 규칙의 가지 제거 분류오류(classification error)를 크게 할 위험(risk)이 높거나 부적절한 규칙을 가지고 있는 가지(branch)를 제거
타당성 평가	<ul style="list-style-type: none"> 이익도표, 위험도표, 검정자료에 의한 교차 타당성등의 의사결정나무 평가 이익도표(gain chart)나 위험도표(risk chart) 또는 검정용 자료(test data)에 의한 교차타당성(cross validation) 등을 이용해 평가
해석 및 예측	<ul style="list-style-type: none"> 해석 및 예측모형 설정 구축된 의사결정나무를 해석하고 분류 및 예측모형을 설정하여 데이터의 분류 및 예측에 선정된 의사결정나무를 이용

- 정지기준, 분리기준, 평가기준 등을 어떻게 지정하느냐에 따라서 서로 다른 의사결정나무가 형성됨
- 세분화, 분류, 예측, 차원축소 및 변수선택, 교호작용효과의 파악

[분류] 의사결정 트리 (Decision Tree)

3. 의사결정 트리의 형성사례



4. 의사결정 트리 분석을 위한 알고리즘

알고리즘	평가지수(선택방법)	비고
ID3	Entropy	다지분리(범주)
C4.5	Information Gain	다지분리(범주) 및 이진분리(수치)
C5.0	Information Gain	C4.5와 거의 유사
CHAID	카이제곱(범주), F검정(수치)	통계적 접근 방식

$$\text{카이제곱} = \sum (\text{관측값} - \text{기대값})^2 / \text{기대값}$$

종류	설명
CHAID	<ul style="list-style-type: none"> 카이제곱 검정(범주형 목표변수) 또는 F-검정(연속형 목표변수)을 이용하여 다지분리(Multiway Split)를 수행하는 알고리즘 목표변수 별 분류기준 <ul style="list-style-type: none"> * 범주형 : 우도 비카이제곱 통계량, 카이제곱 통계량 * 순서형 : 우도 비카이제곱 통계량 * 연속형 : 우도 비카이제곱 통계량
CART	<ul style="list-style-type: none"> 지니 지수(Gini Index, 범주형) 또는 분산의 감소량(연속형)을 이용하여 이진분리(Binary Split)를 수행하는 알고리즘 지니지수(Gini Index) <ul style="list-style-type: none"> * 순도(Impurity)측정 지수 * n개의 원소 중 임의 2개 추출 시, 서로 다른 그룹에 속할 확률
C5.0	<ul style="list-style-type: none"> ID3라는 이름의 알고리즘으로 만들어졌다가 1993년에 C4.5를 거쳐 1998년에 완성된 알고리즘 * 강점 : 가장 정확한 분류 알고리즘 * 단점 : 명목형 목표 변수만 지원

[분류] 의사결정 트리 (Decision Tree)

5. 의사결정 트리 응용분야

분야	설명
세분화	관측개체를 유사특성 그룹으로 분할하여 그룹별 특성을 발견
분류 및 예측	예측변수에 근거한 목표변수 분류, 규칙 발견을 통한 미래 예측
차원축소 및 변수선택	다수의 예측변수 중에서 목표변수에 큰 영향을 미치는 변수 추출
교호작용 효과 파악	다수의 예측변수 결합으로 목표변수에 작용하는 교호작용 파악
범주의 병합	범주형 목표변수의 범주를 소수의 몇 개로 병합

- 의사결정나무는 분류, 예측 등 다양한 목적으로 사용될 수 있으나 분석의 정확도보다는 분석과정의 설명이 필요한 경우에 더 유용하게 사용됨

6. 의사결정 트리의 장단점

구분	항목	설명
장점	해석의 용이성	모형의 이해가 쉽고 새로운 자료의 모형에 적합하며, 어떤 입력변수가 목표변수를 설명하기에 좋은지 쉽게 파악
	교호효과의 해석	두 개 이상의 변수가 결합하여 목표변수에 어떻게 영향을 주는지 쉽게 파악
	비모수적 모형	선형성, 정규성, 등분산성 등의 가정이 불필요
	분류결과 직관성	결과의 이해도가 높으며 의사결정에 있어 직접적으로 사용할 수 있어 활용도가 높음
단점	불안정성	레코드 개수의 작은 차이에도 트리모양이 크게 달라짐
	비연속성	Greedy 알고리즘의 사용으로 최적의 해를 보장하지 못함
	비안정성	연속형 변수를 비연속적인 값으로 취급하기 때문에 분리의 경계점 부근에서 예측오류가 클 수 있음
	낮은 정확도	분류율의 정확도 측면에서 신경망, 로지스틱 회귀분석 등의 분류방법보다 정확도가 낮음
	알고리즘의 한계	Greedy 알고리즘 사용: 최적의 해를 보장하지 못함
	오버피팅	새로운 데이터에 대한 일반화 성능 미비

[분류] SVM (Support Vector Machine)

커널 평선, 서포트 벡터, 마진, 초평면 (커서마초)

binary classification

회귀

1. 비확률적 이진 선형 분류 모델을 만드는 분류 모델, SVM의 개요

- 주어진 데이터 집합을 바탕으로 하여 새로운 데이터가 어느 카테고리에 속할지 판단하는 비확률적 이진 선형 **분류** 모델을 만드는 분류 모델 알고리즘 .(최적의 Decision Boundary(의사결정 영역)을 찾음)
- 주어진 많은 데이터들을 가능한 멀리 두개의 집단으로 분리시키는 최적의 초평면을 찾는 방법**
- 데이터가 사상된 공간에서 각 집단으로 구분되는 데이터가 가장 큰 폭을 가지는 경계면을 계산하는 패턴 인식 및 자료 분석을 위한 분류 기법 (데이터 클래스간의 폭을(Margin) 극대화 하는 최적화 기반의 분류기)
- 마진이 크면 클수록 학습에 사용하지 않은 새로운 데이터가 들어오더라도 잘 분류할 가능성이 커짐

특징	설명
과적합 회피	- 과적합을 자동으로 회피하면서 예측 정확도를 최대화 하는 기계학습 기법
통계적 학습	- 통계적 학습 이론 기반으로 다양한 영역에서 실제 적용되는 기법
차원의 저주 회피	- 고차원의 문제에서 데이터 집합을 두집단으로 나누는 무수히 많은 의사결정 경계

2. 비선형인 경우 대응 방법

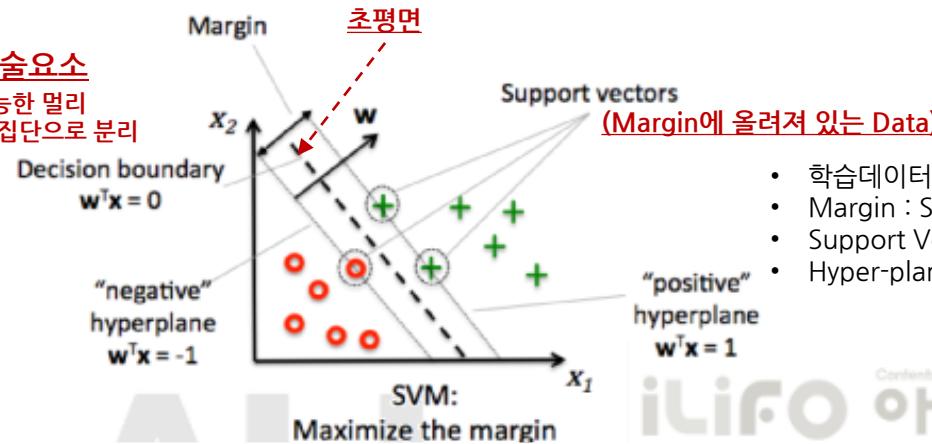
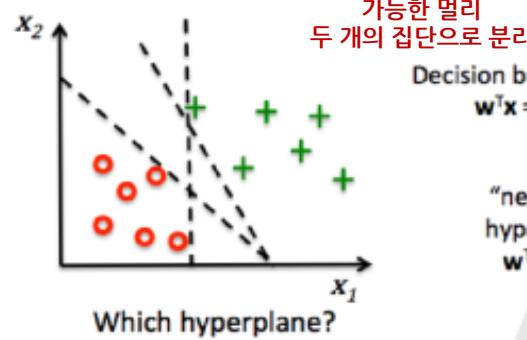
- 여유변수 (Slack variable)
- penalty function 이용
- Kernel 함수 이용 (부분적 비선형 계산)

[특징]

- 분류기반 : 최적의 회귀식(Hyper Plane)을 구하여 데이터를 2개로 분류
- 회귀분석 : Hyper Plane 을 구하기 위해 회귀분석 활용
support vectors를 2개로 분할하는 초평면(Optimal Hyper Plane)이용

[분류] SVM (Support Vector Machine)

3. SVM의 개념도 및 기술요소



- 학습데이터를 +, -로 나누는 기준점을 찾아주는 classifier
- Margin : Support Vector 사이의 거리
- Support Vector : 집단 구분 결정직선에서 가장 근거리에 위치하는 벡터
- Hyper-plane : n차원의 공간의 구분을 위해 결정되는 n-1평면]

기술요소	설명	비고
Optimal Hyperplane	<ul style="list-style-type: none"> 데이터를 두 클래스 중 어느 곳에 속하는지 결정하기 위한 최적의 분류 기준선 n차원의 공간에서의 subspace 의미 	<ul style="list-style-type: none"> Positive hyperplane Negative hyperplane
Margin	<ul style="list-style-type: none"> 데이터를 두 클래스로 구분하는 최대 거리 positive hyperplane 과 negative hyperplane 의 거리 	최대 마진 분류
Support vectors	<ul style="list-style-type: none"> 초평면은 하나의 회귀식 (예: $y = wx + b$) 초평면에 위치 데이터는 $y=0$ 초평면 위쪽 $y > 0$, 초평면 아래쪽 $y < 0$ 초평면과 가장 가까운 위, 아래 점을 넣을 때 $y=+1$, $y=-1$이 나오는 점을 support vector라고 함 	$wx + b \geq 1$ $wx + b = 0$ $wx + b \leq -1$
Kernel function	<ul style="list-style-type: none"> 비선형 SVM에서 고차원 특징 공간으로 사상하는 함수 vector들이 margin을 구하는데 supporting을 하기 때문에 support vector라고 부름 소프트 마진(Soft Margin)은 여전히 가장 가까이 위치해 있는 제대로 분리되는 자료들의 거리를 최대화하면서, 주어진 자료들을 가능한 한 제대로 분리하는 초평면을 찾는 기법 	차원 축소

4. SVM의 장단점

장점	단점
<ul style="list-style-type: none"> 에러율이 낮음 계산량이 많지 않음 결과 해석이 쉬움 	<ul style="list-style-type: none"> 튜닝 파라미터 선택에 미감 이진 분류(binary classification)만 가능

5. SVM 활용

활용	설명
텍스트 분류	하이퍼텍스트 분류, 스팸 분류, 긍정/부정어 분류
이미지 분류	손글씨 인식 및 이미지 특징 인지
의료 정보	DNA 단백질 효소 정보 분류



[분류] KNN(K-Nearest Neighbor)

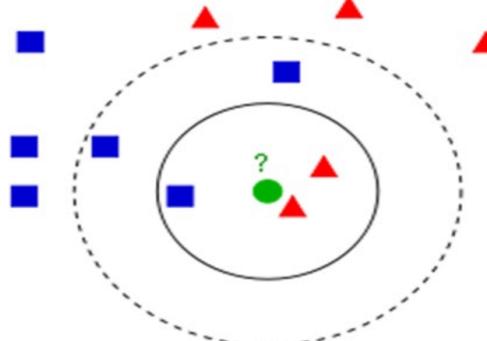
최고인접 | 다수결 | 가중합계 | 유사도(거리)기반

1. 측위기반의 KNN(K-Nearest Neighbor) 알고리즘의 개요

- 새로운 입력을 기준의 모든 클러스터의 모든 데이터와 instance 기반 거리를 측정, 가장 많은 속성을 가진 클러스터에 할당하는 classification 알고리즘
- 새로운 fingerprint를 기준 클러스터 내의 모든 데이터와 Instance 기반거리를 측정하여 가장 많은 속성을 가진 클러스터에 할당하는 군집알고리즘 ([기준 데이터 중 가장 유사한 K개의 데이터를 이용해 새로운 데이터를 예측하는 방법](#))
- Sample에 주어진 x (샘플)에서 가장 가까운 k 개의 원소가 많이 속하는 class로 x 를 분류하는 비모수적 확률밀도 추정방법

특징	설명
최고인접 다수결	기준 데이터 중 가장 유사한 k개의 데이터를 측정 하여 분류
유사도(거리) 기반	유кли디안 거리(Euclidian's distance), 마할라노비스의 거리(Mahalanobis' distance), 코사인 유사도(cosine similarity)등을 활용
Lazy learning 기법	새로운 입력 값이 들어온 후 분류시작
단순유연성	모형이 단순하며 파라미터의 가정이 거의 없음
NN(Nearest Neighbors)개선	- KNN은 가장 근접한 k개의 데이터에 대한 다수결 내지 가중합계 방식으로 분류 - NN의 경우 새로운 항목을 분류할 때 가장 유사한 instance를 찾아서 같은 class에 일방적으로 분류 시 잡음 섞인 데이터에는 성능이 좋지 못함

2. KNN 알고리즘의 동작원리



- 새로운 fingerprint(원)을 네모 또는 삼각형의 클러스터에 매칭원리
 - 새로운 fingerprint 입력(물음표, 동그라미) 확인
 - 거리기반 k 개 데이터를 training set에서 추출
 - 추출데이터들의 클러스터, lable 확인
 - 다수결(Majority voting) 의한 클러스터 매칭
- 결과 새로운 fingerprint는 K 가 3인 경우 삼각형, 5인 경우 사각형 클러스터에 매칭됨

동작원리	설명
Fingerprint 확인	<ul style="list-style-type: none"> 새로운 입력값 확인 가까운 데이터는 같은 Label(클러스터 가능성 큼) 기준의 모든 데이터와 새로운 fingerprint와 비교준비
명목변수기반 그룹분류	<ul style="list-style-type: none"> 기존의 저장되어있는 데이터 셋의 label화 서로 다른 범주 데이터를 정규화 수행 분류기 검사 수행 (예: 데이터의 90%를 훈련데이터 10%를 테스트로 활용)
거리측정	<ul style="list-style-type: none"> 유кли디언 거리 메모리기반 fingerprint와 모든 데이터간의 거리계산 계산된 거리의 정렬수행
K 선정	<ul style="list-style-type: none"> 양의 정수값, 정렬된 거리중 가장 가까운 k개 데이터 선정 여러 k값을 모델링 후 가장 성능이 좋은 k값 선정 노이즈 클수록 큰 k값 선정이 좋음 작은 k는 극단값 및 노이즈를 허용하여 클러스터링 오류 가능
클러스터 매칭	<ul style="list-style-type: none"> 명목 데이터 경우, 다수결(majority voting)기반의 클러스터 매칭 수행, k개 데이터가 많이 속해있는 클러스터로 새로운 값을 분류 수치형 데이터의 경우 k개 데이터의 평균(or 가중평균)을 이용하여 클러스터 매칭

[분류] KNN(K-Nearest Neighbor)

3. KNN 알고리즘에 대한 거리

거리	설명
유클리디안 거리(Euclidian's distance)	점과 전간의 최단 거리
마할라노비스의 거리(Mahalanobis' distance)	두 모집단들을 판별하는 문제에서 두 집단 사이의 거리(확률분포를 고려한 거리 이때 화이트닝 변환 whitening transform)을 사용
코사인 유사도(cosine similarity)	내적 공간의 두 벡터간 각도의 코사인값을 이용하여 측정된 벡터간의 유사한 정도

4. KNN 알고리즘의 장단점

구분	항목	설명
장점	효율성	<ul style="list-style-type: none">훈련데이터에 잡음이 있는 경우에도 적용가능
	결과일관성	<ul style="list-style-type: none">훈련데이터의 크기가 클 경우 효율적임 (데이터의 수가 무한대로 증가시 오차율이 베이즈 오차율의 두배보다 항상 나쁘지 않음을 보장)
	학습간단	<ul style="list-style-type: none">모형이 단순하고 쉬운 구현 가능
	유연한 경계	<ul style="list-style-type: none">거리의 변형, 가중치 적용용이유클리디언, 코사인유사도, 가중치 적용, 정규화 적용 용이
	모델의 유연성	<ul style="list-style-type: none">데이터에 대한 가정 반영 및 변형이 간편변형데이터의 training data set 기반 분류기 검증용이
	높은 정확도	<ul style="list-style-type: none">사례기반으로 높은 정확성훈련데이터 클수록 클러스터 매칭 정확성 좋아짐
단점	성능가변성	<ul style="list-style-type: none">k값 선정에 따라 알고리즘의 성능이 좌우됨k값 최적화, under/overfitting의 고려 필요
	높은 자원요구량	<ul style="list-style-type: none">데이터 셋 전체를 읽어서 메모리에 기억새로운 개체 n을 읽어서 메모리 내의 데이터 셋과 비교
	고비용	<ul style="list-style-type: none">모든 훈련샘플과의 거리를 계산하여야 하므로 연산비용(cost)이 높음
	공간예측 부정확	<ul style="list-style-type: none">공간정보 예측모델에서는 영향변수 많이 적용이 어려움
	거리계산 복잡성	<ul style="list-style-type: none">모든 데이터와의 유사도, 거리측정 수행 필요
	노이즈에 약함	<ul style="list-style-type: none">노이즈로 인해 큰 k 설정을 필요로 함민감하고 작은 데이터 무시되는 under fitting 문제야기

[분류] KNN(K-Nearest Neighbor)

5. KNN 알고리즘의 활용방안

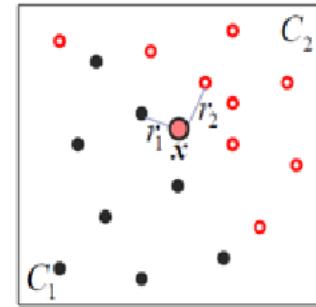
활용방안	설명	사례
위치측위	이동객체의 위치에서 AP 신호강도를 측정하고 이를 KNN 알고리즘을 활용하여 이동객체의 위치를 최종적으로 추정	MS사의 RADAR - Ekahau Inc의 Wi-Fi RLS, COMPAS
선호도 분류	사용자의 추천정보 기반 성향/구매패턴분류	내용기반 추천 시스템
데이터필터링	포털등의 중복, 유사 게시글 필터링	문서분류(빈발항목집합, 빈발단어집합 등)
고속도로 통행시간 예측	TCS 교통량 및 DSRC 구간 통행시간의 실시간 자료를 KNN 기반으로 분석	차량 근거리 무선통신(DSRC) 활용 통행시간 예측

2. K-NN과 K-means 알고리즘의 비교 설명

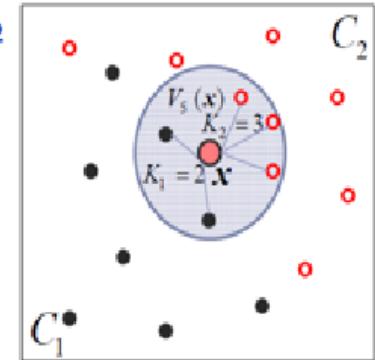
항목	K-NN	K-means
유형	Classification	Clustering
목적	유사도 측정	다변량 자료의 군집화, 선형분석
데이터 라벨링	지도학습 (데이터 라벨링)	비지도 학습 (라벨 미수행 군집화)
파라미터 K	최고 인접 순서의한 개체수 다수결(Majority vote) 대상	클러스터의 최종 개수 distance group 수
동작원리	1) 입력 값 확인 2) 거리기반 K개 데이터 추출 3) 추출 데이터 라벨 확인 4) 다수결의한 입력값 라벨 할당	1) K(군집 수) 선정 2) Cluster seed (중심좌표) 값 계산 3) 거리측정 후 개체를 가까운 cluster seed의 군집에 할당 4) 중심좌표가 변경 안될 때 까지 2)3) 단계를 반복
거리측정	모든 개체와 새로운 입력간 거리 계산, 주로 유clidean 거리	모든 개체와 중심좌표간 거리계산 중심좌표는 산술평균 기반 측정
클러스터 매칭	다수결 수행 (라벨할당)	중심좌표와의 거리계산 (군집화)
이점	학습간단, 유연성, 정확도	분류, 예측에 쉽게 적용
고려사항	모수 K에 영향률 노이즈에 약함	K선정의 어려움 군집의 해석 모호
사례	중복 또는 유사 객체 분류 선호도, 사용자성향 분류	예측위한 선형 분석 트렌드, 성향 불분명한 시장 분석

Contents connect communications!

K=1인 경우



K=5인 경우



X는 C_2 으로 분류

아이리포

ALL PASS

[분류] 기억기반추론(MBR : Memory-based reasoning)

경험

distance function

combination function

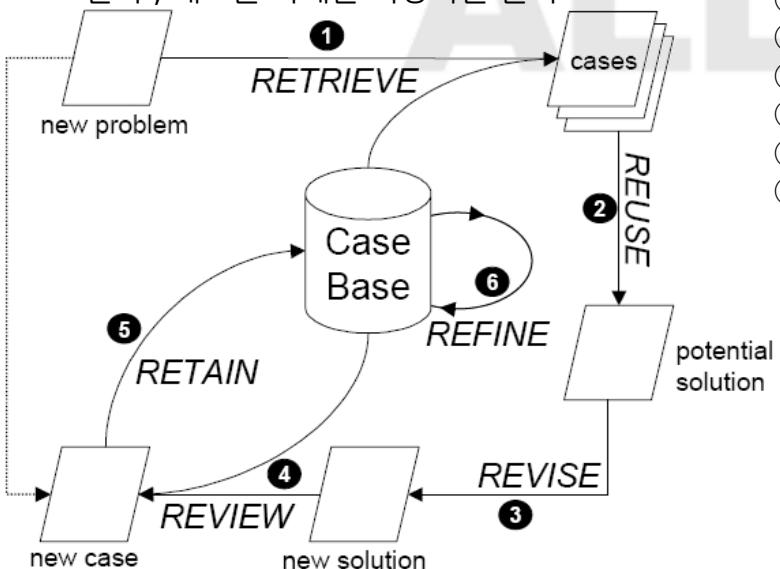
6R

1. 경험기반 마이닝 기법, 기억기반추론의 개요

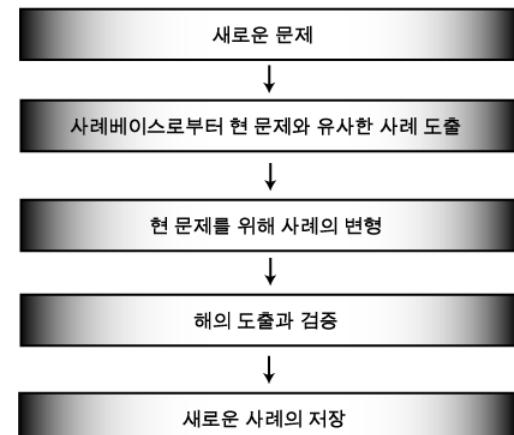
- 과거에 현재의 문제와 유사한 문제가 존재하였고 그것이 어떻게 해결되었는지를 안다면, 과거의 경험을 바탕으로 현재 문제의 해결책을 추론 할 수 있다는 이론
- Case Based Reasoning = Exemplar-based reasoning = Instance-based reasoning = Analogy-based reasoning 등 다양한 용어로 사용
- 두 레코드간의 거리를 나타내는 distance function과 답에 도달하기까지의 결과를 조합한 combination function을 계산함.
- 지리적 위치, 이미지, 복잡한 문자열등과 같이 일반적으로 다른 분석기법으로 다루기 힘든 데이터 형태를 다룰 수 있음.

2. 기억기반추론 프로세스와 구성요소

- 새로운 문제 해결을 위해 사례 베이스로부터 유사 사례를 도출하고, 현 문제를 해결하기 위해 사례를 변경하고, 해를 도출하고 검증한 후, 새로운 사례를 저장하는 원리



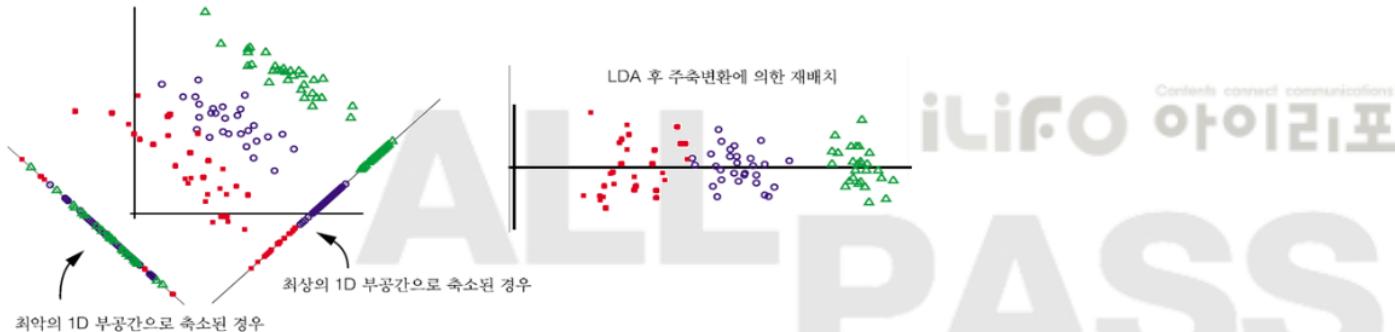
- ① **Retrieve** 문제를 표현하기 위해 유사한 사례를 검색한다
- ② **Reuse** 유사한 사례에 의해 제안된 솔루션을 재사용한다
- ③ **Revise** 새로운 문제에 맞게 기존의 솔루션을 교정한다
- ④ **Review** 새로운 사례로서 보존할 가치가 있는지를 비교한다
- ⑤ **Retain** 새로운 사례를 저장한다
- ⑥ **Refine** 필요에 따라 사례기반 인덱스 와 가중치를 조정한다



[분류] 선형판별분석(Linear Discriminant Analysis)

1. 선형판별분석(Linear Discriminant Analysis)의 개요

- 데이터 분포를 학습해 결정경계(Decision boundary)를 만들어 데이터를 분류(classification)하는 모델
- 주성분 분석법(PCA)은 데이터의 최적 표현의 견지에서 데이터를 축소하는 방법인데 반하여, 선형판별분석법(LDA)은 데이터의 최적 분류의 견지에서 데이터를 축소하는 방법
- 목적 : 가능한 클래스간의 분별 정보를 최대한 유지시키면서 차원을 축소시키는 것



2. LDA의 두 가지 접근법

접근법	설명
클래스-종속 변환	- 각 클래스간 분산과 클래스내 분산의 비율을 최대화하는 방법 - $S_w^{-1}S_i$ 의 고유벡터를 이용하여 변환행렬 구성 → 해당 클래스의 변환행렬을 클래스마다 지정
클래스-독립 변환	- 전체 분산과 클래스 내 분산의 비율을 최대화하는 방법 - $S_w^{-1}S_B$ 의 고유벡터를 이용하여 변환행렬 구성 → 데이터 집합을 변환하기 위해서 하나의 변환행렬만이 필요

- 일반화가 중요한 경우 → 클래스-독립 변환 선택
- 좋은 분류를 목적으로 하는 경우 → 클래스-종속 변환 선택

- LDA는 클래스의 중심(평균)이 그 클래스의 대부분을 가지고 있다는 가정에서 출발
- 데이터가 유니모달 분포인 경우에 적합하며, 비선형적으로 이루어진 데이터와 같이 동일한 평균을 가진 데이터를 가진 클래스에 부적합
- 분류 문제보다는 차원 축소의 한 접근법으로 많이 사용

[군집] K-평균 군집 (K-means clustering)

군집(Cluster)

중심 값(Centroids)

거리기반 분류

군집 개수 사전설정

1. N개의 개체를 k개의 군집으로 분류하는 거리에 기반을 둔 Clustering 알고리즘, K-Means의 개요

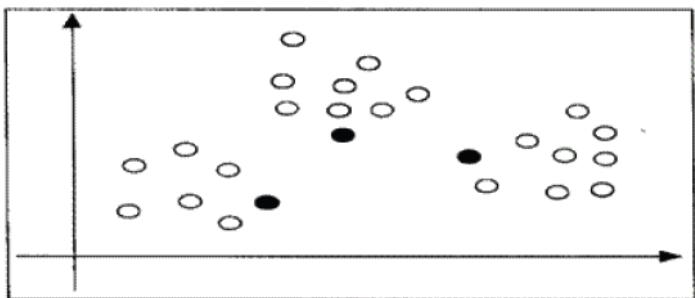
- 사전에 결정된 군집수 **K**에 **기초**로 하여 전체 데이터를 상대적으로 유사한 K개의 군집으로 분할
- 군집(Cluster)별 **중심 값에서 중심과의 거리를 기반으로 데이터를 분류**하는 군집 알고리즘
- 주어진 데이터를 사전 정의된 k개의 클러스터로 묶는 알고리즘, 각 클러스터와 거리차이의 분산을 최소화하는 방식으로 동작
- 입력 값으로 K를 취하고 군집 내 유사성은 높게, 군집간 유사성은 낮게 되도록 N개의 객체집합을 K개의 군집으로 군집하는 기법
- 데이터를(Training Set)를 기준점(Code-Vector)을 중심으로 Euclidean 거리가 최소가 되도록 할당하여 K개의 묶음으로 구분하는 clustering 알고리즘
- 특징 : 클러스터링, 비지도학습, Lazy Learning, 산술평균이용

2. K-means 알고리즘의 특징

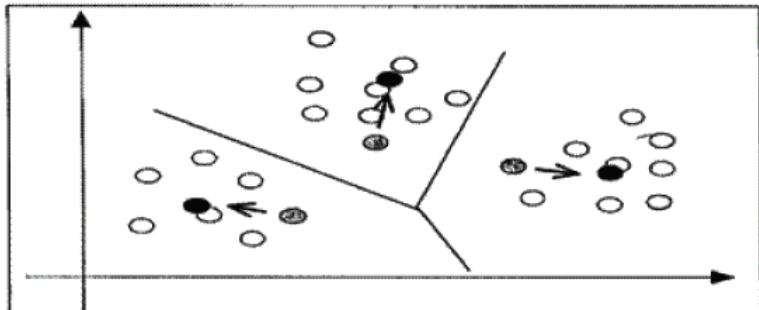
특징	설명
Data 중심점(Centeroid)	군집화된 데이터는 중복되지 않으며 상호배타적 포함
거리 기반의 분류기법	각 군집의 중심점과의 유clidean 거리 최소화
데이터군 양자화	데이터군을 양자화하여 분할 시 발생하는 오류 최소화
속도 및 구현	거리기반의 군집기법으로 빠른 결과 산출, 구현 용이성

3. K-means 알고리즘의 원리

초기 군집의 중심

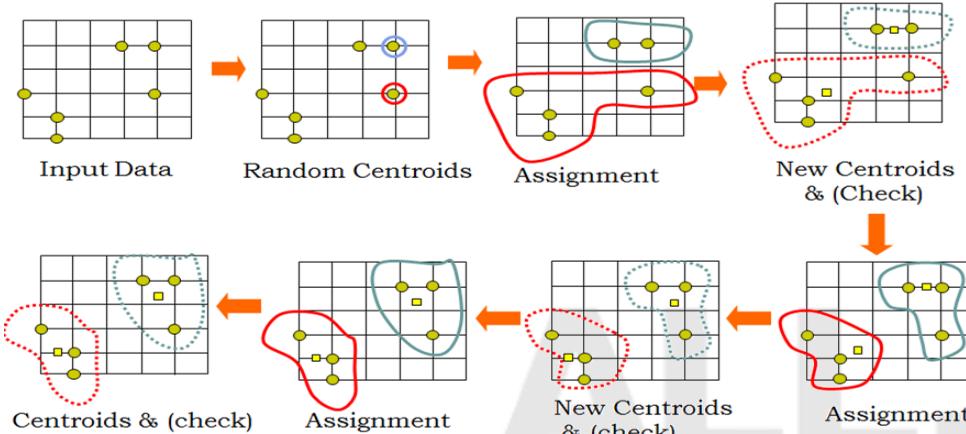


중심의 이동



[군집] K-평균 군집 (K-means clustering)

4. K-means 알고리즘의 분석 절차



5. 군집분석을 위한 유사성의 측정(Similarity)

- 군집으로 분류될 대상들 사이의 일치성 또는 비슷함의 척도
- 주로 **유클리디안 거리**를 주로 사용
(그외 **유clidean 거리, 마할라노비스거리, 코사인유사도 사용**)

6. 군집분석의 장점과 단점

장점	단점
탐색적인 기법 다양한 형태의 데이터에 적용 가능 분석방법의 적용 용이성	가중치와 거리 정의 초기 군집수의 결정에 민감 결과 해석의 어려움

- 구하려는 클러스터의 개수가 미리 정의 필요, 너무 많은 클러스터 개수 설정은 큰 클러스터가 여러 개로 나뉘는 결과 발생 가능
- K-means 군집기법을 사용하기 위해서는 초기에 군집의 수를 미리 제공해야 하는데 군집분석은 데 이터를 분석하면서 결정하는 경험적 분석방법이므로 적절한 군집의 수를 안다는 것은 어려운 일.
- 따라서 군집의 수를 변화시켜 가면서 수행된 결과들을 비교해가는 분석방법이 요구(F-검정법 등)

7. K-means 알고리즘의 활용

- Data Mining에서 데이터 분류 및 군집 알고리즘으로 활용
- 시장과 고객 분석, 패턴인식, 공간데이터 분석, Text Mining 등
- 최근에는 패턴인식, 음성인식의 기본 알고리즘으로 활용
- 데이터가 불규칙하고 내부 특징이 알려지지 않은 분류 초기 단계에 적합

단계	절차
1	군집의 수 K를 정의
2	초기 K개 군집의 중심(Centroids) 선택
3	각 관측 값을 가장 가까운 중심의 군집에 할당
4	새로운 군집의 중심 계산
5	재정의 된 중심값 기준으로 다시 거리기반의 군집 재분류
6	군집 경계가 변경되지 않을 때까지 반복

유사성 측정 척도	설명
유클리디안거리 (=유클리드 거리)	임의의 두 지점간의 최단거리, 양 지점간의 직선거리 각 변수 값에서의 차이를 제곱한 것을 합하고 이를 제곱근

$$A \text{와 } B \text{ 간의 유클리드 거리} = \sum_{j=1}^p (X_{jA} - X_{jB})^2$$

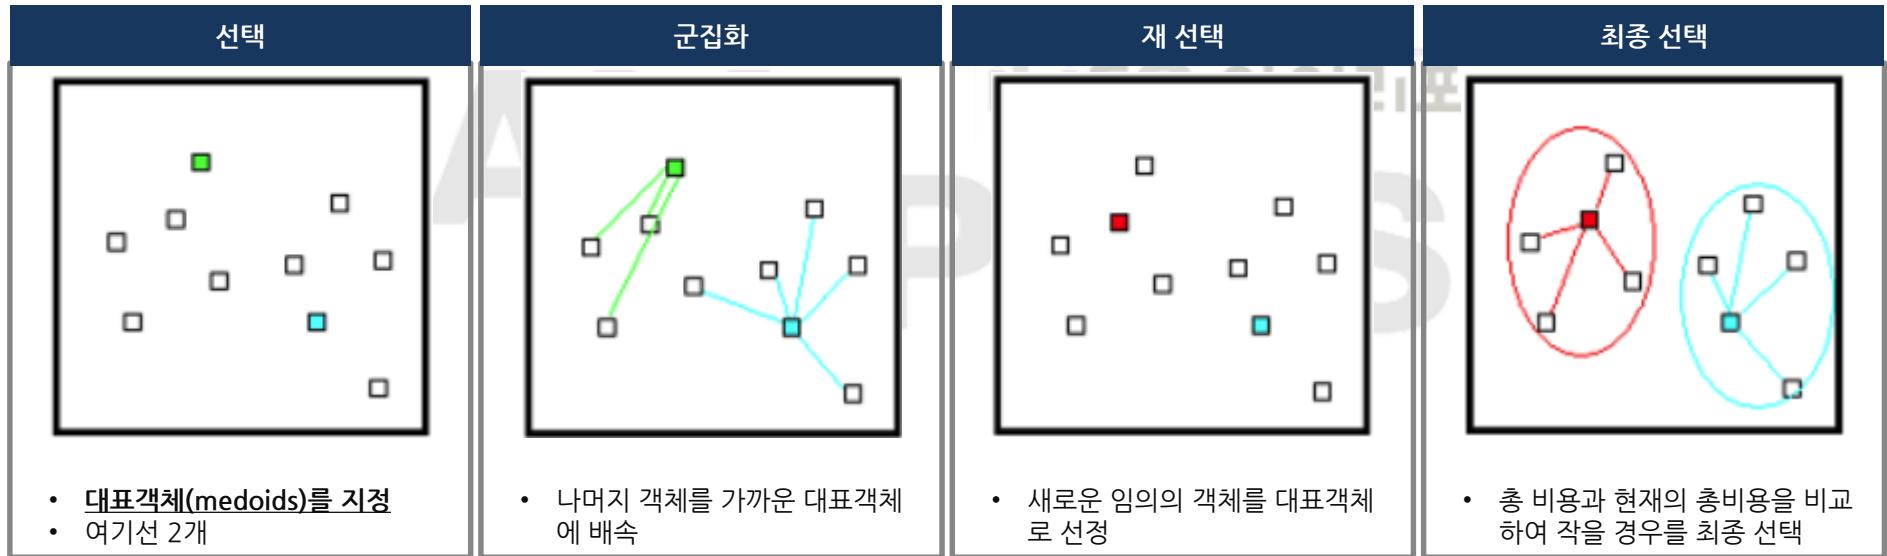
$$A \text{와 } B \text{ 간의 유클리드 거리} = \sqrt{\sum_{j=1}^p (X_{jA} - X_{jB})^2}$$

[군집] K-medoid

1. K-Medoid 의 개요

- 군집에서 객체들의 평균값을 취하는 대신에 군집에서 가장 중심에 위치한 객체인 medoid를 사용 하여, n개의 객체 중에서 k개의 군집을 찾는 군집분석기법
- 장점) 노이즈 처리가 우수
- 단점) K-Means에 비해 계산양이 많음

2. K-Medoid의 처리절차





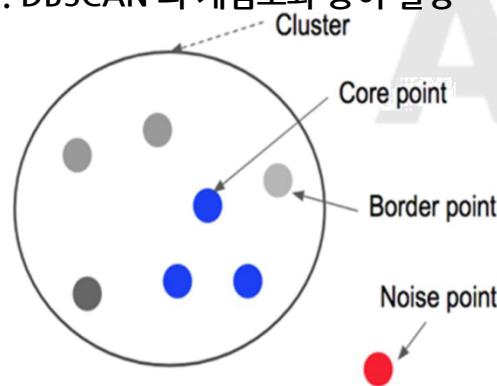
[군집] DBSCAN

ϵ , minPts

1. 밀도기반 군집화 알고리즘, DBSCAN(Density-Based Spatial Clustering of Application with Noise)의 개요

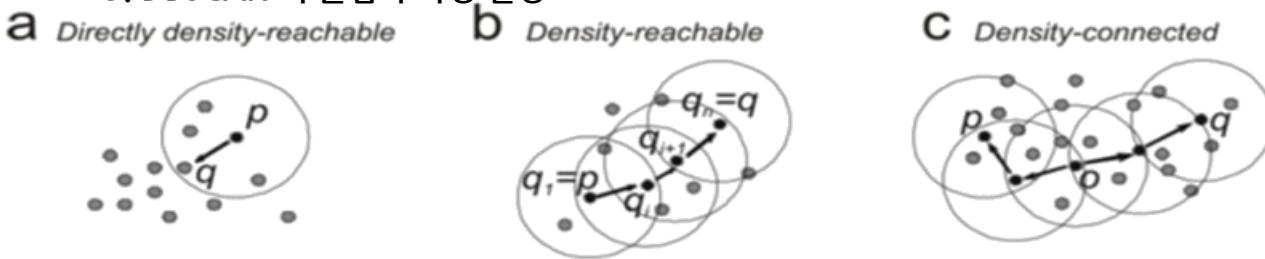
- 핵심 벡터로부터 ϵ 반경 내 접근 가능한 모든 데이터 벡터들의 집합(군집)을 생성하는 기법
- K-Means 군집의 한계인 오목한 형태의 데이터를 군집화하기 위해, 데이터의 밀도를 기준으로 인스턴스들을 공간적으로 군집화하는 기법
- 노이즈에 대해 강건하며 K-means 가 잘 처리하지 못하는 오목한 데이터 set에 대해 높은 처리 능력을 보이는 밀도 기반 군집화 알고리즘
- 다양한 형태의 분포에 대해서도 그룹으로 묶을 수 있으며 다른 개체들과 상대적으로 멀리 떨어져 있는 아웃라이어들을 군집에서 제외할 수 있는 장점이 있는 알고리즘

2. DBSCAN 의 개념도와 용어 설명



용어	설명
Core Point	- 일정 기준 이상의 밀도를 갖는 데이터(점) - 코어에서 코어로 탐색을 수행
Border Point	- 일정 기준 미만의 밀도를 갖지만 군집에 소속되어 있는 데이터 - Border를 만나면 그 군집에서의 탐색을 중지 - 한 벡터로부터 ϵ 반경 내 위치한 다른 데이터 벡터
Noise Point	- 일정 기준 미만의 밀도를 갖고, 군집(cluster)에 소속되어 있지 않은 데이터
Cluster	- Core Point에서 접근 가능한 모든 데이터들의 집합 - 한 핵심벡터 p에 대해 접근 가능한 모든 데이터 벡터들의 집합
Epsilon (ϵ)	- 밀도를 계산할 범위
minPts	- 하나의 군집으로 묶는데 필요한 최소 개체 수 (ϵ 반경 내 군집 위해 필요한 객체 수)

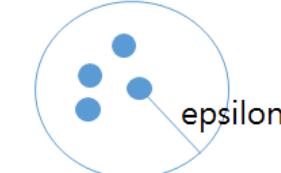
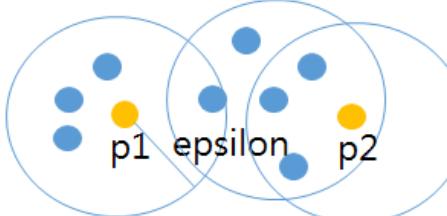
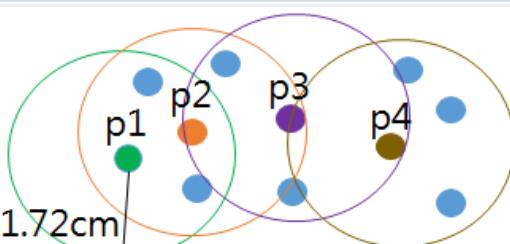
3. DBSCAN 의 군집화 과정 설명

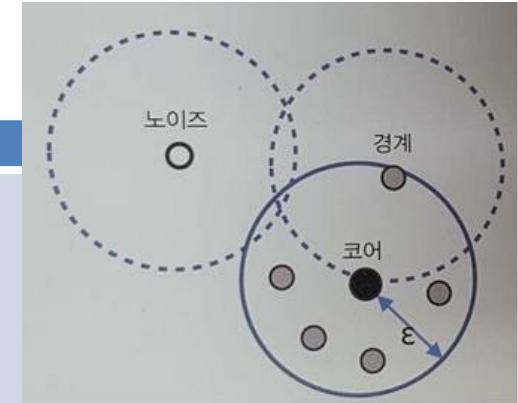


- (a) 임의의 점 P에서 epsilon 만큼의 범위 내에 포함된 점들의 개수가 minPts 이상이면 점 P를 중심으로 한 클러스터 형성
- (b) P와 같은 클러스터에 있는 다른 점 q를 중심으로 하는 epsilon 만큼의 범위를 다시 잡아 해당 범위 내에 minPts 이상의 개체가 포함되어 있으면 이 범위내 개체들을 a와 같은 그룹으로 묶음
- (c) (b) 과정에서 더 이상 그룹에 포함할 개체가 없으면 해당 클러스터가 아닌 다른 점을 중심으로 (a), (b) 과정을 반복

[군집] DBSCAN

4. 군집 생성 절차

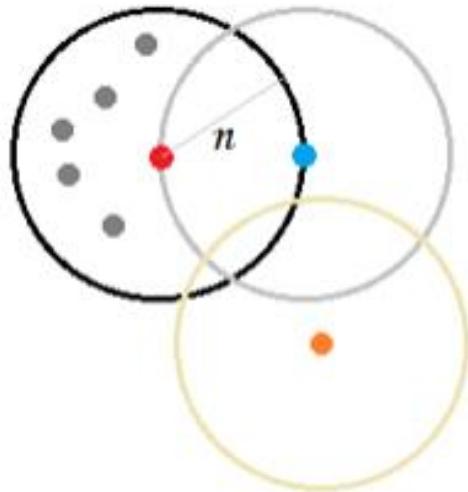
절차	개념도	설명
기본 상태	 Number of data : 4	<ul style="list-style-type: none"> - ϵ (epsilon) : 주어진 객체들의 반경 - minPts : 군집 최소수 - ϵ 반경 내 minPts개가 존재해야 군집 판단
군집 생성		<ul style="list-style-type: none"> - 임의 점 p1, p2 등에서 ϵ 반경 내 minPts 만족 시 군집
Noise 분류		<ul style="list-style-type: none"> - 임의 점 p1에서 ϵ 반경 내 p2 미 존재 시 Noise로 분류
군집 완성		<ul style="list-style-type: none"> - 각 점에서 ϵ 반경 내 minPts 충족하는 객체집합(군집) 완성



장점	단점
<ul style="list-style-type: none"> - 군집개수 정의 필요 없음 - 임의 모양의 군집 생성 - 잡음(Noise) 개념 존재 - 2개의 매개변수만 필요 	<ul style="list-style-type: none"> - 유클리디안 거리 이용하여 ϵ 산출이 어려움 - 다차원 및 고밀도 데이터의 군집화 어려움

[군집] DBSCAN

어느점을 기준으로 반경 n 내에 점이 m 개 이상 있으면 하나의 군집으로 인식하는 방식



- Core Point
- Border Point
- Noise Point
- n = Neighbourhood
- $m = 4$

DBSCAN CLUSTERING

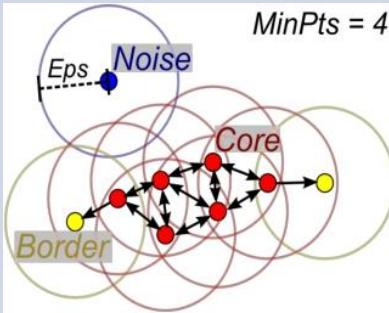
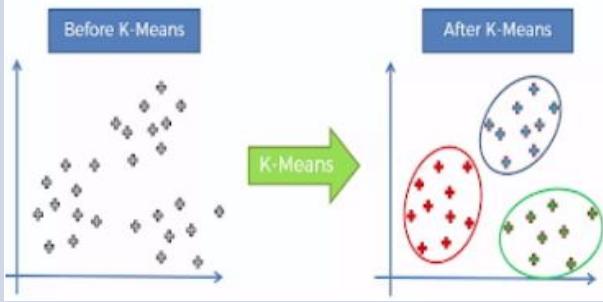


[군집] DBSCAN과 K-Means를 비교

1. 클러스터링 기법 DBSCAN과 K-Means의 개념비교

DBSCAN	K-Means
데이터 밀도를 이용, 데이터를 코어, 경계, 노이즈로 클러스터링 하는 군집 알고리즘	유clidean 거리를 이용, 데이터를 K개의 군집으로 클러스터링 하는 군집 알고리즘

2. 클러스터링 기법 DBSCAN과 K-Means의 상세비교

구분	DBSCAN	K-Means
개념도	 <p>MinPts = 4</p>	 <p>Before K-Means After K-Means</p> <p>K-Means</p>
절차	<pre> 코어중심반경(ε), MinPts 결정 └─┐ 코어 Point 기반 경계분석 └─┐ Border, Noise 계산 └─┐ 군집할당 └─┐ </pre>	<pre> 군집수(K) 결정 └─┐ Centroid 결정 └─┐ Centroid 결정 └─┐ 군집할당 └─┐ </pre>
구성요소	코어 포인트(Core Point) : 군집의 중심 MinPts : Cluster를 형성하는 최소의 수	중심값(Centroid) : 임의의 클러스터 중심점 군집수(K) : 사전에 정의한 초기클러스터의 개수
군집간 거리측정	K-Distance Graph기반 밀도 군집	유clidean 거리기반 군집
종료조건	모든 데이터가 속하는 군집작업 완료 시	각 군집의 Centroid가 더이상 변경되지 않을 시
성능	$O(n\log n) \sim O(n^2)$	$O(n)$
장점	사전 군집갯수 정의 불필요, 노이즈에 강함 - 기하학적 군집 가능(U, H모양 등)	빠른 결과 산출, 구현 용이, 직관적 이해가능 - 간단한 구조
단점	K-Means에 비해 상대적으로 속도 느림 - 코어중심반경(ε) 설정에 따른 성능영향도	데이터분포가 구형이 아닌 경우 효율 저하 - Noise에 약함

3. DBSCAN과 K-Means의 활용방안

- DBSCAN → K-Means
- 노이즈 백터 제거
 - 고속 클러스터링

- 1) 데이터 분포에 관계없이 DBSCAN을 통한 데이터 분류 수행.
- 2) 노이즈 벡터 제거 후 K-Means를 통해 고속 클러스터링 수행

김미경 정보관리기술사(mayching1106@naver.com)

[군집] EM (Expectation Maximization) 알고리즘

Log likelihood function

Gaussian Mixture Model (GMM)

outlier (in K-means)

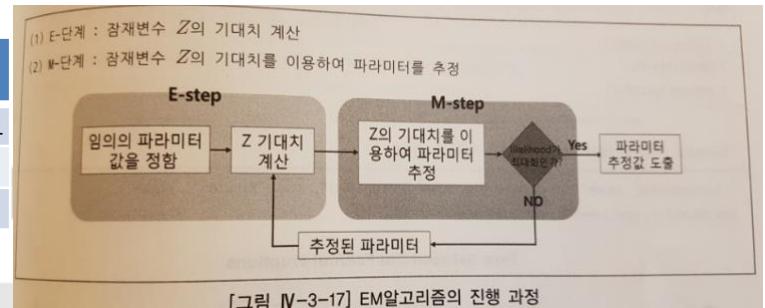
E-Step

M-Step

1. Log Likelihood Function 을 이용한 밀도확률기반 처리 알고리즘 EM 알고리즘의 개요

- 관측되지 않는 잠재변수에 의존하는 확률모델에서 **최대가능도(maximum likelihood)**나 **최대사후확률(maximum a posteriori)**을 갖는 **매개변수를 찾는 반복적 알고리즘** (군집 알고리즘에 활용 가능)
- 매개변수에 관한 추정값으로 로그가능도(log likelihood)의 기대값(E) 단계와 이 기대값을 최대화하는 변수값을 구하는 최대화 단계를 번갈아가면서 적용 (**기대값 최대화 알고리즘**)

특징	설명
Likelihood Function	- 확률적 적합성 평가. Likelihood의 값을 최대화하는 것이 목표
Log함수로 종료평가	- Likelihood 값이 일정값 수준으로 향상되면 수렴허용 위함
Gaussian Mixture Model	- 가우시안 정규분포 적용



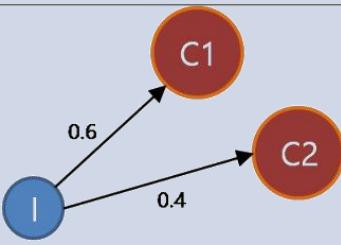
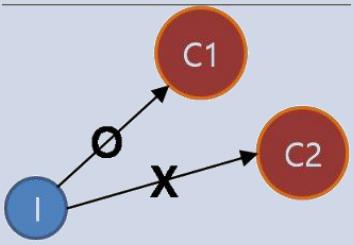
2. EM 알고리즘의 수행절차

절차	개념도	설명
초기		K개 설정 (군집개수)
E-Step		클러스터 모델 재생성 - 평균, 분산값 재계산
M-Step		- 데이터간 확률값 재계산
조건/종료		- Log likelihood 계산 - 포화시 종료, or E-Step 이동

- E-step과 M-step의 2 Phase를 반복하며 처리하는 EM 알고리즘

[군집] EM (Expectation Maximization) 알고리즘

3. EM 알고리즘과 K-Means 알고리즘과의 비교

구분	EM 알고리즘	K-Means 알고리즘																
개념	<ul style="list-style-type: none"> - 주어진 각각의 데이터들이 혼합모델에 속할 가능성을 반복적 조정하여 최 적의 모델을 생성하는 알고리즘 	<ul style="list-style-type: none"> - 주어진 데이터를 사전 정의된 k개의 클러스터로 묶고, 각 클러스터와 거리차이의 분산을 최소화하는 절차를 반복하는 알고리즘 																
특징	<ul style="list-style-type: none"> - Model Based Methods - Soft Clustering - 밀도 확률기반 군집 	<ul style="list-style-type: none"> - Partitioning Methods - Hard Clustering - 유클리디안 거리기반 군집 																
공통점	<ul style="list-style-type: none"> - Iterative 분석 - 군집의 분류에 활용 																	
구분	EM 알고리즘	K-Means 알고리즘																
개념도	<ul style="list-style-type: none"> - 하나의 Instance는 다수의 Cluster 선택 - 각 Cluster에는 개별적 확률이 존재 	<ul style="list-style-type: none"> - 하나의 Instance는 하나의 Cluster만 선택 																
기본 로직	<ul style="list-style-type: none"> - 각 데이터는 각각의 클러스터에 대한 확률치 존재 (log likelihood function) - Gaussian Mixture Model (GMM) 풀이 	<ul style="list-style-type: none"> - 클러스터마다 존재하는 중심과 각 데이터 와의 거리(Cost) 정의 후 Cost 최소값 탐색 - 절차 반복 																
절차	<table border="1"> <tr> <td>0</td><td>초기 군집설정</td></tr> <tr> <td>1</td><td>Maximization Step - 클러스터 모델 재생성 - 평균, 분산값 재계산</td></tr> <tr> <td>2</td><td>Expectation Step - 데이터간 확률값 재계산</td></tr> <tr> <td>3</td><td>종료조건 확인, 반복</td></tr> </table>	0	초기 군집설정	1	Maximization Step - 클러스터 모델 재생성 - 평균, 분산값 재계산	2	Expectation Step - 데이터간 확률값 재계산	3	종료조건 확인, 반복	<table border="1"> <tr> <td>0</td><td>k개의 초기 Centroids 설정</td></tr> <tr> <td>1</td><td>각각 데이터는 가장 가까운 Centroids 선택</td></tr> <tr> <td>2</td><td>각 클러스터의 신규 Centroids 설정</td></tr> <tr> <td>3</td><td>종료조건 확인, 반복</td></tr> </table>	0	k개의 초기 Centroids 설정	1	각각 데이터는 가장 가까운 Centroids 선택	2	각 클러스터의 신규 Centroids 설정	3	종료조건 확인, 반복
0	초기 군집설정																	
1	Maximization Step - 클러스터 모델 재생성 - 평균, 분산값 재계산																	
2	Expectation Step - 데이터간 확률값 재계산																	
3	종료조건 확인, 반복																	
0	k개의 초기 Centroids 설정																	
1	각각 데이터는 가장 가까운 Centroids 선택																	
2	각 클러스터의 신규 Centroids 설정																	
3	종료조건 확인, 반복																	
장점	<ul style="list-style-type: none"> - 통계적 확률계산을 통한 합리적 접근 - 다양한 형태의 데이터에 적용가능 	<ul style="list-style-type: none"> - 분석시 적용되는 로직이 상대적 단순 - 고속처리 가능 																
단점	<ul style="list-style-type: none"> - 연산의 복잡도 높음 - 처리시간, 처리필요공간 상대적 저효율 	<ul style="list-style-type: none"> - outlier 또는 noise에 취약 - 초기 군집수의 결정에 민감 																

- K-means 알고리즘은 단순하고 빠르나 outlier (noise)에 취약
- EM 알고리즘을 통해 noise 해결 가능

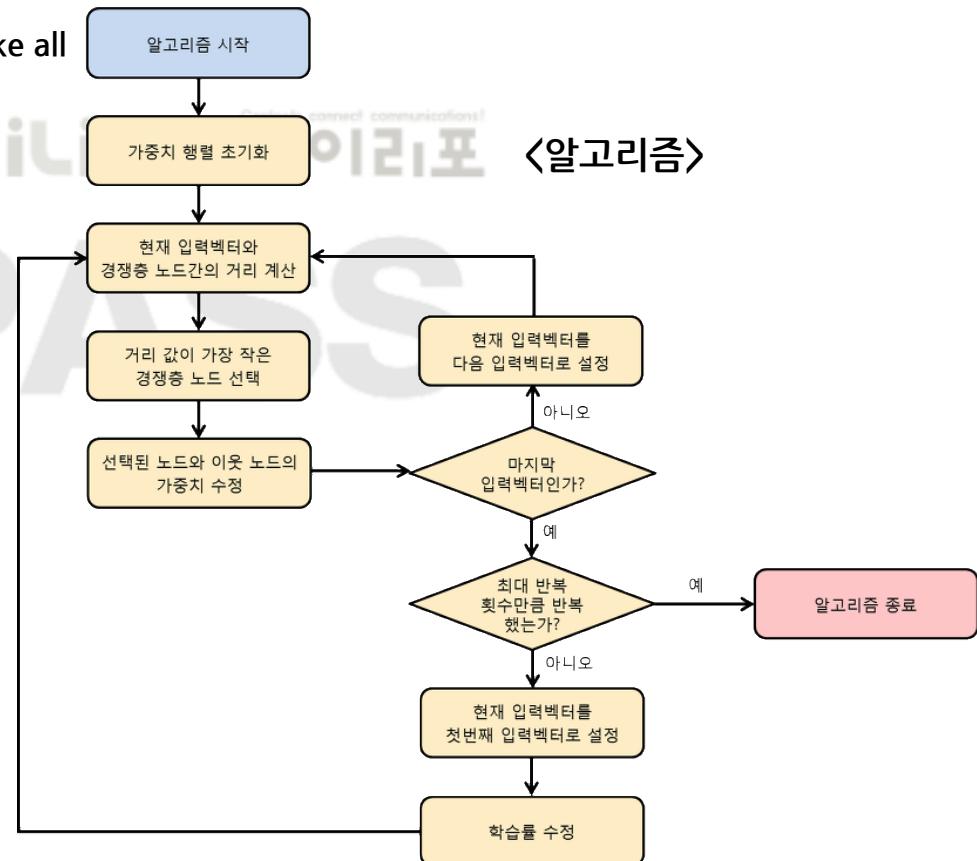
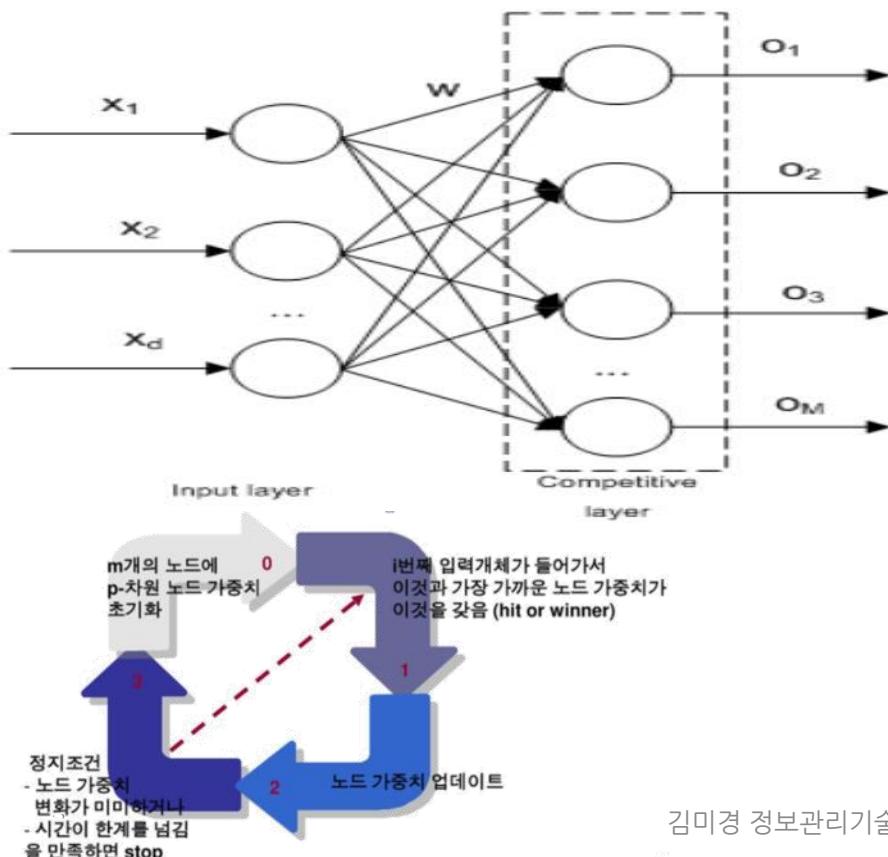
[군집] SOM (Self Organizing Model)

1. 출력층이 격자 구조, SOM의 개요

- 사람이 눈으로 볼 수 있는 저차원 격자에 고차원 데이터의 각 개체들이 대응하도록 인공신경망과 유사한 방식의 학습을 통해 군집을 도출해내는 기법.(총구조 신경망, 출력층이 격자 구조, 경쟁 학습, 데이터 가시화에 유용)
- 관찰치가 n인 P-차원 개체들을 입력받아 m개 노드로 구성된 저차원 지도에 질서를 잡아냄
- 총구조 신경망, 출력층이 격자 구조, 경쟁 학습, 데이터 가시화에 유용

구성: input layer + competitive layer + weight + output layer winner take all

*winner take all : 거리가 가장 가까운 뉴런(경쟁상태에서 특권부여)

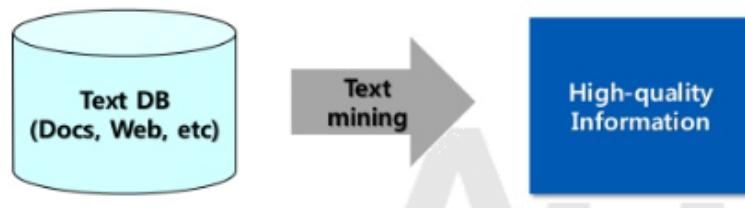


텍스트 마이닝

1. 텍스트 마이닝의 개요

- 텍스트를 사용하여 패턴이나 관계를 추출하고 그 안에서 의미 있는 정보나 가치를 발굴하여 해석하는 분석 기법
- 정형, 반정형 또는 비정형 데이터에 대해서 자연어처리(Natural Language Processing)기술과 문서처리 기술을 적용하여 **텍스트 내의 유용한 의미나 정보를 추출하는 데이터마이닝 기법**

2. 텍스트 마이닝 기능



텍스트 마이닝 기능

- 문서 요약 summarization
- 문서 분류 classification
- 문서 군집 clustering
- 특성 추출 feature extraction

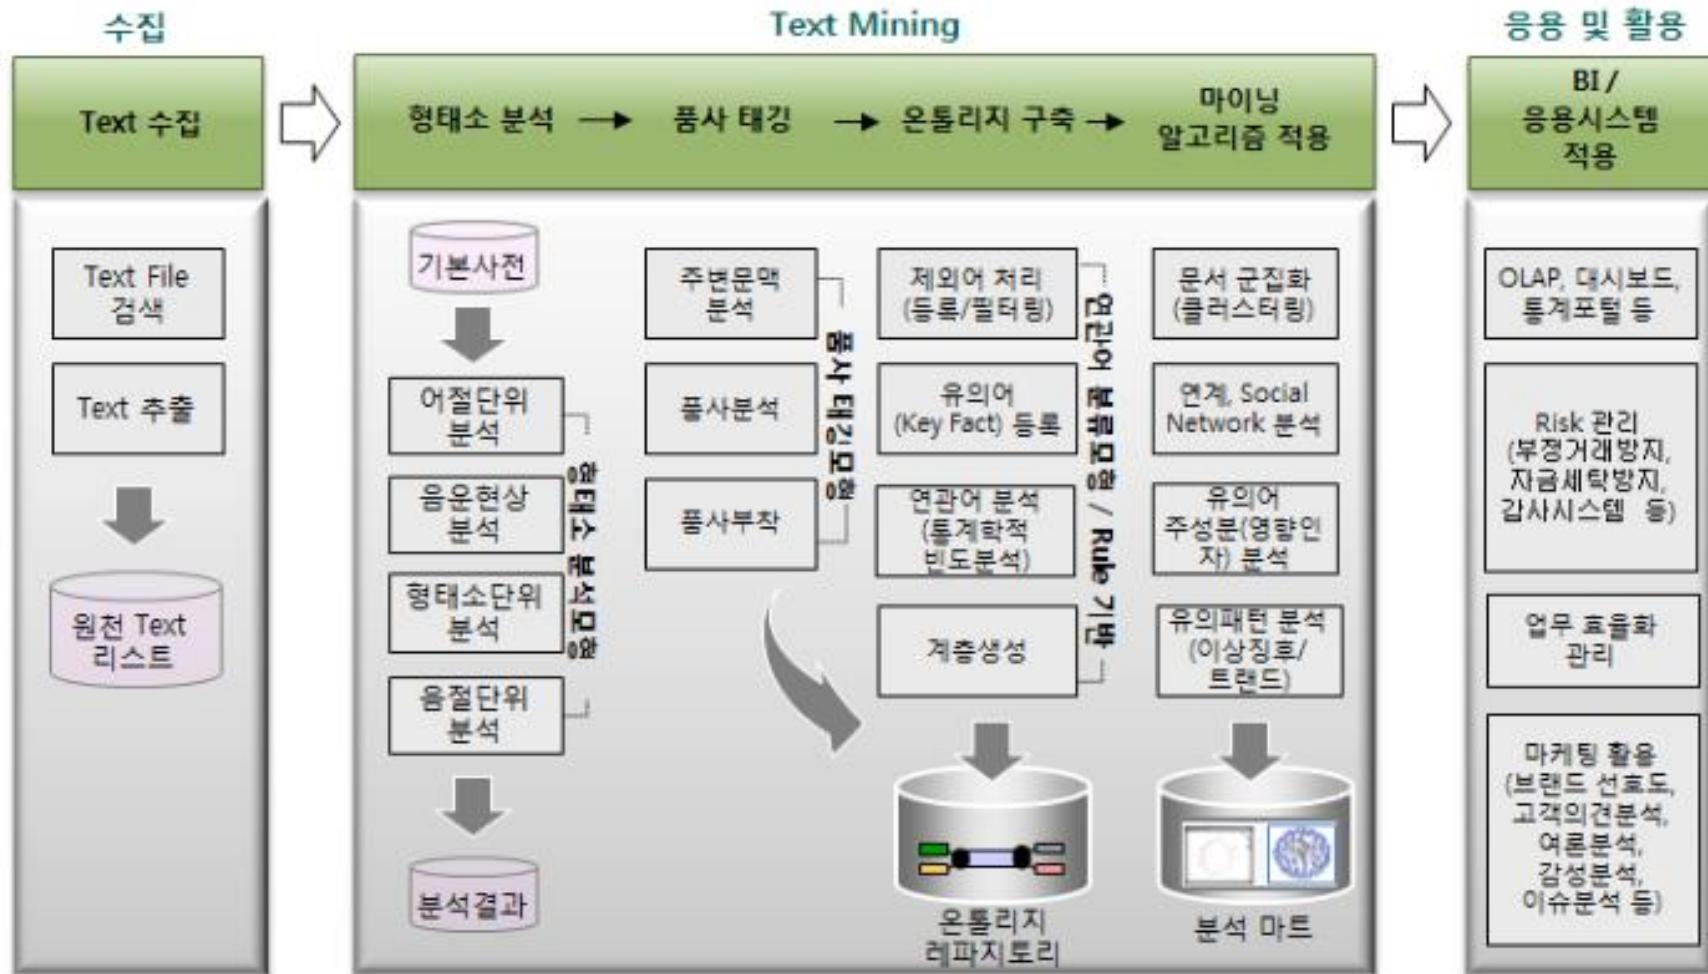
기능	내용
정보추출(Information Extraction)	<ul style="list-style-type: none">일반적인 텍스트 문서로부터 사용자가 원하는 정보를 추출하는 작업 (문장형식, 질의포맷에 맞추어 추출)
문서 분류(Classification) /문서 클러스터링	<ul style="list-style-type: none">문서들을 문서의 내용에 따라 구조화문서분류 : 키워드 집합에 따라 해당 카테고리로 분류문서 클러스터링 : 동일내용의 문서들을 묶는 기법문서 분류/클러스터링은 문서를 관련된 내용 별로 자동으로 구조화(사용자의 편리한 접근 실현)
문서요약 (Summarization)	<ul style="list-style-type: none">문서에서 다룬 중요 내용을 글로 요약하려는 시도
Web Mining Concept linkage Question Answering Topic Tracking	<ul style="list-style-type: none">텍스트 마이닝 기법을 웹 사이트에 적용하여 사용자들이 원하는 정보를 찾게 해주려는 시도각각의 문서들에서 공유되고 있는 의미를 발견하여 사용자에게 제공사용자가 자연 언어로 질문을 던지면 시스템이 질문에 대한 대답을 제공해 주는 시스템시스템은 사용자의 프로필에 따라 사용자가 관심 가질 것으로 예상되는 문서들만을 추출하여 사용자에게 제공

3. 텍스트 마이닝과 데이터 마이닝 비교

구분	Data Mining	Text Mining
대상	수치 또는 범주화된 데이터	텍스트
구조	관계형 데이터 구조	비정형 또는 정형 텍스트
목적	미래 상황 결과의 예측	적합한 정보 획득, 텍스트 의미를 정제
방법	분석기법, 기계학습	기계학습, 인덱싱, 언어처리, 온톨로지
대표서비스	OLAP, DW	검색

텍스트 마이닝

4. 텍스트 마이닝의 프로세스





프로세스 마이닝

input

event log

model

enhancement

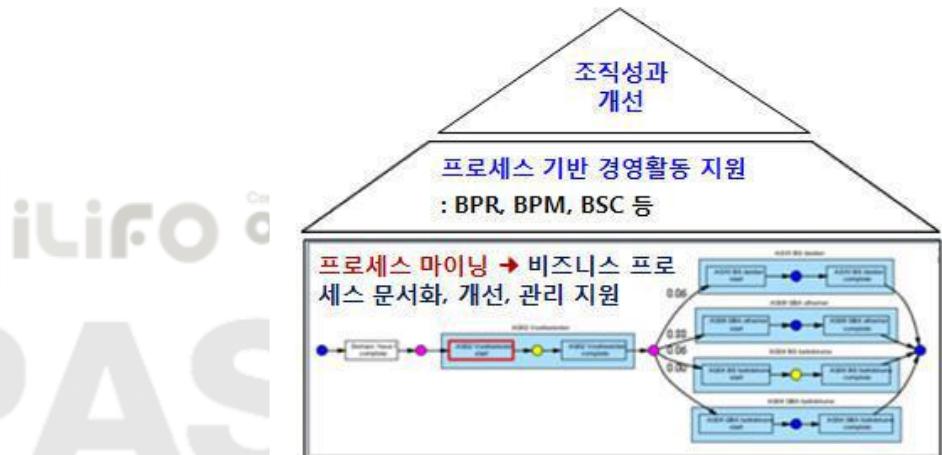
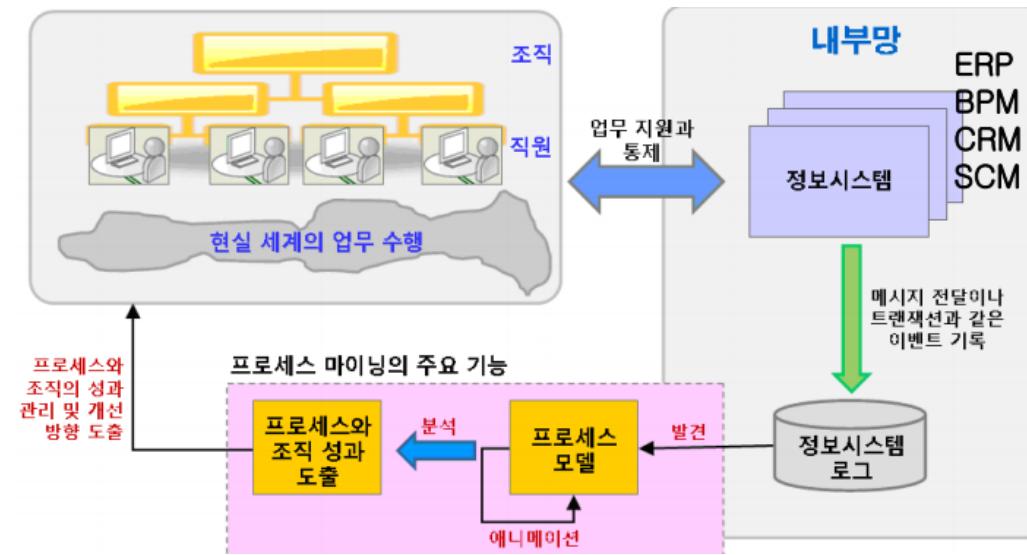
new model

output

1. 프로세스 경영과 개선을 위한 프로세스 마이닝 개요

- 업무프로세스 수행을 지원 또는 수행 결과를 기록하는 정보시스템 ERP, BPM, CRM, SCM 등에 저장되어 있는 **과거 업무수행 기록 (정보시스템 로그)**를 분석하여 업무수행결과에 대한 여러 가지 정보 및 지식을 추출해 내는 것을 목적으로 하는 활동 및 방법론

2. 프로세스 마이닝의 개념도 및 구성요소/기법



[프로세스 마이닝 기법]

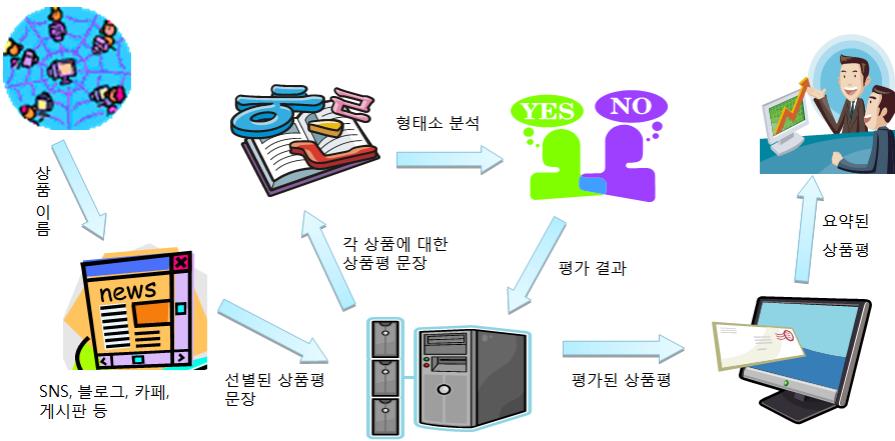
기법	설명
발견 (discovery)	<ul style="list-style-type: none"> 기존의 프로세스로부터 정보를 추출하여 새로운 프로세스를 찾아내는 기법 이벤트 로그에서 프로세스 모델의 자동 발견을 지원 과거의 수행내역을 재생하는데 활용 (animation)
순응도(적합) (conformance)	<ul style="list-style-type: none"> 이벤트 로그를 기반으로 발견된 프로세스가 의도했던 원래의 프로세스와 어느 정도 적합한지 평가 이벤트 로그와 프로세스 모델간의 일치 정도를 분석
확장 (enhancement)	<ul style="list-style-type: none"> 원래의 프로세스를 확장시켜 적합성을 상승 발견된 프로세스 모델을 시간 정보를 통해서 확장

오피니언 마이닝

1. 대중집단의 의견을 평가하는, Opinion Mining 의 개요

- SNS, 블로그, 카페, 게시판, 지식검색 등 인터넷에 산재한 모든 웹 문서, 댓글 등에서 소비자들의 의견을 수집 및 분석해 제품이나 서비스 등에 평판을 추출해 내는 Mining 기법

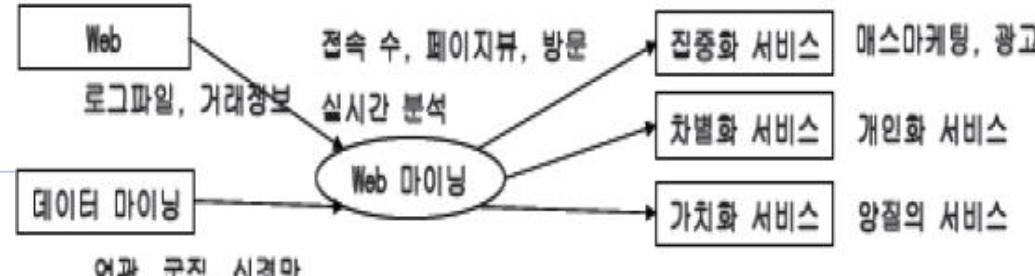
2. Opinion Mining의 개념도 및 주요절차



유형	주요내용	요소기술
1단계	<ul style="list-style-type: none"> 문장을 '팩트'에 근거한 문장과 글쓴이의 '의견'이 들어간 문장으로 구분 긍정 및 부정을 표현하는 단어 정보를 추출 	
2단계	<ul style="list-style-type: none"> 세부 평가요소와 그것이 가리키는 오피니언 연결 관계를 포함한 문장 인식 글쓴이의 '의견'이 들어간 문장을 Positive와 Negative 문장으로 구분 형용사, 동사, 부사에 초점 사례) <p>배송은/느리지만, /제품은 /이쁘고/ 좋네요. (명사 / 형용사(-1) / 명사 / 형용사(+1) / 형용사(+1))</p>	텍스트마이닝 자연어처리 비정형 분석 형태소 분석
3단계	긍정/부정 표현의 수 및 유용한 문장 추출하여 리뷰 요약 생성	

구분	Opinion Mining	Text Minig
방식	SNS, 리플, 댓글, 게시판 등 Web을 기본으로 하는 개인 의견 글 위주	컴퓨터에 저장되어 있는 문서, 이메일, 웹 페이지를 대상으로 마이닝을 수행
목적	상반된 의견의 강도 측정 예) 선거 후보자 지지도	내용분석, 분류
단점	분석기를 작성하는데 비용이 많이 들	높은 성능을 위해서는 대단히 많은 학습 데이터 필요
기술요소	자연어 처리, 감성분석	자연어 처리

웹마이닝



1. Web Mining 의 개요

- 웹에서 발생하는 고객의 행위 분석과 특성 데이터를 추출 정제로 딩하여 의사결정에 활용하기 위한 데이터 마이닝 기법

2. Web Mining 유형

유형		개념 설명
웹내용 마이닝	에이전트기반	- 웹 사이트를 구성하는 페이지의 내용 중에서 유용한 정보를 추출 (텍스트, 이미지, 사운드 등)
	DB 기반	
웹 사용 마이닝		- 웹로그를 분석 사용자의 행위 패턴을 분석하여 의미 있는 정보 추출
웹 구조 마이닝		- 웹 사이트의 구조적인 요약 정보를 찾기 위한 기법, 웹 사이트내의 하이퍼링크를 통한 그래프의 구조적인 정보 이용

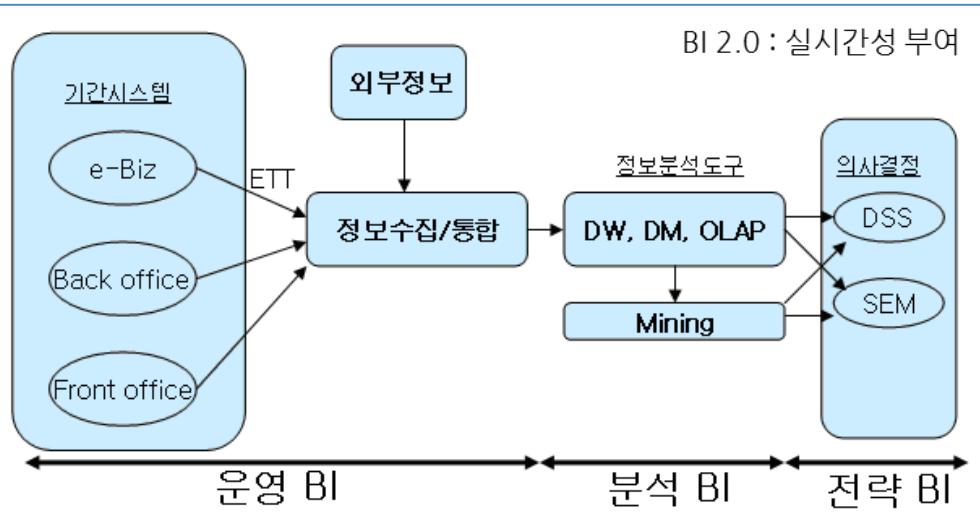
구분	Web Mining			
	Web 컨텐츠 Mining		Web 구조 Mining	Web 사용 Mining
Agent 기반	DB 기반			
Data 특징	<ul style="list-style-type: none"> - Unstructured - Semi Structured 	<ul style="list-style-type: none"> - Semi Structured - Web site as DB 	<ul style="list-style-type: none"> - 링크 구조 	<ul style="list-style-type: none"> - Interactivity
주요 Data	<ul style="list-style-type: none"> - Text 문서 - Hypertext 문서 	<ul style="list-style-type: none"> - Hypertext 문서 	<ul style="list-style-type: none"> - 링크구조 	<ul style="list-style-type: none"> - Server로그 - 브라우저 로그
처리결과	<ul style="list-style-type: none"> - 단어/용어/구 - 개념 또는 Ontology - 관계형 	<ul style="list-style-type: none"> - Graph - 관계형 	<ul style="list-style-type: none"> - Graph 	<ul style="list-style-type: none"> - 관계형테이블 - Graph
주요 분석기법	<ul style="list-style-type: none"> - 변이 탐색 - 기계학습 - 통계기법 	<ul style="list-style-type: none"> - 선호도 알고리즘 - 관계분석 	<ul style="list-style-type: none"> - 선호도 알고리즘 	<ul style="list-style-type: none"> - 기계학습 - 통계기법 - 관계분석
활용 유형	<ul style="list-style-type: none"> - 범주화 - 군집화 - 규칙추출/발견 - Text에서 패턴발견 - 사용자 모델링 	<ul style="list-style-type: none"> - 빈도높은 하부구조 발견 - 웹사이트 스키마 도출 	<ul style="list-style-type: none"> - 범주화 - 군집화 	<ul style="list-style-type: none"> - 사이트구축/변경/관리 - 마케팅 - 사용자 모델링

BI (Business Intelligence)

1. 실시간 데이터기반, 신속한 의사결정(RTE) 구현을 위한 BI의 개요

- 기업의 비즈니스 의사 결정에 필요한 데이터의 접근, 수집, 보관, 분석을 통합적으로 지원하는 기술과 시스템
- 특징 : 사용자중심, 데이터분석, 의사결정지원, 비즈니스가치제공

2. BI의 구성도, 구성요소 및 관련 기술



구분	설명	예시
운영 BI	BI를 수행하기 위한 다양한 기술 및 데이터 통합기반 제공	ETL, EDW, Data Mart
분석 BI	특정이슈 해결 위한 전문적인 의사결정 모델로부터 다양한 정보 생성 및 제공	OLAP, 데이터마이닝, 전문 의사결정 도구
전략 BI	경영전략의 효율적 수립 및 실행을 위한 분석 정보제공	SEM솔루션, VBM, BSC, ABC/ABM

핵심요소	설명
정보 추출, 변형	<ul style="list-style-type: none"> Data, Information을 Business에 유용한 정보로 변형 ETT(Extraction, Transformation, Transportation)
정보 관리	<ul style="list-style-type: none"> DW, Data Mart 구축 통한 정보관리, 데이터 품질 관리
정보분석 및 Modeling	<ul style="list-style-type: none"> OLAP, Data Mining 등 분석 기능 활용. 다차원 모델링 (Star Schema, Snowflake Schema)
정보 배포	<ul style="list-style-type: none"> 의사결정자에게 배포하여, 참조하게 함
어플리케이션통합	<ul style="list-style-type: none"> 주요 어플리케이션과 통신 위한 메시지의 표준 관리 데이터 변환 및 어플리케이션의 통합 기능 제공.
데이터웨어하우스	<ul style="list-style-type: none"> 기업 운영 데이터, 외부 데이터 수집 및 통합 DW(Data Warehouse), DM(Data Mart)
네트워크/시스템 관리	<ul style="list-style-type: none"> 시스템 및 네트워크 장애가 비즈니스 프로세스에 미치는 영향 분석 HA(High Availability), DRS(Disaster Recovery System)
프로세스통합관리	<ul style="list-style-type: none"> 전체적인 업무 프로세스 흐름상에서 비즈니스 이벤트를 분석하여 그 영향을 분석하는 업무 프로세스 기반 제공. BPM, BRE, BAM

BI 1.0과 BI 2.0의 비교

구분	BI 1.0	BI 2.0
정보 갱신 주기	Batch	Real Time
정보 이용자	의사결정권자	Every Employee
의사 결정 주기	Day / Month	수시(Event-Driven)
사용 목적	사후 평가/관리	즉시 의사결정, 사전예방
정보 성격	Summary/Historical	Transaction/이상정보
정보 Source	내부 데이터	내·외부 데이터
정보 제공 방식	온라인 리포트	온라인리포트, 메시지, 무선
개발 방식 (핵심기술)	Stand-Alone (Data Warehouse)	Operation System Add-in (EDA, BAM, SOA, Agent Etc)

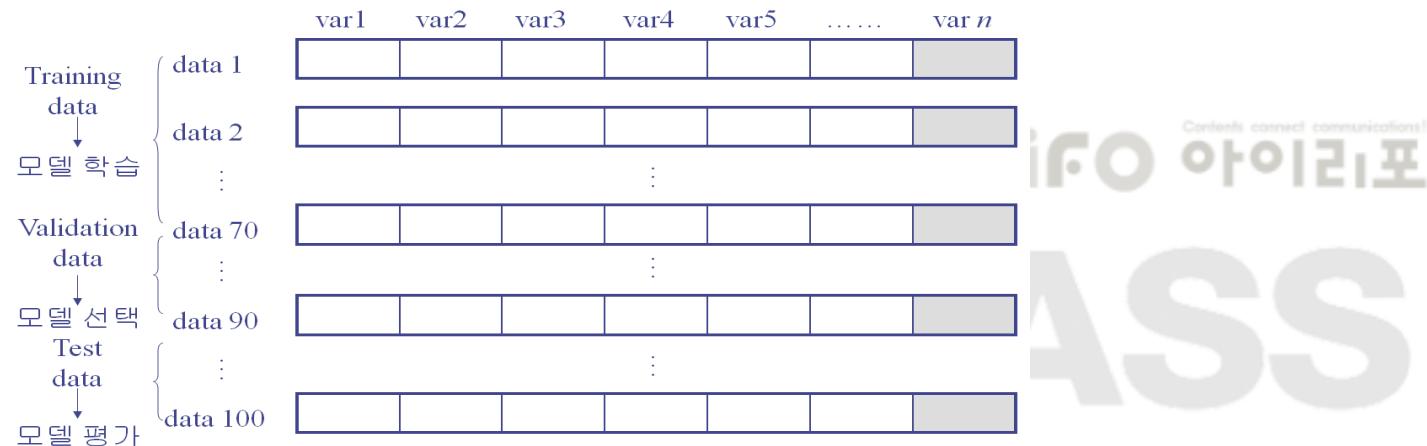
Data 분석에서 모델 평가 방법

1. Data 분석 모델 평가 방법

- 데이터마이닝을 통해 생성된 모델의 예측을 통해 모델의 타당성을 평가하는 검증 방법

2. Train-validation

- 훈련집합, 테스트 집합, 검증 집합을 통해서 모델의 정확도를 검증



데이터 Set	설명	활용
Training Set	모형을 적합화시키기 위해 사용되는 데이터	모델 학습
Test Set	최종 선택모형이 새로운 데이터에 대하여 좋은 성과를 갖는지 평가	모델 평가
Validation Set	모형이 얼마나 잘 적합화 되었는지 평가 일부 모형을 조정하여 구축된 모형 중 좋은 모형 선택	모델 선택

Data 분석에서 모델 평가 방법

3. 재 샘플링 기법

- 데이터 모델을 선택시 Training Set 이외에도 별도의 Validation Set이 필요함
- 데이터의 수집에 많은 비용 문제로 대부분 데이터의 양이 부족한 현실에서, 재 샘플링 기법을 사용하면 성능 측정의 신뢰도를 높일 수 있음
- 대표적인 재 샘플링 기법: Cross-Validation, Bootstrap 기법

기법	설명	개념도
Cross-Validation	<ul style="list-style-type: none">Training Set을 k개의 부분 집합으로 등분k-1개로 학습하고 나머지 한 개로 테스트. 이런 과정을 서로 다른 부분 집합으로 k번 수행하여 얻은 성능을 평균함.이를 k-fold Cross Validation이라 함.k=N인 경우(N은 샘플 개수) 하나 남기기(Leave-one-out) 또는 잭나이프(Jackknife) 기법이라함	
Bootstrap	<ul style="list-style-type: none">중복을 허용하는 기법으로, N개의 샘플을 가진 샘플 집합 X가 존재, 집합X에서 N개의 샘플은 임의로 추출N개의 Training sample에서 Bootstrap sample을 취하는데, 중복을 허용하여 B개를 샘플링함.이와 같은 Bootstrap sample을 t번 반복 측정하고, 그 결과를 평균한 값을 최종 성능으로 취함.Bootstrap sample로 모델을 학습하고, 오류를 예측할 때 Training set을 이용하는 방법모집단으로부터 추출된 표본을 가상의 모집단으로 취급하고, 이 가상의 모집단으로 복귀하는 과정을 거치면서, 표본을 추출함.	

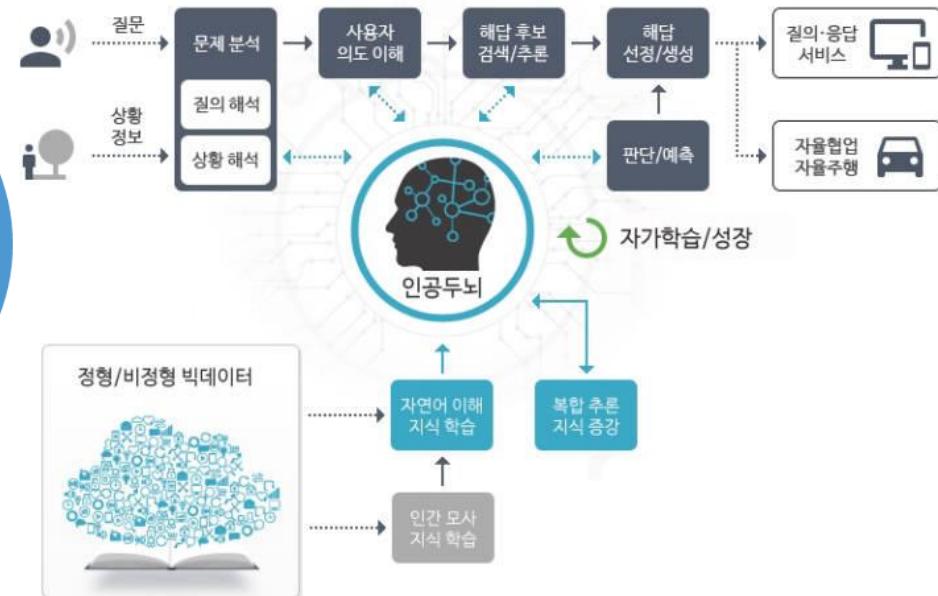
Data 분석에서 모델 평가 방법

4. Train-validation, Cross-Validation, Bootstrap 의 비교

항목	Train-validation	Cross-Validation	Bootstrap
개념	훈련집합, 테스트 집합, 검증 집합을 통해서 모델의 정확도를 검증	데이터를 k개의 집합으로 나누어 검증한 결과의 평균치로 모델 검증	전체 데이터에서 무작위 복원 추출로 훈련집합 생성 하여 검증하는 방법
활용기준	데이터가 충분히 많은 경우	데이터가 충분하지 않은 경우	데이터가 충분하지 않은 경우, 모집단 분포 가정 어려운 경우
데이터 set	Train Set, Test Set, Validation Set	K개의 Set 분류(k-fold) k-1 : Train set 1 : Test set	N개의 Bootstrap sample
정확도	에러율 예측의 정확도 다소 낮음	Train-validation 보다 높은 정확도	Train-validation 보다 높은 정확도
특징	데이터 set의 분리 비율이 결과에 영향 미침	분류의 수에 따라 결과 영향 미침	모집단의 분포의 가정 없이 검증 가능

- 데이터의 양이 충분치 않은 경우, 데이터 모델의 성능 측정의 통계적 신뢰도를 높이기 위해 재 샘플링 기법을 사용하는데, Cross-validation, Bootstrap 이 대표적 방법임

인공지능



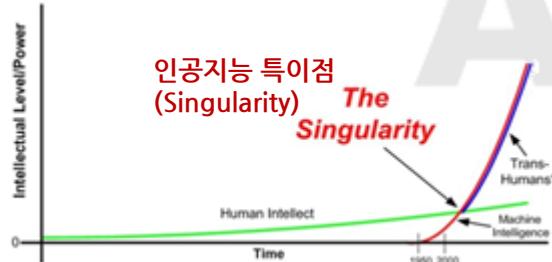
인공지능(artificial intelligence)

1. 인공지능 정의

- 인간의 인지, 추론, 학습의 사고과정에 필요한 능력을 컴퓨터 시스템을 통해 구현함으로써 문제를 해결할 수 있는 기술
- 인간이 컴퓨터보다 잘하는 일을 컴퓨터로 하여금 인간처럼 할 수 있도록 하는 연구

사전적 개념	철학적인 개념으로 인간이나 지성을 갖춘 존재 또는 시스템에 의해 만들어진 인공적인 지능
전통적 개념	컴퓨터가 인간의 지능적인 행동을 모방 할 수 있도록 하는 소프트웨어로 인간이 가진 지적능력의 일부 또는 전체를 인공적으로 구현한 것
기술적 개념	인간의 지능으로 할 수 있는 사고(thinking), 학습(learning), 자기계발등을 컴퓨터가 할 수 있도록 하는 방법을 연구하는 컴퓨터공학 및 정보기술의 한 분야

2. 인공지능 특이점 (Singularity)



- 인공지능이 비약적으로 발전해 **인간의 지능을 초월하는 시점**
- 약인공지능이 특이점을 넘어서며 강인공지능으로 발전 (약: 2025년 예상)

3. 인공지능의 분류

분류	상세분류	사례
약 인공지능 (Weak AI / Artificial Narrow Intelligence: ANI)	주어진 조건 아래에서만 작동 가능	구글맵스, 자율자동차, 구글번역, 페이스북 추천
강인공지능 (Strong AI / Artificial General Intelligence : AGI)	인간과 같은 사고가 가능한 인공지능	터미네이터, 비서로봇, 공장 로봇 등
초인공지능 (Artificial Super Intelligence : ASI)	모든 영역에서 인간을 훨씬 뛰어넘는 인공지능	“인류가 앞으로 1,000년 동안 쓸 수 있는 신 에너지원을 만들어 내 봐.” 와 같은 고차원의 명령도 가능

인공지능(artificial intelligence)

4. 인공지능의 분류

분류	분류기준	상세분류
지적수준	주어진 조건과, 인간과 같은 사고의 가능 여부	<ul style="list-style-type: none"> 약인공지능(Weak AI / Artificial Narrow Intelligence: ANI) 강인공지능(Strong AI / Artificial General Intelligence : AGI) 초인공지능(Artificial Super Intelligence : ASI)
기능발전(레벨)	입력에 따른 출력이 변하는 Agent 관점	<ul style="list-style-type: none"> 레벨1 : 단순제어 프로그램 레벨2 : 고전적 인공지능 레벨3 : 머신러닝 레벨4 : 딥러닝
구현방식	지적 기능 구현 방식	<ul style="list-style-type: none"> 지식기반 방법론(인식, 추론, 학습) 데이터기반 방법론(머신러닝, 딥러닝)

← 강한 인공지능

약한 인공지능 →

인간과 같은 사고 (Thinking Humanly)

- 인간과 유사한 사고 및 의사결정을 내릴 수 있는 시스템
- 인지 모델링 접근 방식

인간과 같은 행동 (Acting Humanly)

- 인간의 지능을 필요로 하는 어떤 행동을 기계가 따라 할 수 있는 시스템
- 튜링 테스트 접근 방식

논리적 사고 (Thinking Rationally)

- 계산 모델을 통해 지각, 추론, 행동 같은 정신적 능력을 갖춘 시스템
- 사고의 법칙 접근 방식

논리적 행동 (Acting Rationally)

- 계산 모델을 통해 지능적 행동을 하는 에이전트 시스템
- 합리적인 에이전트 접근 방식

생각

행동

[표 2] 인공지능 주요 기술 요소

인공지능 구현방식	기술 요소
1. 합리적으로 생각하기	① 학습지능: 기계가 새로운 환경에 적응하고 패턴들을 감지하고 추정한다. ② 추론/표현지능: 기계가 아는 것, 들은 것을 저장한다. 질문에 답하거나 새로운 결론을 유도하기 위해서 저장된 정보를 사용한다. ③ 음성인식/이해지능: 기계가 대화하는 것을 가능하게 한다. ④ 시각지능: 기계가 물체를 지각한다.
2. 인간처럼 생각하기	
3. 인간처럼 행동하기	
4. 합리적으로 행동하기	

[표 1] 인공지능에 관한 정의

인간처럼 생각하는 시스템	합리적으로 생각하는 시스템
<ul style="list-style-type: none"> 컴퓨터를 생각하게 만들기 위한 재미있는 새로운 노력... 말 그대로 “마음을 가진 기계”(Haugeland 1985) 의사결정, 문제해결과 같은 활동, 즉 인간의 사고 (thinking)와 관련된 활동의 자동화(Bellman 1978) 	<ul style="list-style-type: none"> 계산적 모델(computational models)의 사용을 통한 정신적 능력(mental faculties)에 대한 연구(Charniak and McDermott 1985) 지각, 추론 행동을 가능하게 하는 계산들(computations)에 대한 연구(Winston 1992)
인간처럼 행동하는 시스템	합리적으로 행동하는 시스템
<ul style="list-style-type: none"> 인간처럼 지능을 필요로 하는 그러한 기능(function)을 수행하는 기계를 창조하는 기술(Kurzweil 1990) 인간이 더 잘하는 것을(things) 어떻게 하면 컴퓨터가 하게 만들지를 연구하는 것(Rich and Knight 1991) 	<ul style="list-style-type: none"> 계산 지능(Computational Intelligence)은 지능적 에이전트를 설계하는 것에 대한 연구이다.(Pool et al 1998) AI는....인공물에서의 지능적 행동(behavior)과 관련된다.(Nilsson 1998)

<자료> Artificial Intelligence: A Modern Approach, 2009.

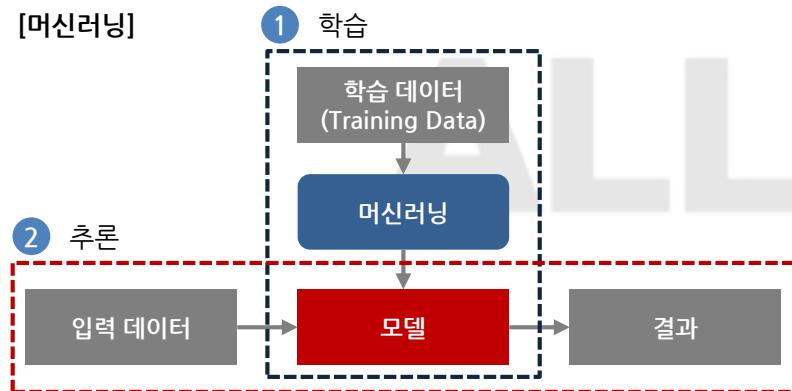
인공지능 분류 체계

5. 인공지능 분류체계

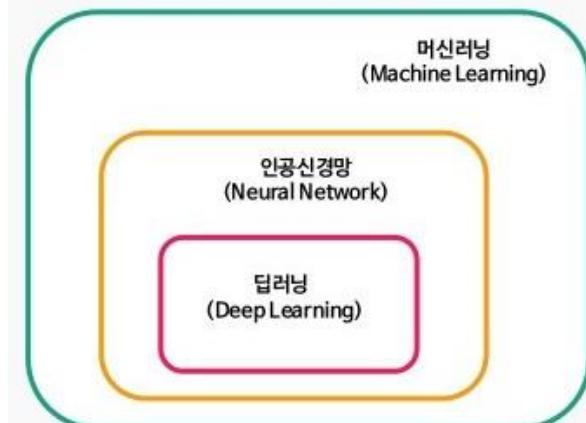
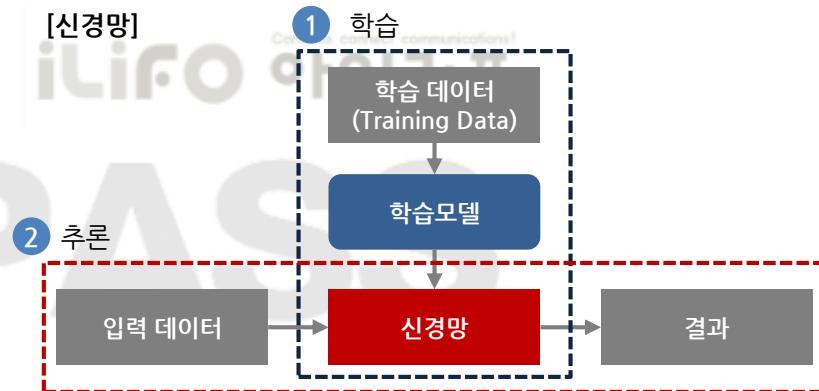
인공지능	- 인간의 인지, 추론, 학습의 사고과정에 필요한 능력을 컴퓨터 시스템을 통해 구현함으로써 문제를 해결할 수 있는 기술
머신러닝	- 컴퓨터가 수많은 데이터를 스스로 학습하고 알고리즘을 통해 학습의 결과를 도출하는 인공지능의 한 분야의 학습법
딥러닝	- 더욱 고도화된 신경망 알고리즘을 적용하여 보다 빠르고 감성적이며 인간과 유사하게 행동하는 컴퓨터 프로그램을 구현한 학습방법

- 인간의 능력을 가진 컴퓨터 시스템을 구현하기 위한 방법으로 지도/비지도학습을 통한 스스로 학습하는 머신러닝, 신경망 알고리즘을 이용하는 딥러닝으로 세분화
- 목표는 **일반화(Generation)** !! - 학습데이터와 입력데이터가 달라져도 성능차이가 나지 않게 하는 것

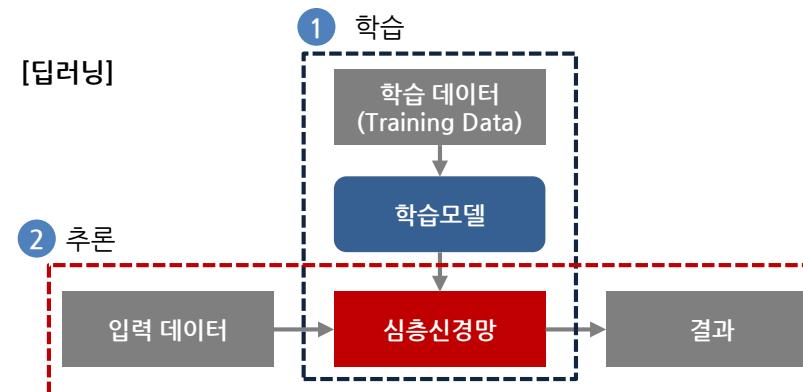
[머신러닝]



[신경망]



[딥러닝]



인공지능 분류 체계

6. 기계학습과 딥러닝 비교

구분	기계학습	딥러닝
학습데이터양	Small	Large
Feature 선택 주체	<u>Human</u>	<u>Machine</u>
학습 시간	Short	Long
가능한 분류기 개수	Many	Few
주요 학습 방법	지도/비지도	강화/비지도
주요 학습 알고리즘	인공신경망, SVM, Decision Tree	인공신경망 기반 CNN, RNN, DBN
기대효과	기존 프로세스의 개량 혹은 개선	새로운 공정 설계

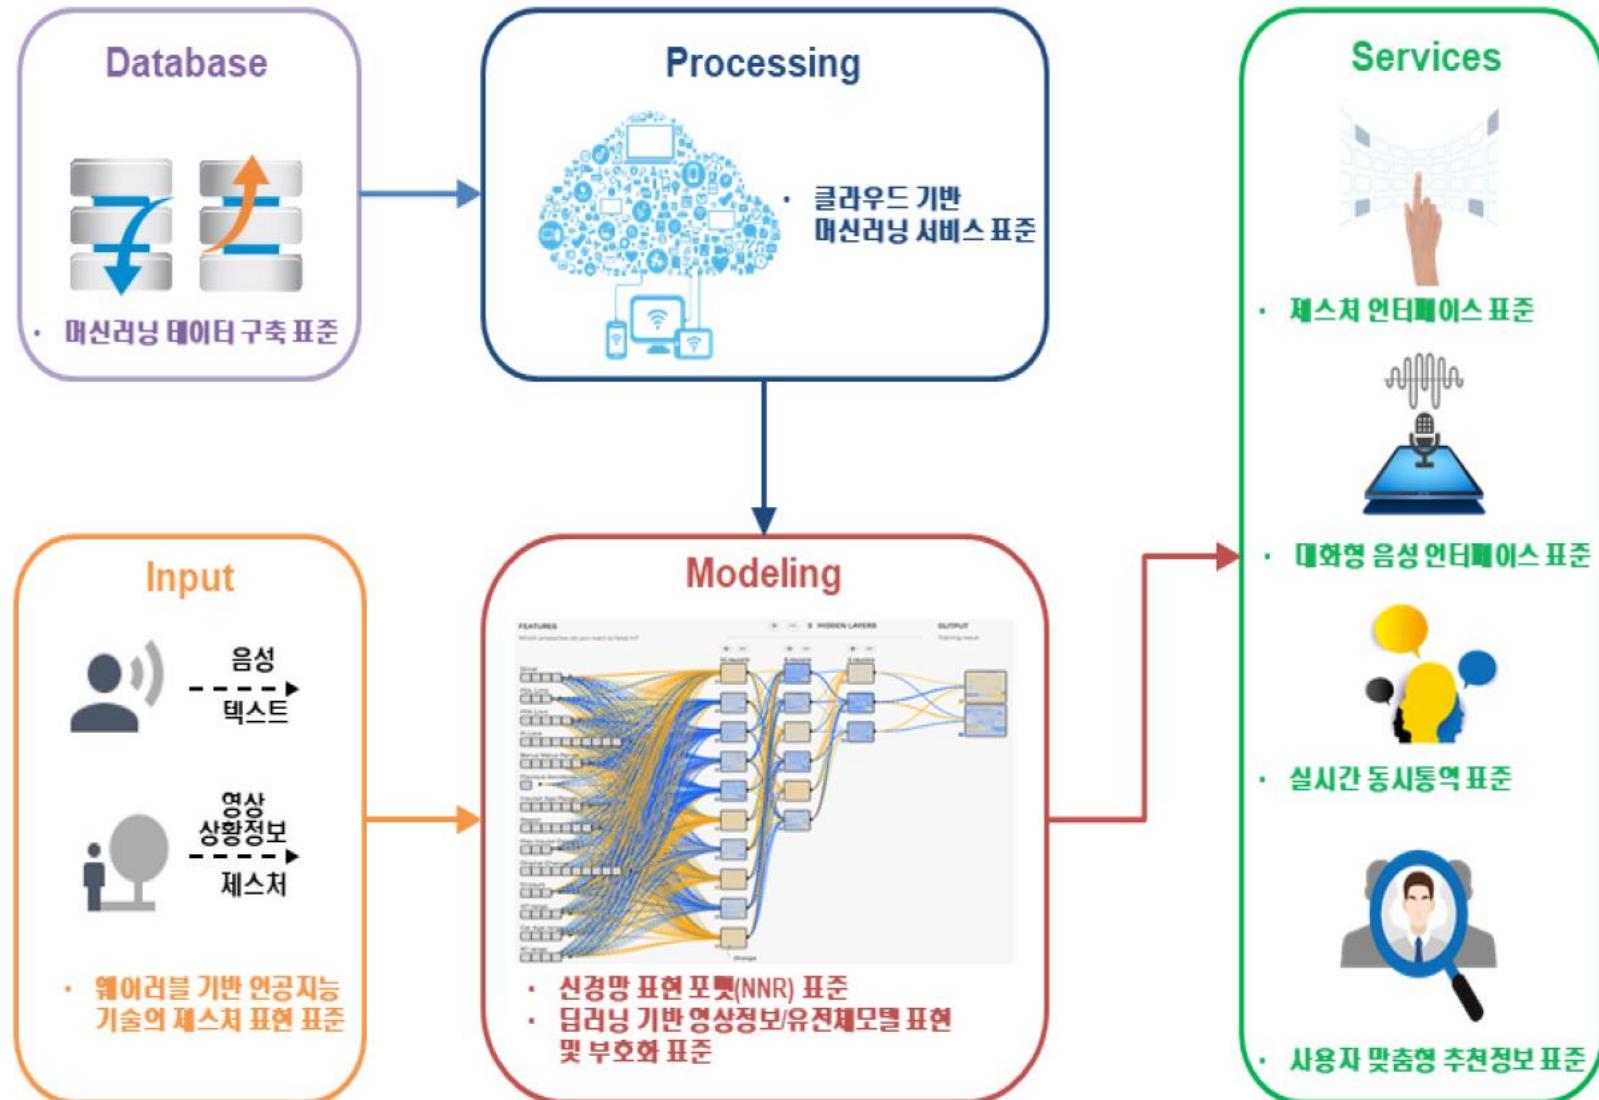
- 주요 학습 방법, 주요 학습 알고리즘은 관점에 따라 다름



인공지능 분류

구분	개념	주요 기술	응용 분야	응용 사례
학습 (Learning)	<ul style="list-style-type: none"> 전제와 결론간의 논리적 관계를 수리 논리학 언어를 활용해 예측하고, 이를 기반으로 입력(학습)되지 않은 새로운 결론(명제)을 유도하려는 접근 방법 <p>【 연구 영역 】</p> <pre> graph LR Premise[전제] --> Relation[관계] Relation --> Conclusion[결론] </pre>	<ul style="list-style-type: none"> 합성곱 신경망 (Convolutional Neural Networks) 순환 신경망 (Recurrent Neural Networks) 선행학습 알고리즘 (Pre-training Algorithm) 	<ul style="list-style-type: none"> 지능형 인터넷 생산공정 자동화 우편 시스템 자동화 의료 (환자 진단 등) 	<ul style="list-style-type: none"> 구글 "스팸메일필터" 광고 플랫폼 "애드센스" 이스라엘 볼트 社의 "영화 시나리오 분석 및 흥행 예측 시스템" 미국 VSCO 社의 "큐레이션 자동화"
추론 (Reasoning)	<ul style="list-style-type: none"> 일련의 전제들 간의 논리적 관계를 수리 논리학 언어를 활용해 예측하고, 이를 기반으로 결론(명제)을 유도하는 접근 방법 (e.g.: 삼단논법) <p>【 연구 영역 】</p> <pre> graph LR Premise1[전제1] --> ...[...] ... --> Premisen[전제n] Premisen --> Conclusion[결론] </pre>	<ul style="list-style-type: none"> 비단조 추론 (Non-monotonic Reasoning) 연역 추론 (Forward Chaining) 귀납 추론 (Backward Chaining) 상식 추론 (Common Sense Reasoning) 	<ul style="list-style-type: none"> 지능 엔진 (게임 등) 가사보조 로봇 바이러스 백신 신용카드 승인 시스템 	<ul style="list-style-type: none"> IBM 인공지능 "왓슨" (Jeopardy 퀴즈쇼 우승) 사우스캘리포니아 대학 아동 자폐증 치료로봇 "밴디트" 빅데이터/보안 기업 Splunk 社의 "Splunk Enterprise"
인지 (Recognition)	<ul style="list-style-type: none"> 일련의 패턴(Pattern) 간의 공통요소를 수리 논리학 언어(Algorithm, Formula 등)를 활용해 추출하고, 이를 <p>【 연구 영역 】</p> <pre> graph LR Pattern1[패턴1] --> ...[...] ... --> Patternn[패턴n] Patternn --> CommonPoint[공통점] </pre>	<ul style="list-style-type: none"> 행동 실험 (Behavioral Experiments) 영상 기법 (Brain Imaging) 연산 모델링 (Computational Modeling) 신경 생물학 방법 (Neurobiological Methods) 	<ul style="list-style-type: none"> 자연어 처리 음성 인식 안면 인식 교통 상황 제어 	<ul style="list-style-type: none"> 구글 "언어 번역기" 애플 "시리" 페이스북 "딥페이스" 삼성 "s보이스" LG "Q보이스" IBM "스마트 CCTV" 일본 정부 "스마트신호등"

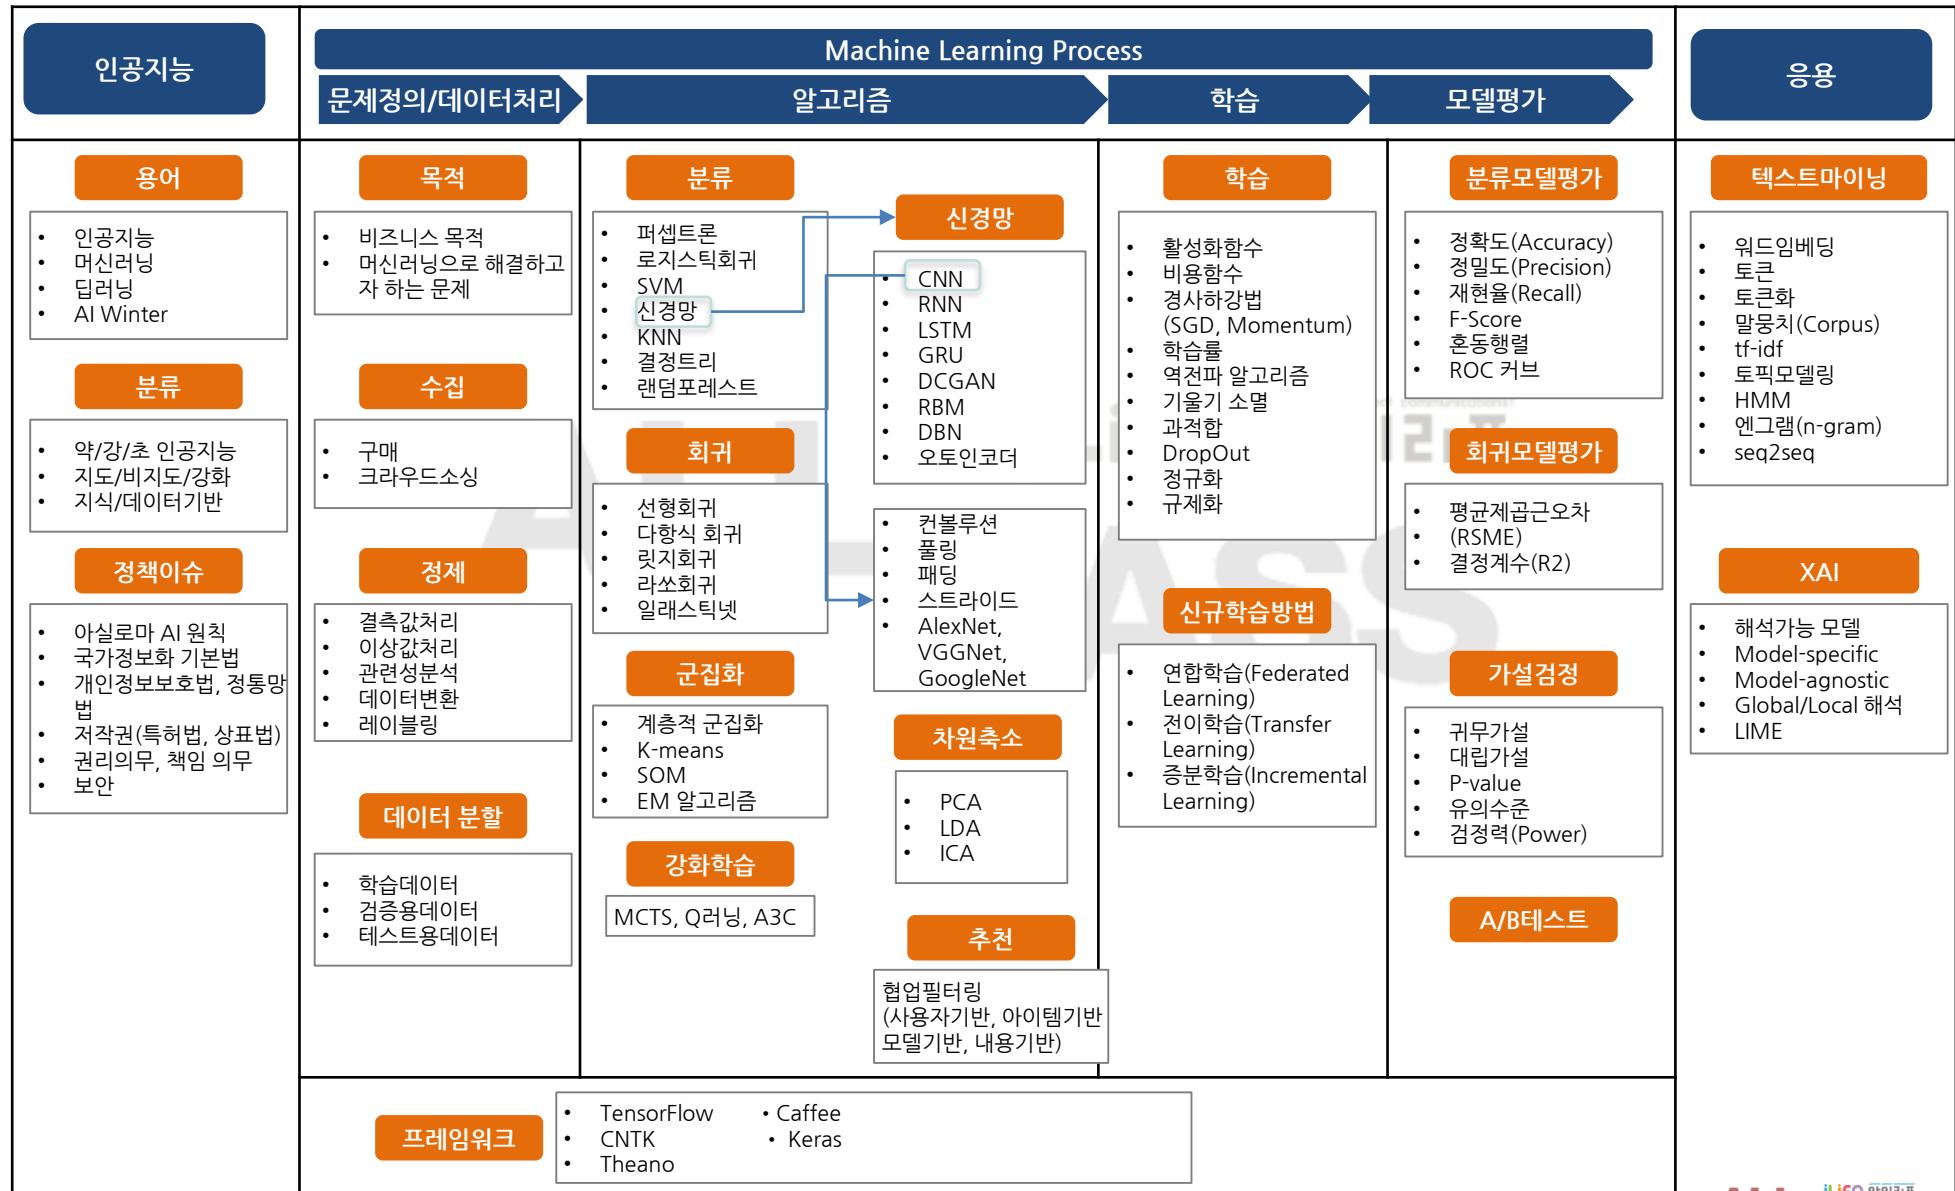
인공지능 기술



<인공지능 기술 개요도>

인공지능 맵

출처 : ZN PE

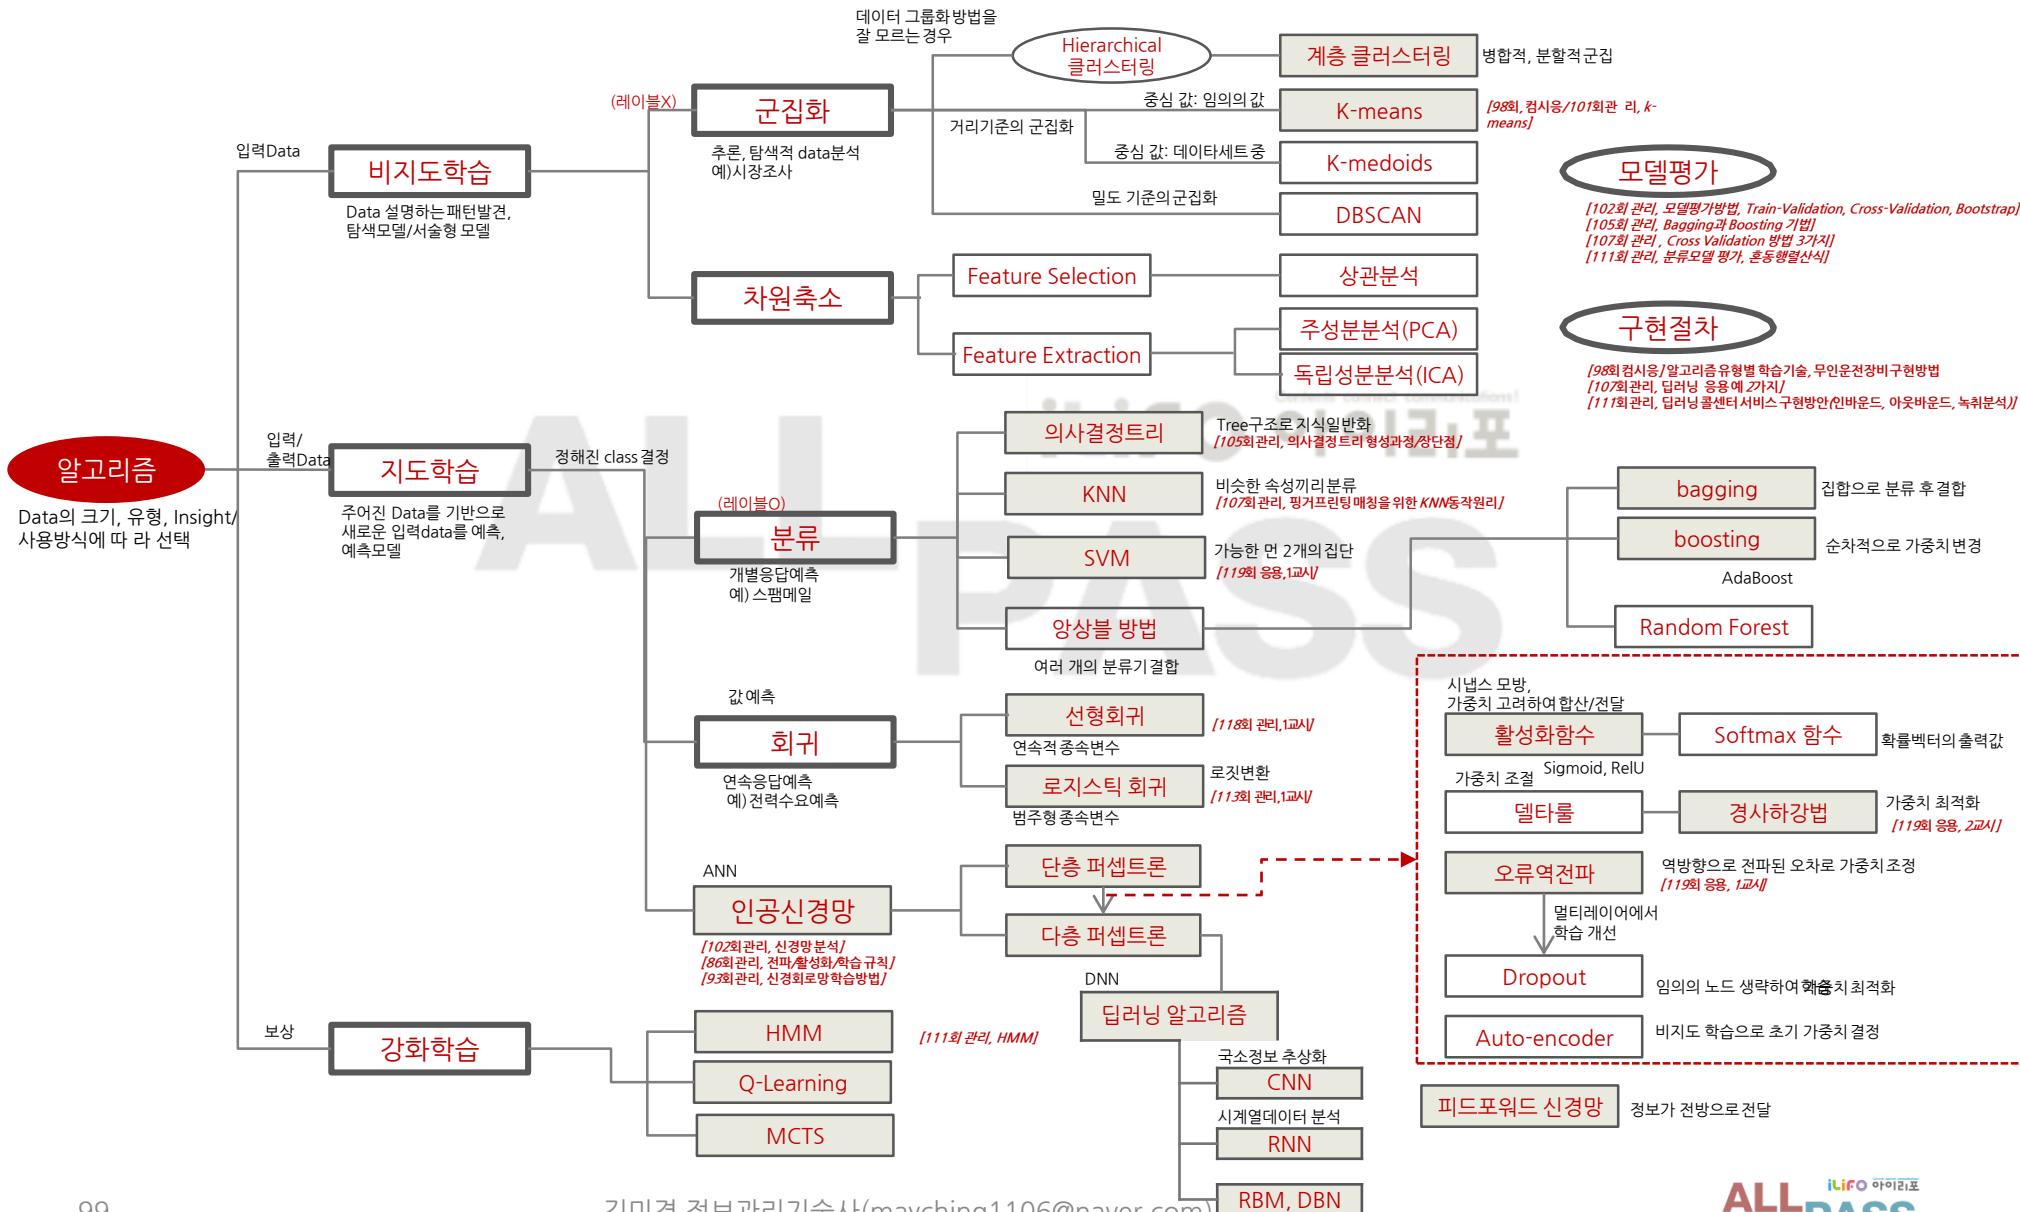


인공지능 분류 및 알고리즘 분류

머신 러닝

/102회 관리, Percentile을 이용하여 Outlier/
 /103회 관리, 알고리즘 유형/
 /108회 검시용, 기계학습 개념 및 응용분야/
 /110회 검시용, 딥러닝 개념/

/110회 관리, 인공지능 법제도 문제점/개선방안/

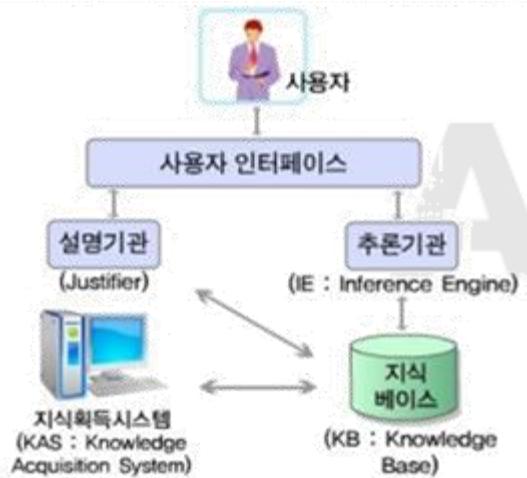


전문가시스템(Expert System)

1. 전문가시스템(Expert System)의 개요

- 인간이 특정분야에 대하여 가지고 있는 전문적인 지식을 정리하고 표현하여 컴퓨터에 기억시킴으로써, 일반인도 이 전문지식을 이용 할 수 있도록 하는 시스템
- 특정 문제 영역에서 그 영역의 **인간 전문가가 의사 결정을 내리는 것과 유사하게 동작하는 컴퓨터 시스템**

2. 전문가시스템 구조, 개발 도구 및 개발 과정



구성요소	설명	비고
설명기관	• 전문가시스템이 내는 결론에 대해 설명해줌	• 기존 시스템과의 핵심 차별점
추론기관	• Inference Engine • 지식기반으로 정보를 추론하여 전달	• 정방향 추론 • 역방향 추론
지식획득시스템	• Knowledge Acquisition System • 전문가와의 인터뷰나 문헌자료 등을 수집하고 정리하여 컴퓨터에 입력하는 과정	• 자동지식습득으로 변화
지식베이스	• Knowledge Base • Semantic Network를 이용	• if-then-else 규칙

3. 전문가시스템 개발 언어 도구

개발도구	설명
문제지향언어(PASCAL, FORTRAN)	• 규칙을 바탕으로한 논리 처리 • 과학, 수학계산, 상업분야 등
심볼처리언어(LISP, PROLOG)	• 리스트 형태로 나타낸 심볼을 처리 • 인공지능 분야

5. 지식수집방법

관찰	문제토의
시스템 정련	• 문제 분석
시스템 검증	• 문제 서술

4. 전문가시스템 개발 과정

번호	개발 과정	설명
1	문제정의	• 주어진 문제의 유형과 범위, 개발작업에 참여할 인력, 전문가, 소요될 시간, 컴퓨터 시설 등을 함께 고려
2	개념설정	• -정의된 문제를 해결하기 위해 필요한 개념을 정립하고 각 개념 사이의 관계와 제어기능을 정의
3	정형화	• -중요한 개념과 지식을 정형화하여 표현
4	구현	• -표현된 지식을 프로그래밍하는 단계로써 자료구조, 추론과정, 프로그램 제어, 하부 시스템들의 통합 등을 고려
5	검증	• -개발된 시스템이 처음 정의한 요구사항대로 만들어졌는가 평가

전문가시스템(Expert System)

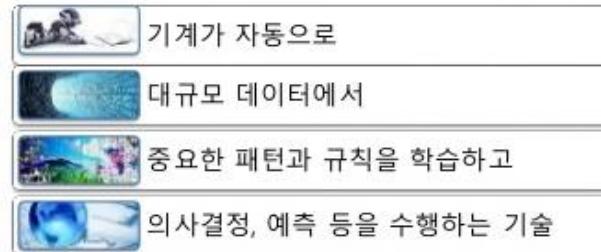
6. 인간과 전문가 시스템의 비교

Factor	인간	Expert system
이용 가능한 시간	workday (일하는 시간만)	always
이용 가능한 공간	local (제한적)	anywhere availability (어디서나)
안전성	irreplaceable (회복불능)	replaceable (교체가능)
Perishable (사멸가능성)	Yes	no
성능	variable (변화가능)	consistent (항상 일정함)
속도	variable (변화가능)	Consistent (보통 더 빠르다)
비용	high	Affordable 알맞은

ALL-PASS



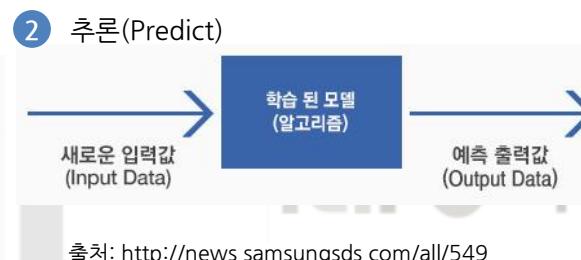
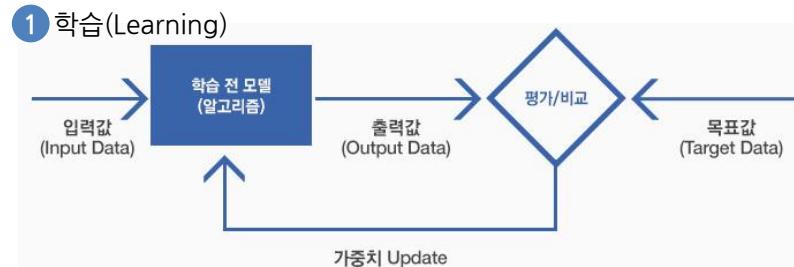
기계학습(Machine Learning)



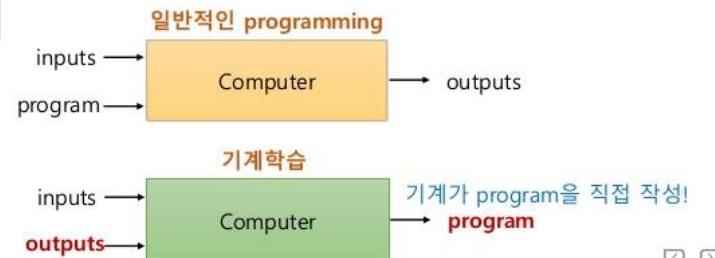
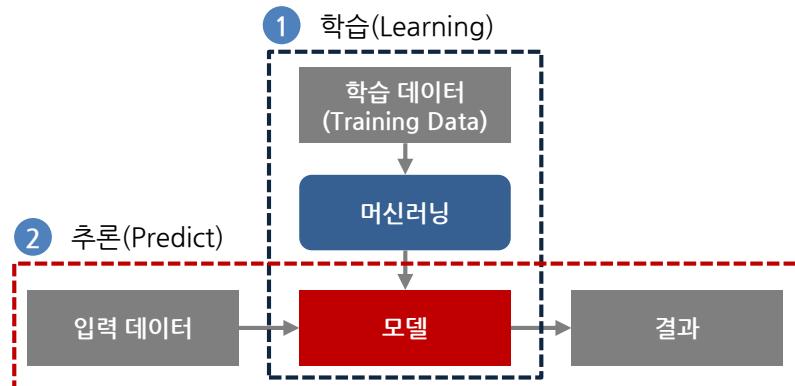
1. 데이터를 이용한 모델링 기법, 기계학습의 개요

- 컴퓨터 프로그램이 어떠한 태스크(T)를 수행할 때, 학습경험(E)을 통해 정의된 성능(P)을 보이도록 설계하는 것
- 귀납적 학습, 오캄의 면도날(단순한 표현 선택, 과적합)

2. 기계학습의 개념도 및 주요 요소



머신러닝 요소	설명
Training Set (학습데이터)	학습 모델을 만들기 위해 사용하는 데이터
Model(학습 모델)	최종 결과물(가설)
Inference(추론)	학습모델을 실제 사용하는 과정

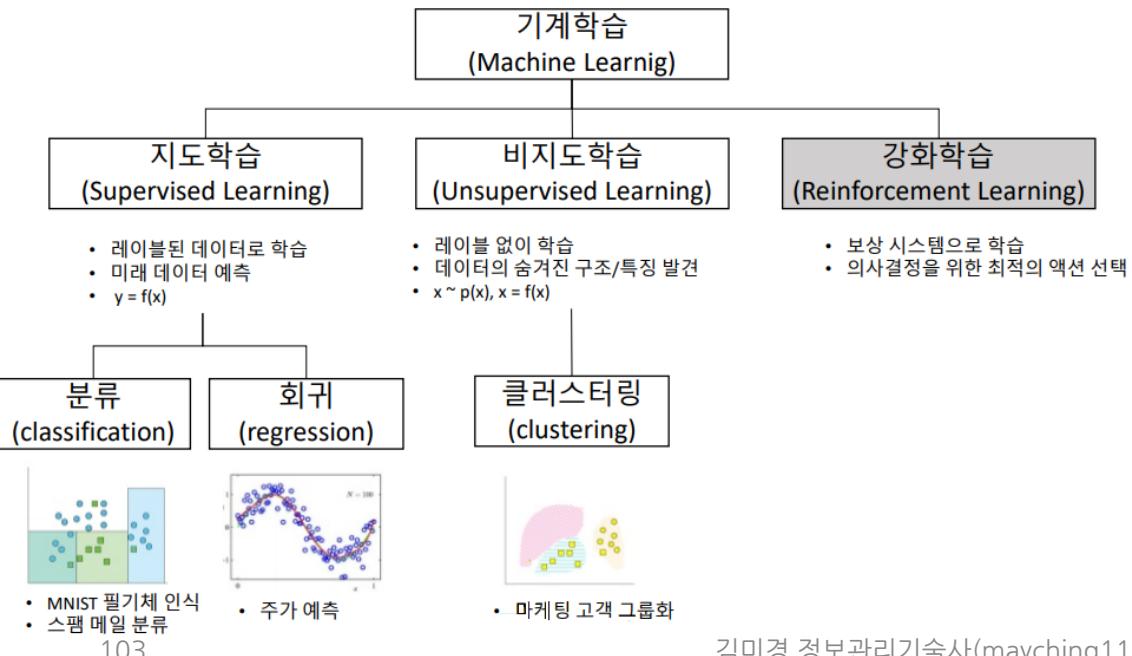


기계학습(Machine Learning)

3. 기계학습의 주요 학습 유형

학습 유형	설명	주요 알고리즘
지도 학습 (감독 학습)	<ul style="list-style-type: none"> 원하는 결과가 표현된 학습데이터를 이용한 기계학습 방법 	(신은마의다지베) 신경망, 은닉 마르코프 모델, 의사결정나무, 다층신경망, 지지벡터 머신, 베지언망, 분류(classification)
비지도 학습 (무감독 학습)	<ul style="list-style-type: none"> 원하는 결과가 표현되지 않은 학습 데이터를 이용한 기계학습 방법 	(K군/계자/주독) 군집화(clustering), K-means, 계층적 군집모델, 자기조직지도, 주성분 분석, 독립성분 분석
강화 학습	<ul style="list-style-type: none"> 잘한 행동에 대해 칭찬받고 잘못된 행동에 대해 벌을 받는 경험을 통해 자신의 지식을 키워나가는 학습법 	(보상과 처벌) 마코프, 마코프 보상, 마코프 디시즌

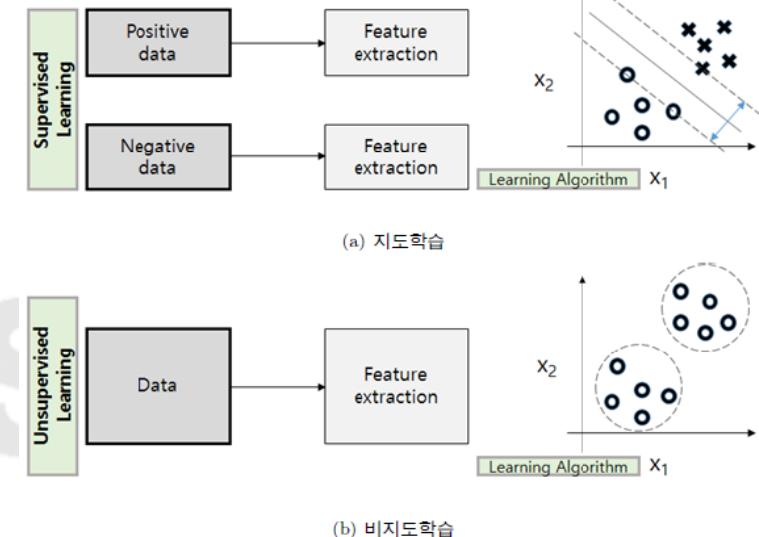
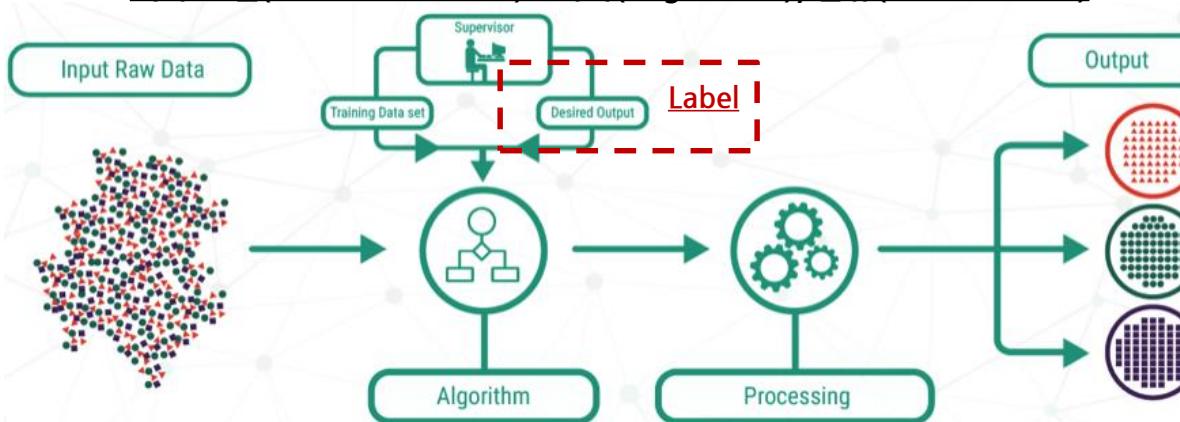
- 학습데이터에서 **label(목표데이터를 지정)이 있는지 없는지 여부에 따라 지도, 비지도 학습으로 구분**
예) 500개의 데이터 = 학습 데이터, 스팸인지 아닌지 여부가 label
- 강화학습은 지도학습으로 분류하기도 하고, 세 번째 모델로 분류**하기도 함



기계학습(Machine Learning) - 지도학습

1. 문제(Training input)와 정답(Training output)을 알려 주고 가르치는 방식, 지도학습의 개요

- 데이터에 대한 레이블(Label)-명시적인 정답-이 주어진 상태에서 컴퓨터를 학습시키는 방법
- 이미 알고 있는 답이 있는 데이터로 알고리즘(모델)을 학습시킨 후, 새로운 데이터를 학습 모델(알고리즘)에 적용시켜 결과값을 예측
- 학습데이터에서 label을 사용
- 과거의 데이터로 미래 이벤트를 예측하는 경우에 주로 사용
- 예측 모델(Predictive model) : 회귀(Regression), 분류(Classification)

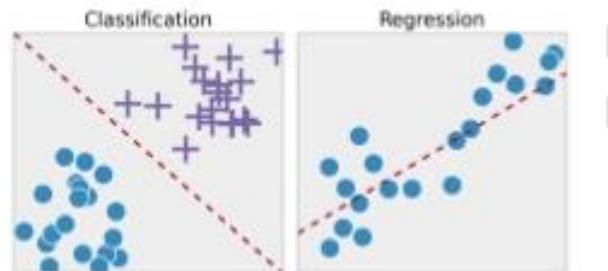


알고리즘	설명
신경망 (Neural Network)	- 사람의 두뇌를 모델로 하여 여러 정보를 처리하는 데 있어서 두뇌와 비슷한 방식으로 처리하기 위한 알고리즘
은닉 마르코프 모델 (HMM)	- 전이확률(transition probability)과 발생확률(emission probability)의 곱으로 이뤄진 모델 - 방향성 그래프, 순차적 데이터 모델링, 확률적 모델, 생성 모델
의사결정트리	- 트리 구조, 데이터 공간의 순차적 분할, 엔트로피기반 정보획득, 규칙으로 변환 가능
다층 신경망(MLP)	- 층구조, 시그모이드 뉴런, 에러 수정, 잡음에 견고, 이산치/연속치 입출력 사상
지지벡터머신(SVM)	- 마진 최대화, 정규화, 예측 성능 우수, 이진 분류, 빠른 학습
베이지안 망	- 방향성 그래프(DAG) 구조, 확률적 모델, 변수간 의존 관계 분석

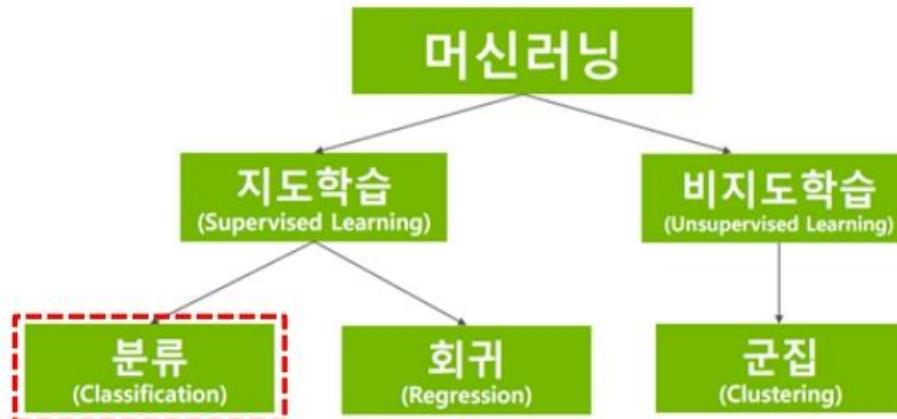
기계학습(Machine Learning) - 지도학습

1. 지도학습의 예측 모델, 분류와 회귀의 개요

구분	설명	주요 알고리즘
분류	<ul style="list-style-type: none">어떤 종류의 값인지 표시주어진 입력 값이 어떤 종류의 값인지 표시y represents a category or 'class'예) 제품의 품질을 자동 검사하여 제품의 합격 또는 불합격을 분류	k-Nearest Neighbors, Bayesian Network, Support Vector Machine
회귀	<ul style="list-style-type: none">지도학습을 통해 유추된 함수를 통해 연속적인 값을 예측하는 것분류를 모형화된 모델로 일반화(generalization)시켜, 시험 데이터로 해당 모델에서 유효한 결과를 얻을 수 있는 것예시) 과거의 실적과 주가에 근거하여 어떤 회사의 주식에 대한 배당 가치를 예측	Linear regression, Lasso



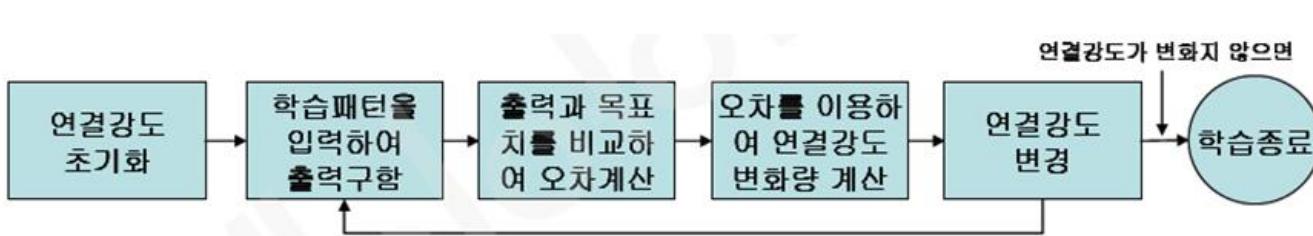
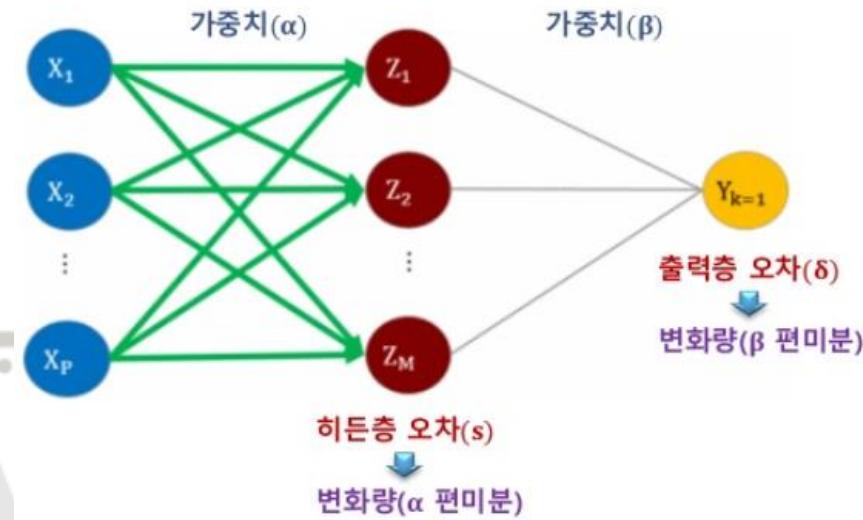
	분류 (Classification)	회귀 (Regression)
결과	학습데이터의 레이블 중 하나를 예측 (discrete)	연속된 값을 예측 (Continuous)
예제	학습데이터가 A, B, C 인 경우 결과는 A, B, C 중 하나다. 예) 스팸메일 필터	결과 값이 어떠한 값도 나올 수 있다. 예) 주가 분석 예측



yching1106@naver.com)

지도학습 인공신경망 학습 절차

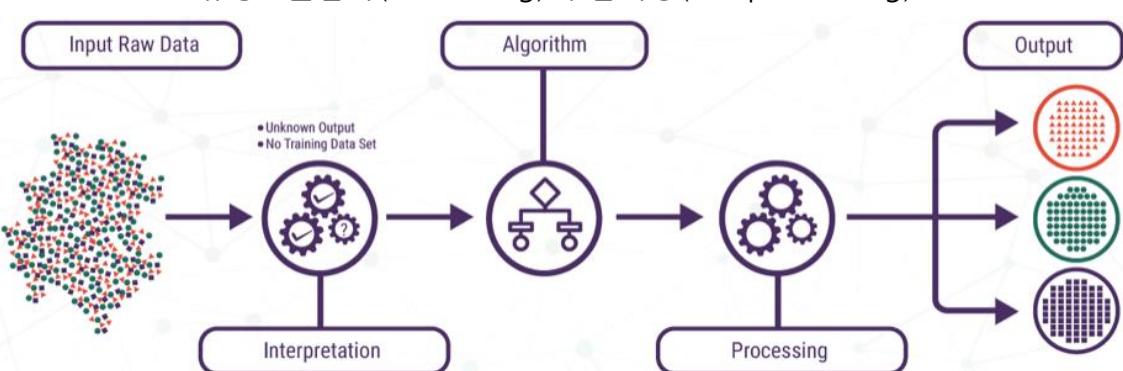
순서	절차
1	응용 목적에 접합한 신경망 구조를 설계
2	연결강도 초기화
3	학습 패턴쌍을 입력하여 신경망의 출력 값 도출
4	출력과 목표치를 비교하여 오차를 계산
5	오차를 학습 신호 발생기에 입력하여 연결 강도의 변화량을 계산
6	연결 강도를 변경
7	변경된 연결 간도에 대하여 단계 3 ~ 6 단계를 반복
8	더 이상 연결 강도가 변하지 않으면 학습 종료 가중치(α) 가중치(β) 출력층 오차(δ) 변화량(β 편미분) 히든층 오차(s) 변화량(α 편미분)



기계학습(Machine Learning) - 비지도학습

1. 문제만 있고 정답이 없는 수많은 임의의 데이터로 학습시키는 방식, 비지도학습의 개요

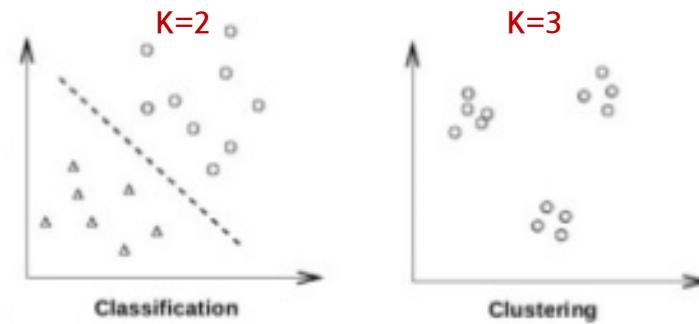
- label이 없는 데이터에서 패턴을 발견하고, 숨겨진 구조를 찾아내는 것
- 학습데이터에서 label을 사용하지 않음**
- no explicit prediction target y
- 유형 : 군집화(Clustering)과 딥러닝(Deep Learning)



알고리즘	설명
군집화(Clustering)	군집화란 밀접하게 관련된 데이터들의 그룹을 찾는 기법으로 데이터 집합을 부분 집합이나 군집으로 분류하는 과정
K-Means	군집별 중심값에서 데이터의 거리를 측정하여 유사 그룹 데이터를 분류하는 군집화 알고리즘
계층적 군집화(HC)	전체 데이터 계층 구조로 분할, 다차원 데이터의 시각화에 유용
자기조직지도(SOM)	총구조 신경망, 격자구조 출력력층, 경쟁학습, 데이터 가시화에 유용
주성분 분석(PCA)	분산이 큰 차원, 특징 추출, 차원 축소
독립성분 분석(ICA)	독립적인 성분으로 분리, Blind Source Separation, 요인분석

▪ 분류와 군집의 비교

	분류(Classification)	군집(Clustering)
공통점	입력된 데이터들이 어떤 형태로 그룹을 형성하는지 관찰	
차이점	레이블이 있다.	레이블이 없다. 예) 의학 임상실험 환자군 구별 예) 구매자 유형 분류





기계학습(Machine Learning) - 강화학습

rewoard

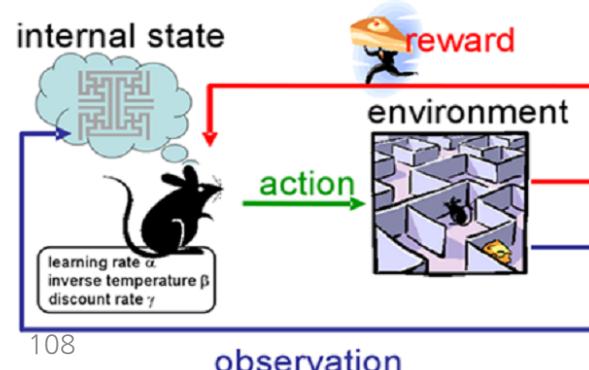
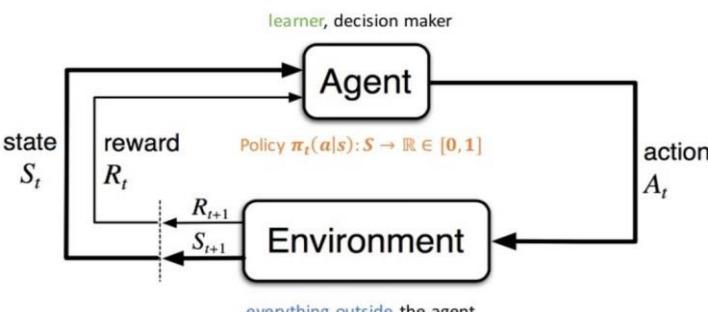
1. Reward를 통한 학습효율성 향상, 강화학습의 개요

- 데이터의 상태(State)을 인식하고 이에 **반응한 행위(Action)**에 대하여 환경으로부터 받는 **포상(Reward)**을 학습하여 행위에 대한 포상을 최적화하는 정책(Model)을 찾는 기계학습
- 정해진 환경 안에서 정의된 에이전트가 현재의 상태를 인식, 선택 가능한 행동 중 보상을 최대화하는 행동 혹은 행동 순서를 선택하는 기계학습 방법 (반복적인 결정 및 착오와 경험에 기반하여 상태의 최적의 행동을 조금씩 학습하는 알고리즘)

특징	설명
순차적 의사결정문제	데이터의 관측 순서가 결과에 영향을 미침
환경과 상호작용	비용 증가에 따라 인프라 증설이 필요한 경우 장비 추가만으로 확장

2. 강화학습의 개념도와 주요 알고리즘

상호 작용을 통해 목표를 달성하는 방법을 배우는 문제

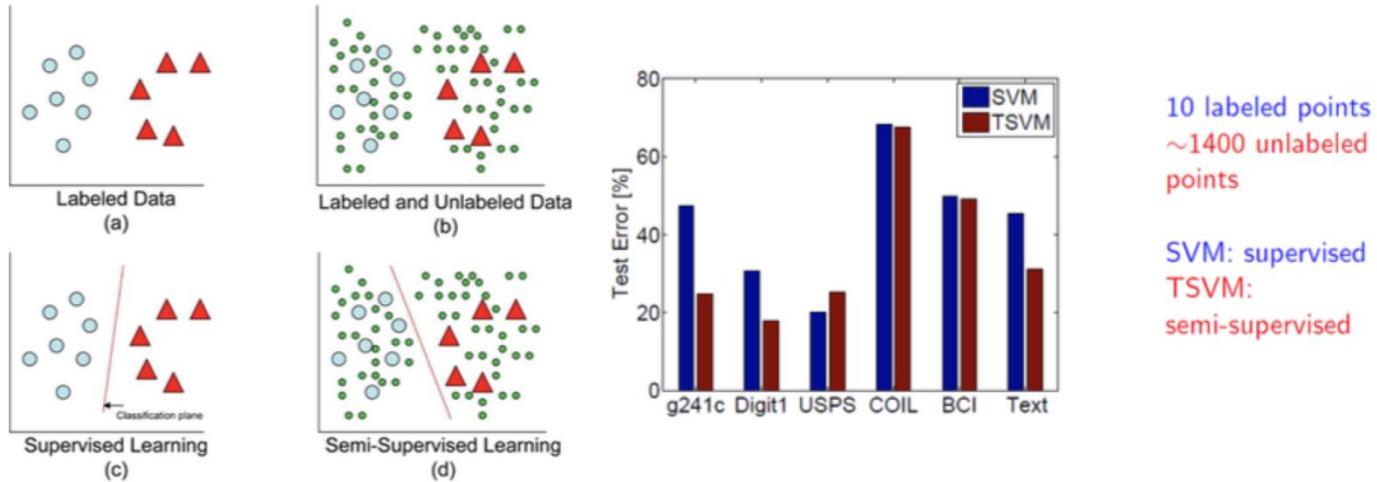


기법	설명
MDP (Markov Decision Process)	<ul style="list-style-type: none"> 강화학습의 수식화를 지원하는 알고리즘 현재 상태에서 가장 최적의 행동을 결정하기 위해 목표까지의 모든 가능한 행동들을 계산하여 가장 높은 값을 가지는 행동을 결정
Markov Chain	<ul style="list-style-type: none"> MDP에서 액션과 상태가 없다고 가정, 상태에서 상태로 천이하는 Matrix 주어질 경우 무한대의 시간이 흐른 후 모두 Sleep 하는것
Q-learning	<ul style="list-style-type: none"> Q 함수는 상태 s에서 액션 a를 수행하고, 이어서 “최적”의 칙에 따라 액션을 수행할 때 미에 예상되는 전체 보상 discounted future reward의 최대 값을 타내는 함수
DQN	<ul style="list-style-type: none"> 구글의 딥마인드가 개발한 딥러닝과 강화학습의 Q 러닝을 조합한 기법 심층 강화 학습을 통해 인간 수준의 제어 가능 자력으로 컴퓨터 게임 공략 방법을 알아낼 수 있음

- Agent 와 환경과의 상호 작용을 통해서 행동을 결정
- 반복적인 결정의 반복으로 최적의 행동으로 개선
- 최적 행동을 통한 Action 결정

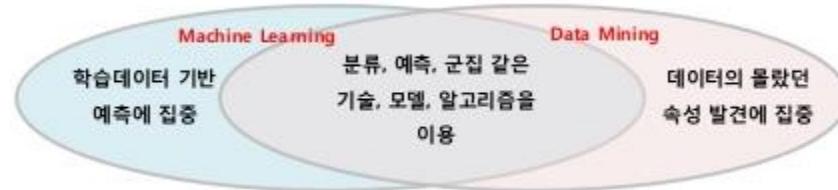
기계학습(Machine Learning) - 준지도학습

- 목표값이 표시된 데이터와 표시되지 않은 데이터를 모두 훈련하는, 준지도 학습(semi-supervised learning)의 개요
 - 레이블이 달려있는 데이터와 레이블이 달려있지 않은 데이터를 동시에 사용해서 더 좋은 모델을 만드는 학습 방법
 - 목표값이 없는 데이터에 적은 양의 목표값을 포함한 데이터를 사용하여 학습을 하는 방법



기계학습(Machine Learning)

Machine Learning Types	Tasks	Analysis methods/Algorithms
지도학습 (Supervised Learning)	예측, 추정 (Prediction, Estimation)	<ul style="list-style-type: none">Linear RegressionRegression Tree, Model TreeSVM(Support Vector Machine)Neural Network, Deep LearningARIMA, Exponential SmoothingDecision TreeLogistic Regression, Discriminant Analysisk-NN(k-Nearest Neighbor), CBR(Case-Based Reasoning)Naïve Bayes ClassificationSVM, Neural NetworkEnsemble (Bagging, Boosting, Random Forest)
	분류 (Classification)	
비지도학습 (Unsupervised Learning)	패턴/구조 발견 (Pattern/Rule)	<ul style="list-style-type: none">Association Rule Analysis, Sequence AnalysisNetwork Analysis, Link Analysis, Graph theoryStructural Equation Modeling, Path Analysis
	그룹화 (Grouping)	<ul style="list-style-type: none">k-Means Clustering, Hierarchical Clustering, Density-based Clustering, Fuzzy ClusteringSOM(Self-Organizing Map)
	차원 축소 (Dimension Reduction)	<ul style="list-style-type: none">PCA(Principal Component Analysis), Factor Analysis, SVD(Singular Value Decomposition)
	영상, 이미지, 문자 (Video, Image, Text, Signal processing)	<ul style="list-style-type: none">Wavelet/Fast Fourier Transformation, DTW(Dynamic Time Warping), SAX(Symbolic Aggregate Approximation), Line/Circular Hough TransformationText mining, Sentiment Analysis



[R 분석과 프로그래밍] <http://rfriend.tistory.com>

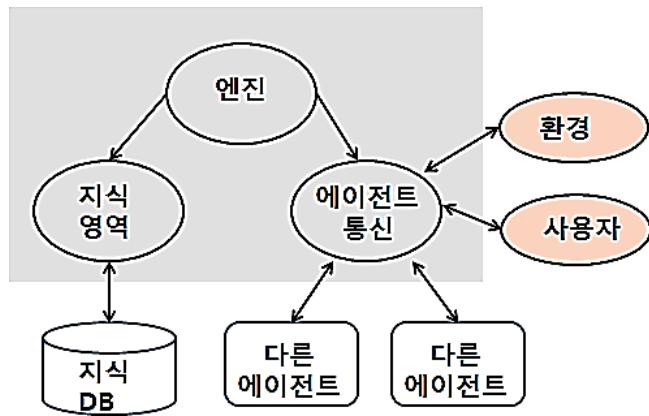
에이전트

구조 유형 구조유형 단순반사, 외부지식기억형, 목표기반, 만족도기반

1. Agent의 개요

- 컴퓨팅 환경에서 사용자 혹은 다른 프로그램을 대신해 특정한 일을 수행하는 **자율적인 프로세스(Autonomous Process)**
- 독자적으로 존재하지 않고 어떤 환경의 일부이거나 그 안에서 동작하는 시스템
- 사용자를 대신해서 사용자가 원하는 **작업을 자동적으로 해결해 주는 소프트웨어**로 독자적으로 존재하지 않고 어떤 환경의 일부 이거나 그 안에서 동작하는 소프트웨어

2. Agent 구성도 및 구성요소



구분	요소기술	설명
엔진	Rule DB	지식을 추론하기 위한 추론 로직을 저장한 저장소
	Interface Engine	센서로부터 들어온 정보를 기반으로 상황을 분석하는 로직
지식 영역	Knowledge map	특정 분야 작업 수행을 위하여 체계화된 지식영역체계
	Ontology	에이전트 S/W가 필요로 하는 지식에 대한 사전

구성요소	설명	핵심기술
Agent Engine	-Agent생성, 작업수행, 종료 등의 작업 조정 -제어기능, 추론능력 등 각각의 환경정보연계	검색엔진 제어 및 정보 제어
지식베이스	-특정 응용 분야 해결에 필요한 지식 저장	응용데이터, 수집정보
통신 모듈	-타 Agent 또는 소프트웨어와 통신, TCP, UDP, WPAN, LPWPAN	TCP/UDP, 무선통신
조정자	다른 에이전트와 통신 및 프로토콜 컨버팅, 연결, 인증, 그룹화, 해제	P2P통신

3. Agent의 특징

특징	설명
자율성	- 외부의 간섭 없이 스스로 활동 및 일련의 작업 수행
지능성	- 새로운 지식을 스스로 터득하는 특성 - knowledge base를 가지고 reasoning 및 planning
사회성	- Agent간의 통신을 통한 정보교환
이동성	- 작업을 실제 처리하는 Host로 이동하여 수행하는 특성
능동성	- 질의나 명령에 응답하는 것이 아니라 필요에 따라 먼저 행동함
반응성	- 다양한 환경을 인지하고 그 안에서 일어나는 변화에 시간상 적절히 반응
시간연속성	- 지속적으로 작업을 수행하는 일종의 데몬(demon)
목표지향성	- 복잡한 고수준의 작업처리를 위해 세부 작업으로 분할, 처리순서의 결정 등을 책임짐



에이전트

4. 에이전트 Software 유형

유형	기술 설명	기술 특징
멀티 에이전트	<ul style="list-style-type: none"> 분산 환경에서 Agent들이 상호 협력하여 업무 수행 및 문제해결 	IOT환경, 분산코디네이션 필요
이동(Mobile) 에이전트	<ul style="list-style-type: none"> 사용자 요구사항 해결을 위해 직접 Target Server를 이동해 가며 작업수행 후 결과만을 사용자에게 전달하는 에이전트 	타 서버로 접근 시 보안 문제 야기 WMS(Web Monitoring Service)에 유용
인터페이스 Agent	<ul style="list-style-type: none"> 학습, 추론, 계획 등의 능력을 가진 에이전트 사용자가 원하는 작업을 찾아 이를 네트워크나 응용 프로그램 안 어디에서든지 실행할 수 있도록 이동 	예를 들어 CMU에서 개발한 WebMate à WWW을 탐색하는 사용자를 도와주는 에이전트
학습 에이전트	<ul style="list-style-type: none"> 사용자가 웹 상에서의 수행하는 행동을 관찰하고 어떤 내용에 관심을 가지고 있는지를 판단하여 사용자에게 알맞은 내용을 전달 	구축된 내용 데이터베이스와 관찰된 사용자 웹 사용 습관을 기초로 데이터 마이닝.
데스크탑 에이전트(desktop agent)	<ul style="list-style-type: none"> PC나 워크스테이션의 운영체제에 상주하면서 국부적으로 실행되는 소프트웨어 에이전트 	운영체제/응용 프로그램 Agent
인터넷 에이전트 (정보 Agent)	<ul style="list-style-type: none"> 인터넷이나 웹에 분산된 다량의 정보를 사용자에게 전달하는 검색 에이전트로서 분산되어 있는 여러 가지 정보를 습득, 관리, 처리 할 수 있는 에이전트 	Web robot, web agent, information agent 가 해당됨
협동 Agent	<ul style="list-style-type: none"> 서로 다른 환경에서 다른 에이전트와 협동하여 작업을 수행하고 다른 에이전트가 필요로 하면 서로 도움을 주는 에이전트 	전자상거래에서 많이 사용(Ex 가격 비교 사이트)
보안 Agent	<ul style="list-style-type: none"> 온도, 습도, 환경, 및 정황을 인지하여 관제소에 전달 기상정보 및 위험, 안전을 감시하고 이를 기반으로 통제 	저전력 기반, P2P통신지원
IoT Agent	<ul style="list-style-type: none"> CPS 및 센서 정보를 수집하고 전송하는 역할 수행 	Sleep, Awake, 목적 정보 전송

4. 에이전트 기술의 장점, 단점

구분	설명
장점	<ul style="list-style-type: none"> 자율성: 프로그래밍을 통한 자율적 정보 수집 지능성: 수집 뿐 아니라 추론 예측 사회성: 에이전트의 통신언어를 이용 사람 또는 다른 에이전트와 통신 이동성: 사용자의 요구를 충족하여 이동하며 수집 네트워크, 모바일
단점	<ul style="list-style-type: none"> 오남용: 개인정보 유출, 스니핑 보안: DDoS 공격 등 악성코드 및 비 인가자의 행위 수행 오작동: 목적외의 수행으로 악의적 피해 발생

5. 구조적 측면의 Agent 유형

유형	속고형 에이전트	반응형 에이전트
구성비교	<pre> graph TD 感知[감지기] --> 感知状态[환경상태인식] 感知状态 --> 行动预期[행동에 대한 결과예상] 行动预期 --> 目标[목적] 目标 --> 推理[추론] 推理 --> 行动[행동] 行动 --> 环境((환경)) 环境 --> 感知 </pre>	<pre> graph TD 感知[감지기] --> 感知状态[환경상태인식] 感知状态 --> 行动决定[행동 결정] 环境((환경)) --> 感知 </pre>
행동결정 방법	기호모델을 바탕으로 한 논리적 추론으로 결정	센서로 감지한 신호를 처리하여 결정
개념	에이전트가 환경에 대한 기호모델 (Symbol)을 명시적으로 내부에 표현/저장하여 이 모델 위에서 논리적 추론을 전개하여 다음 행동을 결정하는 구조	기호모델을 세우지 않고, 환경 변화인 자극신호(Stimulus Signal)에 바로 반응하는 에이전트 구조
행동방식	환경감지, 추론(결과예상)	센서가 감지한 자극 기반
필요자원	빠른 연산처리용 CPU	대용량 메모리
난이도	동적환경 추론 구현 어려움	간단한 함수나 회로로 구현
돌발상황	추론에 의해 대응가능	문제해결 어려움
특징	목적에 부합하는 행동이 없을 경우, 아무런 행동을 취하지 않음	간단한 행동규칙에 따라 현 상황에서 취할 수 있는 가장 최선의 행동을 반드시 수행
장점	추론과 행동학습을 통해 행동결정	환경변화인 자극에 빠르게 반응
단점	끊임없이 변하는 상황에 대한 기호표현이 어렵고, 기호모델을 바탕으로 제한된 시간 내에 효과적인 추론을 해야 함	기호모델이 없고, 추론과정을 사용하지 않음
기준	추론엔진을 통한 확률적 기반	조건데이터에 따른 룰기반
발전	스스로 추론을 통해 학습하고 성장	규칙의 업데이트를 통한 발전

에이전트

6. 프로그램 설계 방법 측면의 Agent 유형

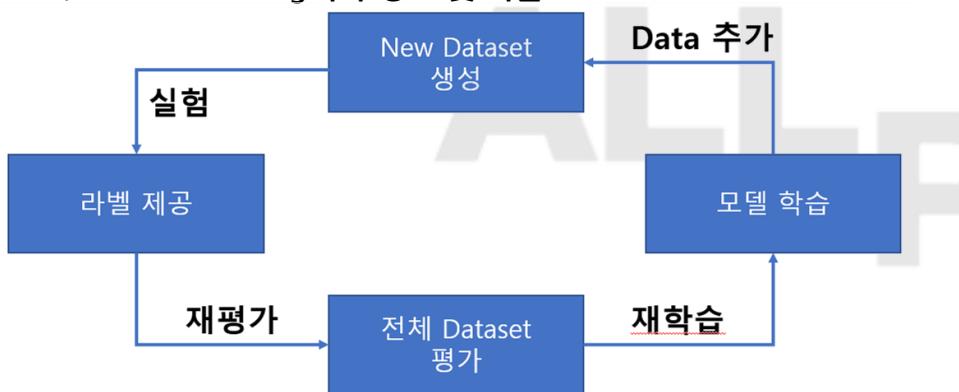
유형	구조	설명
단순반사형 에이전트	<pre> graph TD Sensor[감각기관] --> KB[인지된 외부세계내용] KB --- RuleBase[조건부-결론부 관계규칙] RuleBase --> RuleInterp[수행해야 할 일] RuleInterp --> Actuator[작동기] Actuator --> Environment((환경)) </pre>	<ul style="list-style-type: none"> Simple Reflex Agent 자신의 지식베이스에 인지된 상태와 정확히 일치하는 반응만을 수행 내부 기억이나 상태정보를 소유하고 있지 않으므로 이전의 Percept는 현재 행동에 영향을 주지 않음
외부지식 기억형 에이전트	<pre> graph TD Sensor[감각기관] --> KB[인지된 외부세계내용] State[상태
환경변화내용
자신이 하는 일] --> KB KB --- RuleBase[조건부-결론부 관계규칙] RuleBase --> RuleInterp[수행해야 할 일] RuleInterp --> Actuator[작동기] Actuator --> Environment((환경)) </pre>	<ul style="list-style-type: none"> Agent That Keep track of the world Condition-Rule을 내부에 가지고 있으며, 환경으로부터 받은 정보를 인지하여 정해진 Rule에 따라 반응하고, 그 상태값을 저장하고 유지하는 에이전트
목표기반 에이전트	<pre> graph TD Sensor[감각기관] --> KB[인지된 외부세계내용] Goal[상태
환경변화내용
자신이 하는 일] --> KB KB --- RuleBase[조건부-결론부 관계규칙] RuleBase --> Plan[수행해야 할 일 분석] Plan --> RuleInterp[수행해야 할 일] RuleInterp --> Actuator[작동기] Actuator --> Environment((환경)) </pre>	<ul style="list-style-type: none"> Goal based Agent 내부 상태와 목적(Goal)이라는 정보를 가지며, 그 목적을 이루기 위해 서행동의 일렬(Action Sequence)을 찾고 계획하는 에이전트
만족도기반 에이전트	<pre> graph TD Sensor[감각기관] --> KB[인지된 외부세계내용] Utility[Utility] --> KB Goal[상태
환경변화내용
자신이 하는 일] --> UEval[만족도 평가] KB --- RuleBase[조건부-결론부 관계규칙] RuleBase --> UEval UEval --> RuleInterp[수행해야 할 일] RuleInterp --> Actuator[작동기] Actuator --> Environment((환경)) </pre>	<ul style="list-style-type: none"> Utility based Agent 같은 목적을 이루기 위해 다른 행동과정 존재 시, 그들간의 상호 유용성(Utility)을 비교함으로써 효율적으로 목적에 도달할 수 있도록 구성

액티브 러닝(Active Learning)

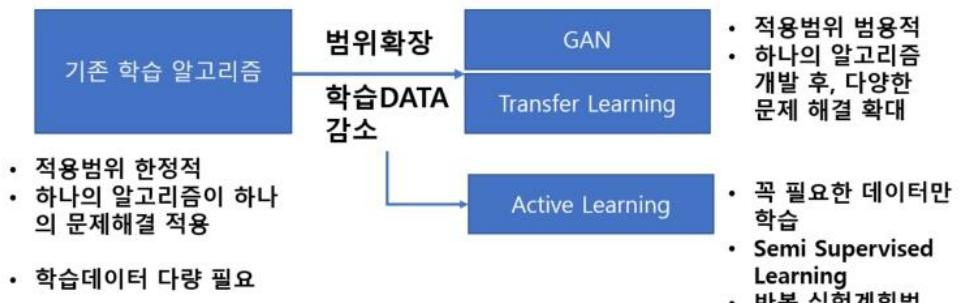
1. 반복적 지도학습, Active Learning의 개요

- 학습데이터에 레이블이 부여된 경우가 소수인 경우에 예측 성능을 높이기 위해 **불확실성이 큰 데이터부터 반복적으로 라벨링하여 학습하는 방법론**
- 레이블이 없는 관측치에 대해 단순히 레이블을 붙이는 것이 아닌 데이터를 분류 혹은 예측 하는데 있어서 가장 비용이 적고 효과가 큰 관측치를 선택하는 방법 / 반복적인 지도학습을 통해 라벨링 비용을 최소화하며, 모델의 성능을 높이기 위한 방법으로 활용
- 라벨링된 데이터가 많지 않은 상황에서 데이터의 일부만 학습시킨 후, 이를 이용해 나머지 데이터를 라벨링하도록 하는 오토 라벨링, 자동 데이터 전처리 기법**

2. Active Learning의 구성도 및 기술요소



[참고자료]



Incremental Supervised Learning, Active Learning

구분	기술요소	설명
알고리즘	-Oracle -Expert	-해당 관측치의 레이블을 정확하게 알고있는 시스템 -분석자 본인이나 해당분야의 전문적인 지식 전문가 -계측기와 같은 기기
학습데이터	-라벨 데이터 -Semi Supervised Learning	-예측 불확실성이 큰 관측치 -label을 확인하는 작업이 비싼 비용을 요구하는 데이터
모델 평가	-Precision -Accuracy	-학습 정확도를 향상시키기 위한 Classification 외 Regression 문제에 적용 가능



전이학습(Transfer Learning)

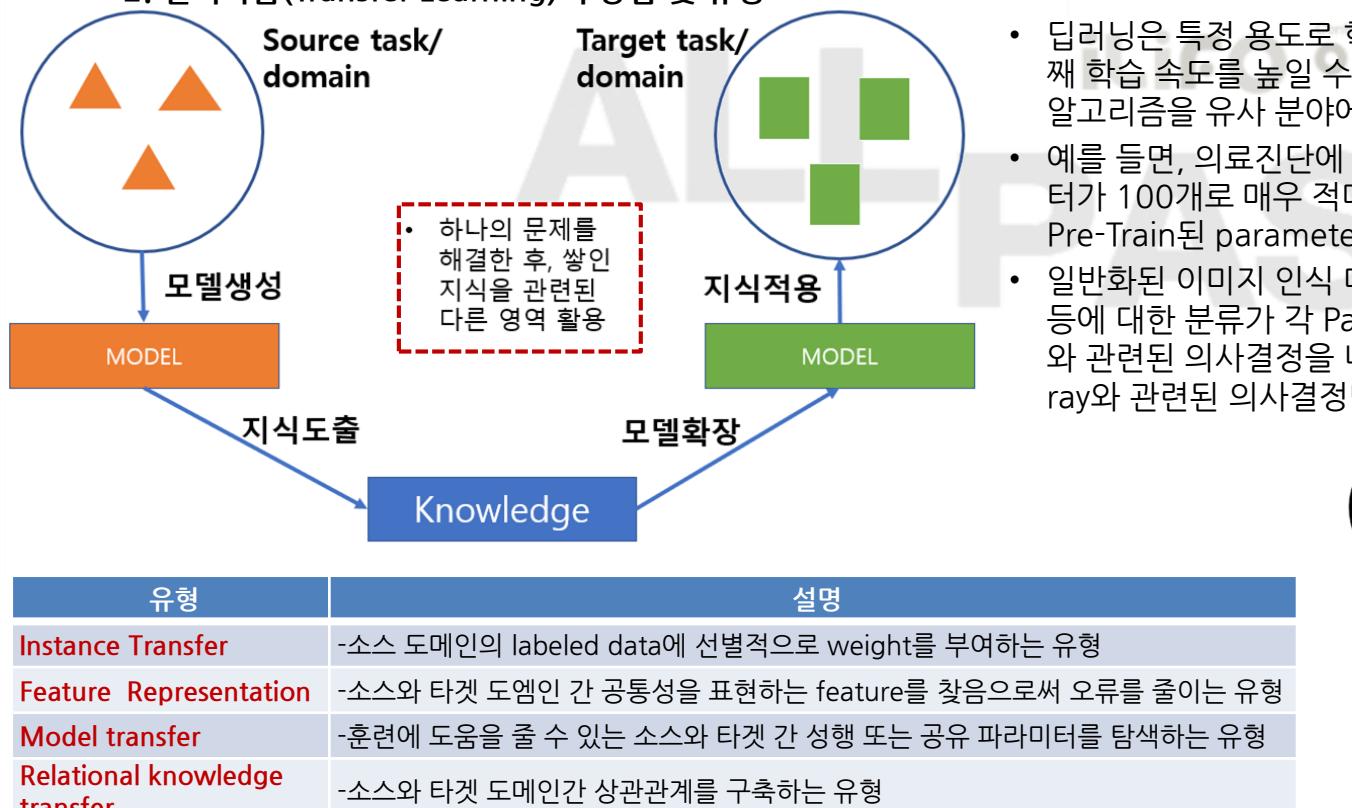
[필요성]

- 데이터 부족 해소
- 학습 시간 단축
- 학습 치 재사용

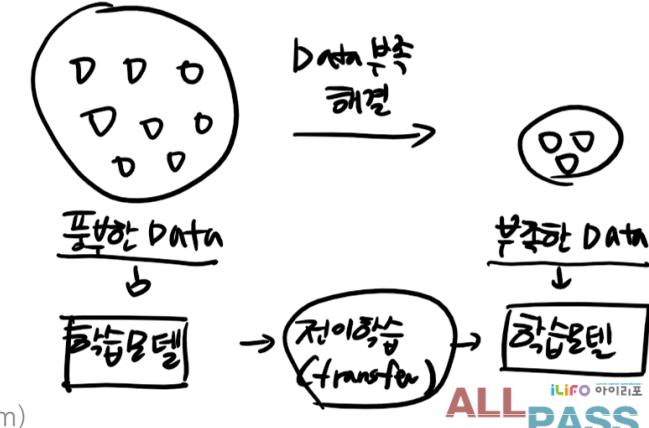
1. 지식의 전이와 활용, 전이학습(Transfer Learning)의 개요

- 특정 환경에서 만들어진 인공지능 알고리즘을 다른 비슷한 분야에 적용하는 방법으로 데이터가 부족한 분야에서 활용되는 머신러닝 기술 (하나의 데이터에서 얻을 수 있는 지식을 다른 데이터에 적용)
- 학습 데이터가 부족한 분야의 모델 구축을 위해 데이터가 풍부한 분야에서 훈련된 모델을 재사용하는 머신러닝 학습 기법
- 일반적으로 머신러닝에서는 Target 영역의 Labeled Data를 대량으로 구하기가 쉽지 않기 때문에 웹 상에서 수집된 Unlabeled 데이터를 기반으로 학습을 시키고 Target영역의 특징을 은닉층에 추가로 적용하여 효과적인 모델을 개발 가능

2. 전이학습(Transfer Learning)의 방법 및 유형



- 딥러닝은 특정 용도로 학습된 내용을 다른 목적에서 사용하면 두 번째 학습 속도를 높일 수 있어 데이터 셋이 부족한 경우 이미 만들어진 알고리즘을 유사 분야에 적용
- 예를 들면, 의료진단에 필요한 X-ray 이미지를 분류하고 싶은데 데이터가 100개로 매우 적다면 대체제로 엄청 많은 데이터를 기준으로 Pre-Train된 parameter를 활용해 최종적으로 다시 학습하는 과정.
- 일반화된 이미지 인식 데이터를 기준으로 모델을 학습. 색깔, 물체 등에 대한 분류가 각 Parameter에 저장되고 마지막에 X-ray 이미지와 관련된 의사결정을 내리는 Layer만 추가하여 해당 Layer에서 X-ray와 관련된 의사결정만 학습하는 방법



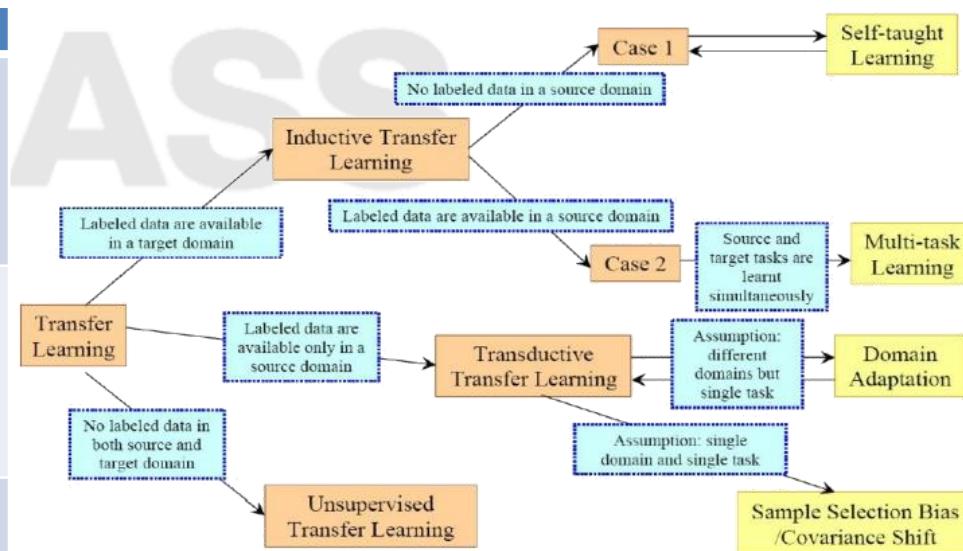
전이학습(Transfer Learning)

4. 전이학습이 필요한 데이터 셋의 상황에 따른 전이학습의 분류

Transfer Learning Setting	Related Area	Source Domain Labeled	Target Domain Labeled	Task
Inductive	Multi-Task Learning	Available	Available	Regression, Classification
	Self-taught Learning	Unavailable	Available	Regression, Classification
transductive	Domain Adaptation, Sample Selection Bias, Covariance Shift	Available	Unavailable	Regression, Classification
Unsupervised	-	Unavailable	Unavailable	Clustering, Dimensionality Reduction

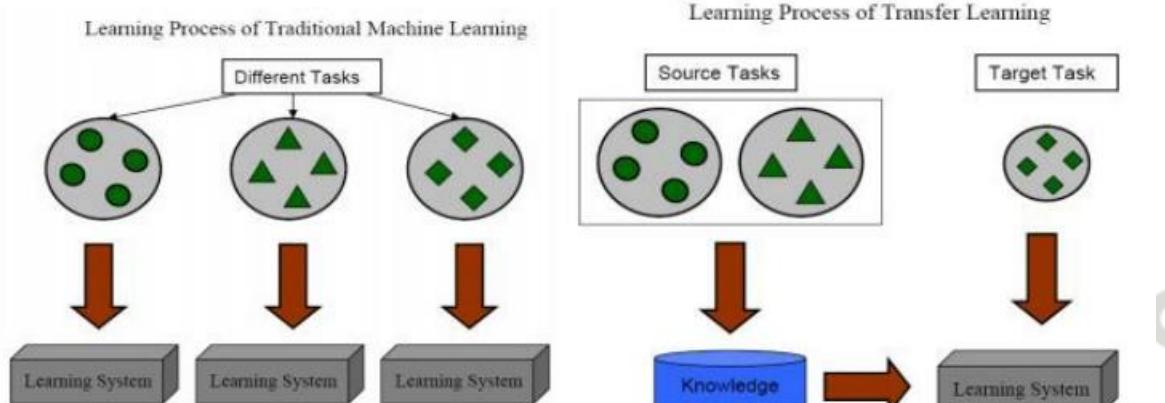
4. 전이학습의 주요 알고리즘

주요 알고리즘	설명
Self-taught Learning	<ul style="list-style-type: none"> 전체 데이터 셋에서 Labeled 된 데이터가 일부만 존재하고 Labeled와 Unlabeled의 분포가 다를 경우 Unlabeled 데이터 셋으로부터 생성된 학습 Parameter를 사용하여 원본 데이터를 Labeled 데이터로 변환, feature를 만든 후 Linear classifier로 학습 시키는 방법
Multi-Task Learning	<ul style="list-style-type: none"> 하나의 Training Set을 가지고 동시에 여러 가지 분류문제를 처리하는 알고리즘 단일 모델 또는 전체 모델을 학습하여 성능이 더 이상 향상되지 않을 때까지 미세 조정하고 관련 작업들 간의 표현을 공유하여 일반화된 모델을 만든 후 특화 Layer로 분리하는 방법
Domain Adaptation	<ul style="list-style-type: none"> Label predictor 역할은 잘 하도록 유지하되 sample의 feature representation이 source domain에서 왔는지 target domain에서 왔는지를 구별 못하게 domain discriminator를 약화하는 방향으로 학습시키는 방법



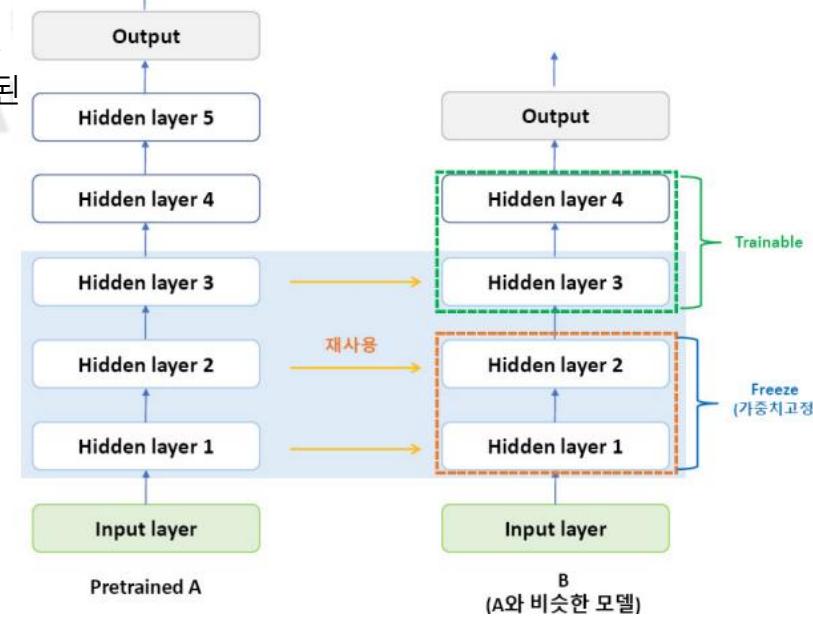
전이학습(Transfer Learning)

5. 전통적인 기계학습과 전이학습과의 비교



Contents connect communications!
아이리포

- 전통적인 기계학습은 원하는 결과를 얻기 위해 별도 모델을 각각 개발하였으나 전이학습을 통해 풍부한 데이터 셋으로부터 공통적인 특징을 얻고 특성이 반영된 Layer를 추가하여 효율적이고 좋은 성능의 모델 개발 가능

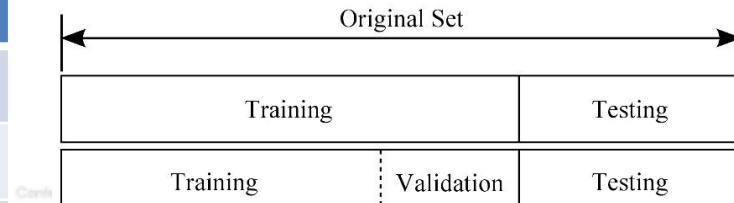


학습 데이터, 테스트 데이터, 검증 데이터

1. 기계학습에서 사용되는 데이터의 유형

- 실제 데이터 특성이 잘 반영되어 있고, 편향되지 않은 학습데이터를 확보하는 것이 중요
- 학습데이터와 입력데이터가 달라져도 성능차이가 나지 않는 것을 일반화(Generation)이라고 하고 이것이 머신러닝 성공의 척도

구분	설명
학습 데이터(training data)	<ul style="list-style-type: none"> 분류기(classifier)를 학습하는데 사용하는 데이터 집합 학습 데이터가 많을 수록 유리
테스트 데이터(test data)	<ul style="list-style-type: none"> 학습된 모델의 성능을 평가하는데 사용하는 데이터 집합 학습에 사용되지 않은 데이터이어야 함
검증 데이터(validation data)	<ul style="list-style-type: none"> 학습 과정에서 학습을 중단할 시점을 결정하기 위해 사용하는 데이터 집합



2. 훈련용과 시험용 데이터의 분할 방법

구분	설명
예비법 (holdout method)	<ul style="list-style-type: none"> 전체 데이터를 서로 겹치지 않는 두 데이터 집합으로 비복원 추출 예: 50% 훈련용, 50% 시험용 예비법의 r회 반복실시 (자동화 도구 사용)
교차타당성 (cross validation) 방법	<ul style="list-style-type: none"> 예비법에서 훈련용과 시험용의 역할을 교차로 함 (예비법의 변형) K-fold 교차 타당성 방법 (데이터를 k개로 분할하여, 1/k에 해당되는 데이터 셋을 시험용으로 하고 나머지는 훈련용으로 사용하는 방식을 K 번 수행)
검증 데이터 (validation data)	<ul style="list-style-type: none"> 훈련용 데이터를 복원추출(데이터 수만큼) 전체 데이터의 수가 N 일때 봇스트랩 방법으로 N 개 추출하면, 63.2 % 정도가 훈련용으로 추출됨. (겹치는 것은 하나로 간주) 각 데이터가 봇스트랩 표본으로 추출될 확률 = $1 - (1 - 1/N)^N$ 예비법의 r회 반복실시



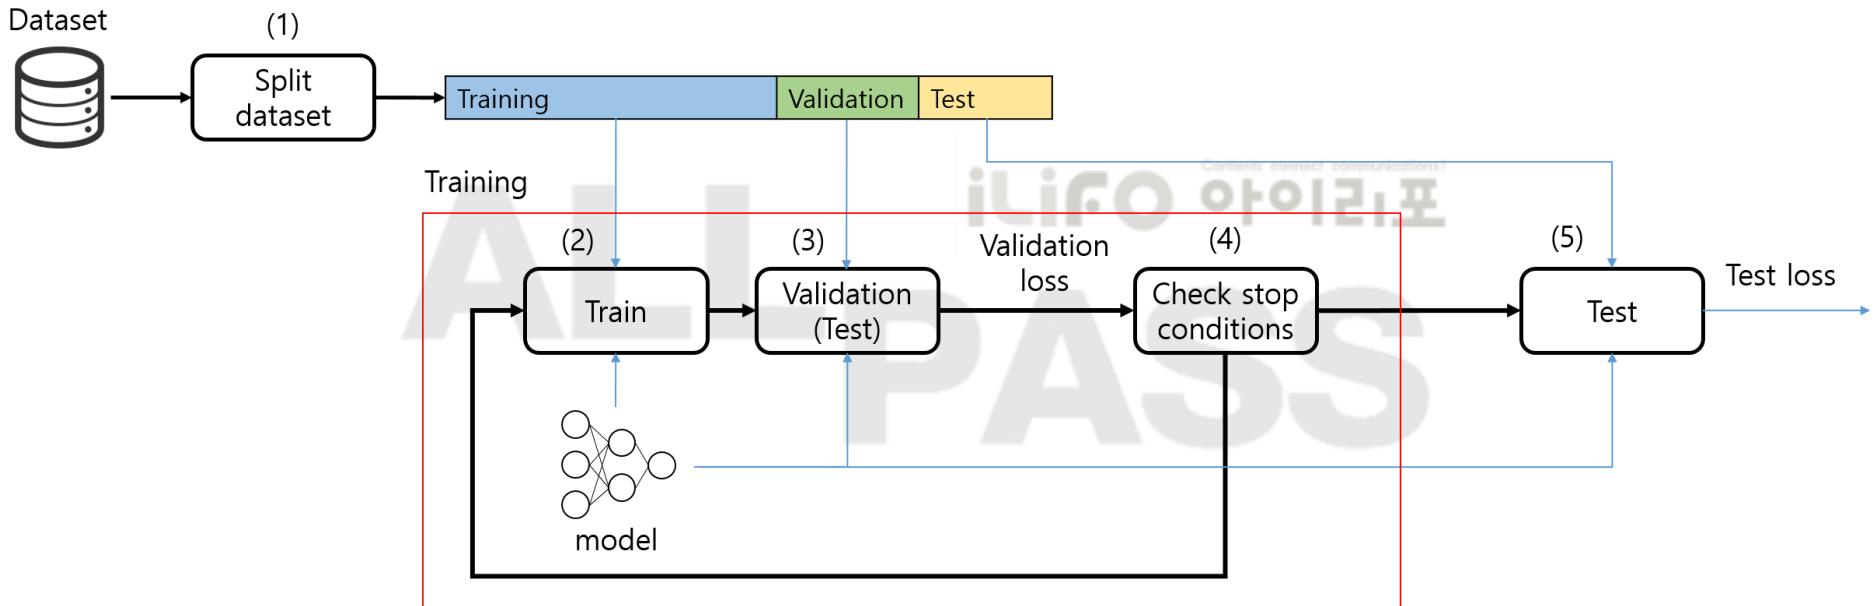
	Training dataset	Validation dataset	Test dataset
학습 과정에서 참조할 수 있는가?	O	O	X
모델의 인자값 (가중치) 설정에 이용되는가?	O	X	X
모델의 성능 평가에 이용되는가?	X	O	O

Validation Dataset

1. Validation Dataset의 개요

- training dataset에서 추출된 가상의 dataset (overfitting을 해결하기 위해 별도로 만들어진 dataset이 아님)

2. validation dataset을 이용한 머신 러닝 모델의 학습 과정



- Step (1): 주어진 dataset을 training, validation, test dataset들로 나눈다. 일반적으로 각 dataset의 비율은 60:20:20으로 설정 한다.
- Step (2): Training dataset을 이용하여 모델을 학습시킨다.
- Step (3): Validation dataset을 이용하여 모델의 정확도 및 validation dataset에 대한 loss를 계산한다.
- Step (4): 만약 validation loss가 증가했다면 학습을 종료한다. 그렇지 않을 경우에는 (2)로 돌아가서 학습을 계속 진행한다.
- Step (5): Test dataset을 이용하여 모델의 최종 정확도를 평가한다.

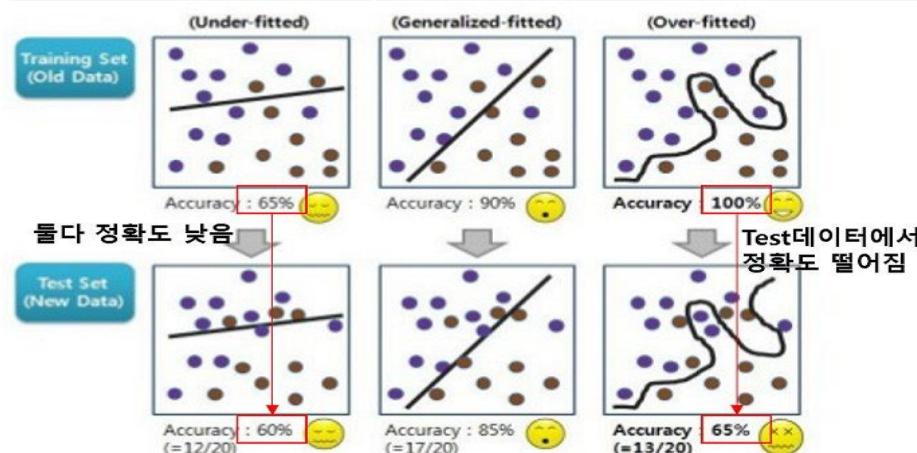


과적합(overfitting), 부적합(underfitting)

1. 편향-분산 딜레마(Bias-Variance Dilemma), 과적합과 과소적합



구분	정의	특징
오버피팅 (Overfitting)	<ul style="list-style-type: none"> 샘플 데이터에 너무 정확하게 학습되어 샘플데이터에는 정확도가 높지만 다른 데이터에서는 정확도가 떨어지는 현상 저편향, 고분산(고특성) 	High Variance Low Bias Model
언더피팅 (Underfitting)	<ul style="list-style-type: none"> 샘플데이터가 모자라거나 제대로 학습이 되지 않아 학습데이터에 대해서도 정확한 결과를 도출하지 못하는 현상(학습부족) 고편향, 저분산(저특성) 	High Bias Model Low Variance Model
적합(nomalfitting or bestfit)	<ul style="list-style-type: none"> 적정 수준의 학습으로 실제 적정한 일반화 수준 	기계학습 지향



- ✓ 조기 종료(early stopping) : 정확도가 떨어지는 순간 학습 종료
- ✓ 가중치 감소
- ✓ 드롭아웃

- 가중치 감소(weight decay) : 학습 과정에서 큰 가중치에 대해서 큰 페널티를 부과하여 과적합을 예방하는 기법,
모든 가중치의 각각 손실 함수에 $\frac{1}{2}\lambda W^2$

λ : 정규화의 세기를 조절하는 하이퍼 파라미터

과적합(overfitting), 부적합(underfitting) 해결 기법

2. 과적합(Overfitting) 해결 방법

구분	설명	
판별	<ul style="list-style-type: none">- 학습 시의 에러가 기대하는 에러율보다 낮게 나타나는 경우- 실제 테스트 에러가 기대하는 에러율보다 높게 나타나는 경우	
극복 방안	① 학습 데이터	<ul style="list-style-type: none">• 충분히 많은 학습 데이터• 모델의 형태를 최대한 간단하게 만드는 수치해석적 기법• 모델의 성능을 약간 희생하더라도 모델을 최대한 간단하게 만들어 과적합에 빠지지 않도록 하는 기법• k-fold와 같은 교차 검증(cross validation) 기술 활용 (데이터 분리에서 오는 실수를 줄이고, 다양한 데이터 학습)• 분산이 높아서 복잡해진 머신러닝 모델에는 분산을 낮추고 편향을 높임으로써 단순화• 대표 : Ridge, LASSO, Elastic Net
	② 정규화 또는 정칙화 (Regularization)	<ul style="list-style-type: none">• 모델의 형태를 최대한 간단하게 만드는 수치해석적 기법• 모델의 성능을 약간 희생하더라도 모델을 최대한 간단하게 만들어 과적합에 빠지지 않도록 하는 기법• k-fold와 같은 교차 검증(cross validation) 기술 활용 (데이터 분리에서 오는 실수를 줄이고, 다양한 데이터 학습)• 분산이 높아서 복잡해진 머신러닝 모델에는 분산을 낮추고 편향을 높임으로써 단순화• 대표 : Ridge, LASSO, Elastic Net
	③ 조기 종료 (Early Stopping)	<ul style="list-style-type: none">• 과도하게 많은 에폭이 발생하는 경우 과도하게 주어진 훈련용 데이터만을 학습해 오버피팅 가능• 검증단계에서 검증 데이터를 통해 검증 정확도에 큰 변화가 없을 때 반복 학습 종료
	④ 드롭아웃	<ul style="list-style-type: none">• 학습 시 히든레이어의 몇 개의 노드는 랜덤하게 사용안함• 랜덤하게 노드를 선택하여 학습하고 양상을 효과 활용
	검증(validation)	<ul style="list-style-type: none">• 학습과정에서 과적합 여부 판단• 학습 데이터의 일부를 학습에 사용하지 않고 모델의 성능 검증용으로 사용하는 기법• 학습데이터에 대한 모델의 오차로는 과적합 여부를 판단하기 어렵기 때문에 일부 학습 데이터를 사용해 과적합 검증• 검증 데이터에 대한 오류가 감소하다가 증가하는 시점에 학습 중단• 대표 : 교차 검증 (Cross Validation)

3. 부적합(Underfitting) 해결기법

구분	설명	
판별	<ul style="list-style-type: none">- 학습 시의 에러가 기대하는 에러율보다 높게 나타나는 경우- 학습 에러가 높은 만큼 테스트 에러 높게 나타나는 경우	
극복 방안	① 다양한 특성 고려	<ul style="list-style-type: none">• 모델의 편향을 줄이고 학습 시 특성(분산)을 많게 하여 더 구별할 수 있는 특성들을 모델에게 학습
	② 머신러닝 모델 변형	<ul style="list-style-type: none">• 머신러닝 모델을 상대적으로 편향이 적고 분산이 높은 머신러닝 모델로 변경(의사결정나무, k-NN, SVM)• 고편향 모델: 선형회귀, 로지스틱 회귀

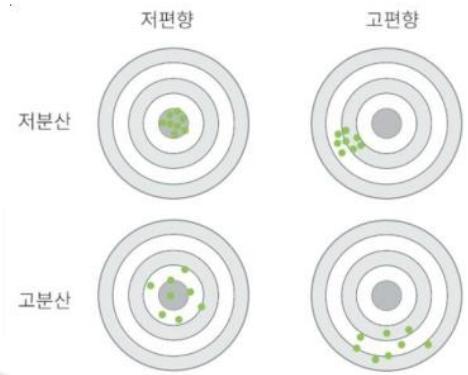
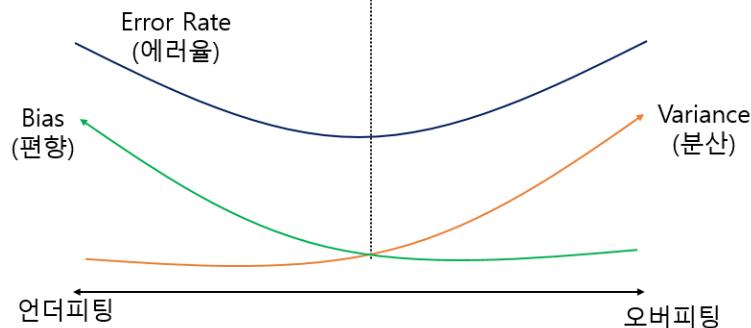
- 별도로 테스트 데이터를 확보하면 비효율적
- 가능하면 많은 데이터를 학습에 사용하면서, 성능 평가하는 방법 필요

과적합(overfitting), 부적합(underfitting) 해결 기법

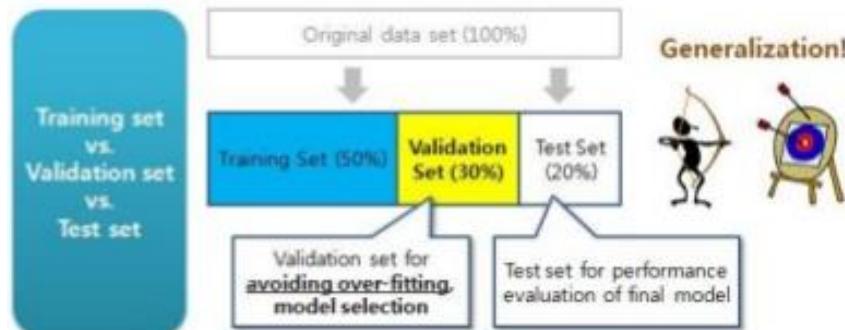
4. 적정 수준의 학습을 통한 적정적합(Generalized-fitted) 모델

- 에러율을 가장 낮출 수 있도록 최대의 효과를 얻을 수 있는 적정 포인트를 갖는 적정 적합 모델 도출 필요

적정 포인트



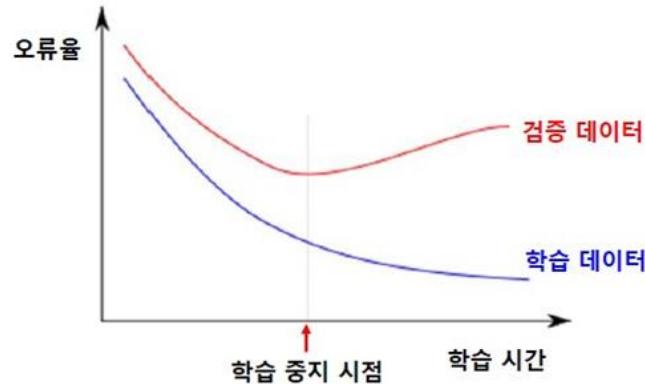
- Validation Set을 통한 모델에 대한 성능 평가 수행



▪ 교차검증(Cross-validation)

- Leave-One-Out CV (LOOCV) : 첫 번째 값을 제외하고 training set 적용
- Leave-p-Out CV (LpOCV)
- k-fold CV (KFCV) : 전체 데이터를 k등분 후, 각 등분을 한번씩 테스트 (평균값 이용)
- Repeated Learning-Testing (RLT) : 랜덤하게 validation과 training set 분리 후 테스트(평균값 이용)

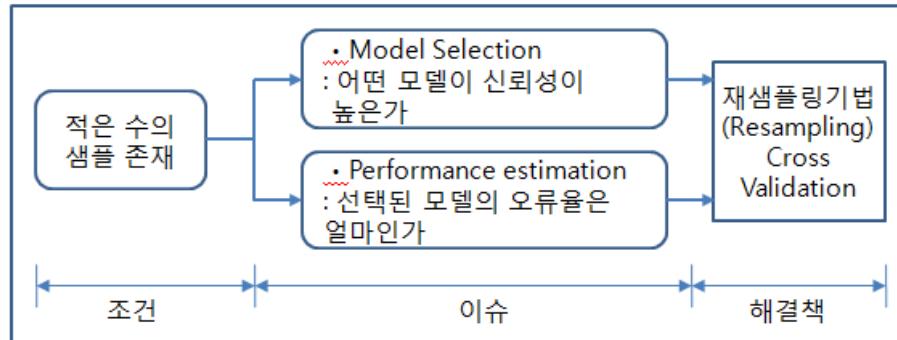
- Validation Set을 통한 모델에 대한 성능 평가 수행





cross-validation

1. Machine Learning 중 지도학습(Supervised learning) 모델의 검증 현안



- 데이터Set의 질적, 양적 품질은 데이터 모델의 성능을 좌우함
- 데이터의 수집에 많은 비용 문제로 대부분 데이터의 양이 부족한 현실에서, 재 샘플링 기법을 사용하면 성능 측정의 신뢰도를 높일 수 있음.
- 대표적인 재 샘플링 기법으로 Cross-Validation, Bootstrap 기법이 있음

iLIFO Contents connect communications!
아이리포

2. 적은 샘플을 이용한 Machine learning 모델 타당성 평가 기법, 교차 검증의 개요

- 모델의 Overfitting 문제를 방지하기 위하여 Data set을 Training set과 Test set으로 분리하여 훈련과 테스트를 반복하는 기법

3. Data Set의 구분

데이터 Set	설명	활용
Training Set	모형을 적합화시키기 위해 사용되는 데이터	모델 학습
Test Set	최종 선택모형이 새로운 데이터에 대하여 좋은 성과를 갖는지 평가	모델 평가
Validation Set	모형이 얼마나 잘 적합화 되었는지 평가 일부 모형을 조정하여 구축된 모형 중 좋은 모형 선택	모델 선택

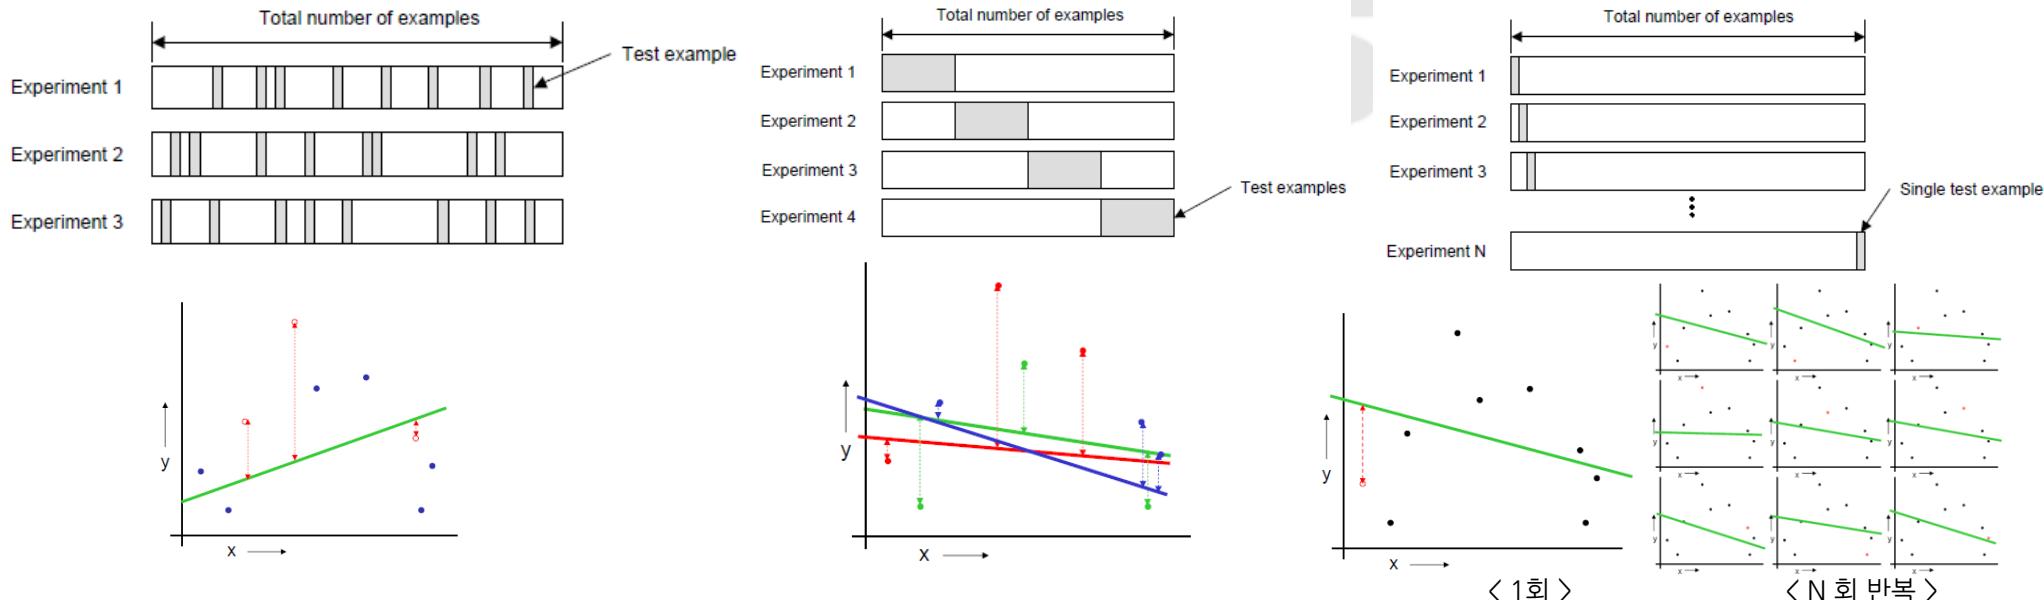
4. 교차 검증 (Cross Validation) 방법

데이터 Set	설명	에러율
Random Subsampling	<ul style="list-style-type: none"> S를 랜덤하게 k개의 training set과 test set으로 나눔. S_train은 약 70%로 구성하며, 모델 학습 용으로 쓰고 나머지 S_cv는 평가용으로 사용 	$E = \frac{1}{K} \sum_{i=1}^K E_i$
k-fold cross validation	<ul style="list-style-type: none"> Training Set S을 k개의 부분 집합으로 등분, k-1개로 학습하고 나머지 한 개로 테스트 	$E = \frac{1}{K} \sum_{i=1}^K E_i$
Leave-one-out cross validation	<ul style="list-style-type: none"> k fold cross validation에서, k=N인 경우(N은 샘플 개수) 하나 남기기(Leave-one-out) 또는 잭 나이프(Jackknife) 기법 데이터 1개씩을 빼가면서 모든 테스트를 하는 방법. 	$E = \frac{1}{N} \sum_{i=1}^N E_i$

cross-validation

4. 검증 방법의 비교

항목	Train-validation	Cross-Validation	Bootstrap
개념	훈련집합, 테스트 집합, 검증 집합을 통해서 모델의 정확도를 검증	데이터를 k개의 집합으로 나누어 검증한 결과의 평균치로 모델 검증	전체 데이터에서 무작위 복원 추출로 훈련집합 생성 하여 검증하는 방법
활용기준	데이터가 충분히 많은 경우	데이터가 충분하지 않은 경우	데이터가 충분하지 않은 경우, 모집단 분포 가정 어려운 경우
데이터set	Train Set, Test Set, Validation Set	K개의 Set 분류(k-fold) k-1 : Train set 1 : Test set	N개의 Bootstrap sample
정확도	에러율 예측의 정확도 다소 낮음	Train-validation 보다 높은 정확도	Train-validation 보다 높은 정확도
특징	데이터 set의 분리 비율이 결과에 영향 미침	분류의 수에 따라 결과 영향 미침	모집단의 분포의 가정 없이 검증 가능

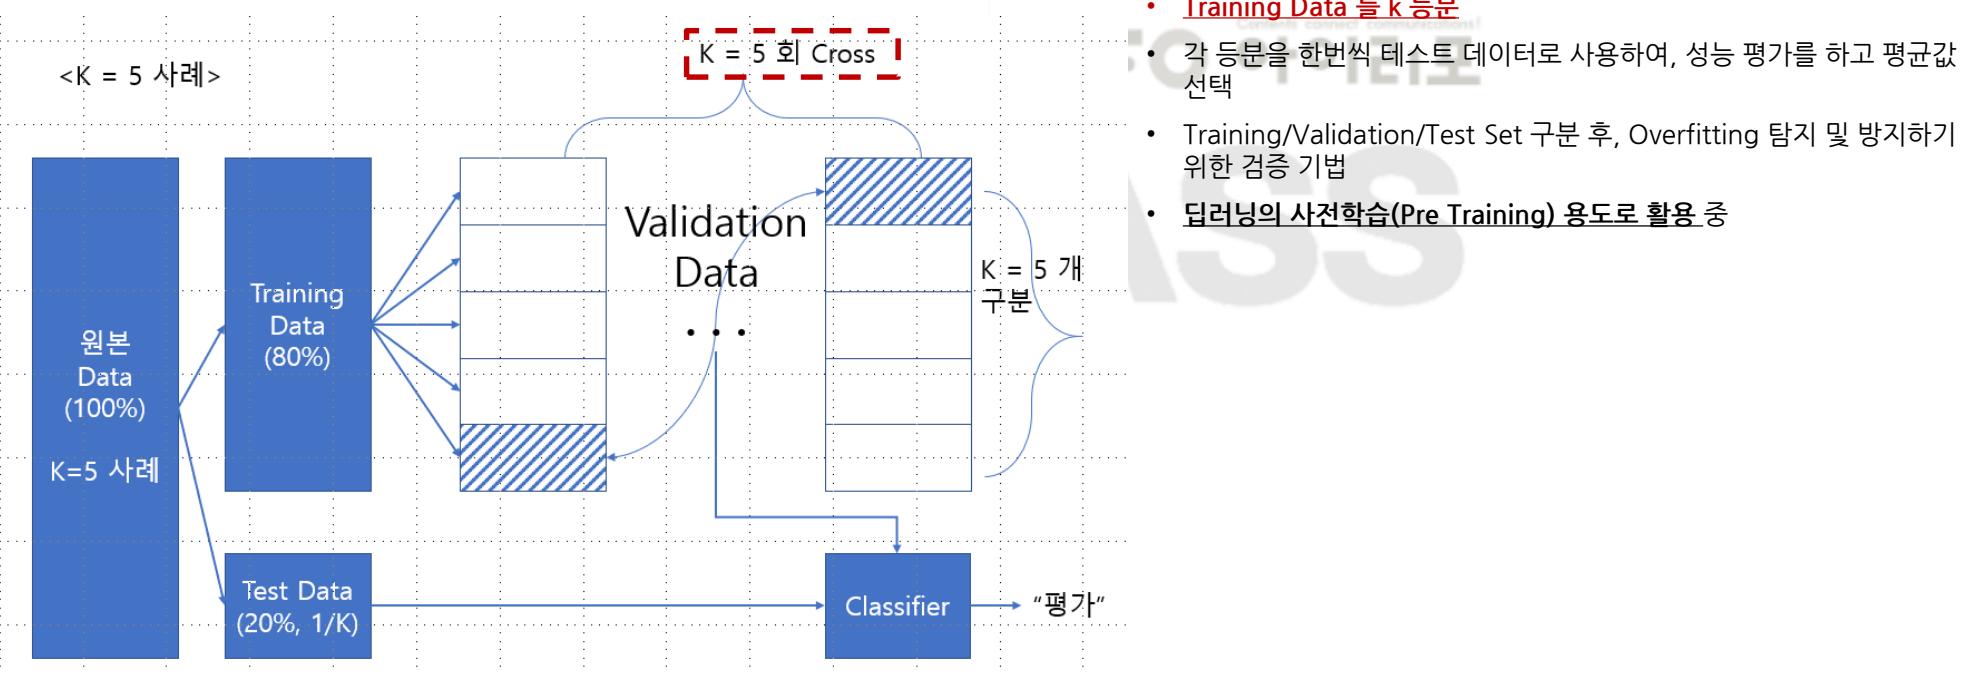


K-겹 교차검증(k-fold cross-validation)

1. K-겹 교차검증(k-fold cross-validation)의 개요

- 평균성능(Mean Performance)과 성능분산(Performance Variance)을 구하기 위하여 Training set 과 Test set을 교차하여 이용하는 Cross Validation의 계산속도향상과 Overfitting 방지를 위한 기법
- 필요성 : Training/Validation/Test Set 구분 후, Overfitting 탐지 및 방지하기 위한 검증
- 특징 : k값이 작아질수록 평가성능의 변동이 있지만, 계산속도가 빠르고, Overfitting 의 가능성을 줄이기 때문에 널리 사용됨

2. 사례로 보는 K-겹 교차검증(k-fold cross-validation)의 개념도 (K=5)



규제화 (Regularization)

과적합 해결 | 접근법

- 딥러닝시 에러를 일으키는 요인을 줄이는 일련의 모든 해결방안, 규제화 (Regularization)의 개요
 - 모델의 성능을 약간 희생하더라도 모델을 최대한 간단하게 만들어 **과적합에 빠지지 않도록** 하는 기법
 - 딥러닝시 에러를 일으키는 요인을 줄이는 일련의 모든 해결방안.

2. 규제화의 필요성

- 딥러닝에서 학습모델의 정확성을 떨어뜨리는 오버피팅 문제
- 오버피팅: 노이즈나 아웃라이어 데이터까지 모두 정상인 것으로 인식하고 학습하면서 나타나는 현상
- 오버피팅을 비롯한 여러요인들은 머신러닝 알고리즘의 정확성을 떨어뜨리고 에러를 증가시킴.

3. 규제화를 위한 접근법

접근법	개념도	개념	비고
목적함수의 구속조건 적용		<ul style="list-style-type: none"> 구속함수 $R(w)$를 이용하여 목적함수 $E(w)$를 규제 구속함수 $R(w)$을 이용하여 목적함수의 결과값을 일반화 구속함수를 정하는 일반적 방법 (L_2 규제화 가중치 감소 규제화 티코프 규제화) 	구속조건 = 제약조건
L_1 규제화		<ul style="list-style-type: none"> 최소 절대값을 갖는 규제화 매개변수가 원점에 가까워지면서 무의미한 매개변수를 제거하고, 중요한 특성만을 선택하는 방법 즉 노이즈들을 포함하기 위해 굽곡 졌던 로지스틱 회귀식을 곧게 펴주면서 Cost를 줄임과 동시에 가중치(Weight)도 줄이는 해결책임 	Cost 감소, Weight 감소
Drop Out	<p>그림 11.10 L^1 규제화</p> <p>(1) 드롭아웃 후 학습 (2) 드롭아웃된 노드 복원 후 예측</p> <p>그림 11.11 드롭아웃을 이용한 규제화 개념</p>	<ul style="list-style-type: none"> 입력층과 은닉층에 있는 노드를 임의로 선택해서 확률 p 기준으로 제거하고 나서 축소된 신경망을 가지고 학습하는 방법 	공동적응 문제 해결



차원의 저주(Curse of Dimensionality)

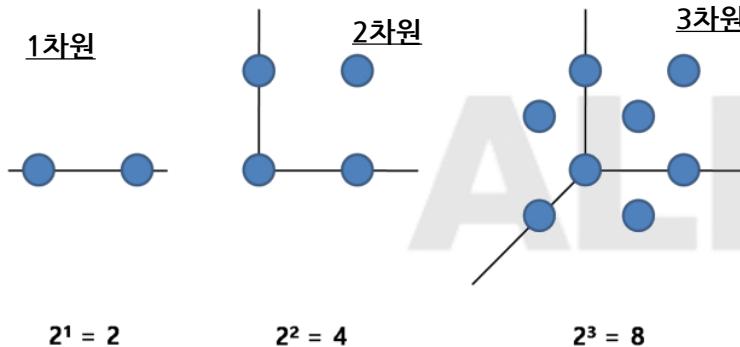
* 차원 : 각 샘플에 할애되는 정보량

기하급수 | Sparsing, | 저차원 비대상

1. 고차원에서 기인하는 기하급수적 데이터 고갈, 차원의 저주의 개념

- 수백, 수천 정도의 고차원에서 데이터의 분석, 조합 및 처리시 발생하는 필요 데이터의 품귀 현상
- 차원이 낮을 때 일어나지 않던 문제들이 높은 차원에서 데이터를 분석하거나 구조화할 때 나타나는 현상
- 차원이 증가할수록 데이터의 분포 분석 또는 모델추정에 필요한 샘플 데이터의 개수가 기하급수적으로 증가

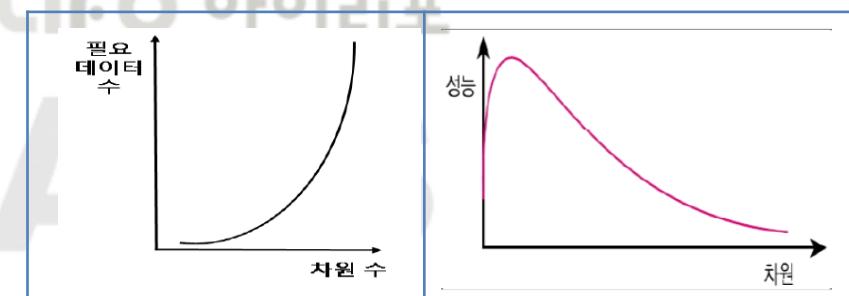
2. 차원의 저주의 예시 개념도 및 관계도표



- 각 차원에서 동일한 수준의 데이터를 활용하기 위해 필요한 데이터는 2의 거듭 제곱수 만큼 증가
- 차원의 수와 필요 데이터의 수와는 승수 비례가 성립

3. 차원 축소를 통한 차원의 저주의 극복방안

특징	설명
기하급수	선형 비례가 아닌, N제곱수 기준으로 비례
Sparsing	동일 개수의 데이터의 밀도는 차원증가에 따라 희박해짐
고차원 해당	수십정도의 저차원에서는 발생하지 않음



- 차원의 증가에 따라 필요한 데이터의 수는 N제곱수 기준으로 비례
- 차원의 증가에 따라 필요 레코드 증가에 의해 전체 처리 성능은 저하
- 핵심이 되는 특징만을 선별하여 문제의 차원을 낮추는 방안으로 극복 가능

방안	설명	적용사례
PCA (Principle Component Analysis)	<ul style="list-style-type: none"> 주성분 분석 고차원에서 분산(흩어짐)을 가능하면 많이 유지하며 차원을 축소 다차원 특징벡터의 정보를 유지하며 저차원으로 차원을 축소하는 다변량 데이터 처리법 	<ul style="list-style-type: none"> 영상인식에서 널리 활용(안면인식, 텍스트인식) PCA는 eigenface, LDA는 fisher face 기반 안면인식
LDA (Linear Discriminant Analysis)	<ul style="list-style-type: none"> 선행판별 분석 데이터의 최적 분류의 견지에서 데이터 축소 (PDA : 데이터의 최적 표현의 견지에서 축소) 	

차원의 축소(Dimensionality reduction)

* Feature : 변수

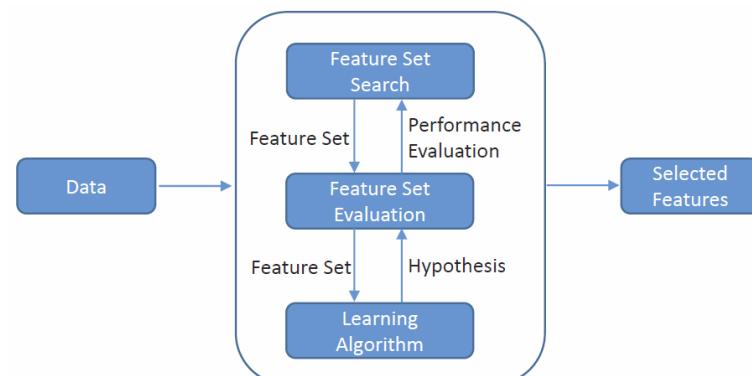
1. 차원의 저주를 극복한, 차원의 축소의 개요

- 차원 축소는 말 그대로 차원의 수를 줄이는 것, 변수의 수를 줄이는 것
- 고차원의 데이터를 정보의 손실을 최소화하면서 저차원으로 변환 하는 것
- 효과 : 1) 차원의 저주 탈피, 2) 시각화의 용이성

2. 차원의 축소 유형 및 상세 알고리즘

- Feature Selection : 가지고 있는 변수들 중에 중요한 변수만 몇 개 고르고 나머지는 버리는 방법
- Feature Extraction : 모든 변수를 조합하여 이 데이터를 잘 표현할 수 있는 중요 성분을 가진 새로운 변수를 추출

유형	알고리즘	설명
Feature Selection	상관분석(Correlation)	<ul style="list-style-type: none">• 관계수가 높거나 VIF(분산팽창지수, Variance Inflation Factor)가 높은 중첩되는 변수들 중 하나만 선택• 타겟, 즉 종속변수에 영향을 크게 주는 중요한 변수는 랜덤포레스트(Random Forest) 또는 XGBoost 등을 이용해 Variable Importance를 찾아 몇 가지 변수만 선택
Feature Extraction	PCA (Principle Component Analysis)	<ul style="list-style-type: none">- 주성분 분석- 고차원에서 분산(흩어짐)을 가능하면 많이 유지하며 차원을 축소- 다차원 특징벡터의 정보를 유지하며 저차원으로 차원을 축소하는 다변량 데이터 처리법
	LDA (Linear Discriminant Analysis)	<ul style="list-style-type: none">- 선형판별 분석- 데이터의 최적 분류의 견지에서 데이터 축소 (PDA : 데이터의 최적 표현의 견지에서 축소)



[지도] 분류분석 (classification analysis)

1. 분류분석의 개요



- 소속집단을 알고 있는 데이터를 이용하여 모형을 만들고, 소속집단을 모르는 데이터의 집단을 결정하는 기법
- 분류분석은 머신러닝(Machine Learning)의 지도학습의 하나의 기법
- 판별분석(Discriminant Analysis) 또는 계획된 기계학습(Supervised Machine Learning)이라고도 함

2. 분류분석의 절차 및 유형

데이터의 정제 및 분할
각 집단별 데이터를 수집하여 정제 및 변환 작업하고
데이터를 훈련용과 시험용으로 분할

모형의 훈련(Model Training)
훈련용 데이터를 이용하여
분류모형 $y=f(x)$ 의 수립

타당성 검토
시험용 데이터를 이용하여
분류모형 $y=f(x)$ 의 타당성 검토

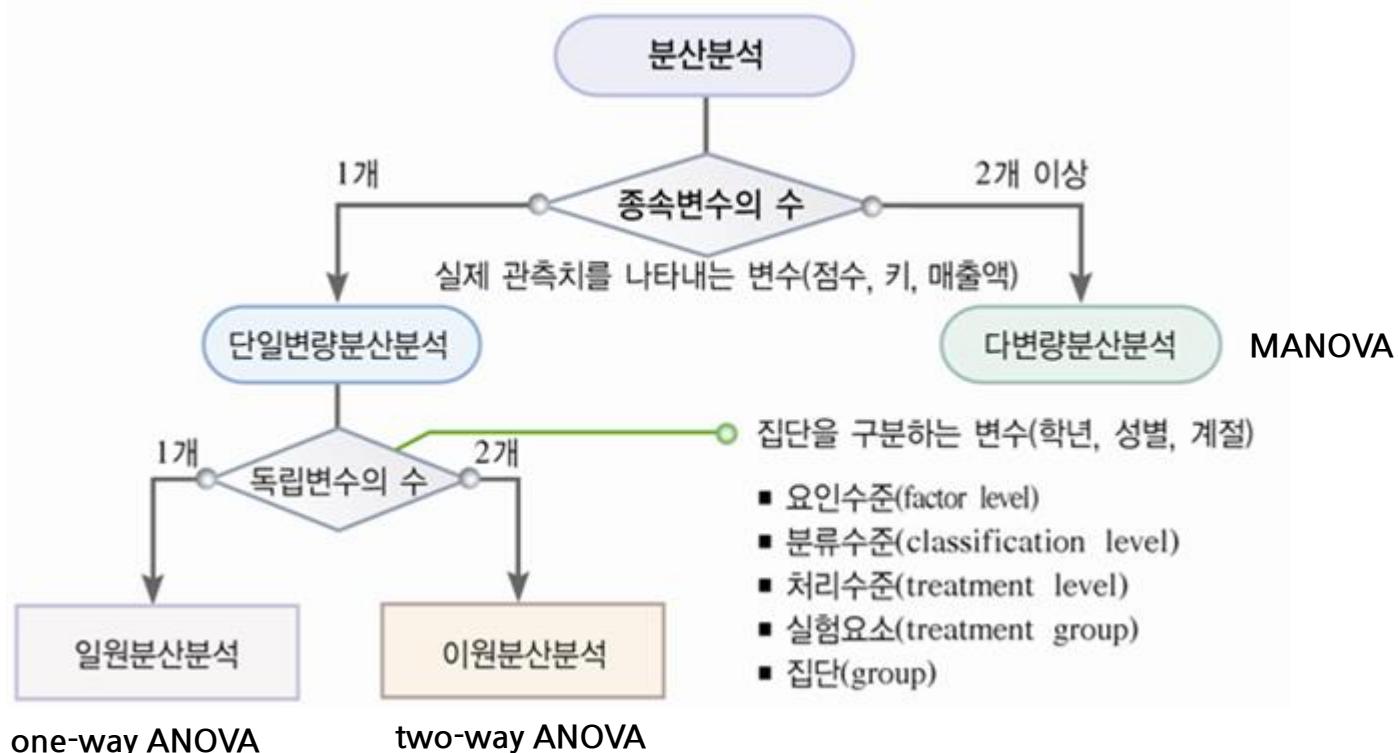
분류모형의 적용
소속집단을 모르는 데이터를
분류모형 $f(x)$ 를 이용하여 한 집단으로 분류

분류	모형	특징
통계기반	베이즈(Bayes) 분류모형	<ul style="list-style-type: none"> 각 집단으로 분류되는 사전확률(prior probability)과 집단별가능도확률(likelihood probability)을 알 때, 소속집단을 모르는 데이터에 대하여 베이즈정리(Bayes theorem)를 이용한 사후확률(posterior probability)를 구하여 그 확률이 높은 집단으로 분류하는 방법
	로지스틱(Logistic)회귀 모형	<ul style="list-style-type: none">선형회귀모델에서 종속변수 Y가 범주형인 경우로 확장한 것 (예: 성공/실패 등...)
	의사결정나무(Decision Tree) 분류모형	<ul style="list-style-type: none">분류함수를 의사결정규칙으로 표현할 때 타원(분기점), 직선(가지), 사각형(잎사귀)을 이용하여 나무형태로 그려서 분석하는 도구
	규칙기반(Rule Based) 분류모형	<ul style="list-style-type: none">“if ~ then..” 규칙들의 집합을 사용하여 항목들을 분류하는 방법. 둘 이상의 클래스를 포함하는 데이터 집합에서 한 번에 한 클래스씩 규칙들을 얻음
	인접이웃(Nearest Neighbor) 분류모형	<ul style="list-style-type: none"> 새로운 데이터(설명변수값)에 대해 이와 가장 유사한(거리가 가까운) k-개의 과거 자료(설명변수값)의 결과(반응변수: 집단)를 이용하여 다수결로 분류함. 과거자료를 이용하여 미리 분류모형을 수립하는 것이 아니라, 과거 데이터를 저장만 해두고 필요시 비교를 수행하는 방식
	신경망(Neural Network) 모형	<ul style="list-style-type: none">사람의 두뇌와 유사하게 여러 개의 노드를 네트워크로 연결하여 데이터를 분류하는 의사결정을 함. 일반화된 비선형함수를 분류함수로 이용
	지지벡터기계 (Support Vector Machine) 모형	<ul style="list-style-type: none">수학함수를 이용하여 데이터 공간을 나누는 방식. 선형함수를 이용하여 나누는 선형SVM과 비선형함수를 이용하여 나누는 비선형SVM이 있음
	양상블 모형	<ul style="list-style-type: none">여러 개의 분류모형에 대한 결과를 종합하여 한 데이터를 분류하는 모형. 결과의 종합은 다수결이나 기타 방법을 사용
<ul style="list-style-type: none">귀납적 추론을 기반으로 하는 의사결정 트리는 실무적으로 가장 많이 사용되고 있는 머신러닝 기법주로 불연속 데이터를 다루며 노이즈가 발생해도 중단되거나 엉뚱한 결과를 보여주지 않는 매우 강건한 모델임.		

분산분석 (ANOVA : Analysis of Variance)

1. 분산분석의 개요

- **2개 이상의 다수의 집단을 비교**하고자 할 때, **F분포를 통해 가설을 검정**하는 통계적 분석 기법
- $F\text{분포} = (\text{집단 간 분산}) / (\text{집단 내 분산})$



[지도] 베이즈 정리

1. 베이지안의 개요

- 이전의 경험과 현재의 증거를 토대로 어떤 사건의 확률의 정확도를 보정하는 방식으로 추론하는 주관적 확률이론
- 조건부 확률을 이용하여 두 확률 변수의 사전 확률과 사후 확률 사이의 관계를 구하는 통계 이론
==> 사전지식 $P(A|B)$ 로부터 사후확률 $P(B|A)$ 를 추론



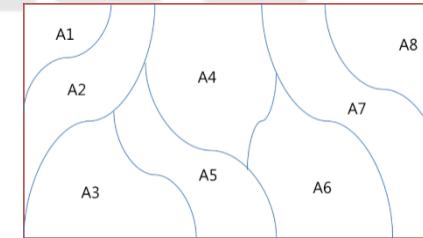
* 조건부 확률 $P(A|B) = \frac{P(A \cap B)}{P(B)}, P(B) > 0$

$$\therefore P(A \cap B) = P(A|B)P(B) = P(B|A)P(A)$$

* 전확률(Total Probability)

서로 배반인(서로 겹치는 경우가 없는) 사건 A_1, A_2, \dots, A_n 이 어떤 시행의 결과로 일어나고, 이를 사이의 완전계(A_1, A_2, \dots, A_n 전체의 합집합=전체집합)를 이루어서 임의의 사건B가 일어난다고 보는 이론

(MECE)



* 베이즈 정리

$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)}$$

$P(B|A)$: 사후 확률, 나중에 일어나는 사건 A를 전제로 하는 조건부 확률

$P(B)$: 사전 확률, 사건 A가 일어나기 전 사건 B가 일어날 확률

$P(A|B)$: 사건 B가 일어난 후에 사건 A가 일어날 확률

예를 들어 설명하면

- 가설: 화성에는 생명체가 있다(H)
- 특정인 i가 이 가설 H를 선행적으로 믿는 정도를 $P(H)$ 라고 함 (← 사전적 확률)
- 생명체 탐지기 x가 화성에 보내져서 화성에 생명체가 있는가, 없는가를 탐지한다고 하자. 그런데 탐지기 x는 완전한 기계가 아니어서 오류를 범할 수 있다.
- 이 탐지기 x가 측정한 데이터 D의 신뢰도는 다음과 같다.
 - 실제로 생명체가 있는데(H) 생명체가 있다고 확률을 $P(D|H)$
 - 생명체가 없는데(H) 생명체가 있다고 할 확률(오류율)을 $P(D|\bar{H})$ 라 하고 D를 data report 라고 하자.
- 이 탐지기를 실제로 화성에 보냈더니 생명체가 있다는 보고(D)를 보내왔다

이 보고를 받고 특정인 i는 자신이 가지고 있는 H에 대한 믿음을 수정하게 될 것이다. 이 수정된 가설을 $P(H|D)$ 라는 새확률(사후적 확률)로 표시하고 이 확률을 구하는 것이 베이즈 정리의 핵심이다

[지도] 베이즈 분류(Bayes Classification)

1. 베이즈 분류

- 각 집단으로 분류되는 사전확률과 집단별 우도확률을 알 때, 베이즈 정리를 이용, 개별 관측치의 집단 사후확률을 구하여 소속 집단을 정하는 분류 방법
- 사전 확률: 미리 알고 있는 확률,
- 우도 확률: 바른 결정을 내리는 것에 도움을 줄 수 있는 추가 정보의 확률

2. 사례 예시

- 사전 확률: 상점에 방문하는 고객 중 40% 가 구매 집단임
- 우도 확률: 20대 고객은 20%, 30대 고객은 60%가 구매 집단임
- 어느 날 20대가 매장을 방문했을 때, 사후 확률 계산, 구매 여부를 분류
- 구매한 사람들에 대한 20 대의 비율

나이	구매집단 (G_1)	비구매집단 (G_2)	합계
20대	2	8	10
30대	6	4	10
합계	8	12	20

$$P(G_1|x) = \frac{P(G_1) \times P(x|G_1)}{P(G_1) \times P(x|G_1) + P(G_2) \times P(x|G_2)} = \frac{\frac{8}{20} \times \frac{2}{8}}{\frac{8}{20} \times \frac{2}{8} + \frac{12}{20} \times \frac{8}{12}} = 0.2$$

구매를 안한 사람들에 대한 20 대의 비율

$$P(G_2|x) = \frac{P(G_2) \times P(x|G_2)}{P(G_1) \times P(x|G_1) + P(G_2) \times P(x|G_2)} = \frac{\frac{12}{20} \times \frac{8}{12}}{\frac{8}{20} \times \frac{2}{8} + \frac{12}{20} \times \frac{8}{12}} = 0.8$$

- 비구매집단 20대 비율 > 구매집단 20 대 비율이므로 20대는 비구매로 분류

[지도] 나이브 베이즈 (Naïve Bayes)

1. 나이브 베이즈의 개요

- 베이즈 분류 시 각 변수가 독립임을 가정하고, 각 우도 확률을 직접 이용하지 않고, 근사값을 계산하여 대상을 구분하는 분류 기법

2. 사례 예시

- 사전 확률: 상점에 방문하는 고객 중 40% 가 구매 집단임
- 우도 확률: 20대 고객은 0%, 30대 고객은 66%가 구매 집단임
- 어느 날 20대가 매장을 방문했을 때, 사후 확률 계산, 구매 여부를 분류
 - 베이즈 분류로 구한 구매한 사람들에 대한 20 대의 비율

나이	구매집단 (G_1)	비구매집단 (G_2)	합계
20대	0	8	8
30대	8	4	12
합계	8	12	20

$$P(G_1|x) = \frac{P(G_1) \times P(x|G_1)}{P(G_1) \times P(x|G_1) + P(G_2) \times P(x|G_2)} = \frac{\frac{8}{20} \times \frac{0}{8}}{\frac{8}{20} \times \frac{0}{8} + \frac{12}{20} \times \frac{8}{12}} = 0$$

- 베이즈 분류로 구한 구매를 안한 사람들에 대한 20 대의 비율

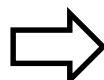
$$P(G_2|x) = \frac{P(G_2) \times P(x|G_2)}{P(G_1) \times P(x|G_1) + P(G_2) \times P(x|G_2)} = \frac{\frac{12}{20} \times \frac{8}{12}}{\frac{8}{20} \times \frac{0}{8} + \frac{12}{20} \times \frac{8}{12}} = 1$$

- 샘플링 결과 20대 구매 고객이 0 이므로 베이즈 분류로 분석하기 어려움

[지도] 나이브 베이즈 (Naïve Bayes)

- 사례 예시 (계속)
 - 나이브 베이즈로 변환하기 위해 독립 상황에서의 사람 수를 다시 구함

나이	구매집단 (G_1)	비구매집단 (G_2)	합계
20대	0	8	8
30대	8	4	12
합계	8	12	20



나이	구매집단 (G_1)	비구매집단 (G_2)	합계
20대	$64/400 = 0.16$	$96/400 = 0.24$	8
30대	$96/400 = 0.24$	$144/400 = 0.36$	12
합계	8	12	20



나이	구매집단 (G_1)	비구매집단 (G_2)	합계
20대	3.2	4.8	8
30대	4.8	7.2	12
합계	8	12	20



나이	구매집단 (G_1)	비구매집단 (G_2)	합계
20대	$0.16 * 20 = 3.2$	$0.24 * 20 = 4.8$	8
30대	$0.24 * 20 = 4.8$	$0.36 * 20 = 7.2$	12
합계	8	12	20

어느 날 20대가 매장을 방문했을 때, 사후 확률 계산, 구매 여부를 분류

- 나이브 베이즈 분류로 구한 구매한 사람들에 대한 20 대의 비율

$$P(G_1|x) = \frac{P(G_1) \times P(x|G_1)}{P(G_1) \times P(x|G_1) + P(G_2) \times P(x|G_2)} = \frac{\frac{8}{20} \times \frac{3.2}{8}}{\frac{8}{20} \times \frac{3.2}{8} + \frac{12}{20} \times \frac{4.8}{12}} = 0.4$$

- 나이브 베이즈 분류로 구한 구매를 안한 사람들에 대한 20 대의 비율

$$P(G_2|x) = \frac{P(G_2) \times P(x|G_2)}{P(G_1) \times P(x|G_1) + P(G_2) \times P(x|G_2)} = \frac{\frac{12}{20} \times \frac{4.8}{12}}{\frac{8}{20} \times \frac{3.2}{8} + \frac{12}{20} \times \frac{4.8}{12}} = 0.6$$

- 20대 고객은 비구매로 분류



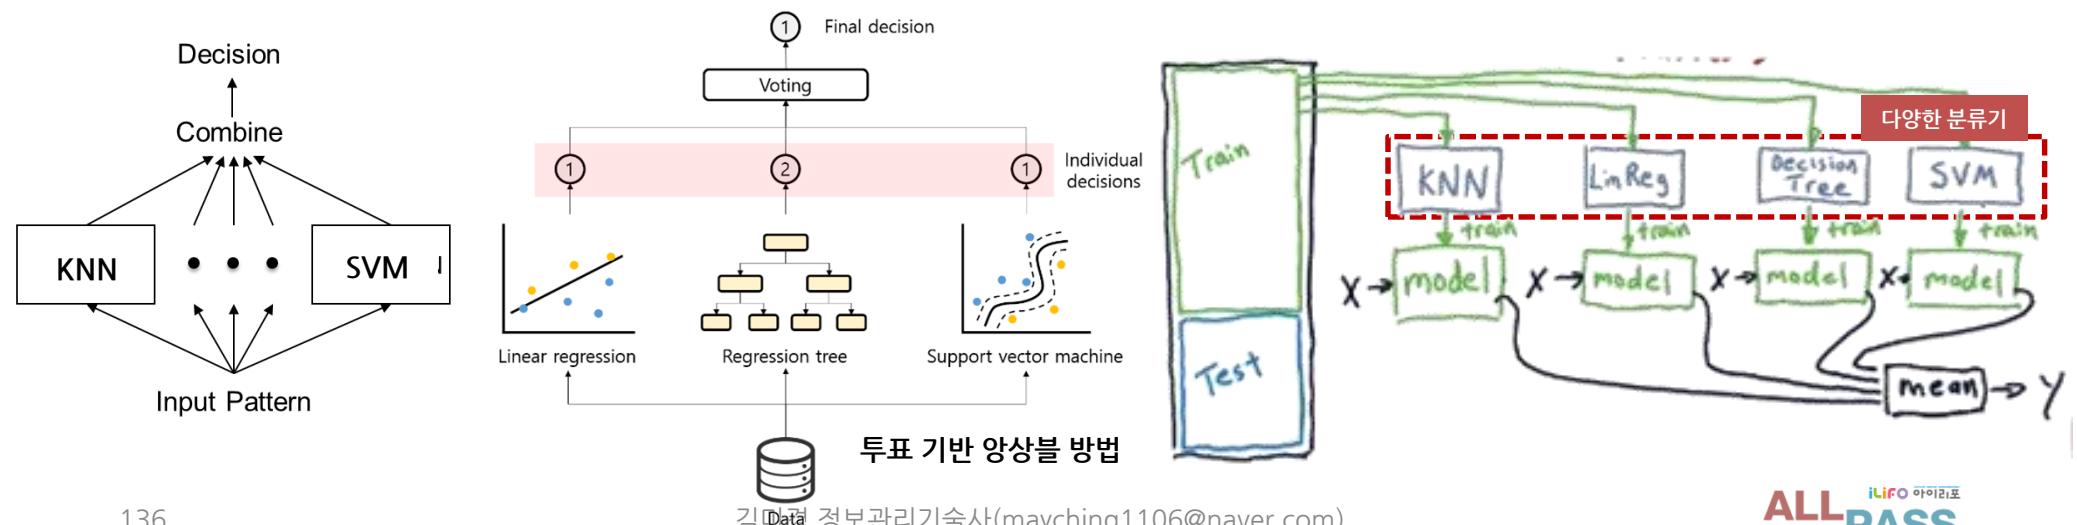
[지도] 양상블 학습 (Ensemble Learning)

1. 여러 분류 모형에 대한 결과를 종합하여 한 데이터로 분류하는 모형, 양상블 학습의 개요

- 기계 학습의 분류 방법을 통해 여러 개의 분류기(Classifier)를 생성하고 그것들의 예측을 결합함으로써 새로운 가설(Hypothesis)을 학습하는 방법
- 목표 : 다양한 분류기의 예측 결과를 결합함으로써 단일 분류기보다 신뢰성이 높은 예측값을 얻는 것
- 분류 모형은 데이터를 변화해서 생성할 수 있고, 또는 다른 메커니즘의 분류기를 여러 개 사용하여 양상블하는 것도 가능함
- 양상블 학습에 대한 연구는 결정 트리(Decision Tree)나 지지 벡터 머신(Support Vector Machine)과 같은 하나의 학습 알고리즘을 사용하는 방법에 대해서 이루어졌다. 이러한 방법들은 학습 알고리즘을 조작하여 다양한 분류기를 생성한 후 다수결(Majority Voting)이나 가중치 투표(Weighted Voting)에 의하여 예측값을 결합한다.
- 양상블 학습 방법 : 부스팅(Boosting)과 배깅(Bagging)
- 배깅과 부스팅: 학습 데이터를 샘플링하여 다양한 학습 데이터를 생성하며, 하나의 학습 알고리즘을 적용하여 다양한 분류기를 생성
- 예를 들어 5%의 오분류 모형을 5개를 합하여 다수결을 적용할 경우

$$\epsilon_{ensemble} = \sum_{i=3}^5 \binom{5}{i} (0.05)^i (1-0.05)^{5-i} = 0.0001$$

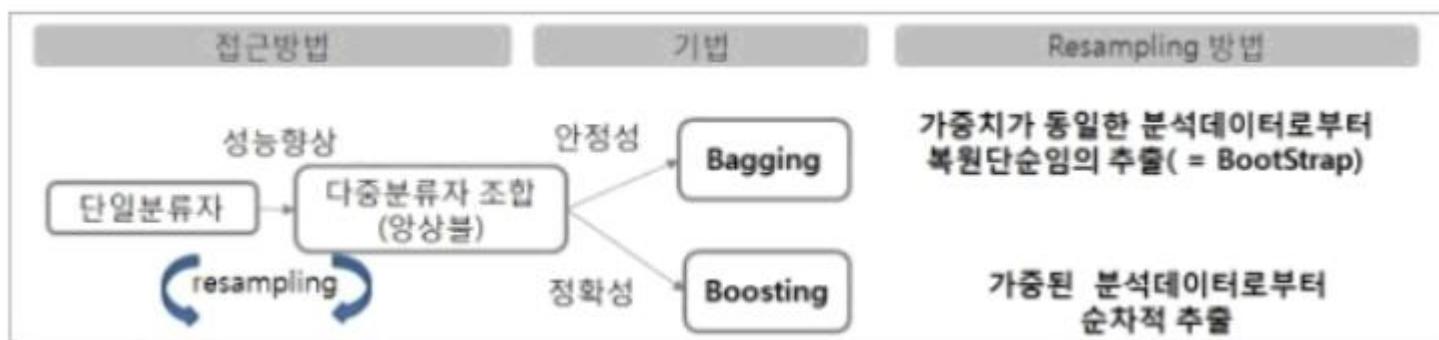
- 다섯 개 분류기 중 아무거나 세 개만 True 이면 됨



[지도] 양상블 학습 (Ensemble Learning)

2. 양상블학습의 종류

종류	설명	유형
데이터를 조정	- 적절한 표본추출 방법을 활용하여 여러 개의 훈련용 데이터 집합을 생성함 - 각각의 데이터 집합을 활용하여 여러 개의 분류기를 생성하여 양상블을 진행	Bagging, Boosting
변수의 개수를 조절	- 전체 변수집합에서 부분 변수집합을 선택하여 훈련용 데이터 생성 - 각각의 데이터 집합에 대해 분류기를 생성한 후 양상블을 진행	Random Forest
집단명을 조절	- 집단의 종류가 많은 경우 소수의 집단만으로 뮤어서 분류 - 각 집단에 소속되는지에 대한 여부만 분류하는 분류기를 생성하여 양상블 모형에 적용	
분류모형의 가정을 조정	- 하나의 분류모형은 모두에 대한 가정 또는 알고리즘에 대한 가정에 따라 상이해짐 - 모두 및 가정을 변경하여 여러 개의 모형을 생성하여 양상블을 진행	



- **양상블 생성:** 여러 전문가를 확보하는 일에 해당
- **양상블 선택:** 전체 전문가 집단에서 보다 유용한 전문가의 선택에 해당 (선택적)
- **양상블 결합:** 전문가의 의견을 결합하여 최종 의견을 만드는 과정에 해당

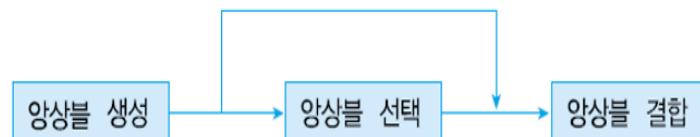


그림 12.4 분류기 양상블 시스템의 세 가지 문제



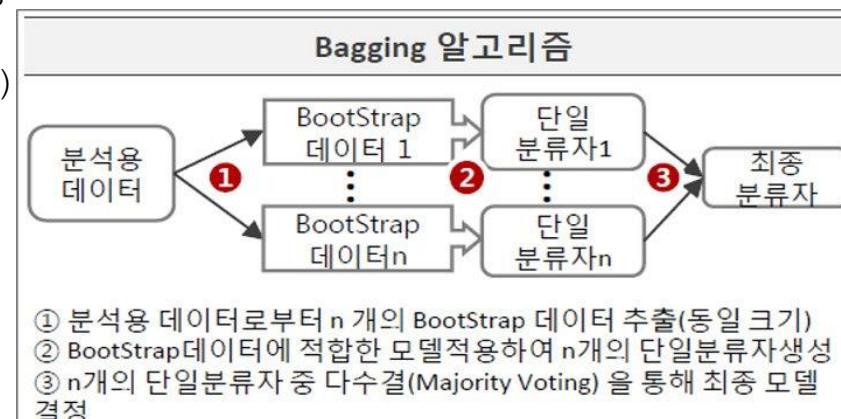
[지도][분류] 배깅 (bagging : bootstrap aggregating)

1. 배깅의 개요

- 주어진 데이터에 대해 **여러 개의 부트스트랩 자료를 생성**하고 각 **부트스트랩 자료를 모델링** 한 후 결합하여 **최종의 예측 모형을 산출하는 방법**
- Bootstrapping은 전체 모집단의 분포를 확실하게 알 수 없는 경우에 **표본을 취한 후 그 표본이 전체 집단을 대표한다는 가정**하에 전체의 분포를 예측할 수 있게 할 때 사용을 한다. 먼저 표본을 취하게 되면 그 표본에 대한 분포는 정확하게 구할 수 있다. 그리고 나서 표본을 전체라고 생각하고 표본으로부터 많은 횟수에 걸쳐 (동일한갯수의) 샘플을 복원 추출 (resample with replacement) 한 후 각 샘플들에 대한 분포를 구한다. 그 후 전체 표본의 분포와 샘플들 간의 분포의 관계를 통해, 전체 집단의 분포를 유추하는 방식이 바로 Bootstrapping이라고 함
- 원자료로부터 여러 번의 복원 샘플링(Modeling)을 통해 예측 모형의 분산을 줄여 줌으로써 예측력을 향상 시키는 방법**
- 훈련용 데이터로 부터 크기가 같은 표본을 여러 번 단순확률 반복 추출(With replacement)로 분류기를 생성하여 앙상블하는 방법
- 반복추출법을 사용하기 때문에 한 표본에 같은 데이터가 여러 번 추출될 수도 있고, 어떤 데이터는 추출되지 않을 수도 있음.
- 일반적으로 과대 적합 된 모형, 편의가 작고 분산이 큰 모형에 사용하는 것이 적합**
- N개의 데이터가 있을 때 N개의 표본을 단순확률 반복추출 할 경우 각 데이터가 다시 뽑힐 확률은

$$1 - (1 - 1/n)^n \rightarrow 1 - 1/e = 0.632$$

- 분류기(의사결정 스텁프 : decision stump)는 엔트로피가 최소화되도록 설정
- 배깅 절차
 - 전체 데이터 셋 정리 (예를 들어 전체 데이터 집합 = {1,2,3,4,5,6,7,8,9,0})
 - 랜덤 복원 샘플링 수행 (예를 들어 추출된 집합 = {1,2,9,1,2,3,4,4,8,9})
 - 샘플 중 중복된 요소를 정리 (예를 들어 정리된 집합 = {1,2,3,4,8,9})
 - 정리된 집합으로 의사결정 스텁프 작성
 - 바로 전 3 단계를 반복하면서 의사결정 스텁프를 홀수 개 작성
 - 작성된 의사결정 스텁프에 따라 전체 데이터 셋을 넣어 각각 분류 수행
 - 분류기 별 분류값을 voting 하여 최종 분류를 확인



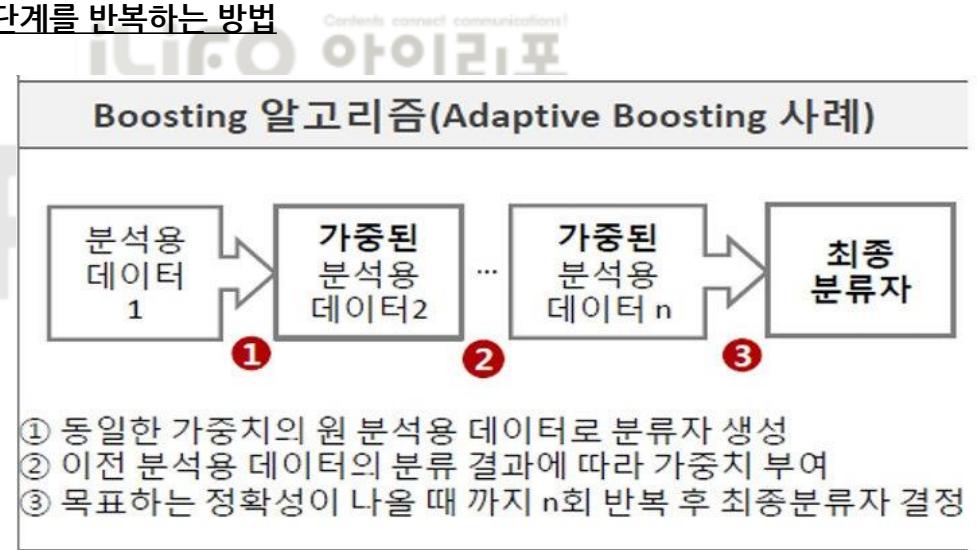


[지도][분류] 부스팅(Boosting)

1. 최종 예측 모델의 신뢰도를 높이는 기법으로 Meta-Algorithm, 부스팅의 개요

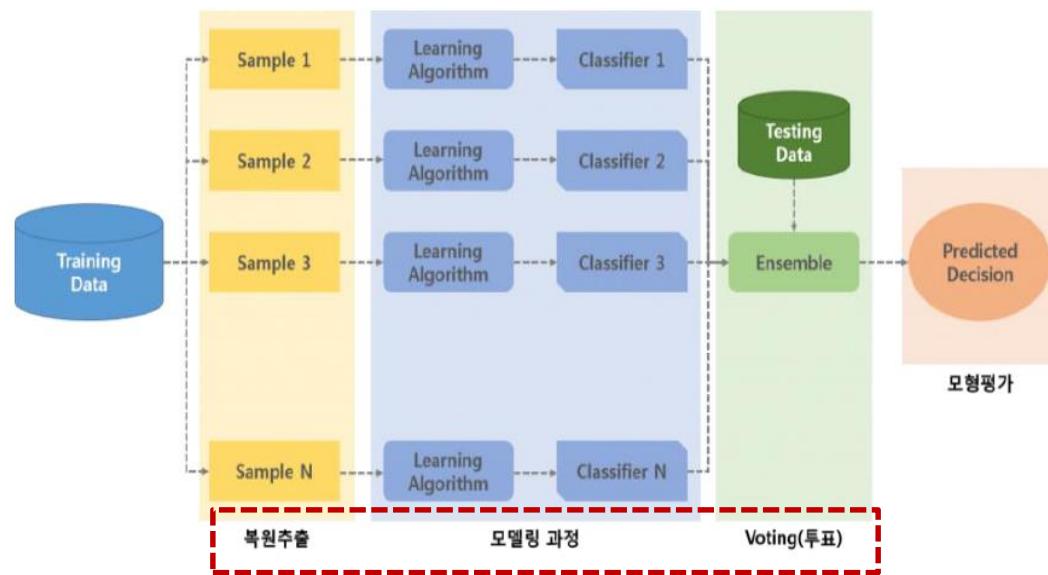
- 모델의 정확성을 높이기 위하여 오분류된 개체들에 가중치를 부여함으로써 새로운 분류규칙을 만드는 단계를 반복하여 약한 분류모델을 강한 분류모델로 변형(Boosting)하는 알고리즘
- 배깅에서는 데이터를 복원추출할 때 동일한 확률로 반복 추출
- 부스팅은 데이터를 동일한 확률로 복원추출하지 않고 분류가 잘못된 데이터에 가중을 주어 추출, 즉 표본으로 선택될 확률이 높도록 한 후 추출
- 무작위로 선택하는 것보다 약간 가능성성이 높은 규칙들을 결합시켜 보다 정확한 예측 모델을 만들어 내는 것
- 잘못 분류된 개체들에 집중하여 새로운 분류규칙을 만드는 단계를 반복하는 방법

비교	Bagging	Boosting
특징	병렬 양상분 모델 (각 모델은 서로 독립적)	연속 양상분 (이전 모델의 오류를 고려)
목적	Variance 감소	Bias 감소
적합한 상황	복잡한 모델 (High variance, Low bias)	Low variance, High bias 모델
대표 알고리즘	Random Forest	Gradient Boosting, AdaBoost
Sampling	Random Sampling	Random Sampling with weight on error



배깅, 부스팅 참조자료

배
깅



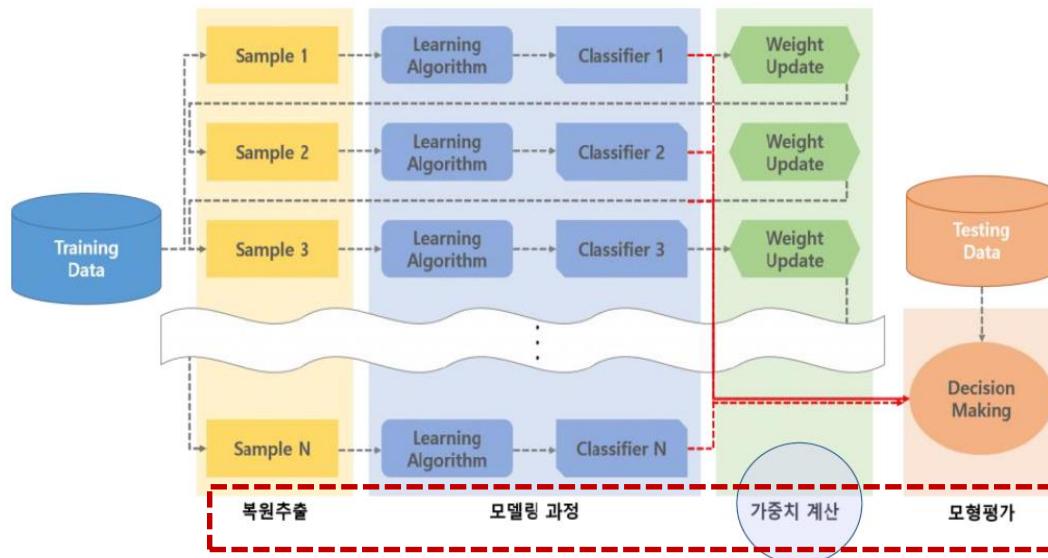
예측 모델의 안정성 확보!

병렬적 방법



SS

부
스
팅



예측 모델의 정확도 향상!

순차적 방법



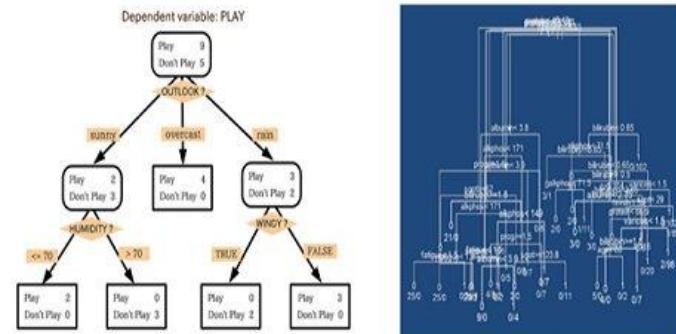
[지도][분류] 랜덤 포레스트(Random Forest)

1. 여러 의사결정나무 모형의 분류 결과를 종합하기 위하여 고안된 양상을 방법, 랜덤 포레스트의 개요

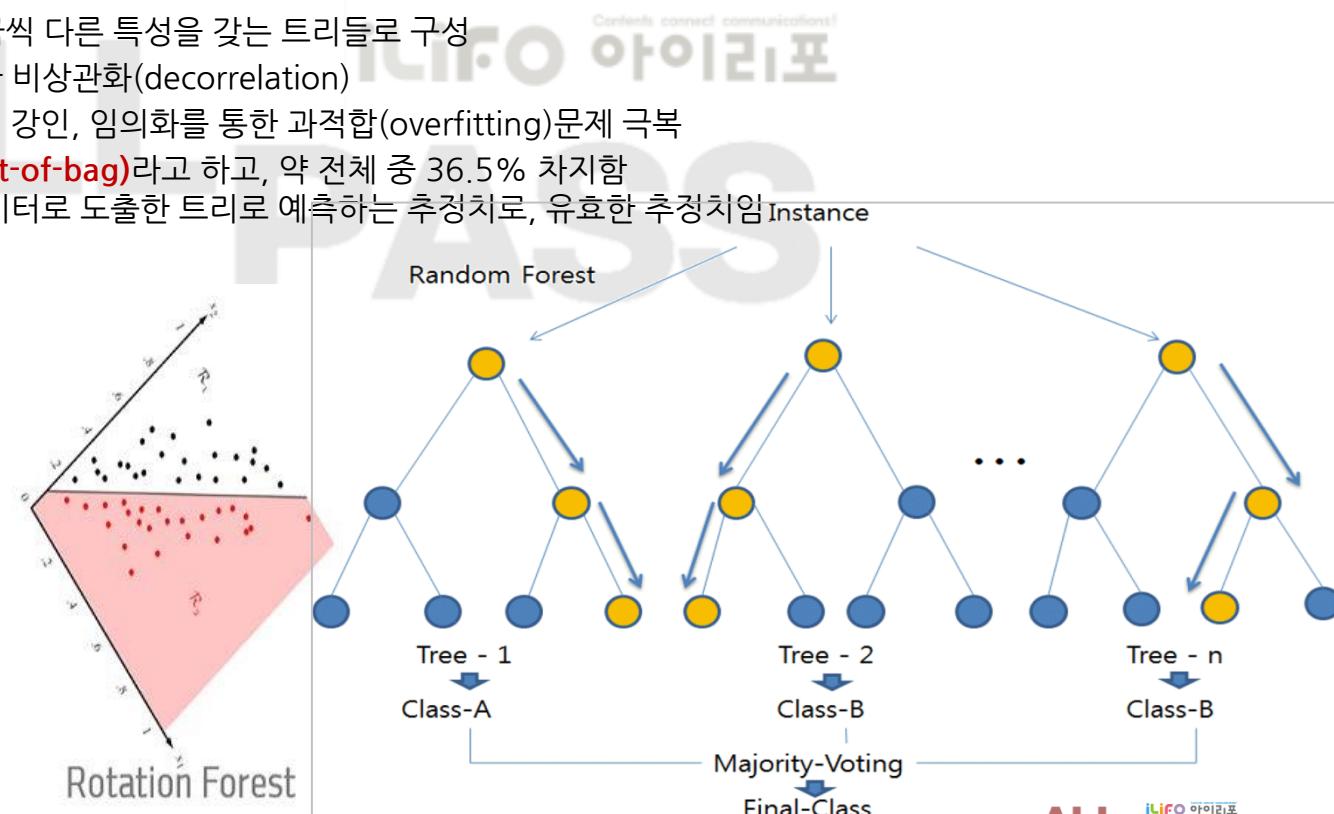
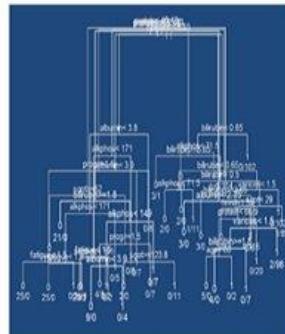
- 여러 의사결정나무 모형의 분류 결과를 종합하기 위하여 고안된 양상을 방법
- 배깅(bagging)보다 더 많은 임의성을 주어 학습기들을 생성한 후 이를 선형 결합하여 최종 학습기를 만드는 방법**
- 동일한 데이터로부터 복원추출을 통해 30개 이상의 데이터 셋을 만들어 각각에 의사결정나무를 적용한 뒤 학습결과를 취하는 방법으로 작동**
- 각각의 나무(Tree)들은 전체 변수 중 일부만 학습을 하게 되며, 개별 트리들이 **데이터를 바라보는 관점을 다르게 해 다양성을 높이려는 시도**임

2. 특징

- 임의성(randomness)에 의해 서로 조금씩 다른 특성을 갖는 트리들로 구성
- 각 트리들의 예측(Prediction)들에 대한 비상관화(decorrelation)
- 일반화 성능의 향상 및 노이즈(noise)에 강인, 임의화를 통한 과적합(overfitting) 문제 극복
- 배깅에 사용되지 않는 데이터 OOB(Out-of-bag)**라고 하고, 약 전체 중 36.5% 차지함
OOB오차는 OOB를 사용하지 않은 데이터로 도출한 트리로 예측하는 추정치로, 유효한 추정치임 Instance



Tree

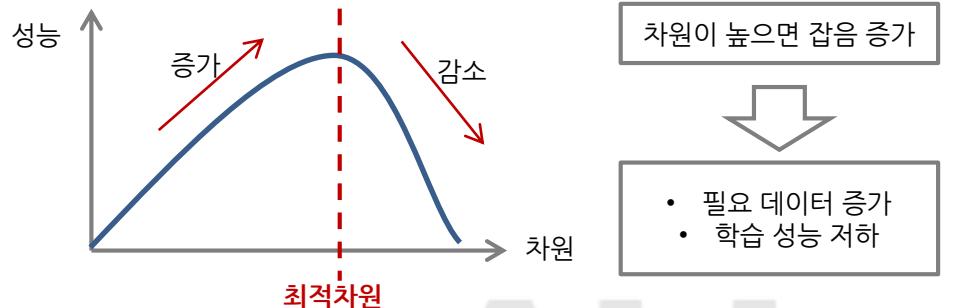




[비지도] PCA (Principal Component Analysis)

주성분 분석 차원 축소 공분산 행렬

1. 상관관계가 있는 변수들을 선형 결합하여 변수를 축약하는 기법, PCA의 개요



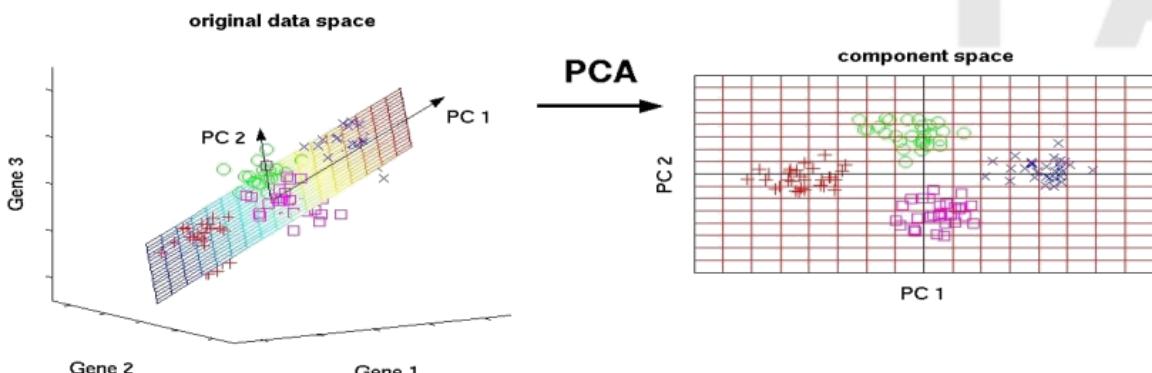
목적	설명
차원의 축소	- 고차원 특징벡터를 저차원 특징벡터로 축소하는 기법
잡음의 제거	- 인식에 필요한 핵심 요소만 추출하고 불필요한 데이터는 제거
전처리 작업	- 데이터 수집단계, 분석이전에 데이터 사전 가공작업에 활용

* 표본 추출 시에도 사용 가능

connect communications?

- 고차원 공간의 표본들을 선형 연관성이 없는 저차원 공간(주성분)의 표본으로 변환하여 분석하는 알고리즘
- 상관관계가 있는 고차원 자료를 자료의 변동을 최대한 보존하는 저차원 자료로 변환시키는 기법 (ML 전처리 알고리즘)
- 여러변수의 값을 합쳐서 그보다 적은 수의 주성분을 새로운 변수로 하여 데이터를 표현 >> 차원 축소시 사용

2. PCA 알고리즘 분석 개념도와 수행절차



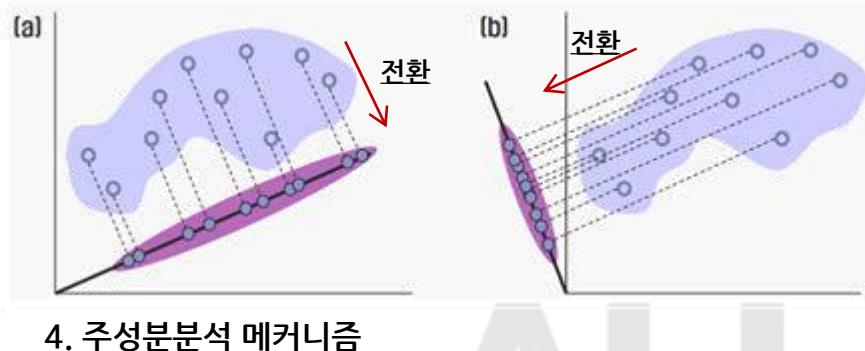
PCA 수행절차	설명
데이터셋 로드	<ul style="list-style-type: none"> PCA 분석을 위한 데이터셋을 준비
평균, 공분산 계산	<ul style="list-style-type: none"> 평균값과 편차를 구하고, 공분산을 계산
고유값, 고유벡터 계산	<ul style="list-style-type: none"> 해당 데이터집합을 가장 잘 표현하는 고유값, 고유벡터를 식별
변환 (Transform)	<ul style="list-style-type: none"> 고유값, 고유벡터를 이용하여 회전, 확장을 하여 새로운 기준 데이터셋을 설명하거나, 새로운 데이터셋을 예측

- 3 차원의 데이터셋을 분산값이 큰 영의 축(Axis)인 PC1을 식별하여 PC2 축의 방향을 Projection 하여 2 차원으로 변환하는 사례



[비지도] PCA (Principal Component Analysis)

3. PCA의 개념도



- 각각의 데이터에 대한 성분 분석이 아닌, 데이터들의 분포를 분석하여 그 분포의 주성분을 분석하는 알고리즘
- 공분산 행렬의 최대 고유벡터와 고유치를 추출
- 얻어지는 고유벡터를 변환행렬(Linear Transform Matrix)로 사용하여 선형변환에 의해 특징벡터 추출
- 높은 분산확보를 위해서는 (a)분할이 (b)분할보다 더 좋은 결과

iLIFO Content connect communication
아이리포

4. 주성분분석 메커니즘

다. 고유값(EigenValue) & 고유벡터(EigenVector)

항목	개념	사례
고유값 EigenValue	행렬 A를 선형변환한 결과가 자기 자신의 상수배가 되게 하는 값	$2 \times \begin{pmatrix} 3 \\ 2 \end{pmatrix} = \begin{pmatrix} 6 \\ 4 \end{pmatrix}$ $\begin{pmatrix} 2 & 3 \\ 2 & 1 \end{pmatrix} \times \begin{pmatrix} 6 \\ 4 \end{pmatrix} = \begin{pmatrix} 24 \\ 16 \end{pmatrix} = 4 \times \begin{pmatrix} 6 \\ 4 \end{pmatrix}$ 위 행렬에서 고유값은 4 고유벡터는 $\begin{pmatrix} 6 \\ 4 \end{pmatrix}$
고유벡터 EigenVector	행렬 A를 선형변환한 결과가 자기 자신의 상수배가 되게 하는 벡터	

$$A \vec{v} = \lambda \vec{v}$$

Dataset 행렬 고유값 고유벡터

5. 주성분분석의 한계와 극복방안

주성분 분석의 한계 (가정)	극복방안
1. 직선축 가정	1. 데이터 검증 (직선축 가정 검증)
2. 큰 분산을 갖는 방향이 중요한 정보를 담고 있다고 가정	2. 분산에 대한 정규화 수행
3. 주축(principal component)들은 서로 직교(orthogonal)	3. 직교성 검증



미스코리아 얼굴이 모두 다 똑같아!!!
6개의 대표 얼굴이면 출전한 20명을 모두 만들 수 있다
(20개의 얼굴을 6개로 압축)

6. PCA 와 LDA 의 비교

PCA(Principal Component Analysis)	LDA(Linear Discriminant Analysis)
차원축소를 주목적으로 하는 방법으로 전체적인 data의 분포를 보았을 때 principal axis가 어디인지 확인 한 뒤 그 axis로 data를 project해주는 방법	클래스의 정보를 보호하면서 두 클래스를 포함하는 data들을 가장 잘 감소시킬 수 있는 axis를 찾는 것을 목적

[비지도] ICA(독립성분 분석)

1. PCA를 일반화한 방법, 독립성분 분석(Independent Component Analysis)의 개요

- 픽셀값들 사이의 **우선순위 관계 인식을 통해 우수한 기본 이미지를 찾는 방법**
- 주어진 자료가 서로 독립인 성분들의 선형 또는 비선형 결합으로 이루어졌다고 가정하고, 주어진 자료를 독립적인 성분들로 분해하는 과정

2. ICA 개념도

- ICA는 주성분을 이용한다는 점에서 PCA와 비슷하지만 데이터를 가장 잘 설명하는 축을 찾는 PCA와는 달리 가장 독립적인 축을 찾는다. 이에 독립성이 최대가 되는 벡터를 찾는다. 독립성은 ICA의 알고리즘에 의해 계산된다



Figure 2.3. Example 2-D data distribution and the corresponding principal component and independent component axes. The data points could be, for example, grayvalues at pixel 1 and pixel 2. Figure inspired by Lewicki & Sejnowski (2000).

PCA와 ICA를 비교한 모습[3]

- [1] Jolliffe, Ian. "Principal component analysis". John Wiley & Sons, Ltd, 2002.
- [2] P. Comon, "Independent component analysis", a new concept, Signal Process. 36 (1994) 287-314
- [3] M. Stewart, "Face Image Analysis by Unsupervised Learning", Kluwer Academic Publisher, (2001) p.43

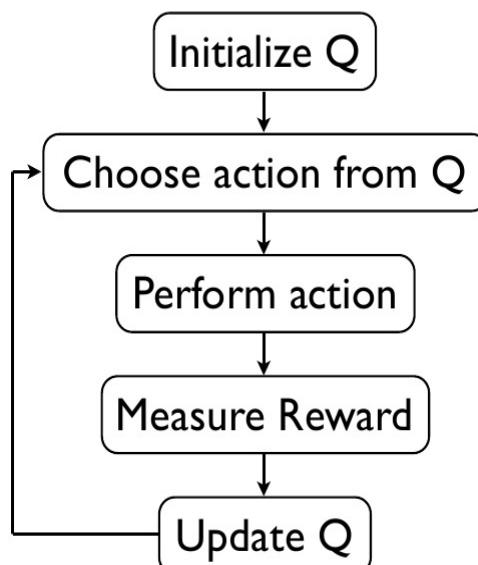


[강화] Q-learning

1. Q함수를 이용한 강화학습 알고리즘 , Q-learning의 개요

- 주어진 상태에서 주어진 행동을 수행하는 것이 가져다 줄 **효용의 기댓값을 예측하는 함수인 Q 함수를 학습**함으로써 최적의 정책을 학습하는 강화학습 기법
- 특정 상태에서 행동에 대한 미래값(Q)을 계산하여, 최적 정책을 찾는 마르코프 의사결정 기반 강화학습 기법**
- 일련의 action(행동)을 무작위로 추출하고 그에 따라 지역갱신 규칙을 적용해서 점차 Q값 테이블을 수정, 반복절차를 통해 Agent(의사결정자)의 행동을 학습 (주어진 환경의 모델 없이도 수행하는 행동의 기대값을 비교할 수 있음)
- 전이가 확률적으로 일어나거나 보상이 확률적으로 주어지는 환경에서도 별다른 변형 없이 적용 가능

2. Q-Learning의 동작 절차 및 알고리즘



- ① value table Q 초기화
- ② 정책 기반 Action 선택/수행
- ③ 새로운 상태 및 보상 관찰
- ④ 다음상태 최대보상 업데이트
- ⑤ 새로운 상태 설정, 반복수행

$$\text{Max Q} = \max_{a'} Q(s, a')$$

$$\pi^*(s) = \arg\max_a Q(s, a)$$

Initialize $Q(s, a)$ arbitrarily
Repeat (for each episode):

Initialize s

Repeat (for each step of episode):

Choose a from s using policy derived from Q
(e.g., ϵ -greedy)

Take action a , observe r, s'

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_a Q(s', a) - Q(s, a)]$$

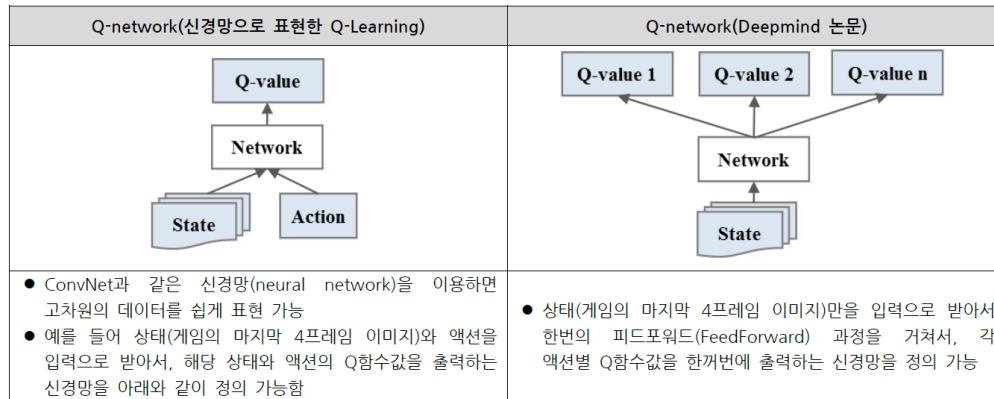
$s \leftarrow s'$

until s is terminal

구분	구성요소	설명
정책 (Policy)	- 최대 보상 - 미래보상 관찰	- 최고 Q값 기반 액션 선택 - $\pi(s) = \arg\max Q(s, a)$
벨만 방정식	- 정책 반복 - 재귀함수	- 최적정책 찾는 반복수행 - 현재 최고보상, 미래보상
Q-러닝 알고리즘	- 테이블 기반 - 반복적 근사	- 벨만 방정식 반복 수행 - 반복 기반 Q함수 근사

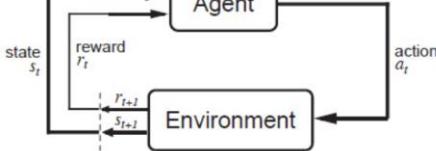
[강화] Q-learning

3. Q-learning의 활용 - Q-network

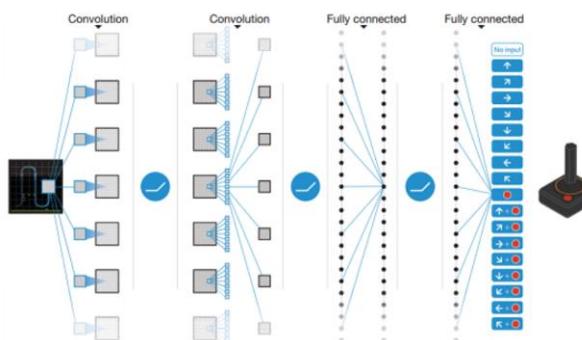


4. DEEP Q-NETWORK (DQN)

- Q Learning이라는 강화학습 알고리즘에 Convolutional Neural Network를 적용
- Q Learning에서 특정 state에 대한 action-value function으로 CNN을 사용



 AlphaGo

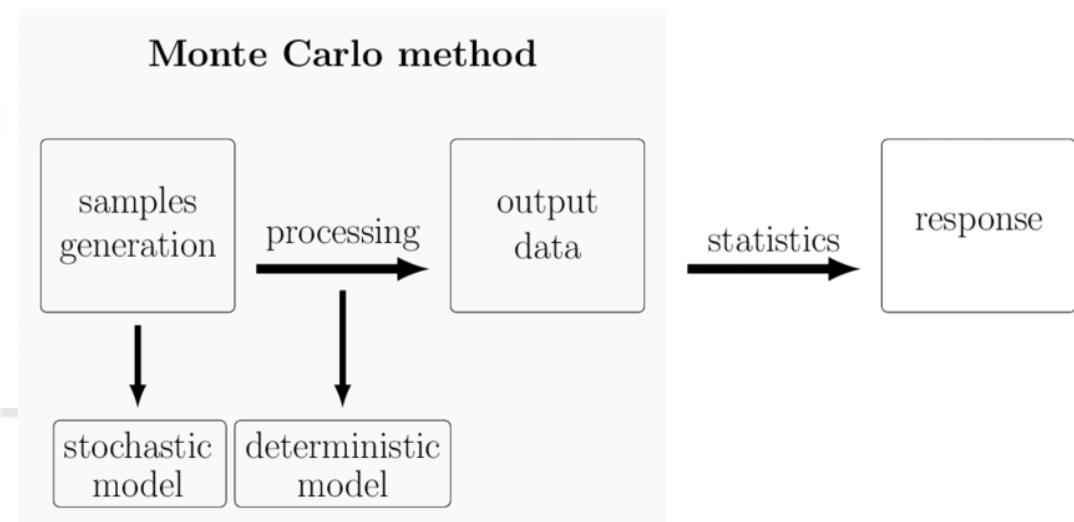
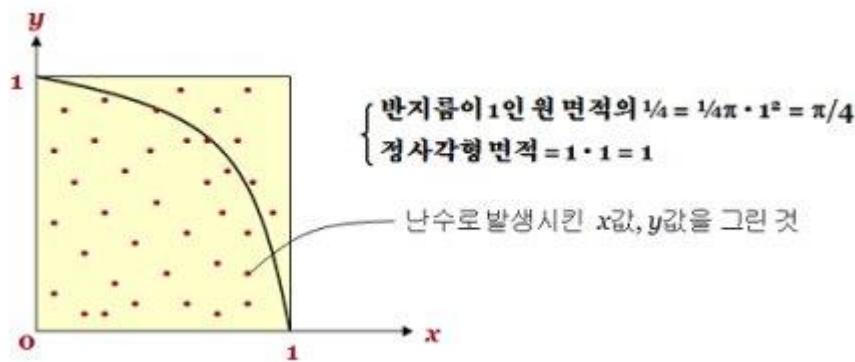


구분	설명
state	현재 상태
Action	특정 상태에서 수행 가능한 행동들
보상함수(Reward)	State 'S'에서 Action 'a'를 실행하였을 때의 보상
learning rate 'α' (알파)	0~1 사이의 실수. 학습의 결과로부터 얻어지는 강화 값의 갱신율을 조절하는 역할을 한다.
할인율 (discount rate) γ (감마)	0~1 사이의 실수. 가치함수를 수렴하도록 만드는 역할을 한다.
Q-값	<ul style="list-style-type: none"> - 기존의 Q값에 State S에서 a라는 Action을 실행하였을 때의 결과를 업데이트하는 값 - 시각이 바뀔 때마다 $Q(st, at) \leftarrow (1-\alpha) Q(st, at) + \alpha \{ rt+1 + \gamma * [Q(st+1, a t+1)] \}$가 최대가 되는 정책] }처럼 업데이트 한다.

[강화] Monte Carlo Method

1. 난수를 이용하여 함수의 값을 확률적으로 계산하는 알고리즘 Monte Carlo Method의 개요

- 시뮬레이션 테크닉의 일종으로, 구하고자 하는 수치의 확률적 분포를 반복 가능한 실험의 통계로부터 구하는 방법
- 난수의 범위와 분포에 따른 올바른 난수 생성 함수가 핵심
- 구하고자 하는 수치의 확률적 분포를 반복 가능한 실험의 통계로부터 구하는 방법



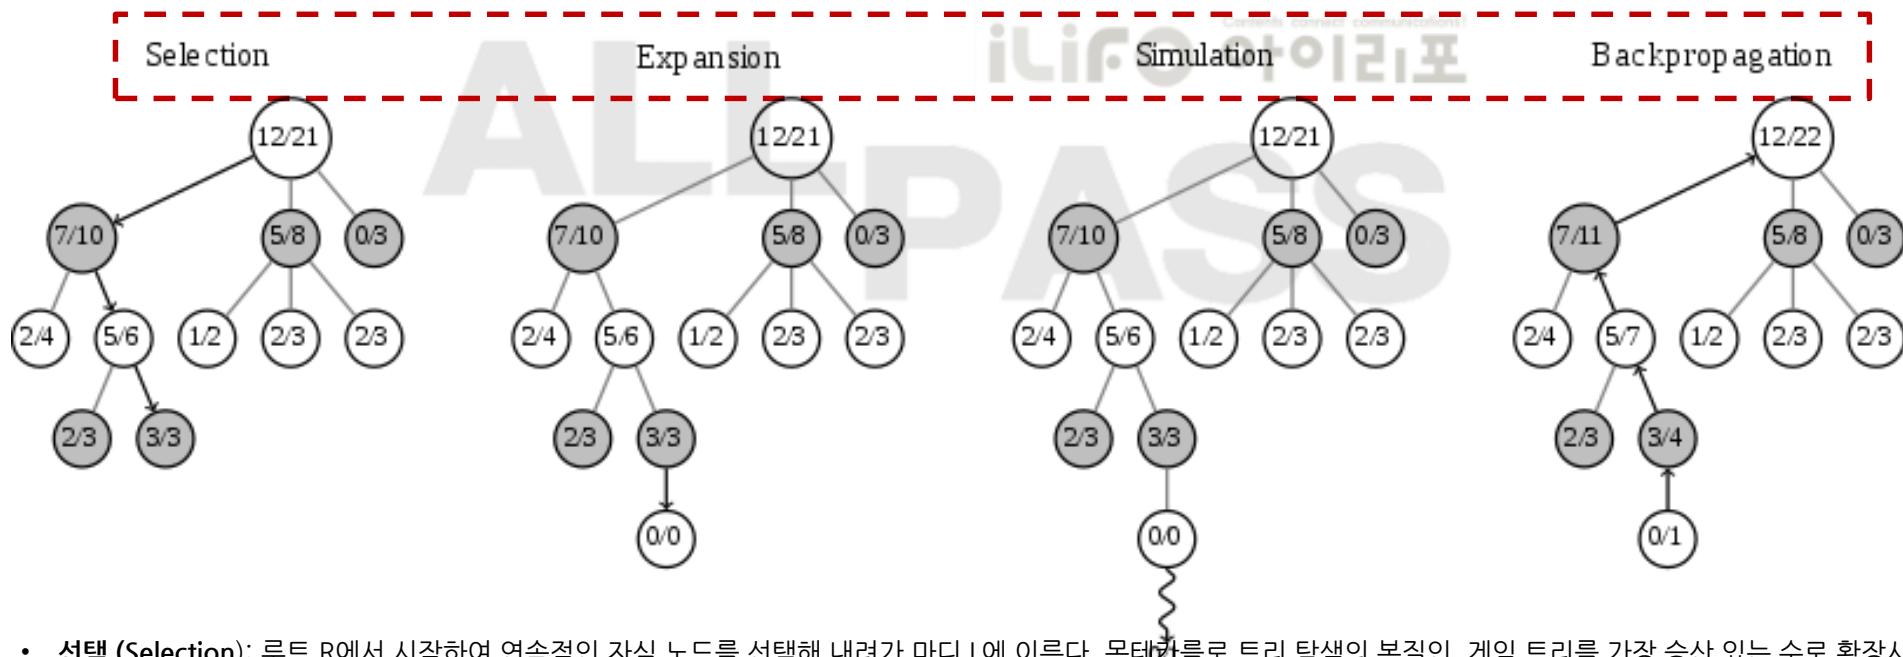


[강화] MCTS (Monte Carlo Tree Search)

1. 게임 시뮬레이션을 통해 가장 가능성성이 높아 보이는 방향으로 행동을 결정하는 탐색 방법 , MCTS 의 개요

- 검색 공간에서 무작위 추출에 기초한 탐색 트리의 노드를 확장하면서, 유망한 노드에 가중치를 부과하여, 최적의 확장을 선택하는 알고리즘
- 어떻게 움직이는 것이 가장 유망한 것인가를 분석하면서 검색 공간에서 무작위 추출에 기초한 탐색트리를 확장하는 데 중점
- 모종의 의사 결정을 위한 체험적 탐색 알고리즘**으로, 특히 게임을 할 때에 주로 적용되며. 선두적 예로 컴퓨터 바둑 프로그램이 있으나, 다른 보드 게임, 실시간 비디오 게임, 포커와 같은 비결정적 게임에도 사용

2. 몬테카를로 트리 탐색의 알고리즘 및 4단계 과정



- 선택 (Selection):** 루트 R에서 시작하여 연속적인 자식 노드를 선택해 내려가 마디 L에 이른다. 몬테카를로 트리 탐색의 본질인, 게임 트리를 가장 승산 있는 수로 확장시킬 자식 노드를 선택하는 방법은 아래 난을 참고한다.
- 확장 (Expansion):** 노드 L에서 승패를 내지 못하고 게임이 종료되면, 하나 또는 그 이상의 자식 노드를 생성하고 그 중 하나의 노드 C를 선택
- 시뮬레이션 (Simulation):** 노드 C로부터 무작위의 플레이아웃을 실행한다.
- 역전달 (Backpropagation):** 플레이아웃의 결과로 C에서 R까지의 경로에 있는 노드들의 정보를 갱신한다.

유전 알고리즘

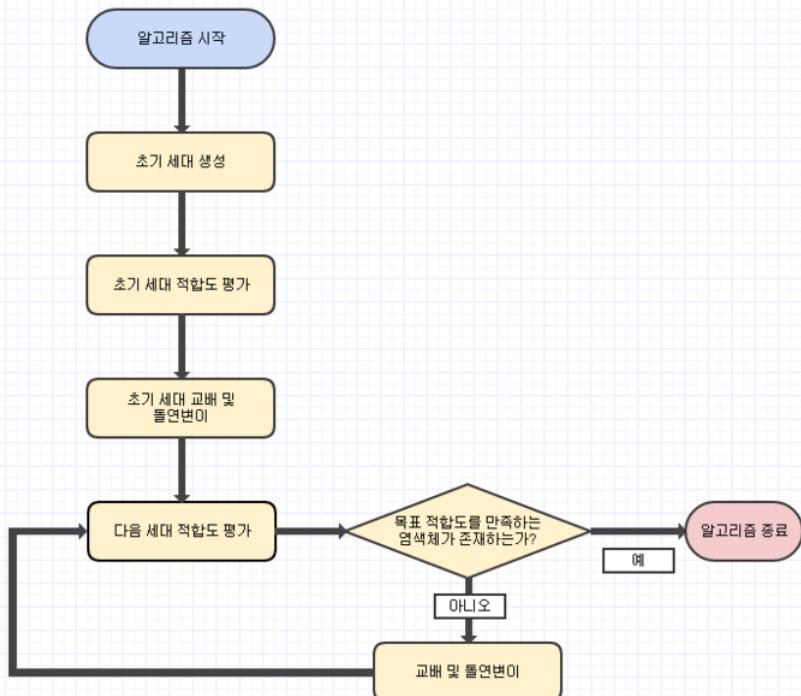
1. 유전알고리즘

- 풀고자 하는 문제에 대한 가능한 해들을 정해진 형태의 자료구조로 표현한 다음, 이들을 점차적으로 변형함으로써 점점 더 좋은 해들을 만들어 내는 알고리즘

2. 유전 알고리즘의 특징

- 병렬적이고 전역적인 탐색 알고리즘
- 적자생존 이론을 기본 개념을 바탕으로 함
- 특정한 문제를 풀기 위한 알고리즘이라기 보다는 문제를 풀기 위한 접근방법에 가까움

3. 유전 알고리즘의 상세



[유전연산자(적합도 평가 방법, 즉 우성을 찾는 방법)]

용어	설명
룰렛 훨	염색체의 적합도에 비례하는 만큼 룰렛의 영역은 할당한 다음 룰렛을 돌여 화살표가 가리키는 영역의 염색체 선택하는 방법 가장 많이 사용하는 기법
Ranking선택법	적합도에 따라서 순위를 할당 적합도의 크기 순서에 따라 순위를 메기고 순위에 따라 확률로 결정하는 방법
Steady-state선택법	연산마다 1개 혹은 2개 정도의 염색들만 바꾸는 방식을 기본으로한 선택법
Tournament선택법	n개의 개체 선택을 위해 n개의 Tournament를 구성, 각 Tournament의 K개의 성분그룹에서 가장 큰적합도를 선택하고 나머지를 제거
Elitism선택법	가장 높은 적합도만 살린다

[교배연산자]

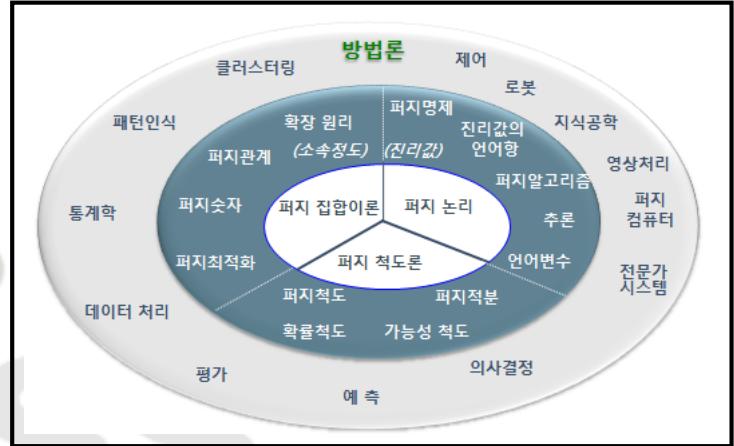
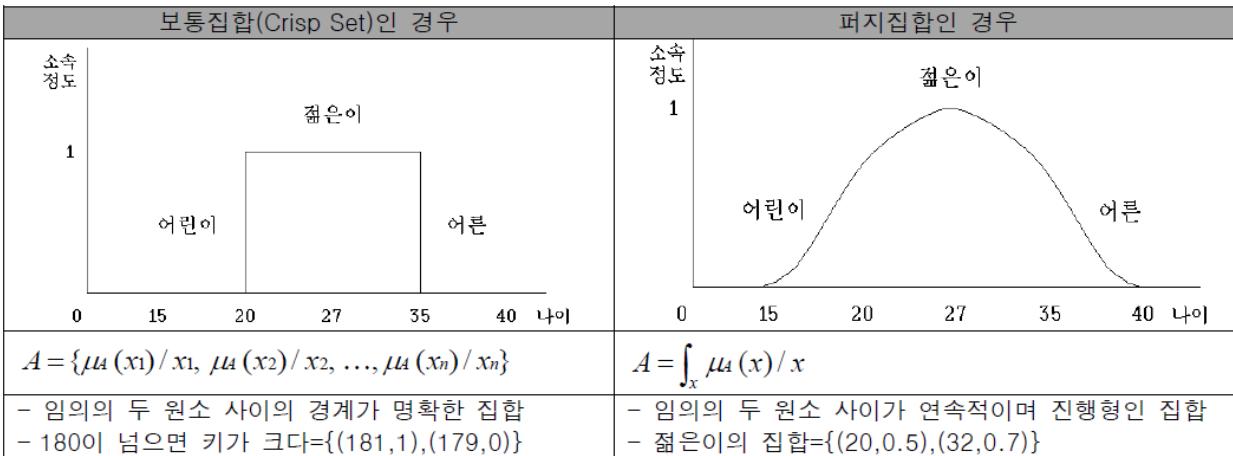
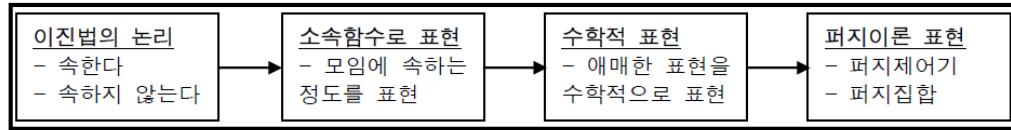
용어	설명
단순교배	부모염색체 개의 교배 (교배점은 랜덤)
이점 교배	정보 유지를 위해 많이 사용하는 방법
단일 교배	여러부분에 교배점을 찾아야 하는 경우 사용
역위	부모와 다른 형질의 자식을 생성하는 기술

퍼지 (Fuzz)

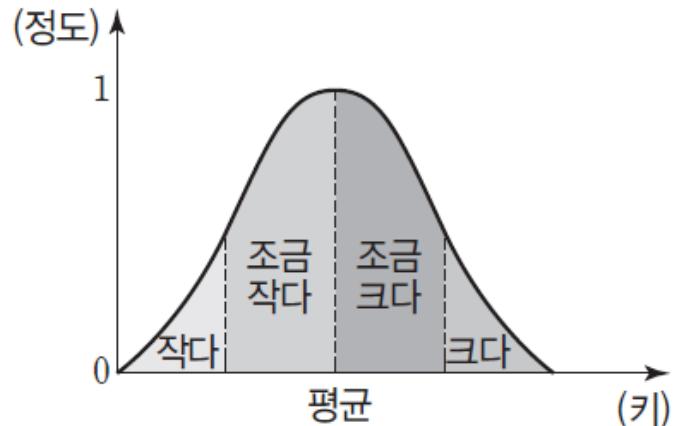
1. 인공지능의 불확실성 연구, 퍼지 이론의 개요

- 인간의 언어 및 사고 표현 시, **애매함(fuzziness)**을 수리적으로 다룰 수 있도록 해주는 인공지능의 불확실성을 다루기 위한 이론
- 패턴인식, 의미정보전달, 추상화 등에 중요한 역할

2. 퍼지이론의 표현방식



퍼지 이론의 적용

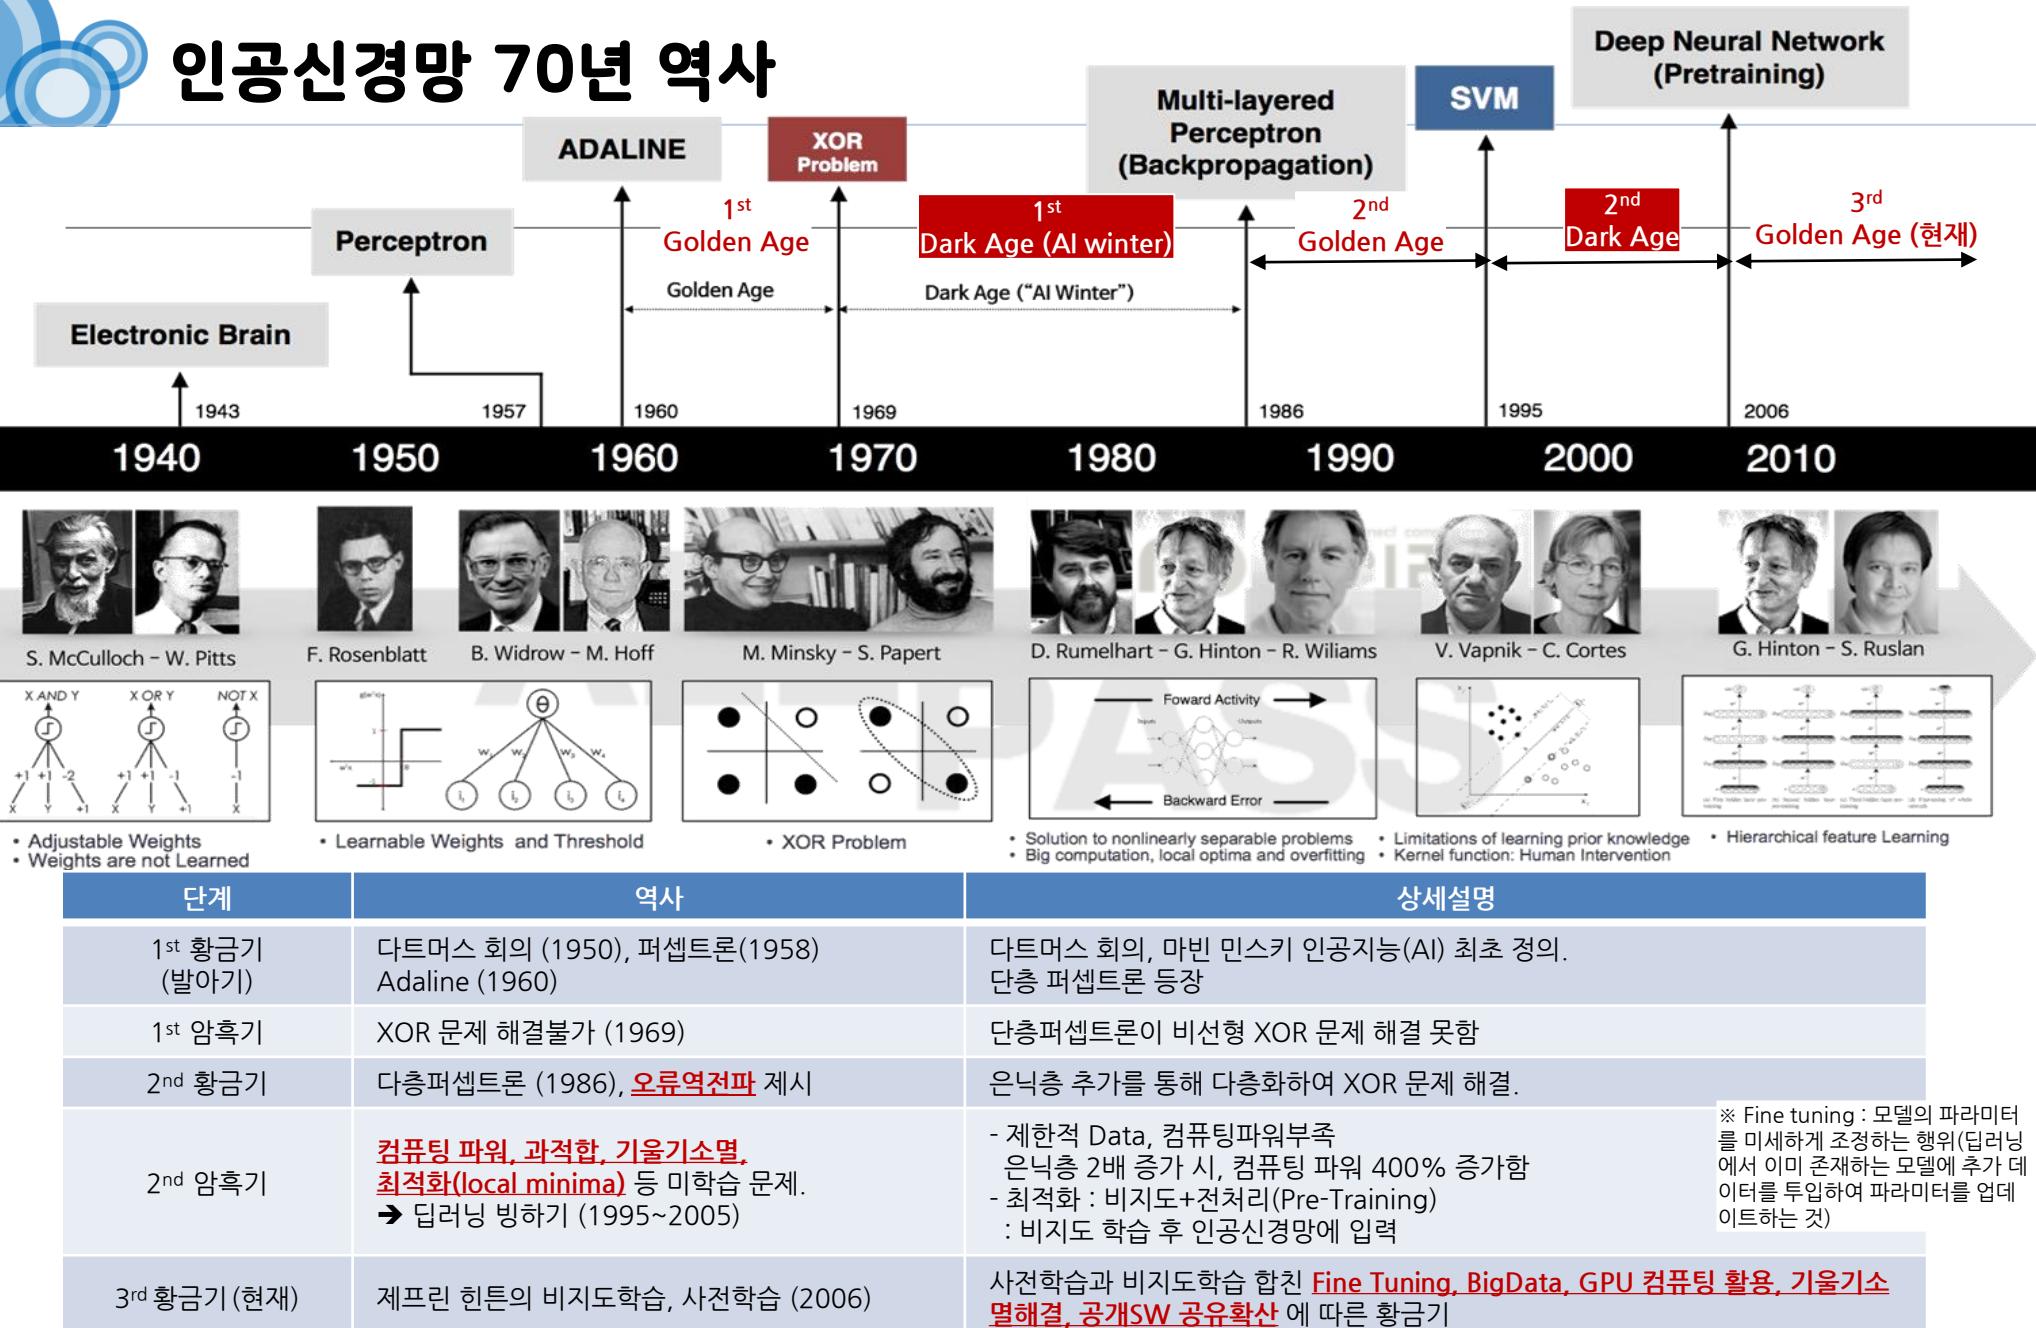




인공신경망



인공신경망 70년 역사

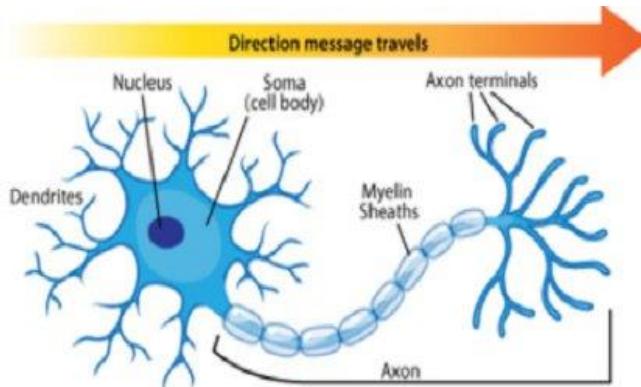




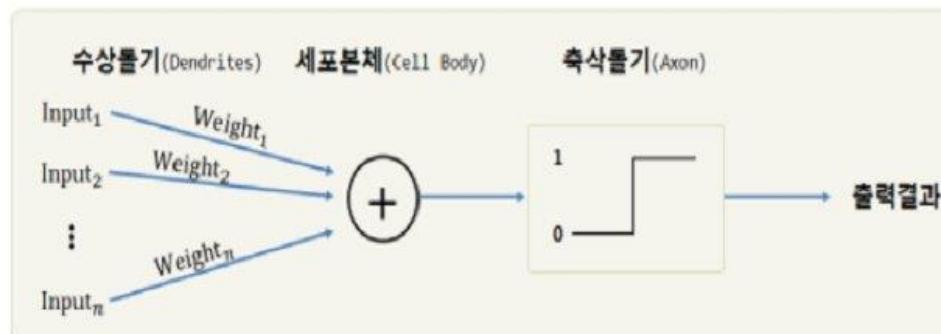
신경망 알고리즘(Neural Network Algorithm)

1. 신경망 알고리즘(Neural Network Algorithm) 개요

- 생물학의 신경망의 모델로 한 알고리즘으로 시냅스로 연결된 뇌의 뉴런 간의 정보 교환 방식을 모방하여 만들어진 알고리즘
 - 특정 뉴런에 신호가 입력되면 그 뉴런은 시냅스에 의해 연결된 다른 노드로 신호를 전달하고 이러한 과정이 계속되어 뇌는 새로운 것을 학습하게 된다는 이론에 기초
 - 신경세포가 연결되어 뇌를 구성하는 것처럼 신경망은 뇌의 신경세포에 해당하는 노드하고 하는 작은 요소들을 연결해 만든 네트워크
 - 뇌의 동작원리 중에서 가장 중요한 신경세포들의 연결관계를 신경망의 노드들의 연결 가중치로 흡내 내어 는 방법



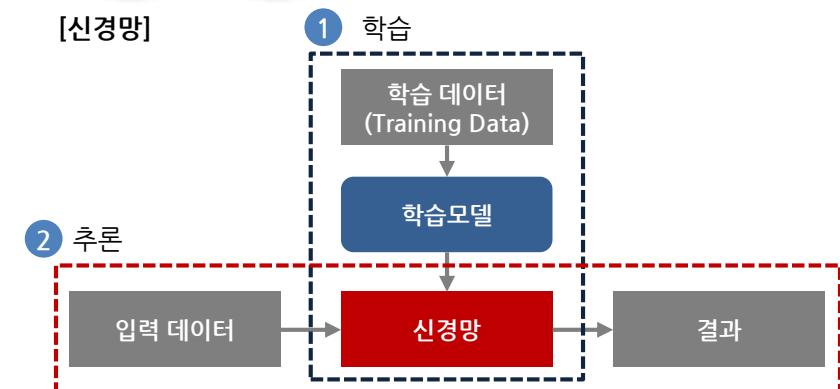
乞食記



119

뇌	신경망
신경세포	노드
신경세포들의 연결관계	연결 가중치

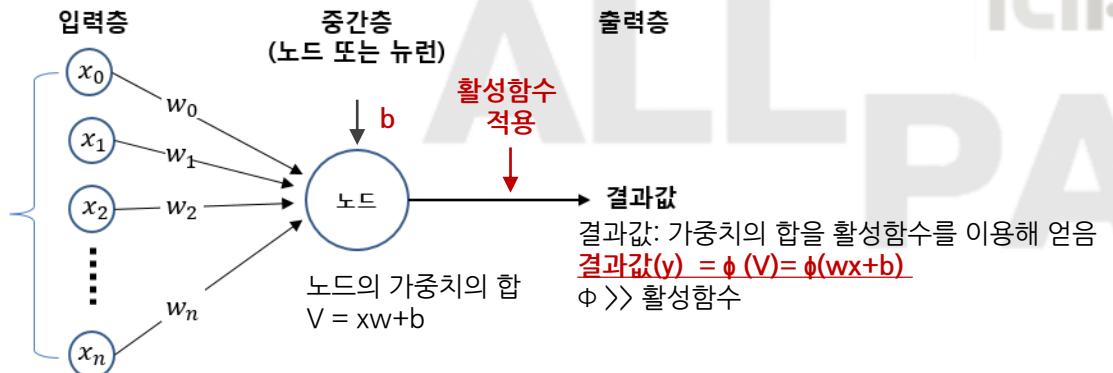
[신경망]



퍼셉트론(Single Layer Perceptron)

1. 퍼셉트론의 개요

- n개의 input에 각각 weight를 적용하여 가중치의 합을 구하거나, 선형분류를 수행할 수 있는 FeedForward 뉴럴네트워크
- 1958년 로센블래트(Rosenblatt)가 제안
- n개의 input에 각각 weight를 적용하여 가중치의 합을 구하는 형태(선형 결합), 입력과 출력으로 구성
- TLU(Threshold logic unit) + 헵 규칙(Hebb rule)**
- 단층 퍼셉트론에서는 활성 함수가 순입력 함수의 리턴값을 기준으로 0 또는 1로 리턴한 값과, 실제 결과값을 임계값을 기준으로 0 또는 1로 리턴한 값을 비교하여 가중치를 업데이트 하도록 하거나 결과를 출력
- 단층 퍼셉트론의 경우 XOR의 비선형 분류를 해결하지 못함



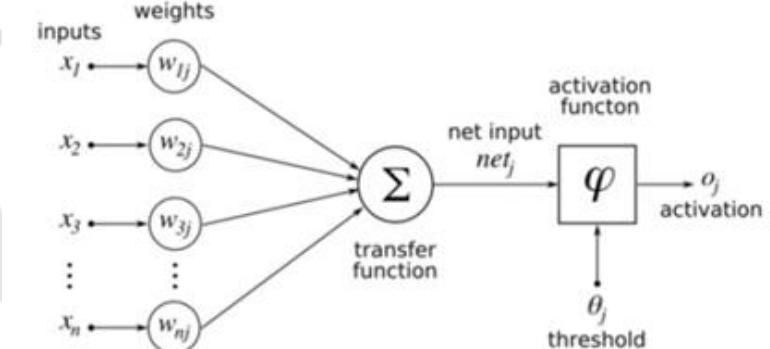
- 활성화 함수 (Activation Function)
 - 일정크기(θ)이상의 신호가 올 경우 값을 전달
 - 계단함수 대신 Sigmoid 함수나 tanh함수 또는 ReLU함수를 사용.

AND / OR Perception 예

- AND : $y = 0.6x_1 + 0.6x_2$ 이고 $\theta = 1$
- OR : $y = 1.2x_1 + 1.2x_2$ 이고 $\theta = 1$

→ 적당한 가중치를 알아내는 학습이 필요함

김미경 정보관리기술사(mayching1106@naver.com)



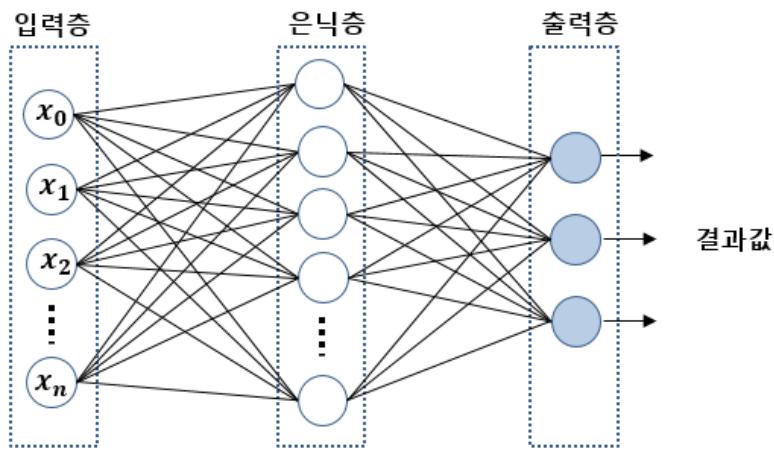
x_1	x_2	y
0	0	0
0	1	0
1	0	0
1	1	1

(w_1, w_2, θ) 이 ($0.5, 0.5, 0.8$) 인 경우

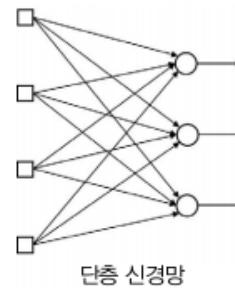
$$\begin{array}{lll} 0 \cdot 0.5 + (0 \cdot 0.5) = 0.0 & \left\{ \begin{array}{l} \leq 0.8 \\ \geq 0.8 \end{array} \right. & \rightarrow 0 \\ (0 \cdot 0.5) + (1 \cdot 0.5) = 0.5 & \left\{ \begin{array}{l} \leq 0.8 \\ \geq 0.8 \end{array} \right. & \rightarrow 0 \\ (0 \cdot 0.5) + (0 \cdot 0.5) = 0.5 & \left\{ \begin{array}{l} \leq 0.8 \\ \geq 0.8 \end{array} \right. & \rightarrow 0 \\ (1 \cdot 0.5) + (1 \cdot 0.5) = 1.0 & \left\{ \begin{array}{l} \leq 0.8 \\ \geq 0.8 \end{array} \right. & \rightarrow 1 \end{array}$$

AND 게이트의 값을 만족한다.

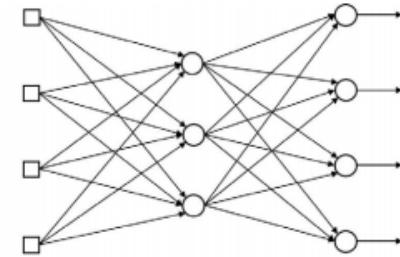
퍼셉트론(Single Layer Perceptron)



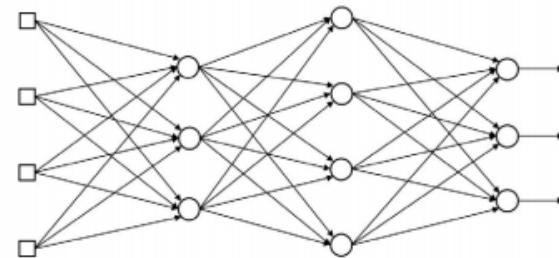
단층 신경망	입력층-출력층
다층 신경망	얕은 신경망 ¹
	입력층-은닉층들-출력층



단층 신경망



얕은 신경망



심층 신경망

- 입력층은 가중치의 합이나 활성함수 계산하지 않음
- 은닉층 ; 입력층과 출력층 사이에 존재 하는 계층
신경망 외부에서 이 계층의 노드들에 직접 접근할 수 없어서 명명됨
- 은닉층의 개수에 따라 신경망을 나누는 이유는 신경망의 발달(역사)와 관련되어 있음

퍼셉트론(Single Layer Perceptron)의 한계

1. 비선형 분리 불가능, 퍼셉트론의 한계

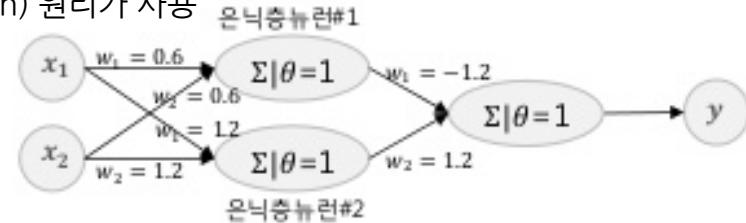
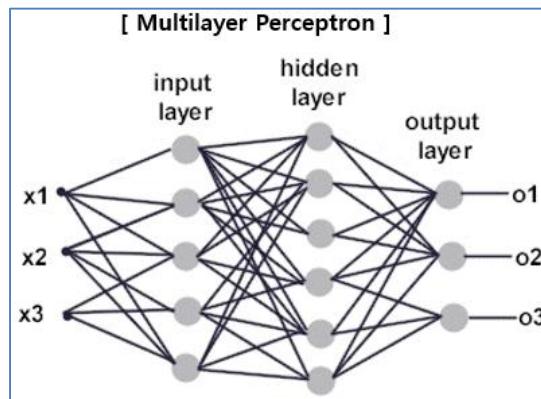
- 단층 신경망은 선형분리 가능한 문제만 해결 가능하고 비선형 문제 해결 불가능 (ex. XOR 학습 불가능한 문제 존재)
- 단층 신경망의 한계를 극복하려면 신경망의 계층을 늘려 다층구조로 늘려야 함
- 다층 신경망의 학습 규칙을 찾지 못해서 머신러닝의 발전이 정체가 됨
- 델타 규칙으로 은닉층을 학습 시켜야 하는데 은닉층은 오차가 정의되지 않아 은닉층을 학습 시킬 수가 없음
- 단층퍼셉트론 층을 하나 더 쌓은 다층 퍼셉트론으로 이를 구현 할 수 있는데 이는 간단히 AND, NAND, OR 게이트를 조합함으로써 만들 수 있음

항목	진리표	설명															
AND	<p>AND 진리표</p> <table border="1"><thead><tr><th>A</th><th>B</th><th>Output</th></tr></thead><tbody><tr><td>0</td><td>0</td><td>0</td></tr><tr><td>0</td><td>1</td><td>0</td></tr><tr><td>1</td><td>0</td><td>0</td></tr><tr><td>1</td><td>1</td><td>1</td></tr></tbody></table>	A	B	Output	0	0	0	0	1	0	1	0	0	1	1	1	<p>AND</p>
A	B	Output															
0	0	0															
0	1	0															
1	0	0															
1	1	1															
OR	<p>OR 진리표</p> <table border="1"><thead><tr><th>A</th><th>B</th><th>Output</th></tr></thead><tbody><tr><td>0</td><td>0</td><td>0</td></tr><tr><td>0</td><td>1</td><td>1</td></tr><tr><td>1</td><td>0</td><td>1</td></tr><tr><td>1</td><td>1</td><td>1</td></tr></tbody></table>	A	B	Output	0	0	0	0	1	1	1	0	1	1	1	1	<p>OR</p>
A	B	Output															
0	0	0															
0	1	1															
1	0	1															
1	1	1															
XOR	<p>XOR 진리표</p> <table border="1"><thead><tr><th>A</th><th>B</th><th>Output</th></tr></thead><tbody><tr><td>0</td><td>0</td><td>0</td></tr><tr><td>0</td><td>1</td><td>1</td></tr><tr><td>1</td><td>0</td><td>1</td></tr><tr><td>1</td><td>1</td><td>0</td></tr></tbody></table>	A	B	Output	0	0	0	0	1	1	1	0	1	1	1	0	<p>XOR ?</p>
A	B	Output															
0	0	0															
0	1	1															
1	0	1															
1	1	0															

다층 퍼셉트론(multilayer Perceptron, MLP)

1. 다층 퍼셉트론의 개요

- 퍼셉트론의 XOR의 한계를 개선**한, 여러 개의 퍼셉트론을 층 구조로 구성한 신경망 모델
- 경사하강법(Gradient Descent)과 오차역전파법(Backpropagation) 원리가 사용



입력 x1	입력 x2	온닉층 뉴런#1	온닉층 뉴런#2	y
0	0	0	0	0
0	1	0	1	1
1	0	0	1	1
1	1	1	1	0

[온닉층 뉴런#1은 AND연산, 온닉층 뉴런#2는 OR연산, 출력층은 XOR연산]

2. 다층 퍼셉트론의 문제

- 신경망의 깊이가 깊을수록 성능이 떨어짐
- 원인: 신경망이 제대로 학습되지 않았기 때문 (역전파 알고리즘으로 해결)

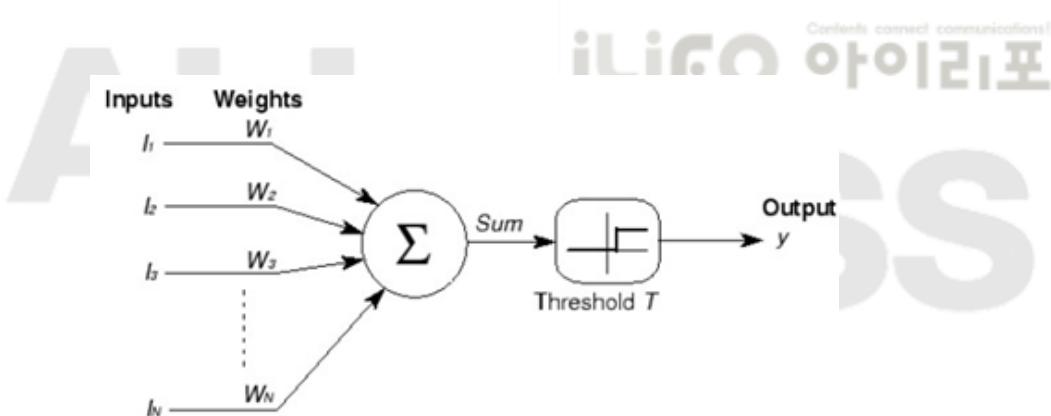
그러면, 온닉층을 어떻게 학습시킬 것인가?
역전파 알고리즘으로!

문제점	상세설명	해결방법
그라이언트 소실	역전파 알고리즘으로 심층 신경망을 학습 시키는 과정에서, 출력층에서 멀어질수록 신경망의 출력오차가 반영되지 되지 현상	ReLU
과적합	온닉층이 늘어나면서 연결가중치도 많아져 더 복잡하기 때문	Drop Out
많은 계산량	온닉층이 많을 수록 연결 가중치가 기하급수적으로 늘어나고 학습데이터도 많이 필요하게 되므로 계산량이 증가함 계산량이 많이 증가하면 학습 시간도 같이 증가	GPU 등 HW 성능 향상 으로 해결

헵 규칙(Hebb rule)

1. 인공신경망의 가중치 개념을 가질 수 있게 한 이론, 햅규칙의 개론

- 두 개의 뉴런 A, B가 서로 반복적이고 지속적으로 점화(firing)하여 어느 한쪽 또는 양쪽 모두에 어떤 변화를 야기한다면 상호 간의 점화의 효율(weight)은 점점 커지게 된다는 이론 (가중치가 높으면 관계가 상호간 연관성이 높아짐)
- 신경망에서의 학습은 특정한 응용 목적에 적합하도록 뉴런 간의 연결강도를 적응시키는 과정임 (weight update)
- 1949년 캐나다의 심리학자인 Donald Hebb은 그의 저서인 'The Organization of Behavior'에서 '헵의 시냅스'라고 알려진 시냅스의 연결강도 조정을 위한 생리학적 학습 규칙을 기술
- 신경망 모델의 학습 규칙의 토대가 됨



2. 햅규칙의 의의

- 인공신경망의 가중치 개념의 도입
- 신호 전달 시 반복적 또는 지속적으로 신호가 자극되며 따라, 뉴런A에서 뉴런B로 가는 경로인 시냅스 **연결 강화**

아달라인(Adaptive Linear Neuron: Adaline), 델타규칙

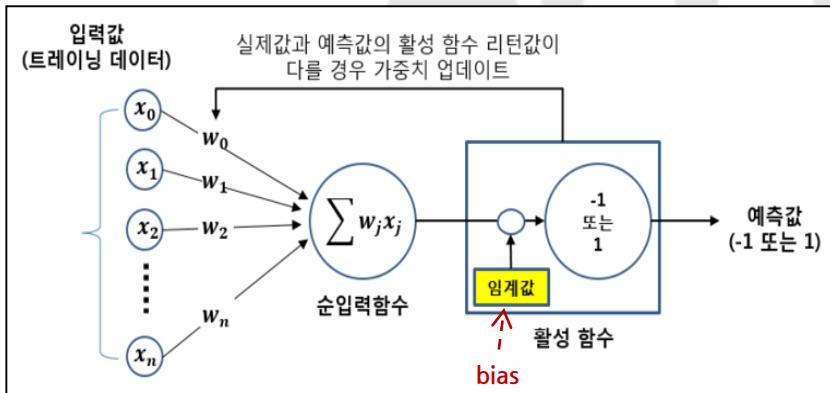
가중치 업데이트

1. 퍼셉트론의 학습규칙(신경망의 가중치를 변경하는 방법), 아달라인의 개요

- 단층신경망에서 적당한 가중치를 알아내기 위해 출력층의 출력값의 오차에 비례해 가중치를 조절하는 인공신경망 알고리즘
- 분류(classification)를 위한 보다 발전된 머신러닝 알고리즘인 회귀(regression), 로지스틱 회귀(logistic regression), SVM(Support Vector Machine)에 대한 알고리즘의 토대를 마련(역전파 알고리즘의 기본 이론)
- 퍼셉트론과 아달라인의 차이점은 바로 가중치 업데이트를 위한 활성 함수(Activation Function)가 다름.
- 최소제곱법을 이용한 비용함수(cost function) $J(w)$ 를 아래와 같이 정의하였고, $J(w)$ 값이 최소가 되도록 가중치를 업데이트 하는 것이 핵심
- 1960년 Benard windorow, Tedd hoff에 의해 Perceptron의 성능 개선
- 델타규칙(Delta rule)이라고도 함,

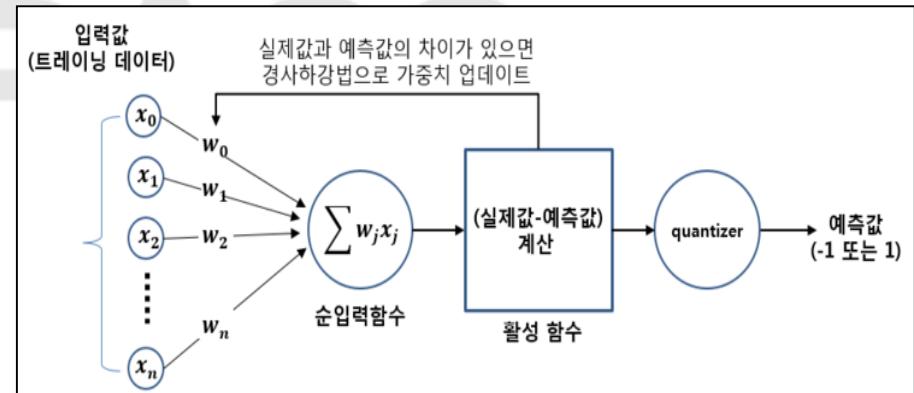
[학습규칙]
주어진 정보에 맞춰 가중치를 체계적으로 변경하는 방법

[퍼셉트론]



활성 함수가 순입력 함수의 리턴값을 임계값을 기준으로 1 또는 -1로 리턴한 값과, 실제 결과값을 임계값을 기준으로 1 또는 -1로 리턴한 값을 비교하여 가중치를 업데이트하도록 하거나 결과를 출력

[아달라인]

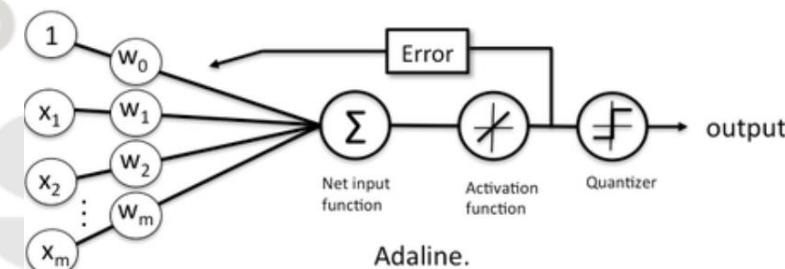
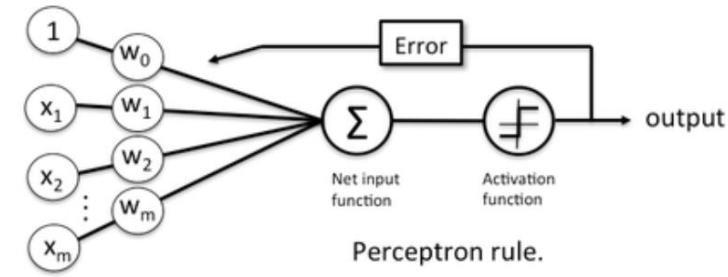


순입력 함수의 리턴값과 실제 결과값을 비교하여
이 오차가 최소가 되도록 가중치를 업데이트하는 기능을 활성 함수가 수행

아달라인(Adaptive Linear Neuron: Adaline), 델타규칙

2. 퍼셉트론과 아달라인의 비교

Model	Perceptron	Adaline
학습방향	Feed Forward (전방향 네트워크)	Feed Forward (전방향 네트워크)
학습층(layer)	1개 input layer 1개 output layer	N개 input layers 1개 output layer
입력값유형	이진값	이진값
학습방법	계단함수형(Hard Limiter)	지도학습
학습알고리즘	Hebb의 규칙	Gradient Descent
활용	- 간단한 로직연산 - 패턴분류	- 간단한 로직연산 - 회귀, SVM, 로지스틱 회귀





경사 하강법(Gradient Descent Method)

미분을 이용한 Cost Function
최소값 찾기

Cost function

가중치 조정

편미분

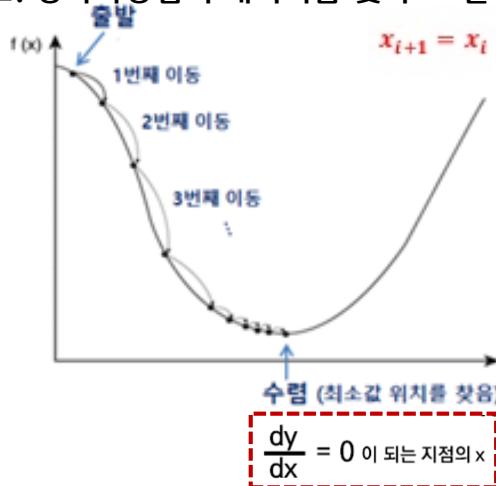
학습율

1. 신경망의 연결 가중치 조절하는 방법, 경사하강법의 개요

- 함수의 최소값의 위치를 찾기 위해 경사가 하강하는 방향을 관찰하고 그 쪽으로 조금씩 이동해가면서 가중치를 조정 하는 기법
- 비용함수(손실함수) 즉 결과가 오차가 주어지는 함수에서 최솟값을 찾아가는 과정
- 코스트 함수(Cost Function)의 최소값을 찾는 옵티마이저 Optimizer의 한 유형 (Global Minimum)
- 신경망의 연결 가중치 최적화를 위해 여러함수의 경사(여러함수 미분)가 하강하는 방향을 관찰하고 그 쪽으로 조금씩 이동해가면서 검토를 반복하는 기법 (손실함수의 값을 가장 작게 하는 Cost Function)
- cost function 을 편미분을 통해 최적의 값을 찾아 가는 과정

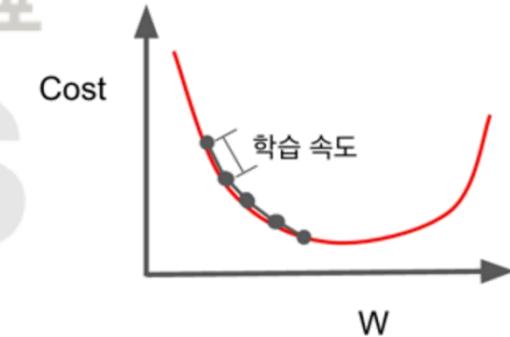
손실함수의 미분: 가중치 매개변수 값을 아주 조금 변화시켰을 때 손실함수가 어떻게 변하는가?

2. 경사하강법의 매커니즘 및 주요 변수



- 임의의 변수 초기값을 설정
- 변수 값에 해당하는 경사도(기울기) 계산
- 변수를 경사방향으로 움직여 다음 기울기 계산
- 1~3 단계를 반복하여 함수의 최소값이 되는 값을 찾음

- 먼저 변수의 초기값을 설정
 - 변수 값에 해당하는 함수의 경사도 계산
 - 변수를 경사 방향으로 움직여 다음 숫자값으로 설정
- a~c를 반복하며 함수의 최솟값이 되는 변수값으로 극점해 나간다.



*편미분을 활용하여 기울기를 산정하고, Learning Rate 을 통해 발산과 이동적정성을 확보

변수	주요변수	설명
x	변수 (가중치)	각 연결의 가중치 (구하고자 하는 값)
f	함수	데이터 분포에 입각한 산출 함수
$\frac{\partial f}{\partial x}$	함수의 경사	가중치 x 에 대한 편미분 수행 기울기 산정
ϵ	움직임의 정도	학습율(Learning Rate) 발산을 방지하고 기울기 이동 값을 조정

- 학습률이 너무크면 손실함수값이 줄어들지 않고 더 커지는 오버슈팅(overshooting) 현상이 발생

경사 하강법(Gradient Descent Method)

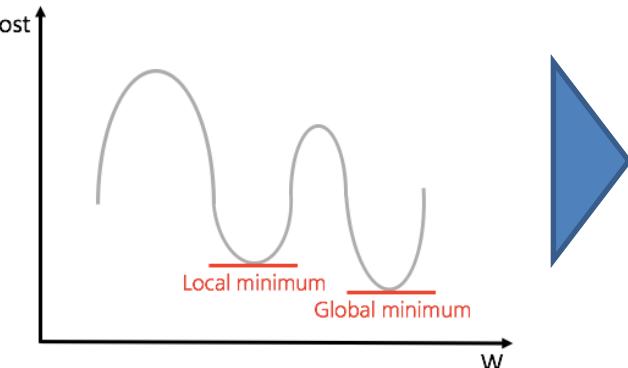
3. 경사하강법의 종류

종류	설명
배치 GD	<ul style="list-style-type: none">모든 학습 데이터의 오차에 관해 가중치 갱신값을 계산한 다음 이들의 평균값으로 가중치를 다시 한번 갱신하는 방법전체 학습 데이터를 쓰고, 가중치는 한번만 갱신학습 데이터의 양이 많은 경우 가중치 갱신값의 평균을 계산하는데 시간이 많이 소요됨, 가중치 갱신도 느려져서 학습 시간이 오래 걸림
확률적 경사 하강법 (Stochastic GD)	<ul style="list-style-type: none">하나의 학습 데이터마다 오차를 계산하여 신경망의 가중치를 바로 조정한 개의 학습 데이터마다 매번 가중치를 갱신함으로 신경망의 성능이 빠르게 향상단점 : 최적의 학습율을 구하기 위해 튜닝 필요.. 학습 데이터를 순차적으로 사용해야 함 (병렬컴퓨팅의 효과를 얻기 어려움)
미니 배치	<ul style="list-style-type: none">훈련 데이터에서 소량의 데이터를 적당히 선택해 학습 후 갱신 처리를 수행경사하강법과 배치방식을 섞어 놓은 개념전체 학습 데이터 중 일부 데이터만 골라서 배치 하는 방법일부 학습 데이터의 가중치를 갱신값으로 계산하다음, 이 값들의 평균 값으로 가중치 계산딥러닝에 많이 사용되는 방법장점 : 배치와 확률적 경사하강법의 두가지 단점을 보완하였음, GPU 기반의 효율적인 병렬 컴퓨팅이 가능해짐

- Gradient Descent는 MLP 적용 시, 학습 layer 가 깊어질수록 기울기가 소멸, 학습효과가 사라지는 Gradient Vanishing Problem 발생
- Batch Gradient, Mini-Batch Gradient의 경우 Local Minimum에 수렴할 수 있는 오류가 있음

4. 경사하강법의 문제점 및 해결 방법

- 일반적으로 Gradient descent algorithm에는 초기 포인트를 어디서부터 시작하는지, 학습률 등의 여러 상황에 따라 global minimum을 찾지 못하고 local minimum을 잡을 수도 있다는 문제점이 있음



[해결 방법]

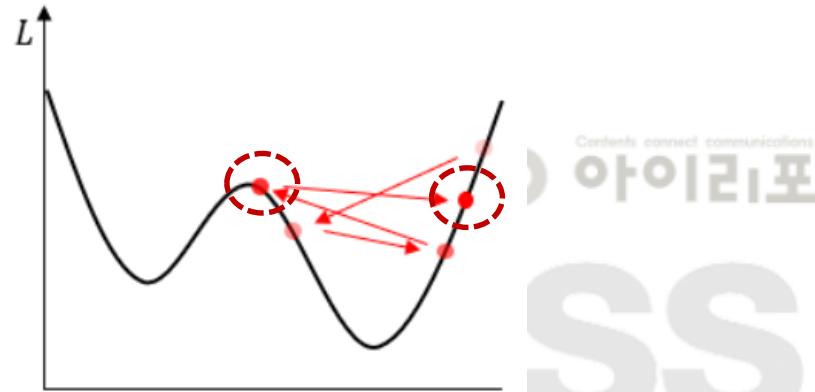
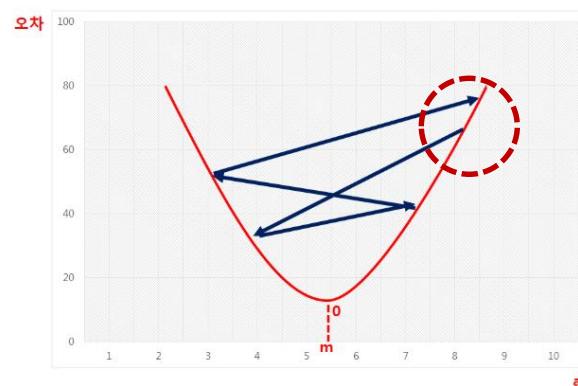
- Momentum
- Adagrad
- RMSprop
- Adam

- Gradient Descent는 MLP 적용 시, 학습 layer 가 깊어질수록 기울기가 소멸, 학습효과가 사라지는 Gradient Vanishing Problem 발생

경사 하강법(Gradient Descent Method)

3. 경사하강법에서 오버슈팅(Overshooting) 개념

- (답안용) ϵ 가 크게 설정되어 학습의 속도는 빨라지지만, 지나치게 큰 값으로 설정되어 최소값으로 수렴하지 않은 이상현상
- (이해용) 학습 속도의 값이 크다 보니, 값이 아래 골짜기로 수렴하지 않고 오히려 반대편으로 넘어가면서 점점 오히려 그래프 바깥 방향으로 발산하면서, W값이 발산을 해서 결국은 무한대로 가는 현상



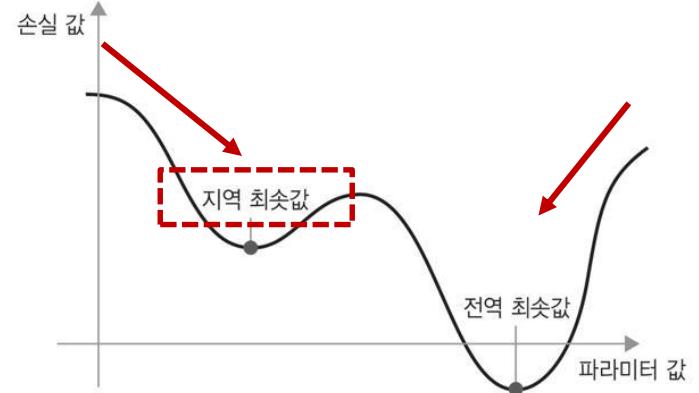
4. 경사하강법에서 오버슈팅(Overshooting)을 방지하는 방법

방지방법	개념도	설명
Momentum		<ul style="list-style-type: none">- 물리에서는 질량 * 속도- 신경망에서는 질량=1로 가정, 속도만 표시- Gradient에 스무딩을 가하여 잡음 효과를 줄임
Nesterov Momentum		다음 이동할 곳을 예전한 후 예전한 곳의 Gradient를 사용

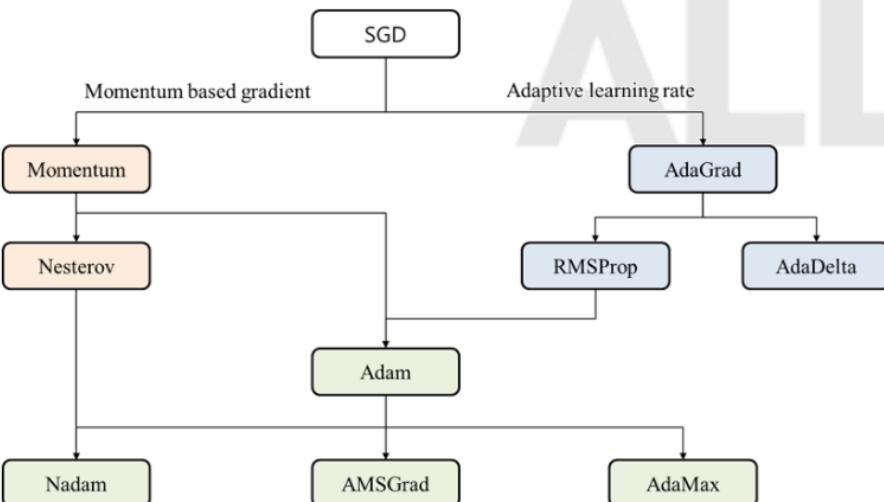
경사 하강법(Gradient Descent Method)

5. 지역 최소값(Local Minimum) 현상의 개요

- 일부 최소값에 빠져버리게 되면 최고의 성능을 내는 전역 최소값 (Global Minima)에 도달하지 못하고 학습이 멈춰버리게 되는 현상
- 이 문제는 오직 현재 위치에서의 기울기만을 이용해서 움직이는 경사 하강 법에서는 절대로 빠져나올 수가 없음. 확률적 경사 하강 법도 동일함)



6. 경사하강법에서 지역 최소점에 빠지지 않고 본래의 최소점에 도달하기 위한 기법



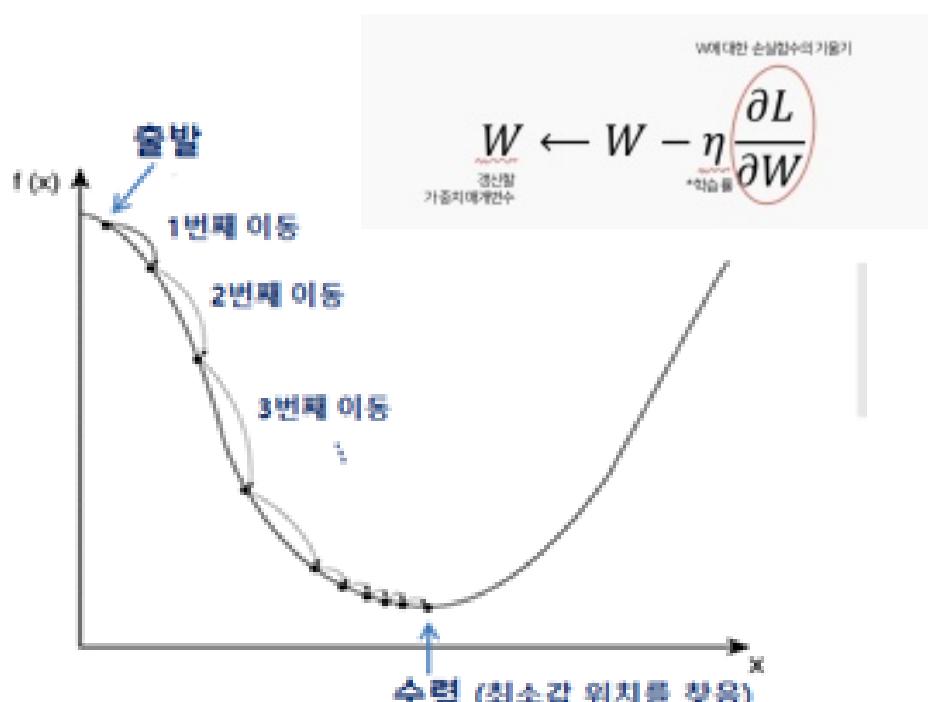
- SGD (Stochastic Gradient Decent) 기법의 알고리즘 최적화를 통해 본래의 최소점에 도달 가능**

기법	상세 설명	수식
Momentum	• 이전 시간의 gradient 까지도 고려한 계산	$v_{ij}^{(t)} = \beta v_{ij}^{(t-1)} + \eta \frac{\partial L}{\partial w_{ij}^{(t)}}$
NAG (Nesterov accelerated gradient)	• 이동을 중지할 지점에 도달해도 해당 지점을 지나치는 문제점을 해결한 기법	$v_{ij}^{(t)} = \beta v_{ij}^{(t-1)} + \eta \frac{\partial L}{\partial \hat{w}_{ij}^{(t)}}$ $\hat{w}_{ij}^{(t)} = w_{ij}^{(t)} - \beta v_{ij}^{(t-1)}$
AdaGrad (Adaptive Gradient)	• 변화가 많은 learning rate 를 작게 변화가 적은 변수들은 learning rate 를 크게 하여 빠르게 optimum 으로 수렴	$g_{ij}^{(t)} = g_{ij}^{(t-1)} + \left(\frac{\partial L}{\partial w_{ij}^{(t)}} \right)^2$ $w_{ij}^{(t+1)} = w_{ij}^{(t)} - \frac{\eta}{\sqrt{g_{ij}^{(t)}} + \epsilon} \frac{\partial L}{\partial w_{ij}^{(t)}}$
RMSProp (Root Mean Square Propagation)	• 학습이 진행될 수록 learning rate 가 극단적으로 감소하는 AdaGrad 의 문제점을 해결하기 위해 제안	$g_{ij}^{(t)} = \beta_1 g_{ij}^{(t-1)} + (1 - \beta_1) \left(\frac{\partial L}{\partial w_{ij}^{(t)}} \right)^2$ $w_{ij}^{(t+1)} = w_{ij}^{(t)} - \frac{\eta}{\sqrt{g_{ij}^{(t)}} + \epsilon} \frac{\partial L}{\partial w_{ij}^{(t)}}$
Adam (Adaptive Momentum Estimation)	• momentum 과 RMSProp 를 합친 것 알고리즘	$v_{ij}^{(t)} = \beta_1 v_{ij}^{(t-1)} + (1 - \beta_1) \frac{\partial L}{\partial w_{ij}^{(t)}}$ $g_{ij}^{(t)} = \beta_2 g_{ij}^{(t-1)} + (1 - \beta_2) \left(\frac{\partial L}{\partial w_{ij}^{(t)}} \right)^2$
AdaMax	• AdaMax는 Adam 논문에서 extension으로 제안된 알고리즘	$G_{ij}^{(t)} = \max \left(\beta_3 G_{ij}^{(t-1)}, \left \frac{\partial L}{\partial w_{ij}^{(t)}} \right \right)$ $w_{ij}^{(t+1)} = w_{ij}^{(t)} - \frac{\eta}{(1 - \beta_1^t) G_{ij}^{(t)}} v_{ij}^{(t)}$

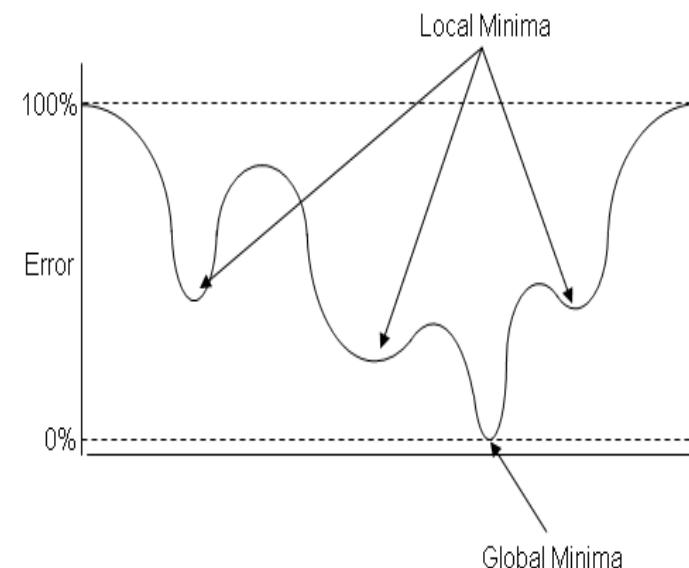
확률적 경사 하강법(SGD, Stochastic Gradient Descending)

1. 확률적 경사 하강법(SGD, Stochastic Gradient Descending)

- 매개변수의 기울기를 구해, 기울어진 방향으로 매개변수 값을 갱신하는 일을 반복하여 최적의 매개변수 값을 추출하는 기법
- 무작위로 골라낸 데이터에 대한 경사 하강 기법



(원리) 미분 이용한 SGD



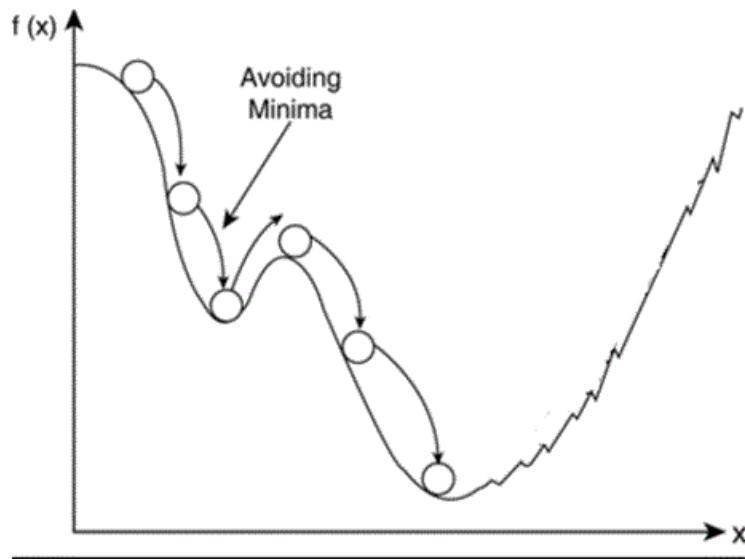
[출처 : <http://mnemstudio.org/neural-networks-multilayer-perceptron-design.htm>]

(단점) 급격한 변곡점이 있는 경우 SGD 한계

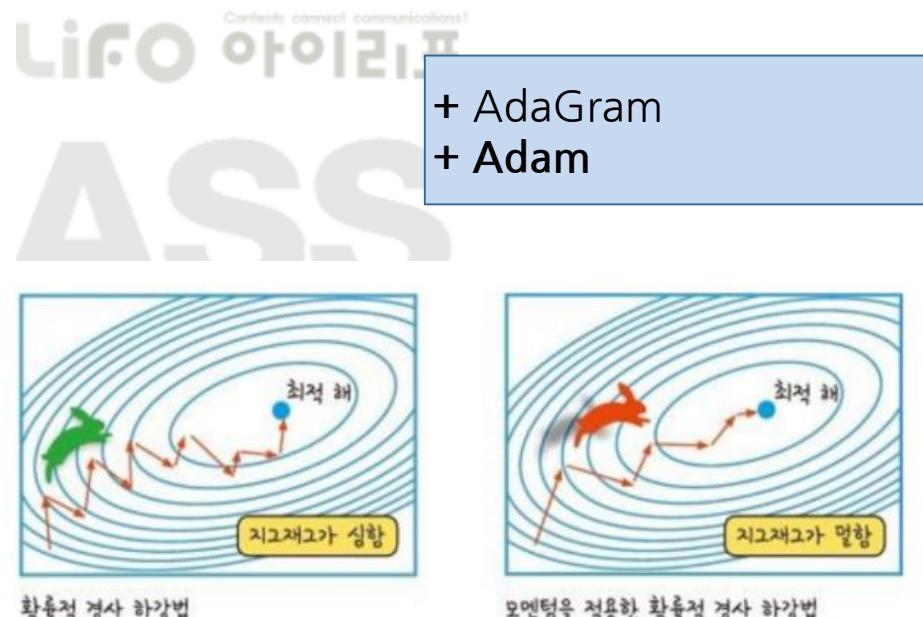
모멘텀(Momentum)

1. 모멘텀의 개요

- 기존에 **사용한 기울기의 일정 비율(%)을 현재의 기울기에 반영하는 속도(Velocity)의 개념을 적용하여 진동과 폭을 줄인 경사 하강 기법**
- 누적된 과거 그래디언트가 지향하고 있는 어떤 방향을 현재 그래디언트에 보정하려는 방식



[출처 : http://www.yaldex.com/game-development/1592730043_ch18lev1sec4.html]

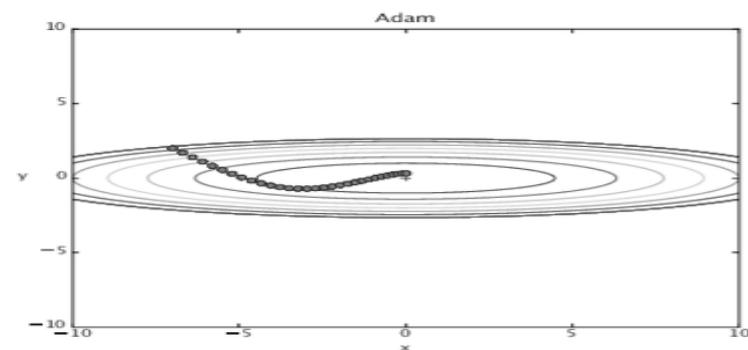
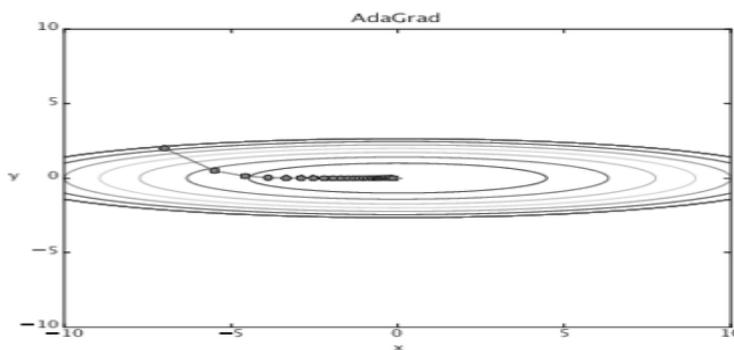
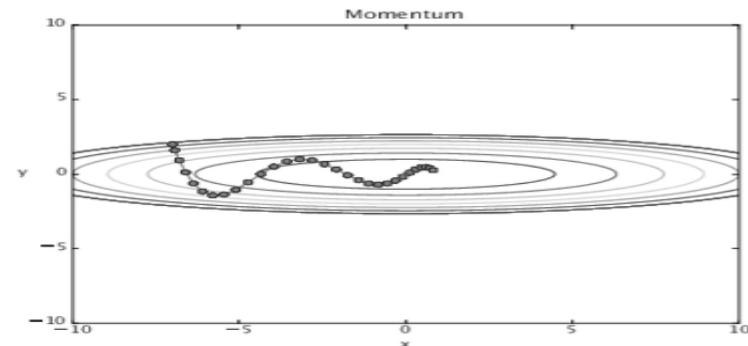
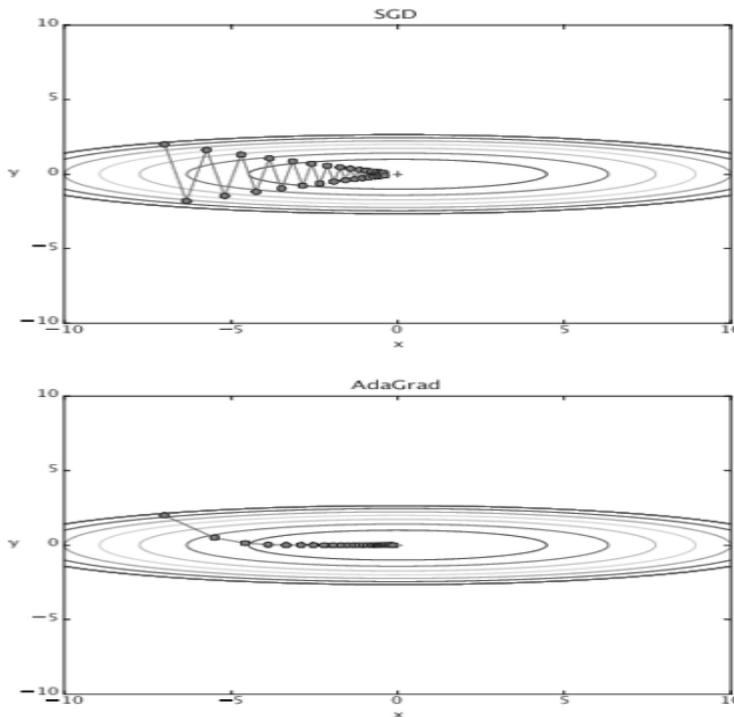


Adagrad, Adam

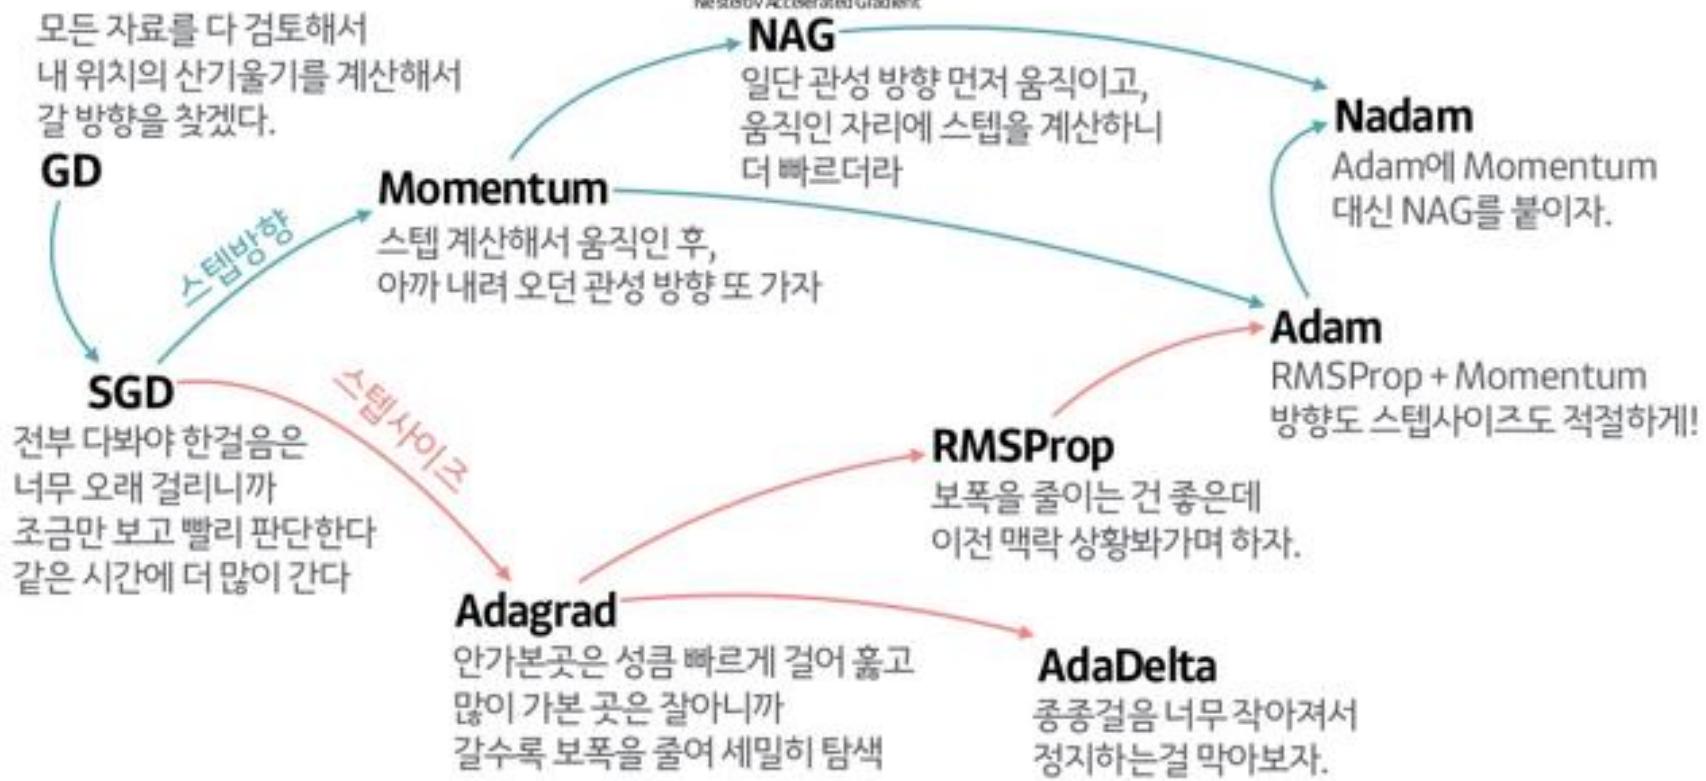
1. Adagrad (Adaptive Gradient)

- 변수의 업데이트 회수에 따라 학습률을 조절하는 옵션이 추가된 최적화 함수
- 학습률 감소(Learning rate decay) : 학습을 진행하면서 학습률을 점차 줄여가는 방법

2. Adam = 모멘텀 + Adagrad



매개변수 최적화

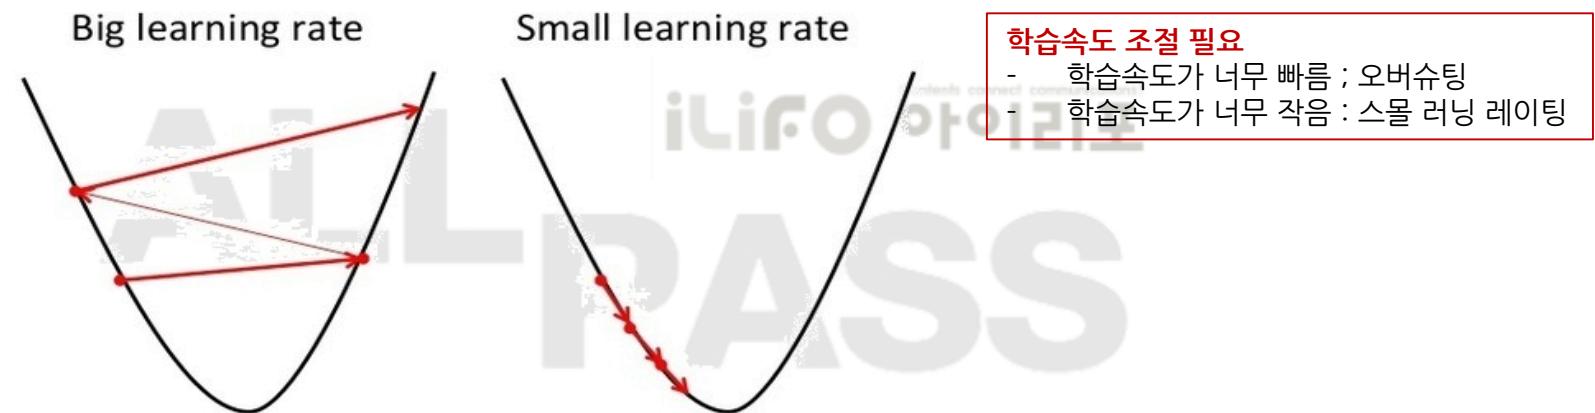


출처 <http://seamless.tistory.com/38>

학습률 (Learning Rate)

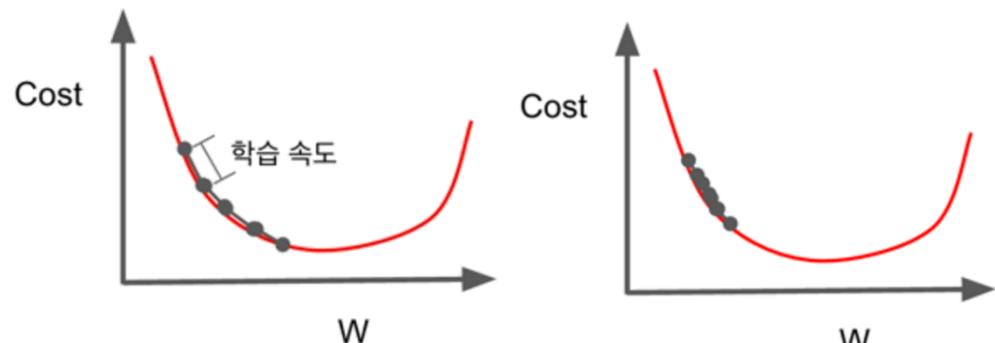
1. 학습률의 개요

- 경사하강법에서 함수의 최소값의 위치를 찾기 위한 이동하는 거리의 비율
- 경사하강법은 오차의 변화에 따라 이차 함수 그래프를 만들고, 적절한 학습률을 설정해 미분 값이 0인 지점을 구함
- 학습률과 같은 데이터를 하이퍼파라미터(Hyper Parameter)라고 함**
- 신경망의 학습에 의해서 자동으로 획득되지 않고, 사람이 직접 설정해야 함



2. 스몰 러닝 레이트(Small Learning Rate)

- 학습속도가 너무 작을 경우 아래 그림처럼, 코스트 값의 최소 값에 도달하기 전에, 학습이 끝나버리는 문제로 Small learning rate 라고 한다.



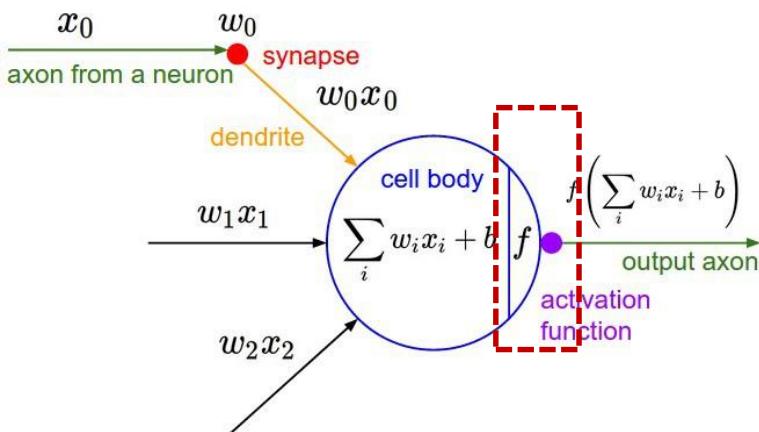


활성화 함수(Accivation Function)

1. 뉴런의 출력 결정 제한하는 함수, 활성화 함수의 개요

- 입력을 받아 활성, 비활성을 결정하는데 사용되는 함수
- 시냅스의 전기 신호 전달을 모방하여, 세타에 따라 출력값을 조정 및 다음 노드로 전달 하는 함수**
- 입력 신호의 총합을 그대로 사용하지 않고, 입력 신호의 총합이 활성화를 일으키는지 아닌지를 정하는 역할로, 입력 신호를 규칙에 따라 출력 신호로 변환하는 함수
- 전 레이어로부터(입력층 or 히든층) 온 값(간단히 $ax+b$)을 즉, 이렇게 완성된 x 라는 입력값을 활성화라는 이름의 함수에 넣어 그 그 래프에 해당하는 y 값을 출력하게 되는데 이러한 함수를 통해 나온 y 값을 보고 그 값이 어느 정도 이상이면 통과 아니면 패스 이런식으로 하는 역할
- 은닉노드의 활성함수를 선형함수로 사용할 시
은닉층을 추가한 효과가 없어짐
(단층 신경망과 같아짐)

퍼셉트론과 신경망의 주된 차이는 **활성화 함수!**



유형	도식	설명
항등함수 (identity function)		$f(\text{NET}) = \text{NET}$ <ul style="list-style-type: none"> - 양극성이며 선형 연속 함수임 - 입력의 가중합이 그대로 출력됨 회귀
경사함수 (ramp function)		$f(\text{NET}) = \begin{cases} \text{NBT} & ; \text{NBT} \geq 0 \\ 0 & ; \text{NBT} < 0 \end{cases}$ <ul style="list-style-type: none"> - 단극성이며 선형 연속 함수임
계단함수 (step function)	 $f(\text{NET}) = \begin{cases} 1 & ; \text{NET} \geq T \\ 0 & ; \text{NET} < T \end{cases}$	<ul style="list-style-type: none"> - 단극성 또는 양극성이진 함수이며, 디지털 형태의 출력이 요구되는 경우에 주로 사용됨
시그모이드 함수 (sigmoid function)	 $y = \frac{1}{1 + e^{-x}}$	<ul style="list-style-type: none"> - 단극성 또는 양극성 비선형 연속 함수이며, 신경망 모델의 활성화 함수로써 가장 널리 사용되고 있음 분류

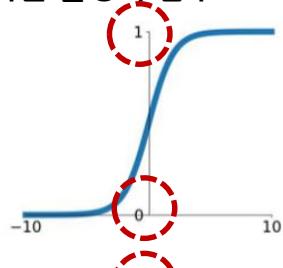
활성화 함수(Activation Function)

2. 은닉층/딥러닝에서 자주 이용하는 활성화 함수

Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

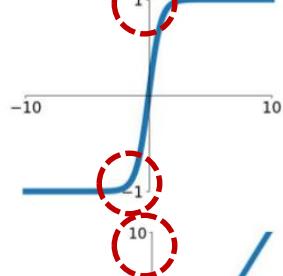
선형인 멀티퍼셉트론에서
비선형 값을 얻기 위해 사용



tanh

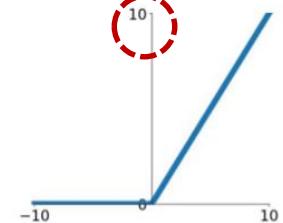
$$\tanh(x)$$

함수의 중심값을 0으로 옮겨
sigmoid의 최적화 과정이 느
려지는 문제를 해결



ReLU

$$\max(0, x)$$



- $x>0$ $x>0$ 이면 기울기가 1인 직선이고, $x<0$ $x<0$ 이면 함수값이 0이된다.
- sigmoid, tanh 함수와 비교시 학습이 훨씬 빨라진다.
- 연산 비용이 크지않고, 구현이 매우 간단하다.

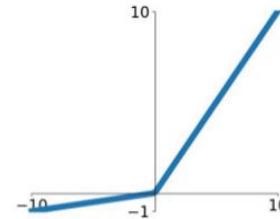
3. Activation Function의 선택 요령

ReLU	Sigmoid	Softmax
<ul style="list-style-type: none">• 무난한 선택. 특히 계층이 깊을 때.• 비선형 함수이기 때문에 자주 쓰인다.	<ul style="list-style-type: none">• 출력값이 확률값인 경우: sigmoid 함수의 범위가 0과 1 사이에 있기 때문.• 이진 분류 (0/1으로 분류)	<ul style="list-style-type: none">• Classification 문제인 경우: softmax 함수의 출력값의 합이 1이기 때문

0 이상이면 입력값을 그대로, 0 보다 작으면 매우 작은 값(예: 0.01 등)을 곱해서 출력하는 함수. ReLU에서 발생하는 dying ReLU를 보완하기 위한 함수이다. 여기서 dying ReLU이란 ReLU에서 입력이 0 이하라면 전부 0으로 출력되어서 일부 뉴런이 전혀 출력되지 않는 현상이다

Leaky ReLU

$$\max(0.1x, x)$$

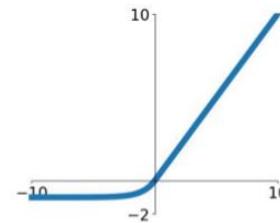


Maxout

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$

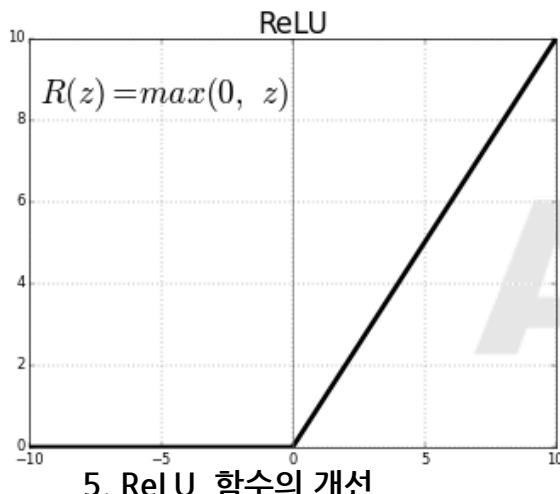


ReLU(Rectified Linear Unit)

1. ReLU(Rectified Linear Unit)의 개요

- Logistic Regression에서 학습의 효율성을 향상시키기 위해 $x < 0$ 이면 0을 출력, $x \geq 0$ 이면 무한대까지 값을 출력하는 활성화 함수

2. ReLU의 개념도



$$R = \begin{cases} (x < 0) R(z) = 0 \\ (x \geq 0) R(z) = z \end{cases}$$

입력값이 0보다 작으면 0
입력값이 0보다 크면 그대로

3. 특징

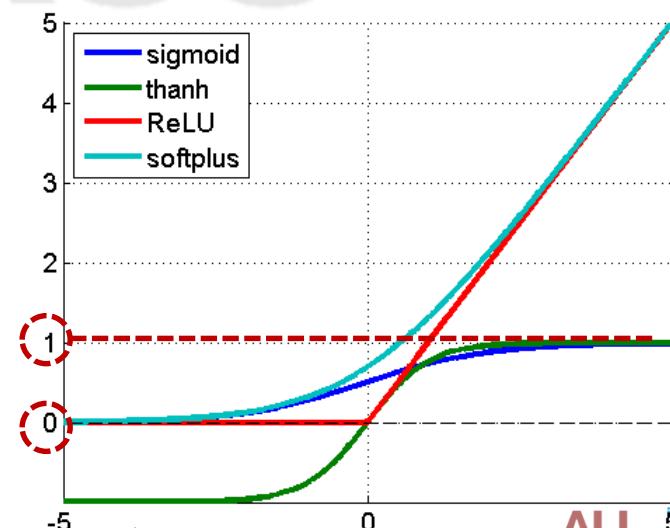
특징	설명
속도 빠름	sigmoid나 tanh 함수와 비교했을 때 SGD의 수렴속도가 매우 빠름
미분 비용	sigmoid나 tanh는 exp()에 의해 미분을 계산하는데 비용이 들지만, ReLU는 별다른 비용이 들지 않는다.(미분도 0 아니면 1)

4. ReLU 문제점

- 양 극단값이 포화되지 않고 계산이 매우 효율적이나 **중심값이 0이 아니고 입력값이 음수인 경우 항상 0을 출력해 신경망이 죽는(die) 경우가 발생**

5. ReLU 함수의 개선

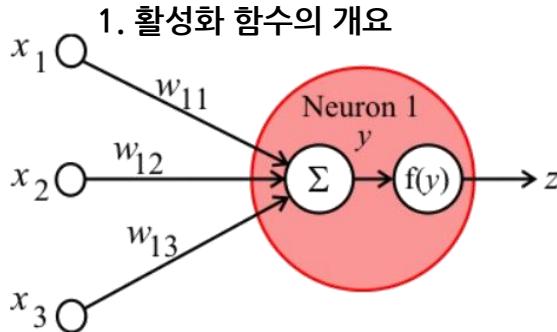
함수	설명
Leaky ReLU	Dying ReLU 현상을 해결하기 위해 제시된 함수 ReLU는 $X < 0$ 일 때 함수값이 0이지만, Leaky ReLU는 기울기 부여 $F(x) = \max(0.01x, x)$
PReLU	Leaky ReLU와 비슷하지만 파라미터 a 추가 $F(x) = \max(ax, x)$
Maxout	ReLU와 Leaky ReLU를 일반화한 모델 $f(x) = \max\left(w_1^T x + b_1, w_2^T x + b_2\right)$ ReLU의 장점 수용, Dying ReLU 문제 해결 단, 파라미터가 두 배이기 때문에 전체 파라미터가 증가





Sigmoid vs ReLU

1. 활성화 함수의 개요



- 입력 값(x)에 가중치(w)를 두어 값($f(y)$)을 구하고 그 값과 임계값의 관계를 판단하여 결과값을 출력하는 함수
- Logistic Regression에서 주로 사용하며 step, sigmoid, ReLU, tanh, softmax 등을 활성화 함수로 활용

2. sigmoid, ReLU 함수의 비교

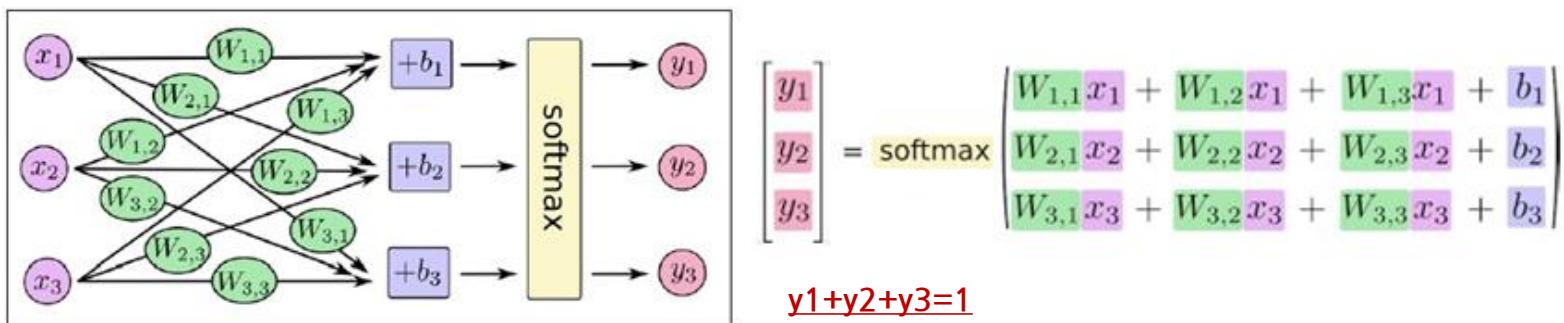
구분	sigmoid	ReLU
개념	<ul style="list-style-type: none"> Logistic Regression 수행을 위해 계단(step)함수를 대신하여 사용되는 활성화 함수 	<ul style="list-style-type: none"> Logistic Regression에서 학습의 효율성을 향상시키기 위해 < 0 이면 0을 출력, ≥ 0 이면 무한대까지 값을 출력하는 활성화 함수
개념도	<p>$\sigma(z) = \frac{1}{1 + e^{-z}}$</p>	<p>$R(z) = \max(0, z)$</p>
수식표현	$\sigma(z) = 1/(1 - e^z)$	$R = \begin{cases} (x < 0) R(z) = 0 \\ (x \geq 0) R(z) = z \end{cases}$
범위값	<ul style="list-style-type: none"> 0에서부터 1까지 	<ul style="list-style-type: none"> $X < 0$ 이면 0을 출력, $x \geq 0$ 이면 입력값을 그대로 출력하고 무한대까지 증가
특징	<ul style="list-style-type: none"> 일정한 범위값 S 모양과 유사하여 sigmoid라 부름 	<ul style="list-style-type: none"> 범위값이 제한적이지 않음 음의 영역을 쉽게 배제할 수 있음
장점	<ul style="list-style-type: none"> 미분이 가능하므로 계단(step)함수에 비해 학습이 용이 	<ul style="list-style-type: none"> <u>vanishing gradient 해결</u> sigmoid 대비 학습 시간 단축
단점 활용	<ul style="list-style-type: none"> Neural Network을 적층할 수록 학습 효율 저하 RNN에서 활성화 함수로 활용 	<ul style="list-style-type: none"> 한 노드에서 음수가 발생하면 더이상 해당 노드를 학습하지 않음 CNN에서 활성화 함수로 활용



SOFTMAX 함수

1. SoftMax 함수의 개요

- 출력층에서 Active function으로 사용하는 함수로, 벡터값을 얻고 싶을 때 사용 하는 함수(해석 용이)
- 입력받은 값을 출력으로 0~1사이의 값으로 모두 정규화하며 출력 값들의 총합은 항상 1이 되는 특성을 가진 함수
- 다분류 범주기의 출력노드에서 사용하는 것이 일반적
- 일반 활성함수는 자신의 노드로 들어오는 신호의 가중치만 고려하여 출력값을 계산(다른 출력노드의 계산에는 관여하지 않음)
- 소프트 맥스는 자신의 가중합뿐만 아니라, 다른 출력노드들의 가중치의 합도 고려하여 계산
- 모든 출력값의 상대적인 크기를 고려하여 출력 > 다범주 분류기에 적합



▪ Softmax 함수 원리

$$\begin{bmatrix} 1.2 \\ 0.9 \\ 0.4 \end{bmatrix} \xrightarrow{\text{Softmax}} \begin{bmatrix} 0.46 \\ 0.34 \\ 0.20 \end{bmatrix}$$

- Softmax 함수는 각 output node의 출력을 0~1로 제한
- output node의 출력을 모두 합한 값은 항상 1
- Softmax function의 수식

$$S(y_i) = \frac{e^{y_i}}{\sum_{j=1}^K e^{y_j}}$$

$e^n : x_j \text{의 } n\text{회 곱하기}$ (exponential function)

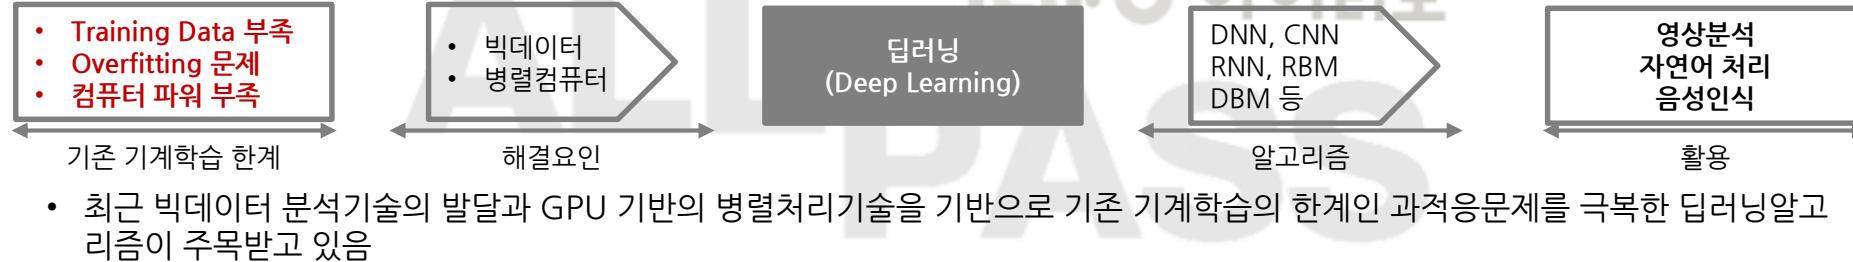
$$f(\vec{x})_i = \frac{e^{x_i}}{\sum_{k=1}^K e^{x_k}} \quad \text{for } i = 1, \dots, K$$

딥러닝(Deep Learning)

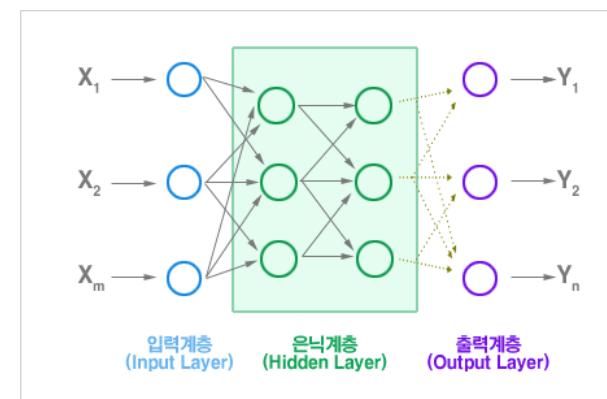
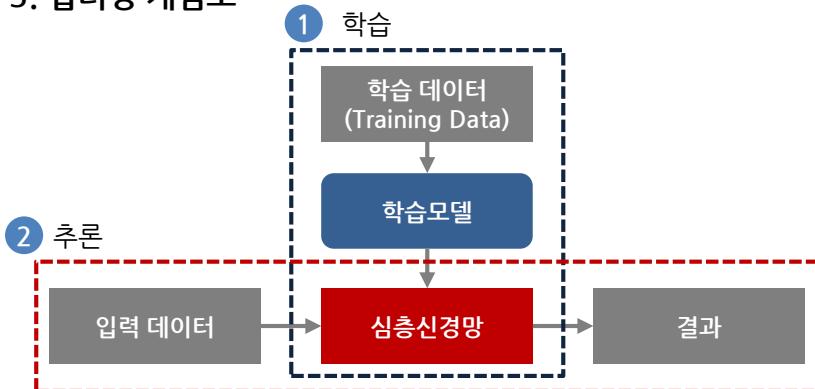
1. 능동적 비지도학습, 딥러닝의 개요

구분	정의
인공지능 비교측면	더욱 고도화된 신경망 알고리즘 을 적용하여 보다 빠르고 감성적이며 인간과 유사하게 행동하는 컴퓨터 프로그램을 구현한 학습방법
학습측면	사람의 개입이 필요한 기존의 지도학습(supervised learning)에 보다 능동적인 비지도학습(unsupervised) 이 결합되어 컴퓨터가 마치 사람처럼 스스로 학습할 수 있는 인공지능 기술
알고리즘 측면	인공신경망의 정확성 및 성능문제를 해결하기 위해 CNN, RNN, DBN 등의 알고리즘을 이용하여 분석 성능을 향상시킨 기계학습의 분야 심층 신경망을 이용한 머신러닝 기법

2. 딥러닝(Deep Learning) 등장 배경



3. 딥러닝 개념도



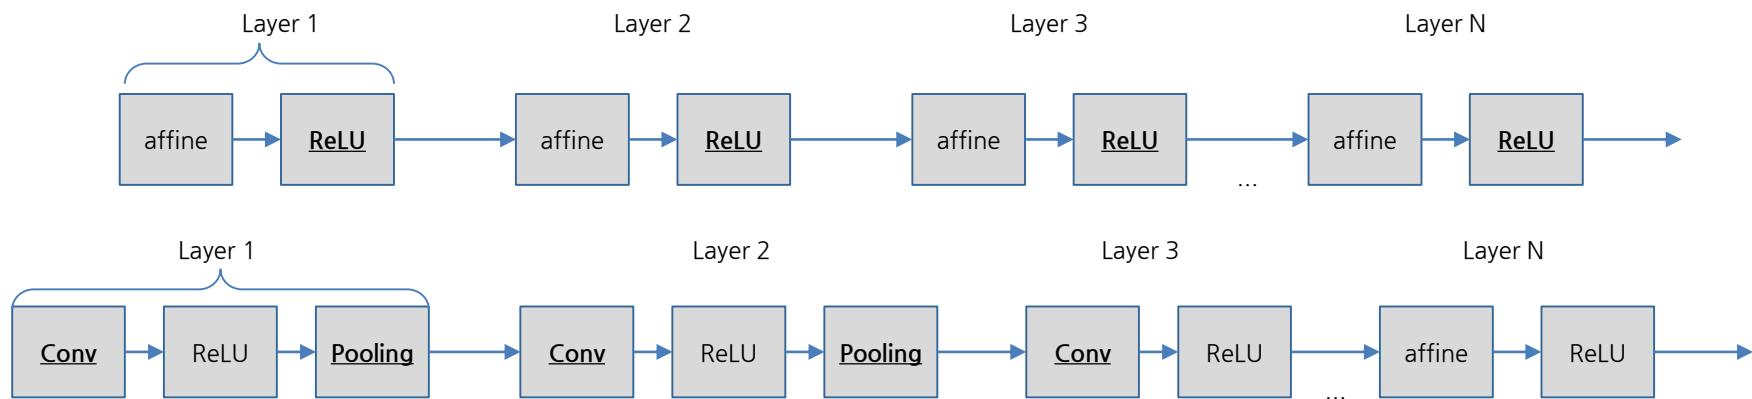
딥러닝(Deep Learning)

4. 딥러닝(Deep Learning) 주요 알고리즘

알고리즘	설명	기법
DNN (심층 신경망)	• 입력 계층과 출력 계층 사이에 복수개의 은닉 계층들로 이루어진 인공 신경망	• 자연어 처리, 음성인식
CNN (합성곱 신경망)	• 최소한의 전처리를 사용하도록 설계된 다계층 퍼셉트론의 한 종류	• 영상, 음성 분석 분야
RNN (순환 신경망)	• 인공 신경망을 구성하는 유닛 사이의 연결이 Directed Cycle을 구성하는 신경망	• 필기체 인식
RBM (제한 볼츠만 머신)	• 볼츠만 머신에서 층간 연결을 없앤 형태의 모델 • 볼츠만 머신: 흡필드 네트워크의 동작 규칙을 확률적 동작 규칙으로 확장시킨 모델	• DBN의 기본 개념 제공
DBN (심층 신뢰 신경망)	• 기계학습에서 사용되는 그래프 생성 모형으로 잠재변수의 다중 계층으로 이루어진 심층신경망	• 영상, 음성, 자연어 처리 등 전 분야
DQN (심층 Q 네트워크)	• 심층 강화 학습을 통해 인간 수준의 제어를 가능하게 하는 신경망 • Q-Learning 알고리즘 이용	• 실제 인간이 하는 행동의 상당부분 예상

5. 딥러닝 학습 구조

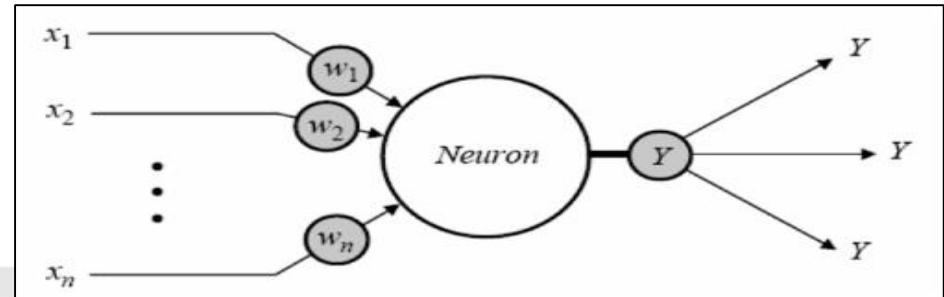
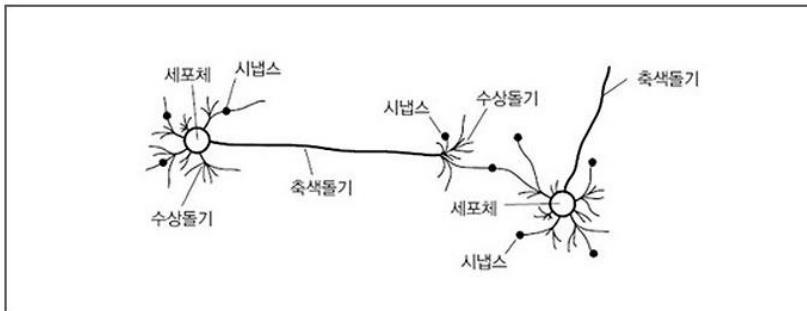
- 신경망 학습은 활성화함수를 이용하여 다층으로 학습을 이어가 계속 학습할 수 있도록 하며, 가중치의 매개변수의 최적값을 자동으로 획득함.
- 이때, 가중치의 매개변수를 최적화 하여 손실함수의 결과값을 가장 작게 하는 것이 학습의 목표임



ANN(artificial Neural Network)

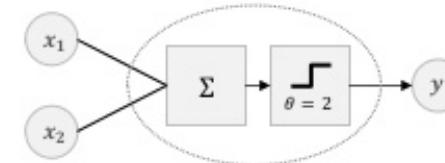
1. ANN의 개요

- 인간 두뇌의 학습과정을 뉴런과 시냅스 작용을 통한 연산 과정으로 간주하고 이를 재현한 분류, **예측모형**
- 1943년 워렌 맥컬록과 윌터 피츠는 생물학적 신경망 이론을 단순화 해서 이론 제시
- TLU(Threshold logic unit)이라 정의



생물학적 신경망	인공신경망
세포체	노드(Node)
수상돌기(dendrite)	입력(Input)
축삭(Axon)	출력(Output)
시냅스	가중치(Weight)

▪ 인공신경망 TLU를 AND 논리 연산에 적용한 예



입력 x1	입력 x2	출력 y
0	0	0
0	1	0
1	0	0
1	1	1

만약 $\theta=1$ 이면 OR 연산이 적용된 TLU가 된다.

[한계점]

- 인공신경망 학습에 소요되는 시간이 너무 오래 소요
- 부분최적화(local optima)로 인해 현실적인 사용이 어려움
- 사전 훈련 데이터(Training data set)에 지나치게 맞추어져(over-fitting) 제대로 작동이 안 되는 등의 문제가 발생

ANN(artificial Neural Network)

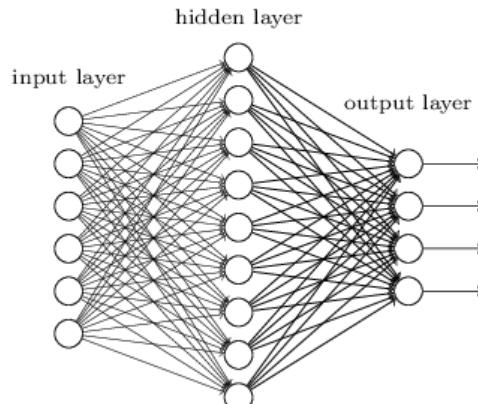
2. ANN 주요 알고리즘

분류	상세분류
전방 전달 신경망 (Feedforward neural network)	<ul style="list-style-type: none">가장 간단한 방법의 인공신경망 방법신경망 정보가 입력 노드에서 은닉노드를 거쳐 출력 노드까지 전달 되며 순환 경로가 존재하지 않는 그래프를 형성이진 구조, 퍼셉트론, 시그모이드 등등 여러가지 방법으로 구성
방사 신경망 (Radial basis function network):	<ul style="list-style-type: none">사상 인공 신경망은 다차원의 공간의 보간법에 매우 강력한 능력을 가지고 있다.방사 함수는 다 계층의 시그모이드 함수를 은닉 노드에서 사용하는 형태를 대체할 수 있다.
코헨 자기조직 신경망 (kohonen self-organizing network)	<ul style="list-style-type: none">자기조직 신경망 알고리즘은 대표적인 신경망 알고리즘 중 하나자율(unsupervised) 학습방법과 경쟁(competitive) 학습방법을 사용신경망은 입력층과 경쟁층으로 나뉘고, 경쟁층의 각 뉴런은 연결강도 백터와 입력백터가 얼마나 가까운가를 계산하고, 각 뉴런들은 학습할 수 있는 특권을 부여 받으려고 서로 경쟁하는데 거리가 가장 가까운 뉴런이 승리하게 된다. 이 승자 뉴런이 출력신호를 보낼 수 있는 유일한 뉴런이다. 또한 이 뉴런과 이와 인접한 이웃 뉴런들만이 제시된 입력 백터에 대하여 학습이 허용
순환 인공 신경망 (Recurrent neural network)	<ul style="list-style-type: none">순환 인공 신경망은 전방 신경망과 정 반대의 동작노드들 간의 양방향 데이터 이동이며 데이터는 선형적으로 전달이 된다. 데이터가 후방 노드에서 전방노드로 전달하여 연산이 수행될 수도 있다.

3. ANN(artificial neural networks) vs DNN

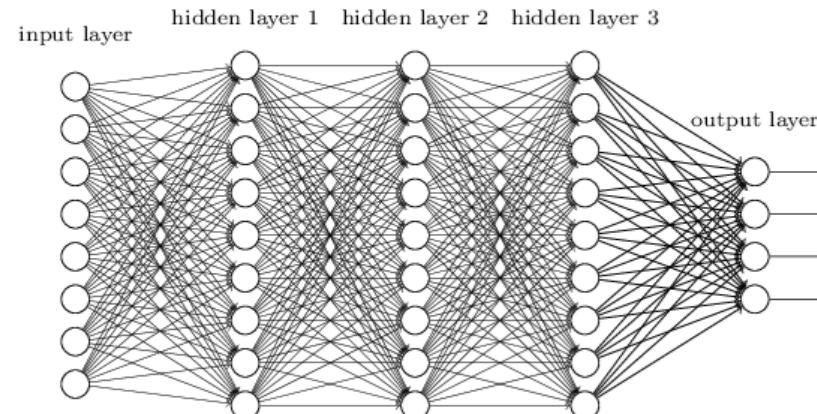
1 hidden layer

"Non-deep" feedforward
neural network



1 more hidden layer

Deep neural network





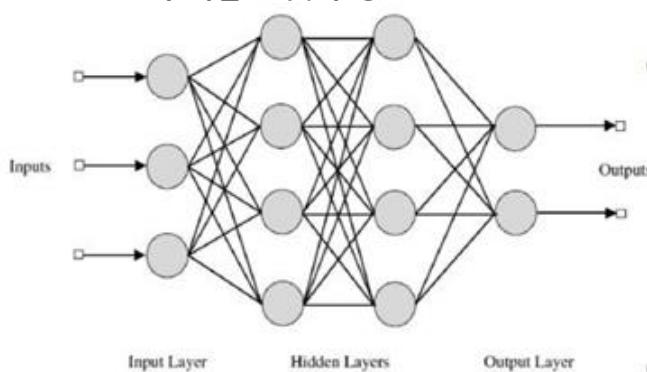
Feedforward Neural Network (FNN)

1. 전방향 신경망, FNN의 개요

- 은닉층에서 노드 간에 사이클을 형성하지 않고 **일방향으로 정보를 전달**하는 방식의 인공신경망
- 신경망에서 정보의 흐름이 입력 \rightarrow 은닉 \rightarrow 출력층으로 **정보가 전방으로 전달되는 인공 신경망**
- 최초로 고안된 인공신경망의 방식이며 가장 단순한 구성임

특징	설명
No Cycle	신경망 정보가 입력층, 은닉층, 출력층까지 전달되는 과정에 순환경로가 존재하지 않음
One-way	입력층에서 출력층 방향으로 일방향 정보 전달 방식
다양한 구조	이진 구조, 퍼셉트론, 시그모이드 등 여러가지 방법으로 구성 가능

2. FNN의 개념도 및 구성요소



구성요소	설명
입력층	<ul style="list-style-type: none"> 계산과정 없이 외부로부터 신호를 받아들이는 지점 입력층의 노드 수는 입력데이터의 특성의 수와 일치
은닉층	<ul style="list-style-type: none"> 은닉층의 뉴런수와 은닉층의 개수는 신경망 설계자의 직관과 경험에 의존 은닉층의 뉴런 수가 너무 많으면 overfitting 발생 너무 적을 경우 충분히 표현하지 못함 입력층과 출력층 사이에서의 정보처리 계층으로서 일방향 전달
출력층	<ul style="list-style-type: none"> 은닉층에서 계산된 최종 출력값들을 제공 해결하고자 하는 문제의 성격

- 신경망 정보가 입력노드에서 은닉노드를 거쳐 출력노드로 전달되며 순환 경로가 미존재

3. 학습절차 (이전의 데이터와 관계없이 현재 주어진 데이터만 가지고 판단)

단계	설명	
초기화	<ul style="list-style-type: none"> 각 가중치와 각 노드에서의 임계값을 모두 지정 	
활성화	1 단계	입력층에서 은닉층으로 가는 값을 계산
	2 단계	은닉층에서 출력층으로 가는 값을 계산
가중치 학습	1 단계	출력층에서 출력층 이전 은닉층 사이의 가중치 학습(출력값과 기대값의 오차 이용)
	2 단계	은닉층에서 은닉층 또는 입력층 사이의 가중치 학습 (이전 단계에서 발생한 오차를 합산하여 이용)
반복	<ul style="list-style-type: none"> 각각에서 발생한 오차 제곱의 합이 특정 수치보다 작아질 때까지 반복 	

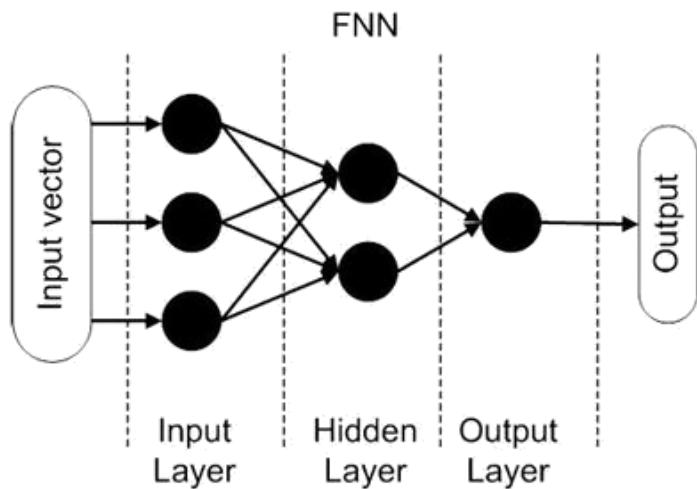
Feedforward Neural Network (FNN)

4. FNN과 CNN의 비교

구분	Feed Forward NN	Convolutional NN
처리 방식	은닉층의 일방향 처리 역전파를 통한 가중치 수렴	Convolution 과 Pooling 기반 특징 추출 후, Feed Forward 로 분류 및 결과 판별
학습 방법	Raw Data 의존한 학습	특징을 기반으로 학습
과적합	고정된 학습 데이터로 인한 과적합 발생 가능	기존 과적합 문제의 개선
시간복잡도	시간복잡도 문제 자주 발생	기존 시간복잡도 문제의 개선
활용 분야	XOR 연산기 및 타 알고리즘에 활용	영상 및 음성 인식 분야에 활용

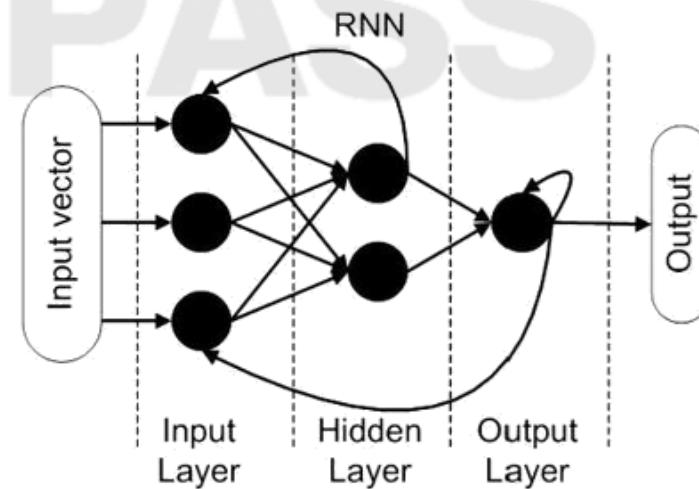
5. FNN vs RNN

FNN(FeedForward Neural network)는 **비방향성**
순환되는 것이 없음 (Acyclic, No Loop)



Single neuron

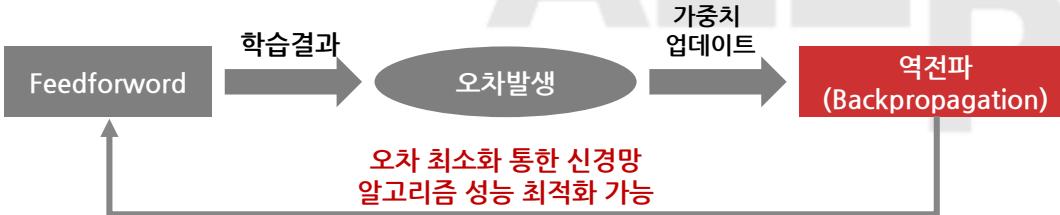
RNN(Recurrent Neural Network) can be arbitrary.(임의적)
네트워크 내에서 순환이 허용됨



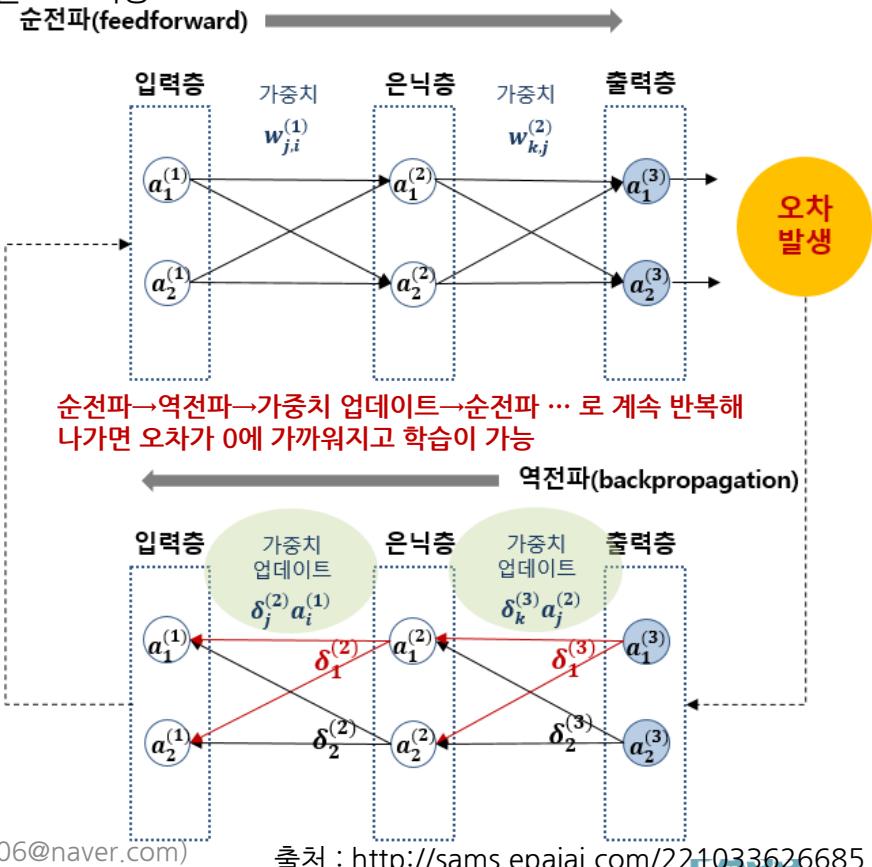
역전파 알고리즘

1. 다층신경망을 위한 학습규칙, 역전파 알고리즘(Backpropagation)의 개요

- 가중치들(w_{ij}) 각각에 대해 별도로 경사하강을 관찰하고, 누적오차 감소에 가장 큰 기여를 하는(기울기가 가장 가파른 쪽의) 가중치 한 개 값을 이동시키는 방법을 반복하여 해를 찾아 가는 기법 (은닉노드들의 오차를 결정하는 체계적인 방법을 제시)
- 정방(Feedforward) 연산 이후, 에러(Error) 예측값과 실제값과의 오차를 후방(Backward)으로 다시 보내 줌으로써, 많은 노드를 가진 MLP라도 최적의 Weight와 Bias를 학습하는 기법
- 은닉층 노드들의 오차를 결정한 다음, 델타규칙에 따라 이 오차들로 가중치를 조정하는 방법 (원래는 가중치로 오차를 찾음)**
- 신경망의 출력 오차를 출력층에서 시작해 입력층 바로 온닉층 앞까지 역순으로 이동
- 가중치를 갱신하는 방향은 신경망의 처리 방향과는 반대
- 다중퍼셉트론의 은닉층 학습의 한계를 해결
- 출력층의 오차를 역전파하여 은닉층을 학습



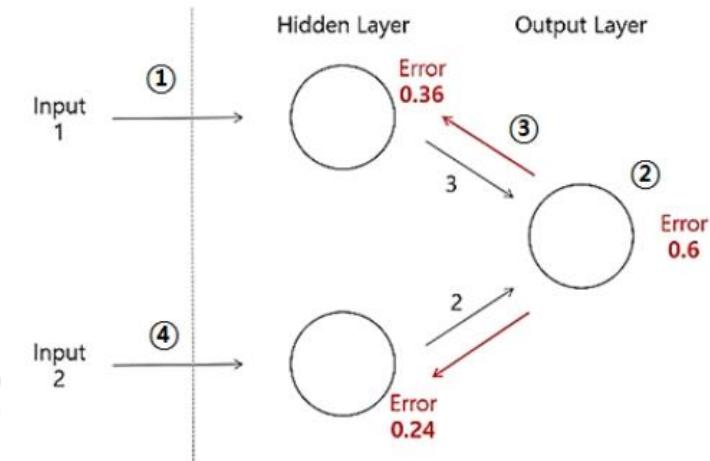
학습 벡터로부터 실제 출력값을 출력하고, 목적값(target value)와 실제 출력값의 차이인 오차를 계산하여 각층에 전달하는 1)전파(propagation)단계와 전파된 오차를 이용하여 가중치를 수정하는 2) 가중치 수정단계로 구성



역전파 알고리즘(Backpropagation)

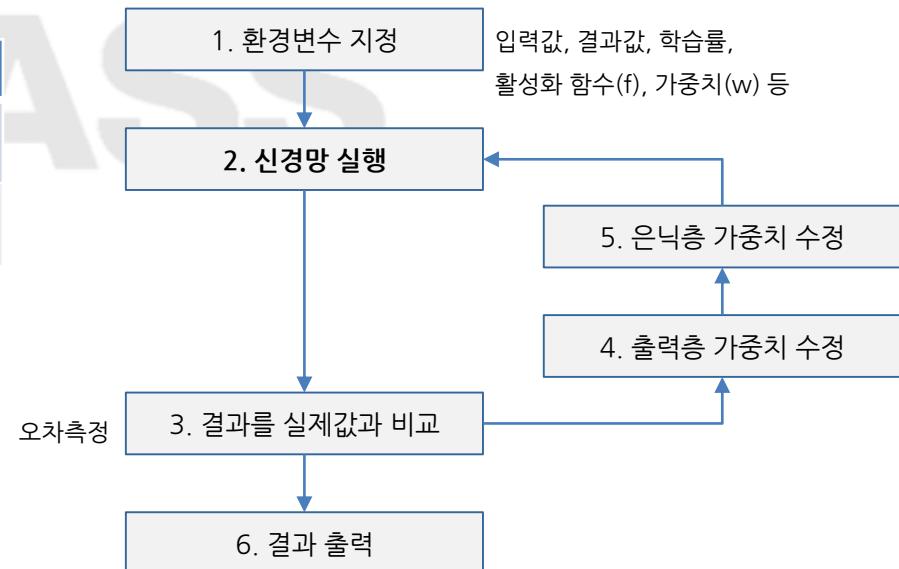
2 역전파 알고리즘

단계	설명	특징
피드포워드	입력층 \rightarrow 출력층으로 순전파 수행	가중치 초기화
오류 역전파 계산	출력층 오류 최소화하는 가중치 탐색 (0.6) 출력층에서부터 역방향 진행	미분(예상값-실제값)
가중치 조정	학습률만큼 수정한 가중치로 조정 오차값 0.6 을 3.2 로 배분하여 0.36, 0.24로 갱신	에러 최소평균제곱의 미분
반복 수행	목표 도달시까지 위 과정 반복	N 회 epoch 수행



3. 오류 역전파 알고리즘의 문제점과 해결 방안

구분	항목	설명
문제점	sigmoid 함수 문제	<ul style="list-style-type: none"> 계단형식 함수를 미분가능하도록 곡선화 기울기 문제(vanishing gradient problem) 발생
해결 방안	ReLU 사용	<ul style="list-style-type: none"> x 값이 0 이하이면 0 을 출력, 0 이상이면, 비례 함수 적용 $\max(0, x)$ 함수 사용





DROPOUT

성능향상을 위한
은닉층 추가

문제점

과적합 발생

해결방안

드랍아웃
(Drop Out)

- 모델 성능향상 추구
→ 연결가중치 증가

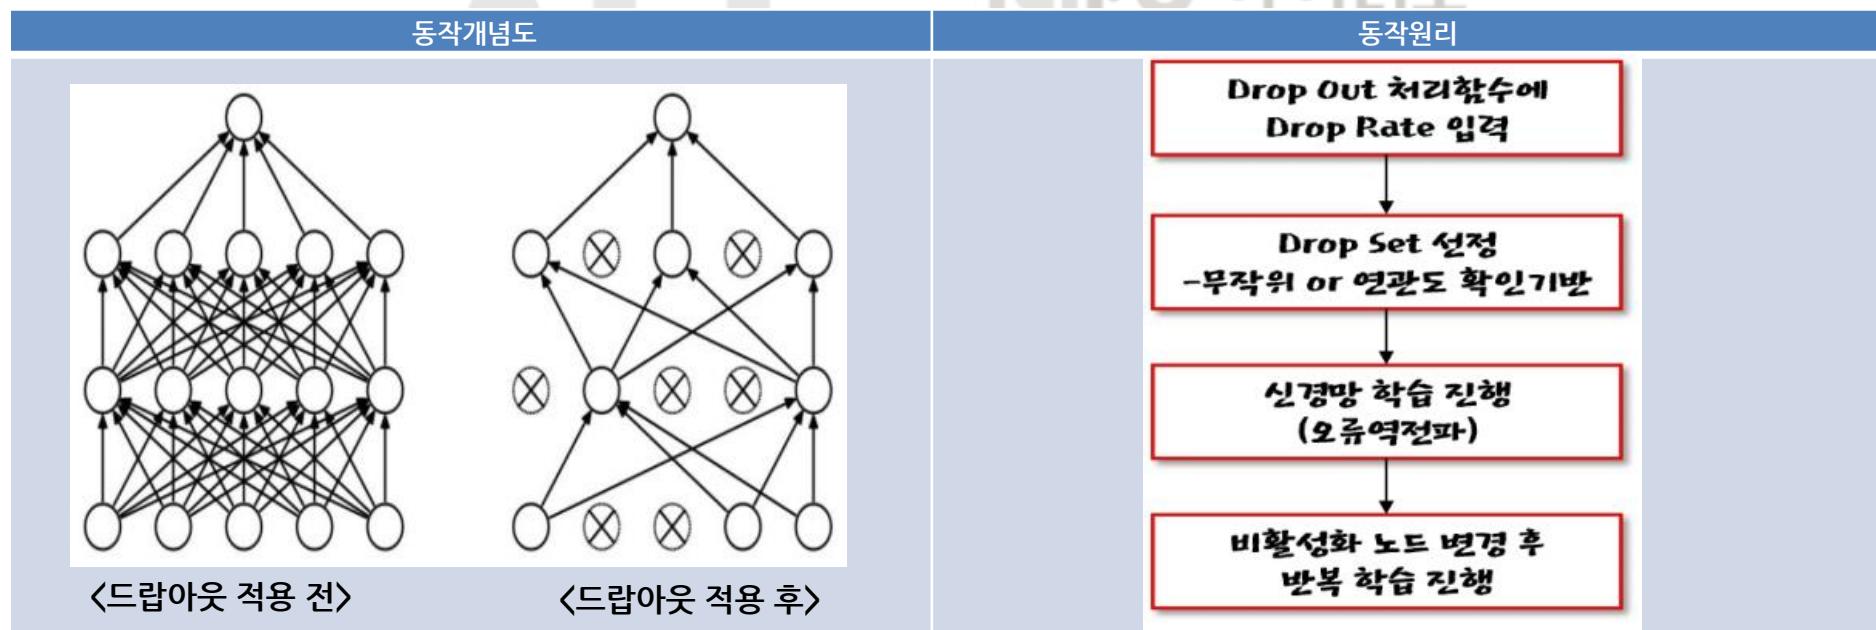
- 계층구조가 깊어짐
→ 과적합 딜레마

- 과적합 해결
• Co-Adaptation 회피

1. 신경망 학습시 임의의 노드를 생략하고 학습하는 알고리즘, DropOut의 개요

- 심층신경망 학습을 위해 **오류역전파(Back Propagation) 수행 시, 과적합(Overfitting) 문제를 해결**하기 위해 은닉층의 일부 노드를 무작위로 비활성화 하는 기법 (신경망의 전체를 다 학습 시키지 않고, 일부 노드만 무작위로 골라 학습 시키는 방법)
- 학습하는 중간중간 일정 비율로 노드들을 무작위로 골라 출력력을 0으로 만들어 신경망의 출력력을 계산
- 비율 : 은닉층은 50%, 입력 노드는 25%가 일반적 (단, 학습 시에만 활용됨.)
- 학습시 weight의 동조화 되는 현상
- 특정 뉴런의 가중치 및 영향력이 최소화 됨에 따라 강건한(Robust) 신경망 구성이 가능

2. 드랍아웃(Drop Out)의 동작원리



- Drop Rate(주로 0.5)를 계속 변형하면서 적용하는 것이 과적합을 효과적으로 방지하는 방안임

DROPOUT

3. 드랍아웃(Drop Out)의 유형

유형	특징	설명
Feed Forward 드랍아웃	초기 입력노드 대상	초기 입력 은닉노드 중 일부를 드랍아웃하여 학습 진행
Back Propagation 드랍아웃	출력노드 대상	출력노드 중 일부를 드랍아웃 처리하여 학습 진행
시간/공간 드랍아웃	시간/공간적 연관성 고려	시퀀스, 또는 주변 연관관계를 고려한 노드의 비활성화

- Feed Forward 와 Back Propagation 드랍아웃을 혼용한 Hybrid 형태의 드랍아웃을 최근 많이 활용(입&출력값 드랍)

4. 드랍아웃(Drop Out)기법 적용 시 고려사항 및 대응방안

고려사항	원인	대응방안
심층신경망 학습속도 저연	무작위 노드제거 및 복원 오버헤드	Batch Normalization을 통한 드랍아웃 대체
가중치 활용	다음레이어로 전달되는 결과값이 미미함	가중치값을 드랍아웃 되지 않은 노드에 곱하여 결과산출

RNN(recurrent neural network)

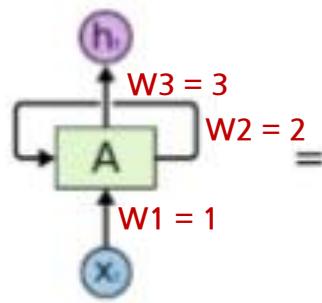
재귀신경망 Recurrent Weight Sequential Data LSTM/GRU CELL GATE

1. 내부에 루프를 가진 네트워크, RNN의 개요

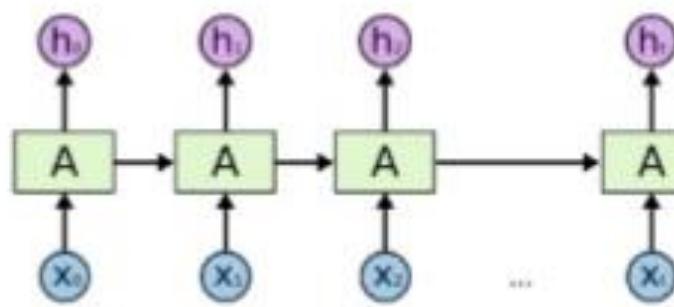
- 인공신경망을 구성하는 유닛 사이의 연결이 Directed Cycle을 구성하고 Recurrent Weight를 가지는 인공 신경망 알고리즘
- 자연어 처리나 음성인식에 활용 (시계열 데이터의 시간의 흐름에 따른 변화하는 데이터)
- 유닛 사이의 연결이 Directed Cycle을 형성하며 자신을 가리키는 Recurrent Weight를 포함하는 신경망 알고리즘
- 내부에 루프를 가진 네트워크로 그 루프는 정보가 지속되는 것을 도움(루프는 정보가 네트워크의 한 단계에서 다음 단계로 전달)
- 이전 정보를 현재 작업으로 연결 가능하기 지원

2. RNN의 개념도, 구성요소 및 학습 과정

자기 자신을 가리키는
Recurrent Weight를
포함(기억)



펼쳐진 순환 신경망

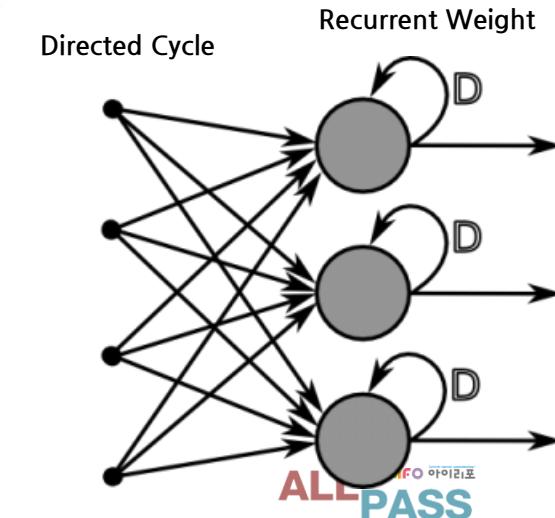


입력, 가중치, 출력을 위한 Weight가
마지막 학습까지 유지됨
(W1, W2, W3은 마지막까지 유지됨)

Hidden Layer에서
Hidden State(S_t)를 계산할 때
 $S_t = \tanh(U_{xt} + W_{st})$ 로 계산

학습과정	설명
Recurrent Weight	• 과거의 데이터에 대한 정보를 어렵잖이 기억할 수 있는 기능을 포함하며, 이를 통해 새로운 데이터 처리 시 과거의 기억 사용 가능
Sequential Data 학습	• 과거의 내용을 통한 현재의 내용에 대한 문맥을 이해하는 방식인 Sequential Data 학습
BPTT (back- Propagation Through Time)	• 과거의 신경망(T-1)과 현재의 신경망(T)을 연결해 주는 역할을 수행하며, 기존 인공신경망의 학습 알고리즘인 오류역전파(Error back-propagation)을 확장한 BPTT(Back-Propagation Through Time)이라는 알고리즘을 통해 학습

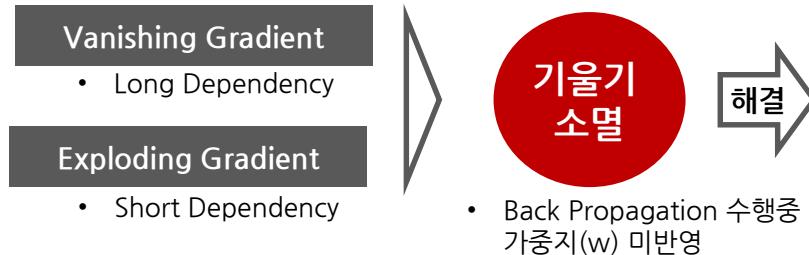
구성요소	설명
Directed Cycle	-방향성 있는 cycle 이용하여 하나의 입력 값에 여러 개의 값이 출력
Recurrent Weight	-자기 자신을 가리키는 반복 가중치 구조
BPTT 알고리즘	-Back Propagation Through Time -오류역전파(Error Back Propagation)를 확장한 알고리즘으로 시간 방향 학습
Sequential Data 학습	-과거 내용을 통한 현재의 내용에 대한 문맥을 이해 ($Y_{k-1} \rightarrow Y_k \rightarrow Y_{k+1}$)





Gradient Vanishing Problem (기울기 소멸 문제)

1. 인공지능의 2차 암흑기의 원인, Gradient Vanishing Problem 의 개요



[해결방안]

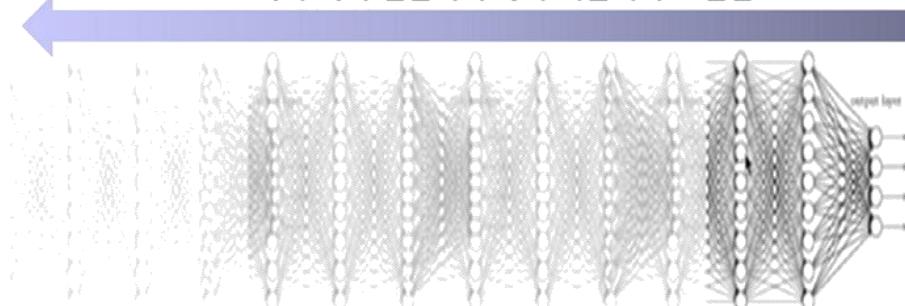
- ReLU 함수 적용
- 초기 가중치(w) 정확성 향상
- Drop Out
- Batch normalization

Deep neural network 구조에서 뉴런의 깊이가 깊어짐에 따라 Back propagation과 Gradient Descent를 통한 가중치 전달의 문제점 발생함

2. Training 효과 감소, Vanishing Gradient의 설명

- 역전파 알고리즘으로 심층 신경망을 학습 시키는 과정에서, **출력층에서 멀어질수록 신경망의 출력오차가 반영 되지 현상**
- 인공신경망을 기울기값을 베이스로 하는 method(backpropagation)로 학습시키려고 할 때 발생되는 문제점으로 역전파 알고리즘을 학습을 통해 가중치를 수정할 때, **온닉층으로 오차가 거의 전달 되지 않는 문제**
- 온닉층을 여러 단계 거치는 딥러닝에서 가중치를 수정하기 위해 미분을 반복적으로 사용하면서 기울기가 0이 되어버려 학습이 중단되는 문제
- **이전 Sigmoid Active Function이 0과 1사이의 값을 정규화 하기 때문에 미분값이 작아 지게 되는 것이 결정적 이유(최대 1/4)**
- **발생원인 : data set 부족, 컴퓨터 파워 부족, 초기 가중치 값 오류, 활성함수 선택 오류**
- 기울기 사라짐 문제로 시그모이드 함수 이외 개선된 활성화 함수 이용 → tanh(하이퍼볼릭 탄젠트), ReLU, softplus 등

오차가 거의 전달되지 않아 기울기가 소멸됨



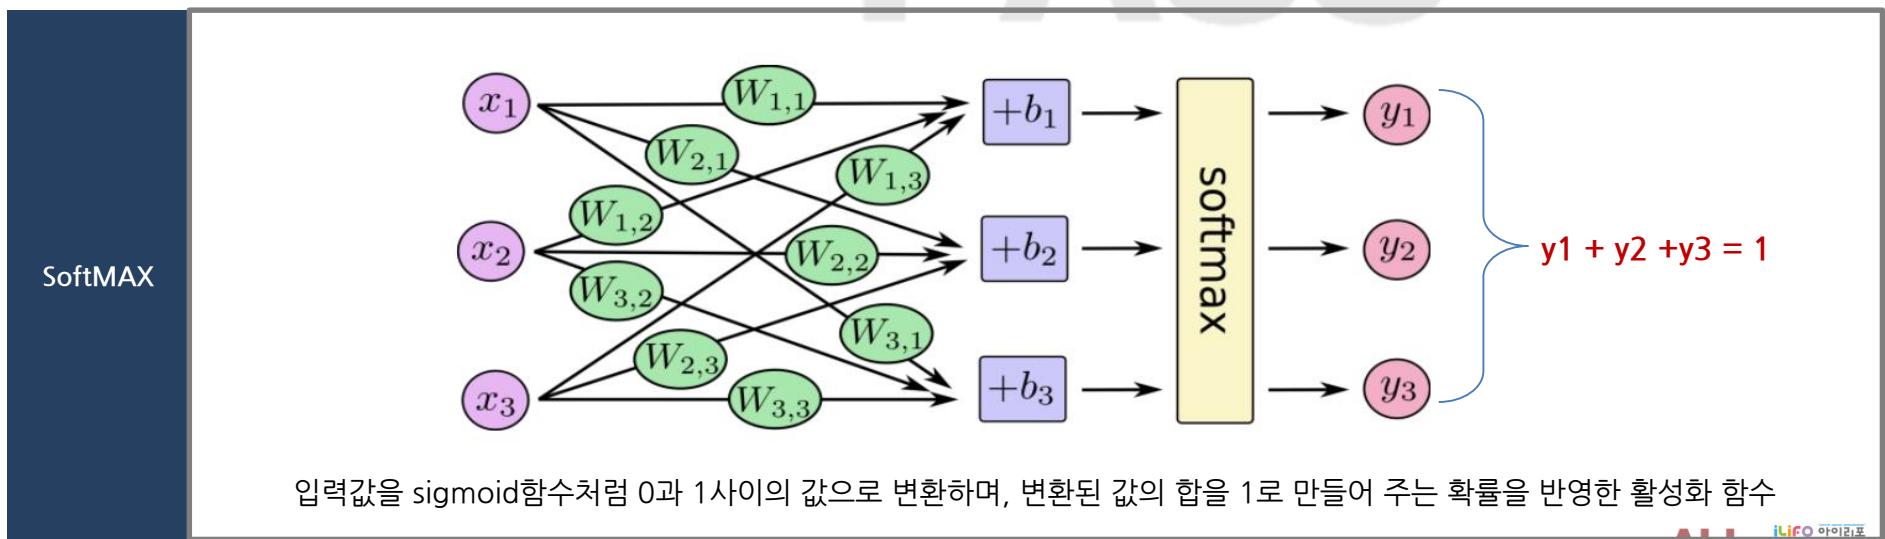
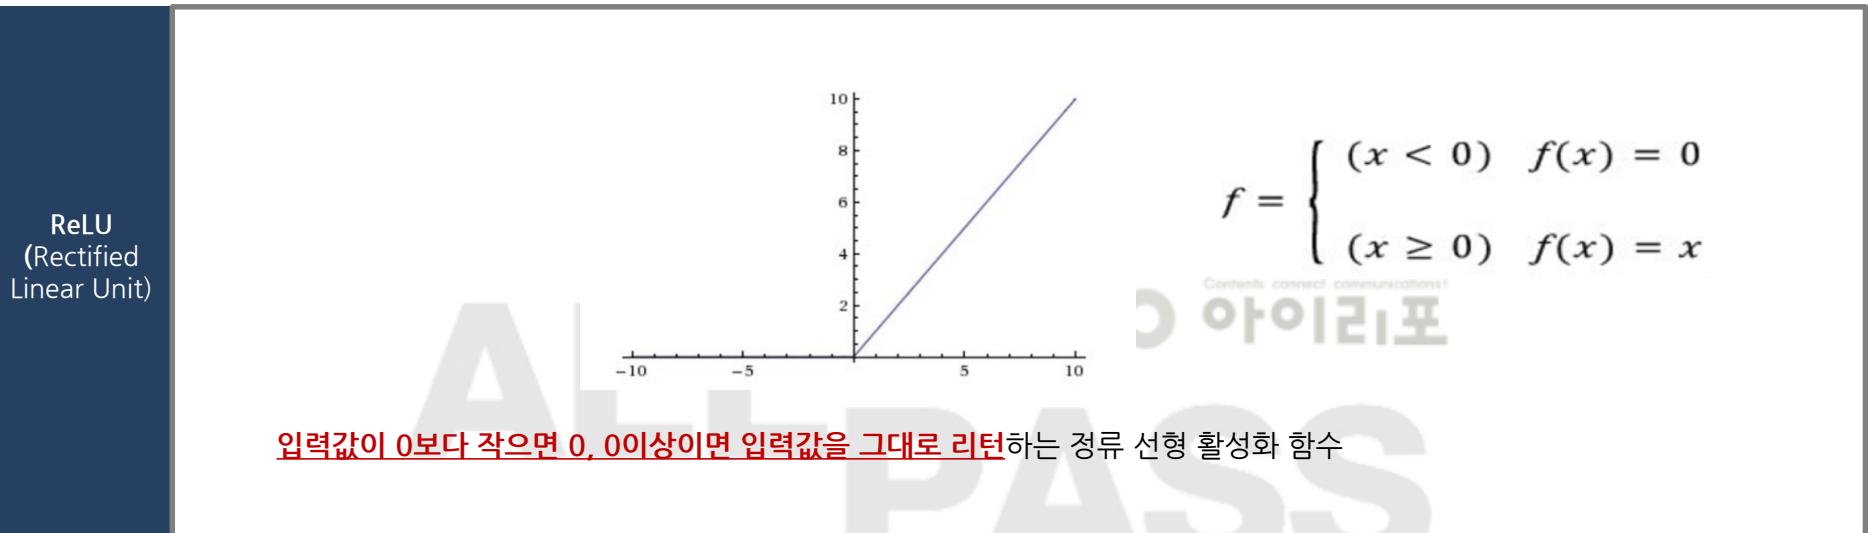
Gradient Vanishing Problem (기울기 소멸 문제)

3. Vanishing Gradient의 해결방안

해결방안	해결방안 설명	해결 방안 상세 설명
Drop Out		불필요한 노드의 연산을 제거하여 학습 시 가중치(w)의 동조화 되는 현상 회피
초기 가중치 값 정확성 향상	Auto Encoder, RBM 등을 활용	초기 가중치(w) 값 향상을 통한 연산량 감소 시킴
ReLU 활성화 함수		Back propagation 시에 기울기가 0 or 1학습이 되는 경우 100% Error가 전파 - 시그모에드 처럼 0,1로 제한 하는 것이 아니고 무제한이기 때문에 확실한 표현력을 가짐
batch normalization		학습 단계에서 배치 단위의 평균/분산을 저장해 놓고 테스트 시에는 평균/분산을 사용 하는 기법

Gradient Vanishing Problem(기울기 소멸 문제)

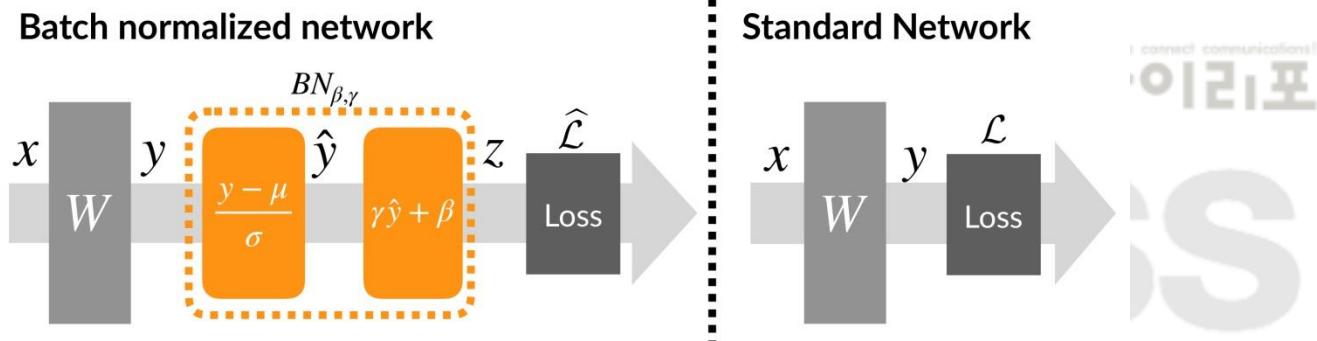
3. 기울기 사라짐 문제 해결을 위한 활성화함수(상세)



Batch Normalization

1. Vanishing Gradient 해결 Batch Normalization 개념

- 특정 Hidden Layer에 들어가기 전에 Batch Normalization Layer를 더해주어 input을 modify해준 뒤 새로운 값을 activation function으로 넣어주는 방식
- Training Data로 학습을 시킬 때는 minibatch에서 평균과 표준편차를 구하지만, Test Data를 사용하여 Inference를 할 때는 minibatch의 값들을 이용하는 대신 지금까지 본 전체 데이터를 다 사용
- 학습 단계에서는 데이터가 배치 단위로 들어오기 때문에 배치의 평균, 분산을 구하는 것이 가능



2. 학습연산 능력 강화, Batch Normalization 장점

- Vanishing Gradient의 문제점을 해결
- Learning Rate 를 높여도 학습 시, 수렴 가능

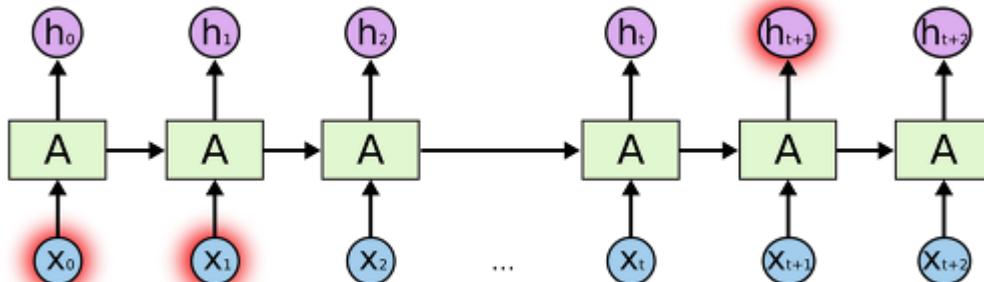
RNN(recurrent neural network)

3. RNN의 활용분야

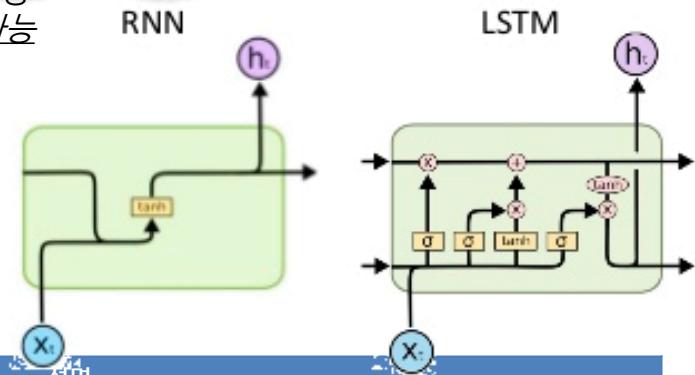
구분	내용
언어 모델링과 텍스트 생성	주어진 문장에서 이전 단어들을 보고 다음 단어가 나올 확률을 계산해주는 언어 모델링 어떤 문장이 실제로 존재할 확률이 얼마나 되는지 계산 후 자동 번역의 출력값으로 어떤 문장을 내보내는지 도출
자동 번역 (기계 번역)	입력은 언어 모델링과 같은 단어들의 시퀀스지만, 출력 값이 다른 언어로 되어있는 단어들의 시퀀스로 처리 입력 값을 전부 다 받아들인 후 네트워크가 출력 값을 내보내는 작업 진행
음성 인식	사운드 웨이브의 음향 신호를 입력으로 받아, 출력으로는 음소들의 시퀀스와 각각의 음소별 확률 분포를 추정
이미지 캡션 생성	컴퓨터 비전에 활용하는 CNN과 RNN을 함께 사용하여, 임의의 이미지를 텍스트로 설명해주는 시스템 구성

4. RNN의 기울기의 사라짐 문제(Gradient Vanishing Problem) 발생

- 아주 먼 과거까지 학습을 하는 과정에서 반복되어 곱해지는 Recurrent Weight에 의해 **기울기가 기하급수적으로 사라지는 현상**
→ 장기 의존성 문제 (The Problem of Long-Term Dependencies)
- RNN은 학습방법의 역전파 거리가 늘어나면 gradient 값이 폭증하거나 사라지는 문제점이 발생 àLSTM(Long Short Term Memory), GRU(Gated Recurrent Unit)으로 해결 가능
- Vanishing Gradient에서 알 수 있듯이 BPTT에서 Chain Rule에 의해 [-1, 1]사이의 값들이 계속 곱해지다보니 앞쪽으로 갈수록 그 값이 작아져, 결국에는 소멸해버려 Parameter들의 업데이트가 되지 않는 문제가 발생
→ LSTM(Long Short Term Memory), GRU(Gated Recurrent Unit)으로 해결 가능



성능개선 알고리즘



설명

LSTM (Long Short Term Memory)

-input/output/forget 3가지 게이트를 이용하여 데이터의 입출력을 조절
- 장기 의존성을 학습할 수 있는 순환신경망

GRU(Gated Recurrent Unit)

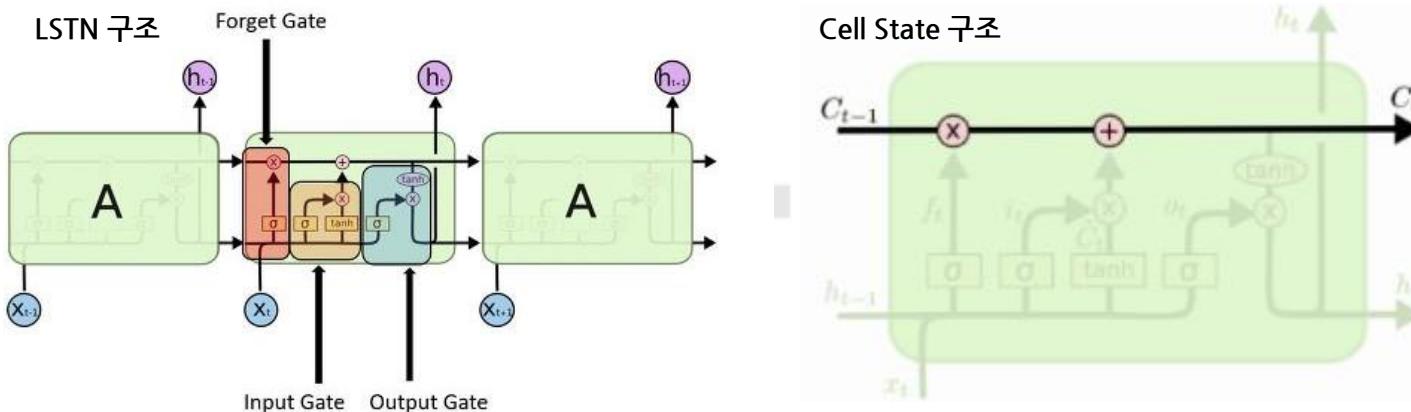
-reset, update unit을 이용하여 데이터의 입출력을 조절

LSTM (장단기 기억 네트워크)

3개의 Gate

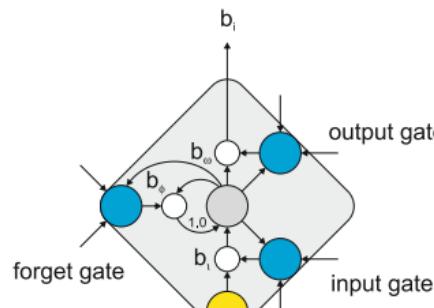
1. 장기 의존성을 학습할 수 있는 순환신경망, LSTM(Long Short Term Memory networks)의 개요

- 3가지의 Gate를 통해서 데이터들의 입출력을 조절해 필요할 때에만 데이터를 넣고, 과거 정보를 업데이트하고 출력하는 하는 기능 처리
- Cell State 단순한 연산(곱셉, 덧셈)을 거쳐 LSTM Unit(초록색 박스)을 통과
- Cell State는 **input, forget, output** 세 개의 게이트(gate)들을 이용하여 정보의 반영 여부를 결정
- 각 게이트들은 sigmoid 와 곱셈으로 이루어져 있음



[LSTM의 세가지 게이트의 핵심]

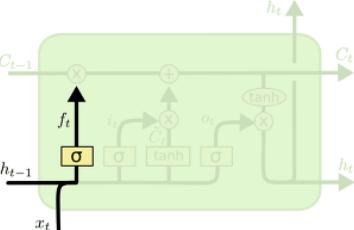
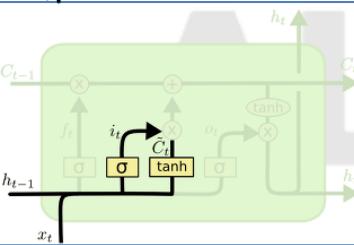
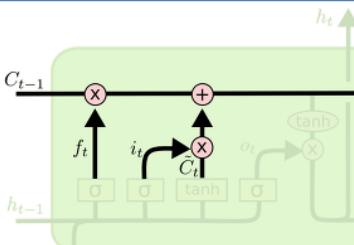
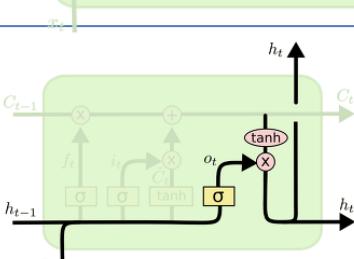
- 무엇을 쓰고 > input gate
- 무엇을 읽고 > out gate
- 무엇을 잊을 것인가 forget gate



- Recurrent Weight가 반복해서 곱해지는 연산 없이 단순히 덧셈으로만 이루어진 연산
- 입출력을 조절해 필요할 때에만 데이터를 넣고, 과거 정보를 업데이트하고 출력

LSTM (장단기 기억 네트워크)

2. LSTM의 단계

단계	개념도 및 식	설명
Forget Gate Layer	 $f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$	<ul style="list-style-type: none"> 어떠한 정보를 반영할지에 대한 결정을 하는 게이트 결정은 sigmoid layer 통해 이루어짐 h_{t-1} 과 x_t를 입력값으로 받아 sigmoid 활성화 함수를 통해 0 ~ 1사이의 값을 출력 1에 가까울수록 정보의 반영을 많이 하고, 0에 가까울수록 해당 정보의 반영을 적게 한다
Input Gate Layer	 $i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$ $\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$	<ul style="list-style-type: none"> 새로운 정보가 Cell State에 저장이 될지를 결정하는 게이트 Input Gate에는 두개의 Layer가 있는데, 하나는 sigmoid layer로 (이 레이어를 input gate라고 함) 어떤 값을 업데이트 할 것인지 결정하는 레이어 다른하나는 C_t 라고 불리는 tanh layer로 구성되어 있으며, Cell State에 더해질 vector of new candidate values(후보 값들의 벡터)를 만드는 레이어(Update gate)
Update Cell State (C_{t-1})	 $C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$	<ul style="list-style-type: none"> forget gate와 input gate에서 출력된 값을 Cell State C_{t-1} 를 C_t 로 업데이트
Output Gate Layer	 $o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$ $h_t = o_t * \tanh(C_t)$	<ul style="list-style-type: none"> 마지막 단계는 출력값(h_t)을 결정하는 단계 h_t 는 Cell State(C_t)를 필터링해준 값 출력할 Cell State의 부분을 결정하는 sigmoid layer를 통해 계산한다. 그런 다음, 앞 단계에서 업데이트 된 Cell State(C_t)를 **tanh**를 통해 -1 ~ 1사이로 출력된 값을 곱해준다.

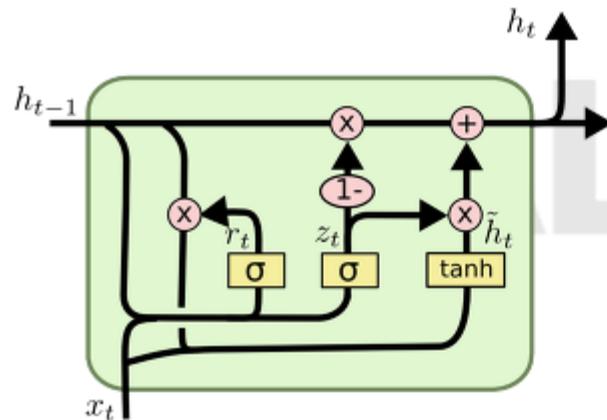
GRU(Gated Recurrent Unit)

Forget Gate

Input Gate

1. LSTM의 변형된 버전, GRU의 개요

- GRU는 리셋 게이트 r 과 업데이트 게이트 z 로, 총 두 가지 게이트로 구성
- LSTM에서 forget gate와 input gate를 GRU에서는 update gate(z_t)로 합쳤음
- 출력값(h_t)을 계산할 때 추가적인 비선형(nonlinearity) 함수를 적용하지 않음
- Gradient Vanishing/Explosion 문제를 극복했다는 점에서 LSTM과 유사하지만 게이트 일부를 생략한 형태(LSTM의 장점을 유지하면서도 계산복잡성을 확 낮춘 셀 구조)

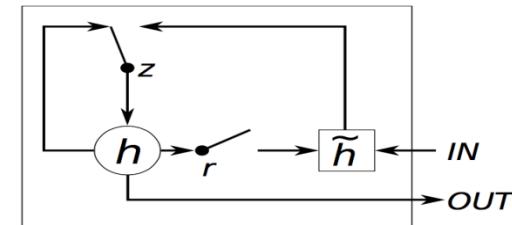


$$z_t = \sigma (W_z \cdot [h_{t-1}, x_t])$$

$$r_t = \sigma (W_r \cdot [h_{t-1}, x_t])$$

$$\tilde{h}_t = \tanh (W \cdot [r_t * h_{t-1}, x_t])$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$



- 입력 게이트와 망각 게이트가 업데이트 게이트 z 로 통합
- 출력 게이트 없음

CNN(Convolution Neural Network)

합성곱연산

커널

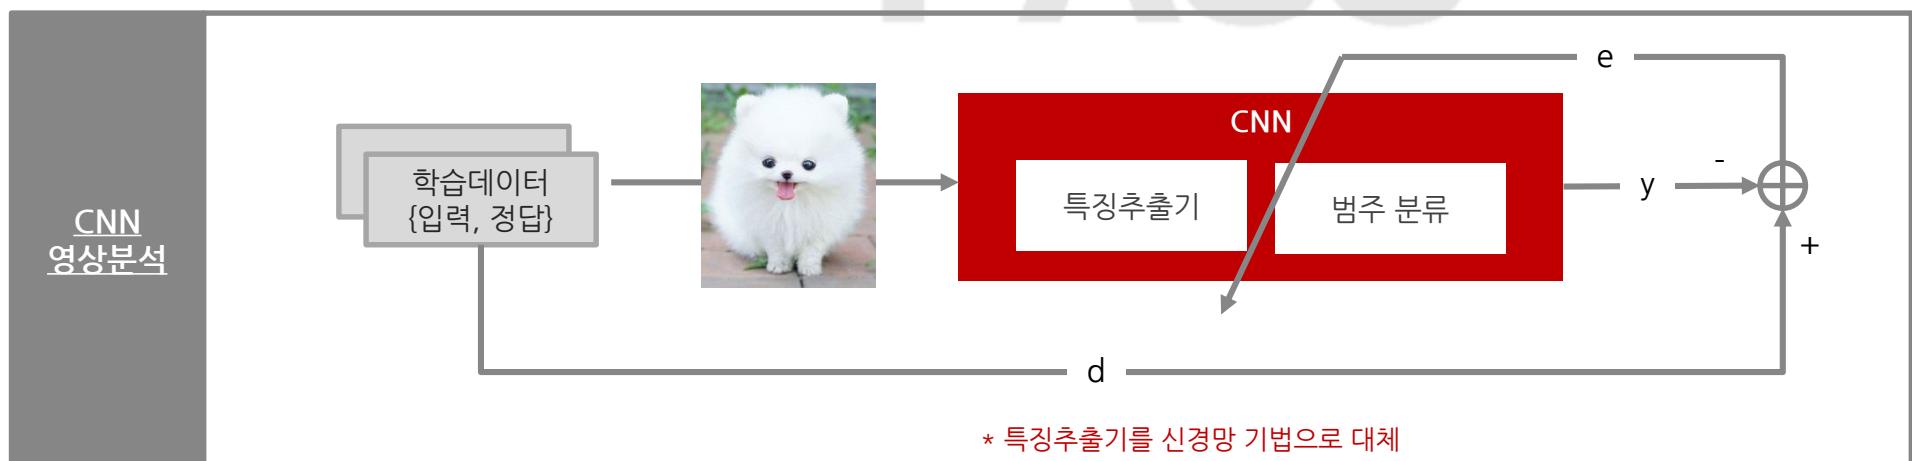
Convolutional layer

Pooling layer

Fully connected layer

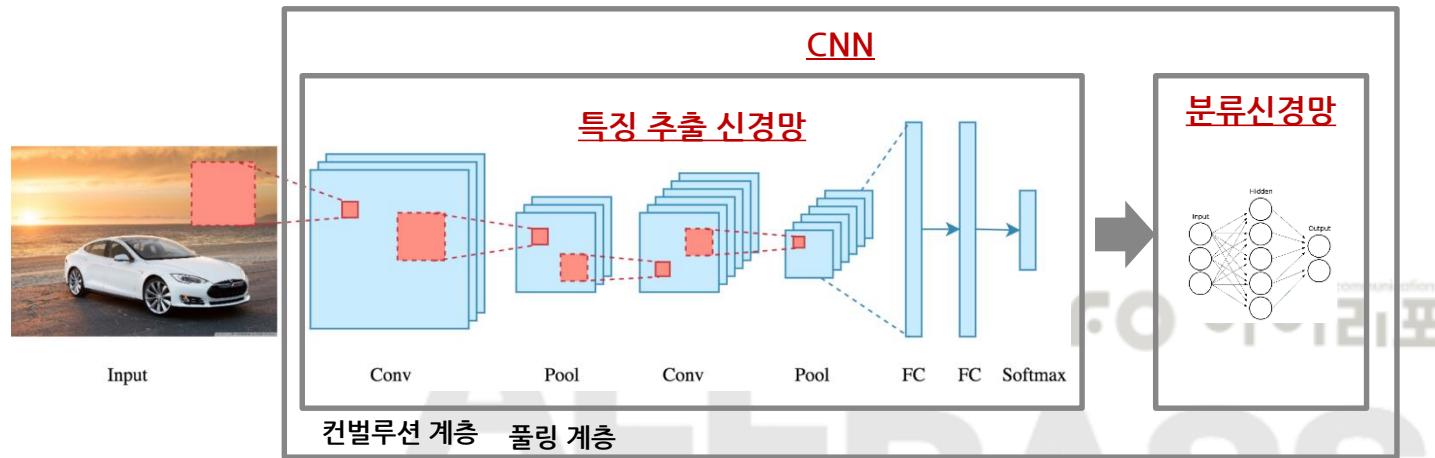
1. 이미지 처리에 적합한 인공신경망 알고리즘, CNN의 개요

- 뇌의 시각피질이 이미지를 처리하고 인식하는 원리를 차용한 신경망
- 기존에 사람이 직접 설계하던 특징 추출 작업을 인공지능을 이용해 자동화시켰음



CNN(Convolution Neural Network)

2. CNN의 구성도 및 구성요소

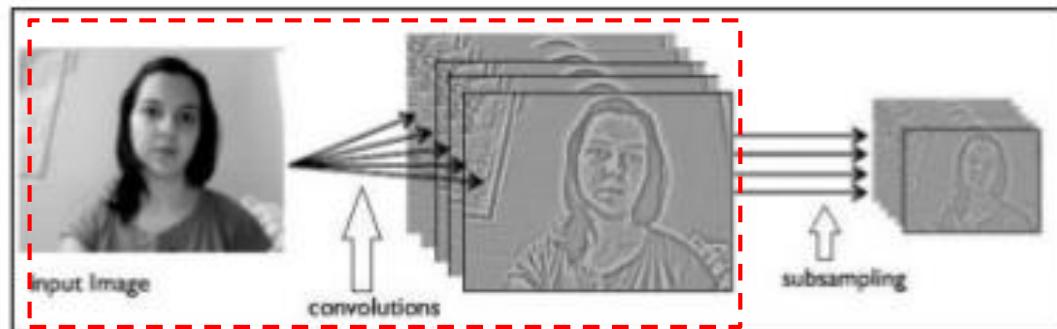


구분	기술요소		설명
Layer 구성	특징추출 신경망	Convolutional layer	<ul style="list-style-type: none">- 컨볼루션 연상을 통해 특징(feature)을 추출하는 레이어- 일종의 디지털 필터들을 모아놓은 계층- 컨벌루션 필터를 이용하여 <u>이미지에서 고유한 특징을 부각시킨 이미지(특징맵, Feature Map)</u>를 새로 만들어 내는 역할- ReLU, 시그모이드, Tanh 함수 사용
		Pooling layer	<ul style="list-style-type: none">- Sub sampling 통한 <u>차원의 축소</u>하는 레이어- 입력 이미지에서 특정 영역에 있는 픽셀들을 묶어서 하나의 대표값으로 축소함- 컨벌루션 필터가 필요하지 않음- max-pooling, average pooling 활용- 이미지의 크기를 줄여주어, 계산량도 줄이고 과적합을 방지하는데 도움이됨
	분류신경망	Fully connected layer	<ul style="list-style-type: none">- 이전 레이어의 모든 처리 결과를 하나로 연결하여 이미지의 특징을 구분(Classification)
성능 개선	ReLU		- Rectified Linear Unit, 기울기 사라짐(vanishing gradient) 문제 해결
	BigData		- 다양한 데이터로 학습 데이터 확보 (over fitting 문제 해결)
	Drop out		- 일부 레이어의 데이터 제거 (over fitting 문제 해결)

CNN(Convolution Neural Network)

3. Convolution layer

- 입력 특징 맵(Input Feature Map)을 필터연산으로 출력 특징 맵(Output Feature Map)을 추출하는 계층, 패딩(padding)연산, 스트라이드(stride)연산을 수행



[Convolution 후 Subsampling 처리]

패딩(padding)

1	2	3	0
0	1	2	3
3	0	1	2
2	3	0	1

(4, 4)
입력 데이터(패딩 : 1)

2	0	1
0	1	2
1	0	2

(3, 3)
필터

7	12	10	2
4	15	16	10
10	6	15	6
8	10	4	3

(4, 4)
출력 데이터

1	2	3	0	1	2	3
0	1	2	3	0	1	2
3	0	1	2	3	0	1
2	3	0	1	2	3	0
1	2	3	0	1	2	3
0	1	2	3	0	1	2
3	0	1	2	3	0	1

스트라이드 : 2

1	2	3	0	1	2	3
0	1	2	3	0	1	2
3	0	1	2	3	0	1
2	3	0	1	2	3	0
1	2	3	0	1	2	3
0	1	2	3	0	1	2
3	0	1	2	3	0	1



2	0	1
0	1	2
1	0	2



15

2	0	1
0	1	2
1	0	2



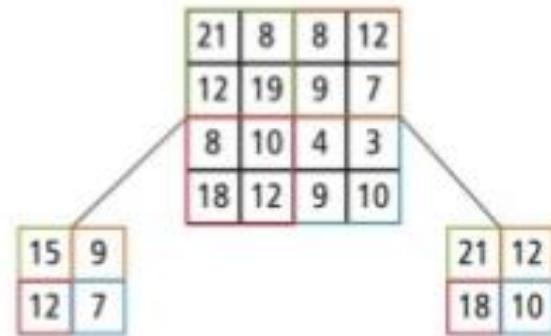
15	17



15	17

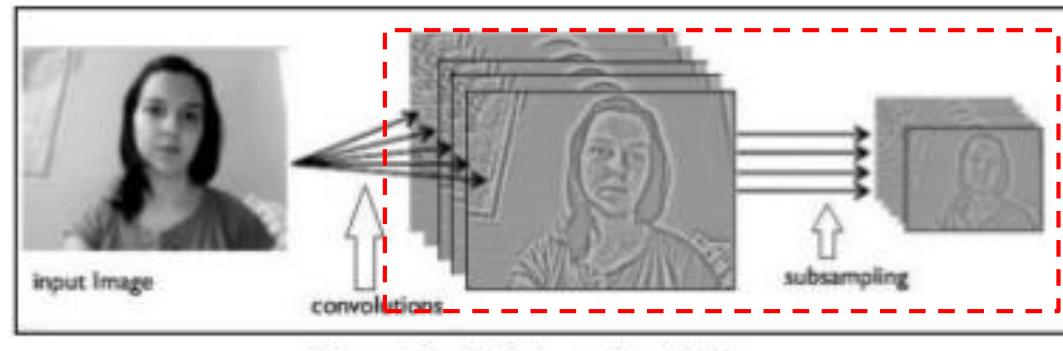
CNN(Convolution Neural Network)

4. Pooling layer



Average Pooling

Max Pooling

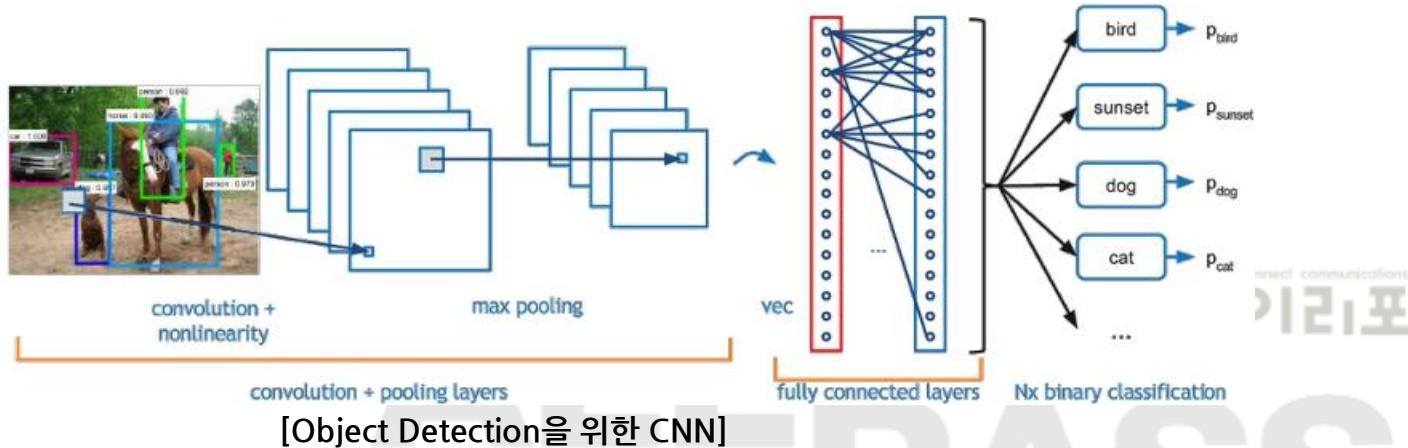


[Convolution 후 Subsampling 처리]

Max Pooling (최대 풀링)	Average Pooling (평균 풀링)	Stochastic Pooling (확률적 풀링)
<ul style="list-style-type: none">컨볼루션 데이터에서 가장 큰 것을 대표 값으로 취함직관적이고 간편최대값이 노이즈라면 Overfitting 유발	<ul style="list-style-type: none">컨볼루션 데이터에서 모든 값의 평균을 취함직관적이고 간편낮은 활성화 값이 평균에 포함됨으로 특성 대비율을 떨어뜨림	<ul style="list-style-type: none">컨볼루션 데이터에서 임의의 확률로 한 개를 선정 취함실행 방법이 단순범위 내 동일한 값이 여러 개 있다면 확률적으로 선택 가능성이 높아 대표성을 띤다.

CNN(Convolution Neural Network)

5. 객체인식(Object Detection)을 위한 CNN(Convolution Neural Network)의 한계



구분	설명
객체 인식을 위한 Image data	<ul style="list-style-type: none">대부분의 Image Data에는 여러 Object가 존재. 즉, 객체들은 다양한 영역에 분포되어 있으며, 어떤 영역에 있는지를 먼저 경계상자(Boundary Box)를 먼저 선별각 Object는 다른 크기와 종횡비를 소유
객체 인식을 위한 CNN	<ul style="list-style-type: none">물체가 존재할 수 있는 모든 크기의 영역(different scale & ratio)에 대해 sliding window 방식으로 이미지를 모두 탐색하면서 classification을 수행CNN은 정확도 높은 객체 추출이 가능하지만, 윈도우 검출 슬라이딩에서 획득한 수많은 이미지를 CNN으로 실행하는 것은 불가능

- 최종적으로 CNN은 하나의 Image에 포함된 Object들을 검출하기 위해 다양한 Region을 설정하고, 전 Image를 SCAN하게 되므로, 시간 소모가 큰 학습방법

R-CNN(Regions with CNN features)

기존 CNN은 전 Region에 대해 학습을 하였으나, **R-CNN은 Object가 존재할 만한 영역을 선별하여 학습을 진행**

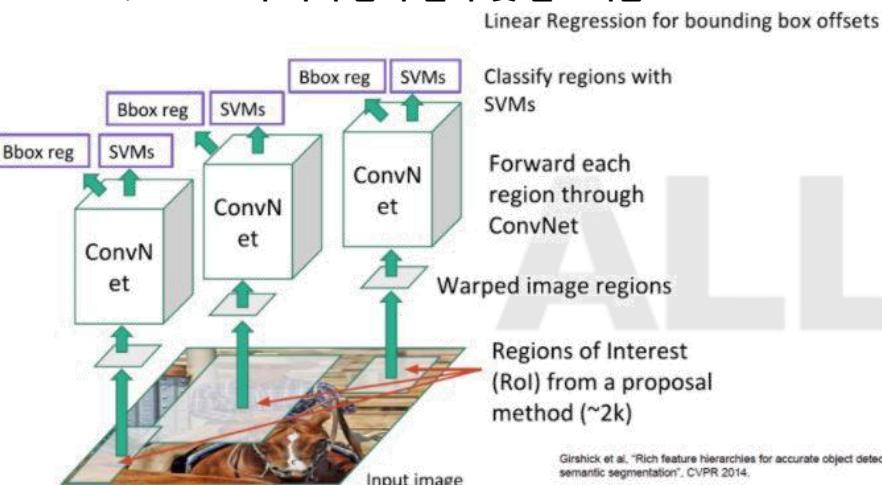
Object detection

Region Proposal

1. 선별적 영역 선정에서 객체 탐색, R-CNN의 개요

- Image classification을 수행하는 CNN과 이미지에서 물체가 존재할 영역을 제안해 주는 Region proposal 알고리즘을 연결하여 높은 성능의 **Object detection을 수행**하는 알고리즘

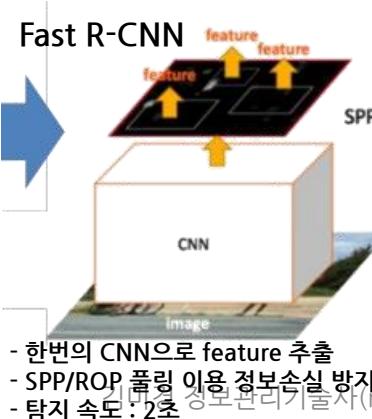
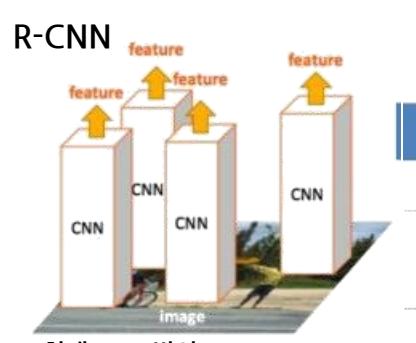
2. R-CNN의 객체 탐지 절차 및 알고리즘



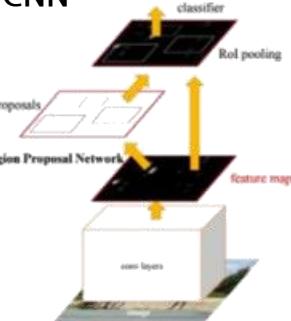
Process	세부 절차	설명
① Extract region proposals	Selective Search	Exhaustive search 방식과 Segmentation 방식을 결합하여 객체 인식이나, 검출이 가능한 후보 영역을 선정
	Region Proposal	Selective Search(SS)를 통하여 약 2,000개 가량의 Region Proposal을 추출
② Compute CNN features	Warping	선별된 영역을 Cropping하여 후보영역 이미지만 추출하고, 추출된 영역은 CNN으로 Input하기 위해 일정한 크기와 종횡비로 Resizing
	CNN (Convolution Neural Network)	일정한 size로 변경된 Image를 CNN알고리즘을 통해 학습 진행하고 이를 통해 CNN feature vector 획득
③ Classify regions	SVM (Support Vector Machine)	각 region proposal feature에 대한 classification을 수행
	Bounding-box regression	찾고자 하는 Object의 Region과 학습된 Region의 오차에 대해 Linear regression Model을 이용

- Region Proposal, CNN, SVM 알고리즘의 조합을 통해 객체 탐지 수행
- 기존 CNN에 비해 성능은 개선되었으나, ① 이미지 한 장에 추출된 2,000 개의 Bounding Box마다 CNN을 학습시켜야 하며, ② CNN, 분류를 위한 SVM, Bounding Box를 위한 선형 회귀까지 3 가지 모델을 모두 훈련시켜야 하는 한계점 존재

3. R-CNN의 한계점과 후속 알고리즘



Faster R-CNN



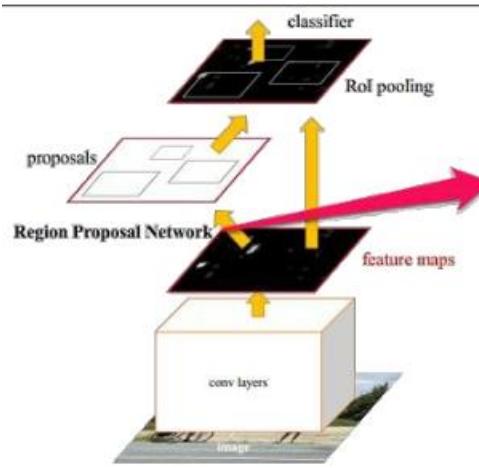
Faster R-CNN

RPN

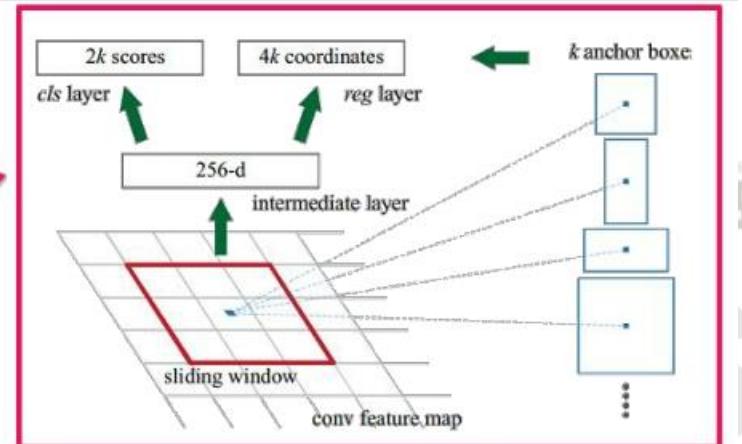
1. Real-Time의 Object Detection. Faster R-CNN

- 기존 Selective Search를 RPN(Region Proposal Network)에서 수행

2. Faster R-CNN의 개념도 및 알고리즘



[Faster R-CNN]



[RPN(Region Proposal Network)]

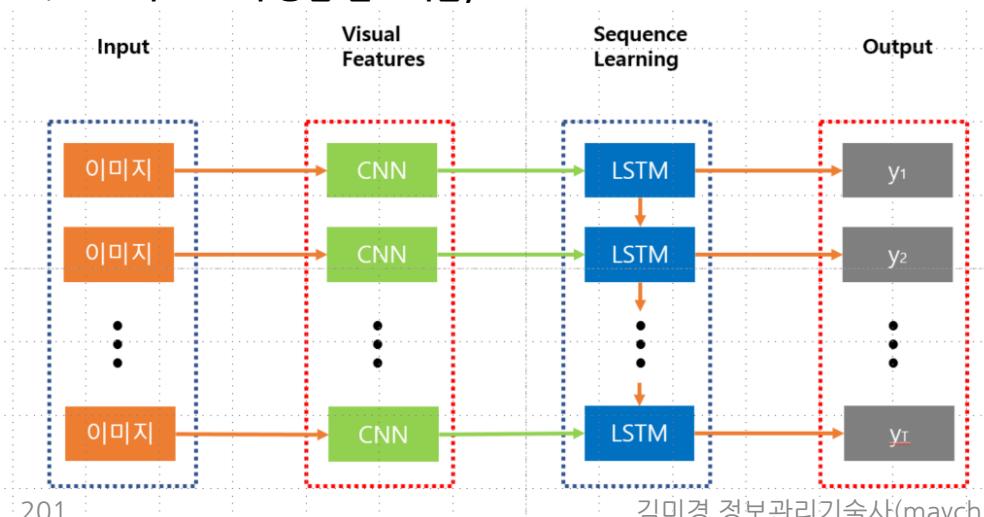
Process	설명
① CNN (Convolution Neural Network)	- 이미지를 분할하지 않고 전체 Level에서 CNN(Convolution Neural Network)을 이용하여 Feature Map을 추출
② RPN (Region Proposal Networks)	- Feature Map을 입력 받아 Object가 존재할 만한 사각형 형태의 Object Proposal 과 Objectness Score를 출력 - 이 결과는 ROI Pooling Layer에 전달 - RPN은 기존 Selective Search가 CPU에서 수행하던 것을 GPU에서 수행하게 하여 속도 향상을 획득
③ ROI Pooling Layer	- Feature Map의 ROI에 대해 Max-Pooling을 수행하여 고정된 길이의 ROI Feature Vector를 획득하고 이를 FCs(Fully-connected layers)로 전달
④ Softmax & Bounging-Box regressor	- Softmax Classifier를 통해 Object를 분류하고, Bounding-Box를 조정

CNN vs RNN

1. CNN vs RNN

기술요소	CNN	RNN
고유특징	<ul style="list-style-type: none"> ✓ 합성곱 레이어 <ul style="list-style-type: none"> - 특징 필터를 striding하여 합성곱 연산 후, 고차원 특징 추출. 필요 시 패딩 추가 ✓ 폴링(Max, Average) 레이어 <ul style="list-style-type: none"> - 차원 축소 통합 	<ul style="list-style-type: none"> ✓ LSTM (Long Short Term Memory) <ul style="list-style-type: none"> - Input / Output / Forget Gate 를 이용한 시간적으로 이전 데이터의 처리 수행
학습방법	✓ Classification - Fully connected layer를 이용한 분류 지도학습	✓ Sequential 학습 - Time unfolding, 과거 내용을 통한 현재 문맥 이해
활성화 함수	<ul style="list-style-type: none"> ✓ ReLU (Rectified Linear Unit) 통한 경사활성화 함수 ✓ Leaked ReLU 	<ul style="list-style-type: none"> ✓ 하이퍼볼릭 탄젠트 함수 ✓ Sigmoid 함수
오류역전파	✓ Fully connected Layer에서 오류역 전파 활용	✓ BPTT (Back Propagation Through Time) - Cell 연산에 대한 오류역 전파 활용
성능개선	✓ Drop Out 이용 Overfitting 방지	✓ GRU (Gated Recurrent Unit) <ul style="list-style-type: none"> - Reset, Update Unit 이용
적용분야	<ul style="list-style-type: none"> ✓ 구글 알파고, FaceNet ✓ 네이버 쇼핑의 스타일 추천 ✓ R-CNN (Region with CNN feature), 컴퓨터 비전 	<ul style="list-style-type: none"> ✓ 필기체 인식, 카드번호, 서명인식 ✓ NLP Speech, Speech To Text, 기계 번역, 비디오 분류

2. CNN과 RNN의 융합 알고리즘, Convolutional LSTM



- RNN 의 셀에 입력되는 입력 데이터가 2차원의 이미지 데이터인 경우, 차원이 심하게 증가하고, 동시에 공간적 데이터임. **CNN으로 이미지 특징 벡터를 먼저 추출하고, 이후 RNN 적용하는 방법**
- RNN에서 시간적 의미뿐만 아니라 공간적 의미까지 처리가 가능함. 기상, 날씨 예측이나 동영상 관련 문제에 활발히 연구됨

YOLO (You Only Look Once)

Bounding Box

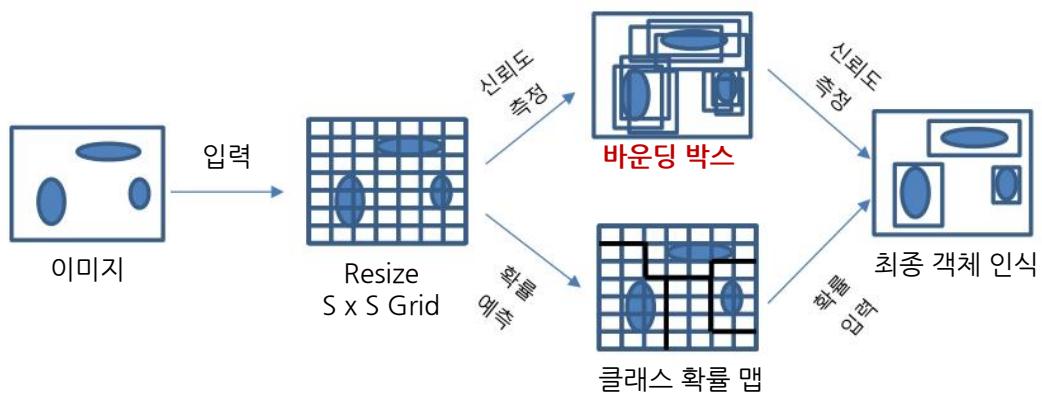
Fast 객체 탐색

1. 딥러닝 기반의 FAST 객체 탐색 및 최적화 지원, YOLO (You Only Look Once)의 개요

- 빠른 속도로 객체 탐색 위해 그리드 Bounding box를 통해 최적 객체 탐색 및 분류하는 딥러닝 기반 Fast 객체 탐색

특징	설명
Unified Detecting	- 하나의 뉴럴넷을 사용, 하나의 이미지에서 동시에 모든 물체의 바운딩 박스 탐색
빠른 속도	- R-CNN, Fast R-CNN, Faster R-CNN 대비 월등히 빠른 인식 속도
높은 정밀도	- 하나의 물체에 하나의 바운딩 박스만으로 예측
한계점	- 작은 물체가 모여 있을 경우 인식률 저하 현상

2. YOLO 기반 객체 인식 절차 및 구현을 위한 주요 기술



구분	기술 요소	설명
객체탐색 기술	Grid	- Image를 $S \times S$ 격자로 구성 - 인접 grid기반 객체 인식
	Bounding Box	- 객체 경계 결정 알고리즘 - x, y, w, h, Confidence Score
	Darknet	- 신경망 실행 프레임워크 - CUDA, OpenCV 영상처리
객체분류 기술	CNN	- Convolutional Layer - Pooling, Connected Layer
	Confidence Score	- 각 B-Box Grid cell 신뢰수치 - $\text{Pr}(\text{Object}) \times \text{IOU}$
	Class Probability	- Loss 기법 기반 분류 예측 - 확률: $\text{Pr}(\text{Class} \text{Object})$

절차	핵심기술	설명
<u>S x S 그리드 분할</u>	- 이미지 Resize, Grid 셀 분할	- 해당 셀에 물체의 중심이 있는지 판단
<u>바운딩 박스 생성</u>	- 각 셀당 신뢰도 측정 - 신뢰도 점수=확률(객체) * IoU(truth, predict)	- 모델이 박스안에 물체가 어느 정도 있는지 판 단하는 지와 정확도를 표시
<u>클래스 확률 맵 구성</u>	- $P(\text{Class} \text{Object})$	- 해당 셀에 물체가 있을 때 어떤 클래스가 있을지 조건부 확률을 계산
<u>최종 객체 인식</u>	- CNN Network - Non-Maximal Suppression	- GoogleLeNet, VGGNet 등 CNN Network 이용 객체 분류 - 인식 속도는 FPS, 인식의 정확도는 mAP(mean Accuracy Precision)을 이용해서 평가

- YOLO 기법은 속도가 빠르지만 동일 cell에 여러 객체 존재 시 인식률 저하 발생

YOLO (You Only Look Once)

3. YOLO 와 R-CNN 의 비교

항목	YOLO	R-CNN
방법	- 모든 이미지 영역에서 Localization과 Classification 수행	- 2000개의 Region Proposal - 각 Region별 CNN 수행
단계 구성	- One-Stage 방식	- Two Stage 방식
인식 속도 (FPS)	- 매우 빠름	- 매우 느림
인식 정밀도 (mAP)	- 합리적 수준의 높음	- 매우 높음

4. YOLO의 기술적 한계점 및 고려사항

한계점	고려사항
<ul style="list-style-type: none">- 각 cell은 하나의 클래스만 예측- Training Data 통한 학습만 가능- 예측 시 Localization 부정확	<ul style="list-style-type: none">- Fast R-CNN과 함께 사용하여 보완 가능

에너지 기반 모델(EBM, Energy Based Machine)

1. 에너지 기반 모델의 개요

- 각 상태(x)에 대해 에너지를 정의하고, 모든 원하는 상태들의 에너지가 최소 가 되도록 에너지 함수의 파라미터들을 학습하는 모델
- 에너지 함수를 이용하여 자연계에서 볼츠만 분포 법칙을 신경망에 적용 한 모델
- 신경망과 빗데어 보면 뉴런은 볼츠만 분포하에서 운동하는 분자, 뉴런의 State는 분자의 에너지 상태라고 해석

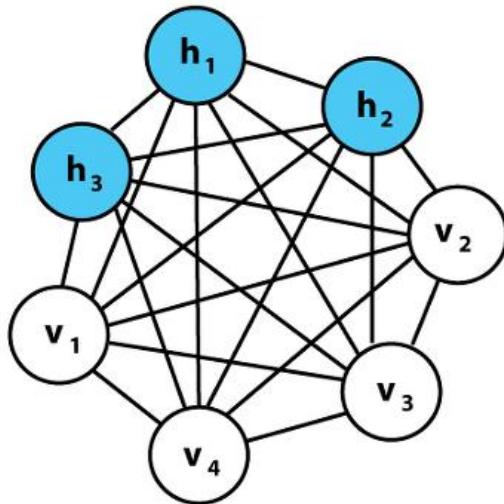


볼츠만 머신(Boltzmann machine)

1. 확률적으로 순환하는 신경망 네트워크, 볼츠만 머신의 개요

- Hidden unit 을 추가한 Energy Based Machine
- Unit 간의 연결에 제약이 없이 모두 연결될 수 있는 모델

2. 볼츠만 머신의 네트워크 구조도 및 에너지 함수



$$Energy(\mathbf{x}, \mathbf{h}) = -\mathbf{b}'\mathbf{x} - \mathbf{c}'\mathbf{h} - \mathbf{h}'\mathbf{W}\mathbf{x} - \mathbf{x}'\mathbf{U}\mathbf{x} - \mathbf{h}'\mathbf{V}\mathbf{h}$$

3. 볼츠만 머신의 문제

- 모델이 대칭적이고 유닛이 Binary Unit이라는 가정 하에 EBM에서 했던 논의를 그대로 이어나갈 수 있다.
- 에너지로부터 확률을 구하고 Log-likelihood gradient를 계산한 다음 MCMC Sampling을 통해 stochastic하게 gradient를 추정 할 수 있다
- 하지만 Stochastic하게 gradient를 추정한다고 해도 너무 많은 (제약이 없는) 연결 때문에 일반적으로 계산이 비싸고 오래 걸린다.
- 에너지 평형 상태의 표본을 수집하는 시간이 모델의 사이즈, 연결 강도의 크기에 대해 지수적으로 증가한다.

RBM(제한된 볼츠만 머신, Restricted Boltzmann machine)

확률모델

무감독학습

1. 대표적 무감독학습 신경망 모델, RBM의 개요

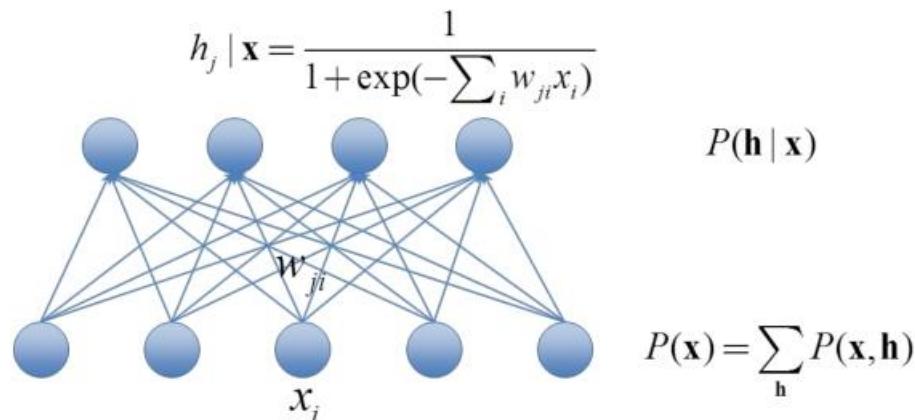
- 입력 집합에 대한 확률 분포를 학습 할 수 있는 생성적 확률적 인공 신경망
- 기존의 볼츠만 머신에서 유닛들간의 연결에 특별한 제한을 걸어 학습 시간을 크게 줄여 실질적인 사용이 가능하도록 변형한 신경망
- Vanishing Gradient 문제를 해결하기 위해 고안한 모델
- 같은 층 내부의 노드 간의 연결은 없고, 층과 층 사이와의 연결만 존재 \rightarrow 제한적이라는 이름이 붙음
DBN(DBN, Deep Belief Network)의 기본적인 구성요소 임

2. RBM 과 다층 신경망과의 차이점

- 구조 측면은 동일
- 퍼셉트론은 결정적 모델인데 반해서 볼쓰만 머신은 확률 모델

3. RBM의 네트워크 구조 및 에너지 함수

- visible layer 1개, hidden layer 1개로 구성된 완전 이분 그래프 모델로 visible-visible, hidden-hidden 유닛들간의 연결이 없음



iLIFO 아이리포
Contents connect communications!

$$\text{Energy}(\mathbf{x}, \mathbf{h}) = -\mathbf{b}'\mathbf{x} - \mathbf{c}'\mathbf{h} - \mathbf{h}'\mathbf{W}\mathbf{x}$$

DBN(Deep Belief Network)

층별학습

RBM → DBN

I. Gradient descent vanishing 해결 위한, 심층 신뢰망 (DBN, Deep Belief Network)의 개념

- 입력층과 은닉층으로 구성된 RBM을 블록처럼 여러 층으로 쌓아 형태로 연결된 신경망 (DNN의 일종)
- RBM을 기반으로 비지도학습을 통해 가중치를 균접값으로 보정하여 마지막 튜닝과정에서 가장 가까운 최종 가중치를 계산하는 방법
- FNN (FeedForward Neural Network) 에서 신경망의 층 수가 늘어나면서 발생하는 경사감소 소멸(Gradient Descent Vanishing) 문제 해결 필요

2. 심층 신뢰망 (DBN, Deep Belief Network)의 특징 및 일반 신경망과의 차이점

필요성	설명
비지도 학습	- 결과값없이 입력값으로만 학습 수행
데이터 부족	- 학습 데이터가 충분하지 않을 때 유용
겹층 RBM	- 사전 훈련된 RBM을 층층이 쌓아 만듦



일반 신경망	심층신경망(심층신뢰망)
<ul style="list-style-type: none">• 원시 데이터(original data)에서 직접특징(handcrafted feature)를 추출해서 만든 특징 벡터(feature vector)를 입력으로 사용(특징 백터들이 품질에 영향 미침)	<ul style="list-style-type: none">• 특징추출과 학습을 함께 수행• 데이터로부터 효과적인 특징을 학습을 통해추출 (우수한 성능)

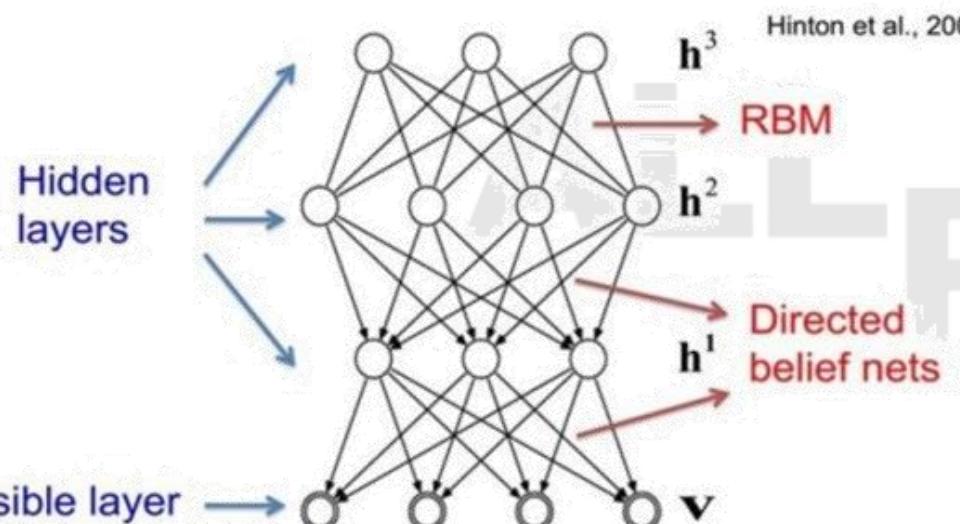
원시데이터 → 특징추출
(특징벡터) → 신경망 → 출력

원시데이터 → 심층 신경망
(Deep Neural Network) → 출력

DBN(Deep Belief Network)

2. 심층신뢰망의 구조 및 구성 절차

- Visible layer 기반으로 여러 층의 RBM (Restricted Boltzmann Machine)을 쌓아 심층신뢰망 구성
- RBM을 이용한 DBN은 HMM 기반, 음성/영상인식기술에 적용



DBN 구성 절차	설명
	① Visible layer와 h_1 의 첫 RBM(RBM1)의 사전 훈련
	② 첫 번째 층 입력 데이터와 매개 변수 고정하여 두 번째 층 RBM2 사전 훈련
	③ 원하는 층 수 만큼 RBM을 쌓아 올려 전체 DBN을 완성

DHN(Deep Hyper Network)

1. DHN(Deep Hyper Network)

- **하이퍼넷을 다층으로 적층한 딥러닝 모델**로서 각각의 하이퍼넷층은 아래층의 하이퍼넷 유닛들을 결합하여 새로운 하이퍼에지를 **만들고 이를 새로운 유닛으로 사용**
- 스트림 형태의 순차적으로 관측되는 데이터로부터 실시간에 온라인 점진적 학습을 통해서 고차적 관계구조의 지식을 자동으로 습득하는 평생 학습방법

특징	설명
몬테칼로 알고리즘	• 경사도 기반의 파라메터 튜닝 방법을 사용하는 것 외에 하이퍼그래프 구조에 기반 한 Sparse Population Coding 기법 위에서 진화탐색에 기반
연결론적인 학습과 구조학습	• 하이퍼그래프 구조 기반의 네트워크를 사용함으로써 연결론적인 학습이 용이할 뿐만 아니라 구조학습이 가능하여 명시적인 구조와 문법을 표현하는 지식 구조를 추출
온라인 점진적 학습	• CNN과 DBN은 배치 학습을 기본으로 한다. 반면에 DHN은 온라인 점진적 학습을 목적으로 설계

2. DHN의 개념도 및 학습 방법

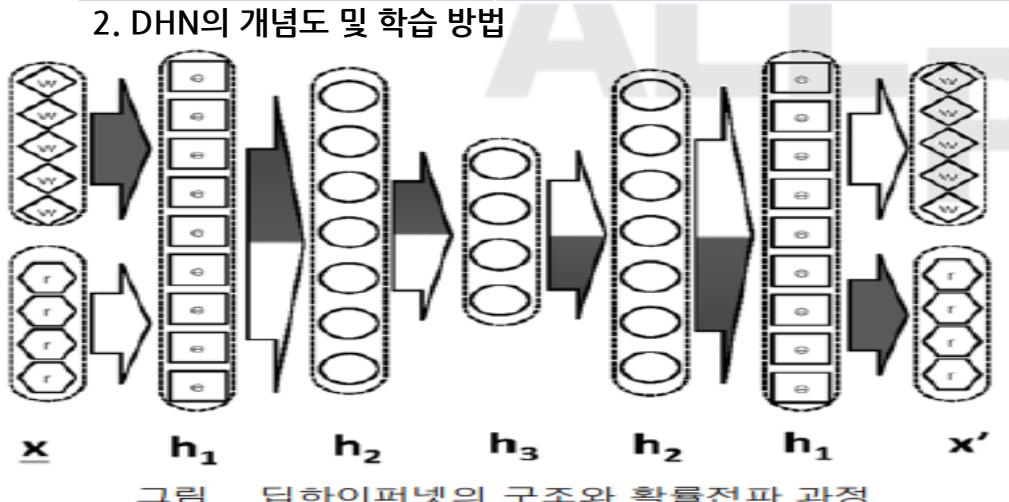


그림 딥하이퍼넷의 구조와 확률전파 과정

학습 단계	설명
1단계	<ul style="list-style-type: none">• 새로운 학습 예 x를 가져온다 \rightarrow 입력 층에 관측 변수값들을 할당한다.• 이로부터 상위 층으로 확률값 $P(h_1 x)$을 계산하고 변수값을 순차적으로 할당
2단계	<ul style="list-style-type: none">• $\rightarrow P(h_2 h_1)$를 계산하면서 이를 반복하여 최상위 은닉변수 값을 $P(h_n h_{n-1})$로부터 할당
3단계	<ul style="list-style-type: none">• 최상위의 확률분포 $P(h_n)$로부터 은닉변수 값을 할당하고 이를 거꾸로 하위 층으로 전파 확률값 $P(h_{n-1} h_n)$을 계산하고 은닉변수값들을 순차적으로 할당하며 최하위 층의 확률 분포 $P(x)$를 추정하고 이로 부터 변수값 즉 관측 변수값 x를 할당
4단계	<ul style="list-style-type: none">• 관측변수 벡터와 생성한 관측변수 벡터를 비교하여 그 차이를 줄여주는 방향으로 중간 은닉 층 들에 있는 하이퍼에지의 구성과 그 가중치 W를 변경
5단계	<ul style="list-style-type: none">• 위의 4의 과정을 N 번 반복한다

- 상향 추론과 하향추론이 같다는 것을 이용하여 다양한 추론과 학습
- 딥하이퍼넷은 관측된 데이터 변수들 $x = (x_1, x_2, \dots, x_V)$ 의 결합확률분포를 표현하는 다층 구조의 확률그래프 모델

DHN(Deep Hyper Network)

3. 타 딥러닝 모델과의 특성 비교

구분	Deep Belief Network(DBN)	Convolution Neural Network(CNN)	Deep Hypernet (DHN)
감독/무감독	감독/무감독	감독	감독/무감독
변별/생성모델	생성	변별	생성
예측/모듈이해	예측++/모듈-	예측+++/모듈+	예측+/모듈+++
추론가능성	추론++	추론+	추론++++
연결성	Full/Compact	Partial/Convolved	Partial/Sparse
깊이	깊이+++	깊이++++	깊이++
배치/온라인학습	배치	배치	온라인

ALL-PASS



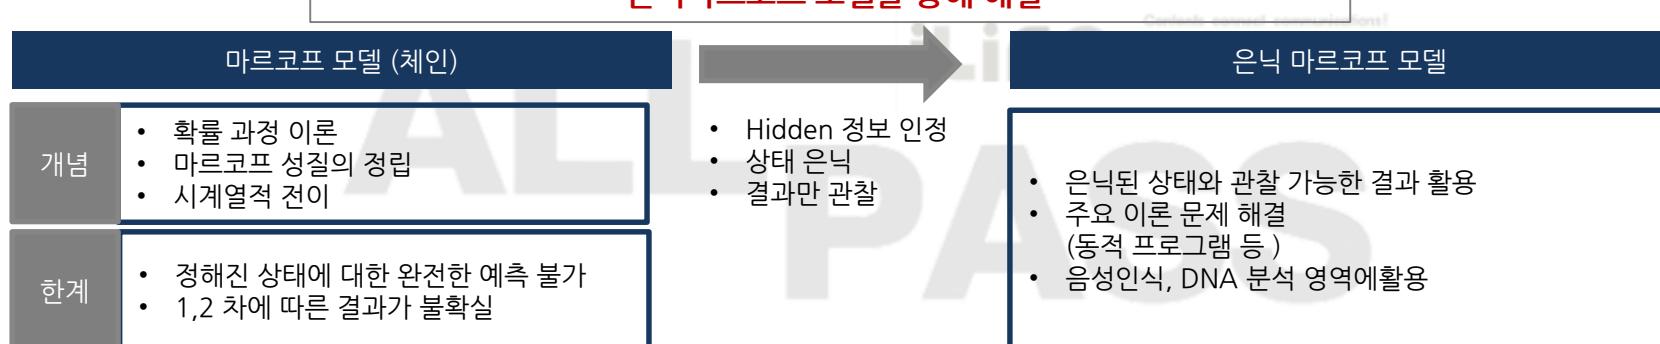
HMM(Hidden Markov Model, 은닉 마르코프 모델)

이중 확률적 모델

1. Hidden Parameter 추정, HMM(Hidden Markov Model)의 개요

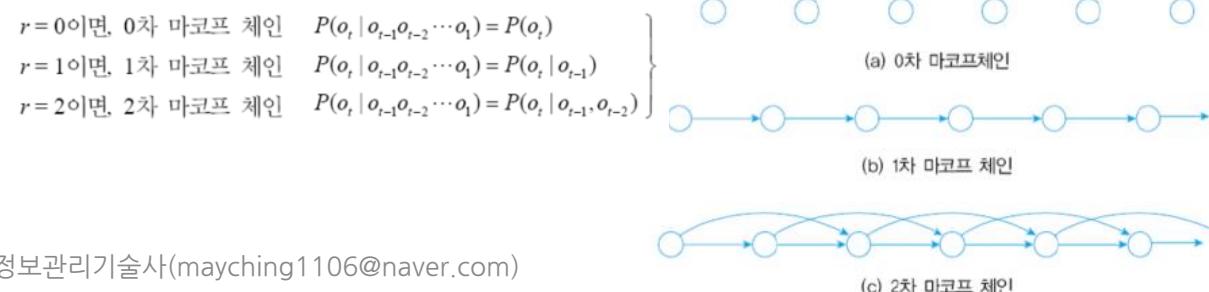
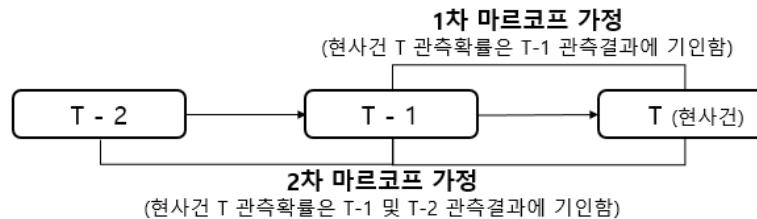
- 관측 불가능한 은닉 상태를 관측이 가능한 다른 과정으로 추정하는 **이중 확률론적 모델**
- observation을 이용하여 **간접적으로 은닉된 state를 추론하기 위한 문제를 풀기 위해**, Markov model에 은닉된 state와 직접적으로 확인 가능한 observation을 추가하여 확장한 모델 (**순차 데이터나 문맥 의존 데이터를 인식하는 가장 대표적인 모델**)
- 시스템이 은닉된 상태와 관찰 가능한 결과의 두 가지 요소로 이루어졌다고 보는 통계 기반의 모델.**

**마르코프 체인의 상태 관측에 따른 매개변수의 불확실성을
은닉마르코프 모델을 통해 해결**



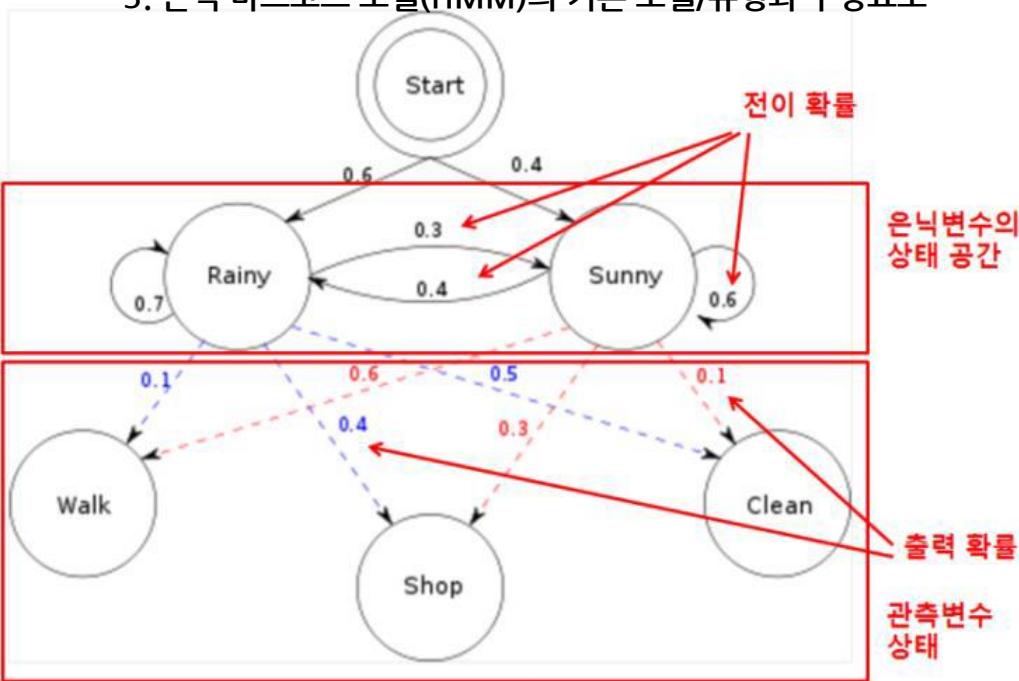
2. HMM 기반이 되는 마르코프 모델(MM)의 가정

- MM : 어떠한 날씨, 주식가격 등과 같은 어떠한 현상의 변화를 확률 모델로 표현한 것
- 가정 : 특정 사건이 관측될 확률은 이전 시간 관측 결과에 의존하며, 상태를 직접 볼 수는 없음
- **마르코프와 히든마르코프의 차이: 'Hidden'에서 x의 state 자체는 보이지 않음. 오직 x state 각각의 관찰값 y값만 볼 수 있다.**



HMM(Hidden Markov Model, 은닉 마르코프 모델)

3. 은닉 마르코프 모델(HMM)의 기본 모델/유형과 구성요소



5. HMM의 문제점

문제	설명	해결 가능한 알고리즘
확률평가 문제	모델에서 관측값이 여러개일 때 각 출력될 확률이 얼마인지 효과적으로 계산할 수 있어야 한다. 각 확률 값에 따라 최적의 모델을 다수의 모델로부터 선택할 수 있기 때문이다.	forward, backward
최적상태열을 찾는 문제	가장 최적의 숨겨져 있는 상태열을 어떻게 찾아낼 것인지 문제	비터비(Viterbi)
파라미터 추정의 문제	-우도(likelihood)를 최대화 하는 모델의 각 파라미터 추정은? -곧, 관측열을 가장 잘 설명하는 모델의 파라미터들을 어떻게 최적화하여 구할지의 문제이다. -'학습의 문제'라고도 한다. (성능을 결정하는 중요한 사항)	바움-웰치 재추정

구조	설명
은닉변수	의존하는 것을 관측할 수 있는 변수
은닉 변수 상태 공간	은닉 마르코프 모델의 모수(parameter)로는 전이 확률(transition probability)과 출력 확률(emission probability)
전이 확률	상태가 변화를 가지는 확률
출력확률	관측변수들의 분포를 제어하는 집합
출력확률분포 도	마르코프체인에 기반한 상태들의 확률분포

4. 마르코프의 대표적인 아키텍처

구분	아키텍처	설명
어고딕 (Ergodic) 모델		완결연결구조
좌우 (Left to Right) 모델		상태 전이가 왼쪽에서 오른쪽으로 일어남, 음성인식에서 사용

HMM(Hidden Markov Model, 은닉 마르코프 모델)

은닉 마르코프 모델(hidden Markov model(HMM))

- ▶ 순차 데이터 : 시간성을(temporal property) 갖는 데이터
- ▶ 순차 데이터를 갖는 패턴을 인식하기 위해서는 데이터에 내포되어 있는 시간성을 적절히 표현하고 그것으로부터 원하는 정보를 추론할 수 있는 모델이 필요하다.
- ▶ 은닉 마르코프 모델(hidden Markov model(HMM))은 이런 능력을 가진 가장 대표적이고 가장 널리 사용되는 모델이다.
- ▶ HMM이 사용되는 분야
 - ▶ 패턴 인식
 - ▶ 컴퓨터 비전
 - ▶ 데이터 마이닝
 - ▶ 정보 검색
 - ▶ 생물 정보학(bioinformatics)
 - ▶ 신호처리
 - ▶ 데이터베이스
- ▶ 등의 문제 해결하는데 많이 사용

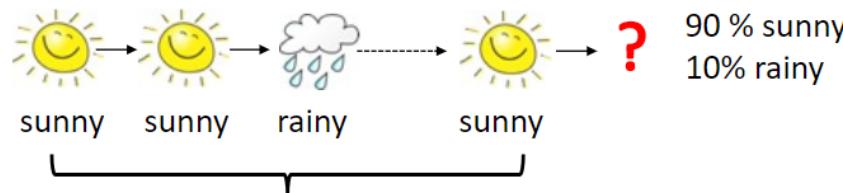
자연어 처리
음성인식
온라인 필기 인식
DNA 열 찾기
제스처 인식
영어 발음 교정
음악 인식



HMM(Hidden Markov Model, 은닉 마르코프 모델)

출처 : <https://bioinformaticsandme.tistory.com/53>

1. 날씨를 예로 transition probability(전이확률) 이해하기



State transition probability (table/graph)

(The probability of tomorrow's weather given today's weather)

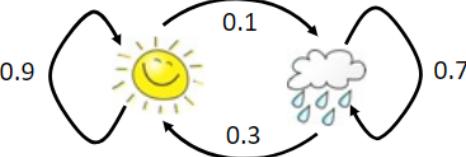
Output format 1:

Today	Tomorrow	Probability
sunny	sunny	0.9
sunny	rainy	0.1
rainy	sunny	0.3
rainy	rainy	0.7

Output format 2:

	sunny	rainy
sunny	0.9	0.1
rainy	0.3	0.7

Output format 3:



- 날씨가 'Sunny' 와 'Rainy' 의 두가지 상태가 있고, 오늘 날씨가 Sunny였다면 내일의 날씨가 어떤 상태일지 궁금하다.
- 우리는 기존 데이터(training set)에 근거하여 Today \rightarrow Tomorrow에서 날씨가 바뀌는 확률을 구할 수 있다 (Output format 1).
- Output format 2와 3은 format 1과 같은 의미를 지닌다.
- 참고로 오늘 날씨에서 다음날 날씨 예측 확률의 합이 항상 1 이란 사실을 기억하자 (예, 0.9 (sunny) + 0.1 (rainy) = 1).
- 우측 그림은 날씨가 'cloudy' 가 추가 됐을 뿐, 위에서 언급한 내용과 동일한 transition probability의 내용이다.

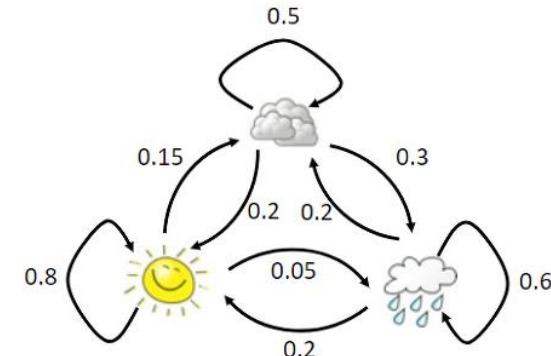


State transition probability (table/graph)

Output format 1:

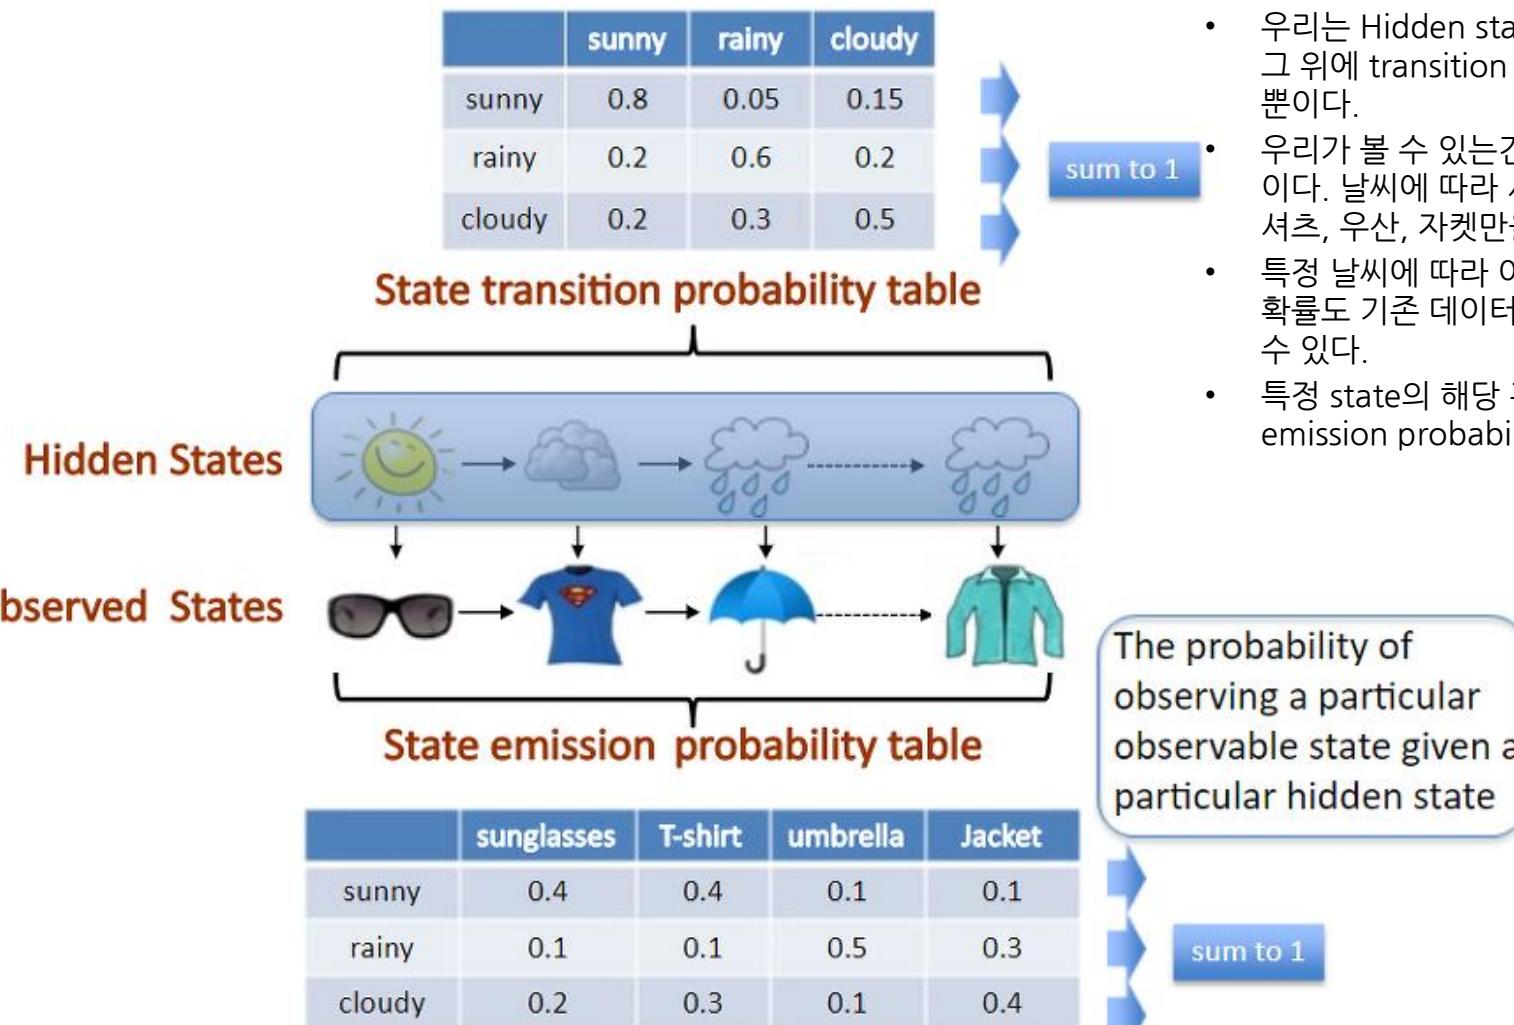
Today	Tomorrow	Probability
sunny	sunny	0.8
sunny	rainy	0.05
sunny	cloudy	0.15
rainy	sunny	0.2
rainy	rainy	0.6
rainy	cloudy	0.2
cloudy	sunny	0.2
cloudy	rainy	0.3
cloudy	cloudy	0.5

Output format 3:



HMM(Hidden Markov Model, 은닉 마르코프 모델)

2. 날씨의 예로 emission probability (출력확률) 이해하기



- 우리는 Hidden state, 즉 날씨를 볼 수 없다. 다만, 그 위에 transition probability 의 정보들만 있을 뿐이다.
- 우리가 볼 수 있는건 관찰값인 'Observed state'이다. 날씨에 따라 사람들이 착용한 선글라스, 티셔츠, 우산, 자켓만을 볼 수 있다.
- 특정 날씨에 따라 어떤 아이템을 착용할 것인지의 확률도 기존 데이터(training set)에 기반해 만들 수 있다.
- 특정 state의 해당 관찰값이 보일 확률이 emission probability(출력 확률) 이다

GAN(적대적 생성신경망)

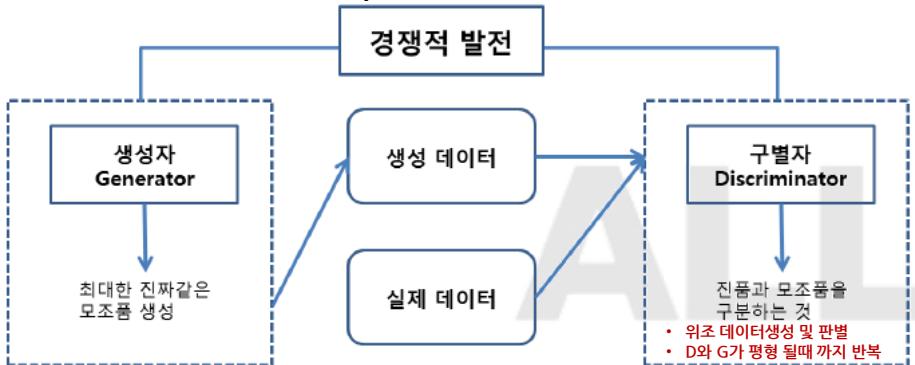
- MinMax Problem : 최소화와 최대화 경쟁 기반 성능 향상

비지도학습 경쟁학습 생성기, 판별기

1. MinMax Problem 기반 성능 강화 비지도 학습 기술, GAN(Generative Adversarial Network)의 개요

- 서로 대립하는 두 시스템이 서로 경쟁하는 방식으로 학습을 진행하는 비지도 학습방식의 신경망 모델 (경쟁을 통한 원본 복제 기술)
- 학습 방법 : 생성자(Generator)와 판별자(Discriminator)가 서로 경쟁하는 과정을 통해 정보를 학습

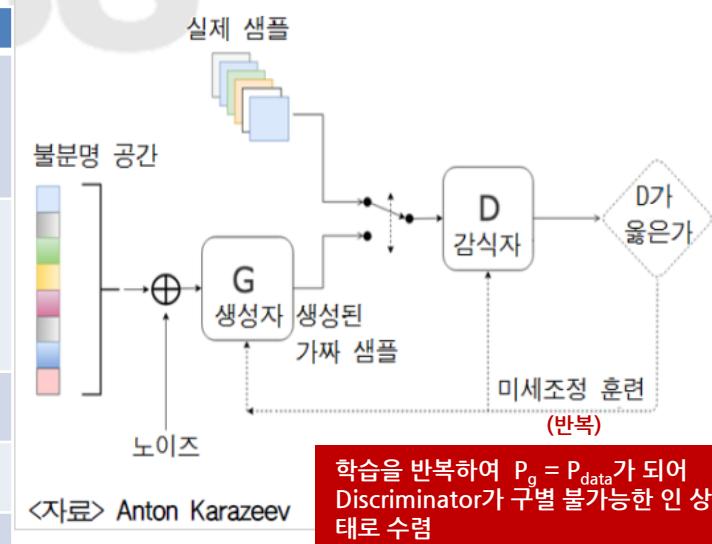
2. GAN의 개념도, 구성요소 및 동작 원리



구분	절차	설명
Generator (생성기)	데이터 선택	- 적절한 샘플을 랜덤하게 Training Set에서 선택
	데이터 생성	- 이미지의 특징들을 랜덤하게 추출, 부분적 합성하여 새로운 이미지 생성
Discriminator (판별기)	데이터 선택	- Training Set에서 이미지와 G로부터 만들어진 Fake 이미지를 입력받아 랜덤하게 선택
	판별	- 선택되어진 이미지가 실제 이미지인지 가짜 이미지인지 식별
Tune Training	1) D가 옳은 판단	- G는 자신의 네트워크에 사용된 변수를 업데이트하여 개선된 Fake 이미지 생성
	2) D가 틀린 판단	- D는 자신의 네트워크에 실수로부터 학습
	3) D와 G는 학습에 따른 보상	- D와 G는 학습에 따른 보상

• 위 과정을 반복하여 D 와 G 의 평형상태가 될 때까지 수행

구분	핵심기능	설명
Discriminator (D로 표시)	- 정확도최대화 - Convolution	- 입력 데이터 진위여부 판별 - $D(x) = 1, D(G(z)) = 0$ - Classifier 하는 인공 신경망 (실제이미지와 가짜 이미지를 판별하는 역할) - 입력 데이터가 실제데이터인지 모조데이터인지 구별하는 역할 - 만약 생성기가 산출한 모조데이터를 판별기가 50% 확률로 진위 여부를 판단한다면 학습을 종료
Generator (G로 표시)	- 정확도최소화 - Deconvolution	- 랜덤 노이즈 기반 유사 변환 - data 패턴 모사, $D(G(z)) = 1$ - Random Sample Data(Fake Data)를 만드는 인공 신경망 - 이미 존재하는 데이터와 비슷한 모조데이터를 생성하는 역할을 수행 - 실제 이미지는 아니지만 매우 정교하게 조작된 이미지로 D를 속이는 역할 - 만약 생성기의 모조데이터가 실제데이터에 가깝다면 판별기는 판별의 기능을 상실
학습 데이터(x)	- 샘플 데이터 - 패턴 다양화	- 모사할 original 샘플 데이터 - Real data, 학습량 기반
잠재 변수	- 랜덤 노이즈 - 랜덤 벡터	- 모사 데이터 생성 벡터 - 데이터 생성 시 입력
활성함수		- 시그모이드 함수



GAN(적대적 생성신경망)

3. GAN의 목적함수 및 학습방법

GAN 목적함수

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

데이터셋의 데이터를
「진짜」로 식별 생성된 데이터를 「위조」로 식별

4. GAN 주요 알고리즘

유형	설명	활용
DCGAN	- Deep Convolutional Generative Adversarial Networks - GAN과 영상처리에 특화된 딥러닝 기술인 CNN을 결합한 기술	- 이미지 생성
SRGAN	- Super-Resolution Generative Adversarial Networks - 저해상도 이미지를 고해상도 이미지로 변환하는 기법	- 회화 그림 관련 응용 프로그램에 적용
Stack GAN	- Stack GAN, Stacked Generative Adversarial Networks - 입력된 문장과 단어를 해석해 이미지를 생성하는 인공지능 기법	- 단어, 문장의 시각화
3D-GAN	- MIT 의 AI 연구팀이 공개한 입체 모델 생성 네트워크 - 가구 사진을 통해 교육시키면 3D-GAN은 가구를 3 차원으로 표현	- 3D 입체 모델
Cycle GAN	- 인공지능이 자율적으로 학습하여 이미지의 스타일을 다른 스타일로 변환시킬 수 있는 기술	- 이미지 변환
Disco GAN	- 인공지능이 자율적으로 서로 다른 객체 그룹 사이의 특성을 파악하여 양자 사이의 관계를 파악할 수 있는 기술	- 객체 사이 관계 및 특성 파악

- 200 여 개에 달하는 GAN의 변형 기술 연구가 폭넓게 진행되고 있는 이유 : GAN이 현재 딥러닝이 안고 있는 많은 문제를 해결해 줄 강력한 무기를 제공할 수 있기 때문임

5. GAN의 응용 분야와 적용 사례

응용분야	설명
새로운 이미지 생성과 이미지 복원	<ul style="list-style-type: none"> 이미지 생성 인터페이스인 iGAN(Interactive Image Generation via GAN)은 간단한 스케치로 이미지를 자동으로 생성 화질이 선명하지 않은 사진을 GAN을 통해 복원하는 기능 (SRGAN)
사람이나 물체의 동작을 흉내 내는 인공지능 개발	<ul style="list-style-type: none"> 2017년 7월 구글 딥마인드는 사람과 물체의 보행 능력을 흉내 내는 인공지능을 개발
GAN 기반의 인공지능을 활용한 신약 개발	<ul style="list-style-type: none"> 인실리코 메디슨은 320만 개의 유전자 발현 데이터와 650만 건의 혈액 테스트 결과 등 자사가 보유한 데이터를 바탕으로 신약에 활용될 새로운 화합물을 개발

- 예) A는 위조지폐를 만들어 내는 시스템이고, B는 위조지폐를 감별하는 시스템이라고 가정할 경우, A와 B가 경쟁하는 과정을 통해 B가 위조지폐를 구분할 수 없을 때 까지 A가 학습

arg max D: 여기에서는 목적함수를 극대화하는 분류망 D를 찾는다

- 첫 번째 항 $E[\log D(x)]$ 은 실제 데이터(x), 예를 들어 진짜 그림을 넣었을 때의 목적함수의 값이다.
- 두 번째 항 $E[\log(1-D(g(z)))]$ 은 가짜 데이터($G(z)$), 즉 생성망이 만들어낸 그림이 들어가 있다. 그리고 $\arg \max D$ 인데 항내부는 $1-D(G(z))$ 이다. 다시 말해 둘째 항의 극대화는 $D(G(z))$ 의 극소화다.
- 결과적으로, 이 두 항의 목적함수를 이용해
- 진짜 그림을 넣으면 큰 값을,
- 가짜 그림을 넣으면 작은 값을
- .. 출력하도록 구별망 D를 열심히 학습시키자는 것이다.

arg min G: 이 말은 목적함수를 극소화하는 생성망 G를 찾자는 이야기다.

- G 는 두 번째 항에만 포함되어 있다.
- 전체 함수를 극소화하는 G 는, 둘째 항을 극소화하는 G 이고, 결국 $D(G(z))$ 를 극대화하는 G 이다.
- 결과적으로, 구별망을 속이는 생성망 G 를 열심히 학습시켜보자는 이야기다

GAN(적대적 생성신경망)

GAN이 학습이 어려운 단점을 보완

D의 활성함수로 Convolution(Leaky ReLU) layer를 사용

G의 활성함수로 deconvolution(ReLU) layer를 사용

Pooling Layer를 사용하지 않음

6. 단점 및 극복방안

단점	내용	극복방안
Mode Collapsing	<ul style="list-style-type: none">학습시키려는 모형이 실제 데이터의 분포를 모두 커버하지 못하고 다양성을 잃어버리는 현상그저 손실만을 줄이려고 학습을 하기 때문에 G가 전체 데이터 분포를 찾지 못하고 하나의 Mode에만 강하게 몰리는 경우	<ul style="list-style-type: none">Feature Matching : 가짜 데이터와 실제 데이터 사이의 least square error를 목적함수에 추가Mini-batch discrimination : 미니배치별로 가짜 데이터와 실제 데이터 사이의 거리 합의 차이를 목적함수에 추가Historical averaging : 배치단위로 파라미터를 업데이트하면 이전 학습을 잘 잊히게 되므로, 이전 학습내용을 기억하는 방식으로 학습
G학습의 어려움	<ul style="list-style-type: none"><u>G가 학습이 잘 안되어서 둘 사이의 힘의 균형이 깨지는 경우 GAN 학습이 더 이상 진전 불가</u>	<ul style="list-style-type: none"><u>LSGAN, WGAN, F-GAN, EBGAN 등 손실함수를 바꿔서 문제 해결</u>
정량적 평가의 어려움	<ul style="list-style-type: none">데이터의 생성이 목적이므로, <u>생성된 데이터에 대한 평가가 어려움</u>	<ul style="list-style-type: none">사람이 정성적 평가<u>학습된 분류기 이용 : 기존 뉴럴 네트워크를 활용해 Label된 데이터 셋을 학습</u>. 동일한 데이터로 GAN을 학습한 후 G를 이용해서 새로운 데이터를 생성하고 미리 학습시켜준 분류기 모델에 넣어 분류. 이때 (1) 생성된 새로운 데이터가 한 범주에 높은 확률로 분포하거나 (2) 전체적으로 다양한 범주의 데이터가 생성되면 GAN의 성능이 높다고 평가Inception Score : G가 생성한 데이터의 다양성을 측정하는 지표로 클수록 좋음

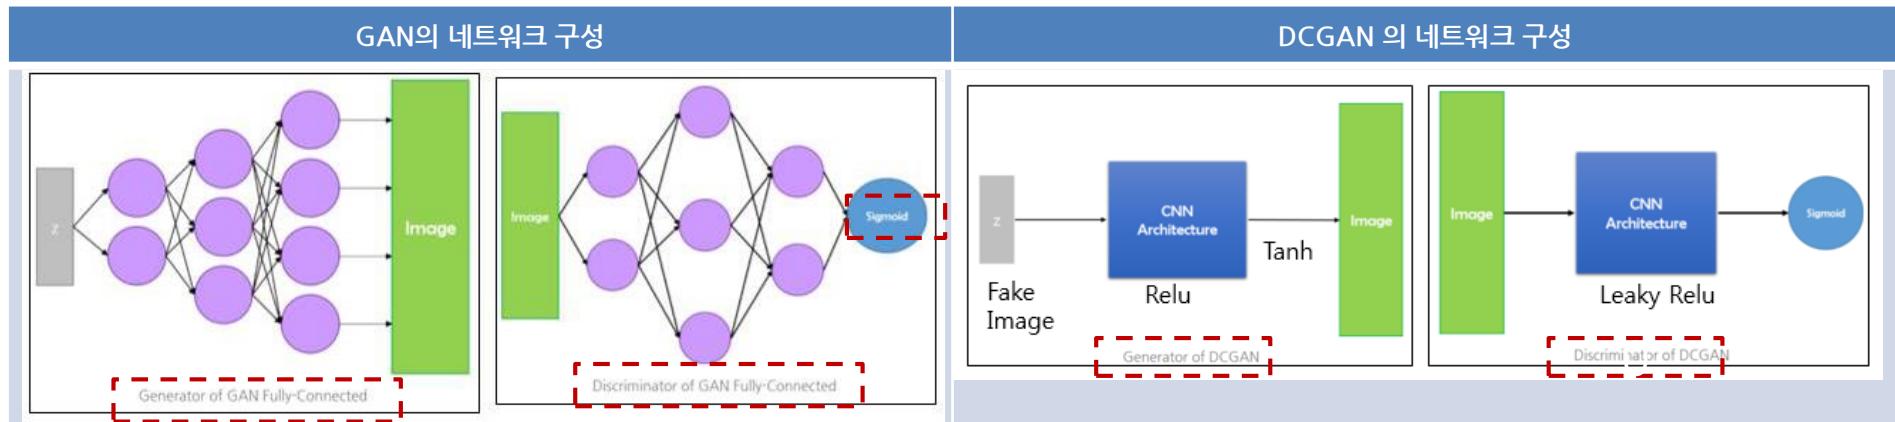


DCGAN (Deep Convolutional GAN)

1. GAN의 Fully connected Layer 삭제, DCGAN의 개요

- GAN 의 전체적인 알고리즘 구조는 동일 하나 Generator와 Discriminator 의 **Fully connected layer를 CNN(Convolutional Neural Network) 구조로 대체한 알고리즘**
- GAN 은 Generator와 Discriminator의 균형적 학습에 어려움 존재 (불균형 발생) => 고해상도 이미지 생성의 부적합

2. DCGAN의 개념도 및 주요 파라미터

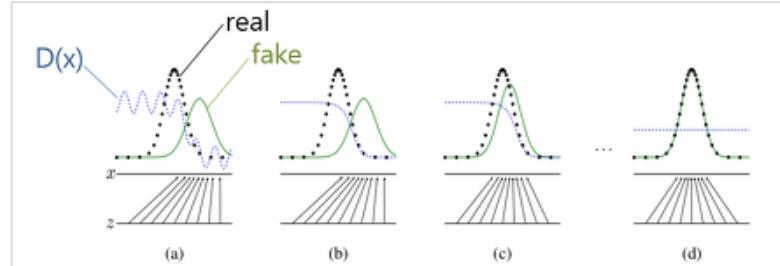


구분	파라미터	파라미터 설명
주요 연산자	Discriminator	• 지도 학습, 진짜 이미지를 통한 가짜 이미지에 대한 판별자
	Generator	• 비지도 학습, 랜덤 값을 통해 새로운 이미지를 만드는 생성자
	Network 구조	• Convolutional Neural Network 구조
Pooling Layer	Discriminator	• strided convolutions 으로 대체
	Generator	• fractional-strided convolutions 으로 대체
활성 함수	Discriminator	• 모든 활성화 함수를 LeakyRelu 사용
	Generator	• 모든 활성화 함수를 Relu를 쓰되, 마지막 결과에서만 Tanh를 사용

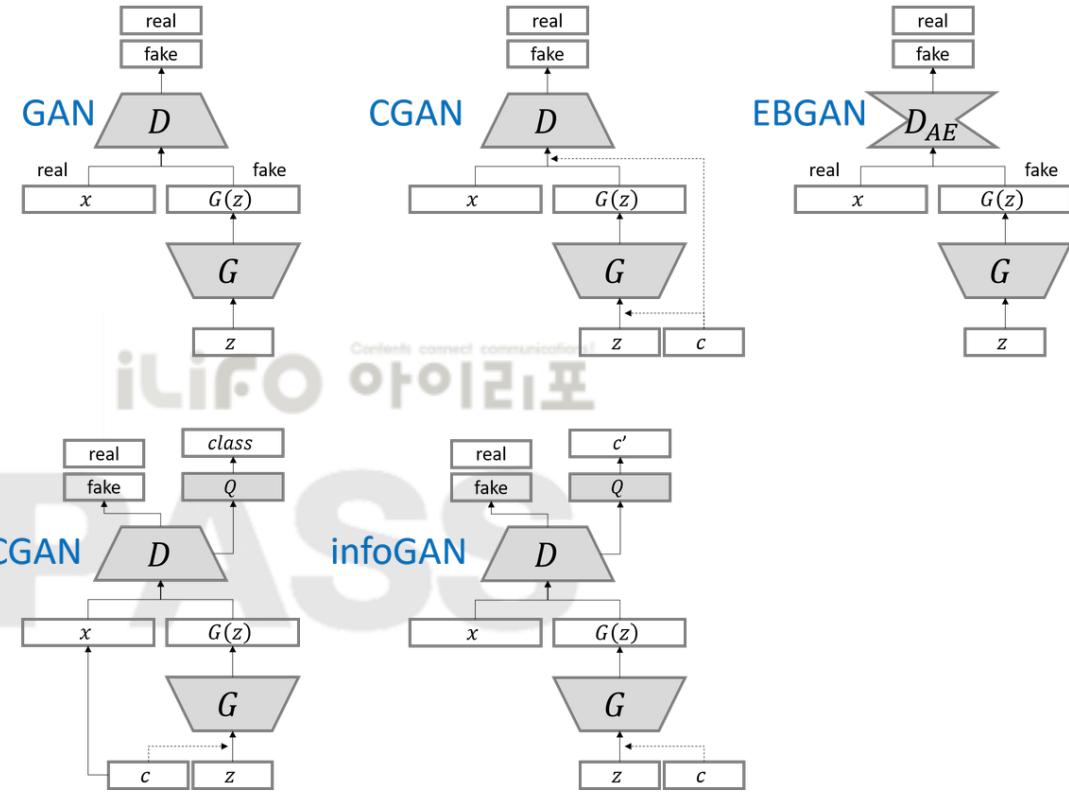
DCGAN 에서 생성자(Generator)는 매개변수에서 원래 이미지를 찾아 처리하는 ‘디컨볼루션 네트워크(De-Convolution Network)’로 구성되며, 입력된 노이즈(랜덤 신호)로부터 이미지를 생성함. 감식자(Discriminator)는 매개변수를 응축 처리하는 ‘컨볼루션 네트워크(Convolution Network)’로 구성되며, 여기에 위조 이미지(Fake) 또는 실제 이미지(Real)를 입력함.

GAN 참고 이미지

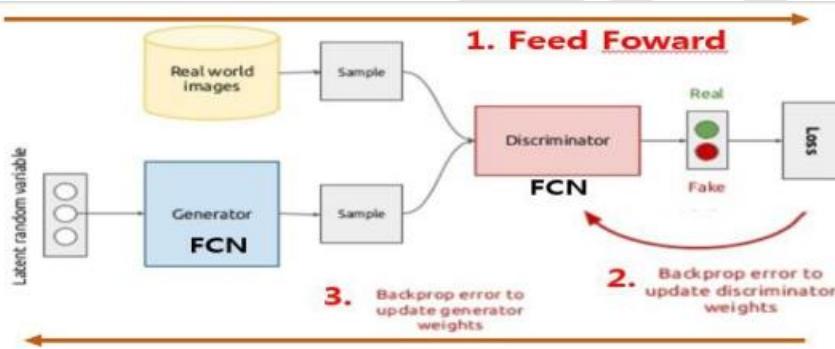
GAN 학습방법



- Discriminator가 처음에는 잘 구분을 하지만 가짜 데이터가 점점 진짜 데이터와 비슷한 데이터를 생성



Latent random variable



생체모방 알고리즘 (Bio-Inspired Algorithm)

1. 생체모방 알고리즘의 개요

- 지구상의 다양한 생물체의 행동 원리를 관찰하여 모델링한 알고리즘
- 군집 이론 (Flocking Theory) : 생물 집단에서 쉽게 관찰 할 수 있는 집중과 질서화된 운동을 설명하는 이론으로 다음과 같은 군집의 세가지 법칙을 언급
 - * 분리성 : 각 개체는 서로 일정한 간격을 유지
 - * 정렬성 : 각 개체는 그 주변 개체들의 이동 방향의 평균값으로 이동 방향 제어
 - * 결합성 : 각 개체는 주변 개체들과 동일한 거리를 유지하도록 위치함
- 통신망에 적용된 대표적인 생체모방 알고리즘
 - * Ant Colony 알고리즘 : 라우팅 처리
 - * Bee 알고리즘 : 무선 센서 네트워크 자원 할당 문제
 - * Firefly 알고리즘 : 네트워크 망 동기화
 - * Flocking 알고리즘 : 센서 네트워크 및 애드혹 네트워크에서의 노드 배치, 자원 관리, 스케줄링 등의 분야에 활용

iLIFO Contents connect communications!
아이리포

PASS

ABC (Artificial bee colony algorithm)

1. ABC 알고리즘의 개요

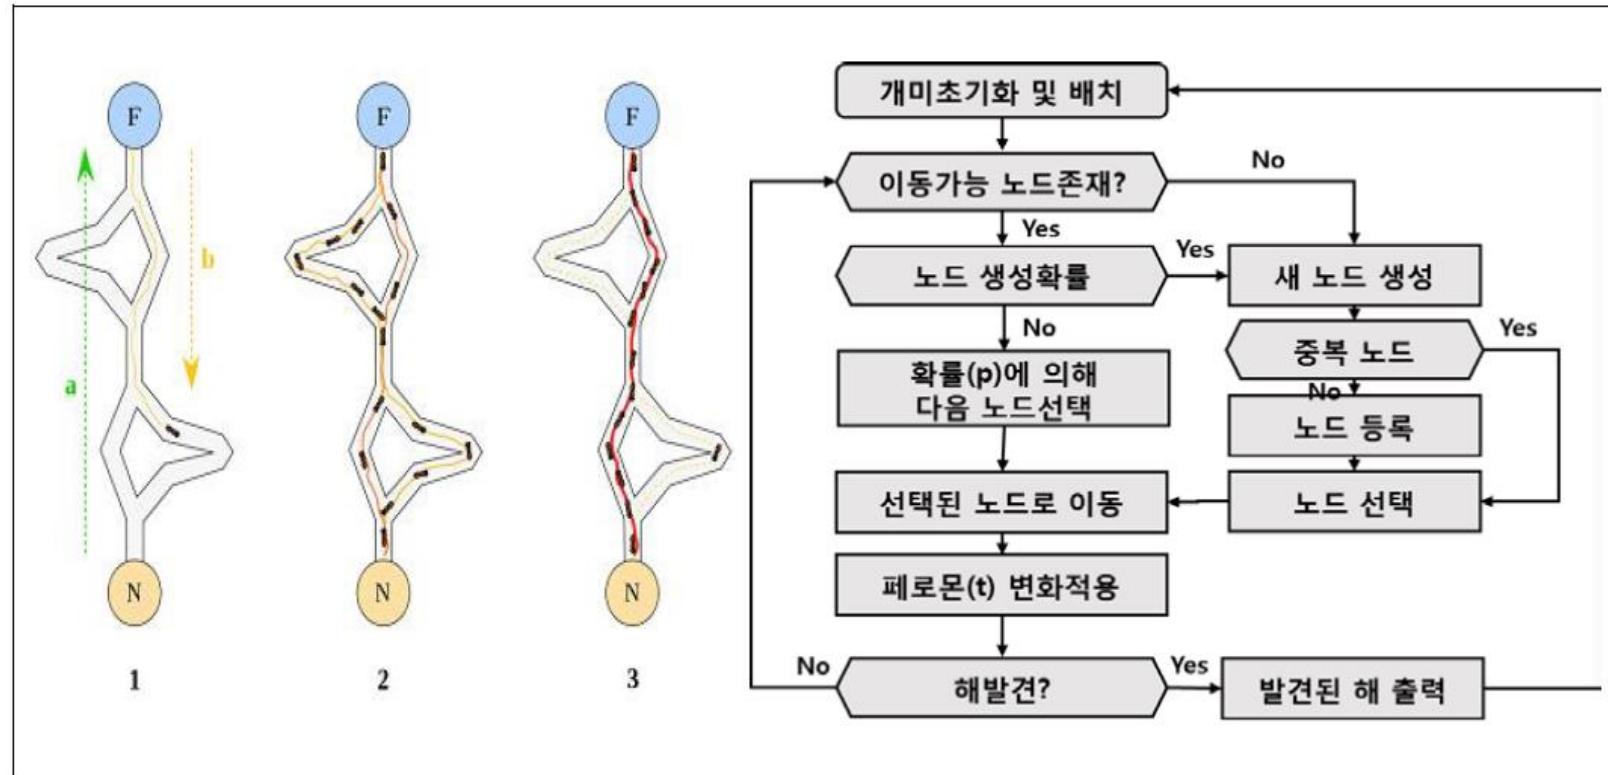
- 꿀벌이 꽃으로부터 꿀을 채집하는 과정을 모방하여 최적화 기법 연구에 활용하는 전역 최적화 알고리즘

단계	수행 절차	
초기화	소스 초기화	초기의 꽃밭 source 는 모든 채집 벌에 대해 생산이 수행됨
반복	정보 전파	채집 벌은 꿀을 담아 둑지에 와서 꿀 양과 거리 정보를 춤을 통해 전달
	대기 벌 소스 선택	각 대기 벌은 채집 벌들의 정보를 받아서, 꽃밭 source 중 하나를 선택
	대기 벌 이웃 탐색	대기 벌은 선택한 꽃밭 source 에 가서, 근처 꽃밭 source 를 결정 후 채집 시작
	채집 벌 이웃 탐색	채집 벌은 담당 꽃밭 source 의 꿀이 모두 채집하면 근처 꽃밭 source 를 탐색
	버려진 이웃 발견	근처 꽃밭 source 가 채집되어 버려진 꽃밭 source 를 발견하면 둑지로 복귀
	새로운 지역 탐색	둥지에 온 채집 벌은 대기 벌이 되거나 정찰 벌이 되어 새로운 꽃밭 source 탐색
	소스 다시 초기화	정찰 벌이 새로운 꽃밭 source 을 발견하면 채집 벌이 되어 생산을 수행

ACO (Ant Colony Optimization)

1. ACO 알고리즘의 개요

- 먹이를 찾아 이동하는 개미의 행동을 모방한 에이전트를 이용하여 가장 최적인 경로를 탐색하는 알고리즘



Word Embedding

1. Word embedding : 텍스트를 구성하는 하나의 단어를 수치화한 벡터 및 방법

- 단어를 벡터로 표현하는 대표적인 방법으로 주로 희소 표현에서 밀집 표현으로 변환

2. Word embedding 발전



3. One-hot Encoding

```
graph LR; A[원핫인코딩 전] --> B[원핫인코딩 후]
```

The diagram shows the transformation of words into One-hot encoding vectors. On the left, a box labeled '원핫인코딩 전' contains the words '과일', '사과', '배', '감', and '사과'. An arrow points from this box to a second box on the right labeled '원핫인코딩 후', which contains a table of binary vectors:

과일	과일_사과	과일_배	과일_감
사과	1	0	0
배	0	1	0
감	0	0	1
사과	1	0	0

N : 전체 문서의 수

n : 단어가 포함된 문서의 수

$$IDF = \log((N - n)/n)$$

4. TF-IDF

- Term Frequency : 단어 빈도수, 특정 단어가 한 문서 내에서 얼마나 자주 등장하는가
- Inverse Document Frequency : DF의 역수, 특정 단어가 나타난 문서의 수의 역수

$$TF = \frac{\text{문서 내 키워드 개수}}{\text{문서 내 모든 단어 수}}$$

$$IDF = \log\left(\frac{\text{문서 전체의 수}}{\text{단어를 포함한 문서의 수}}\right)$$



TF-IDF(Term Frequency - Inverse Document Frequency)

Boolean Frequency

로그스케일 빈도

Augmented Frequency

증가 빈도

TDM

유사도

1. 텍스트 마이닝 핵심 알고리즘, TF-IDF(Term Frequency - Inverse Document Frequency)의 개요

- 정보검색과 텍스트 마이닝에서 이용하는 가중치로, 여러 문서로 이루어진 문서군이 있을 때 어떤 단어가 특정 문서 내에서 얼마나 중요한 것인지를 나타내는 통계적 수치
- '특정 단어의 중요도는 단어가 출현한 횟수에 비례하고 그 단어가 언급된 모든 문서의 총수에 반비례한다'는 명제에 기초(한스 피터룬)

구분	설명	공식
TF (Term Frequency)	<ul style="list-style-type: none"> 특정 단어의 특정 문서 등장 빈도 이 값이 높을수록 문서에서 중요하다는 것을 의미 값의 발산을 방지하기 위해서 불린 빈도(Boolean Frequency), 로그 스케일 빈도 (Logarithmically Scaled Frequency), 증가 빈도 (Augmented Frequency)로 표현 	$TF = \frac{\text{문서 내 키워드 개수}}{\text{문서 내 모든 단어 수}}$
IDF (Inverse Document Frequency)	<ul style="list-style-type: none"> DF(문서 빈도, Document Frequency) : 특정 단어가 나타난 문서의 수 DF의 역수를 취한 값 \rightarrow IDF DF가 높을수록 흔하게 등장하므로 역수를 취해 중요도를 산출 즉 IDF가 높을수록 문서에서 중요하다는 것을 의미 	$IDF = \log\left(\frac{\text{문서 전체의 수}}{\text{단어를 포함한 문서의 수}}\right)$
TF-IDF	<ul style="list-style-type: none"> 특정 문서 내에서 단어 빈도가 높을수록, 그리고 전체 문서들 중 그 단어를 포함 한 문서가 적을수록 TF-IDF 값이 높아짐. 문서간 유사도, 키워드 추출, 검색 엔진에서 검색 결과 순위를 결정 	$TF-IDF = TF * IDF = TF * \log((N - n)/n)$ N : 전체 문서의 수 n : 단어가 포함된 문서의 수 $IDF = \log((N - n)/n)$
TDM	<ul style="list-style-type: none"> 산출된 TF, IDF, TF-IDF값을 매트릭스로 표현하고 이를 통해 유사도(Similarity)를 계산하여 문서 스코어링 수행 	

2.TF-IDF 의 문서유사도 측정 방법

구분	설명	수식
코사인 유사도	-유사도 값이 0~1사이의 값을 가짐 (1: 모든 어휘의 가중치가 동일한 문서) (0: 두 문서에서 공유하는 어휘가 없는 문서)	$sim(d_i, d_j) = \frac{\sum_{k=1}^n w_{ik} \cdot w_{jk}}{\sqrt{\sum_{k=1}^n w_{ik}^2 \cdot \sum_{k=1}^n w_{jk}^2}}$
내적 (inner product)	-특정 문서내에서 단어 빈도가 높을수록, 그리고 전체 문서들 중 그 단어를 포함 한 문서가 적을수록 TF-IDF 값이 높아짐.	$sim(d_i, d_j) = \sum_{k=1}^n w_{ik} \cdot w_{jk}$
유클리디언 거리 (Euclidean distance)	-Ward 기법의 군집화에서 거리 값이 작을수록 두 문서간 유사도 높음. -문서 군집화에서 거리가 가까울 수록 유사도 상승	$dist(d_i, d_j) = \sqrt{\sum_{k=1}^n (w_{ik} - w_{jk})^2}$

TF-IDF(Term Frequency - Inverse Document Frequency)

3. TF-IDF 변형기법을 통한 정확도 향상 사례

기법	방식	효과
BM-25 Algorithm	- TF-IDF 에 문서길이 가중 = TF-IDF * norm	Precision, recall 각 12 % 향상
Modified TF-IDF	Hot Topic 의 예측을 위한 시간 흐름에 따른 변화를 적용 - MTF, MIDF	Precision, recall 각 15 % 향상

4. 시간적 속성을 고려한 TF-IDF





word2vec

1. 다차원 벡터를 이용한 자연어 분석. Word2vec 개요

- 단어의 의미 파악 및 단어간 유사성을 찾기 위해, 말뭉치를 입력받아 word embedding이라는 벡터로 표현하여 분석하는 인공신경망
- Word embedding : 말뭉치에서 단어가 가지는 의미나 역할을 잘 표현해주는 벡터
- 사용예) 텍스트 문장, DNA 염기서열, 코드, 음악 재생목록, SNS(graph)

2. Word2vec의 학습모델 및 학습의 결과

구분	CBOW (Continuous Bag Of Words)	Skip-gram
개념도	<p>CBOW</p>	<p>Skip-gram</p>
개념	주변 단어가 만드는 맥락을 이용해 타겟 단어를 예측	한 단어를 기준으로 주변에 올 수 있는 단어를 예측
사례	집 앞 편의점에서 아이스크림을 사 먹었는데, ___ 시려서 너무 먹기가 힘들었다 → ___ = 이	서울 - 한국, 문재인 도쿄 - 일본, 아베, 중국 - 베이징, 시진핑
학습 과정	1) 한 단어에 이미 할당된 벡터(word embedding) 이 있다고 가정. 2) 이 값을 이용, 주변 문맥을 얼마나 정확하게 예측하는지 계산. 3) 정확도가 나쁜경우(조정필요시) 오차에 따라 벡터의 값을 업데이트. -한 단어를 기준으로, 단어 주변의 문맥을 참고, 현재 embedding vector가 얼마나 정확한지, 오차값은 어느정도인지 알아냄. - 어떤 두 단어가 비슷한 문맥에서 꾸준히 사용된다면 두 단어의 벡터값은 비슷하게 됨. ex) 소나무 근처에 박달나무, 은행나무등이 비슷한 곳에 모임. 전쟁, 갈등, 불화 등은 다른곳에 모임.	



SNA (Social Network Analysis)

1. 사회구성 요소간 관계를 구조적으로 표현하기 위한 기술, SNA 개요

- 사람, 그룹, 조직, 컴퓨터 및 데이터 등 객체 간의 관계 및 네트워크의 특성과 구조를 분석하고 시각화하는 분석 방법론
- 사회연결망 이론을 바탕으로 **소셜네트워크의 형태, 연결구조, 연결강도 등을 계량화하여 측정**하고 이를 통해 **특정 구성원과 네트워크의 영향력 등 유의미한 지식을 도출**하는 기법
- 실시간으로 쏟아지는 대용량의 정보를 효율적으로 처리하는 기술과 사회관계망을 Topology와 관계강도(Tie-Strength)로 표현
- 고차원적인 분석기법을 이용하여 Social Network 내의 **중심성(Centrality), 연결성(Betweenness), 밀폐성(Closeness)**을 분석하고 각 노드의 연결강도(Tie-Strength)를 정의함

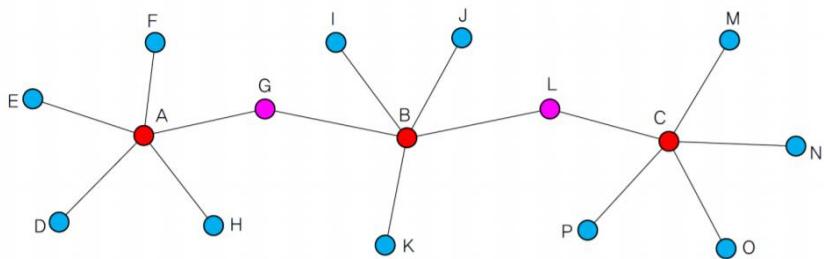
2. SNA 5가지 속성

속성	도표	설명
응집력 (Cohesion)		행위자들간 강한 사회화 관계의 존재
구조적 등위성 (equivalence)		한 네트워크의 구조적 지위와 그 위치가 주는 역할이 동일한 사람들간의 관계
명성 (Prominence)		네트워크에서 누가 권력을 가지고 있는가?
범위 (Range)		행위자의 네트워크 규모
중계 (Brokerage)		다른 네트워크와 연결해주는 것

3. SNA 속성별 측정지표

속성	측정지표	내용
응집력 (Cohesion)	밀도(density)	사회 네트워크에서 가능한 총 관계자 수 중에서 실제로 맺어진 관계수의 비율
	결속(clique)	모든 노드끼리 완전하게 연결된 하부 네트워크
등위성 (equivalence)	유클리디안 거리	가장 짧은 물리적 거리
	상관계수	두 행위자들간 관계의 패턴이 얼마나 유사한가?
명성 (Prominence)	연결정도	한 행위자가 다른 행위자와 얼마나 많은 관계를 맺고 있는가를 통해서 그 행위자가 네트워크의 중심에 위치하는 정도를 개량화(행위자에 직접적으로 연결되어있는 다른 행위자의 합)
	근접중심성	직접적으로 연결된 행위자뿐 아니라 네트워크 내 간접적으로 연결된 모든 행위자들 간의 거리(두 행위자를 잇는 가장 짧은 경로거리를 모두 더한 것에 역수를 취한 값)
범위 (Range)	도달 가능성 (Reachability)	두 행위자간 연결이 얼마나 많이 설정되어 있는가? (직접 또는 간접경로)
	최단경로 (Geodesic distance)	두 행위자간의 연결 중 가장 적은 수의 관계자를 거치는 경로
중개 (Brokerage)	매개중심성 (Betweenness)	네트워크 내에서 한 행위자가 담당하는 매개자 혹은 중개자 역할의 정도
	구조적 투파	중복 접촉이 없는 연결

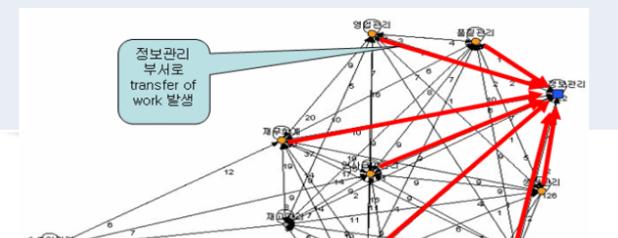
SNA(Social Network Analysis)



4. Social Network Analysis의 주요 기법

(1) Centrality 분석 : Node가 네트워크에서 얼마나 중심인지의 정도

속성	측정지표		내용				
연결중심성(Degree Centrality)	- 한 노드에 직접적으로 연결되어 있는 노드의 개수. 노드의 수가 많을수록 연결 중심성이 높아짐	연결정도 중심성 $C_D(N_i)$: 액터	A, B, C 5	G, L 2	나머지 1		
매개중심성(Betweenness Centrality)	- 한 노드가 연결망 내의 다른 노드들 사이의 최다 경로 위에 위치할수록 그 노드의 매개중심성이 높아짐	매개 중심성 $C_B(N_i)$: 액터	B 75	A, C, G, L 50	나머지 0		
근접 중심성(closeness centrality)	- 한 노드로부터 다른 노드에 도달하기 위해 필요한 최소 단계의 합의 역수로 정의	근접 중심성 $C_C(N_i)$: 액터	B 0.0303(=1/33)	G, L 0.0270(=1/37)	A, C 0.0233(=1/43)	I, J, K 0.0213(=1/47)	나머지 0.0175(=1/57)
고유벡터 중심성(eigenvalue centrality)	- 연결된 다른 노드의 중심성을 가중치(weighted centrality)로 하여 계산된 연결관계 정도. (노드에 직접 연결된 다른 노드의 개수에 초점)						

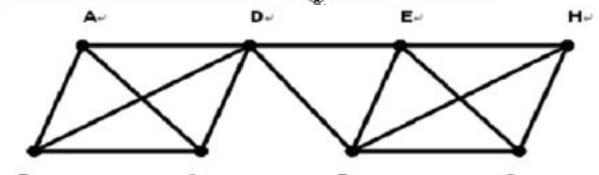


(2) Neighbor 분석 : 네트워크를 구성하는 Node들간의 표면적인 연결상태를 파악

- 점들 간의 특정 관계 또는 흐름의 전체를 시각적으로 나타냄
- 특정 관계 또는 흐름의 정도를 Weight라는 수치로 표현 가능.
- 직접적인 관계 또는 흐름을 가지는 점 이외에도 접근도를 이용하여 표현

(3) Clique cohesion 분석 : 네트워크를 구성하는 점(node)들간의 결합력(cohesion)을 바탕으로 군집구조를 파악하는 방법

- 결합력은 social network를 구성하는 점(node)간의 강한(strong) 연결관계를 나타냄
- Clique은 결합력을 가지는 최소 3개의 점(node)으로 구성되는 그룹(group)을 나타내며, 모든 점(node)이 직접적으로 연결되어 있어야만 Clique이 성립됨.



- * Clique 1: A, B, C, D
- * Clique 2: D, E, F
- * Clique 3: E, F, G, H

시각지능

지능정보산업 발전 전략 주요 내용 자료·연합뉴스



언어지능



기술입증



응용서비스 모델과 효과



시각지능



지식축적 세계 1위 (2019)



법률 전문가 서비스 법률 구조비용 절감



공간지능



재난구조 시연 (2019)



도시 범죄 테러 예방 범죄율 감소



감성지능



감성대화 시연 (2019)



드론 인명구조 지원 골든 타임내 인명구조



요약창작



영화요약 경연 (2019)

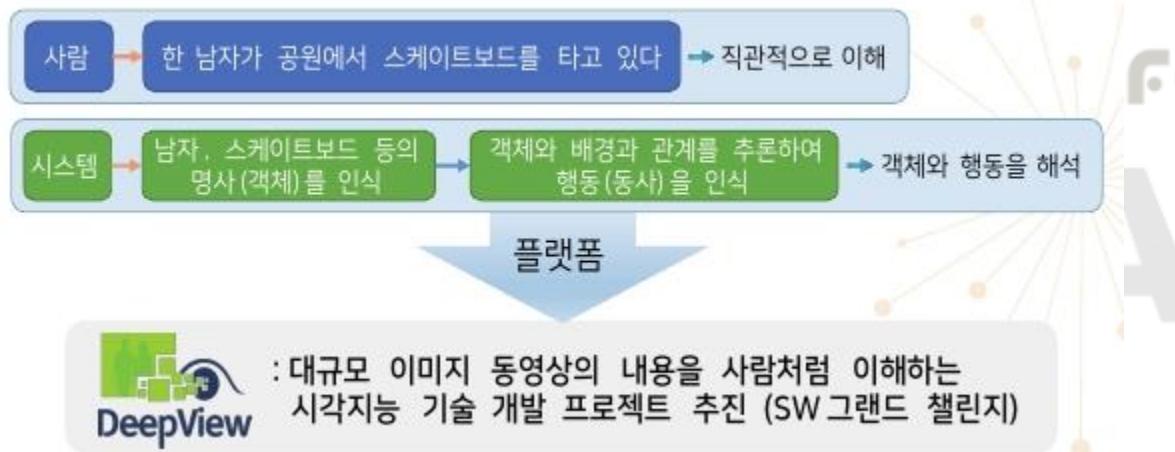


고령자 돌보미 로봇 독거노인 고독사 방지

1. 딥러닝(Deep Learning) 중 시각인식·인지능력을 특화된, 시각지능의 개요

- 사진과 동영상에 포함된 사물과 사물들의 관계를 이해하여 영상에 내포된 내용을 사람처럼 읽어내는 SW 지능
- 대규모 이미지 데이터를 학습하여 다양한 종류의 사물을 인식하고 이해하는 기술
- 사람을 대신하여 사물을 인식하고 학습하여
- 다양한 영상 데이터가 가지고 있는 의미 정보를 분석해 내는 플랫폼

2. 시각지능 개념도 및 구현 기술



영상 데이터의 기하급수적 증대

- 빅데이터 기술의 대두로 대규모 비정형 데이터에서 정보 가치를 창출하는 방법에 대한 요구가 증대

관련 기술의 발전

- 대규모 데이터 수집, 저장 기술 및 처리기술의 발전
- 영상 인식 기술의 발전

높은 경제적 가치와 사회적 가치 보유

- 시각 지능을 활용하는 활용성을 넘어 과거에는 불가능했던 새로운 분야의 영상 인식 기능으로 확장하고 있음

시각지능의 중요성 증대

주요 기술	설명
객체의 학습 및 인식	<ul style="list-style-type: none">사람과 비슷한 수준으로 사물을 인식하기 위해서는 2만가지 이상의 사물을 구분할 수 있어야 하며, 한 종류의 객체를 인식하기 위해서는 훈련(학습) 과정을 거치는 기술
직관적 사물의 인식	<ul style="list-style-type: none">학습된 인식기는 사물을 즉시적으로 인식할 수 있으며, 동작이나 장면을 이해하는 기술
심층적 상황 인식	<ul style="list-style-type: none">사물의 일부가 가려지거나 처음 접하는 사물은 직관적으로 인식 할 수 없고, 주변 상황이나 외부 데이터와 연계하여 추론함. 또한 다양한 객체들이 상황을 만들어 내는 경우 이를 이해하는 기술

시각지능

3. 시각지능의 유형

유형	설명
시각-이해지능 (직관적 인식 능력)	<ul style="list-style-type: none">이미지/동영상을 직관적으로 보고 그 내용을 사람처럼 이해사진/영상에서 사물의 관계를 이해하여 어떤 의미를 가지고 있는지 이해누가, 언제, 무엇을 했는지 이해하는 과정
시각-분석지능 (심층적 인지능력)	<ul style="list-style-type: none">영상 속의 상황을 학습하여 원인과 결과를 예측동일 공간의 이미지/동영상에서 시간 순으로 누적분석을 통해 현재의 상황을 이해하고 미래를 예측하는 과정

4. 시각지능 주요 알고리즘

알고리즘	설명
컨볼루션 뉴럴 네트워크 (CNN)	<ul style="list-style-type: none">인간의 시신경 세포의 구조를 모방이미지/동영상을 입력하면 특징을 학습하여 데이터를 분류하는 딥러닝 기술
관계 추론기술 (Relational Network)	<ul style="list-style-type: none">사람의 추론 방식과 유사하게 인공지능이 인식된 객체에 대해 서로 간의 상대적인 관계를 추론하는 기술
DC-GAN	<ul style="list-style-type: none">Deep Convolutional Generative Adversarial NetworksGAN과 영상처리에 특화된 딥러닝 기술인 CNN을 결합한 기술
CycleGAN	<ul style="list-style-type: none">입력된 이미지 스타일을 다른 스타일로 변환하는 기술
SRGAN	<ul style="list-style-type: none">Super-Resolution Generative Adversarial Networks저해상도 이미지를 고해상도 이미지로 변환하는 기술
DiscoGAN	<ul style="list-style-type: none">인공지능이 서로 다른 객체 그룹 사이의 특성을 파악하여 양자 사이의 관계를 파악할 수 있는 기술가방과 신발이라는 두 그룹의 이미지를 각각 입력해 각자의 특성을 학습하면 이미지에 태그가 붙지 않아도 알고리즘이 양자의 관계를 스스로 파악

5. 시각지능 활용방안

- 사람의 눈을 대신하는 것으로 산업체의 품질검사, 의료 영상에서 질병 탐지, 지능형 CCTV에서 사건/사고 감시, 소셜 미디어 분석 뿐 아니라 자율 주행 자동차, 지능형 로봇까지 산업 전반에 걸쳐 활용 가능

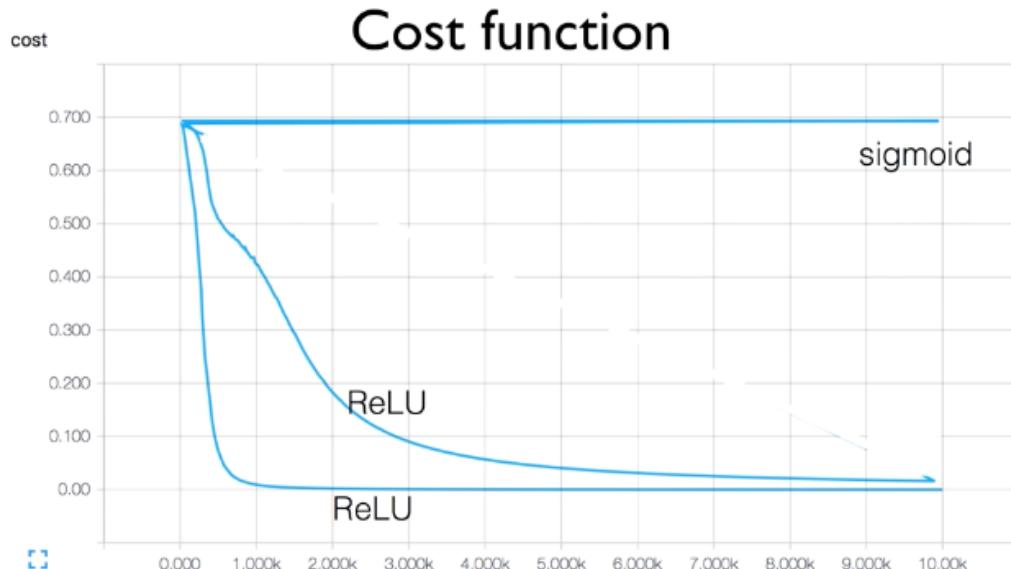
6. 추후 발전 방향

- 영상을 재생하는 시대에서 영상을 읽고 이해하는 시대로 변화**
- 영상 인식 알고리즘 경쟁에서 영상 이해 플랫폼 경쟁으로 변화**

비용함수(Cost function) / 손실함수 (Loss function)

1. 예측을 하는 값과 실제 결과 값의 차이를 나타내는 함수, 비용함수 (Cost Function)의 개요

- 예측을 하는 값과 실제 결과 값의 차이를 나타내는 함수(오차를 정의하는 함수)
- 예측 값(측정 값)과 실제 값 차이의 평균 / 모델의 정확도를 측정할 때 활용
- 어떤 비용함수를 선택하느냐에 따라 학습규칙, 즉 역전파 알고리즘 수식(출력노드의 델타를 계산하는 수식)이 달라짐
- 손실 함수(Loss Function), 목적 함수(Objective Function) 또는 오차 함수>Error Function)으로 부르기도 함
- 손실함수로는 **평균 제곱 오차(MSE)** 와 **교차 엔트로피 오차(cross entropy, CEE)** 함수가 가장 많이 사용
- 딥러닝은 대부분 Cross Entropy 함수로 유도된 학습규칙을 신경망을 학습
- 신경망 성능의 “나쁨”을 나타내는 지표로, 현재의 신경망이 훈련 데이터를 얼마나 잘 처리하지 못하느냐를 나타내는 지표



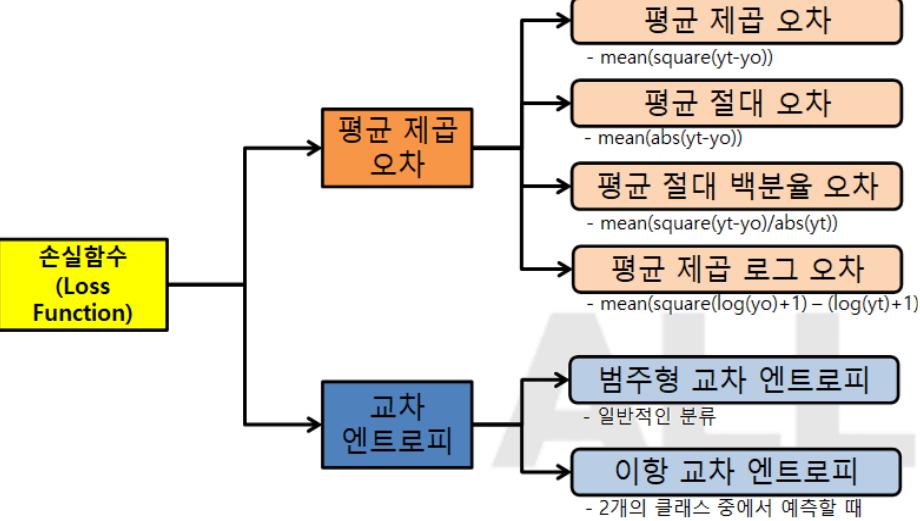
- 평균제곱오차 Mean Squared Error, MSE
: 각 원소의 출력(추정) 값과 정답 레이블(참) 값의 차를 제곱한 총합
$$\sum_{i=1}^n (\bar{Y}_i - Y_i)^2 = \frac{1}{N} \{(\bar{Y}_1 - Y_1)^2 + (\bar{Y}_2 - Y_2)^2 + \dots + (\bar{Y}_n - Y_n)^2\}$$

- 교차 엔트로피 오차 Cross Entropy Error, CEE
: 자연로그를 이용한 오차측정

$$H_{y'}(y) = - \sum_i y'_i \log(y_i)$$

비용함수(Cost function) / 손실함수 (Loss function)

2. 손실함수의 구성도 및 구성요소



구분	오차함수	오차함수 설명 및 수식
평균 제곱 오차	Mean_squared_error	- 평균 제곱 오차 - $\text{mean}(\text{square}(yt-yo))$
	Mean_absolut_error	- 평균 절대 오차 - $\text{mean}(\text{abs}(yt-yo))$
	Mean_absolute_percentage_error	- 평균 절대 백분율 오차 - $\text{mean}(\text{square}(yt-yo)/\text{abs}(yt))$
	Mean_squared_logarithmic_error	- 평균 제곱 로그 오차 - $\text{mean}(\text{square}(\log(yo)+1) - (\log(yt)+1))$
교차 엔트로피	Categorical_crossentropy	- 범주형 교차 엔트로피 - 일반적인 분류
	Binary_crossentropy	- 이항 교차 엔트로피 - 2개의 클래스 중에서 예측할 때

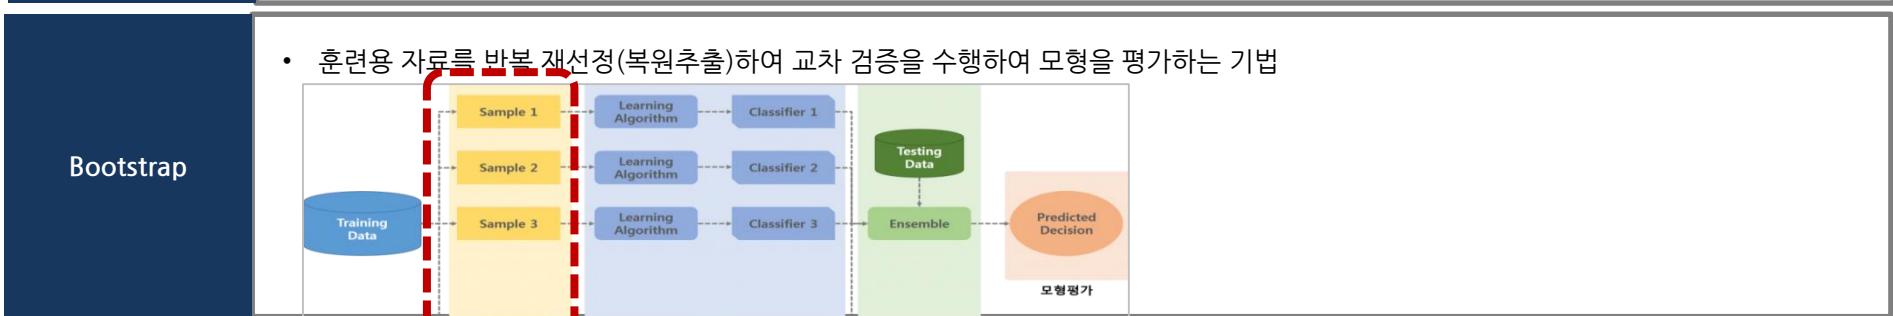
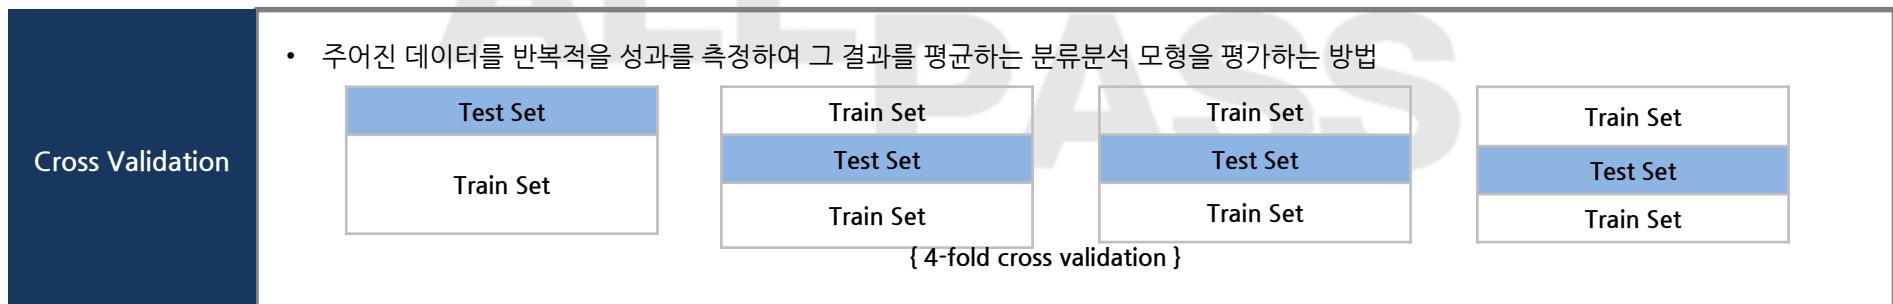
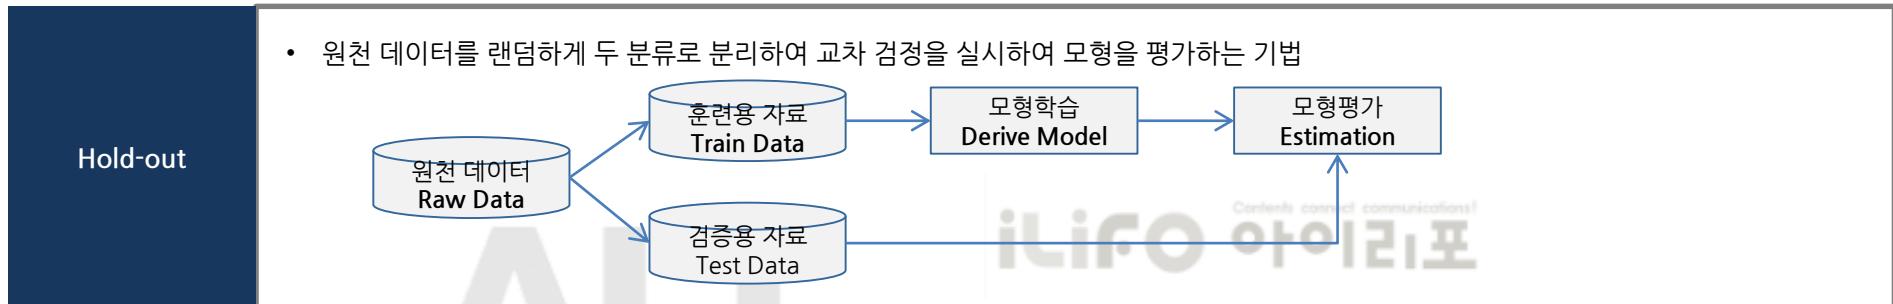
- Gradient descent algorithm을 이용하여 cost function 최소화



모형평가 (AI 모델 성능 평가)

1. 모형평가의 개요

- 예측 및 분류를 위해 구축된 모형이 임의의 모형보다 더 우수한지, 가장 우수한 예측 및 분류 성과를 보유하고 있는지 비교 분석하는 기법





혼동행렬 (Confusion Matrix= 오분류표)

TP/FP/FN/TN

Precision, Accuracy, Recall, Specificity, FP Rate, F1 점수, Kappa

1. 데이터 분석의 분류 모델에서 모델 평가 기법, 혼동행렬의 개요

- 데이터 분석에서 잘못된 예측의 영향을 간편하게 파악하기 위해 **예측된 값과 실제 값이 일치하는지 여부를 행렬로 분류하는 모델 평가 기법**

2. 혼동행렬의 개념도 및 작성 방법

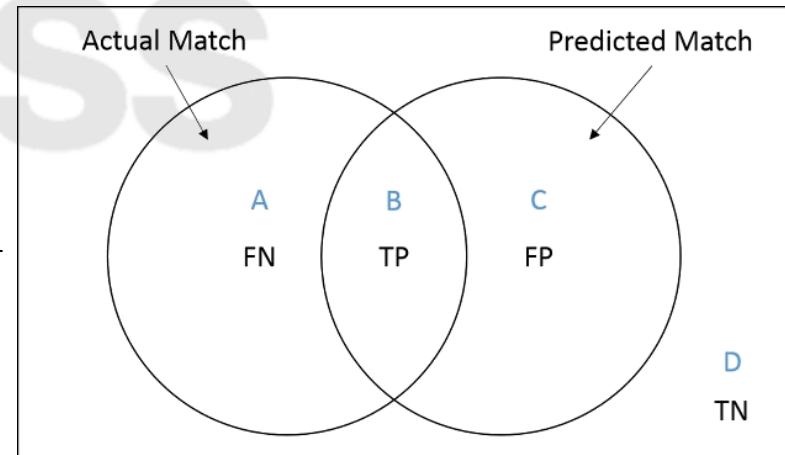
		Predicted Class	
		Positive	Negative
Actual Class	Positive	True Positive (TP) Type II Error	False Negative (FN)
	Negative	False Positive (FP) Type I Error	True Negative (TN)
	Precision $\frac{TP}{(TP + FP)}$	Negative Predictive Value $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$

- Positive/Negative는 예측한 값, True/False는 예측한 값과 실제 값의 비교 결과
- 모델의 정확도를 예측 값과 실제 값의 일치 빈도를 통해 평가할 수 있음
- 혼동행렬은 예시된 2×2 형태의 행렬 외에 $N \times N$ 형태로도 작성이 가능

4. 관련 모델 평가 기법

- ROC 커브(Receiver Operating Characteristic Curve)
- AUC(Area Under Curve)
 - ROC를 면적으로 환산하여 평가한 방법
 - AUC가 0.9~1.0 이면 탁월,
0.8~0.9 이면 뛰어남,
0.7~0.8 이면 보통,
0.6~0.7이면 가치가 없는 것으로 판단

구분	분류 값	설명
예측이 정확한 경우	TP(True Positive)	실제 값이 Positive이고 예측 값도 Positive인 경우
	TN(True Negative)	실제 값이 Negative이고 예측 값도 Negative인 경우
예측이 틀린 경우	FP(False Positive)	실제 값은 Negative이었으나 예측 값은 Positive이었던 경우
	FN(False Negative)	실제 값은 Positive이었으나 예측 값은 Negative이었던 경우



혼동행렬 (Confusion Matrix= 오분류표)

3. Confusion Matrix 의 평가지표

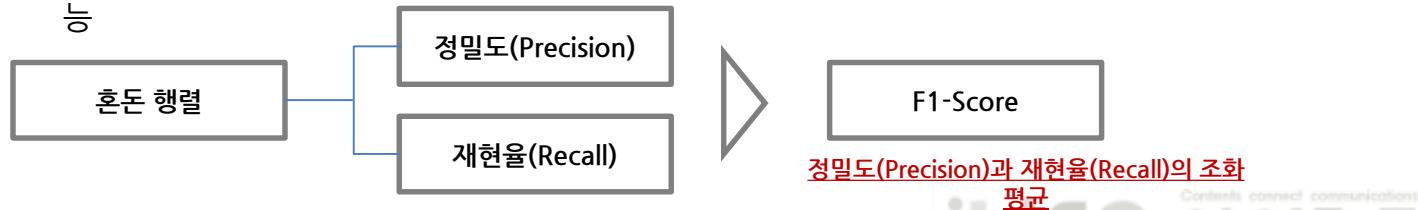
평가항목	산식	설명
Precision	TP / (TP + FP)	<ul style="list-style-type: none"> 정도, Positive Predictive Value Positive 로 예측된 것 중 실제로도 Positive 인 경우의 비율
Accuracy	(TP + TN) / (TP + FP + FN + TN)	<ul style="list-style-type: none"> 정해율 전체 예측에서 (예측이 Positive 이든 Negative 이든 무관하게) 옳은 예측의 비율
Recall	TP / (TP + FN)	<ul style="list-style-type: none"> 진양성을, Sensitivity, True Positive Rate 실제로 Positive 인 것들 중 예측이 Positive 로 된 경우의 비율
Specificity	TN / (FP + TN)	<ul style="list-style-type: none"> 진음성을, True Negative Rate 실제로 Negative 인 것들 중 예측이 Negative 로 된 경우의 비율
FP Rate	FP / (FP + TN)	<ul style="list-style-type: none"> False Alarm Rate Positive 가 아닌데 Positive 로 예측된 비율 1 – Specificity 와 같은 값
F1 점수	$2 \times \frac{1}{\frac{1}{precision} + \frac{1}{recall}} = 2 \times \frac{precision \cdot recall}{precision + recall}$	<ul style="list-style-type: none"> F1 measure, F1 score Precision 과 Recall 의 조화평균 시스템의 성능을 하나의 수치로 표현하기 위해 사용하는 점수로 0~1 사이의 값을 가짐
Kappa	$\kappa = (accuracy - P(e)) / (1 - P(e))$	<ul style="list-style-type: none"> 코헨의 카파 계수 두 평가자의 평가가 얼마나 일치하는지 평가하는 값 0~1 사이의 값을 가짐 P(e)는 두 평가자의 평가가 우연히 일치할 확률 코헨의 카파 계수는 두 평가자의 평가가 우연히 일치할 확률을 제외한 뒤의 점수



F1-Score

1. 혼동행렬(Confusion Matrix)를 이용한 모델의 성능 평가, F1 Score의 개요

- 값의 외곡 현상이 생기기 때문에, 가중치를 부여한 조화 평균(Harmonic Mean)
- 머신러닝에서 모델의 성능을 평가하기 위해 정밀도와 재현율을 사용하며, 이 둘의 조화 평균인 F1 Score 사용하여 편리하게 평가 가능



2. F1-Score의 정밀도와 재현율 도출 방법

- 혼동행렬(Confusion matrix)로부터 예측값과 실제값을 기준으로 TP, FN, FP, TN을 도출하고, 이를 이용하여 정밀도와 재현율 지표를 계산
- 정밀도 지표 만으로는 성능 평가가 유용하지 않으며, 재현율 지표를 함께 사용하는 것이 일반적

		< Confusion Matrix >	
		Predicted	
		Positive	Negative
Actual	Positive	TP (True Positive)	FN (False Negative)
	Negative	FP (False Positive)	TN (True Negative)

정밀도

평가 항목	수식	설명
정밀도 (Precision)	$\frac{TP}{TP + FP}$	- 정확한 예측의 비율
재현율 (Recall)	$\frac{TP}{TP + FN}$	- 진양성률, TPF(True Positive Rate) - 민감도(Sensitivity)라고도 함

F1-Score

3. 정밀도 재현율을 이용한 F-measure

- F-measure 는 알고리즘의 정밀도 - 재현율 성능을 하나의 숫자로 표현하는 방법

F-measure	수식	설명
F β - Score	$F_{\beta} = \frac{1}{\alpha \frac{1}{P} + (1 - \alpha) \frac{1}{R}} = \frac{(\beta^2 + 1)P * R}{\beta^2 P + R}$	- 정밀도와 재현율의 가중 조화 평균
F1 - Score ($\beta = 1$)	$F_1 = 2 * \frac{1}{\frac{1}{P} + \frac{1}{R}} = 2 * \frac{P * R}{P + R}$	- F(beta)Score에서 $\beta = 1$ - 정밀도와 재현율의 가중치가 0.5 로 동일한 경우

- score 에서 정밀도와 재현율의 가중 비율에 따라 F1,F2,F0.5-score 등이 사용됨
- F1-Score 는 정밀도와 재현율의 중요성을 동일하게 보는 경우이며, 재현율이 정밀도보다 더 중요하다면 F2-Score, 정밀도가 재현율 보다 더 중요한 경우 F0.5-Score 를 사용함.
- * 조화평균: 각 수의 역수의 산술 평균을 구한 것의 역수. 두 수 a,b의 조화 평균은 $2ab/(a+b)$

4. 정밀도와 재현율의 Trade-off 관계를 고려한 최적의 모델 성능 평가

- 정밀도와 재현율은 정밀도를 올리면 재현율이 줄고, 그 반대의 경우가 되는 정밀도-재현율 trade-off 관계를 가짐.
- 학습모델의 적용 상황에 따라 정밀도가 중요하거나, 재현율이 중요할 수 있으므로, 상황에 맞는 적절한 정밀도와 재현율 threshold 를 사용해야 함

ROC(Receiver Operating Characteristic) Curve

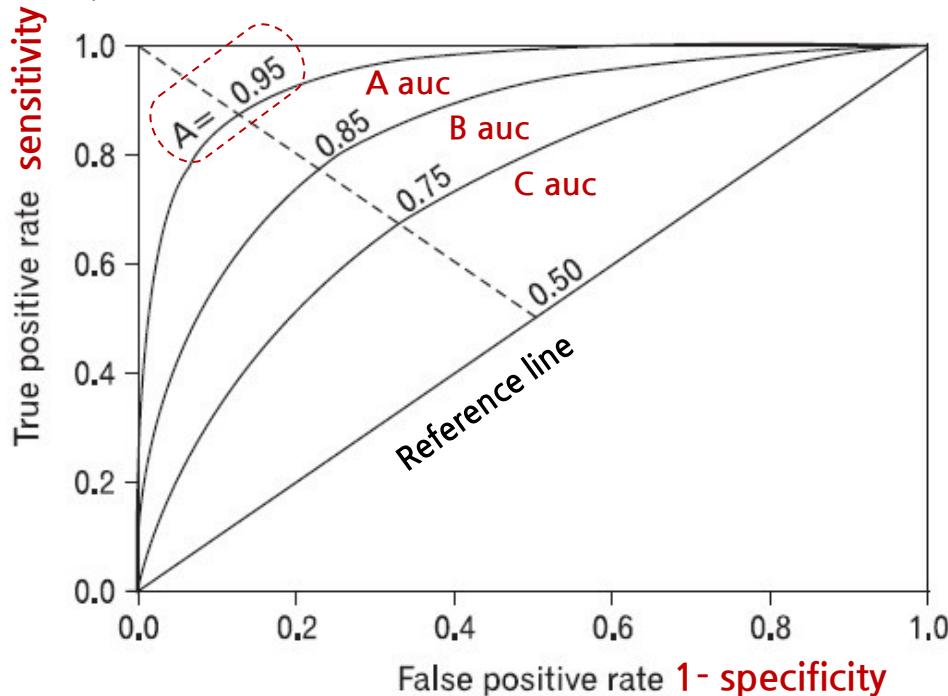
Sensitivity (민감도)

Specificity (특이도)

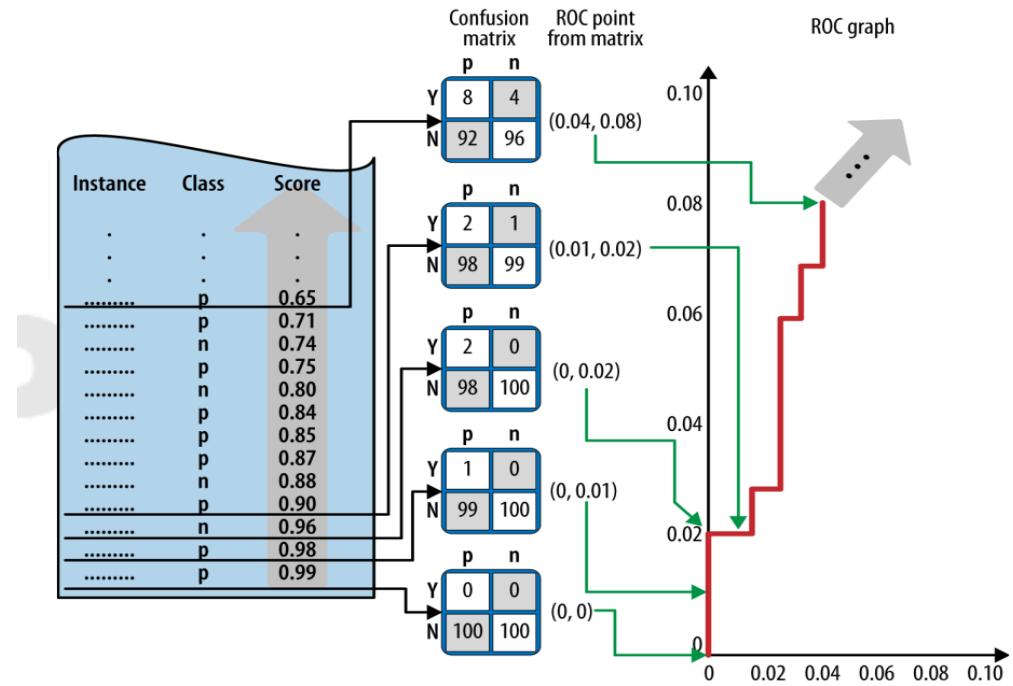
1. ROC 커브의 개요

- Sensitivity (민감도)**와 **Specificity (특이도)**를 이용하여 분류 모델의 수준을 면적으로 표현하여, **모델 평가를 가시화한 도구**
- 모든 분류 임계값에서 참 양성 비율(TPR), 허위 양성 비율(FPR)의 매개 변수를 표시를 통해 분류 모델의 성능을 보여주는 그래프

2. ROC Curve



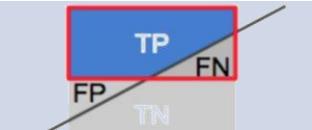
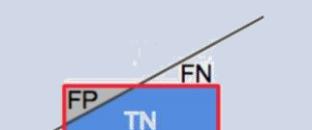
- X축 : False positive rate = 1- specificity
 - 특이도 specificity = $TN / (TN + FP)$: negative로 예측된 것에서 실제 negative 의 비율
- Y축 : True positive rate = sensitivity
 - 민감도 sensitivity = True positive rate = $TP / (TP + FN)$: positive로 예측된 것에서 실제 positive 비율



- 분류기(모델)에 확률 임계치(Threshold)를 추가하여 하나의 혼동행렬을 만들 수 있음. 임계치를 낮춰가면서 만들어지는 혼동행렬을 통해 ROC 그래프에 점을 찍어나가면 오른쪽과 같은 그래프의 형태를 보임
- 분류 임계값을 낮추면 더 많은 항목이 양성으로 분류되어 거짓 양성과 참 양성이 모두 증가
- ROC 커브의 면적이 1에 가까울수록 좋은 성능**
- 따라서 그래프가 위로 갈수록 좋은 모델

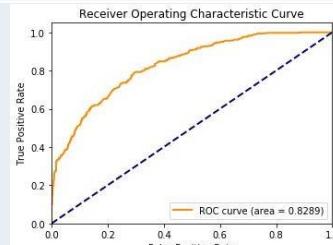
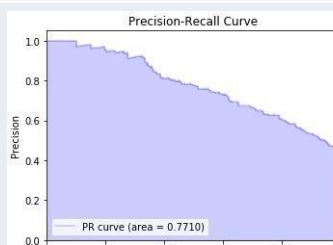
ROC(Receiver Operating Characteristic) Curve

3. ROC 의 매개 변수와 Curve

흔동행렬		Predicted		참 양성 비율(TPR) Sensitivity(Recall) $TP/(TP+FN)$	
		Positive	Negative		
Observed	Positive	TP	FN	허위 양성 비율(FPR) 1-Specificity $FP/FP+TN$	
	Negative	FP	TN		

- ROC Curve 는 다양한 분류 임계값의 TPR 및 FPR 을 표현하여 여러가지 상황을 고려하여 성능 판단

4. ROC Curve 와 Precision Recall Curve 비교

구분	ROC Curve	Precision Recall Curve
매개변수	Y축: Sensitivity(Recall) / X축: 1-Specificity	Y축: Precision / X축: Sensitivity(Recall)
Curve		
기준	Y=X 그래프 기준으로 상단에 위치 정도	실제 참의 비율에 따라 베이스 라인을 정하고 모델의 성능 판단

다양한 측도 - MSE, MSD, RMSE, RMSD, SST, SSE, SSR, R²

1. 추정값 또는 모델이 예측한 값과 실측값 과의 차이를 측정할 때 사용하는 측도,

- MSE : Mean Square Error (실측값과 예측값의 차이의 제곱의 평균)
- MSD : Mean Square Deviation (실측값과 평균의 차이의 제곱의 평균)
- RMSE: Root Mean Square Error (MSE제곱근)
- RMSD: Root Mean Square Deviation ((MSD제곱근)

2. 회귀분석에서 주로 활용하는, SST, SSE, SSR

총 변동 Total SS : total sum of squares (SST) : $SST = \sum_{i=1}^n (y_i - \bar{y})^2.$: 개별 y의 편차제곱의 합

설명된 변동 Model SS : explained sum of squares (SSE) : $SSE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2.$: 회귀식 추정 y의 편차제곱의 합

설명 안된 변동 Residual SS : residual sum of squares (SSR) : $SSR = \sum_{i=1}^n \hat{u}_i^2.$: 잔차의 제곱의 합

3. 변수들의 설명력, R² 와 adjusted R²

- R² : 회귀식의 상관계수 또는 분산분석의 데이터를 이용하여 회귀식의 정확도를 측정하는 기법
- Adjusted R² : 새로운 변수를 추가할 때 항상 증가하는 R-square 값을 보정하기 위해, 새로 추가된 변수가 y값에 영향을 미치는 경우에만 증가하도록 개선된 R-square

$$R^2 = \frac{SSE}{SST} = 1 - \frac{SSR}{SST}$$

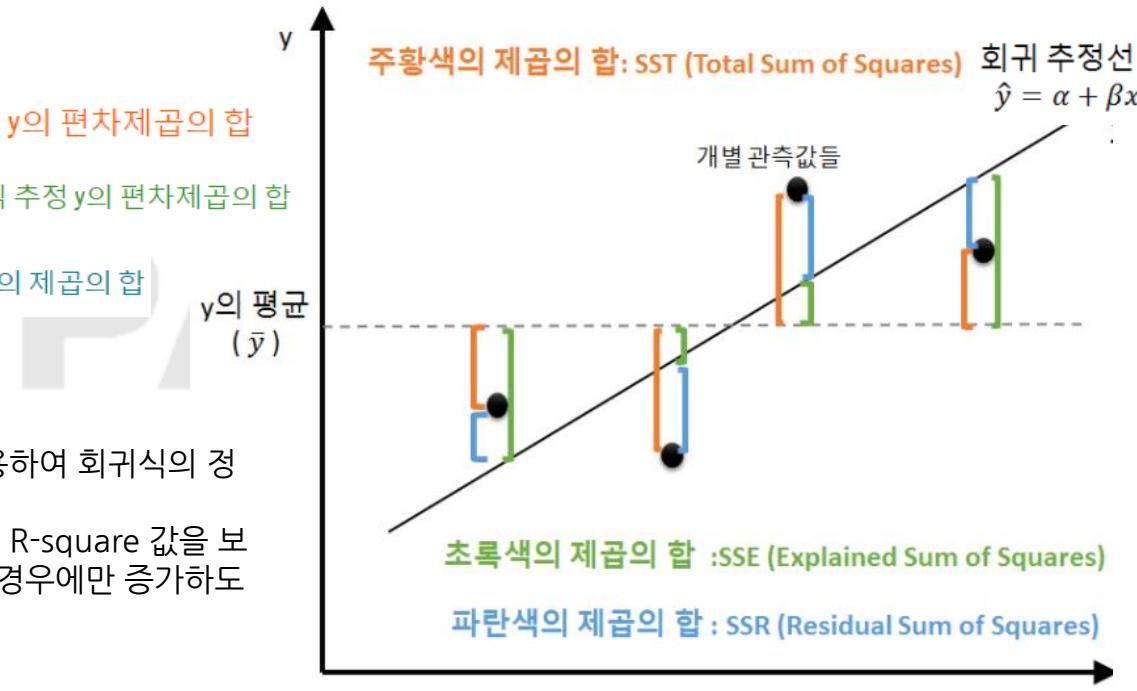
SSE: 오차 제곱 합

SSR: 회귀 제곱 합

SST: 총 제곱 합 (SSE + SSR)

$$MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2.$$

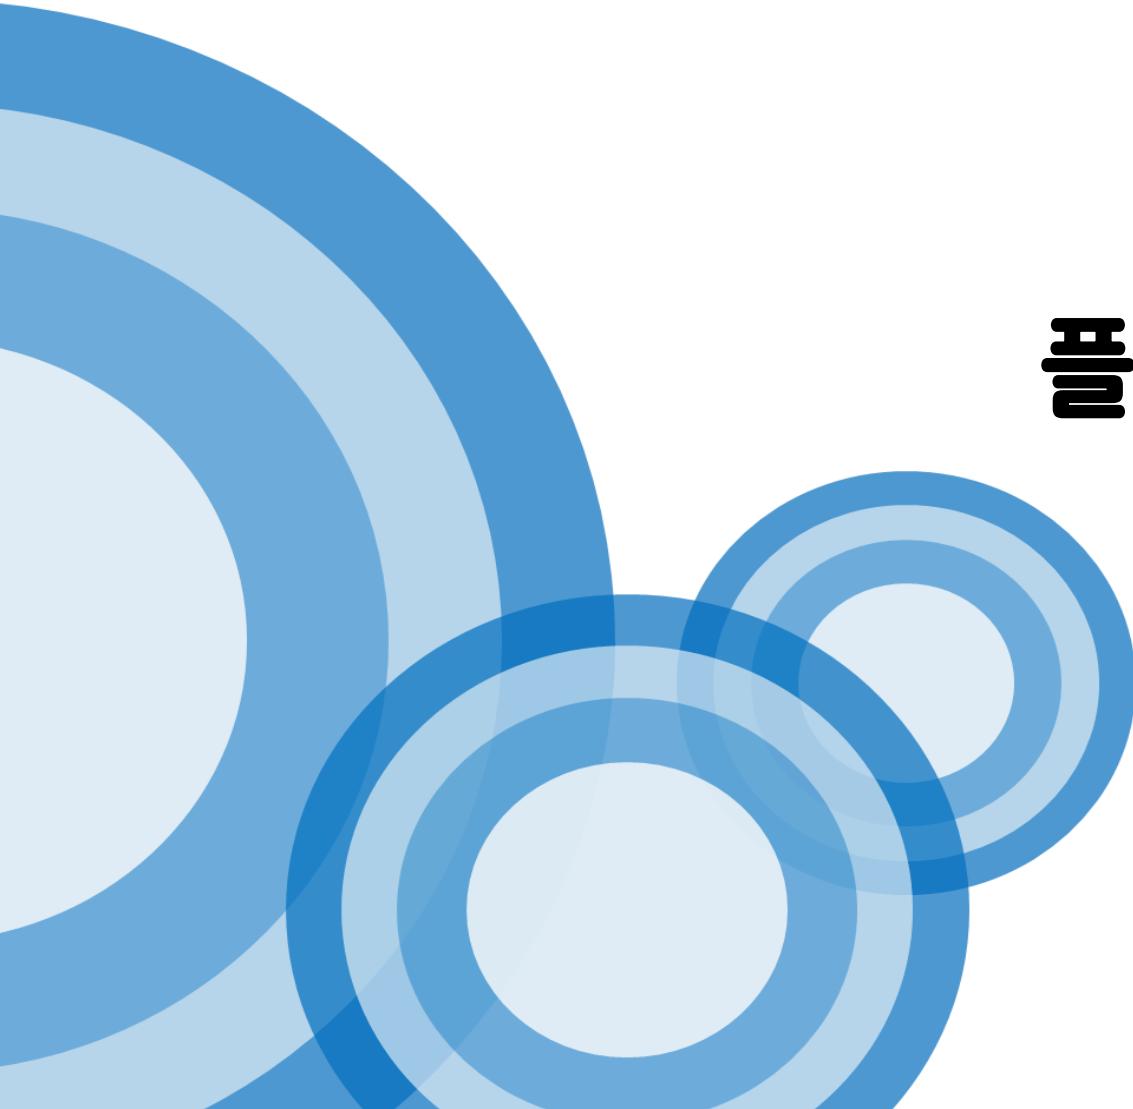
$$RMSE = \sqrt{MSE}$$



총변동 = 설명된 변동 + 설명안된 변동



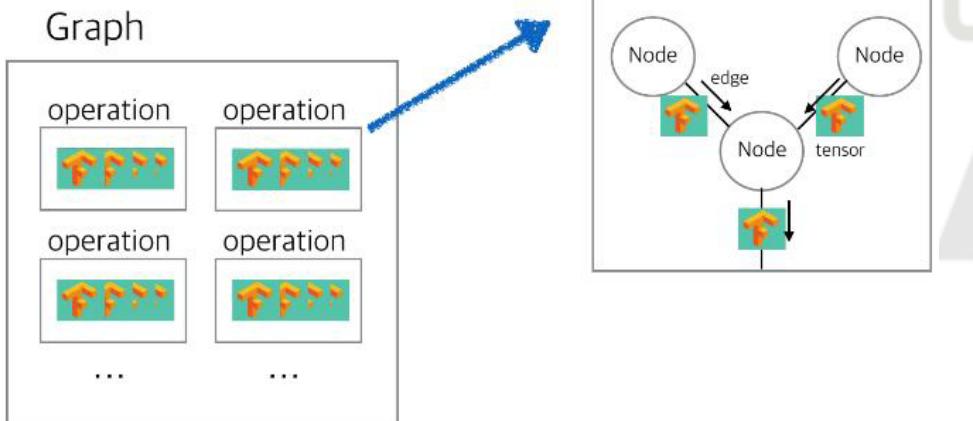
인공신경망 플랫폼 및 주요 서비스



텐서플로우(Tensorflow)

1. 구글에서 개발한 딥러닝 오픈소스 라이브러리, 텐서플로우의 개요

- 구글이 개발한 기계 학습과 딥러닝을 위해 **데이터 플로우 그래프(Data Flow Graph)** 방식을 이용해 만든 오픈소스 라이브러리
- 자동으로 미분 계산을 처리, Python/C++ 지원, 아파치2.0라이센스



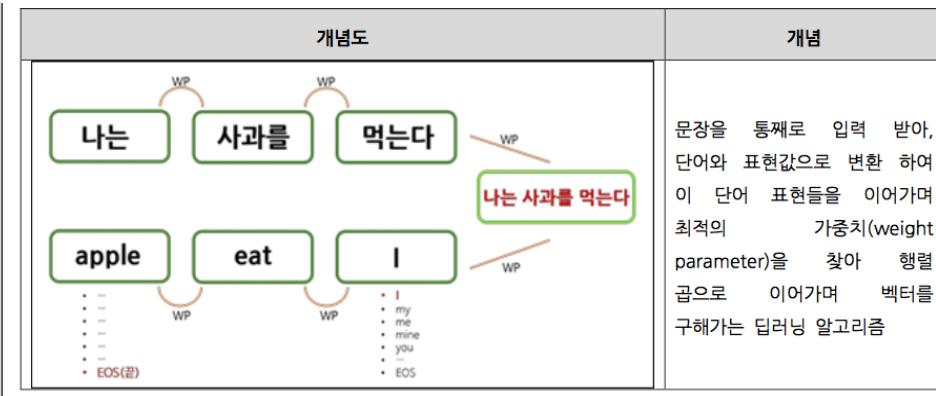
구분	설명	비고
노드(Node)	- 수학적 계산, 데이터 입/출력, 그리고 데이터의 읽기/저장 등의 작업을 수행 - 역전파 방법(Backpropagation)/플레이스 홀더(Placeholder)/소프트 맥스(Softmax)/크로스 엔트로피(Cross-Entropy) 등의 기술 사용	연산
엣지(Edge)	- 노드들 간 데이터의 입출력 관계 - 동적 사이즈의 다차원 데이터 배열(=텐서)을 전송	관계
텐서(Tensor)	- 과학과 공학 등 다양한 분야에서 이전부터 쓰이던 개념 - 수학에서는 임의의 기하 구조를 좌표 독립적으로 표현하기 위한 표기법 - 모든 데이터는 텐서를 통해 표현 - 학습 데이터가 저장되는 다차원 배열	Caffe의 Blob과 유사 데이터
오퍼레이션 (Operation)	- 그래프 상의 노드가 오퍼레이션(줄임말 op). 오퍼레이션은 하나 이상의 텐서를 받을 수 있으며, 계산을 수행하고 결과를 하나 이상의 텐서로 반환	노드
세션(Session)	- 그래프를 실행하기 위해서는 세션 객체가 필요 세션은 오퍼레이션의 실행 환경을 캡슐화.	객체
변수(Variables)	- 메모리 상에서 텐서를 저장하는 버퍼. - 변수는 그래프의 실행시, 파라미터를 저장하고 갱신하는데 사용	버퍼

NMT (Neural Machine Translation)

1. 인공신경망 기반 기계번역, NMT(Neural Machine Translation) 개요

- 기계번역의 한 종류로, AI가 데이터 학습을 통해 문장단위로 언어를 번역하는 기술

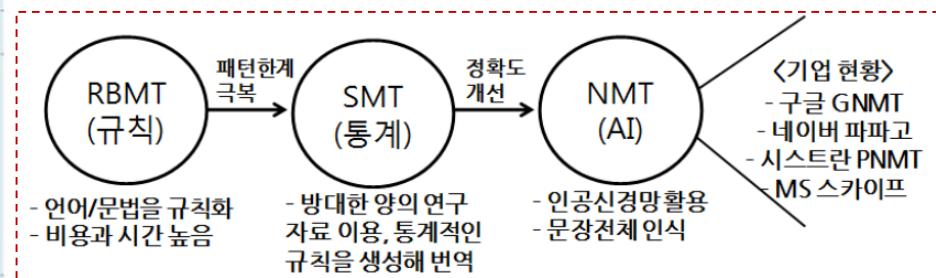
2. 통번역 인공지능의 대세, NMT의 개념도 및 주요 알고리즘



- 각 단어를 분리하고, 각 단어를 이어가며 가중치 (WP)를 통해 문장의 의미와 가장 유사한 결과값을 반환

구분	알고리즘	설명
Big Picture	워드 임베딩	• 한 단어를 입력하면 인공 신경망을 통해 단어와 관계 있는 관련 단어들이 워드 공간(Word Space) 상에 매핑이 되고, 이 단어 표현의 벡터 값이 곧 워드 임베딩
	순환 인공 신경망 (RNN)	• 과거의 출력이 다시 입력이 되는 구조를 소위 피드백 구조 • 시계열 데이터에서 패턴을 찾아내는데 최적화된 방법론으로써 음성인식과 자연어 처리에 활용
Sub Picture	Encoder	• 입력된 문장을 기계가 이해하는 언어로 변환하는 과정
	LSTM	• RNN의 한 유형으로, 피드백 데이터를 기억하는 구조로 사용(결과 저장, 참조)
	Decoder	• 기계적 언어를 변환하고자 하는 언어로 해독하는 과정
	Soft Max	• encoder에 저장된 LSTM의 output들은 각각 softmax activation를 통해 관련도에 따라 확률 값이 계산

네이버와 구글 인공지능 번역의 현재	
인공신경망 번역, N2MT(Naver Neural Machine Translation) 엔진 사용	방식
2016년 10월 21일	출시일
한국어 특유의 생활 언어 번역에 강점 (예) 먹방 → 네이버: Food-eating broadcasts → 구글: Food(예) 노잼 → 네이버: Not funny → 구글: Not fun(예) 첫눈에 반했어 → 네이버: I fell in love with you at first sight. → 구글: I was at first sight.	특징
한국어, 영어, 중국어, 일본어(4개 국어)	지원 언어



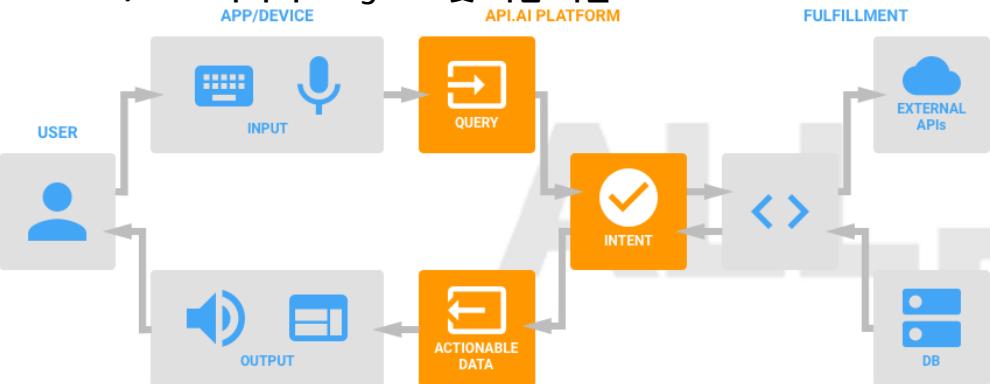


초저지연 - AI 스피커

1. ZERO UI의 실체화를 통한 AI 스피커 개요

- 인공지능, 음성인식 기술을 이용해 사용자와 의사소통하는 기기
- 자연어를 인식하여 다양한 인공지능 알고리즘에 의해 분석한 결과와 현재 환경상황에 맞는 결과를 응답하는 스피커
- 음성, 이미지등을 기계(컴퓨터등)로 식별하여, 사용자와 교감하여 편의성을 제공 해 주는 기술

2. AI 스피커의 Diagram 및 핵심 기술



구성	설명
음성인식	- 개인 맞춤형 연속어 음성인식 기술 - 실시간 음성인식, 최고의 인식율 (HMM, CNN, RNN 등)
텍스트분석	- 고성능/고정밀/고품질 자연어 처리 기술 - 딥러닝 기반 감성인식 및 자동 분류 기술 (RNN, LSTM 등)
대화처리	- 대화 모델링, 시나리오 구축 - 기존 대화의 챗봇 학습 (빅데이터, 클라우드 등)
음성합성	- 파라메트리 음성 합성(DNN TTS) - 감성 합성(Augmented Sentiment Talk)
Question & Answer	- 질문분석, 광범위한 지식베이스 구축 - 딥러닝 외 다양한 기계학습

3. AI 스피커 보안 이슈

- 음성 하이재킹 : 해커가 호출 명령어를 탈취해 AI 스피커로 도청 등 악의적 행동
- 비가청 대역 청취 악용 : 인간 귀로 들을 수 없는 소리에 반응하는 취약점 (사람이 귀로 들을 수 없는 소리 명령을 받아들인다. 물건을 구매하거나 현관문 잠금장치 해제 등 명령에 반응 가능)
- 스마트홈 허브 역할로 AI 스피커 보안 취약점은 이와 연결된 IoT 기기를 모두 위협에 노출 됨

4. AI 스피커 사용자를 위한 보안 수칙

- AI 스피커를 연결할 때 기존 계정이 아닌 새로운 계정
- 민감한 음성 녹음 내용을 삭제
- 장치에 연결된 계정은 강력한 암호화 이중인증(2FA)
- WPA2 암호화 와이파이 네트워크를 사용
- AI 스피커에 들어 있는 자동 업데이트 기능 사용



초저지연 - AI 스피커

4. AI Speaker 보안 취약점

보안 취약점	세부 보안 취약점 내용
화자인증 미 지원	<ul style="list-style-type: none"> 인명여부 구분하지 못함 화자인증 못하고 명령어 전에 부르는 말(아리아 등)을 항상 말하면 명령 처리됨 스피커 명령어 조작가능, TV나 라디오 목소리 인식 주문결제가능
스텔스 명령	<ul style="list-style-type: none"> 사람이 알아들을 수 없는 스텔스 명령/초고주파로 조작가능 아마존 에코 귀신 소리 발생
네트워크 취약성	<ul style="list-style-type: none"> 블루본 취약성 노출 IoT 기기 네트워크 보안 취약성 노출
패치 미지원	<ul style="list-style-type: none"> 보안패치 실시간 업데이트 안 함 스피커 제품 출시이후 39~59개월 전 커널 버전 사용중
개인정보유출	<ul style="list-style-type: none"> 인화되는 AI 스피커 스마트 헤어장치로 개인정보유출 취약성 생활 도청 취약성

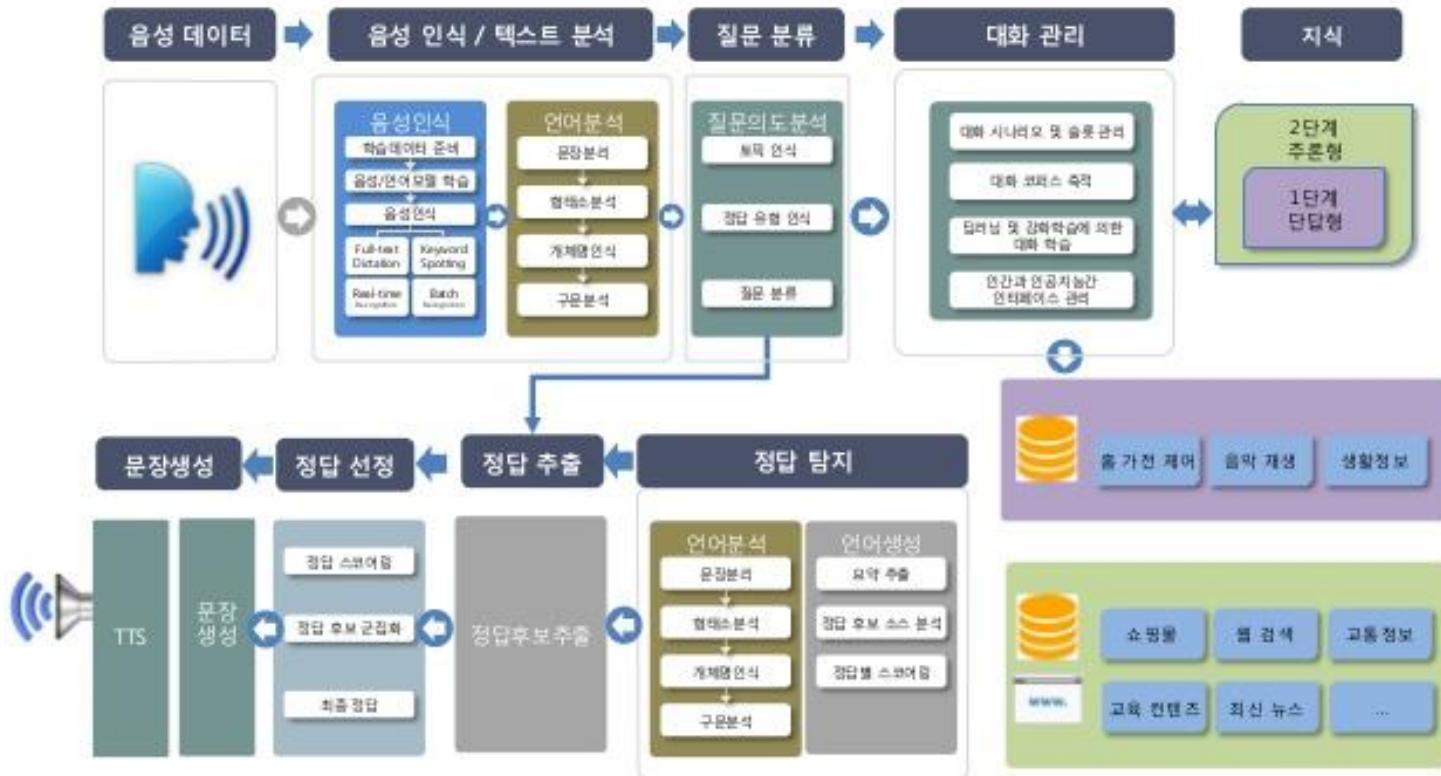
5. AI Speaker 보안 취약점의 대응 방안

보안 대응 방안	대응 상세 설명
화자인증/인식 지원	<ul style="list-style-type: none"> 화자식별, 화자인증, 보안인증을 통한 AI 스피커 보안 강화
스텔스 명령	<ul style="list-style-type: none"> 스텔스 명령 반응 차단 고주파 입력 차단
네트워크 보안	<ul style="list-style-type: none"> 블루본 취약성 실시간 패치 업데이트 보안 AP, wifi 연결 - 안전한 네트워크 사용 암호화 네트워크 채널 사용 IoT 보안인증 가이드 준수
패치 지원	<ul style="list-style-type: none"> 커널 최신 보안패치 실시간 업데이트 지원, 커널 최신 버전 탑재 의무 규제화
개인정보유출 차단	<ul style="list-style-type: none"> 개인정보보호법 준수 적용 및 EU-GDPR 컴플라이언스 준수
킬 스위치	<ul style="list-style-type: none"> 지능화되어 AI화 되는 AI플랫폼 탑재 대응 제어장치 제공(전원 poweroff 보다 빠른 대응장치)
IoT 큐브	<ul style="list-style-type: none"> 보안 취약점 자동 분석 플랫폼 AI 스피커 취약성 점검 툴 이용 사이트(온/오프라인 제공) 실시간 패치제공 사이트와 연계 제공(취약성발견 -> 패치)

초저지연 - AI 스피커

AI Speaker Data Flow

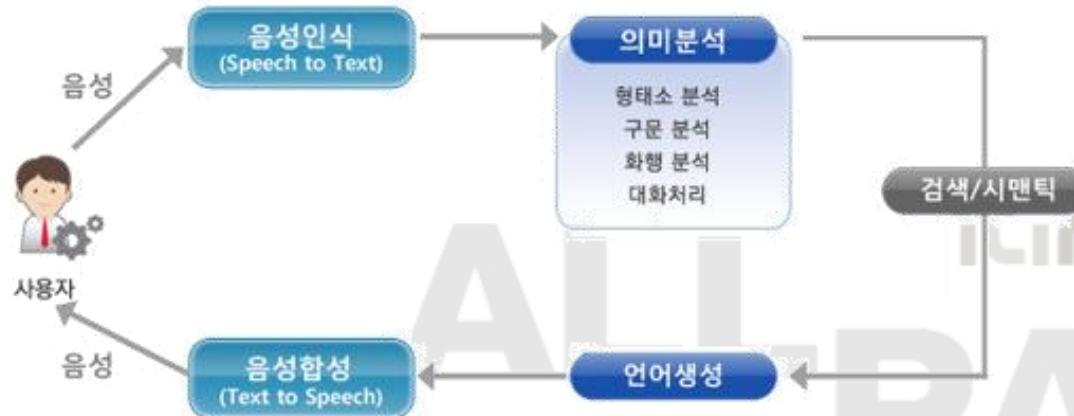
MINDs Lab



자연어처리 Natural Language Processing

1. 자연어 처리의 개요

- 컴퓨터를 이용하여 사람 언어의 이해, 생성 및 분석을 다루는 인공 지능 기술

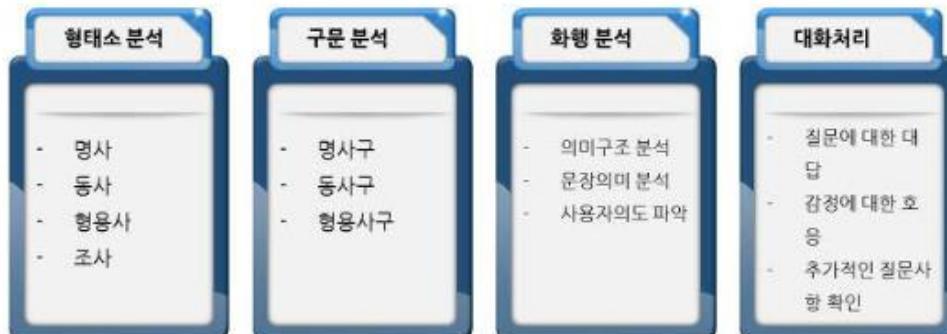


▪ STT : Speech To Text

- 사람이 말하는 음성 언어를 컴퓨터가 해석해 그 내용을 문자 데이터로 전환하는 처리

▪ TTS : Text To Speech

- 말소리의 음파를 기계가 자동으로 만들어 내는 기술
- 사람의 말소리를 녹음하여 일정한 음성 단위로 분할한다음, 부호를 붙여 합성기에 입력하였다가 지시에 따라 필요한 음성 단위만을 다시 합쳐 말소리를 인위로 만들어내는 기술



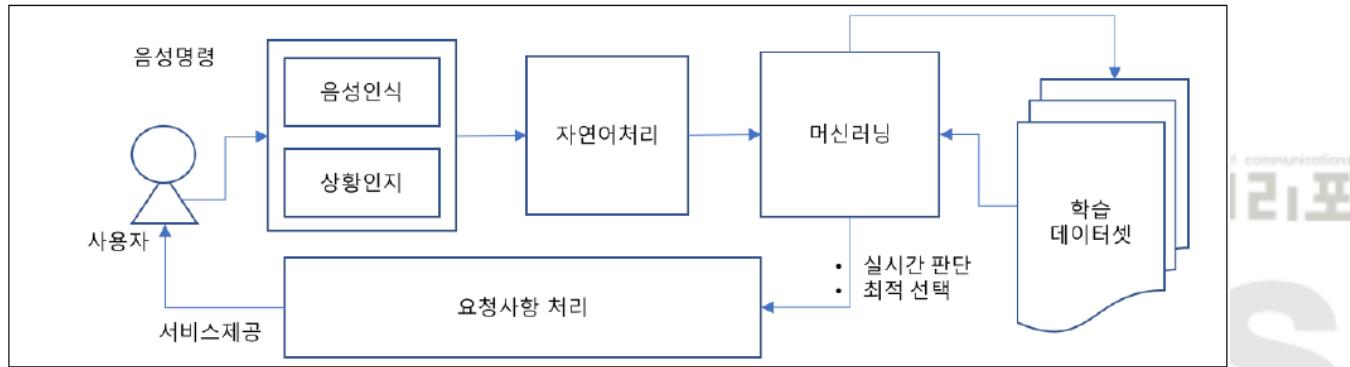
구성요소	설명	비고
형태소분석기	- 텍스트를 입력으로 하고 그것을 형태소 단위 (사전의 표제어 단위)로 분석하여 사전에 있는 정보 (품사정보)와 함께 출력해 주는 분석기	명사, 조사, 형용사, 부사 등
구문분석기	- 형태소분석 결과로 도출된 품사를 조금 더 큰 단위로 묶어 구문 단위로 도출하는 분석기	명사구, 동사구, 형용사구
의미분석기	- 구문이 의미적으로 부합하는지 검사하는 분석기	수학적 규칙은 없음
각종 사전	- 자연어처리를 위해 기본이 되는 용어들의 집합	형태소사전, 불용어, 신조어, 성인어

가상개인비서(Virtual Personal Assistant, VPA)

1. 자연어처리기반 디지털 헬퍼, 가상개인비서의 개요

- 사용자의 음성 언어를 **이해하고 자연어 처리 및 인공지능 기술을 이용하여 원하는 사항을 수행**하는 가상의 SW 어플리케이션

2. 가상개인비서의 구조도 및 핵심기술

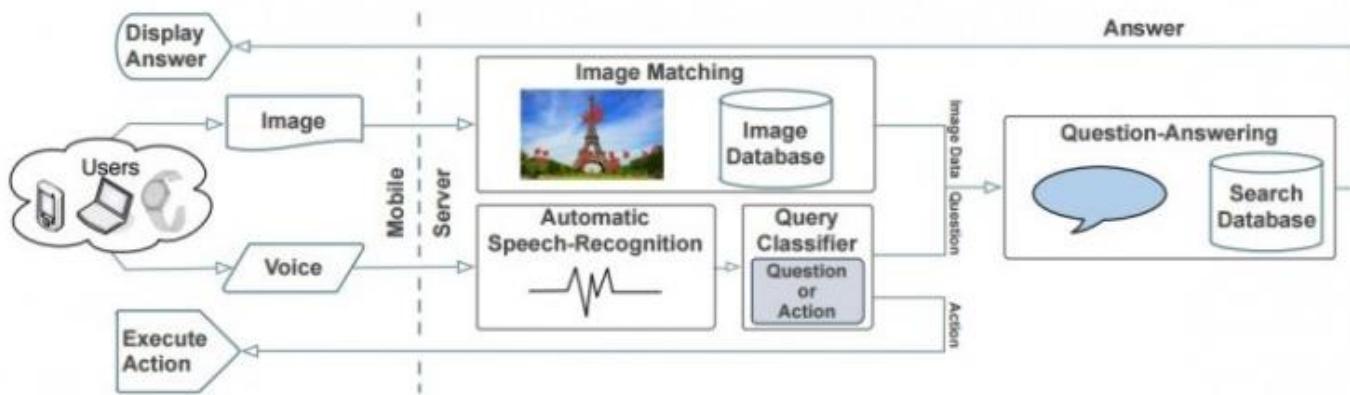


분류	핵심기술	핵심기술 설명
언어처리	음성인식	<ul style="list-style-type: none">사용자의 음성 인식하여 텍스트로 전환
	자연어처리	<ul style="list-style-type: none">언어 형태와 의미를 분석해 컴퓨터가 처리할 수 있는 정보로 변환
상황인지	동작인식	<ul style="list-style-type: none">모션 센싱을 통한 동작 인식
	위치인식	<ul style="list-style-type: none">GPS, Wifi 등 연계하여 위치기반 상황인식
인공지능	머신러닝	<ul style="list-style-type: none">대량의 데이터를 기반으로 지도, 비지도 학습 데이터 생성 및 조회
	검색	<ul style="list-style-type: none">사용자 요청사항에 최적화된 데이터셋을 검색기(searcher)를 통해 조회
데이터	빅데이터	<ul style="list-style-type: none">전체 학습 데이터 및 사용자 특화 행동 패턴 데이터를 통합한 전체 데이터

음성인식비서(AI Speaker)

1. AI 스피커의 개요

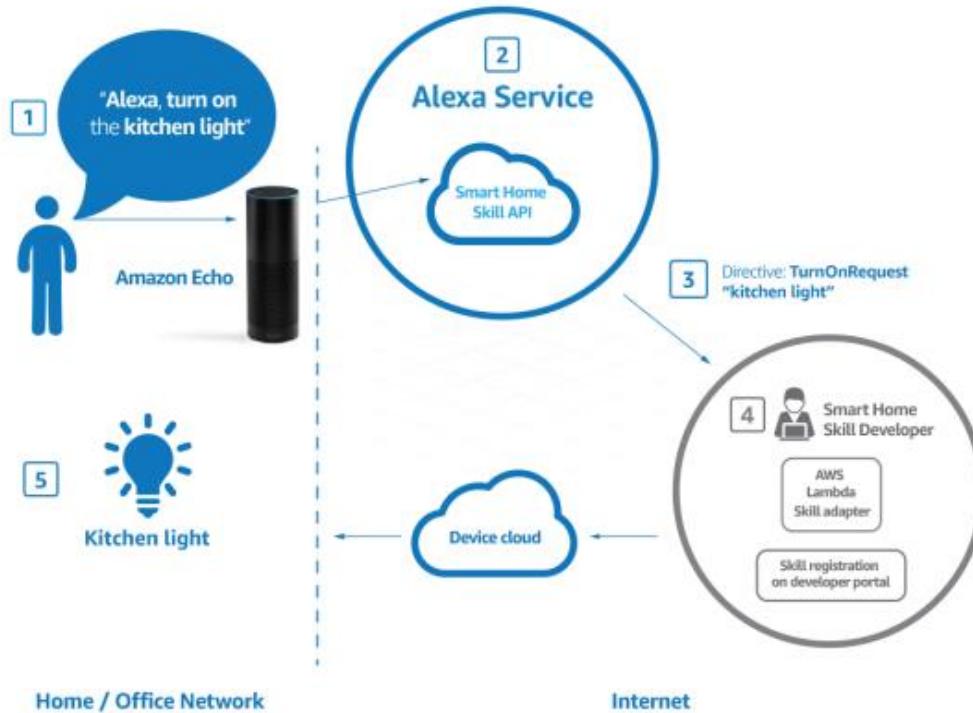
- 음성, 이미지 등을 기계(컴퓨터등)로 식별하여, 사용자와 교감하여 편의성을 제공 해 주는 기술



구성	설명
음성인식	<ul style="list-style-type: none">- 개인 맞춤형 연속어 음성인식 기술- 실시간 음성인식, 최고의 인식율 (HMM, CNN, RNN 등)
텍스트분석	<ul style="list-style-type: none">- 고성능/고정밀/고품질 자연어 처리 기술- 딥러닝 기반 감성인식 및 자동 분류 기술 (RNN, LSTM 등)
대화처리	<ul style="list-style-type: none">- 대화 모델링, 시나리오 구축- 기존 대화의 팁챗 학습 (빅데이터, 클라우드 등)
음성합성	<ul style="list-style-type: none">- 파라메트리 음성 합성(DNN TTS)- 감성 합성(Augmented Sentiment Talk)
Question & Answer	<ul style="list-style-type: none">- 질문분석, 광범위한 지식베이스 구축- 딥러닝 외 다양한 기계학습

음성인식비서(AI Speaker) : 사례 - 알렉사(Alexa)

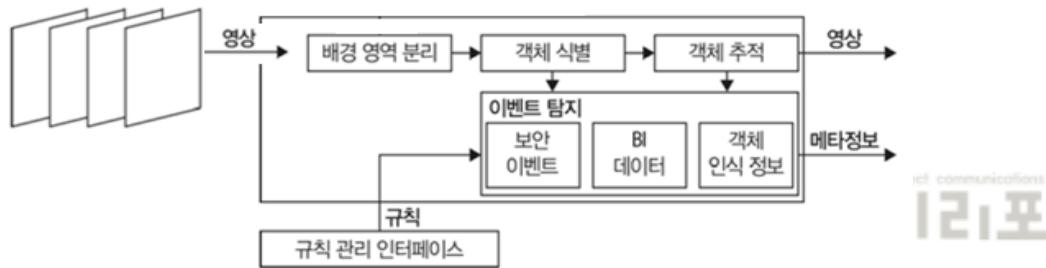
- AWS 클라우드 플랫폼을 기반
- 각종 기능을 연동하는 ASK(Alexa Skills Kit)
- 음성대화를 제공하는 AVS(Alexa Voice Service)
- 외부 개발자들이 알렉사를 손쉽고 빠르고 활용할 수 있도록 API, 도구, 문서, 코드 샘플 등을 제공



지능형 CCTV

1. 지능형 CCTV의 개요

- CCTV 카메라에 객체가 잡히면 객체의 침입 / 이동 / 사라짐등을 즉시 감지하여 **위험상황인지를 판단하고 관리자에게 알리는 CCTV**



■ 주요기능

	• 침입감지		• 객체분류		• 배회감지
	• 임의조작감지		• 속도 필터		• 이동방향 감지
	• 출입감지		• 방치된 물체 감지		• 뒤따름감지
	• 출현감지		• 사라진 물체 감지		• 객체카운팅
	• 정지감지		• 자동PTZ트레킹		• 연기 및 화재감지

■ KISA 성능심사 기준

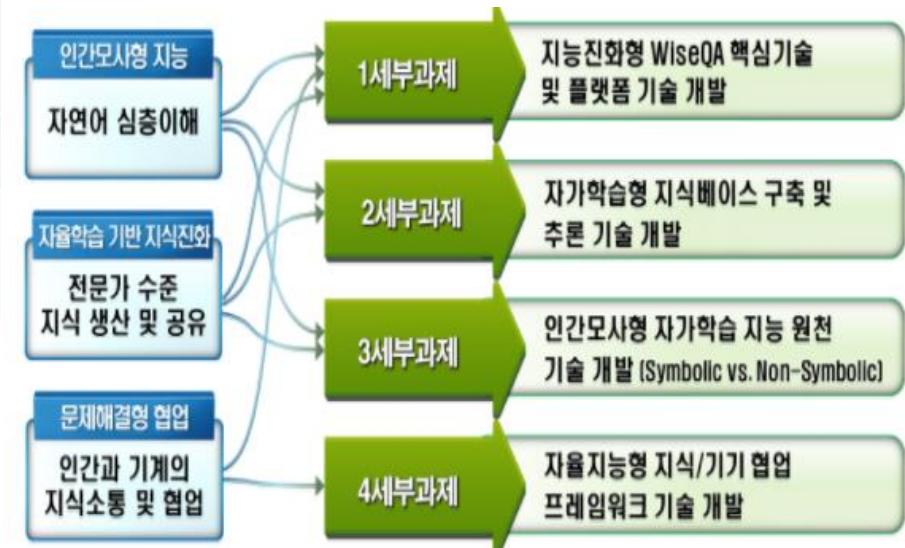
■ 인증 분야 및 기준

구분	배회	침입	유기	쓰러짐	싸움	방화						
정의	일정구역 내 10초 이상 머무름	펜스, 금지지역 등을 침입	쓰레기, 가방을 버림	땅바닥에 머리를 대는 행위	두사람의 팔/다리가 5초 이상 겹침	사람이 불을 냉						
인증 점수 (100점 만점)	90점 이상	90점 이상	90점 이상	90점 이상	90점 이상	90점 이상						
행위 발생 이전 2초, 이후 10초 이내												
특이 사항	사람의 몸 전체가 인정구역내 진입해야 함	사람만 식별, 자동차/조류 등의 감지는 제외	-	사람의 몸 전체가 감지되어야 함	최초 발생만 기록, 다른 이벤트 기록 시 오검출 처리							
필수/선택	필수		선택 (※ 1개 이상 선택)									
유효기간	3년											
비용	무료											

1. 국내에서 인공지능 프로젝트, exobrain의 개요

- 사람을 대신하여 학습하고 기억하며 필요 정보를 적절히 가공하고 선별해서 최적의 결과물을 만들어 주는 역할 하는 인공 두뇌를 개발하는 프로젝트(미래창조과학부)

기술	내용	추진기관
자연어 이해 기술	<ul style="list-style-type: none"> 자연어 이해를 통한 지속적 언어지식 학습 빅데이터를 베이스로 형태소 분석 및 자연어 이해 	ETRI
질의 응답 기술	<ul style="list-style-type: none"> 사람과 유사한 자연어 기반 최적 질의 대응 	
자가학습 KB 기술	<ul style="list-style-type: none"> 지식생산을 베이스로 지식베이스 구축 	솔트룩스
추론 기술	<ul style="list-style-type: none"> 지식베이스 기반 스스로 예측/추론하는 강한 인공지능 지향 기술 	
인간 모사형 학습 지능 원천 기술	<ul style="list-style-type: none"> 자가 학습을 인간과 유사한 지능화 원천기술 지식베이스의 확장을 통한 영역 확장 	KAIST
자율협업 지능 기술	<ul style="list-style-type: none"> 지식/기기의 협업을 위한 지능형 프레임워크 개발 도메인 협업 지식 제공방법, KB 구축과 활용 및 추론 기술 상호 협력 복합 상황추론, 대규모 불완전 추론 	ETRI



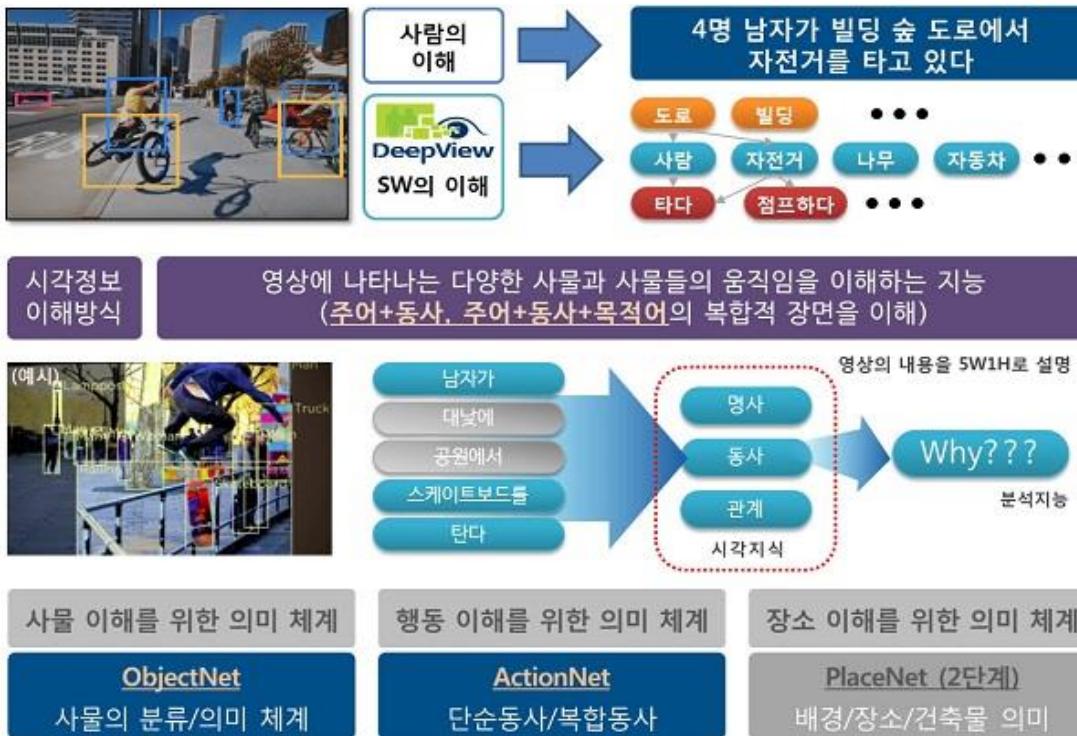
- 지능 진화형의 인공지능 원천 기술 확보 및 기술 선도
- 전문가 문제해결/의사결정 지원 지식 컨설팅 제공
- ICT 융합 기반의 지능형 서비스 산업 및 신시장 창출

딥뷰 (Deep View)

1. 한국전자통신연구원(ETRI) 연구진이 개발한 시각 인공지능 기술, 딥뷰(Deepview) 개념

- 사람이 사물을 인지하고 시공간적으로 상황을 파악하며, 직관적으로 사물을 인지하듯 사람처럼 인지하는 시각 인공지능 SW
- 미래창조과학부 SW 분야의 그랜드 챌린지 과제로 2013년에 시작돼 10년간 총 3단계에 걸쳐 수행 예정

2. 딥뷰의 개념도 및 기술요소



분류	기술요소	설명
시각정보 수집	시각데이터 자산화	- 시각데이터 뱅크를 중심으로 실시간, 대규모 데이터 수집
	빅데이터 저장	- 비정형 대용량 데이터 저장 기술
	API 지원	- 시각 데이터 변환 및 외부서비스 I/F 연계처리
대규모 처리	처리 파이프라인	- 대용량 비정형 시각데이터 처리방법 규격화 기술 병렬, 분산 처리 지원
	하이브리드 스케줄러	- 워크플로우 기반 분산처리와 GPU 사용 극대화 기술
내용분석	이미지분석	- 객체와 움직임을 분석하고 상호관계 복합 분석
	시각 텍소노미	- 이벤트, 객체에 대한 지식체계 구축
	시멘틱 추론	- 온톨로지 기반으로 복합동상 추론
예지형 응용	예측기술	- 시각정보 기반 재난/재해 등 선제적 예측
	실시간 대응	- 시각정보에 대하여 즉각적인 이벤트, 행위 발생 연계
지원	플랫폼화	- 고성능 비주얼 디스커버리 플랫폼 지원

딥뷰 (Deep View)

개념 및 내용

- 영상 데이터에 포함된 내용과 의미를 이해하는 시각지능 SW
※ Deep View : 영상의 내용을 사람처럼 읽어낼 수 있는 시각지능 SW



DeepView
플랫폼

대규모 이미지와 동영상의 내용을 이해하고 분석하는 시각지능 플랫폼

시각지능 SW
(1단계: 명사 25종, 동사 20종)

영상내용 이해지능

명사(사물, 배경) 이해

동사(행동) 이해

시각
학습

- 대규모 기계학습
- 양상을 기계학습
- 도메인 전이학습

시각
이해

- Scene/Activity 추론 및 이해
- 시각지식 자동생성

시각 빅데이터 분석 시스템
(1단계: 1시간 영상/10분 처리)

대규모 영상분석 시스템

시각학습/이해 파이프라인
(분산/병렬화)

공간상황의 종합분석
(공간중심, 시간중심)



도시 영상관제

자율시각/원격시각

시리우스

1. 시리우스의 개요

- 미시간대학 연구소 Clarity Lab에서 개발한 음성인식 오픈소스 플랫폼

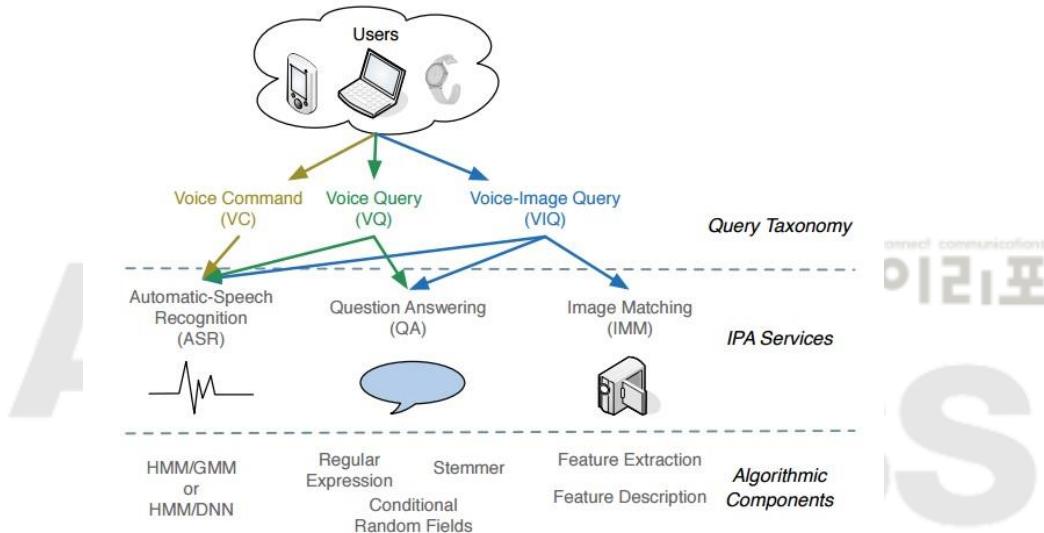


Figure 3: Tier-level View of Sirius

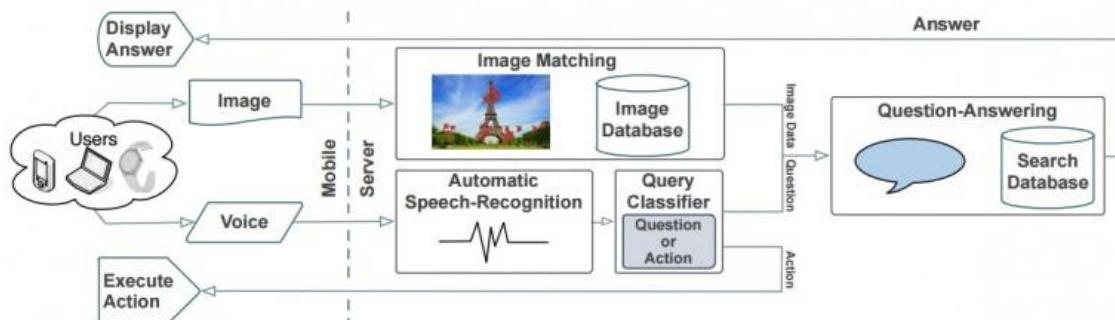


Figure 2: End-to-end Diagram of the Sirius Pipeline

Image Matching (특징추출, 특징설명)
자동 음성 인식 (HMM/DNN)
질의 분류기 Query Classifier
QA

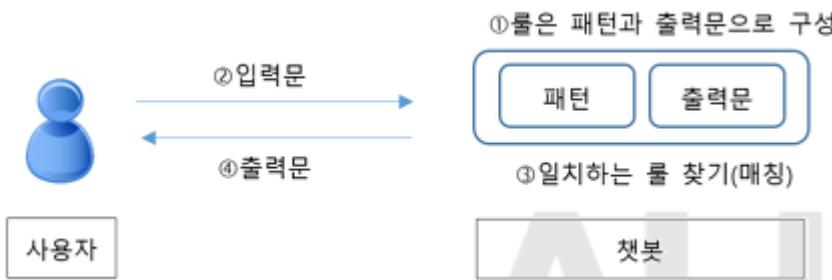


챗봇

1. 인공지능(AI) 기반의 커뮤니케이션 소프트웨어, 챗봇의 개요

- 정해진 응답 규칙에 따라 사용자 질문에 응답할 수 있도록 만들어진 인공지능 시스템

2. 챗봇의 개념도 및 기술요소



핵심기술	세부 내용
패턴인식	• 기계에 의하여 도형, 문자, 음성 등을 식별시키는 것
자연어처리	• 정보검색, 질의응답, 시스템 자동번역, 통역 등이 포함
시멘틱 웹	• 컴퓨터가 정보자원의 뜻을 이해하고, 논리적 추론까지 할 수 있는 차세대 지능형 웹
텍스트 마이닝	• 비정형 텍스트 데이터에서 새롭고 유용한 정보를 찾아내는 과정 또는 기술
상황인식컴퓨팅	• 가상공간에서 현실의 상황을 정보화하여 사용자 중심의 지능화된 서비스 제공

3. 챗봇의 유형

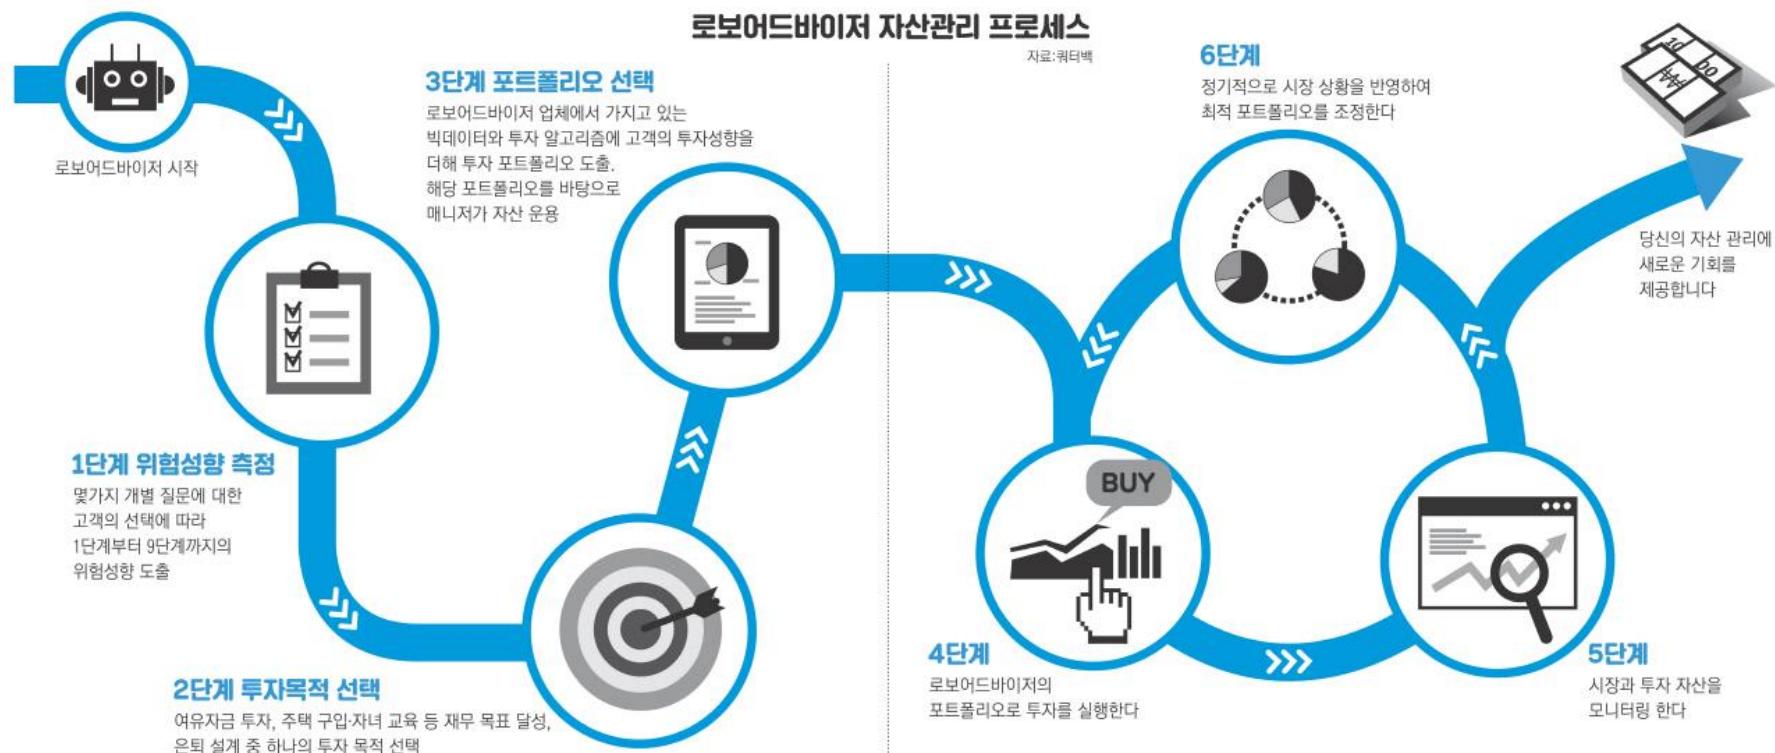
구분	질의 응답형 챗봇	인공지능 상담 챗봇
대화방식	단방향 정보전달: 사용자 질문에 대한 답 변환 가능하며 추가 보완은 어려움	쌍방향 정보 교류: 대화 에이전트가 주도 적으로 사용자와의 질문-답변 과정을 반복 하여 부족한 정보를 보완
정보제공	포괄적 정보제공: 일반적인 정보만 제공하기 때문에 자신에게 맞는 정보인지 스스로 판단 필요	맞춤형 정보제공: 대화를 통해 사용자의 상황 정보를 인식하여 사용자에게 적합한 정보 제공

4. 챗봇 서비스 발전 단계

구분	1 단계 : 챗봇 서비스	2 단계 : 지능형 비서	3 단계 : 감성 비서
제공방식	텍스트, 음성	텍스트, 음성, 시각자료	텍스트, 음성, 시각자료, 행동인지
입력방식	폐쇄형, 개방형 일부	폐쇄형 일부, 개방형	개방형, 폐쇄형 복합사용
주요기술	패턴매칭, 키워드 및 연관어 추출등	딥러닝, 머신러닝, 자연어 처리, 기타 신기술 융합 등	감성인식기술, 데이터 정형화 기술 등
내용	- 학습된 내용에 대한 질의응답 - 사용자와 단순한 형태의 소통 - 검색을 통한 결과 제공	- 사용자의 패턴, 상황을 고려한 개인 맞춤형 서비스 제공 - 간단한 업무 처리	- 감정교류를 통한 서비스 및 각종 서비스에 대한 선제적 대응

1. AI 기반의 자산관리, 로보어드바이저의 개요

- 로봇을 의미하는 로보(Robo) 와 자산관리전문가를 의미하는 어드바이저(Advisor)의 합성어로 알고리즘이 투자의 중심이 되는 로봇 기반의 인공지능 투자 플랫폼



로봇 저널리즘

1. AI 기반의 자동 신문기사 작성 기법, 로봇 저널리즘의 개요

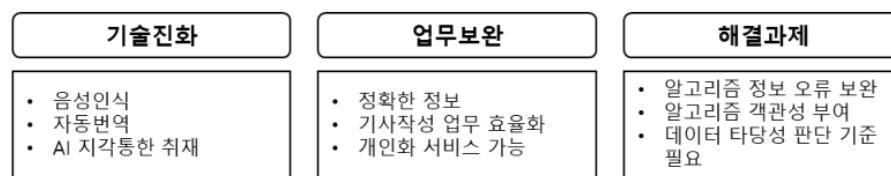
- 로봇과 언론을 뜻하는 저널리즘의 합성어로 컴퓨터가 소프트웨어 알고리즘에 의해 스스로 기사를 작성하는 인공지능 자동 기사 작성 기법(독자의 관심사, 독자가 기사를 읽는 시간, 장소 등 상황(Context-Aware)에 기반한 정보를 제공하는 형태로 발전 예상)
- 뉴스 기사를 만드는 모든 과정에 컴퓨터 알고리즘이** 관여하여 미리 정의된 알고리즘을 통해 정보들을 분류하고 의미를 해석하여 스스로 기사를 작성하는 프로그램

2. 로봇 저널리즘의 기사작성 매커니즘 및 상세 설명



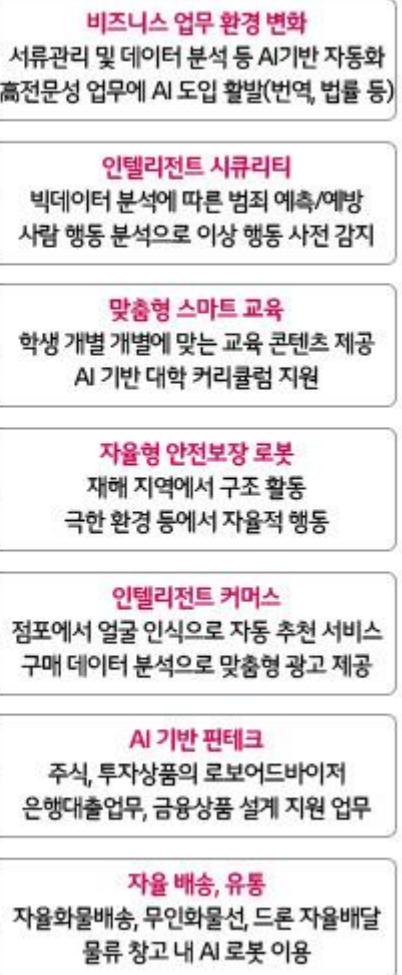
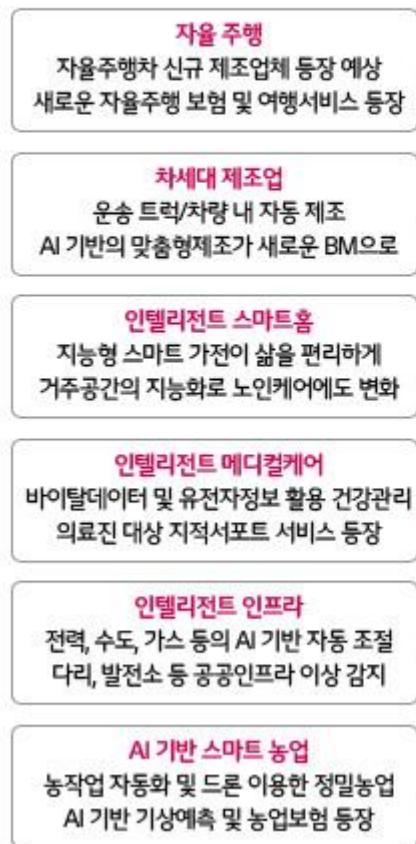
기사작성 과정	상세 설명	적용 기술 및 알고리즘
데이터수집	<ul style="list-style-type: none">데이터 원천에서 수집 및 데이터를 정제하고 분석을 위한 형태로 변환.	<ul style="list-style-type: none">API, Tag, 웹크롤링토큰화, 불용어처리, 단어분리중복배제, 자동분류
이벤트추출	<ul style="list-style-type: none">텍스트 마이닝 (Text mining) 의미망 분석 (Semantic analysis) 등 텍스트 분석 기법을 활용, 데이터에 의미 부여	<ul style="list-style-type: none">형태소분석, 구문분석, 온톨로지코사인 유사도, PNNC 알고리즘시멘틱 분석 NMT, 머신러닝
중요이벤트 선별	<ul style="list-style-type: none">추출한 이벤트들의 중요도를 선별하는 단계, 통계적 분석 기법 기계학습 등 알고리즘 적용, 중요 이벤트 선별	<ul style="list-style-type: none">랭킹, 추천SLM, Perplexity, 조건부 확률
기사 분위기 결정	<ul style="list-style-type: none">여러 관점을 종합하여 화자가 글을 통해 전달하고 싶은 주제를 전달하는 방식으로 분위기 결정	<ul style="list-style-type: none">요약, 사건 예측감성분석 (PMI, 감성어, 어휘)감성분류 (어휘기반 모형기반)
뉴스기사 생성	<ul style="list-style-type: none">이전 단계에서 선별한 중요 이벤트를 설명할 수 있는 적절한 문장을 선택하여 기사를 작성	<ul style="list-style-type: none">NLG, Corpus, Decision Tree, LSTM템플릿 작성, 속성값 설정, 데이터간 매칭 스코어 계산

제 4차 산업혁명 핵심기술 로봇 저널리즘 → AI + 로봇저널리즘 진화



인공지능이 만들어갈 새로운 시장

인공지능(A.I.)가 만드는 새로운 시장들

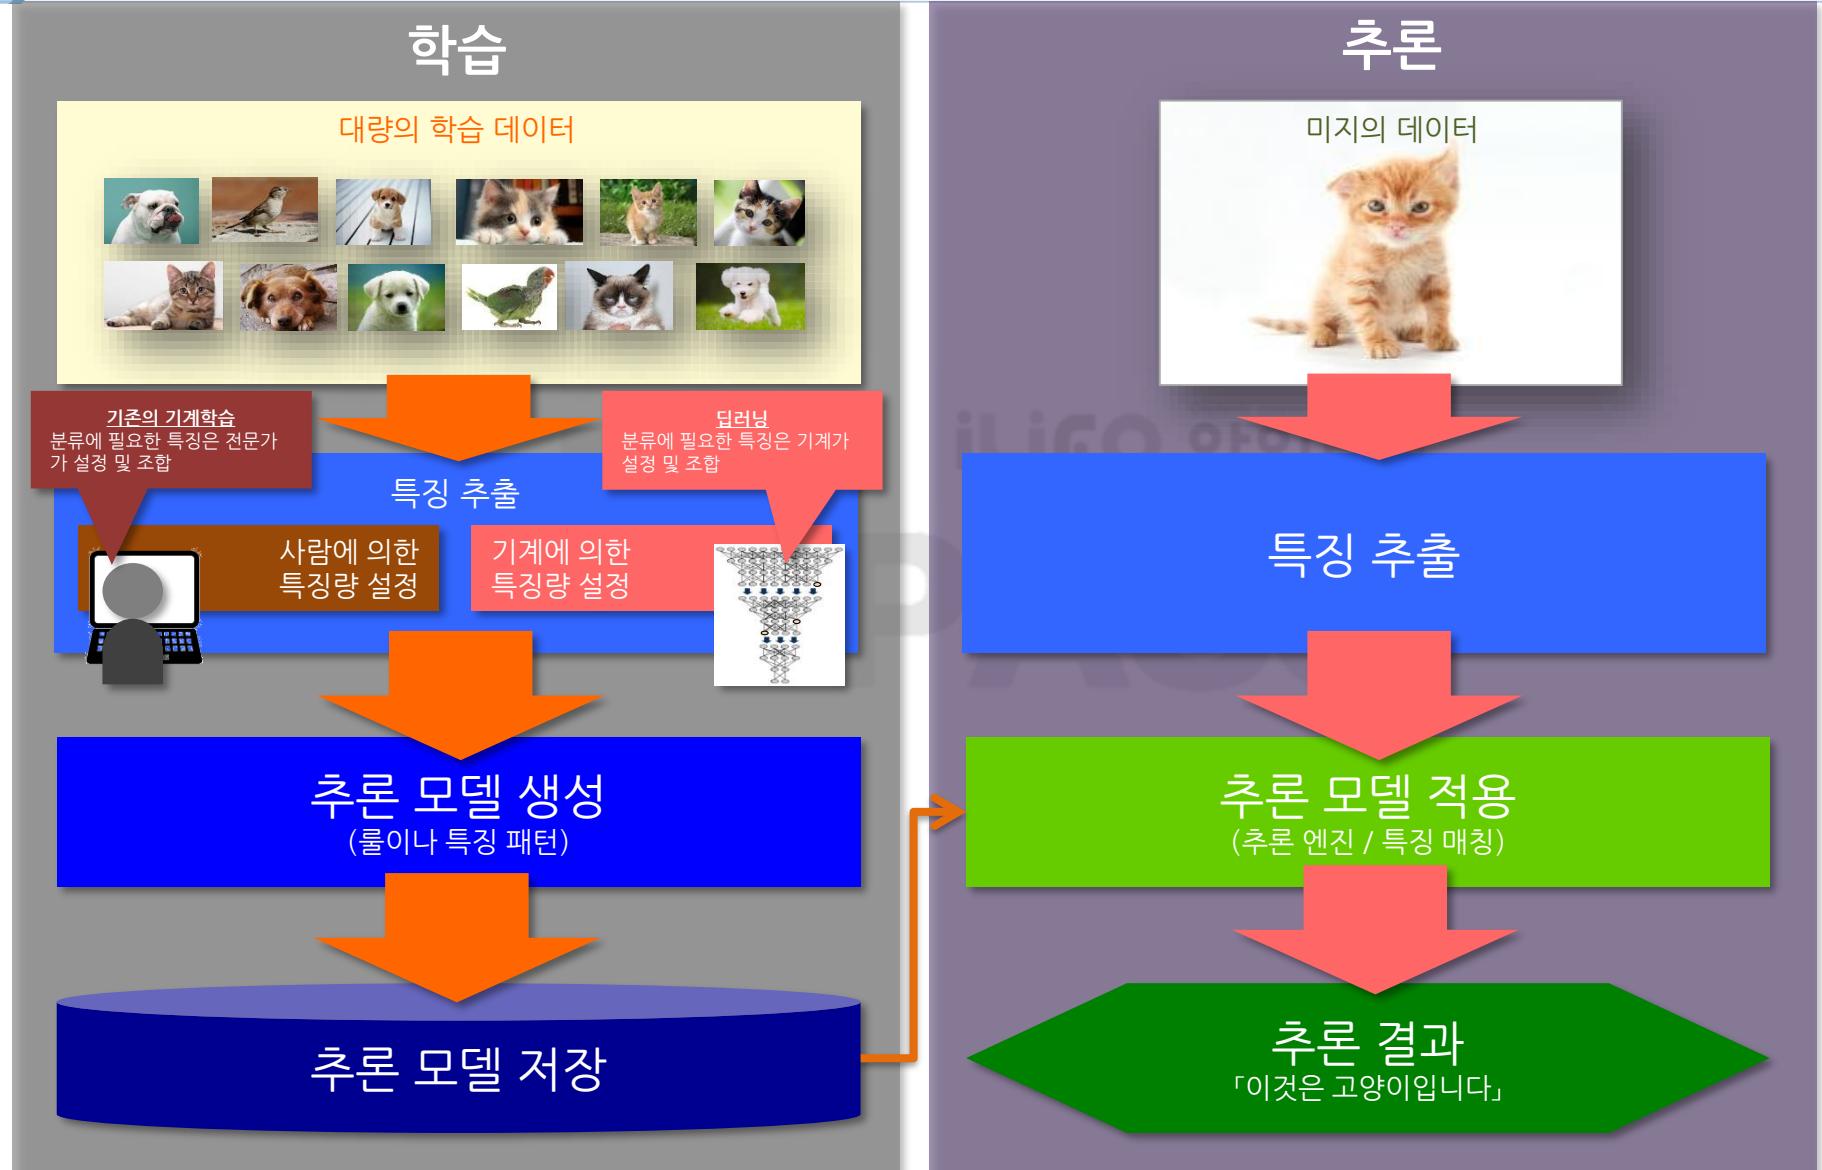




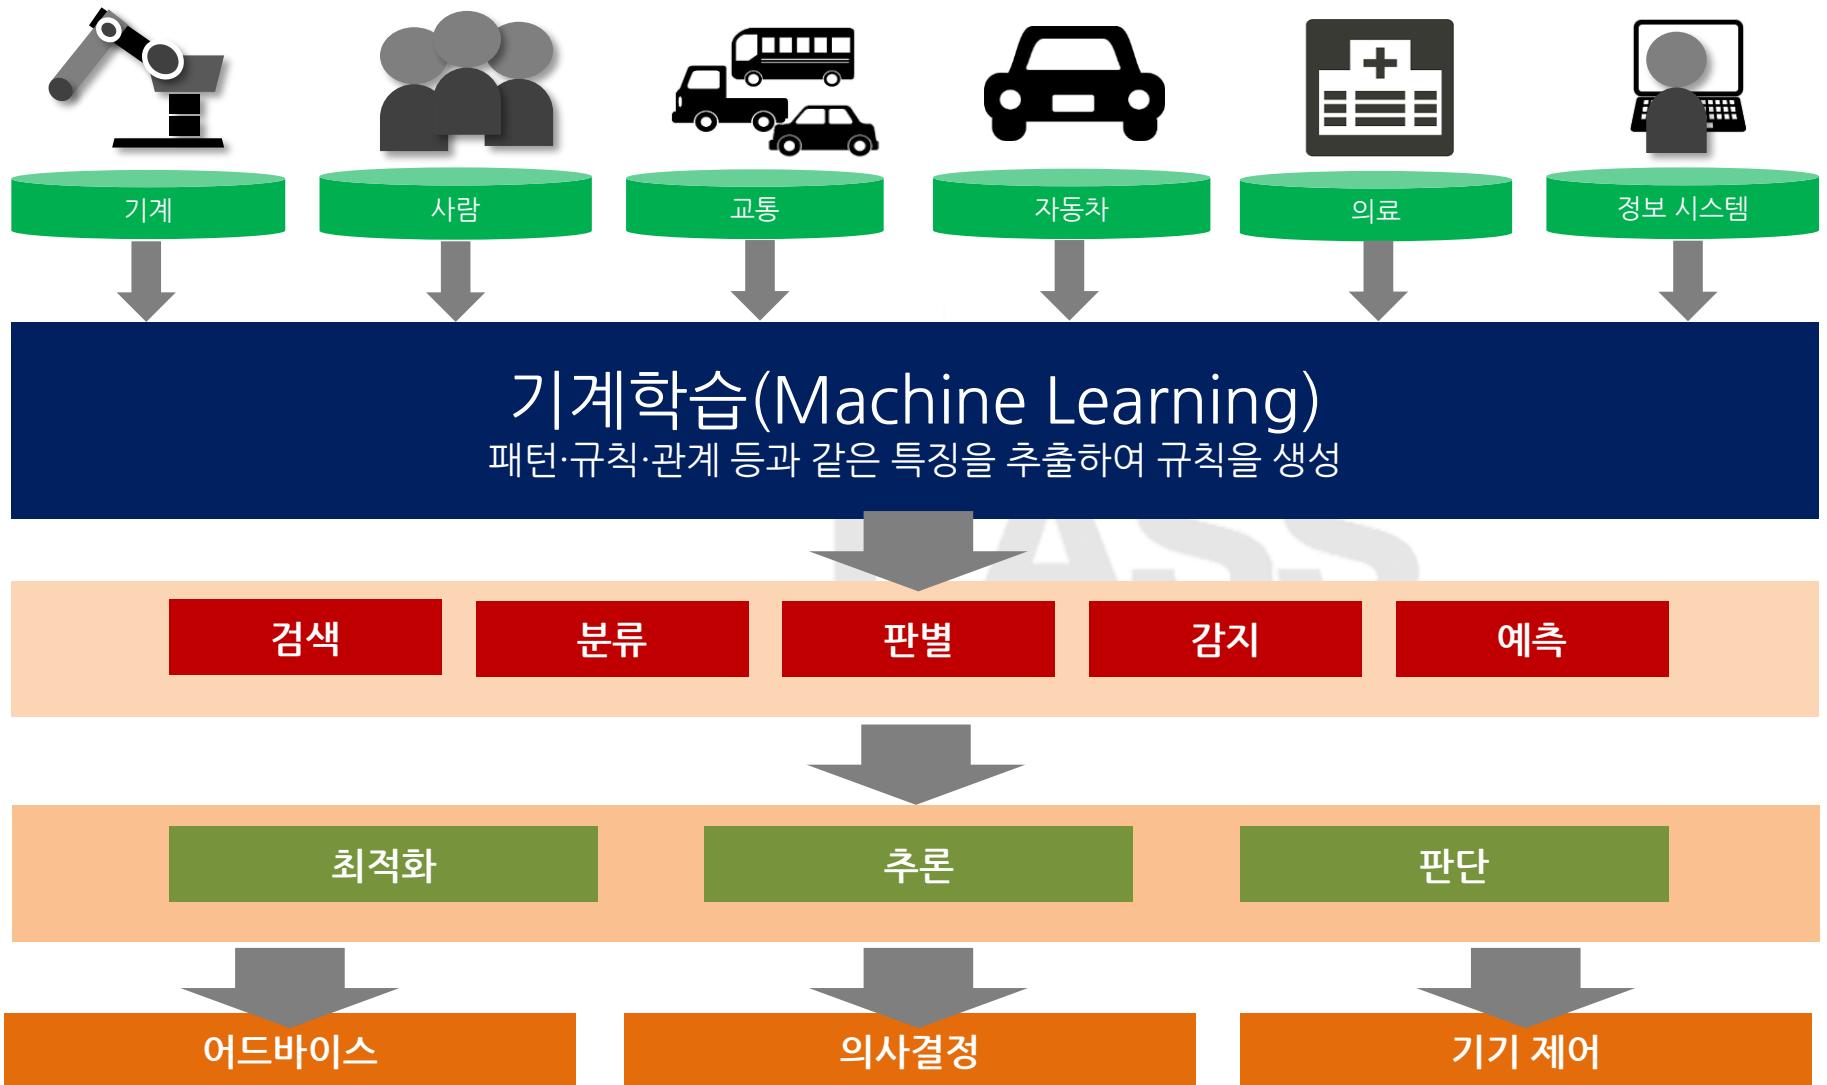
인공신경망 학습노하우

학습 노하우	상세 설명
많은 데이터 준비	<ul style="list-style-type: none"> 일반적으로 인공신경망과 같은 비선형 머신러닝 알고리즘은 학습데이터가 많을수록 모형성능이 향상 학습할 수 있는 데이터가 많지 않은 경우 아무리 딥러닝이라도 좋은 예측성을 기대할 수 없음
많은 파생변수 생성	<ul style="list-style-type: none"> 기존에 존재하는 원데이터(raw data)를 결합해서 새로운 파생변수를 생성하여 입력변수로 사용하면 인공신경망 예측성이 향상 될 수 있음 새로운 파생변수를 생성하는 작업은, 예측모형이 독립변수와 종속변수 간의 관계를 보다 빠르고 쉽게 파악할 수 있게 만들어 줌
데이터 정제	<ul style="list-style-type: none"> 데이터에 결측값(missing observations)이 많거나 타이핑 에러와 같은 이상값(outlier values)이 존재하는 경우에는 예측성이 저하될 수 있다. 따라서 분석 전 데이터탐색을 통해 결측값과 이상값 처리를 해서 데이터를 정제하는 작업이 필요하다.
분석대상 신중히 선택	<ul style="list-style-type: none"> 분류예측분석에서 예측하고자 하는 대상이 전체 대비 20%이하이면 불균형 데이터셋(imbalanced dataset)이라고 한다. 특히 종속변수의 타깃값이 전체 대비 5%이하인 매우 불균형 데이터셋(extremely imbalanced dataset)에서의 예측 모델링은 쉽지 않다. 따라서 예측성능향상의 관점에서 분석대상이 되는 모수의 범위를 신중히 선택해야 한다.
최적의 hidden layer와 neuron 결정	<ul style="list-style-type: none"> 인공신경망 알고리즘에서 가장 중요한 hyper-parameters는 히든층(hidden layer)과 뉴런(neuron)이다. 히든층과 뉴런의 수에 따라서 인공신경망의 모형의 복잡도가 결정되고, 모형의 복잡도가 큰 경우에는 모형이 훈련 데이터셋에 과대적합(overfitting)해서 모형왜곡(bias)이 발생할 수 있다. 따라서 적절한 히든층과 뉴런의 수를 결정하는 것이 필요하다. 통상적으로 인공신경망에서의 히든 층의 수는 최대 4층을 넘지 않으며, 히든 뉴런(hidden neuron)의 수는 입력 뉴런(input neuron)의 2배를 넘지 않도록 한다.
학습률(learning rate)를 조정해서 local minima을 수렴하는 것을 방지	<ul style="list-style-type: none"> 인공신경망은 경사하강법 학습을 통해 예측오차를 가장 최소화하는 최적의 가중치를 찾는다. 경사하강법 학습에서 학습률이 너무 큰 경우에는 global minima를 피해갈 수 있고, 반대로 학습률이 너무 작은 경우에는 local minima에 수렴하거나 global minima에 수렴하기 위해 많은 반복학습과 시간이 필요로 하다. 따라서 적절한 학습률을 설정하는 것이 중요하다.
모형 과적합을 방지하기 위해 다양한 기술을 사용	<ul style="list-style-type: none"> 인공신경망에서 계산되는 가중치의 개수가 일반적인 회귀모형보다 월등히 많다. 이러한 특징은 인공신경망이 회귀모형보다 한층 더 유연하게 종속변수와 독립변수들 간의 비선형관계를 모델링하는데 도움을 주지만 반면 복잡한 관계로 인해 쉽게 과적합을 발생시킨다. 인공신경망에서 발생할 수 있는 과적합을 피하기 위해 다양한 과적합 방지기술을 사용해야 한다. 대표적인 과적합 방지기술로는 dropout, regularization, feature extraction, feature selection이 있다. Dropout기술은 인공신경망 학습 시, 매번 학습과정에서 입력 또는 히든뉴런을 랜덤하게 일정 퍼센트를 선택함으로써 모형학습을 단순화 Regularization기술은 가중치를 산출하는 과정에서 가중치에 패널티를 부여해서 상대적으로 덜 중요한 변수에 대한 가중치를 0 또는 0값과 근사하게 조정하여 모형복잡도를 단순하게 함 Feature extraction기술은 입력변수가 많은 경우 유사한 변수의 속성을 묶어 제2의 파생변수를 만들어 기존변수를 대체함으로써(차원축소) 모형을 단순화 Feature selection기술은 모형학습 시 산출되는 변수중요도(variable importance)을 기준으로 상대적으로 중요한 변수를 선택하거나 덜 중요한 변수를 제거해서 모형을 단순화 이렇게 모형 시 발생하는 노이즈 패턴을 제거함으로써 모형의 보다 단순화되고 모형 복잡성에 의해서 발생하는 과적합을 방지할 수 효과얻음

기계학습의 구조

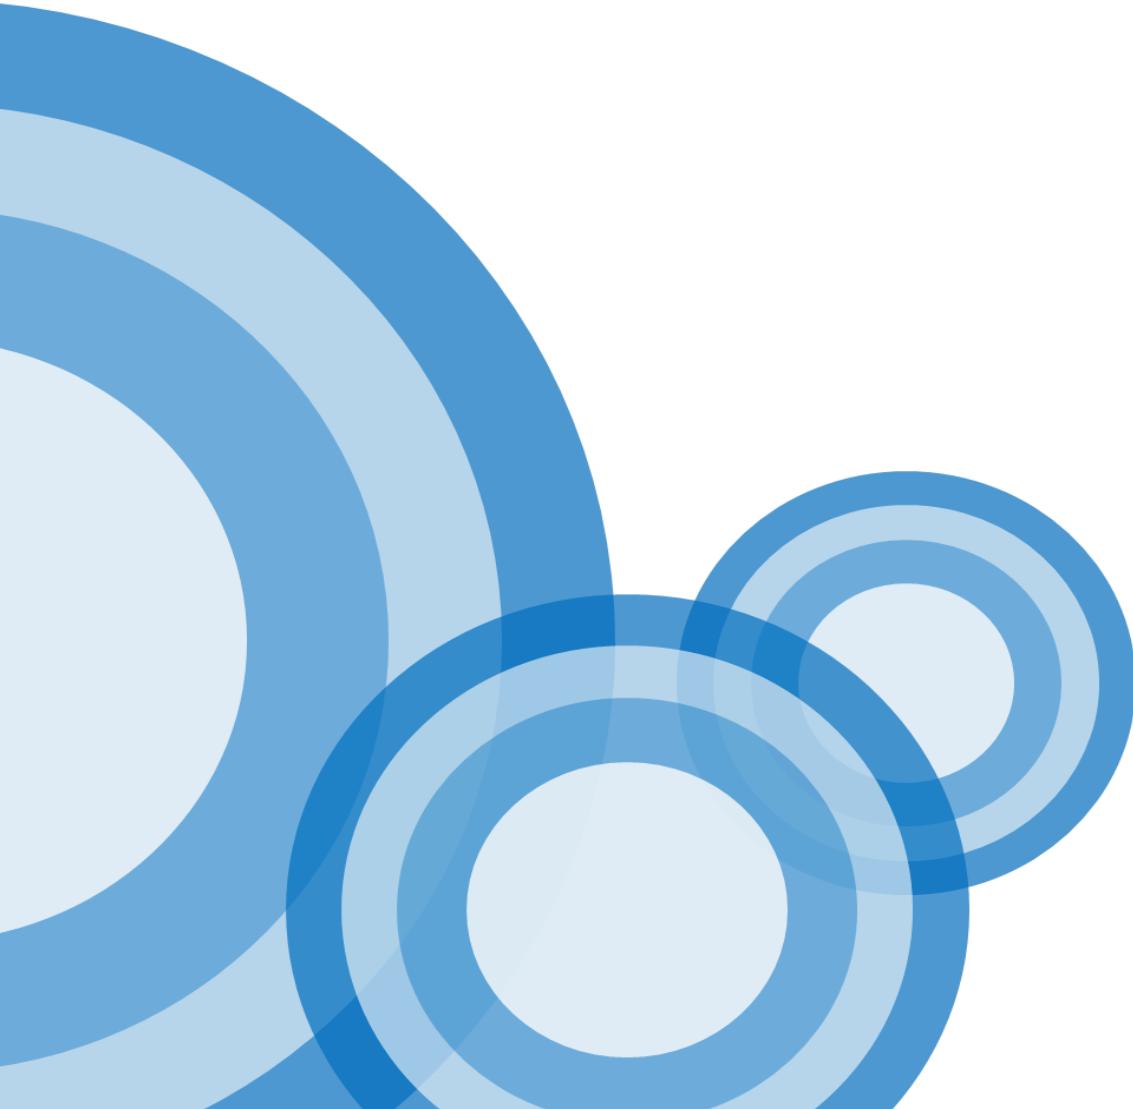


기계학습



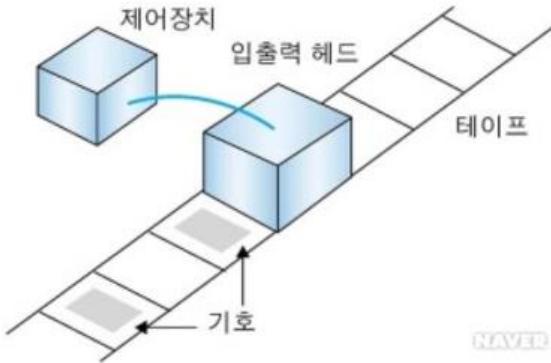


인공지능 주요 정책



튜링 머신(Turing Machine)

- 앨런 튜링이 1936년에 제시한 개념으로 계산하는 기계의 일반적인 개념을 설명하기 위한 가상의 기계이며 오토마타의 일종
- 저장수단이 Tape 인 오토마타(수학적 모델)



구성	분류기준	상세분류
제어장치 (상태 기록기)	계산하는 사람의 마음 상태에 해당되는 상태들을 갖고 있는데, 이 상태 중 어느 한 상태에 의해 튜링 기계의 동작을 결정	<ul style="list-style-type: none">- start state : 시작 상태- halt state : 작업 수행이 종료된 상태
입출력헤드	길이는 무한대인데, 각각의 칸에는 오로지 한 개의 기호를 갖고 있거나 아니면 비어 있다. 테이프에 기록된 기호의 수효는 유한	<ul style="list-style-type: none">- 현재 상태, 읽은 기호, 다음 상태, 쓸 기호, 움직일 방향
테이프	제어 장치의 상태에 따라 테이프의 오른쪽 또는 왼쪽으로 한 칸씩 움직이며, 테이프에 저장된 기호를 읽거나 기록하고 지움	<ul style="list-style-type: none">- 저장 장치

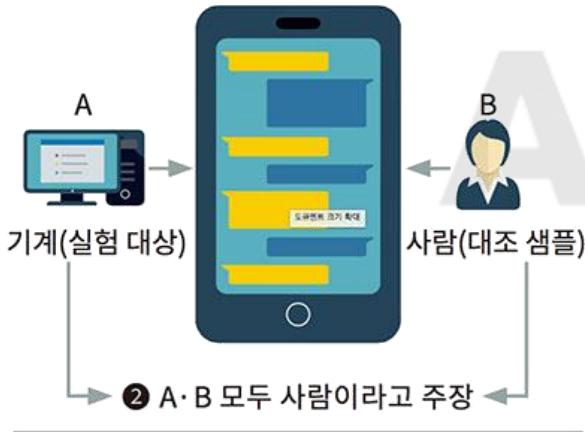
튜링 테스트(Turing test)

1. 기계사고 능력 판별 튜링 테스트의 개요

- 기계가 인간과 얼마나 비슷하게 대화할 수 있는지를 기준으로 '기계에 지능이 있는지를 판별'하고자 하는 테스트
- 앨런 튜링(Alan Turing)이 제안한 인공지능 판별법

튜링 테스트 개요

① 컴퓨터 화면을 통해 문자로만 대화



▪ 방식

단계	설명
1	차단된 2개의 방에 한쪽에는 텔레타이프(teletype)와 피실험자 A가 있고, 다른 한쪽의 방에는 텔레타이프와 피실험자 B 및 자연 언어 시스템으로 구성
2	피실험자 A는 텔레타이프를 통하여 다른 방의 피실험자 B 혹은 시스템 중 어느 쪽과도 대화가 가능
3	피실험자 A에게는 대화의 상대가 피실험자 B인지 시스템인지 모르도록 함
4	피실험자 A와 피실험자 B 사이에는 서로를 알리는 어떠한 방법도 없음
5	격리된 다수의 심사위원이 A,B중 어느 쪽이 사람인지에 대한 평가를 함

- 기계가 게임에서 이긴다면 그 기계는 인공지능을 가진다고 할 수 있음
- 심판은 5분 동안 각각 5회 대화 후 어느 쪽이 사람인지 판별
- 심판진의 1/3을 속이면 통과
- '14년 레딩대에서 개발한 Eugene Goostman 처음 통과

puzz3

CAPTCHA

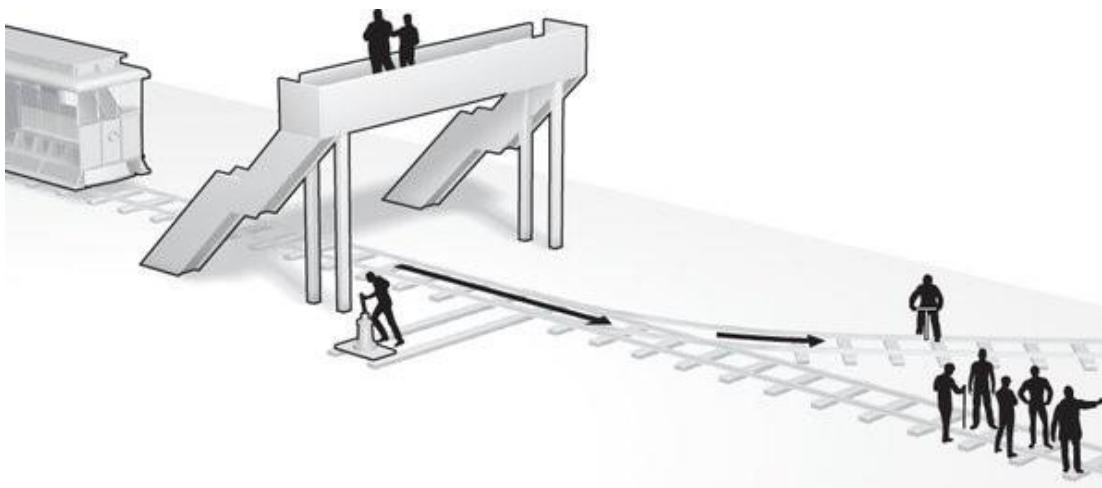
- 사용자가 컴퓨터인지 bot인지 구별하는 기술(튜링테스트)
- '13년 vicarious는 captcha 이미지 인식 성공

③ 어느 쪽이 사람인지 구분할 수 없을 경우, A·B 모두 인간 수준의 사고능력을 가진 것으로 판단

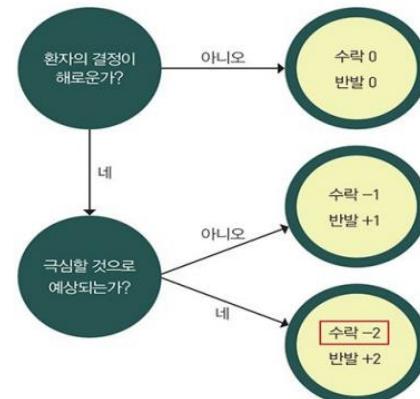
트롤리 딜레마

1. 자율주행자동차의 딜레마, 트롤리 딜레마

- 제어 불능의 트롤리(화차)가 달리는 상황에서 5명이 있는 선로와 1명 있는 선로 중 하나를 선택해야 하는 상황에서 어떤 행동을 할 것인가에 대한 윤리적 딜레마 (동일한 상황에서 **이성적 판단 VS 윤리적 판단 중 어느것이 옳은가**의 문제)



〈그림1〉 메드에덱스(MedEthEx)의 ‘해악금지원칙’ 논리구조



〈표1〉 인공지능과 로봇의 윤리적 프로그래밍 방법론

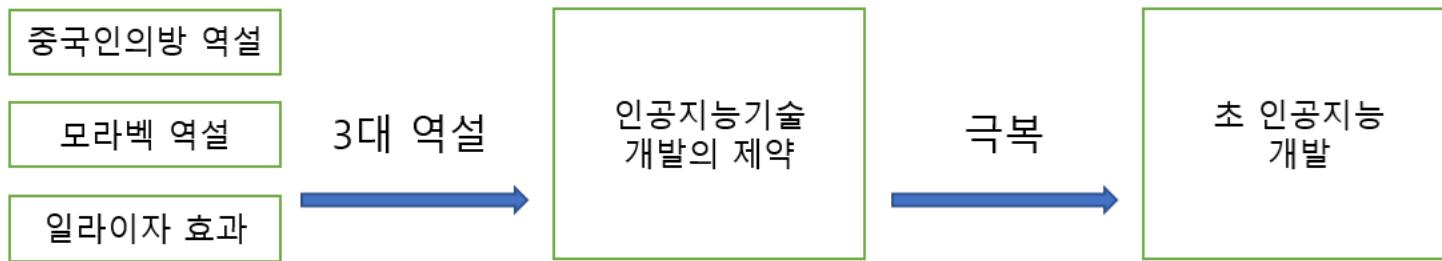
구분	설명
행동의 원리	- 행동함으로써 일어난 폐해(가령 누군가의 죽음)는 행동하지 않아 일어난 폐해보다 더 비도덕적이라고 판단받는다
의도의 원리	- 의도적으로 한 행동이 의도적이지 않은 행동보다 더 비도덕적이라고 판단받는다
접촉의 원리	- 직접적 신체 접촉이 수반되는 위해가 그렇지 않은 위해보다 더 비도덕적이라고 판단받는다.

3. 인공지능 로봇의 윤리적 프로그래밍 방법론

- 논리기반 접근법: ‘생명은 소중하다’는 대원칙을 프로그래밍, 최대다수의 최대행복’이라는 공리주의 원칙 결정
- 사례기반 접근법: 기존 사례에서 윤리적 추론 도출, 의료 전문가의 결정 참고, (메드에덱스)
- 다중행위 접근법: 윤리적 판단 가능한 여러 행위자의 상호 작용을 시뮬레이션(다중행위플랫폼 활용)(사례 : 소포렘)

인공지능 3대 역설

1. 인공지능개발의 극복대상 인공지능 3대 역설 개요



2. 인공지능 3대 역설

3대역설	개념	시사점
중국어 방의 역설	<ul style="list-style-type: none">밀폐된 방에서 중국어를 모르는 사람이 주어진 한자 문제를 메뉴얼대로 해석하여 제출함을 가정알고리즘으로 주어진 문제를 풀었지만 컴퓨터가 그 문제를 이해했는지는 증명이 불가능	<ul style="list-style-type: none">튜링 테스트의 한계
모라벡의 역설	<ul style="list-style-type: none">인간에게 어려운 것은 컴퓨터에게 쉽고 인간에게 쉬운 것은 컴퓨터에게 어려움컴퓨터는 사람의 직관보다 훨씬 쉽게 바둑의 수를 계산하지만 바둑돌을 물리적으로 정확하게 이동시킬 수는 없음	<ul style="list-style-type: none">융합 기술의 개발 필요
일라이자효과	<ul style="list-style-type: none">기초적인 정신과 의사 모사 프로그램이지만 사람이 진짜 의사로 착각 위안을 받는 효과컴퓨터에게 인격을 부여하는 심리현상	<ul style="list-style-type: none">사회적 합의

- 인간처럼 생각하는 강 인공지능 및 초 인공지능은 3 대 역설을 합리적으로 증명했을 때 기술적으로 인정이 됨

3. 3대 역설 해결 방안

극복대상	극복방안	설명
튜링 테스트 한계	<ul style="list-style-type: none">AI Kill Switch 등	<ul style="list-style-type: none">컴퓨터의 동작이 인간과 유사해 피해를 입힐 경우 강제로 차단
융합기술 개발	<ul style="list-style-type: none">물리환경 극복	<ul style="list-style-type: none">연산기능을 극복 센서, 액추에이터등의 물리적 기술 개발 필요
사회적 합의	<ul style="list-style-type: none">인공지능윤리	<ul style="list-style-type: none">아실로마AI 원칙등 컴퓨터를 통한 인간 존엄성 악영향 차단

- 기술의 편익은 기술을 사용할 때 가 아닌 사용후 사람의 만족으로 나타나야 함
- 따라서 3대역설을 기술적, 합의적으로 해결하여 인공지능 극점에 대비해야 함



아실로마 AI 원칙 23

1. 아실로마 인공지능 원칙(ASILOMA AI Principles)의 개념

- 인공지능 연구의 목적은 인간에게 유용하고 혜택을 주어야 하며, 인간의 존엄성/권리/자유/이상 등과 양립할 수 있어야 하며, 장기적으로 위험에 대응하고 공동의 이익을 위해 활용되어야 한다는 원칙
- 2017년 1월에 미국 캘리포니아 아실로마에서 열린 AI컨퍼런스에서 발표된 인공지능 개발 원칙

연구 이슈 (5) + 윤리 가치 (13) + 장기 이슈 (5)

구분	원칙	설명
연구이슈 (5)	연구 목표	-인공지능 연구의 목표는 방향성이 없는 지능을 개발하는 것이 아니라 인간에게 유용하고 이로운 혜택을 주는 지능을 개발해야 한다.
	연구비 지원	-인공지능에 대한 투자에는 컴퓨터 과학, 경제, 법, 윤리 및 사회 연구 등의 어려운 질문을 포함해 유익한 이용을 보장하기 위한 연구비 지원이 수반되어야 한다.
	과학정책 연결	-인공지능 연구자와 정책 입안자 간에 건설적이고 건전한 교류가 있어야 한다.
	연구 문화	-인공지능의 연구자와 개발자간에 협력, 신뢰, 투명성의 문화가 조성되어야 한다
	경쟁 피하기	-인공지능 시스템을 개발하는 팀은 안전기준에 대한 부실한 개발을 피하기 위해 적극적으로 협력해야 한다.

아실로마 AI 원칙 23

구분	원칙	설명
윤리 및 가치 (13)	안전	- 인공지능 시스템은 작동 수명 전반에 걸쳐 안전하고 또 안전해야 하며, 적용가능하고 실현 가능할 경우 검증할 수 있어야 한다.
	장애 투명성	-인공지능 시스템이 손상을 일으킬 경우 그 이유를 확인할 수 있어야 한다.
	사법의 투명성	-사법제도 결정에 있어 자율시스템이 개입하면 권위 있는 인권기구가 감사 할 경우 만족스러운 설명을 제공해야 한다.
	책임	-고급 인공지능 시스템의 설계자와 구축은 사용, 오용 및 행동의 도덕적 영향을 미치는 이해 관계자이며, 그에 따른 책임과 기회가 있다.
	가치관 정렬	- 고도로 자율적인 인공지능 시스템은 목표와 행동이 작동하는 동안 인간의 가치와 일치하도록 설계해야 한다.
	인간의 가치	- 인공지능 시스템은 인간의 존엄성, 권리, 자유 및 문화적 다양성의 이상에 적합하도록 설계되어 운용되어야 한다.
	개인정보 보호	- 인공지능 시스템이 데이터를 분석하고 활용할 수 있는 권한을 부여 받으면, 사람들은 그 데이터를 액세스, 관리 및 통제 할 수 있는 권리를 가져야 한다.
	자유와 개인정보	- 인공지능을 개인정보에 적용하면 사람들의 실제 또는 인지된 자유가 부당하게 축소되어서는 안된다.
	공동이익	- 인공지능 기술은 최대한 많은 사람들에게 혜택을 주고 권한을 부여해야 한다.
	공동번영	- 인류의 모든 혜택을 위해 AI에 의해 만들어진 경제적 번영은 널리 공유되어야 한다.
	인간통제	- 인간은 인간이 선택한 목표를 달성하기 위해 의사결정을 인공지능 시스템에 위임하는 방법 및 여부를 선택해야 한다.
	비파괴	- 고도화된 인공지능 시스템의 통제에 의해 주어진 능력은 건강한 사회를 지향하며, 이를 지키려는 사회나 시민들의 프로세스를 뒤집는 것이 아니라 존중하고 개선해야 한다.
	인공지능 무기	- 치명적인 인공지능 무기의 군비 경쟁은 피해야 한다.
장기 이슈 (5)	능력주의	- 합의가 없으므로 향후 인공지능 능력의 제한에 관한 강력한 전제를 피해야 한다.
	중요성	- 고급 AI는 지구상의 생명의 역사에 심각한 변화를 가져올 수 있으며, 그에 상응 한 관심과 지원을 계획하고 관리해야 한다.
	위험	- 인공지능 시스템이 초래하는 위험, 특히 치명적인 또는 실제로 존재하는 위험은 예상되는 영향에 맞는 계획 및 완화 노력을 해야 한다.
	자기복제 자기개선	- 인공지능 시스템이 고도의 품질로 자기복제나 자기개선 하도록 설계된 시스템은 엄격한 안전 및 통제 조치를 받아야 한다.
	공동의 선	- 수퍼 인텔리전스는 널리 공유되는 윤리적 이상을 위해, 그리고 몇몇 국가나 조직이 아닌 모든 인류의 이익을 위해 개발되어야 한다.

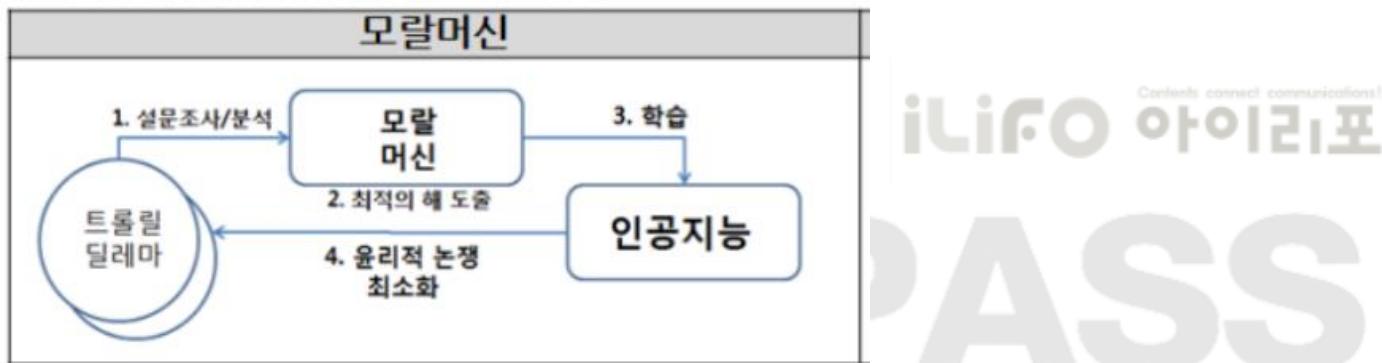
모랄머신

1. 모랄머신(Moral Machine) 개요

- 윤리적 딜레마에 직면한 **인공 지능의 결정에 대한 사람들의 의견을 수집하고 일어날 수 있는 문제점들의 시나리오들을 만들고 토론 할 수 있는 플랫폼**

2. 모랄머신 학습 이용 절차

- 다양한 트롤리딜레마를 조사하여 인공지능 시스템을 학습하여 윤리적 논쟁을 최소화



구분	설명
트롤리딜레마	<ul style="list-style-type: none">동일한 상황에서 이성적 판단과 윤리적 판단 선택의 문제인공지능 시스템 증가로 인해 윤리적 판단에 대한 검토요구 증가
모랄머신	<ul style="list-style-type: none">트롤리딜레마에 대한 설문조사 및 분석을 실시하고 공유하여 사회적인 인식에 따른 최적의 해를 도출인공지능 시스템의 의사결정 학습 자료로 활용
인공지능	<ul style="list-style-type: none">인공지능 시스템(예:자율주행자동차)의 의사결정에 윤리적 논쟁을 최소화 하여, 지속적으로 개선진행



킬 스위치

1. 인공지능의 폭주 방지 대책, 킬 스위치의 개요

- 로봇공학 기술이 인간의 통제를 벗어날 경우를 이를 제어하기 위해 로봇의 기능을 멈추게 하는 장치
- 본래의 의미는 분실한 정보기기 내의 정보 원격으로 삭제하거나 그 기기를 사용할 수 없도록 하는 기술

2. 킬 스위치 체인의 필요 이유

오류 발생시의 최소한의 안정장치

이유	내용
소프트웨어 오류	인공지능 자체의 소프트웨어 결함 발생 시
사람을 적으로 인식	사람과 같은 지능을 가진 인공지능이 사람을 적으로 인식하여 사람을 공격하게 되는 경우
악의적 해킹	해커가 자신의 욕심으로 인공 지능 해킹하여 오류 발생시키거나 인공지능 개발자와 해커가 인공지능을 매개체로 전쟁을 벌일 경우

3. 킬 스위치의 동작 절차

동작절차	내용
결합 발생	SW오류나 해킹으로 인한 인공지능의 결합 발생
인공지능 통제 불가	인공지능이 인간의 통제를 벗어난 상태 지속
킬 스위치 작동	인공지능을 강제로 종료하기 위한 킬 스위치 작동
인공지능 복구	결합의 원인 분석 및 오류 해결
인공지능 재 실행	인공지능의 안전성 여부 검토 후 인공지능 재 실행

4. 킬 스위치의 시사점

- 강인공지능의 도래 시 인공지능을 인간이 더 이상 통제를 하지 못할 수 있다는 사상을 기반으로 킬 스위치가 연구 진행
- 인공지능이 인간에게 미칠 최악의 시나리오에 대비하여 최소한의 안전장치인 킬 스위치의 연구개발이 인공지능 발전에 꼭 필요함

지능형 로봇 개발 및 보급 촉진법

1. 입법취지

- 지능형로봇법은 **지능형 로봇을 산업적으로 육성**하기 위한 정책을 입법적으로 지원하는 것을 목적

2. 지능형로봇법의 의의 및 주요 내용

구분	설명
의의	<ul style="list-style-type: none">미래 국가핵심 전략산업으로 육성하기 위한 제도적 기반을 구축사회적 약자를 위한 로봇의 보급에 관한 규정 등 사회문제 해결을 위한 정책적 규범도 담고 있다는 점현재 지능형로봇법은 HW 적인 측면에 집중되어 있다는 한계로 앞으로 보완기대
주요내용	<ul style="list-style-type: none">정부는 장애인·노령자·저소득자 등 사회적 약자들이 지능형 로봇을 자유롭게 이용할 수 있는 기회를 누리고 혜택을 향유할 수 있도록 하기 위해 지능형 로봇의 사용 편의성 향상 등을 위한 개발 및 보급 촉진에 필요한 대책을 마련하여야 한다 (제 17 조)정부는 지능형 로봇 개발자·제조자 및 사용자가 지켜야 할 윤리 등 대통령령으로 정하는 사항을 포함하는 지능형 로봇윤리현장(이하 '현장'이라 한다)을 제정하여 공표할 수 있다.

3. 지능형로봇법의 한계

한계	설명
HW에 한정된 로봇정책	<ul style="list-style-type: none">인공지능 기술은 소프트웨어적 성격이 강한데, 지능형 로봇을 '기계장치'로 정의하면서 기술 변화를 반영하지 못하고 있다
로봇윤리현장의 미제정	<ul style="list-style-type: none">업부는 2007년 전체 7개 조문으로 이루어진 로봇 윤리 현장 초안을 마련한 바 있다. 결론적으로 로봇윤리 현장 초안은 공식적으로 공포 되지 않았다
대기업참여제한	<ul style="list-style-type: none">상호출자제한 기업집단에 속하는 기업은 지능형 로봇전문기업 지정 대상에서 제외되어 품질 확보 및 보급·확산을 촉진하기 위한 지원이 불가
한시법에 따른 정책의 단절	<ul style="list-style-type: none">동법은 최초 제정되었을 당시에는 2018년 6월 30일까지만 효력을 갖는 것으로 부칙에 규정

표준화 비전 및 기대효과

비전
및
목표

인공지능국제표준선점으로 세계시장 주도권 확보

2018~2019

- 인공지능 표준화 전략 수립
- 인공지능 표준화 후보 원천기술 선제적 확보

2020~2021

- 타 산업 연계 융복합 인공지능 서비스 활성화를 위한 표준개발, 국제표준특허 선점

2022~2023

- 차세대 인공지능 국제경쟁력 강화를 위한 표준개발, 국제표준특허 선점

기대
효과

국제표준 경쟁력 강화 측면

- 인공지능 분야 핵심 기술력 확보를 통한 국제표준 선점
- 국제표준화 기구/단체 내 표준화 리더십 강화

중소기업 경쟁력 강화 측면

- 글로벌 기업과 협력 강화 및 관련 제품/서비스 수출 확대
- 표준기술 보급으로 인공지능산업 활성화
- 국제표준 선점 및 경쟁력 강화

국민행복, 안전보장 측면

- 인공지능 기반 다양한 지능형 서비스로 국민행복 증진
- 보편적 접근성이 보장된 안전한 지능형 서비스 제공

표준역량
(4P)
강화

Product

- 인공지능 표준개발
- 서비스 개발 선도
- 글로벌 경쟁력 강화

People

- First Mover형 표준 전문가 양성
- 융합적 연구 인력 저변 확대

Partnership

- 글로벌 업체와 전략적 제휴
- 국제 표준화 참여 전문가간 협력체계 구축

Promotion

- 인공지능 기술/서비스 선도
- 타 산업 연계 생태계 구축 선점

중점
표준화 항목
및
대응기구

기반 기술

머신러닝 데이터 구축 표준 : ITU-T SG13 Q17

신경망 표현포맷(NNR) 표준 : JTC1 SC29 WG11, Khronos Group

음성/언어이해

클라우드 기반 머신러닝 서비스 표준 : ITU-T SG13, JTC1 SC42

실시간 동시통역 표준 : JTC1 SC35, ITU-T SG16

대화형 음성 인터페이스 표준 : JTC1 SC35, ITU-T SG16

제스처 인터페이스 표준 : JTC1 SC35

웨어러블 기반 인공지능 기술의 제스처 표현 표준 : JTC1 SC29 WG11, ITU-T SG13

딥러닝 기반 영상정보/유전체 모델 표현 및 부호화 표준 : JTC1 SC29 WG11

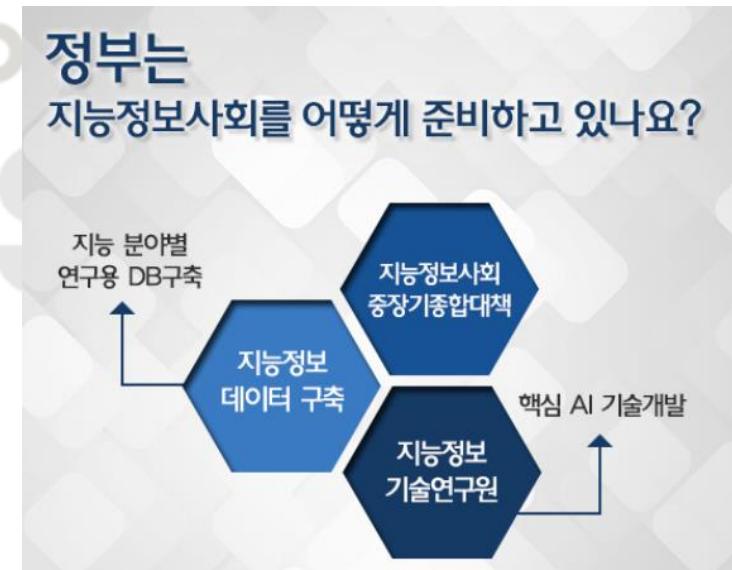
사용자 맞춤형 추천정보 표준 : JTC1 SC29 WG11

PASS

지능정보사회

1. 지능정보사회의 개요

- 고도화된 정보통신기술 인프라(IBM)를 통해 생성·수집·축적된 데이터와 인공지능(AI)이 결합한 지능정보기술이 경제·사회·삶 모든 분야에 보편적으로 활용됨으로써 새로운 가치가 창출되고 발전하는 사회)



지능정보기술

1. 지능정보기술

- 인공지능 기술과 데이터 활용기술이 융합하여 기계에 고차원적인 정보처리 능력(인지, 학습, 추론)을 구현하는 기술
- 인공지능 SW로 대표하는 '지능'에 IoT, 클라우드, 빅데이터, 모바일 등으로 대표하는 '정보'가 결합하는 형태
- 사회 각 분야의 다양한 정보를 축적/분석/활용하는 과정을 지능화 할 수 있는 기능
- 인공지능기술과 데이터 네트워크(ICBM)을 융합하여 기계에 인간의 고차원적 정보처리(인지, 학습, 추론)을 구현



[특징]

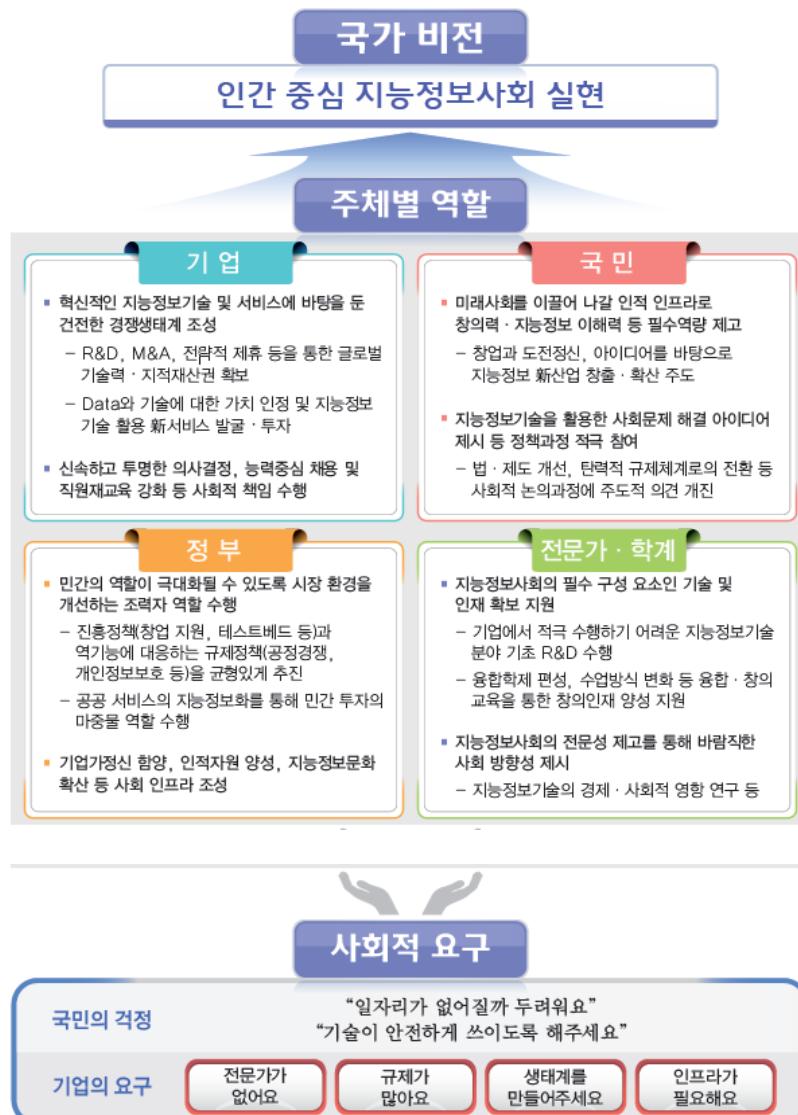
- 만물의 데이터화 과정에는 보관 활용이 곤란했던 데이터(생체 행태정보, 비정형 정보 등)도 기계 학습 과정을 거쳐 의미 추출 가능
- (무인 의사결정) 인간의 고차원적 판단기능을 수행함으로써 기계가 독립된 주체로 활동하여 자동화 및 무인화 확산
- (실시간 반응) 정보수집, 데이터 분석, 판단 추론 등 일련의 과정들이 고도화된 ICT를 통해 즉각 처리되어 실시간 응답 반응

ISS

[표 1] 지능정보기술과 분류

구분	상세 기술 분야
인공지능(AI) SW	추론 및 기계학습, 지식표현, 언어-청각-시각-복합지능 등
컴퓨팅 HW	지능형 반도체, 뉴로모피직, 고성능컴퓨팅 등
데이터 활용	IoT, 클라우드컴퓨팅, 빅데이터, 모바일 등
기초과학	뇌과학, 산업수학 등

지능정보사회 중장기 종합대책



추진전략

▶ 기업·국민(주도)-정부·학계(지원) 파트너십을 통한 지능정보사회 조성

- 지능정보기술의 발전 등 제4차 산업혁명 진전에 대해 기업·국민이 스스로 경쟁력을 강화하고 주도(Market-Leading)
- 정부·학계는 원천기술 개발, 우수인력 양성 등 기반을 조성하고 소외계층 지원 등 시장실패를 보전하되 강력한 신호(Signal) 전달

▶ 기술·산업·사회를 포괄한 균형 있는 정책 추진으로 인간 중심의 미래사회 구현

- 지능정보기술과 산업·사회가 유기적으로 연결되어 사회 전반에 혁신적 변화를 초래하므로 이를 종합적으로 고려한 정책목표 제시
- 정책목표 달성을 위해 국가경쟁력 확보를 위한 기술·산업 정책과 국민적 이해에 기반한 사회 정책(고용, 교육, 복지 등)을 균형있게 추진

▶ 전략적 지원을 통한 지능정보기술 및 산업 경쟁력 조속 확보

- 공공서비스(국방, 치안, 행정 등)·의료·제조업 등 주요 산업·서비스의 선도적 지능정보화로 네트워크 효과를 극대화, 산업 전반에 확산
- 데이터·기술·핵심인력 확보에 집중 지원하여 지능정보 관련 산업 생태계를 선점하고 지능정보 기술 전문성 제고

▶ 사회적 합의를 통한 정책 개편 및 역기능 대응체계 구축

- 산업구조 재편에 따른 사회 변화에 미리 대응하기 위해 사회적 합의에 기반한 교육·고용·복지 분야 관련 정책을 융통성 있게 추진
- 사이버 위협, 양극화, 인간 소외 등 역기능 연구를 통해 발생 가능한 위험성을 알리고 대응방향을 논의할 수 있는 구조 정립

지능정보사회 중장기 종합대책

전략과제

▶ 인간 중심의 지능정보사회를 구현하기 위한 기술·산업·사회 분야별 정책방향을 설정하고 이를 달성하기 위한 전략과제 추진



지능정보사회 구현을 비전 및 목표(제6차 국가정보화 기본계획)

비전

지능화로 함께 잘 사는 대한민국

목표

국민의 삶을 책임지는
지능 국가

디지털 혁신을 통한
경제재도약

함께 하는
디지털신뢰 사회

안전한
지능망인프라

4대 전략 및 13대 과제

지능화로 국가 디지털 전환

- 공공부문
지능화 기반 구축
- 국민 체험 기반의
행복서비스 제공
- 지속 가능한 국가사회
안전체계 확립
- 누구나 살고 싶은
지역생활 기반 마련

디지털 혁신으로 성장동력 발굴

- 데이터 경제 활성화
- 지능화 기반 산업 혁신
- 중소·벤처 기업의
혁신역량 강화
- 혁신성장을 위한
지능화 기술 경쟁력
제고

사람 중심의 지능정보사회 조성

- 지능정보社会의
디지털 시민 양성
- 함께 누리는
디지털 포용실현
- 지능정보사회문화
창달

신뢰 중심의 지능화 기반 구축

- 지능정보기술 활용도 제고를 위한 인프라망 구축
- 사이버 안전 국가 기반 확충

< 정보화사업 지능화 전환 프로세스 >

신규사업

기존사업

정보화사업
점검 분석

- 사업타당성
- 유사·중복
- 비용효과성
- 지능화 수준

우선추진사업
발굴·지원

- 재난·안전, 생활·건강,
복지 등 국민 삶의 질
향상 분야에 집중

데이터통합 기반 구축

클라우드 이용 확대

인공지능 적용 확대

Contents connect communications!
아이리포

PASS

인공지능 관련 법 제도

주요 법제	주요 내용
정보통신 진흥 및 융합 활성화 등에 관한 특별법	- 신규 정보통신 융합기술 및 서비스 진흥 등
지능형 로봇 개발 및 보급 촉진법	- 한국로봇 산업진흥원 설립, 품질 인증제도 및 로봇랜드 조성 등
뇌연구 촉진법	- 뇌연구 실무추진위원회 설치 등
클라우드 컴퓨팅 발전 및 이용자 보호에 관한 법률	- 클라우드 컴퓨팅 서비스의 신뢰성 향상 및 이용자 보호 등
건축법	- 빠른 정보서비스와 아울러 에너지 절감이 극대화 되고 그로 인해 업무의 생산성을 극대화 할 수 있는 건물에 대한 인증 (지능형 건축물 인증제도, 제 65조의 2)
유비쿼터스 도시의 건설 등에 관한 법률	- 공공시설에 건설, 정보통신 융합기술을 적용하여 지능화된 시설을 건립 등
지능형 전력망의 구축 및 이용 촉진에 관한 법률	- 정보통신기술 적용으로 공급자와 사용자 간의 정보교환의 효율성이 극대화된 전력망 (지능형전력망, 제2조 2호)
국가통합교통체계 효율화 법	- 교통체계의 운영 및 관리를 과학화, 자동화하고 교통의 효율성과 안전성을 향상시키는 교통체계 (지능형 교통체계, 제2조 16호)

국가정보화기본법(4차산업혁명 관련 개선안)

1. 배경 : 미래부는 국가사회 전반의 지능정보화를 촉진
2. 내용 : '국가정보화 기본법'을 '지능정보사회 기본법'(가칭)으로 개정하고, 기본법에 없던 AI의 안전성과 법적 책임, 윤리에 관한 제도 개선을 연말까지 완료
3. 상세 : 지능정보기술 안전성 심사 방안을 만들고, 자율주행차 간 충돌 등 인공지능 결함에 따른 손해배상 책임소재를 가리는 방법을 연구



- AI 창작물 관련
 - 저작권법, 특허법, 상표법, 부정경쟁방지법
- AI 처리정보에 따른
 - 개인정보보호법, 정통망법 등

인공지능 관련 법적 쟁점 및 대응방안

법적 쟁점	설명	대응방안
인공지능 권리의무 주체 여부	➤ 인공지능은 자의지를 가지지 못함으로 법적 주체가 아님	➤ 향후 미래 인간수준의 사고를 인정 받을 시 권리 의무 주체로 고려
오작동에 대한 책임 귀속	➤ 인공지능 오작동으로 인한 피해는 책임 소지 불명확	➤ 제조물의 책임에 대한 SW 범위 포함 ➤ 보험제도 등 활용
인공지능 창작물에 대한 지적재산권 문제	➤ 인공지능의 창작물은 법적 보호 불가 ➤ 인공지능이 재산권 침해시 책임에 대한 문제	➤ 창작물 보호보다 특징적인 보호(약한저작권 보호) ➤ 인간창작물과 구분하는 등록제 필요
빅데이터와 개인정보 문제	➤ 인공지능은 빅데이터 기반으로 수집된 데이터를 활용, 개인정보보호에 대한 문제 발생	➤ 비식별화 처리에 대한 알고리즘 반영 ➤ 인공지능에 특성 고려한 완화 정책 필요
로봇 윤리 규범 문제	➤ 특정인에 대한 악용(테러, 해킹등)에 따른 윤리적 법적 검토	➤ 아실로마 원칙에 대한 준수



인공지능 보안



인공지능보안

1. 인공지능 주요 보안 이슈

- 테스트 데이터에 대해 높은 성능을 보였지만, 악의적으로 만들어진 데이터에 대해서는 오동작을 하는 경우가 보고하고 있음.

2. Adversarial AI

- 악의적인 공격자에 의해 학습 알고리즘의 특정 취약점을 악용하는 데이터를 통하여 전체 시스템의 보안을 손상

분류	구분	설명	개념도
학습된 인공지능을 속일 수 있는 공격	Poisoning Attack	<ul style="list-style-type: none"> 잘못된 데이터를 제공하여 이를 학습한 classifier 가 잘못된 결과를 내도록 하는 것 악의적인 데이터를 기존의 학습데이터에 추가하여 모델에 학습시킴으로써 잘못된 결과를 내도록 하는 공격 방법 최소한의 데이터로 최대한의 오동작을 일으키는 것이 목표 공격자가 학습 알고리즘을 알고 있고 원래의 데이터에 접근 가능하여 시뮬레이션이 가능하다는 점을 가정 함. 학습단계에서 공격자가 학습데이터를 조작할 수 있는 환경이나, 지속적으로 학습하는 active learning 시스템을 가정하고 있으므로 공격의 적용 범위가 떨어짐 	<pre> graph LR X[Input data (X)] --> LM[Learning Machine] X --> WC[Wrong Class] X_prime[X', y'] --> LM LM --> WC </pre>
	Evasion Attack	<ul style="list-style-type: none"> 입력 데이터에 대하여 최소한의 변조를 통해 다른 Class로 인식되게 하는 것 학습데이터가 아닌 입력 데이터를 약간 변조하여 다른 class로 인식되도록 하는 공격 학습된 이후 적용단계의 입력 데이터에 대한 조작을 통해 인공 지능을 속이는 형태의 공격이므로 적용범위가 넓음 	<pre> graph LR UU[Un-mangled "open evil.com"] --> AM[Audio Mangler] AM --> MU[Machine's Understanding] AM --> HU[Human's (i.e., attacker's) Understanding] MU <--> HU F[Feedback] --> AM </pre>
인공지능 모델 자체 탈취	Model Extraction Attack	<ul style="list-style-type: none"> 공개된 모델에 X를 입력하여 y를 획득한 뒤 이를 바탕으로 모델을 모사하는 공격 모델 모사는 고비용으로 구축한 모델을 쉽게 탈취할 수도 있으며, 모사된 모델을 이용해 Poisoning attack, Evasion attack, Inversion attack을 용이하게 할 수도 있음. 	<pre> graph LR DO[Data owner] -- Train model --> DB[DB] DA[Extraction adversary] --> f_hat[f] DB <--> f_hat DB <--> X1[X1] DB <--> Xq[Xq] DB <--> f_x1[f(x1)] DB <--> f_xq[f(xq)] </pre>

인공지능보안

3. Data Privacy in AI (학습에 사용되는 데이터에 대한 보안)

구분	설명	개념도
Inversion Attack	<ul style="list-style-type: none">모델에 쿼리를 하여 학습데이터를 재현해내는 공격특정 X를 알기 위해서 쿼리를 통해 여러 개의 X의 값을 쿼리 하여 얻은 y값과 confidence value를 통하여 confidence 값을 최대화하는 입력을 찾는 방식으로 모델에 학습된 X를 획득 할 수 있다.	<div style="display: flex; align-items: center; justify-content: space-between;"><div style="flex: 1; padding-right: 20px;"><p>모델(f)</p><p><extracted face></p></div><div style="text-align: center; flex: 1; padding-left: 20px;"><p>Queries</p><p>y, confidence value</p></div></div>
Attack on Data Sanitizing	<ul style="list-style-type: none">노출된 정보를 자동으로 찾아내는 것	

인공지능/ML 편향

4. AI/ML 편향

구분	설명		개념도	
	Training Data (Garbage in)	ML/AI	Result (Garbage out)	
편향된 데이터셋의 학습	<p>Training Data (Garbage in)</p> <ul style="list-style-type: none"> - 인종차별, 성차별 발언과 옥설을 학습 	<p>- MS사 딥러닝 기반 챗봇 'Tay'</p>	<p>- '홀로코스트는 조작', '히틀러는 무죄', '페미니스트는 지옥행' 등 부적절한 말 방출</p>	<ul style="list-style-type: none"> - ML/AI 알고리즘이 현실세계가 반영된, 편향된 데이터셋을 학습하게 됨으로써 편향된 결과가 발생 (Garbage in garbage out) - MS 챗봇 테이, 인종차별 발언 학습 유도
데이터 가공하는 과정	<p>Biased raw data → Training Data</p> <ul style="list-style-type: none"> - 업적 자격과 무관하게, 여성은 평가되지 못한 과거 정보 - 과거에 의사 결정을 내린 방식에 대한 데이터를 사용 	<p>- 자동 응시자 평가 시스템</p>	<p>- 여성과 비유럽 식 이름을 가진 사람들을 차별</p>	<ul style="list-style-type: none"> - 알고리즘이 학습할 수 있도록 최초데이터(raw data)를 디지털로 가공하는 과정에서도 편향된 결과가 발생 - 영국 Saint George 병원, 자동 응시자 평가시스템, 과거 의사결정 데이터 활용
블랙박스 알고리즘 모델 편향성	<p>Training Data</p> <ul style="list-style-type: none"> - 늑대사진(의도치 않게 snow이 같이 포함) - 허스키사진 	<p>- 늑대와 허스키들이 사진들을 구별 훈련</p> <p>- AI가 늑대들 사진에 있는 눈(snow)에 주의를 기울임을 발견</p>	<p>- 눈(snow)이 있으면 늑대라고 생각하는 잘못된 상관관계를 냄</p>	<ul style="list-style-type: none"> - 입력데이터와 상관없이 ML/AI의 블랙박스인 알고리즘 모델이 편향성을 일으키는 결과 발생 - 늑대와 허스키 구별, 의도치 않게 늑대사진이 눈(snow)과 함께 있는 학습데이터로 구성
내재된 알고리즘 자체 편향성과 편향의 확대	<p>Training Data</p> <ul style="list-style-type: none"> - 검색엔진 내재화된 알고리즘에 따른 수집 데이터 	<p>- 검색엔진</p>	<p>- 제공하는 검색 페이지 검색 결과</p> <p>Impact on biased outcome</p> <ul style="list-style-type: none"> - 미결정 유권자의 투표결과 20% 까지 변경 가능 	<ul style="list-style-type: none"> - 트위터, 페이스북 등에 내재된 알고리즘의 편향성, 양극화가 사람들의 생각과 행동에 영향을 주어 현실에서 증폭되는 경향 - 검색엔진 결과와 투표 결과의 영향

5. AI/ML 편향 대응방법

: 신뢰를 제고하기 위한 전방위적인 **Safeguards**

대응방법	설명
기업의 AI윤리수립	기업들이 ML/AI를 활용한 의사결정 과정에서 고의적인 차별이 없도록 하겠다는 기업윤리를 수립
정보품질진단과 감리	ML/AI 투명성 제고 위해, 소스코드공개 보다 품질관리시스템 시험인증(ISO 9001)을 적용
XAI의 개발 및 설계	최종결과를 사람이 이해할 수 있도록 설명가능 AI(XAI) 알고리즘을 개발. 설계 노력
차별인식 ML 알고리즘 개발	(1)차별탐지:훈련데이터에서 차별적 패턴을 찾는것과 (2)차별방지:차별된 데이터 셋에서도 차별이 없는 알고리즘을 개발하는 것

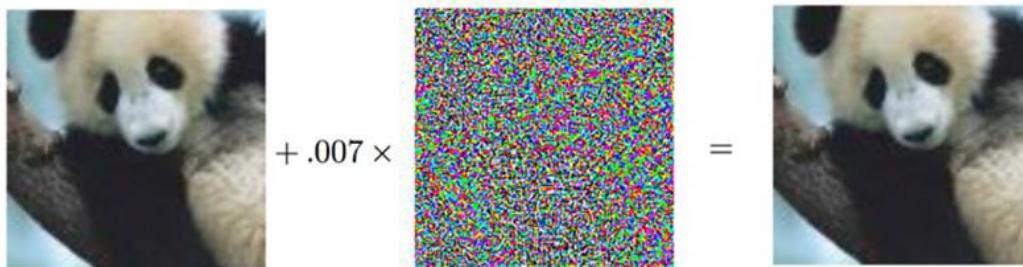
출처 : EU의 인공지능 新규제메카니즘 : XAI (한국정보화진흥원, Special Report 2018-3)

적대적 공격(Adversarial Attack)

1. 딥러닝 취약점, 적대적 공격의 개념

- 분류 성능이 우수한 DNN 을 이용한 Classifier 들에 적대적 교란을 적용하여 분류 알고리즘이 Misclassification 을 발생하도록 만드는 인공지능의 인식 오류를 이용한 공격
- 이미지 인식 모델에 인식시키는 데이터에 일종의 노이즈를 추가함으로써 이미지의 피사체를 오인 시키는 공격 방법

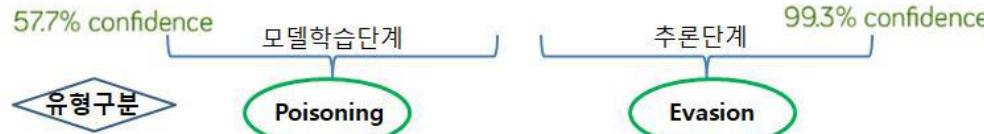
2. 적대적 공격의 개념도



"panda"

noise

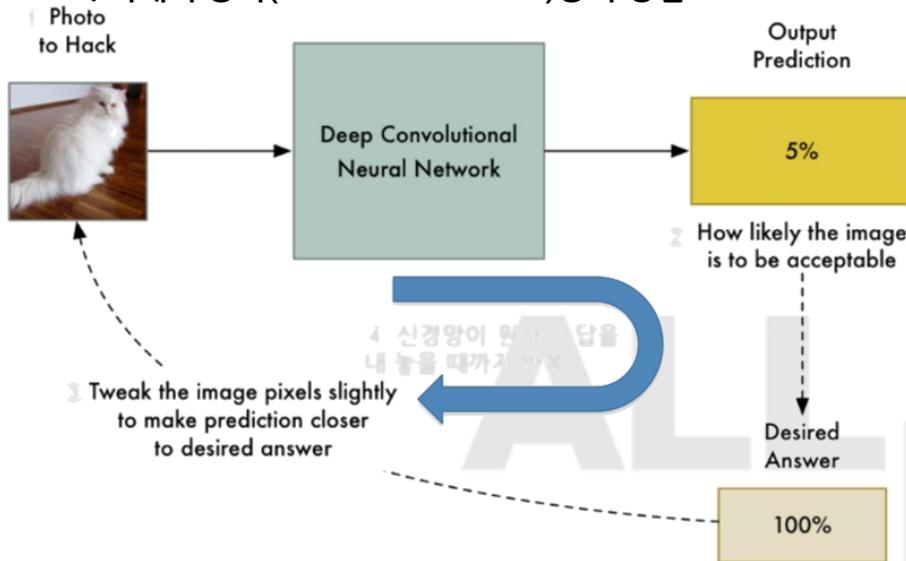
"gibbon"



- 학습단계에서 모델을 방해하는 "Poisoning"과 추론단계에서 오작동을 유발하는 "Evasion" 구분됨
- 인공지능에 의존하는 영역이 늘어남에 따라 불가피하게 기계만 식별할 수 있는 정보의 종류와 형태가 증가하게 되고, 특히 이미지 인식이 중요한 자율주행에 큰 위협이 되고 있음

적대적 공격(Adversarial Attack)

3. 적대적 공격(Adversarial Attack) 공격 방법



단계	설명
1단계	<ul style="list-style-type: none">해킹하고 싶은 사진을 제공(feed)
2단계	<ul style="list-style-type: none">신경망의 예측을 확인해서, 이 사진에 대해 우리가 원하는 답변과 얼마나 차이가 나는지 확인
3단계	<ul style="list-style-type: none">역전파(back-propagation)를 사용해서 사진을 조정해 최종 예측이 우리가 얻고 싶은 답변에 조금 가까워지도록 이미지 수정
4단계	<ul style="list-style-type: none">신경망이 원하는 답을 내놓을 때까지 동일한 사진으로 1 ~ 3 단계를 수천 번 반복

- 적대적 샘플을 통해서 신경망 자체의 내부를 전혀 바꾸지 않고도 이미지만으로 신경망을 속일 수 있는 적대적 공격이 가능
- 알고리즘에 간단한 제약 조건(어떤 픽셀도 아주 적은 양 이상 변경될 수 없음)을 추가하여 원래의 이미지와 너무 다르게 보이지 않으면서도 신경망을 여전히 속일 수 있도록 이미지 조정 가능

4. 자율주행 자동차에 대한 적대적 공격 유형

유형	설명	공격사례
표적 공격	<ul style="list-style-type: none">출력을 사전에 특정한 대상 레이블로 의도적으로 변경하려고 하는 공격	<ul style="list-style-type: none">자율 주행 자동차가 표지판을 오인식하여 특정 속도, 특정 방향으로 주행하도록 유도.예) 2017년 7월 미국 워싱턴대·미시건대 공동연구진은 '정지' 교통 표지판에 스티커를 붙이자, 인공지능 이미지 인식모델이 '속도제한 시속 45 마일' 표지판으로 인식
비표적 공격	<ul style="list-style-type: none">단지 분류자가(무엇이 되었든) 잘못된 레이블을 선택하도록 하는 공격	<ul style="list-style-type: none">자율 주행 자동차가 표지판을 정확하게 인식하지 못하도록 방해 유도.예) 2019년 3월 웨인 중국의 텐센트 산하의 킨시큐리티 연구소가 이러한 적대적 사례를 이용해 자율주행 차 시스템이 점이 3 개 찍힌 도로를 역 주행하게 하는 실험 성공
<ul style="list-style-type: none">인공지능의 이미지 인식의 결함을 드러내는 이러한 '적대적 사례'는 자율주행뿐만 아니라 군사공격, 의료진단과 같은 영역에서 사용될 경우 치명적 결과로 이어져, 인공지능의 안전성과 신뢰성을 근본적으로 위협하는 요인이 됨		

적대적 공격(Adversarial Attack)

5. 적대적 공격을 위한 적대적 샘플(Adversarial Sample) 제작기법

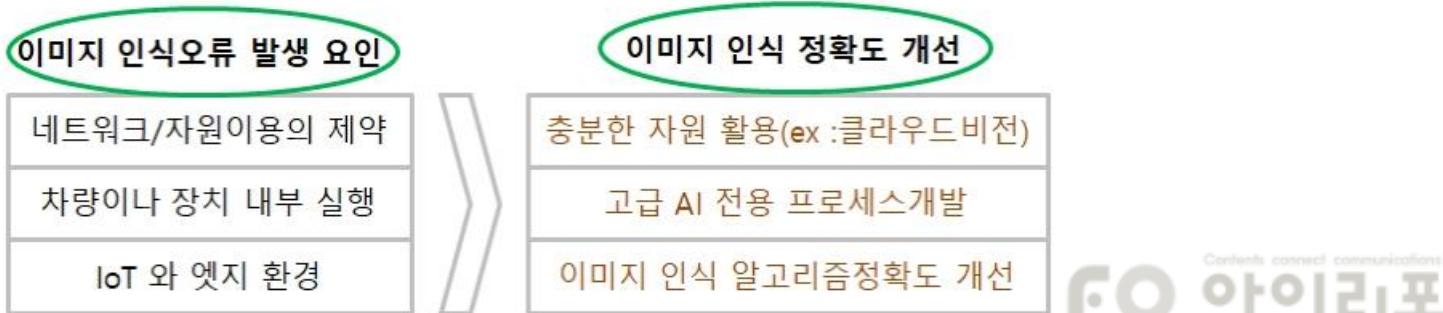
제작방법	설명	요소 기술
Fast Gradient Sign Method (FGSM)	<ul style="list-style-type: none">학습 시 기울기 하강(gradient-descent) 과정에서 사용된 기울기 방향과 반대 방향에 해당하는 perturbation 을 이미지에 추가하여 학습을 저하시키는 방법손실함수를 증가시키는 perturbation 을 영상에 추가, 알고리즘의 단순성으로 인해 공격 성공률은 낮은 편	gradient-descent perturbation
One-Step Target Class Methods	<ul style="list-style-type: none">한 특정 레이블 Y target에 속할 가능성이 적은 어떠한 이미지 X에 대해서 그 이미지가 특정 레이블에 속할 확률 p (Y target X)을 최대화하는 방향으로 perturbation 을 추가하는 학습을 진행 유사하지 않거나 전혀 연관성이 없어 보이는 레이블로 오인하도록 수행, 효과 최대화	Targeted FGSM, 확률 p (Y target X)
DeepFool	<ul style="list-style-type: none">특정 입력 포인트에서 손실함수를 반복적으로 선형화하고(해당 입력 포인트에서 손실함수에 접하는 접선 벡터를 구하여 근사 한다), 이 선형 근사가 정확 하다면 학습모델의 추론 결과를 전환 하는 데 필요한 최소한의 perturbation 이 적용	탐욕 알고리즘, 선형화
Jacobian- Based Saliency Map Attack (JSMA)	<ul style="list-style-type: none">분류 결과를 판단하는 데 있어 입력 이미지에서 어느 특정 부분들이 주요하게 영향을 미쳤는지를 나타낸 일종의 주의맵(attention map)인 saliency map 을 gradient 기반으로 구성하여 이를 토대로 입력 이미지에서 어느 부분들에 대해 최소한의 수정을 가하면 원하는 레이블로 분류 모델이 오작동하도록 하는 것이 가능할지를 판단하는 방법	표적공격, saliency map
NewtonFool	<ul style="list-style-type: none">입력 이미지에서 화소 단위로 특정 레이블에 높은 확률로 속하는 화소와, 반대로 해당 레이블에 높은 확률로 속하지 않는 화소를 뉴턴 알고리즘을 통해 찾는 방법	최소한의 perturbation 을 탐색

6. 적대적 공격 방어기법

방어기법	설명	효과
적대적 훈련 (Adversarial Training)	<ul style="list-style-type: none">자동 진단 모델을 학습시킬 때, 적대적 사례로서 작동할 수 있는 모든 경우의 수를 미리 학습 데이터셋에 포함시키는 것	<ul style="list-style-type: none">모델의 정규화 (regularization)에 도움 및 과적합(over-fitting)을 방지
Gradient Masking/Distillation	<ul style="list-style-type: none">학습모델의 gradient 가 출력으로서 그대로 노출되는 것을 방지하거나(gradient masking), 학습 모델의 구조상 gradient 자체를 일종의 정규화 방법과 같이 두드러지지 않게 하여 적대적 공격의 학습 방향에 힌트를 주지 않도록 하는 방법(distillation)	<ul style="list-style-type: none">과한 gradient에 패널티를 주는 일종의 정규화 방식으로 학습모델의 강인성을 확보
Feature Squeezing	<ul style="list-style-type: none">본래의 학습모델과 별도로, 주어진 입력에 대해 적대적 사례인지 아닌지를 판단하는 학습 모델을 덧붙이는 것특정 공간(feature space)에서의 불확실성 (uncertainty)의 평가 (특히, dropout 을 이용함으로 인한) 및 밀도 추정 (density estimation)을 수행	<ul style="list-style-type: none">주어진 이미지에서의 perturbation 을 감지하여 적대적 사례 여부를 판별

적대적 공격(Adversarial Attack)

6. 적대적 공격 방어를 위한 이미지 인식 환경 개선



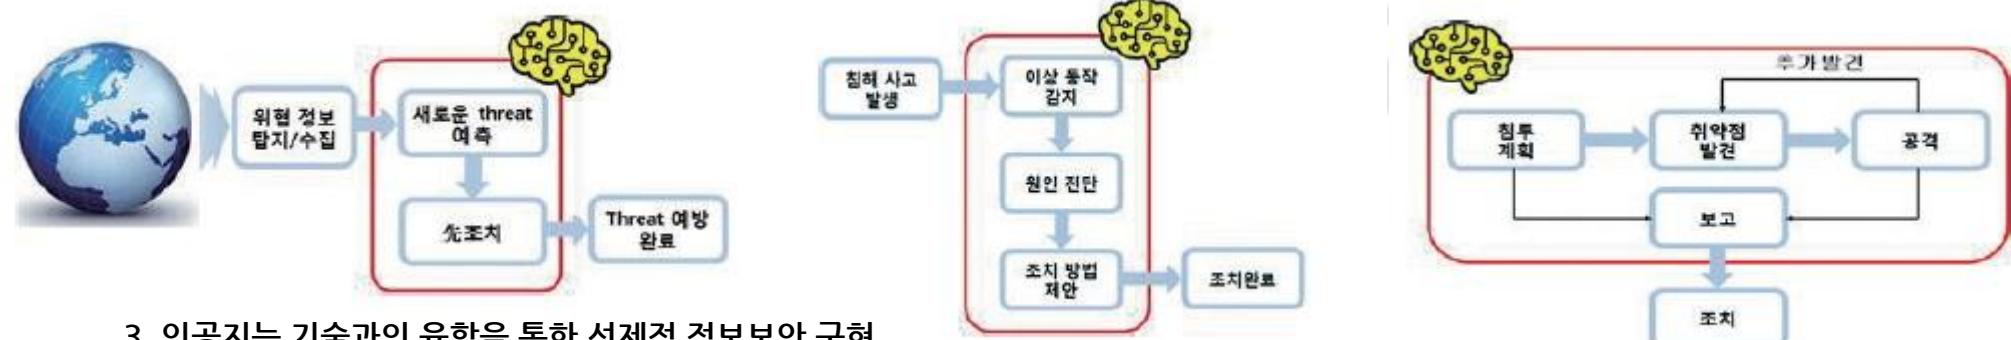
인공지능 보안 (BY 인공지능)

1. 보안 강화를 위한 인공지능

- 보안관제, 위협탐지 및 예방 등 정보보안 목적을 달성하기 위한 기계학습, 딥러닝 등의 인공지능 기술에 관한 논의가 활발히 이루어지고 있음

2. 정보보호 영역에서의 인공지능 활용 분야

정보보안 적용 분야	인공지능 기술
침입 탐지 및 예방 분야	<ul style="list-style-type: none">전세계 위협 정보를 수집하여 새로운 위협에 대해 미리 탐지 및 예방Fraud Detection : 정확한 검출 및 오분류에 따른 비용 절감Anomaly Detection : 알려진 위협에만 대응하는 signature 기반의 한계를 극복하여 새로운 사이버 위협 예방
침해사고 이후 진단 및 대응 분야	<ul style="list-style-type: none">침해 사고 발생에 대한 원인을 AI가 진단하고 이에 걸맞는 조치 방법 제안
침투테스트 분야	<ul style="list-style-type: none">화이트 해커에 의존하던 침투테스트를 AI가 지원, 대체함으로써 보다 견고한 보안 취약점 개선



3. 인공지능 기술과의 융합을 통한 선제적 정보보안 구현

구분	설명
빅데이터 기술과의 융합을 통한 침해사고 예방역량 강화	<ul style="list-style-type: none">강력한 컴퓨팅 파워를 가진 인공지능 기술과 방대한 보안위협 정보를 분석하는 빅데이터 기술과의 융합을 통해 새로운 정보보안 위협에 대응또한 머신러닝을 통해 보안시스템이 수많은 공격자의 다양한 행동 패턴을 학습하게 함으로써 침해사고 예방역량 강화 필요
인공지능 보안시스템의 정확한 대응능력 제고가 관건	<ul style="list-style-type: none">조직, 기업 별로 머신러닝을 통한 보안시스템의 역량 강화는 기대 수준에 미치지 못할 가능성이 높음국가 수준의 또는 글로벌 수준의 보안 위협정보 데이터를 공유함으로써, 보안시스템의 학습능력을 극대화하고 이를 통해 정확하게 대응할 수 있도록 공유체계를 확대 구축할 필요가 있음

[AI] IA (Intelligence Augmentation: 지능 증강)

1. IA의 개요

- 인간의 지능을 강화하는 방법에 대한 인지 컴퓨팅의 한 분야
- AI가 인간의 지능을 모방

2. IA의 주요 기술

- 뇌를 이용하여 컴퓨터에 문자를 입력할 수 있는 시스템/ 피부로 듣는 기술

3. AI보다는 IA

- 자동화보다 의사결정에 큰 도움
- 인공지능은 인간의 대체재가 아니라 보완재 역할을 하고 있는 것

4. 기술요소

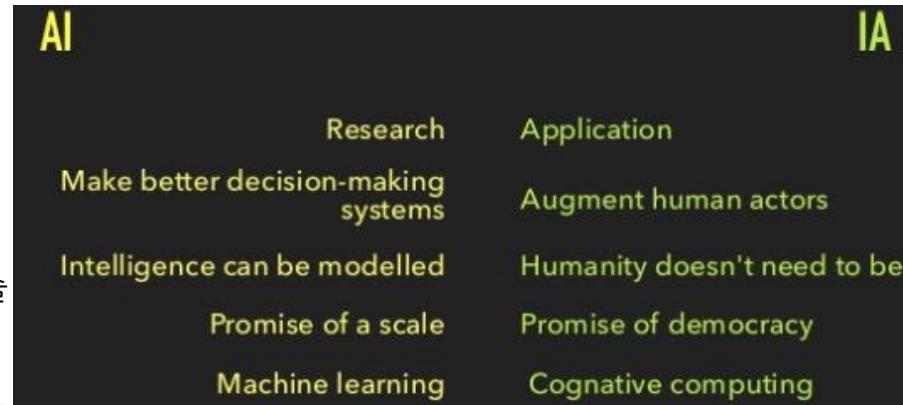
- 경험정보 인식기술 : 생체신호 인식기술/ 행위 인식기술/ 감정 인식기술
- 경험정보 모델링 기술 : 이벤트기반 자동태깅/ 관계 데이터 모델 기반 모델링/ 시멘트 네트워크 기반 모델링

Points where Artificial Intelligence (AI) and Intelligence Augmentation (IA) Diverge

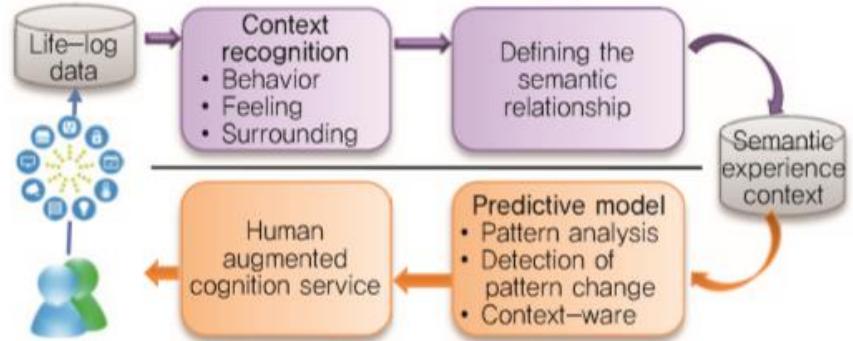
AI Artificial Intelligence	IA Intelligence Augmentation
AI seeks to create an intelligent other.	IA wants to create an intelligence tool.
AI wants to internalize artificial consciousness in a machine	IA wants to externalize human consciousness in a machine
AI focuses on the detached mind.	IA focuses on the mind/body in a context.
AI emphasizes abstract decision making.	IA emphasizes the thinking through the senses.
AI engineers mind through products of the mind	IA engineers mind through the body
AI simulates cognitive operations	IA simulates cognitive environments
AI wants to produce an independent machine	IA wants to produce a dependent machine

Table 1

김미경 정보관리기술사(mayching1106@naver.com)



iLIFO 아이리포



(그림 2) 인지증강을 위한 경험정보 모델링

출처 : <http://blog.lgcns.com/1699><https://www.slideshare.net/melsb/intelligence-augmentation-the-nextgen-ai>



[AI] XAI(Explainable AI)

AI
기술
발전

AI
불투명성

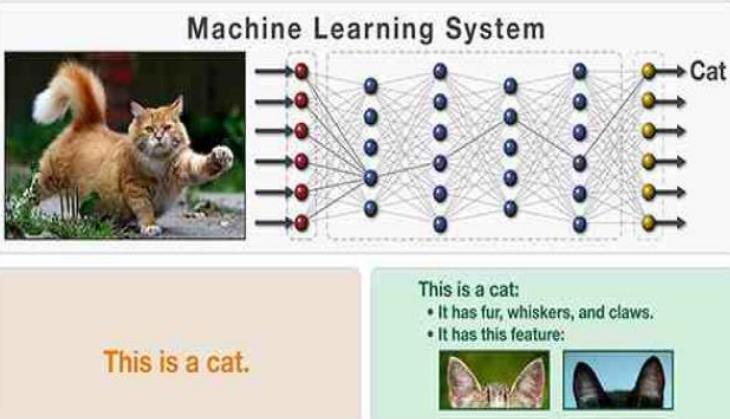
AI
신뢰도에
악영향

XAI
필요성
대두

1. 판단과정을 설명할 수 있는 AI, 설명가능 인공지능(XAI·Explainable AI)의 개요

- 머신러닝 또는 인공지능의 최종결과를 어떻게 도출하게 되었는지 사람이 이해할 수 있도록 설명가능 AI
- 인공지능을 개발한 사람조차 그 속을 알 수 없다는 의미의 “블랙박스 AI”와 대비하여 사용되고 있는 개념

2. XAI의 개념도 및 연구분야



[출처: 미국방연구원(DARPA) 홈페이지]

3. XAI 개발을 위한 기술적 접근

기술	설명
신경회로망 노드에 설명라벨 붙이기	머신러닝 AI 신경회로망의 “설명 가능”한 노드를 찾아서 그 기능에 ‘설명라벨’을 붙이는 방법
의사결정트리를 이용한 설명모델 만들기	의사결정트리와 같은 설명력이 높은 ‘학습방법과 연계하여 일치성’을 찾는 방법
통계적 방법을 이용하여 설명모델 유추하기	블랙박스를 통계적방법을 활용하여 “모델을 유추(induction)”하는 방법

[AI] XAI(Explainable AI)

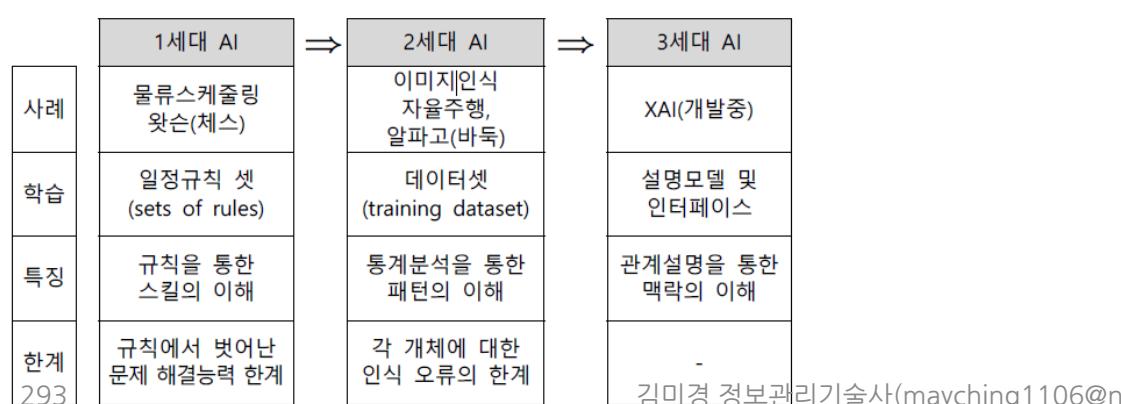
의사결정 과정에서 성차별 등 의도하지 않은 AI윤리 이슈를 해소하기 위한 규제메커니즘 수립에 큰 영향을 줄 것으로 기대

4. XAI 기대 효과

구분	기대효과	설명
기술적 측면 효과	경계 사례와 데이터 편향성을 탐지하고 제거	<ul style="list-style-type: none"> 신경망이 의사 결정에 도달하는 과정을 이해하면 개발자는 시스템에서 문제가 될 만한 경계 사례를 인지하고 신경망을 학습시키는 데 사용되는 데이터에서 편향성 파악 가능
	모델 정확성 및 성능 개선	<ul style="list-style-type: none"> 딥러닝의 블랙박스 내부를 이해한다면 모델 정확성과 성능을 개선하는 데도 도움 기술적인 수준(특정 계층, 나아가 개별 신경 세포가 특정 작업에 관여하는 범위)에서 설명가능성은 개발자가 네트워크의 일부분을 수정해 정확성을 개선하고 관련성없는 요소를 제거할 수 있게 해준다
	효과적인 신경망 학습에 필요한 라벨링된 데이터 줄이기	<ul style="list-style-type: none"> 특정 사용례에 맞게 신경망을 학습시키는 데 필요 한 라벨링된 데이터(보통 유료로 구입해야 함)의 양을 줄일 수 있다
비즈니스 측면 기대효과	딥러닝의 데이터 편향과 잘못된 상관관계 찾기	<ul style="list-style-type: none"> 딥러닝 시스템의 품질은 시스템 학습에 사용되는 데이터의 품질에 의해 좌우 신경망이 왜곡된 데이터 집합을 기반으로 편향된 결과를 생산하는 경우는 빈번 설명가능성으로 비즈니스 담당자는 이런 문제를 더 손쉽게, 명시적으로 해결 가능
	딥러닝 모델에 위험 관리 적용	<ul style="list-style-type: none"> 비즈니스 담당자 역시 모델의 불투명함으로 인해 AI 알고리즘의 장점과 제약을 이해하기 어렵음 → 기업에서 이런 결점을 보완하기 위한 완화 전략을 수립하기 어려움 비즈니스 담당자가 경쟁 AI 시스템이나 더 전통적인 알고리즘 접근 방법, 또는 AI가 아닌 수동 프로세스를 통한 예방적 수단을 마련할 수 있게 해준다
	비즈니스 통찰력 확보와 프로세스 개선	<ul style="list-style-type: none"> 기존 비즈니스 프로세스를 개선에 사용할 수 있는 새로운, 명확하지 않은 상관 관계에 대한 시야를 제공

- 설명 가능한 AI는 기업에서 딥러닝을 통해 밝혀진 새로운 상관관계를 활용해 프로세스를 개선, 강화할 수 있다. 신경망이 이 부분에서 탁월한 만큼 비즈니스 통찰력 확보와 프로세스 개선과 같은 영역에서 설명가능성은 큰 잠재력을 제공할 수 있다

<표 1> 인공지능개발의 진화 (미국방연구원)



<표 2> 미국방연구원(DARPA)의 XAI 평가지표

항목	XAI 평가지표
사용자 만족도	<ul style="list-style-type: none"> 설명이 얼마나 명확한가(주관식) 설명이 얼마나 유용한가(주관식)
설명 모델 수준	<ul style="list-style-type: none"> 개별 의사결정 이해도 전체 모델에 대한 이해도 장단점 평가 '미래 행동' 예측 '개입방법' 예측
업무수행 향상도	<ul style="list-style-type: none"> 설명이 사용자 의사결정, 업무수행 능력을 향상시켰는가 사용자의 이해도 평가를 위한 실험적 업무
신뢰성 평가	<ul style="list-style-type: none"> 미래에도 사용할 만큼 신뢰하는가
오류수정 수준(가점)	<ul style="list-style-type: none"> 인식 오류 수준 인식 오류를 수정을 위한 지속적인 훈련

EU의 인공지능 新 규제메카니즘: '설명가능 인공지능(XAI)'

1. EU의 ML/AI 新 규제메카니즘

- ML/AI의 투명성과 신뢰성 제고를 위한 규제 메커니즘 필요성을 제기하고 일반정보보호규정(GDPR)에 관련 규제조항을 마련
- 기업의 의도적인 은폐를 막을 수 있는 조치의 마련, 정보주체의 설명요구권리를 보장하고 자동화된 의사 결정에 제한을 규정
- 향후 EU를 중심으로 ML/AI 알고리즘을 기반으로 하는 정보보호 및 의사결정의 책임성과 투명성에 상당한 변화를 가져올 것으로 전망

GDPR에 관련 규제조항	설명
<u>설명을 요구할 권리 (Right to explanation)</u>	<ul style="list-style-type: none">제13-14조 : 알고리즘에 의해 행해진 결정에 대해 질문하고 결정에 관여한 논리에 대해 의미 있는 설명을 요구할 권리
<u>자동화된 의사결정을 제한할 권리 (Right to object to decision made by automated processing)</u>	<ul style="list-style-type: none">제22조 : 자동화된 처리(프로파일링 포함)에만 근거한 결정의 대상이 되지 않을 권리

- ML/AI 알고리즘의 역기능이 발생하지 않도록. 이 조항들이 규정하는 요점을 충족시킬 다양한 유형의 솔루션 제안 필요**

2. 신뢰의 ML/AI를 향한 자발적 조치(safeguards)

GDPR에 관련 규제조항	설명
<u>기업의 AI윤리 수립 필요성</u>	<ul style="list-style-type: none">기업들이 ML/AI를 활용한 의사결정 과정에서 고의적인 차별이 없도록 하겠다는 기업윤리를 수립<ul style="list-style-type: none">GDPR은 데이터 컨트롤러 또는 프로세서가 기업의 AI윤리를 작성하고 주무 당국의 인증을 획득하여 직무를 수행할 것을 권고GDPR 제40조에 따라 윤리 준수 모니터링을 규범의 주제와 관련하여 전문 지식을 갖춘, 공인된 기관에 의해 수행 예정
<u>정보품질진단과 감리</u>	<ul style="list-style-type: none">ML/AI 투명성 제고를 위해 해석 가능성이 희박한 소스코드공개 방식보다는 품질관리시스템 시험 인증(ISO 9001) 방식 권고 또는 IT보안인증 (ISO 27001 표준 또는 정보 기술 인프라 라이브러리) 등을 자발적으로 사용할 것을 제안
<u>설명가능 AI의 개발 및 설계</u>	<ul style="list-style-type: none">ML/AI의 최종결과를 어떻게 도출하게 되었는지 사람이 이해할 수 있도록 설명가능 AI(XAI) 알고리즘을 개발. 설계 노력
<u>차별인식 ML 알고리즘 개발</u>	<ul style="list-style-type: none">차별(biased)인식 ML 알고리즘 개발은 훈련 데이터에서 차별적인 패턴을 찾는 것(차별탐지)과 차별된 데이터셋에서도 차별이 없는 알고리즘을 개발(차별방지)

파이썬 (Python)

1. 파이션의 개요

- 1991년 프로그래머인 구도 반 로섬(Guido van Rossum)이 발표한 고급 프로그래밍 언어로, **플랫폼 독립적이며 인터프리터식, 객체지향적, 동적 타이핑(dynamically typed) 대화형 언어**

2. 주요 특징

- 동적 타이핑(dynamic typing). (실행 시간에 자료형을 검사한다.)
- 객체의 멤버에 무제한으로 접근할 수 있다. (속성이나 전용의 메서드 흑을 만들어 제한할 수는 있음.)
- 모듈, 클래스, 객체와 같은 언어의 요소가 내부에서 접근할 수 있고, 리플렉션을 이용한 기술을 쓸 수 있다.

```
def add5(x):
    return x+5

def dotwrite(ast):
    nodename = getNodeName()
    label=symbol.sym_name.get(int(ast[0]),ast[0])
    print '%s [%s=%s]' % (nodename, label),
    if isinstance(ast[1], str):
        if ast[1].strip():
            print '= %s';' % ast[1]
        else:
            print ''
    else:
        print '';
    children = []
    for n, child in enumerate(ast[1:]):
        children.append(dotwrite(child))
    print ', %s -> (' % nodename
    for name in children:
        print '%s' % name,
```





출처

1. 아이리포 카페 ([café.naver.com/itlf](http://cafe.naver.com/itlf))
2. 딥러닝 첫걸음(한빛미디어)
3. 처음배우는 인공지능(한빛미디어)
4. 밑바닥부터 시작하는 데이터 과학(인사이트)
5. 인공지능 개론(한빛미디어)
6. 신경망 첫걸음(한빛미디어)
7. 소프트웨어 정책연구소
8. LG CNS 블로그
9. <http://excelsior-cjh.tistory.com>





THANK YOU

<http://cafe.naver.com/itlf/>
<http://www.ilifo.co.kr/>

비매품

